Modele analizy danych

Podręcznik do przedmiotu

Tomasz Rodak

2026-11-09

Spis treści

Przedmowa **1**
Kod w książce . . . 1
Literatura . . . 1
Konwencje notacyjne . . . 1

I. Fundamenty **3**

1. Czym jest model? **5**
1.1. Pojęcie modelu . . . 5
1.2. Model w analizie danych . . . 6
1.3. Uczenie nadzorowane i nienadzorowane . . . 7
1.4. Regresja i klasyfikacja . . . 8
1.5. Probabilistyczny opis danych . . . 10
1.5.1. Regresja . . . 13
1.5.2. Klasyfikacja . . . 15
1.6. Jak mierzymy jakość predykcji . . . 16
1.6.1. Błąd redukowalny i nieredukowalny . . . 18
1.7. Dwa cele modelowania: predykcja i wnioskowanie . . . 18
1.8. Trening modelu . . . 21
1.9. Metody parametryczne i nieparametryczne . . . 23
1.10. Kompromis między interpretowalnością a dokładnością . . . 26
Zadania . . . 28

2. Ryzyko i predyktory optymalne **31**
2.1. Ile kosztuje reguła przewidywania? . . . 31
2.2. Ryzyko liczone w dwóch krokach . . . 32
2.3. Minimalizacja punktowa . . . 34
2.4. Regresja: najlepsza prognoza liczbowa . . . 35
2.4.1. Dlaczego średnia? . . . 35
2.5. Klasyfikacja: najlepsza odpowiedź tak lub nie . . . 37
2.5.1. Najbardziej prawdopodobna klasa . . . 37
2.5.2. Jeden schemat, dwa zastosowania . . . 38
2.6. Dlaczego optimum ma dodatnie ryzyko? . . . 39
2.7. Inna strata, inna najlepsza prognoza . . . 39
2.7.1. Strata absolutna i mediana . . . 40
2.7.2. Którą stratę wybrać? . . . 40
2.8. Od prawdopodobieństw do decyzji . . . 41
2.8.1. Próg decyzyjny . . . 41
2.9. Od znanego rozkładu do uczenia z danych . . . 42
2.10. Rozszerzenia: inne decyzje i ciągłe cechy . . . 43
Uwagi bibliograficzne . . . 45
Zadania . . . 45

3. Metoda k najbliższych sąsiadów **49**
3.1. Uśrednianie lokalne . . . 49
3.2. Reguła k najbliższych sąsiadów . . . 51
3.3. Co znaczy „blisko” . . . 52
3.4. Rola liczby sąsiadów . . . 54
3.4.1. Gdy danych przybywa . . . 56
3.5. Przekleństwo wymiarowości . . . 56
3.5.1. Otoczenie przestaje być lokalne . . . 56
3.5.2. Skutek dla klasyfikacji . . . 57
3.5.3. Co z tego wynika . . . 58
3.6. Metoda k-NN w praktyce . . . 58
3.7. Rozszerzenie: geometria wysokich wymiarów . . . 59
3.7.1. Objętość poza kulą wpisaną i blisko brzegu . . . 59
3.7.2. Odległości przestają się różnić . . . 60
3.8. Rozszerzenie: zbieżność do optimum . . . 60
Uwagi bibliograficzne . . . 63
Zadania . . . 63

4. Kompromis obciążenie–wariancja **67**
4.1. Błąd uczący a ryzyko . . . 67
4.2. Zbiór uczący jest losowy . . . 69
4.3. Obciążenie i wariancja estymatora . . . 69
4.4. Rozkład oczekiwanego błędu predykcji . . . 71
4.5. Ilustracja: k-NN i regresja wielomianowa . . . 72
4.6. Błąd aproksymacji i błąd estymacji . . . 74
4.7. Krzywe uczenia . . . 75
4.8. Co pomaga zmniejszyć błąd . . . 77
4.9. Obciążenie i wariancja w klasyfikacji . . . 77
4.10. Rozszerzenie: porównanie dwóch rozkładów błędu . . . 79
4.11. Rozszerzenie: tempo uczenia w wielu wymiarach . . . 80
Uwagi bibliograficzne . . . 80
Zadania . . . 81

5. Ocena modeli w praktyce **85**
5.1. Dopasowanie, wybór i ocena . . . 85
5.2. Zbiór testowy . . . 86
5.2.1. Niepewność oszacowania . . . 86
5.2.2. Porównanie dwóch modeli . . . 87
5.2.3. Cena odłożenia danych . . . 87
5.3. Zbiór walidacyjny . . . 88
5.4. Walidacja krzyżowa . . . 89
5.4.1. Co jest uczone i co jest oceniane . . . 90
5.4.2. Ile części . . . 90
5.4.3. Błąd standardowy walidacji krzyżowej . . . 91
5.4.4. Walidacja krzyżowa w klasyfikacji . . . 91
5.5. Wyciek informacji . . . 92
5.6. Selekcja modelu a ocena modelu . . . 93
5.6.1. Mały rachunek optymizmu . . . 94
5.6.2. Wynik zwycięzcy, jego ryzyko i najlepsze ryzyko . . . 94
5.6.3. Wybór przez CV i osobny test . . . 95
5.6.4. Zagnieżdżenie krok po kroku . . . 96
5.6.5. Co uśredniamy i jaki model zostaje . . . 96

5.6.6. Jak duży może być efekt wyboru . . . 98
5.7. Strojenie hiperparametrów . . . 99
5.8. Ocena modeli w praktyce . . . 99
5.8.1. Przygotowanie potoku . . . 100
5.8.2. Ocena procedury wyboru . . . 100
5.8.3. Końcowy wybór i dopasowanie . . . 100
5.8.4. Osobny wariant: reguła jednego błędu standardowego . . . 101
5.9. Krzywe uczenia z danych . . . 101
5.10. Bootstrap . . . 102
5.11. Rozszerzenie: porównania sparowane . . . 104
5.12. Rozszerzenie: LOOCV i liniowe wygładzanie . . . 105
5.13. Rozszerzenie: co dokładniej szacuje CV . . . 106
5.13.1. Co szacuje walidacja krzyżowa . . . 106
5.13.2. Ograniczenia prostych oszacowań niepewności . . . 108
5.14. Rozszerzenie: bootstrapowe oszacowania ryzyka . . . 108
Uwagi bibliograficzne . . . 110
Zadania . . . 110

II. Modele liniowe **115**

6. Regresja liniowa **117**
6.1. Model liniowy . . . 117
6.2. Metoda najmniejszych kwadratów . . . 118
6.2.1. Regresja względem trzech mediów . . . 120
6.2.2. Zapis macierzowy . . . 120
6.2.3. Reszty i dźwignie . . . 121
6.3. Własności estymatora OLS . . . 122
6.3.1. Wariancja predykcji . . . 123
6.3.2. Estymacja wariancji błędu . . . 124
6.3.3. Twierdzenie Gaussa–Markowa . . . 124
6.4. Jakość dopasowania . . . 125
6.5. Wnioskowanie o parametrach . . . 126
6.5.1. Błędy standardowe i przedziały ufności . . . 126
6.5.2. Test t i p-wartość . . . 127
6.5.3. Test F . . . 128
6.5.4. Przedział dla średniej i przedział predykcji . . . 129
6.6. Cechy jakościowe . . . 130
6.7. Interakcje i nieliniowość . . . 131
6.8. Diagnostyka modelu . . . 132
6.8.1. Brak liniowości . . . 132
6.8.2. Skorelowane błędy . . . 134
6.8.3. Heteroskedastyczność . . . 134
6.8.4. Obserwacje odstające i wpływowe . . . 136
6.8.5. Współliniowość . . . 137
6.9. Rozszerzenie: geometria i obliczanie MNK . . . 138
6.9.1. Rzut ortogonalny . . . 138
6.9.2. Macierz daszkowa . . . 139
6.9.3. Obliczanie estymatora . . . 139
6.10. Rozszerzenie: własności OLS i podstawy wnioskowania . . . 140
6.10.1. Macierz kowariancji estymatora . . . 140
6.10.2. Suma kwadratów reszt . . . 140

6.10.3. Optymalność wśród estymatorów liniowych . . . 141
6.10.4. Rozkłady przy normalnych błędach . . . 141
6.10.5. Rozkład statystyki F . . . 142
6.11. Rozszerzenie: rachunek diagnostyki . . . 142
6.11.1. Reszty, odległość Cooka i VIF . . . 142
6.11.2. Błędy skorelowane i estymator kanapkowy . . . 143
Uwagi bibliograficzne . . . 144
Zadania . . . 145

7. Selekcja i regularyzacja **149**
7.1. Dlaczego mniej predyktorów bywa lepiej . . . 149
7.2. Selekcja podzbioru predyktorów . . . 150
7.2.1. Przegląd zupełny . . . 150
7.2.2. Metoda schodów w przód i wstecz . . . 151
7.3. Kryteria wyboru modelu . . . 152
7.3.1. Skorygowany współczynnik determinacji . . . 152
7.3.2. Kryterium Cp Mallowsa . . . 152
7.3.3. AIC i BIC . . . 153
7.3.4. Walidacja krzyżowa i cel wyboru . . . 154
7.4. Regresja grzbietowa . . . 154
7.4.1. Dlaczego skala ma znaczenie . . . 154
7.4.2. Rozwiązanie i mechanizm ściągania . . . 155
7.5. LASSO i geometria regularyzacji . . . 155
7.5.1. Kara bezwzględna i dokładne zera . . . 155
7.5.2. Ścieżki współczynników na Credit . . . 156
7.5.3. Kara jako budżet . . . 157
7.5.4. Co oznacza wybranie cechy . . . 157
7.6. Dobór regularyzacji i porównanie metod . . . 158
7.6.1. Kandydaci i role danych . . . 158
7.6.2. Krzywe błędu i reguła jednego błędu standardowego . . . 159
7.6.3. Końcowa ocena i model do używania . . . 160
7.7. Rozszerzenie: geometria ściągania i efektywne stopnie swobody . . . 161
7.7.1. Kierunki o różnej dokładności . . . 162
7.7.2. Macierz wygładzania i stopnie swobody . . . 162
7.8. Rozszerzenie: obliczanie LASSO przez aktualizację współrzędnych . . . 163
Uwagi bibliograficzne . . . 163
Zadania . . . 164

8. Regresja logistyczna **167**

9. Uogólnione modele liniowe i regresja Poissona **169**

III. Podejście probabilistyczne **171**

10. Paradygmat bayesowski **173**

11. Modele generatywne: LDA, QDA i naiwny Bayes **175**

IV. Poza liniowość **177**

12. Perceptron wielowarstwowy i propagacja wsteczna **179**

13. Maszyny wektorów nośnych **181**

V. Uczenie nienadzorowane **183**

14. Analiza składowych głównych **185**

15. Grupowanie: k-średnich, GMM i algorytm EM **187**

Bibliografia **189**

Przedmowa

Podręcznik powstaje na bazie kursu *Modele analizy danych* prowadzonego na studiach magisterskich kierunku Analiza Danych. Materiał wykładowy z lat poprzednich został potraktowany jako punkt wyjścia, ale jest pisany na nowo: część wątków rozszerzono, część przeredagowano, dodano nowe przykłady i ćwiczenia.

Kod w książce

Fragmenty kodu są w pełni reprodukowalne: wszystkie losowania mają ustalone ziarno. Kod każdego rysunku można rozwinąć i skopiować. Do jego uruchomienia wystarczy Python 3.12 z pakietami `numpy`, `scipy`, `pandas`, `matplotlib`, `scikit-learn` i `statsmodels`. Pliki z danymi, z których korzystają przykłady, są w katalogu `dane/` repozytorium książki.

Literatura

Pierwsze dwie pozycje reprezentują ujęcie statystyczne, dwie kolejne – probabilistyczne, w dużej mierze oparte na metodach bayesowskich.

- **ISLP** (James i in. 2023) – podstawowy podręcznik uzupełniający, z przykładami w Pythonie.
- **ESL** (Hastie i in. 2009) – szerszy zakres i głębsze, bardziej precyzyjne ujęcie tego samego materiału.
- **PRML** (Bishop 2006) i **PML** (Murphy 2022) – uczenie maszynowe budowane konsekwentnie na modelach probabilistycznych i wnioskowaniu bayesowskim.
- Devroye i in. (1996) i Györfi i in. (2002) – teoria klasyfikacji i regresji nieparametrycznej dla Czytelników zainteresowanych ścisłymi dowodami.

Konwencje notacyjne

Oznaczenie	Znaczenie
$\mathbb{R}$	zbiór liczb rzeczywistych
$\mathbf{x}$, $\mathbf{X}$	wektor cech (mała pogrubiona), macierz projektowa lub wektor losowy cech (duża pogrubiona)
Y, y	zmienna objaśniana i jej realizacja
$\mathbb{E}$, $\mathbb{P}$	wartość oczekiwana, prawdopodobieństwo
Var, Cov	wariancja, kowariancja
$\mathcal{N}(\mu, \sigma^2)$	rozkład normalny
$\mathbb{1}(\cdot)$	funkcja wskaźnikowa
$L(y, a)$, $R(f)$	funkcja straty, ryzyko predyktora

Oznaczenie	Znaczenie
f^*, g^*	predyktor optymalny, klasyfikator bayesowski
$\hat{\cdot}$	wielkość estymowana z danych
n, p	liczba obserwacji, liczba cech
$\mathcal{D}$	zbiór danych, $\{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)\}$

Rozkład warunkowy zapisujemy $Y \mid \mathbf{X} = \mathbf{x}$, a wartości oczekiwane względem niego – $\mathbb{E}[\cdot \mid \mathbf{X} = \mathbf{x}]$.

Część I.

Fundamenty

1. Czym jest model?

1.1. Pojęcie modelu

Ogólny termin *model* oznacza abstrakcyjny, uproszczony obraz pewnego fragmentu rzeczywistości. Prostym przykładem jest mapa – model geograficzny reprezentujący terytorium. Uproszczenie sprawia, że model nie jest wierną kopią rzeczywistości, lecz w pewien sposób ją zniekształca. Jest ono jednak konieczne: model doskonale wierny musiałby być kompletną kopią modelowanej rzeczywistości, a wskutek tego byłby równie przeładowany nieistotnymi szczegółami i równie trudny do zrozumienia jak ona sama.

Model jest więc kompromisem między wiernością a użytecznością – narzędziem poznawczym, które pozwala lepiej zrozumieć rzeczywistość właśnie dzięki temu, że ją upraszcza. Myśl tę wyraził George Box (Box 1976), a powtarzane dziś przy tej okazji powiedzenie brzmi: „wszystkie modele są błędne, ale niektóre są użyteczne" (Box i Draper 1987).

Uproszczenie ma jeszcze jedną konsekwencję. Ponieważ każdy model pomija pewne aspekty rzeczywistości, żaden nie jest jej doskonale wiernym obrazem. Może być natomiast mniej lub bardziej trafny oraz użyteczny w określonym kontekście. Doskonała wierność nie może więc stanowić praktycznego kryterium oceny modelu. Zastępują ją kryteria trafności, zakresu stosowalności i użyteczności.

Poniższa lista zbiera własności, które w praktyce charakteryzują dobry model.

- **Celowość.** Model nie powstaje bez określonego celu – jest projektowany pod konkretne pytanie lub klasę zadań. Ten sam obiekt rzeczywisty, na przykład miasto, ma zupełnie inny model dla urbanisty, inny dla epidemiologa, a jeszcze inny dla nawigacji satelitarnej.

- **Selektywność i jawne granice.** Model określa, co znajduje się wewnątrz analizowanego systemu, a co zostaje pominięte. Przebieg tej granicy jest wyborem badacza i powinien być przedstawiony wprost – to, co model pomija, może później ujawnić się jako źródło jego błędu.

- **Zachowanie istotnych relacji.** Choć model odrzuca wiele szczegółów, powinien zachowywać te własności i relacje między elementami, które są istotne ze względu na jego cel. Mapa drogowa powinna na przykład poprawnie przedstawiać połączenia między miejscami, ale nie musi wiernie oddawać wszystkich odległości ani kształtów terenu. O wartości modelu decyduje więc nie liczba uwzględnionych szczegółów, lecz trafność zachowanej struktury.

- **Użyteczność.** Dobry model pozwala wykonać zadanie, do którego został zbudowany: opisać lub wyjaśnić zjawisko, dokonać przewidywania albo przeprowadzić eksperyment typu *„co, jeśli…"* bez ponoszenia kosztów i ryzyka działania w świecie rzeczywistym.

- **Redukcja złożoności poznawczej.** Model sprowadza złożoność otoczenia do rozmiaru, który człowiek lub komputer jest w stanie przetworzyć i zrozumieć.

- **Ograniczony zakres stosowalności.** Każdy model działa w określonym zakresie i przy pewnych założeniach. Nowe dane lub zmiana warunków mogą ujawnić jego ograniczenia i wymusić jego modyfikację. Modelowanie jest zatem procesem iteracyjnym, a nie jednorazowym aktem.

1.2. Model w analizie danych

W analizie danych *modelem* nazywamy sformalizowany opis prawidłowości dotyczących badanego zjawiska, konstruowany i oceniany na podstawie danych. Model nie opisuje bezpośrednio całej rzeczywistości, lecz wybrane, zarejestrowane cechy badanych obiektów oraz relacje między nimi. Pozwala przejść od zbioru pojedynczych obserwacji do bardziej ogólnego opisu, który można zastosować również do nowych przypadków.

Najczęściej model opisuje zależność między:

- **zmiennymi wejściowymi**, nazywanymi również cechami;
- **zmienną wyjściową**, nazywaną zmienną objaśnianą, odpowiedzią albo zmienną docelową.

Działanie modelu możemy schematycznie zapisać jako

$$\hat{y} = \hat{f}(\mathbf{x}),$$

gdzie $\mathbf{x}$ oznacza zestaw cech opisujących obiekt, a $\hat{y}$ – wynik zwracany przez model. Daszek zaznacza, że mamy do czynienia z wielkością wyznaczoną z danych: $\hat{f}$ jest zależnością odtworzoną na ich podstawie, a nie rzeczywistym mechanizmem badanego zjawiska. Obserwowany rzeczywisty wynik (*ground truth*) będziemy oznaczać przez y. Przykładowo $\mathbf{x}$ może zawierać wiek, masę ciała i wyniki badań pacjenta, natomiast y może oznaczać obecność choroby.

W analizie danych zmienne wejściowe nie muszą jednoznacznie wyznaczać obserwowanego wyniku, ponieważ zwykle nie zawierają pełnej informacji o badanym zjawisku. Dwóch pacjentów o takich samych wartościach zarejestrowanych cech może mieć różny stan zdrowia: u jednego rozpoznano chorobę, u drugiego nie. Wynika to między innymi z wpływu czynników nieuwzględnionych w danych, błędów pomiarowych oraz przypadkowej zmienności badanego zjawiska.

Nie oznacza to jednak, że sam model musi być niedeterministyczny. Model jest zwykle funkcją: dla tych samych wartości wejściowych zwraca zawsze ten sam wynik. Obiektom opisanym identycznym wektorem cech przypisze więc identyczną predykcję, chociaż ich rzeczywiste wyniki mogą się różnić.

Nie ma w tym sprzeczności, ponieważ wyniku zwracanego przez model nie należy traktować jako pewnego rozstrzygnięcia o pojedynczym przypadku: z wymienionych wyżej powodów takie rozstrzygnięcie jest nieosiągalne. Skoro obiekty o identycznych cechach mają różne wyniki, żadna pojedyncza odpowiedź nie będzie trafna dla wszystkich. Model opisuje raczej to, czego można się spodziewać wśród obiektów o danych cechach, niż to, co wydarzy się w pojedynczym przypadku. Przewidując czas hospitalizacji, może zwracać wartość przeciętną dla pacjentów o danym profilu, ewentualnie uzupełnioną o przedział, w którym wynik powinien się mieścić. Rozpoznając chorobę, może zamiast jednoznacznej diagnozy podawać oszacowanie ryzyka jej wystąpienia. W obu przypadkach model przypisuje pojedynczemu obiektowi opis regularności obserwowanej w całej grupie obiektów do niego podobnych.

Model może mieć postać wzoru matematycznego, zestawu reguł, drzewa decyzyjnego lub bardziej złożonej struktury obliczeniowej. Słowo *model* jest przy tym używane w dwóch powiązanych

znaczeniach. Może oznaczać **klasę modeli**, czyli zbiór dopuszczalnych zależności różniących się parametrami, a niekiedy także strukturą. Przykładowo regresja logistyczna określa ogólną postać zależności między cechami a prawdopodobieństwem wyniku, ale nie wyznacza jeszcze konkretnych wartości współczynników.

Słowo *model* może również oznaczać **model dopasowany**, czyli konkretny element wybranej klasy, otrzymany na podstawie danych. Regresja logistyczna dopasowana do danych pasażerów *Titanica* jest więc konkretnym modelem należącym do klasy modeli regresji logistycznej. Ma już określone zmienne wejściowe oraz konkretne wartości współczynników.

Model jest czymś innym od **algorytmu uczenia**. Algorytm uczenia jest procedurą, która na podstawie danych treningowych wybiera lub konstruuje konkretny model. W przypadku modeli parametrycznych, opisanych ustaloną liczbą współczynników (zob. Sekcja 1.9), polega to zazwyczaj na wyznaczeniu wartości parametrów, natomiast w innych przypadkach może obejmować również wybór struktury modelu. Proces prowadzący do otrzymania konkretnego modelu nazywamy jego dopasowaniem, uczeniem albo treningiem. Rezultatem tego procesu jest model dopasowany, który można następnie zastosować do nowych obserwacji.

Nie wszystkie modele w analizie danych opisują zależność między wejściem a z góry określonym wynikiem. Niektóre służą przede wszystkim do odkrywania struktury samych danych, na przykład podziału obserwacji na podobne grupy, wykrywania nietypowych przypadków albo redukcji liczby zmiennych. W każdym przypadku zadaniem modelu pozostaje jednak uchwycenie wybranych regularności w postaci prostszej i bardziej użytecznej niż pierwotny zbiór obserwacji.

1.3. Uczenie nadzorowane i nienadzorowane

Podstawowy podział problemów uczenia wynika ze sposobu sformułowania zadania oraz z roli, jaką pełnią w nim obserwowane zmienne. W **uczeniu nadzorowanym** wyróżniamy zmienne wejściowe oraz zmienną wyjściową, a celem jest opisanie zależności między nimi. Dla każdego badanego obiektu obserwujemy zatem parę

$$(\mathbf{x}_i, y_i),$$

gdzie $\mathbf{x}_i$ jest wektorem cech obiektu, a y_i – odpowiadającym mu wynikiem. Zbiór danych ma postać

$$\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)\}.$$

Taka struktura danych odzwierciedla przyjęty sposób opisu zjawiska: zakładamy, że istnieje wynik, który chcemy wyjaśniać lub przewidywać na podstawie pozostałych zmiennych. Dopiero po tak sformułowanym zadaniu wybieramy klasę modeli i algorytm służący do jej dopasowania.

Celem uczenia nadzorowanego jest uchwycenie zależności między cechami a wynikiem. Otrzymany model można następnie zastosować do nowego obiektu, dla którego znamy $\mathbf{x}$, ale nie znamy jeszcze y. Przykładowo na podstawie danych pacjentów o znanym rozpoznaniu możemy zbudować model szacujący ryzyko choroby u kolejnych pacjentów. Podobnie, dysponując informacjami o pasażerach *Titanica* i ich losach, możemy próbować przewidywać przeżycie na podstawie wieku, płci, klasy biletu i innych cech.

Określenie *nadzorowane* nie oznacza, że ktoś bezpośrednio kontroluje każdy krok działania algorytmu. Nadzór polega na obecności zmiennej wyjściowej w danych treningowych. Dzięki niej wynik zwracany przez model można porównać z wynikiem rzeczywiście zaobserwowanym.

W **uczeniu nienadzorowanym** żadna ze zmiennych nie pełni roli z góry określonego wyniku. Każdy obiekt jest opisany jedynie przez wektor cech $\mathbf{x}_i$, a dane mają postać

$$\mathcal{D} = \{\mathbf{x}_1, \ldots, \mathbf{x}_n\}.$$

Celem analizy jest wówczas opisanie struktury występującej w samych cechach, na przykład podobieństwa między obserwacjami, występowania grup albo głównych kierunków zmienności.

Metody nienadzorowane mogą służyć między innymi do:

- podziału obserwacji na grupy obiektów o podobnych cechach;
- przedstawienia danych za pomocą mniejszej liczby zmiennych;
- wykrywania nietypowych obserwacji;
- opisu zależności i geometrycznej struktury danych.

Przykładowo możemy próbować podzielić pacjentów na grupy o podobnych profilach wyników badań, nie określając wcześniej, jakie grupy mają zostać odnalezione. Możemy również zastąpić dużą liczbę silnie powiązanych pomiarów kilkoma zmiennymi syntetycznymi, które zachowują najważniejszą część informacji zawartej w danych.

Brak znanych odpowiedzi sprawia, że wynik uczenia nienadzorowanego jest zwykle trudniejszy do jednoznacznej oceny. Ten sam zbiór obserwacji może mieć kilka użytecznych opisów struktury, zależnie od celu analizy, przyjętej miary podobieństwa i założeń metody. Podział na uczenie nadzorowane i nienadzorowane dotyczy więc nie tylko użytego algorytmu, lecz przede wszystkim sposobu sformułowania zadania i informacji dostępnych podczas uczenia.

W dalszej części skoncentrujemy się głównie na uczeniu nadzorowanym.

1.4. Regresja i klasyfikacja

W uczeniu nadzorowanym wyróżniamy dwa podstawowe rodzaje zadań: **regresję** i **klasyfikację**. Podział ten wynika przede wszystkim z charakteru zmiennej wyjściowej oraz z rodzaju wyniku, który chcemy otrzymać. Nie zależy natomiast od postaci zmiennych wejściowych – te same cechy mogą zostać wykorzystane zarówno w zadaniu regresji, jak i klasyfikacji.

W **regresji** zmienna wyjściowa ma charakter ilościowy. Jej wartości są liczbami, dla których znaczenie mają wielkość, porządek oraz różnice między wartościami. Zadaniem modelu jest przewidywanie wartości liczbowej:

$$\hat{y} = \hat{f}(\mathbf{x}).$$

Przykładami regresji są przewidywanie ceny mieszkania, czasu trwania hospitalizacji, stężenia substancji we krwi albo wielkości plonu. Wynikiem modelu może być pojedyncza wartość, ale model może również opisywać niepewność predykcji, na przykład za pomocą przedziału predykcji lub rozkładu możliwych wartości.

W **klasyfikacji** zmienna wyjściowa ma charakter jakościowy: określa przynależność obiektu do jednej z ustalonych kategorii, nazywanych **klasami**. Jeżeli możliwe są dwie klasy, mówimy o klasyfikacji binarnej. Przykładem jest rozpoznawanie obecności albo braku choroby. Gdy klas jest więcej, mamy do czynienia z klasyfikacją wieloklasową, na przykład przy rozpoznawaniu gatunku rośliny na podstawie jej cech.

Klasy mogą być oznaczone liczbami, nie nadaje im to jednak charakteru ilościowego. Jeżeli brak choroby oznaczymy przez 0, a jej obecność przez 1, różnica między tymi wartościami nie opisuje wielkości choroby. Liczby pełnią tutaj jedynie funkcję etykiet.

W typowych zadaniach podział na regresję i klasyfikację jest związany z podziałem zmiennych na ciągłe i dyskretne. Ciągłą zmienną wyjściową modelujemy na ogół za pomocą regresji, natomiast jakościowa zmienna wyjściowa, przyjmująca wartości z dyskretnego zbioru klas, prowadzi do zadania klasyfikacji. Dlatego podział ten przedstawia się niekiedy w uproszczonej postaci: regresja dotyczy zmiennych ciągłych, a klasyfikacja – dyskretnych.

Rzeczywista różnica leży jednak nie w ciągłości zmiennej, lecz w jej charakterze. Wartości ilościowej zmiennej wyjściowej są uporządkowane i mają skalę, więc sensowne jest pytanie o przeciętny wynik – o „środek" jego rozkładu – oraz o to, jak daleko predykcja od niego odbiega. Klasy nie mają ani porządku, ani skali: średnia z dwóch gatunków rośliny nie jest żadnym gatunkiem, a pomyłka między klasami nie jest „mała" ani „duża". Dlatego model regresyjny podaje charakterystyki rozkładu wyniku, na przykład wartość przeciętną, a model klasyfikacyjny – prawdopodobieństwa poszczególnych klas.

Z tego powodu utożsamienie zmiennych ciągłych z regresją, a dyskretnych z klasyfikacją nie jest ścisłe. Zmienna dyskretna nie musi być zmienną jakościową. Może być również zmienną ilościową, jeżeli jej wartości mają znaczenie liczbowe. W takim przypadku mamy do czynienia z regresją, mimo że zmienna wyjściowa jest dyskretna.

Przykładem jest liczba wizyt pacjenta w szpitalu w ciągu roku. Zmienna ta przyjmuje wartości $0, 1, 2, ...$, jest więc dyskretna, ale jej wartości pozostają liczbami: pacjent z pięcioma wizytami trafiał do szpitala częściej niż pacjent z dwiema, a różnica między nimi daje się zmierzyć. Naturalnym pytaniem jest tutaj, ilu wizyt można się spodziewać u pacjenta o danych cechach – a nie, do której z kategorii „0", „1", „2" pacjent należy. Jest to więc zadanie regresji, mimo że zmienna wyjściowa jest dyskretna. Istnieją metody regresyjne przystosowane do zmiennych zliczeniowych, na przykład regresja Poissona.

Podział na zmienne ciągłe i dyskretne nie pokrywa się więc dokładnie z podziałem na regresję i klasyfikację. Przewidywanie liczby zdarzeń zwykle zaliczamy do regresji, choć przewidywana zmienna jest dyskretna; przewidywanie rodzaju zdarzenia – do klasyfikacji.

Model klasyfikacyjny często nie zwraca bezpośrednio etykiety klasy, lecz oszacowania prawdopodobieństw poszczególnych klas:

$$\hat{\eta}_k(\mathbf{x}) \approx \mathbb{P}(Y = k \mid \mathbf{X} = \mathbf{x}).$$

Na ich podstawie można następnie przypisać obiekt do jednej z klas, na przykład wybierając klasę o największym oszacowanym prawdopodobieństwie. Rozdzielenie tych dwóch etapów jest ważne: ten sam model może prowadzić do różnych decyzji zależnie od przyjętej reguły decyzyjnej. W diagnostyce medycznej próg wymagany do rozpoznania choroby można na przykład ustalić inaczej niż standardowe 0,5, jeżeli przeoczenie choroby jest znacznie bardziej kosztowne niż wynik fałszywie dodatni.

Regresja i klasyfikacja są rodzajami zadań, a nie rozłącznymi rodzinami algorytmów. Drzewa decyzyjne, metody najbliższych sąsiadów czy sieci neuronowe mogą występować zarówno w wersji regresyjnej, jak i klasyfikacyjnej. O charakterze zadania decyduje zmienna wyjściowa i cel analizy. Z tego powodu regresja logistyczna, mimo swojej nazwy, jest metodą klasyfikacji: opisuje prawdopodobieństwo przynależności do klasy, a nie wartość ilościowej zmiennej wyjściowej.

1.5. Probabilistyczny opis danych

Wróćmy do wcześniejszego spostrzeżenia: obiekty opisane tym samym wektorem cech mogą mieć różne wartości zmiennej odpowiedzi. Model przypisuje im wszystkim jedną predykcję, nie ma więc jednej „prawidłowej odpowiedzi", z którą można by ją zestawić. Zanim powiemy, co znaczy, że model jest dobry, musimy odpowiedzieć na dwa pytania:

1. **Z czym porównujemy predykcję**, skoro pojedynczy zaobserwowany wynik nie jest właściwym punktem odniesienia?
2. **Jak wycenić rozbieżność** między predykcją a tym, co zaobserwowaliśmy?

Pierwszemu poświęcona jest ta sekcja, drugiemu – Sekcja 1.6.

Aby odpowiedzieć na pierwsze pytanie, posłużymy się probabilistycznym opisem danych. Przyjmujemy, że zarówno cechy, jak i wynik są losowe: $\mathbf{X}$ jest wektorem losowym cech, Y – losową zmienną wyjściową, a para $(\mathbf{X}, Y)$ ma pewien **rozkład łączny** P. Próbę opisujemy parami $(\mathbf{X}_1, Y_1), \ldots, (\mathbf{X}_n, Y_n)$, niezależnymi i o tym samym rozkładzie P; zaobserwowane dane $(\mathbf{x}_i, y_i)$ są realizacjami tych par. Rozkład P opisuje populację, z której pochodzą dane: określa prawdopodobieństwa wartości cech i wyniku oraz zależności między nimi. W przyjętym opisie cała informacja o danych jest zawarta w P. Wiedza o znaczeniu zmiennych i kontekście ich pomiaru pozostaje poza tym opisem, o ile nie wprowadzimy jej do niego za pomocą dodatkowych założeń. Rozkład P nie jest nam znany – dysponujemy jedynie obserwacjami pochodzącymi z tego rozkładu.

Warto od razu zaznaczyć, że niezależność kolejnych obserwacji jest **założeniem**, a nie własnością danych. Bywa ono naruszone, na przykład gdy obserwacje są uporządkowane w czasie, pochodzą z sąsiadujących lokalizacji albo dotyczą powtarzanych pomiarów tego samego pacjenta. W dalszym ciągu przyjmujemy je milcząco, wskazując w razie potrzeby konsekwencje jego złamania.

Rozkład P opisujemy za pomocą funkcji prawdopodobieństwa lub gęstości, zależnie od rodzaju zmiennych. Oznaczmy tę funkcję przez $p(\mathbf{x}, y)$, a funkcję opisującą rozkład samych cech – przez $p(\mathbf{x})$. Dla $p(\mathbf{x}) > 0$ zachodzi

$$p(\mathbf{x}, y) = p(\mathbf{x}) \cdot p(y \mid \mathbf{x}), \tag{1.1}$$

gdzie $p(y \mid \mathbf{x})$ jest funkcją prawdopodobieństwa lub gęstością warunkową wyniku przy ustalonych cechach.

> **Przypomnienie: zmienna losowa**
>
> **Intuicja.** Wyobraźmy sobie, że losujemy jeden obiekt z populacji – na przykład pacjenta – i mierzymy na nim pewną wielkość, powiedzmy ciśnienie krwi. Zanim losowanie się odbędzie, nie wiemy, jaki wynik otrzymamy; wiemy jedynie, które wyniki są możliwe i jak często się pojawiają. **Zmienna losowa** to właśnie ten pomiar rozważany *przed* losowaniem: reguła, która każdemu możliwemu wynikowi losowania przypisuje liczbę. Opis tego, jak często pojawiają się poszczególne wartości, nazywamy **rozkładem** zmiennej.
> Losowanie obiektu nie jest jedynym źródłem niepewności. Ciśnienie konkretnego, znanego nam pacjenta również nie jest z góry ustalone: zmienia się w ciągu dnia, zależy od warunków pomiaru, a sam pomiar obarczony jest błędem. Zmienną losową możemy więc rozumieć ogólniej – jako wielkość, której wartości nie znamy przed obserwacją, a rozkład – jako opis tego, które wartości są bardziej, a które mniej prawdopodobne.
> **Zmienna a jej realizacja.** Wielką literą oznaczamy zmienną losową, małą – wartość,

którą przyjęła w konkretnym losowaniu, czyli jej **realizację**. Y to „ciśnienie pacjenta, którego dopiero wylosujemy", y to konkretna liczba odczytana z aparatu. Tak samo $\mathbf{X}$ jest wektorem losowym cech, a $\mathbf{x}$ – ustalonym wektorem liczb. Zapis $\mathbb{P}(Y \le y)$ łączy oba obiekty: pyta o prawdopodobieństwo, że zmienna Y przyjmie wartość nie większą od ustalonej liczby y.

Funkcje zmiennych losowych. Jeżeli Y jest zmienną losową, a g – zwykłą funkcją, to $g(Y)$ również jest zmienną losową: najpierw losujemy obiekt, potem odczytujemy Y, a na końcu obliczamy g. Z tego prostego spostrzeżenia będziemy stale korzystać. Na przykład $f^*(\mathbf{X})$ jest zmienną losową, choć f^* jest ustaloną funkcją, a strata $L(Y, f(\mathbf{X}))$ z sekcji 1.6 jest zmienną losową, bo zależy od wylosowanej pary $(\mathbf{X}, Y)$. Wartość oczekiwana takiej zmiennej jest już liczbą.

i Przypomnienie: rozkłady dyskretne i ciągłe

Rozkład dyskretny. Zmienna Y ma rozkład dyskretny, jeżeli przyjmuje wartości ze zbioru $\mathcal{Y}$ skończonego lub przeliczalnego, zwanego **nośnikiem**. Rozkład opisuje wtedy **funkcja prawdopodobieństwa**

$$p(y) = \mathbb{P}(Y = y), \qquad y \in \mathcal{Y},$$

spełniająca $p(y) > 0$ oraz $\sum_{y \in \mathcal{Y}} p(y) = 1$. Prawdopodobieństwo dowolnego zbioru wartości otrzymujemy poprzez sumowanie: $\mathbb{P}(Y \in A) = \sum_{y \in A} p(y)$.

Rozkład ciągły. Zmienna Y ma rozkład ciągły, jeżeli istnieje funkcja $p \ge 0$, zwana **gęstością**, taka że dla każdego zbioru A

$$\mathbb{P}(Y \in A) = \int_A p(y)\, dy,$$

przy czym $\int_{-\infty}^{\infty} p(y)\, dy = 1$. Biorąc $A = \{y_0\}$, otrzymujemy natychmiast $\mathbb{P}(Y = y_0) = 0$: całka po zbiorze jednopunktowym jest zerem. Pojedyncze wartości nie mają więc dodatnich prawdopodobieństw, choć zmienna jakąś z nich przyjmuje.

Gęstość nie jest prawdopodobieństwem. Wartość $p(y)$ nie musi nawet należeć do przedziału $[0, 1]$ – dla rozkładu jednostajnego na [0; 0,1] gęstość jest wszędzie równa 10. Sens probabilistyczny ma dopiero prawdopodobieństwo przedziału: jeżeli gęstość jest ciągła w punkcie y, to dla małych $h > 0$

$$\mathbb{P}(y \le Y \le y + h) \approx p(y)\, h.$$

Gęstość mierzy więc nie prawdopodobieństwo samej wartości y, lecz jego zagęszczenie w otoczeniu tej wartości – stąd jej nazwa. Gęstości wolno porównywać między sobą, bo mówią, gdzie skupia się większa masa prawdopodobieństwa, ale nie wolno ich czytać jako prawdopodobieństw.

Dystrybuanta. Wspólnym opisem obu przypadków jest **dystrybuanta**

$$F(y) = \mathbb{P}(Y \le y),$$

określona dla każdej zmiennej losowej rzeczywistej. W przypadku dyskretnym jest funkcją schodkową ze skokami w punktach nośnika, w ciągłym – funkcją ciągłą, będącą całką z gęstości.

i Przypomnienie: rozkład łączny, brzegowy i warunkowy

Literą p oznaczamy, tak jak wyżej, funkcję prawdopodobieństwa albo gęstość – zależnie od tego, czy zmienna jest dyskretna, czy ciągła.
Rozkład łączny opisuje parę $(\mathbf{X}, Y)$ traktowaną jako całość: przypisuje prawdopodobieństwa zdarzeniom dotyczącym cech i wyniku naraz. Dla zmiennych dyskretnych $p(\mathbf{x}, y) = \mathbb{P}(\mathbf{X} = \mathbf{x}, Y = y)$; w przypadku ciągłym $p(\mathbf{x}, y)$ jest gęstością, a prawdopodobieństwa otrzymujemy przez całkowanie.
Rozkład brzegowy opisuje same cechy, z pominięciem zmiennej wyjściowej. Jego funkcję prawdopodobieństwa lub gęstość otrzymujemy przez zsumowanie albo scałkowanie $p(\mathbf{x}, y)$ po y:

$$p(\mathbf{x}) = \sum_y p(\mathbf{x}, y) \qquad \text{albo} \qquad p(\mathbf{x}) = \int p(\mathbf{x}, y)\, dy.$$

Rozkład warunkowy opisuje wynik przy ustalonych cechach. Jego funkcję prawdopodobieństwa lub gęstość definiujemy dla $p(\mathbf{x}) > 0$ wzorem

$$p(y \mid \mathbf{x}) = \frac{p(\mathbf{x}, y)}{p(\mathbf{x})}.$$

Przy ustalonym $\mathbf{x}$ funkcja ta jest nieujemna i sumuje się (całkuje) po y do jedynki, opisuje więc rozkład prawdopodobieństwa zmiennej Y. Dla zmiennych dyskretnych $p(y \mid \mathbf{x})$ jest zwykłym prawdopodobieństwem warunkowym $\mathbb{P}(Y = y \mid \mathbf{X} = \mathbf{x})$; gdy cechy są ciągłe, zdarzenie $\{\mathbf{X} = \mathbf{x}\}$ ma prawdopodobieństwo zero i definicja wymaga ostrożności – wracamy do tego na końcu sekcji.
Skąd bierze się wzór (1.1). Wystarczy pomnożyć ostatnią równość przez $p(\mathbf{x})$. Wzór ten nie jest więc twierdzeniem o strukturze rozkładu, lecz przekształceniem podanego wzoru na funkcję prawdopodobieństwa lub gęstość warunkową. Cała jego treść leży w interpretacji obu czynników i w tym, że zależność, która nas interesuje, mieści się wyłącznie w drugim z nich.
Przypadek mieszany. W klasyfikacji cechy są często ciągłe, a wynik dyskretny. Funkcja $p(\mathbf{x}, y)$ jest wtedy gęstością względem $\mathbf{x}$ i prawdopodobieństwem względem y:

$$\mathbb{P}(\mathbf{X} \in A,\, Y = y) = \int_A p(\mathbf{x}, y)\, d\mathbf{x}.$$

Rozkład brzegowy cech dostajemy, sumując po y: $p(\mathbf{x}) = \sum_y p(\mathbf{x}, y)$, a rozkład wyniku – całkując po $\mathbf{x}$: $\mathbb{P}(Y = y) = \int p(\mathbf{x}, y)\, d\mathbf{x}$. Taki rozkład najłatwiej zadać w kolejności odwrotnej niż w (1.1): przez prawdopodobieństwa klas $\pi_y = \mathbb{P}(Y = y)$ i gęstości cech w obrębie klas $p(\mathbf{x} \mid Y = y)$,

$$p(\mathbf{x}, y) = \pi_y\, p(\mathbf{x} \mid Y = y).$$

Podstawienie tego iloczynu do definicji rozkładu warunkowego daje wzór Bayesa

$$p(y \mid \mathbf{x}) = \frac{\pi_y\, p(\mathbf{x} \mid Y = y)}{\sum_{y'} \pi_{y'}\, p(\mathbf{x} \mid Y = y')}. \tag{1.2}$$

Pierwszy czynnik, $p(\mathbf{x})$, opisuje **rozkład brzegowy** cech. Mówi, gdzie w przestrzeni cech znajdują się obiekty i jak gęsto. Jeśli na przykład obiektami są pacjenci, a cechami ich wiek i wyniki badań, rozkład ten opisuje, jaki jest typowy wiek pacjenta, jakie kombinacje wyników badań występują często, a jakie prawie wcale. O zależności między cechami a wynikiem nie mówi natomiast nic.

Drugi czynnik, $p(y \mid \mathbf{x})$, opisuje **rozkład warunkowy** zmiennej Y przy ustalonych cechach, oznaczany

$$Y \mid \mathbf{X} = \mathbf{x}.$$

Określa on, jakie wartości zmiennej Y mogą wystąpić wśród obiektów o cechach $\mathbf{x}$ i z jakim prawdopodobieństwem; dla zmiennej ciągłej opisuje go gęstość warunkowa, dla dyskretnej – prawdopodobieństwa poszczególnych wartości. To właśnie w nim zawarta jest cała zależność wyniku od cech, i to on odpowiada na pierwsze z pytań postawionych na początku sekcji: predykcję porównujemy nie z jedną wartością, lecz z całym rozkładem możliwych wyników.

W samym rozkładzie warunkowym możemy wyróżnić część **systematyczną**, związaną z obserwowanymi cechami, oraz **szum**, czyli zmienność wyniku niewyjaśnioną przez te cechy. Słowa *szum* używamy w szerokim znaczeniu. Może on wynikać z błędów pomiarowych, z wpływu czynników nieuwzględnionych w danych albo z rzeczywistej losowości badanego zjawiska. Nie oznacza więc, że dane zostały zebrane nieprawidłowo.

> **i** Po co nam ten podział
>
> Modelując zależność, interesujemy się drugim czynnikiem. Optymalna predykcja w punkcie $\mathbf{x}$ – w sensie, który sprecyzujemy w sekcji 1.6 – zależy wyłącznie od rozkładu warunkowego – rozkład brzegowy cech nie wpływa na nią w żaden sposób. Wpływa natomiast na to, jak bardzo opłaca się być dokładnym w danym obszarze przestrzeni cech, bo obszary rzadko odwiedzane wnoszą do przeciętnej straty niewiele. Do tej obserwacji wracamy w rozdziale 2.
> Wzdłuż tego samego podziału przebiega też granica między dwiema rodzinami metod. Modele **dyskryminacyjne**, takie jak regresja logistyczna, opisują wyłącznie $p(y \mid \mathbf{x})$ i o rozkładzie cech nie mówią nic. Modele **generatywne**, takie jak analiza dyskryminacyjna czy naiwny klasyfikator bayesowski, opisują cały rozkład łączny, docierając do zależności okrężną drogą – przez rozkłady cech wewnątrz klas. Różnicę tę omówimy szczegółowo w rozdziale 11.

1.5.1. Regresja

W przypadku regresji część systematyczną opisujemy za pomocą warunkowej wartości oczekiwanej, nazywanej **funkcją regresji**:

$$f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]. \tag{1.3}$$

Oznacza ona przeciętną wartość zmiennej wyjściowej wśród obiektów o cechach $\mathbf{x}$. Gwiazdka oznacza predyktor optymalny – w jakim sensie, wyjaśniamy niżej – a więc wielkość teoretyczną, opisującą badaną populację, a nie funkcję wyznaczoną z danych; symbolu f bez gwiazdki będziemy używać dla dowolnego predyktora, a $\hat{f}$ – dla predyktora dopasowanego do konkretnego zbioru obserwacji.

> **i** Przypomnienie: warunkowa wartość oczekiwana
>
> Wartość oczekiwana rozkładu warunkowego $Y \mid \mathbf{X} = \mathbf{x}$ to średnia wartość Y wśród obiektów o cechach $\mathbf{x}$:

$$\mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}] = \sum_y y\, p(y \mid \mathbf{x}) \qquad \text{albo} \qquad \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}] = \int y\, p(y \mid \mathbf{x})\, dy.$$

Jest to **liczba** zależna od $\mathbf{x}$, a więc funkcja zmiennej $\mathbf{x}$ – i właśnie tę funkcję nazywamy funkcją regresji.

Dwa zapisy, dwa różne obiekty. Podstawiając w miejsce $\mathbf{x}$ losowy wektor $\mathbf{X}$, otrzymujemy $\mathbb{E}[Y \mid \mathbf{X}] = f^*(\mathbf{X})$, czyli **zmienną losową**: jej wartość zmienia się wraz z wylosowanym obiektem. Wzór (1.3) mówi o liczbie przypisanej ustalonym cechom, natomiast warunek $\mathbb{E}[\varepsilon \mid \mathbf{X}] = 0$ we wzorze (1.4) jest równością zmiennych losowych – znaczy tyle, że dla **każdego** $\mathbf{x}$ zachodzi $\mathbb{E}[\varepsilon \mid \mathbf{X} = \mathbf{x}] = 0$.

Prawo iterowanej wartości oczekiwanej. Uśrednienie funkcji $f^*(\mathbf{X})$ po rozkładzie cech odtwarza zwykłą wartość oczekiwaną:

$$\mathbb{E}\big[\mathbb{E}[Y \mid \mathbf{X}]\big] = \mathbb{E}[Y].$$

Średnia warunkowych średnich jest więc średnią globalną – z wagami danymi przez rozkład brzegowy cech. Ta tożsamość pozwala rozbijać rachunki na dwa kroki: najpierw uśredniamy przy ustalonych cechach, potem po cechach. Będziemy z niej korzystać przy rachunkach dotyczących ryzyka.

Wybór warunkowej wartości oczekiwanej nie jest przypadkowy. W rozdziale 2 pokażemy, że funkcja f^* jest **najlepszym możliwym** predyktorem, jeżeli błędy wyceniamy stratą kwadratową. Przy innej stracie wyróżniona byłaby inna charakterystyka rozkładu warunkowego, na przykład mediana. To, jaką charakterystykę rozkładu warto przewidywać, zależy więc od sposobu wyceniania błędów.

Zdefiniujmy odchylenie wyniku od jego średniej warunkowej jako $\varepsilon = Y - f^*(\mathbf{X})$. Wówczas, przy ustalonych cechach, jego wartość oczekiwana wynosi

$$\mathbb{E}[\varepsilon \mid \mathbf{X}] = \mathbb{E}[Y \mid \mathbf{X}] - f^*(\mathbf{X}) = 0.$$

Zmienną wyjściową możemy więc przedstawić w postaci addytywnej

$$Y = f^*(\mathbf{X}) + \varepsilon, \qquad \mathbb{E}[\varepsilon \mid \mathbf{X}] = 0. \tag{1.4}$$

Składnik ε opisuje odchylenie obserwowanego wyniku od części systematycznej. Dwa obiekty o takich samych wartościach cech otrzymują tę samą wartość $f^*(\mathbf{x})$, ale ich rzeczywiste wyniki mogą się różnić ze względu na różne realizacje ε. Warunek $\mathbb{E}[\varepsilon \mid \mathbf{X}] = 0$ wynika z definicji ε i oznacza, że odchylenia przy ustalonych cechach przeciętnie się znoszą.

Przykładowo model może opisywać zależność między czasem hospitalizacji a wiekiem pacjenta, rozpoznaniem i wynikami badań. Pacjenci o takich samych wartościach zarejestrowanych cech nie muszą jednak przebywać w szpitalu dokładnie tyle samo dni. Na czas hospitalizacji wpływają również czynniki, których model nie uwzględnia, oraz zdarzenia, których nie da się przewidzieć na podstawie dostępnych informacji.

Funkcja f^* opisuje zależność występującą w badanej populacji, ale zazwyczaj nie jest znana. Na podstawie danych treningowych wyznaczamy jej oszacowanie $\hat{f}$, a predykcja dla obiektu o cechach $\mathbf{x}$ ma postać

$$\hat{y} = \hat{f}(\mathbf{x}).$$

1.5.2. Klasyfikacja

W klasyfikacji podział na zależność systematyczną i szum ma ten sam sens, ale nie da się go zapisać addytywnie. Suma etykiety klasy i odchylenia nie byłaby etykietą klasy, więc rozkład (1.4) traci tu zastosowanie. Opisujemy zatem rozkład warunkowy wprost.

Jeżeli zmienna wyjściowa przyjmuje wartości w zbiorze klas $\{1, \dots, K\}$, część systematyczną opisują prawdopodobieństwa warunkowe

$$\eta_k(\mathbf{x}) = \mathbb{P}(Y = k \mid \mathbf{X} = \mathbf{x}), \qquad k = 1, \dots, K, \tag{1.5}$$

spełniające dla każdego $\mathbf{x}$ warunek $\sum_{k=1}^{K} \eta_k(\mathbf{x}) = 1$. W klasyfikacji binarnej wystarczy jedna funkcja $\eta(\mathbf{x}) = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$, a rozkład wyniku przy ustalonych cechach zapisujemy jako

$$Y \mid \mathbf{X} = \mathbf{x} \sim \text{Bernoulli}\,(\eta(\mathbf{x})).$$

Funkcja η pełni więc wobec klasyfikacji tę samą rolę, co f^* wobec regresji: opisuje systematyczną zależność wyniku od cech. Aby na podstawie prawdopodobieństw wybrać przewidywaną klasę, potrzebujemy reguły decyzyjnej. W przypadku binarnym możemy na przykład wybierać klasę 1, gdy $\eta(\mathbf{x}) > 1/2$, a klasę 0 w przeciwnym razie. Jeżeli jednak $0 < \eta(\mathbf{x}) < 1$, obie klasy są możliwe przy tych samych cechach, więc nawet dokładna znajomość $\eta(\mathbf{x})$ nie gwarantuje bezbłędnej klasyfikacji. W praktyce dochodzi do tego drugie źródło błędów: nie znamy $\eta(\mathbf{x})$ i musimy ją oszacować na podstawie danych.

> **i** Jeden opis, dwie charakterystyki
>
> Warto zauważyć, jak niewiele różni oba przypadki. Wspólnym punktem wyjścia jest rozkład warunkowy $Y \mid \mathbf{X} = \mathbf{x}$; różnica polega wyłącznie na tym, co z niego odczytujemy.
> W problemie regresji wygodną charakterystyką jest odpowiednio rozumiany środek rozkładu – na przykład średnia warunkowa $f^*(\mathbf{x})$ lub mediana warunkowa. W problemie klasyfikacji mówienie o „środku" nie ma sensu – klasy nie mają porządku ani skali – więc podajemy cały rozkład, czyli wektor $(\eta_1(\mathbf{x}), \dots, \eta_K(\mathbf{x}))$.
> Dla zmiennej binarnej z klasami zakodowanymi jako 0 i 1 oba opisy pokrywają się: $\mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}] = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$, a więc $f^* = \eta$. Przy innym kodowaniu dwiema różnymi liczbami średnia warunkowa nadal jednoznacznie wyznacza prawdopodobieństwa klas, ale nie jest już wprost jednym z nich.

W praktyce funkcje η_k, podobnie jak f^*, nie są znane i zastępujemy je oszacowaniami $\hat{\eta}_k$ wyznaczonymi z danych. W obu zadaniach mamy więc do czynienia z tym samym układem: nieznaną zależnością występującą w populacji, jej oszacowaniem zbudowanym na skończonej próbie oraz zmiennością wyniku, która pozostaje nawet po ustaleniu wszystkich dostępnych cech.

> **i** Dla Czytelników z przygotowaniem z teorii miary
>
> Zapis wprowadzony w tej sekcji jest uproszczony w kilku miejscach.
> **Zmienna losowa.** Formalnie zmienna losowa to funkcja mierzalna $Y \colon \Omega \to \mathbb{R}$ określona na przestrzeni probabilistycznej $(\Omega, \mathcal{F}, \mathbb{P})$; wektor losowy $\mathbf{X}$ przyjmuje wartości w $\mathbb{R}^p$. Elementy Ω odpowiadają wynikom losowania, a rozkład zmiennej Y to miara $\mathbb{P} \circ Y^{-1}$ na $\mathbb{R}$. W całej książce przestrzeń Ω pozostaje w tle: wszystkie rozważane wielkości zależą od niej wyłącznie przez łączny rozkład rozważanych zmiennych.
> **Rozkład warunkowy.** Gdy zmienna $\mathbf{X}$ ma rozkład ciągły, zdarzenie $\{\mathbf{X} = \mathbf{x}\}$ ma praw-

dopodobieństwo zero i rozkładu $Y \mid \mathbf{X} = \mathbf{x}$ nie można zdefiniować wzorem $\mathbb{P}(\cdot \mid A) = \mathbb{P}(\cdot \cap A)/\mathbb{P}(A)$. Właściwą konstrukcją jest regularny rozkład warunkowy, który dla zmiennych o wartościach w $\mathbb{R}^p$ zawsze istnieje, ale jest wyznaczony jednoznacznie jedynie **z dokładnością do zbioru miary zero** względem rozkładu $\mathbf{X}$. To samo dotyczy funkcji f^* oraz η_k: ściśle biorąc nie są one funkcjami, lecz klasami równoważności funkcji. Konsekwentnie, wszystkie stwierdzenia postaci „dla każdego $\mathbf{x}$" należy w dalszym ciągu czytać jako „dla prawie każdego $\mathbf{x}$".

Symbol p. We wzorze (1.1) litera p oznacza gęstość względem miary, która nie jest ta sama dla obu zmiennych: dla cech ciągłych jest to miara Lebesgue'a, dla jakościowej zmiennej wyjściowej – miara licząca. Formalnie chodzi o gęstość rozkładu łącznego względem miary produktowej. Zapis $p(\cdot)$ jest więc wygodnym skrótem obejmującym gęstości i prawdopodobieństwa punktowe naraz; stosujemy go w całej książce.

Dlaczego pomijamy te zastrzeżenia. Wielkości, którymi będziemy oceniać predyktory (Sekcja 1.6), są wartościami oczekiwanymi, czyli całkami. Dwie wersje funkcji f^* różniące się na zbiorze miary zero dają więc identyczne wartości tych wielkości. Obiekt niejednoznaczny nigdy nie występuje samodzielnie – zawsze pod znakiem wartości oczekiwanej, która tej niejednoznaczności nie widzi.

Ścisłe ujęcie znajdzie Czytelnik w monografii Devroye i in. (1996) dla klasyfikacji oraz Györfi i in. (2002) dla regresji nieparametrycznej.

Odpowiedzieliśmy w ten sposób na pierwsze z pytań postawionych na początku sekcji. Wiemy już, z czym porównujemy predykcję: z rozkładem warunkowym $Y \mid \mathbf{X} = \mathbf{x}$, którego część systematyczną opisuje f^* albo η_k, a resztę stanowi szum.

1.6. Jak mierzymy jakość predykcji

Wróćmy do drugiego z pytań postawionych w sekcji 1.5: co znaczy, że predykcja jest bliska rzeczywistemu wynikowi? Odpowiedź wymaga określenia kosztu błędu danej wielkości. Koszt ten zależy od celu i kontekstu zastosowania modelu; nie wynika z samego rozkładu danych.

Potrzebne będą dwa pojęcia. Pierwsze wycenia pojedynczy błąd, drugie uśrednia ten koszt po całej populacji.

Funkcją straty nazywamy funkcję $L(y, \hat{y}) \geq 0$ określającą koszt predykcji $\hat{y}$, gdy rzeczywistą wartością okazało się y. Naturalnie zakładamy $L(y, y) = 0$: trafna predykcja nie kosztuje nic.

W regresji standardowym wyborem jest **strata kwadratowa**

$$L(y, \hat{y}) = (y - \hat{y})^2, \tag{1.6}$$

karząca duże pomyłki nieproporcjonalnie mocniej niż małe: jeden błąd o wartości 10 kosztuje tyle, co sto błędów o wartości 1. W klasyfikacji najprostszą stratą jest **strata 0–1**

$$L(y, \hat{y}) = \mathbb{1}(y \neq \hat{y}), \tag{1.7}$$

wyceniająca każdą pomyłkę na jednostkę, niezależnie od tego, jakich klas dotyczy. Oba wybory są domyślne, ale nie są jedyne możliwe ani zawsze właściwe – do konsekwencji zmiany straty wrócimy w rozdziale 2.

i Przypomnienie: funkcja wskaźnikowa

Symbol $\mathbb{1}(A)$ oznacza **funkcję wskaźnikową** warunku A:

$$\mathbb{1}(A) = \begin{cases} 1, & \text{gdy warunek } A \text{ jest spełniony,} \\ 0, & \text{w przeciwnym razie.} \end{cases}$$

We wzorze (1.7) warunkiem jest $y \neq \hat{y}$. Strata wynosi więc 1, gdy przewidywana klasa różni się od rzeczywistej, oraz 0, gdy klasy są zgodne.

Strata mówi o pojedynczej obserwacji. Interesuje nas natomiast zachowanie modelu na całej populacji, z której pochodzą dane.

Definicja 1.1 (Ryzyko)**. Ryzykiem** predyktora f nazywamy oczekiwaną stratę

$$R(f) = \mathbb{E}[L(Y, f(\mathbf{X}))], \tag{1.8}$$

gdzie wartość oczekiwaną liczymy względem łącznego rozkładu pary $(\mathbf{X}, Y)$.

Definicja 1.1 jest wspólna dla regresji i klasyfikacji – różni je wyłącznie podstawiona strata. Dla straty kwadratowej ryzyko jest **błędem średniokwadratowym**

$$R(f) = \mathbb{E}[(Y - f(\mathbf{X}))^2],$$

a dla straty 0–1, ponieważ wartość oczekiwana wskaźnika jest prawdopodobieństwem zdarzenia – **prawdopodobieństwem błędnej klasyfikacji**:

$$R(f) = \mathbb{E}[\mathbb{1}(Y \neq f(\mathbf{X}))] = \mathbb{P}(f(\mathbf{X}) \neq Y).$$

Rachunek jest w obu przypadkach ten sam; zmienia się tylko interpretacja wyniku. Dwie wielkości, które w kursach statystyki wprowadza się zwykle osobno i różnymi wzorami, okazują się jednym pojęciem z dwoma różnymi podstawieniami.

! Ryzyko a błąd na danych treningowych

Wartość oczekiwana we wzorze (1.8) jest liczona względem rozkładu całej populacji, a nie względem zbioru obserwacji, którym dysponujemy. Wielkość, którą faktycznie umiemy obliczyć, to **ryzyko empiryczne**

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^{n} L(y_i, f(\mathbf{x}_i)). \tag{1.9}$$

Są to dwie różne rzeczy. Na $R(f)$ nam zależy, ale nie umiemy jej obliczyć, bo nie znamy rozkładu populacji. $\widehat{R}_n(f)$ umiemy obliczyć, lecz jeżeli te same dane posłużyły do dopasowania modelu, jest ona systematycznie zaniżona: model był dobierany tak, aby na nich wypadać dobrze. Dla predyktora ustalonego niezależnie od danych średnia ta byłaby nieobciążonym oszacowaniem ryzyka.
Do rzetelnego szacowania ryzyka wracamy w rozdziale 5.

Ryzyko określa przeciętny koszt błędów predyktora w populacji. Chcemy, by koszt ten był jak najmniejszy, dlatego pytamy: **która funkcja f minimalizuje $R(f)$?** Zauważmy, że pytanie to

nie dotyczy żadnego konkretnego algorytmu ani klasy modeli – minimalizujemy po **wszystkich** funkcjach. Odpowiedź wyznacza więc granicę osiągalności, do której metody uczenia mogą się jedynie zbliżać.

Okaże się, że odpowiedź zależy wyłącznie od wybranej straty. Przy stracie kwadratowej (1.6) optymalna jest funkcja regresji (1.3). Przy stracie 0–1 (1.7) optymalna jest reguła wskazująca klasę o największym prawdopodobieństwie $\eta_k(\mathbf{x})$. Wyprowadzenie obu wyników, wraz z konsekwencjami dla praktyki, jest treścią rozdziału 2.

1.6.1. Błąd redukowalny i nieredukowalny

Ryzyko pozwala rozdzielić dwa źródła błędów predykcji. Rozróżnienie to dotyczy zarówno regresji, jak i klasyfikacji.

W obu zadaniach istnieje najmniejsze ryzyko osiągalne przy ustalonych cechach i wybranej funkcji straty. Nazywamy je **błędem nieredukowalnym**. W regresji ze stratą kwadratową wynika ono ze zmienności wyników wokół średniej warunkowej; w klasyfikacji ze stratą 0–1 – z możliwości występowania różnych klas przy tych samych cechach. Może być dodatnie nawet wtedy, gdy dokładnie znamy rozkład danych i stosujemy optymalną regułę predykcji.

Błąd redukowalny to nadwyżka ryzyka naszego predyktora ponad to minimum. Może wynikać z ograniczeń wybranej klasy modeli lub z niedokładnego dopasowania na podstawie skończonej próby. Możemy go zmniejszać przez wybór odpowiedniejszej metody, lepsze dopasowanie lub zwiększenie liczby obserwacji, przy zachowaniu tego samego zestawu cech.

Rozróżnienie to pozwala ocenić, jaka część ryzyka może zostać zmniejszona przez doskonalenie predyktora przy dostępnych cechach.

> **i** Nieredukowalny – ale względem czego
>
> Przymiotnik „nieredukowalny” odnosi się do **ustalonego zestawu cech**, a nie do zjawiska w ogóle. Zmienność Y przy ustalonym $\mathbf{X}$ może wynikać z wpływu czynników, których nie zmierzyliśmy. Dodanie cechy dostarczającej nowej informacji o wyniku może zmniejszyć błąd dotąd nieredukowalny: część zmienności niewyjaśnionej przez dotychczasowe cechy staje się możliwa do przewidzenia.
> Praktyczna konsekwencja: czego nie da się poprawić modelowaniem, często daje się poprawić pomiarem.

W rozdziale 2 wyznaczymy optymalne reguły predykcji dla regresji i klasyfikacji, a dla każdej z nich także konkretną postać obu składników. Przy stracie kwadratowej (Sekcja 2.6) błąd redukowalny będzie średnim kwadratem różnicy między predyktorem a funkcją regresji, a nieredukowalny – średnią wariancją warunkową wyniku. Przy stracie 0–1 błąd nieredukowalny okaże się ryzykiem najlepszego możliwego klasyfikatora, tzw. błędem bayesowskim, a redukowalny – średnim prawdopodobieństwem trafienia utraconym przez wybór gorszej klasy.

1.7. Dwa cele modelowania: predykcja i wnioskowanie

Opis zależności między cechami a wynikiem może służyć różnym celom. Możemy wykorzystywać model do przewidywania wyników dla nowych obiektów albo do szacowania określonych charakterystyk badanej populacji. Cele te nazywamy odpowiednio **predykcją** i **wnioskowaniem**. Mogą one korzystać z tego samego modelu, ale wymagają różnych kryteriów oceny.

W szerokim znaczeniu wnioskowanie statystyczne obejmuje wykorzystanie danych z próby do formułowania wniosków o populacji, w tym również uczenie predyktora. W tej sekcji używamy tego terminu w węższym znaczeniu: szacowania i badania określonych charakterystyk populacji wraz z oceną niepewności.

Rozważmy zbiór danych zawierający ceny sprzedaży mieszkań oraz ich cechy, takie jak metraż, lokalizacja i liczba pokoi. Na podstawie tych danych możemy szukać odpowiedzi na dwa różne pytania. Pytanie predykcyjne brzmi: „Jaką cenę przewidujemy dla mieszkania o powierzchni 60 m² w danej lokalizacji?". Pytanie dotyczące wnioskowania może brzmieć: „O ile różni się przeciętna cena mieszkań o powierzchni 60 m² od przeciętnej ceny mieszkań o powierzchni 50 m² w tej samej lokalizacji?".

Zapiszmy oba pytania wzorami. Dla prostoty niech funkcja regresji $f^*(s, \ell)$ zależy tylko od metrażu s i lokalizacji ℓ, a $\hat{f}$ oznacza jej oszacowanie z danych. Odpowiedzią na pierwsze pytanie jest liczba $\hat{y} = \hat{f}(60, \ell)$, przewidywana cena konkretnego mieszkania. Drugie pytanie dotyczy wielkości opisującej populację:

$$\Delta(\ell) = f^*(60, \ell) - f^*(50, \ell), \tag{1.10}$$

czyli różnicy między średnimi cenami dwóch grup mieszkań. Szacujemy ją na przykład przez $\widehat{\Delta}(\ell) = \hat{f}(60, \ell) - \hat{f}(50, \ell)$ i podajemy niepewność tego oszacowania. Sam fakt, że model zwraca przewidywania, nie przesądza więc o celu analizy: różnica dwóch przewidywanych średnich może służyć oszacowaniu zależności w populacji.

Wielkość $\Delta(\ell)$ porównuje mieszkania w obrębie tej samej lokalizacji. Porównanie mieszkań o różnym metrażu ogółem jest innym porównaniem: większe mieszkania mogą częściej leżeć w innych miejscach, a różnica średnich cen obejmuje wtedy także różnicę lokalizacji. To samo dotyczy współczynników modelu. Niech lokalizację opisuje odległość ℓ od centrum miasta i niech średnia cena zależy liniowo od obu cech: $f^*(s, \ell) = \alpha + \beta s + \gamma \ell$. Wtedy $\Delta(\ell) = 10\beta$ niezależnie od lokalizacji, więc β jest różnicą średnich cen przypadającą na dodatkowy metr kwadratowy przy ustalonej odległości od centrum. Pomińmy teraz lokalizację i opiszmy średnią cenę samą prostą $\alpha' + \beta' s$. Jeżeli większe mieszkania leżą przeciętnie dalej od centrum, a ceny spadają z odległością ($\gamma < 0$), to nachylenie β' obejmuje także różnicę lokalizacji i jest mniejsze od β; przy silnym powiązaniu metrażu z odległością może być nawet ujemne. Ten sam „współczynnik przy metrażu" oznacza więc w obu modelach różne wielkości.

O sukcesie predykcyjnym decyduje **generalizacja**, czyli zdolność modelu do skutecznego przewidywania wyników dla nowych przypadków z populacji, do której chcemy go stosować. Dobre dopasowanie do danych uczących samo w sobie jej nie zapewnia. Jakość generalizacji szacujemy na danych niewykorzystanych do dopasowania modelu, na przykład na zbiorze walidacyjnym. Wynik na takim zbiorze jest oszacowaniem ryzyka $R(\hat{f})$ w danej populacji, a jego wiarygodność zależy od sposobu zebrania i wykorzystania danych. Miarę jakości dobieramy do zadania; nie zawsze jest nią średnia strata pojedynczych obserwacji. Do zasad tej oceny wrócimy w rozdziale 5.

We wnioskowaniu oceniamy dokładność oszacowania wybranej wielkości, takiej jak $\Delta(\ell)$, oraz wiarygodność towarzyszącej mu oceny niepewności. Możemy w tym celu badać parametry modelu lub charakterystyki wyznaczone z jego odpowiedzi. Interpretacja tych wielkości wymaga uzasadnienia założeń, na których opiera się zastosowana procedura.

Mogłoby się wydawać, że model o małym ryzyku $R(\hat{f})$ daje też dokładne oszacowanie $\widehat{\Delta}$ każdej interesującej nas różnicy średnich. Tak jednak nie jest. Załóżmy, że w danych o mieszkaniach większemu metrażowi niemal zawsze towarzyszy większa liczba pokoi. Model może dobrze przewidywać ceny kolejnych mieszkań, w których te dwie cechy są powiązane w podobny sposób.

Trudniej natomiast ustalić, jak średnia cena wiąże się z metrażem przy ustalonej liczbie pokoi: w danych jest niewiele mieszkań, które pozwalają na takie porównanie. Różne modele mogą więc podobnie przewidywać ceny typowych mieszkań, a jednocześnie wskazywać wyraźnie różne zależności ceny od metrażu przy ustalonej liczbie pokoi. Sam mały błąd predykcji nie rozstrzyga, które oszacowanie tej zależności jest trafne.

i Precyzja a dokładność

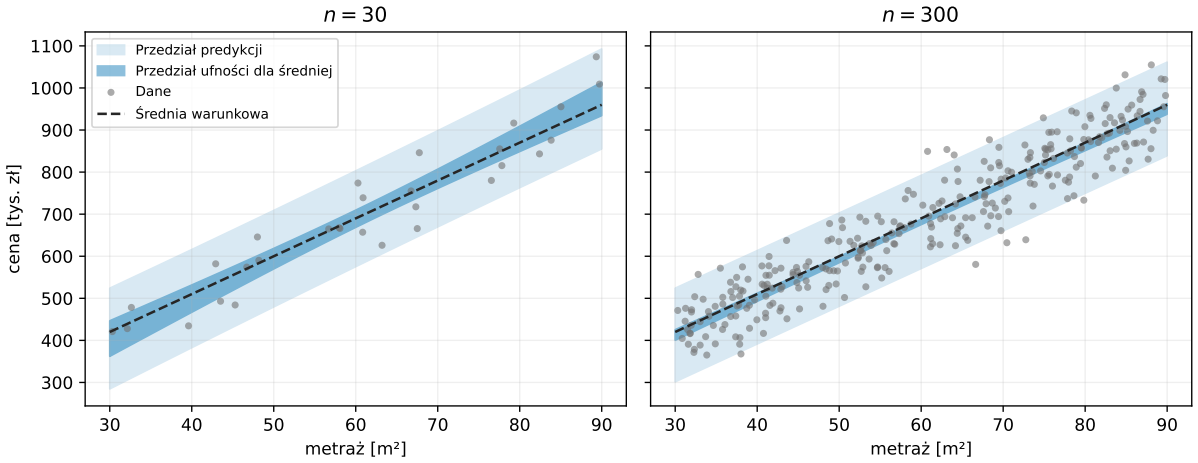
Precyzja oszacowania dotyczy rozrzutu oszacowań, które otrzymywalibyśmy, powtarzając badanie na próbach tej samej wielkości, dobieranych w ten sam sposób, i stosując tę samą metodę. Im mniejszy ten rozrzut, tym większa precyzja. **Dokładność** dotyczy bliskości oszacowań do rzeczywistej wartości szacowanej wielkości. Oszacowania mogą być precyzyjne, a mimo to systematycznie odbiegać od tej wartości.
Na przykład duża próba mieszkań wyłącznie z rynku pierwotnego może pozwolić precyzyjnie oszacować średnią cenę na tym rynku, ale użycie tej średniej jako oszacowania średniej ceny wszystkich mieszkań może prowadzić do systematycznego błędu. Sam wąski przedział ufności nie gwarantuje więc wiarygodnego wnioskowania: jego uzasadnienie zależy od założeń metody i sposobu doboru próby. Zarówno przy wnioskowaniu, jak i przy predykcji musimy określić, do jakiej populacji odnosimy wyniki i co uzasadnia wykorzystanie w tym celu dostępnej próby.

i Zależność a przyczynowość

Jeżeli mieszkania po remoncie mają przeciętnie wyższe ceny, nie oznacza to jeszcze, że zaobserwowana różnica jest skutkiem samego remontu. Obie grupy mogą różnić się także lokalizacją, metrażem czy standardem budynku. Pytanie o skutek remontu dotyczy natomiast porównania ceny tego samego mieszkania w dwóch sytuacjach: gdy przeprowadzimy remont i gdy go nie przeprowadzimy. Dla danego mieszkania obserwujemy tylko jedną z tych sytuacji, więc nie możemy bezpośrednio wyznaczyć jego indywidualnego skutku remontu.
Zwykle celem badania jest oszacowanie **przeciętnego skutku remontu w określonej populacji mieszkań**. Wymaga to odpowiedniego sposobu zaplanowania badania lub dodatkowych założeń pozwalających uzasadnić porównanie mieszkań remontowanych i nieremontowanych. Oszacowanie przeciętnego skutku nie oznacza jednak poznania skutku dla każdego mieszkania z osobna. Samo dopasowanie modelu opisującego zależność cen od cech mieszkań nie dostarcza uzasadnienia dla interpretacji przyczynowej. Dotyczy to także wielkości (1.10): opisuje ona różnicę między grupami mieszkań, a nie zmianę ceny po powiększeniu mieszkania.

Niepewność towarzyszy zarówno wnioskowaniu, jak i predykcji, ale dotyczy w nich różnych wielkości: we wnioskowaniu – ustalonej, choć nieznanej charakterystyki populacji, w predykcji – losowej wartości nowej obserwacji. **Przedział ufności dla średniej ceny** mieszkań o ustalonych cechach wyraża niepewność oszacowania tej średniej na podstawie próby. **Przedział predykcji dla ceny pojedynczego mieszkania** musi dodatkowo uwzględniać zróżnicowanie cen mieszkań o tych samych obserwowanych cechach. Możemy więc precyzyjnie oszacować średnią cenę w danej grupie, a mimo to przewidywać cenę konkretnego mieszkania z dużą niepewnością. Zwiększanie liczby obserwacji poprawia precyzję oszacowania średniej, ale samo w sobie nie usuwa zmienności cen wokół niej – tej samej, którą wcześniej wiązaliśmy z błędem nieredukowalnym.

Rysunek 1.1 pokazuje oba przedziały dla symulowanych cen mieszkań zależnych od metrażu, przy dwóch liczebnościach próby. Wzory, z których je wyznaczono, wyprowadzamy w rozdziale 6.



Rysunek 1.1.: Przedziały 95% wokół prostej dopasowanej do symulowanych cen mieszkań: ciemne pasmo – przedział ufności dla średniej ceny przy danym metrażu, jasne pasmo – przedział predykcji dla ceny pojedynczego mieszkania. Linia przerywana przedstawia średnią warunkową, znaną dzięki symulacji. Przy dziesięciokrotnie większej próbie przedział ufności wyraźnie się zwęża, a przedział predykcji prawie się nie zmienia.

Ten sam model może służyć obu celom: oszacowana funkcja średniej ceny pozwala zarówno przewidywać ceny mieszkań, jak i porównywać średnie ceny przy różnych wartościach cech. Każde zastosowanie wymaga jednak oceny według kryteriów właściwych dla danego celu. Tabela 1.1 zestawia te kryteria.

Tabela 1.1.: Predykcja i wnioskowanie na przykładzie cen mieszkań.

	Predykcja	Wnioskowanie
Pytanie	Jaka będzie cena tego mieszkania?	O ile różnią się średnie ceny dwóch grup mieszkań?
Wynik	przewidywanie $\hat{y} = \hat{f}(\mathbf{x})$	oszacowanie $\widehat{\Delta}$ charakterystyki populacji Δ
Kryterium jakości	ryzyko $R(\hat{f})$ na nowych danych	dokładność $\widehat{\Delta}$ i wiarygodność oceny jej niepewności
Niepewność dotyczy	losowej wartości nowej obserwacji	ustalonej, choć nieznanej wielkości Δ
Typowe narzędzie	zbiór walidacyjny, przedział predykcji	przedział ufności
Co może zawieść	generalizacja na nowe przypadki	założenia metody, dobór próby, rozdzielenie powiązanych cech

1.8. Trening modelu

Wiemy już, jakie zadania może spełniać model i jak oceniać jego predykcje. Pozostaje pytanie, jak na podstawie danych wyznaczyć regułę predykcji $\hat{f}$, która nowym obserwacjom przypisze przewidywaną wartość lub klasę. Chcielibyśmy wyznaczyć predyktor o możliwie małym ryzyku

$R(f)$. Nie znamy jednak rozkładu populacji P, względem którego ryzyko jest zdefiniowane. Dysponujemy jedynie zbiorem treningowym $\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)\}$. **Trening modelu** polega na wykorzystaniu tej próby do wyznaczenia reguły, którą będziemy stosować także do nowych obserwacji. Poniżej opiszemy ten proces z perspektywy zadania predykcyjnego.

Najpierw określamy klasę modeli $\mathcal{F}$ (por. Sekcja 1.2), czyli zbiór dopuszczalnych predyktorów. Każda funkcja $f \in \mathcal{F}$ przypisuje wektorowi cech $\mathbf{x}$ przewidywany wynik: w regresji jest to liczba, a w klasyfikacji – etykieta klasy. Wybór $\mathcal{F}$ wyraża założenie o tym, jakie zależności chcemy odtwarzać: możemy dopuścić na przykład tylko zależności liniowe albo również funkcje o bardziej złożonym przebiegu. Klasa zbyt wąska może nie zawierać funkcji, która dobrze opisuje interesującą nas zależność. Samo poszerzanie klasy nie gwarantuje jednak lepszego wyniku uczenia.

Aby porównać dopuszczalne predyktory, potrzebujemy **kryterium dopasowania**. Podstawowym wyborem jest ryzyko empiryczne zdefiniowane wzorem (1.9):

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^{n} L(y_i, f(\mathbf{x}_i)).$$

Dla każdego kandydata f obliczamy predykcje na danych treningowych, porównujemy je z zaobserwowanymi wynikami i uśredniamy poniesione straty. Przy stracie kwadratowej otrzymujemy średni kwadrat błędu na próbie, $\frac{1}{n}\sum_{i=1}^{n}(y_i - f(\mathbf{x}_i))^2$. Przy stracie 0–1 otrzymujemy odsetek błędnie sklasyfikowanych obserwacji, $\frac{1}{n}\sum_{i=1}^{n}\mathbb{1}(y_i \neq f(\mathbf{x}_i))$. W obu przypadkach mniejsza wartość oznacza lepsze dopasowanie według wybranego kryterium.

Prowadzi to do **zasady minimalizacji ryzyka empirycznego**:

$$\hat{f} \in \arg\min_{f \in \mathcal{F}} \widehat{R}_n(f). \tag{1.11}$$

Równoważnie możemy zapisać:

$$\hat{f} \in \mathcal{F} \qquad \text{oraz} \qquad \widehat{R}_n(\hat{f}) \leq \widehat{R}_n(f) \quad \text{dla każdego } f \in \mathcal{F}.$$

Wybrany predyktor $\hat{f}$ należy więc do klasy $\mathcal{F}$ i ma ryzyko empiryczne nie większe niż jakikolwiek inny predyktor z tej klasy.

Operator $\arg\min$ wskazuje argumenty, dla których minimalizowane wyrażenie osiąga najmniejszą wartość. Tutaj szukamy funkcji $f \in \mathcal{F}$. Minimum może być osiągane przez więcej niż jedną funkcję; $\hat{f}$ wybieramy spośród nich. Zakładamy tu, że minimum w wybranej klasie jest osiągane. Wzór określa zasadę wyboru modelu, ale nie podaje jeszcze sposobu jego znalezienia. W praktyce procedura obliczeniowa może zwracać jedynie rozwiązanie przybliżone.

Tę procedurę nazywamy algorytmem uczenia (por. Sekcja 1.2). Klasa $\mathcal{F}$ określa, jakie predyktory dopuszczamy, kryterium mówi, jak je porównujemy, a algorytm opisuje, jak na podstawie danych wyznaczamy konkretny model. Ta sama klasa i to samo kryterium mogą być obsługiwane przez różne algorytmy. Mogą one różnić się kosztem obliczeń, a przy dopasowaniu przybliżonym także otrzymanym wynikiem.

Minimalizacja ryzyka empirycznego jest ważnym schematem uczenia, ale nie każda metoda bezpośrednio minimalizuje stratę, którą później oceniamy predykcje. Typowy przykład daje klasyfikacja przebiegająca w dwóch etapach z sekcji 1.4. Model prawdopodobieństw klas dopasowujemy, minimalizując na danych treningowych średnią **straty logarytmicznej**, czyli ujemnego

logarytmu prawdopodobieństwa przypisanego zaobserwowanej klasie. Etykiety otrzymane po zastosowaniu reguły decyzyjnej oceniamy natomiast stratą 0–1. Strata 0–1 słabo nadaje się do dopasowania: mała zmiana parametrów zwykle nie zmienia liczby błędów, więc nie wskazuje, w którą stronę poprawiać model. Strata logarytmiczna reaguje na każdą zmianę prawdopodobieństw. Dlaczego jej minimalizacja prowadzi do sensownych prawdopodobieństw, wyjaśnimy w rozdziale 2.

Inne metody w ogóle nie minimalizują jawnego kryterium, tylko konstruują predykcję według ustalonej reguły, choćby na podstawie wyników obserwacji podobnych do przewidywanego przypadku. Dlatego opis metody powinien wskazywać zarówno sposób dopasowania, jak i kryterium oceny otrzymanego modelu.

Małe ryzyko empiryczne świadczy o dopasowaniu do próby, lecz nie zapewnia dobrej generalizacji. Dostatecznie bogata klasa może pozwolić niemal zapamiętać wyniki treningowe, łącznie z przypadkowymi odchyleniami, których nie da się przewidzieć dla nowych obiektów. Takie **nadmierne dopasowanie** może dać bardzo mały błąd treningowy i duży błąd na nowych danych. W uczeniu musimy więc uwzględniać złożoność dopuszczalnych modeli i oceniać ich działanie na danych niewykorzystanych do dopasowania. Do sposobów ograniczania złożoności i oceny generalizacji wrócimy w rozdziałach 4 i 5.

Podobny schemat występuje w uczeniu nienadzorowanym. Dysponujemy wtedy zbiorem $\mathcal{D} = \{\mathbf{x}_1, \ldots, \mathbf{x}_n\}$, bez zmiennej docelowej, więc kryterium nie porównuje predykcji ze znanymi odpowiedziami. Nadal określamy jednak dopuszczalną postać modelu, sposób oceny dopasowania oraz algorytm. W grupowaniu możemy na przykład ustalić liczbę grup i szukać takiego podziału obserwacji oraz takich środków grup, aby suma kwadratów odległości obserwacji od przypisanych im środków była jak najmniejsza. Kryterium wyraża wówczas przyjęte rozumienie dobrej struktury grup, a nie zgodność z etykietami dostarczonymi w danych.

Zarówno w uczeniu nadzorowanym, jak i nienadzorowanym trzeba zatem określić, jaką postać może przyjąć model i jak dane wpływają na jego dopasowanie.

1.9. Metody parametryczne i nieparametryczne

W poprzedniej sekcji punktem wyjścia do uczenia był wybór klasy modeli $\mathcal{F}$. Możemy ustalić postać zależności i na podstawie danych wyznaczyć jedynie pewną liczbę współczynników. Możemy też dopuścić, aby wraz z napływem danych opis zależności stawał się coraz bardziej szczegółowy. Rozróżnienie to prowadzi do **metod parametrycznych** i **nieparametrycznych**. Omówimy je na przykładzie przewidywania wartości liczbowej.

W podejściu parametrycznym przyjmujemy rodzinę funkcji

$$\mathcal{F} = \{f_\theta : \theta \in \Theta\}, \qquad \Theta \subseteq \mathbb{R}^d,$$

gdzie θ jest wektorem parametrów, a jego wymiar d jest ustalony i nie rośnie wraz z liczbą obserwacji n. Przy ustalonym zestawie cech i wybranej rodzinie funkcji trening polega na oszacowaniu θ. Otrzymujemy $\hat{\theta}$, a wraz z nim dopasowany predyktor $\hat{f} = f_{\hat{\theta}}$. Większa próba dostarcza więcej informacji do oszacowania tych samych parametrów.

Prostym przykładem jest **regresja liniowa** z jedną cechą:

$$f_\theta(x) = \beta_0 + \beta_1 x, \qquad \theta = (\beta_0, \beta_1).$$

Jeżeli x oznacza powierzchnię mieszkania, a wynikiem jest jego cena, model przypisuje każdemu dodatkowemu metrowi kwadratowemu taki sam przyrost przewidywanej ceny, równy β_1. Wyraz β_0 ustala położenie prostej; jego wartość dla $x = 0$ nie musi mieć praktycznej interpretacji, jeśli mieszkania o takim metrażu nie należą do zakresu stosowalności modelu. Przy stracie kwadratowej dobieramy oba współczynniki, minimalizując średni kwadrat błędu na danych treningowych. Niezależnie od tego, czy mamy sto, czy dziesięć tysięcy obserwacji, szacujemy dwa współczynniki. Dane zmieniają położenie i nachylenie prostej, ale nie pozwalają jej się zakrzywić.

W podejściu nieparametrycznym nie ograniczamy opisu zależności do rodziny wyznaczonej przez ustaloną, skończoną liczbę parametrów. Złożoność opisu może rosnąć wraz z liczbą obserwacji: dodatkowe dane mogą pozwalać odtwarzać coraz drobniejsze szczegóły zależności. Nie oznacza to, że model dopasowany do skończonej próby ma nieskończony rozmiar. Jego zapis jest skończony, lecz rozmiar ten nie musi być ograniczony z góry niezależnie od wielkości próby.

Przykładem jest **regresja k najbliższych sąsiadów**. Aby przewidzieć cenę mieszkania o metrażu x, wybieramy k mieszkań z próby treningowej, których metraże są najbliższe x, i uśredniamy ich ceny:

$$\hat{f}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i,$$

gdzie $N_k(x)$ oznacza zbiór indeksów tych obserwacji. Przy jednej cesze bliskość możemy mierzyć odległością $|x_i - x|$. W odróżnieniu od regresji liniowej nie wyznaczamy jednej prostej obowiązującej w całym zakresie metrażu. Dla każdego przewidywanego przypadku korzystamy z odpowiedniego fragmentu próby. Gdy zmienia się x, może zmieniać się również zestaw sąsiadów, a więc i przewidywana cena. Opis dopasowanego modelu obejmuje dane treningowe potrzebne do wyszukiwania sąsiadów, zamiast sprowadzać się do dwóch współczynników. Metodę najbliższych sąsiadów w zadaniu klasyfikacji omówimy w rozdziale 3.

> **i** Nieparametryczny nie znaczy „bez parametrów” ani „bez założeń”
>
> Metoda nieparametryczna może mieć wielkości sterujące jej działaniem, takie jak liczba sąsiadów k. Może też wymagać oszacowania wielu współczynników. O nazwie decyduje brak ograniczenia rodziny modeli do ustalonej, skończenie wymiarowej parametryzacji. Pozostają również założenia o odtwarzanej zależności. Uśrednianie wyników sąsiadów jest użyteczne, gdy funkcja regresji $f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ zmienia się niewiele przy niewielkiej zmianie $\mathbf{x}$ – wtedy wyniki sąsiadów mówią coś o średnim wyniku w punkcie $\mathbf{x}$. Znaczenie ma więc wybór cech, sposobu mierzenia odległości i wielkości sąsiedztwa. Zastąpienie prostej lokalnym uśrednianiem zmienia założenia modelu, ale ich nie usuwa.

W tym miejscu warto rozróżnić **parametry modelu** i **hiperparametry**. Współczynniki β_0 i β_1 są parametrami regresji liniowej: wyznaczamy je podczas dopasowania w ustalonej klasie modeli. Liczba sąsiadów k jest natomiast hiperparametrem metody k-NN: określa sposób konstruowania predykcji. Przy małym k odpowiedź zależy od niewielu bliskich obserwacji, a przy dużym – od średniej w szerszym otoczeniu. Hiperparametry ustalamy dla danego dopasowania, ale możemy je dobierać na podstawie danych, porównując wyniki różnych ustawień na zbiorze walidacyjnym. Do zasad takiego doboru wrócimy w rozdziale 5. Sam fakt, że pewna wielkość została dobrana z użyciem danych, nie przesądza więc, czy nazywamy ją parametrem, czy hiperparametrem; istotna jest jej rola w procedurze.

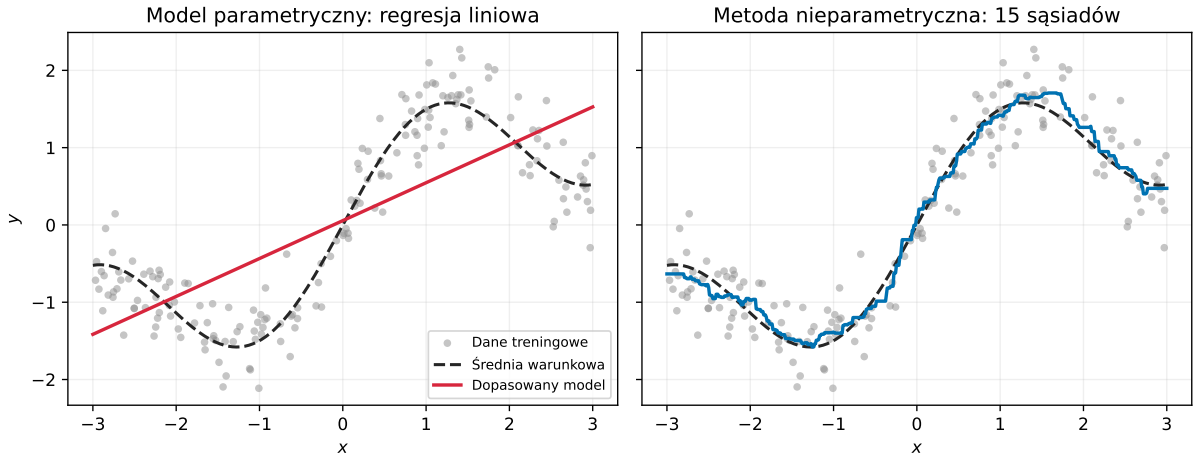
Wybór podejścia ma konsekwencje dla tego, czego możemy nauczyć się z dostępnej próby. Prosta rodzina parametryczna silnie ogranicza dopuszczalne zależności. Jeżeli ograniczenia dobrze odpowiadają problemowi, mogą ułatwić uczenie nawet przy niewielu obserwacjach. Jeśli jednak

średnia cena zmienia się z metrażem w sposób wyraźnie zakrzywiony, żadna liczba obserwacji nie sprawi, że pojedyncza prosta wiernie odtworzy ten przebieg. Takie ograniczenie może prowadzić do **niedopasowania**: model jest zbyt mało elastyczny, aby uchwycić istotną zależność.

Metoda nieparametryczna daje większą swobodę odtwarzania kształtu zależności, ale potrzebuje danych tam, gdzie chcemy poznać jej lokalny przebieg. Przy wielu cechach znalezienie dostatecznie licznej grupy rzeczywiście podobnych obiektów może wymagać bardzo dużej próby. Zbyt małe sąsiedztwo sprawia natomiast, że predykcja silnie reaguje na przypadkowe odchylenia pojedynczych wyników, co sprzyja nadmiernemu dopasowaniu. Zbyt duże sąsiedztwo może zacierać istotne zmiany zależności i prowadzić do niedopasowania. Elastycznością trzeba więc sterować również w metodach nieparametrycznych. Związek między elastycznością, wielkością próby i zmiennością dopasowania rozwiniemy w rozdziale 4.

Podział na metody parametryczne i nieparametryczne nie jest przy tym podziałem na modele liniowe i nieliniowe ani na proste i złożone. Na przykład rodzina funkcji $f_\theta(x) = a\exp(bx)$ ma dwa parametry, choć opisuje zależność nieliniową. Sieć neuronowa o ustalonej architekturze i ustalonej liczbie wag także jest modelem parametrycznym, nawet jeśli tych wag są miliony. Z kolei metoda nieparametryczna z silnym wygładzaniem może odtwarzać jedynie bardzo ogólny przebieg zależności. Sama nazwa podejścia nie przesądza zatem o elastyczności konkretnego dopasowania ani o jakości jego predykcji.

Na Rysunek 1.2 porównujemy oba podejścia na tych samych danych symulowanych. Średnia warunkowa wyniku ma zakrzywiony przebieg, a obserwacje odchylają się od niej wskutek szumu. Do próby dopasowujemy prostą oraz regresję k najbliższych sąsiadów z $k = 15$.



Rysunek 1.2.: Regresja liniowa i lokalne uśrednianie na tej samej próbie. Linia przerywana przedstawia średnią warunkową, znaną dzięki symulacji. Prosta nie odtwarza jej zakrzywienia; metoda najbliższych sąsiadów może za nim podążać, ale jej przebieg zależy także od lokalnych odchyleń w próbie.

Regresja liniowa wybiera jedną prostą jako przybliżenie całej zależności. Lokalne uśrednianie pozwala odtworzyć jej zakrzywienia, ale daje też drobne uskoki: przy zmianie zestawu sąsiadów zmienia się średnia ich wyników. Rysunek ilustruje różnicę w dopuszczalnej postaci predykcji. Nie stanowi ogólnego argumentu za przewagą jednej metody. Gdyby średnia warunkowa była liniowa, ograniczenie do prostych mogłoby być korzystne. W rzeczywistym zadaniu nie znamy tej średniej, a jakość obu metod musimy ocenić na danych niewykorzystanych do ich dopasowania i doboru hiperparametrów.

1.10. Kompromis między interpretowalnością a dokładnością

Porównanie z Rysunek 1.2 można odczytać także z innej strony. Działanie dopasowanej prostej da się streścić jednym zdaniem: każdy dodatkowy metr kwadratowy zwiększa przewidywaną cenę o $\widehat{\beta}_1$. Dla regresji k najbliższych sąsiadów takiego zdania nie ma. Aby opisać, jak przewidywana cena zmienia się z metrażem, trzeba pokazać cały wykres dopasowania albo wskazać dane treningowe, z których powstaje. Większa elastyczność pozwoliła odtworzyć zakrzywienie zależności, ale opis modelu przestał być zwięzły. Napięcie między zdolnością modelu do odtwarzania złożonych zależności a możliwością zrozumienia jego działania nazywa się **kompromisem między interpretowalnością a dokładnością**.

Model nazywamy **interpretowalnym**, jeżeli z jego struktury można odczytać, jak predykcja zależy od cech, bez obliczania jej dla wielu przykładowych obiektów. W regresji liniowej

$$f(\mathbf{x}) = \beta_0 + \beta_1 x_1 + ... + \beta_p x_p$$

predykcje dla dwóch obiektów różniących się jedynie wartością cechy x_j o jednostkę różnią się o β_j, niezależnie od wartości pozostałych cech. Całą zależność opisuje $p + 1$ liczb, a wkład każdej cechy można rozpatrywać osobno. Na tę przejrzystość składa się kilka własności:

- **addytywność** – predykcja jest sumą wkładów poszczególnych cech, więc wpływ jednej cechy nie zależy od wartości pozostałych;
- **prosta postać wkładów** – na przykład liniowa lub monotoniczna;
- **rzadkość** – model korzysta z niewielu cech; współczynniki przy trzech cechach można objąć jednym spojrzeniem, przy trzystu już nie.

Własności te można zachowywać w różnym stopniu. **Model addytywny**

$$f(\mathbf{x}) = \beta_0 + g_1(x_1) + ... + g_p(x_p)$$

dopuszcza nieliniowe funkcje g_j, na przykład zakrzywioną zależność ceny od metrażu, ale zachowuje addytywność: wkład każdej cechy można przedstawić jako osobną krzywą. Addytywność tracimy, gdy dopuszczamy **interakcje**, czyli sytuacje, w których wpływ jednej cechy zależy od wartości innej. Jeżeli dodatkowy metr kwadratowy podnosi cenę bardziej w centrum miasta niż na jego obrzeżach, pytanie „o ile rośnie cena wraz z metrażem?" nie ma jednej odpowiedzi. Odpowiedź zależy od lokalizacji, a przy wielu wzajemnie oddziałujących cechach – od ich kombinacji.

Warto odróżnić interpretację **globalną**, opisującą zachowanie modelu w całym zakresie cech, od **lokalnej**, wyjaśniającej pojedynczą predykcję. Regresja k najbliższych sąsiadów jest lokalnie przejrzysta: przewidywana cena jest średnią cen k wskazanych mieszkań, które możemy obejrzeć. Globalnie nie ma zwięzłego opisu. Przy wielu cechach również lokalne wyjaśnienie staje się mniej oczywiste, bo to, które mieszkania uznajemy za podobne, zależy od wyboru odległości i skal poszczególnych cech.

Popularne metody można schematycznie uporządkować od najbardziej do najmniej interpretowalnych (por. James i in. 2023, rozdz. 2):

1. regresja liniowa z niewielką liczbą niezerowych współczynników, na przykład dopasowana metodą lasso, która część współczynników ustawia dokładnie na zero;
2. regresja liniowa ze wszystkimi cechami;
3. modele addytywne;

4. drzewa decyzyjne, w których predykcję wyznacza ciąg pytań o wartości cech, na przykład „czy metraż przekracza 55 m²?”;
5. zespoły wielu drzew oraz sieci neuronowe.

W tej samej kolejności rośnie zwykle elastyczność. Uporządkowanie jest jednak przybliżone: płytkie drzewo z kilkoma pytaniami jest czytelniejsze niż regresja liniowa z setkami cech, a drzewo o tysiącach liści – mniej czytelne niż model addytywny.

Kompromis jest tendencją, a nie prawem. Dokładność, o którą chodzi, to jakość predykcji na nowych danych, a nie dopasowanie do próby treningowej. Bogatsza klasa modeli pozwala dopasować się do próby co najmniej równie dobrze jak uboższa, ale – jak zauważyliśmy w sekcji 1.8 – może przy tym odtwarzać przypadkowe odchylenia. Jeżeli średnia warunkowa jest liniowa, prosta nie traci niczego na niedopasowaniu, a metoda najbliższych sąsiadów płaci za swoją swobodę większą wrażliwością na losowość próby. Prostszy model jest wtedy jednocześnie czytelniejszy i dokładniejszy. Rudin (2019) zwraca uwagę, że w wielu zadaniach na danych tabelarycznych z sensownie określonymi cechami różnica dokładności między dobrze dopasowanymi modelami interpretowalnymi a złożonymi jest niewielka. Wyraźną przewagę elastyczne modele osiągają zwykle wtedy, gdy pojedyncze cechy nie mają osobnego znaczenia, a istotna informacja tkwi w ich złożonych układach – jak w obrazach, dźwięku czy tekście, gdzie pojedynczy piksel lub znak niewiele mówi. Część elastyczności można też przenieść do doboru cech: logarytm ceny lub metraż podniesiony do kwadratu pozwalają modelowi liniowemu opisać zakrzywioną zależność bez utraty addytywności. Czy kompromis rzeczywiście występuje w danym zadaniu, trzeba więc sprawdzić, porównując modele na danych niewykorzystanych do ich dopasowania.

Czytelny nie znaczy trafny. Łatwość odczytania współczynnika nie gwarantuje, że odczytana wartość opisuje interesującą nas zależność. Jak zauważyliśmy w sekcji 1.7, β_j opisuje różnicę średnich przy ustalonych wartościach pozostałych cech *uwzględnionych w modelu*. Dodanie lub usunięcie cechy może zmienić zarówno wartość współczynnika, jak i jego znaczenie. Gdy metraż i liczba pokoi są silnie powiązane, oszacowania obu współczynników bywają niestabilne: niewielka zmiana próby może przesunąć „wpływ” z jednej cechy na drugą, choć predykcje prawie się nie zmieniają. Jeżeli zaś rzeczywista zależność jest zakrzywiona, nachylenie dopasowanej prostej jest jej uśrednionym podsumowaniem, a jego wartość zależy od tego, jakie metraże przeważają w próbie. Wreszcie żaden, nawet najprostszy, model zależności statystycznej nie uzasadnia sam przez się interpretacji przyczynowej. Interpretowalny model daje prostą odpowiedź, ale trzeba osobno uzasadnić, że jest to odpowiedź na zadane pytanie.

Wybór zależy od celu i kontekstu. Jeżeli celem jest predykcja, najważniejsza jest jakość przewidywań i model elastyczny jest uzasadniony wtedy, gdy rzeczywiście przewiduje lepiej. Jeżeli celem jest wnioskowanie, potrzebujemy modelu, którego wielkości odpowiadają na postawione pytanie i pozwalają ocenić niepewność ich oszacowania; przemawia to za prostszymi strukturami, o ile ich założenia są uzasadnione. Poza samym celem analizy liczy się też sposób użycia modelu. Gdy model wspiera decyzje dotyczące ludzi – przyznanie kredytu, kwalifikację do leczenia – często trzeba uzasadnić pojedynczą decyzję, poddać model zewnętrznej kontroli lub spełnić wymagania prawne.

Interpretowalność pomaga również wykryć, że model nauczył się zależności prawdziwej w danych, lecz bezużytecznej lub szkodliwej w zastosowaniu. Caruana i in. (2015) opisują model ryzyka zgonu pacjentów z zapaleniem płuc, który miał wspierać decyzje o hospitalizacji. Jedna z odczytanych z niego reguł głosiła, że astma *obniża* ryzyko. W danych tak właśnie było: pacjentów z astmą od razu kierowano na intensywną terapię, a intensywne leczenie zmniejszało ich śmiertelność. Model zastosowany zgodnie z przeznaczeniem kierowałby jednak do leczenia domowego właśnie tych chorych, którzy potrzebowali najintensywniejszej opieki. Regułę zauważono, bo model był czytelny. Najdokładniejszym modelem w tamtym badaniu okazała się sieć neuronowa, ale uznano ją za zbyt ryzykowną: mogła nauczyć się tej samej zależności, a nie dało

się tego sprawdzić. Przykład pokazuje, że dobra ocena na danych pochodzących z tego samego źródła co dane treningowe nie wykrywa modelu dokładnego z niewłaściwych powodów.

Zadania

Zadanie 1.1. Wybierz model spoza analizy danych, na przykład schemat linii metra, mapę pogody w prognozie telewizyjnej albo manekina używanego w testach zderzeniowych. Wskaż jego cel, pominięte szczegóły, zachowane relacje oraz sytuację, w której przestaje być użyteczny (Sekcja 1.1).

Zadanie 1.2. Dla każdej sytuacji rozstrzygnij, czy jest to zadanie uczenia nadzorowanego, czy nienadzorowanego, a w pierwszym przypadku – czy jest to regresja, czy klasyfikacja. Uzasadnij odpowiedź i wskaż przypadki, w których rozstrzygnięcie zależy od celu analizy (Sekcja 1.4).

a) Przewidywanie liczby wizyt pacjenta w przychodni w ciągu roku.
b) Przewidywanie oceny filmu w skali od 1 do 5 gwiazdek.
c) Przewidywanie województwa zamieszkania klienta na podstawie jego historii zakupów.
d) Podział klientów sklepu internetowego na grupy o podobnych zwyczajach zakupowych.
e) Szacowanie prawdopodobieństwa, że kredytobiorca spłaci kredyt.

Zadanie 1.3. Dla każdej sytuacji rozstrzygnij, czy celem jest predykcja, czy wnioskowanie, i zaproponuj, jak oceniać jakość modelu (Sekcja 1.7).

a) Bank chce automatycznie odrzucać wnioski kredytowe o wysokim ryzyku niespłacenia.
b) Ministerstwo chce wiedzieć, o ile zmienią się wyniki egzaminów, jeśli zmniejszy liczebność klas.
c) Sklep chce zaplanować zapasy na przyszły tydzień.

W której z tych sytuacji zaobserwowana w danych zależność nie wystarcza do odpowiedzi na postawione pytanie? Dlaczego?

Zadanie 1.4. Dla regresji liniowej i regresji k najbliższych sąsiadów wskaż osobno klasę modeli, model dopasowany i algorytm uczenia. Który z tych elementów zmienia się po dołączeniu nowych obserwacji do zbioru treningowego, a który pozostaje taki sam?

Zadanie 1.5. Metoda k najbliższych sąsiadów jest nieparametryczna. Wskaż jej hiperparametry i założenia, które przyjmujemy, stosując ją (Sekcja 1.9). Czy regresja wielomianowa, w której stopień wielomianu dobieramy na podstawie danych, jest metodą parametryczną? Uzasadnij odpowiedź.

Zadanie 1.6. Wykaż, że w regresji jednego najbliższego sąsiada ryzyko empiryczne (1.9) obliczone na zbiorze treningowym jest równe zeru, o ile w zbiorze tym nie ma dwóch obserwacji o tych samych cechach. Czy wynika stąd cokolwiek o ryzyku tego predyktora? Co się zmienia, jeżeli w zbiorze występują obserwacje o jednakowych cechach i różnych wynikach?

Zadanie 1.7. Podaj przykład zadania predykcyjnego, w którym dodanie jednej cechy zmniejsza błąd nieredukowalny, oraz przykład, w którym zwiększenie liczby obserwacji nie zmniejsza ryzyka dopasowanego modelu. Wyjaśnij każdy z nich w kategoriach błędu redukowalnego i nieredukowalnego.

Zadanie 1.8. Zmienna $X \in \{1, 2, 3\}$ i binarna zmienna Y mają rozkład łączny

$p(x, y)$	$x = 1$	$x = 2$	$x = 3$
$y = 0$	0,24	0,12	0,06
$y = 1$	0,06	0,28	0,24

a) Wyznacz rozkład brzegowy X oraz $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$.
b) Reguła wskazuje klasę 1, gdy $\eta(x) > 1/2$. Wyznacz jej prawdopodobieństwo błędu. Korzystając z faktu, że reguła ta jest optymalna przy stracie 0–1 (Sekcja 1.6), podaj wartość błędu nieredukowalnego.
c) Oblicz $\mathbb{P}(Y = 1)$ bezpośrednio z tabeli oraz jako $\sum_x \eta(x)\, p(x)$. Jaką tożsamość w ten sposób sprawdzasz?
d) Jaki błąd popełnia klasyfikator, który zawsze wskazuje klasę 1? Który składnik błędu jest tu większy niż dla reguły z punktu b)?

Zadanie 1.9. W klasyfikacji binarnej zakodujmy klasy jako -1 i 1, a przez $\eta(\mathbf{x})$ oznaczmy $\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$. Wyraź $\mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ przez $\eta(\mathbf{x})$ i odwrotnie. Jak wygląda ta zależność przy kodowaniu klas dowolnymi liczbami $a \neq b$?

Zadanie 1.10. Zmienna $X \in \{0, 1, 2\}$ ma rozkład $p(0) = \frac{1}{4}$, $p(1) = \frac{1}{2}$, $p(2) = \frac{1}{4}$. Przy $X = 0$ zawsze $Y = 0$; przy $X = 1$ zmienna Y ma rozkład jednostajny na $\{0, 1, 2, 3\}$; przy $X = 2$ przyjmuje wartości 2 i 3 z jednakowymi prawdopodobieństwami.

a) Zapisz tabelę rozkładu łącznego $p(x, y)$.
b) Wyznacz $f^*(x) = \mathbb{E}[Y \mid X = x]$ oraz możliwe wartości $\varepsilon = Y - f^*(X)$ przy każdym x.
c) Sprawdź, że $\mathbb{E}[\varepsilon \mid X = x] = 0$ dla każdego x, i oblicz $\mathrm{Var}(\varepsilon \mid X = x)$. Czy ε jest niezależny od X? Co to mówi o warunku w (1.4)?
d) Oblicz ryzyko kwadratowe predyktora f^* oraz predyktora stałego $f(x) = \mathbb{E}[Y]$. Różnica tych wartości jest ceną za pominięcie cechy.

Zadanie 1.11. Niech X ma rozkład jednostajny na $[0, 1]$.

a) Wyznacz gęstość zmiennej $U = X^2$ i sprawdź, że przyjmuje ona wartości większe od 1, a nawet dowolnie duże. Dlaczego nie prowadzi to do sprzeczności?
b) Niech $Y \mid X = x \sim \mathcal{N}(x^2, \sigma^2)$. Podaj funkcję regresji f^* i wyznacz $\mathbb{E}[Y]$, korzystając z prawa iterowanej wartości oczekiwanej.
c) Oblicz ryzyko kwadratowe predyktora f^* oraz najlepszego predyktora stałego. Jaka część ryzyka tego drugiego wynika z pominięcia cechy X?

Zadanie 1.12. Urna U1 zawiera 5 kul białych i 2 czarne, urna U2 – 3 białe i 1 czarną. Najpierw losujemy urnę: U1 z prawdopodobieństwem 0,4, U2 z prawdopodobieństwem 0,6. Następnie z wylosowanej urny losujemy jedną kulę. Niech Y oznacza urnę, a X – kolor kuli. Obserwujemy tylko kolor.

a) Rozkład łączny jest tu zadany w postaci $p(y)\, p(x \mid y)$, a nie $p(x)\, p(y \mid x)$ jak w (1.1). Zapisz tabelę $p(x, y)$, a następnie wyznacz rozkład brzegowy $p(x)$ i rozkład warunkowy $p(y \mid x)$. Ile wynosi $\mathbb{P}(Y = \mathrm{U2} \mid X = \text{czarna})$?
b) Zasymuluj N powtórzeń doświadczenia w Pythonie, losując w każdym powtórzeniu najpierw urnę, potem kulę. Oszacuj $p(x, y)$ częstościami w próbie, a $\mathbb{P}(Y = \mathrm{U2} \mid X = \text{czarna})$ – frakcją powtórzeń z urną U2 wśród tych, w których wylosowano kulę czarną. Porównaj wyniki z punktem a) dla $N = 100$, 10^4 i 10^6.

c) Niech $n(x, y)$ oznacza liczbę powtórzeń z wynikiem (x, y), a $n(x)$ – liczbę powtórzeń, w których kula miała kolor x. Wykaż, że

$$n(x) = \sum_y n(x, y), \qquad \frac{n(x, y)}{N} = \frac{n(x, y)}{n(x)} \cdot \frac{n(x)}{N}.$$

Które wzory z sekcji 1.5 przybliżają te tożsamości? Dlaczego oszacowania z punktu b) muszą je spełniać dokładnie, niezależnie od N?

Zadanie 1.13. Niech $Y = X_1 + X_2 + \varepsilon$, gdzie X_1, X_2 i ε są niezależne, $X_1, X_2 \sim \mathcal{N}(0, 1)$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

a) Wyznacz funkcję regresji i błąd nieredukowalny przy stracie kwadratowej, gdy dostępne są obie cechy, oraz gdy dostępna jest tylko X_1.
b) Sprawdź oba wyniki symulacją w Pythonie: wygeneruj dużą próbę i oblicz średnią stratę kwadratową obu funkcji regresji.
c) Powtórz rachunek dla przypadku, w którym X_1 i X_2 mają współczynnik korelacji ρ. Jak błąd nieredukowalny przy samej cesze X_1 zależy od ρ? Zinterpretuj przypadki $\rho = 0$ i $|\rho| \to 1$.

Zadanie 1.14. Wygeneruj $n = 30$ obserwacji z modelu $Y = \sin(2\pi X) + \varepsilon$, gdzie X ma rozkład jednostajny na $[0, 1]$, a $\varepsilon \sim \mathcal{N}(0,\, 0{,}3^2)$. Dopasuj metodą najmniejszych kwadratów wielomiany stopni od 1 do 12 (np. funkcją `numpy.polynomial.Polynomial.fit`). Dla każdego stopnia oblicz ryzyko empiryczne na zbiorze treningowym oraz przybliż ryzyko średnią stratą na nowej próbie liczącej 100 000 obserwacji. Przedstaw obie wielkości na jednym wykresie razem z poziomem błędu nieredukowalnego.

a) Dlaczego ryzyko empiryczne maleje wraz ze stopniem wielomianu?
b) Czy którakolwiek krzywa spada poniżej błędu nieredukowalnego? Wyjaśnij, dlaczego tak jest.
c) Jak zmienia się obraz przy $n = 300$?

2. Ryzyko i predyktory optymalne

Model przypisuje obserwowanym cechom pewną odpowiedź. Skąd jednak wiadomo, która odpowiedź jest dobra? W poprzednim rozdziale wprowadziliśmy funkcję straty i ryzyko. Teraz wykorzystamy je do porównywania reguł przewidywania oraz do znalezienia najlepszej z nich.

Zaczniemy od małego przykładu, w którym wszystkie możliwości można wypisać w tabeli. Policzymy ryzyko kilku reguł, a następnie zobaczymy, jak wybierać odpowiedzi, aby je zminimalizować. Ten sam sposób rozumowania posłuży do przewidywania wartości liczbowej i do wskazywania klasy. Regresja i klasyfikacja będą dwoma zastosowaniami jednej zasady.

Przez większą część rozdziału będziemy zakładać, że znamy rozkład danych. To założenie pozwoli nam dokładnie wskazać cel uczenia: regułę, której szukalibyśmy, mając pełną wiedzę o rozkładzie. Na końcu wrócimy do sytuacji, w której zamiast rozkładu mamy jedynie próbę.

2.1. Ile kosztuje reguła przewidywania?

Sklep chce przewidywać dzienny popyt na pewien produkt. Dla uproszczenia przyjmijmy, że popyt Y może wynosić 0, 2 albo 4 sztuki. Znamy też rodzaj dnia X: A oznacza zwykły dzień, a B – dzień lokalnego wydarzenia, które przyciąga dodatkowych klientów. Rodzaj dnia znamy przed sporządzeniem prognozy.

Przyjmujemy następujący model probabilistyczny:

Tabela 2.1.: Rozkład popytu w przykładzie sklepu.

Rodzaj dnia x	$\mathbb{P}(X = x)$	$\mathbb{P}(Y = 0 \mid X = x)$	$\mathbb{P}(Y = 2 \mid X = x)$	$\mathbb{P}(Y = 4 \mid X = x)$
A	0,75	0,6	0,3	0,1
B	0,25	0,1	0,3	0,6

Tabela opisuje **założony rozkład**, nie wyniki zebrane w sześciu dniach. Mówi na przykład, że zwykłe dni stanowią 75% rozważanej populacji dni, a wśród nich zerowy popyt występuje z prawdopodobieństwem 0,6. Prawdopodobieństwo pary obliczamy ze wzoru

$$\mathbb{P}(X = A, Y = y) = \mathbb{P}(X = A)\,\mathbb{P}(Y = y \mid X = A).$$

Dla $y = 0$ otrzymujemy zatem $0{,}75 \cdot 0{,}6 = 0{,}45$.

Predyktor f przypisuje każdemu rodzajowi dnia prognozę liczbową. Zacznijmy od najprostszej reguły: **zawsze przewiduj 2 sztuki**, czyli $f(A) = f(B) = 2$. Oceńmy ją stratą kwadratową $L(y, a) = (y - a)^2$, gdzie a jest prognozą, a y rzeczywistym popytem. Gdy popyt wyniesie 2, strata będzie zerowa. Gdy wyniesie 0 lub 4, strata będzie równa 4.

Strata $(Y - f(X))^2 = (Y - 2)^2$ jest więc zmienną losową, której rozkład wynika z rozkładu pary (X, Y). Poniższa tabela pokazuje, jaką wartość straty otrzymujemy dla każdej pary i z jakim prawdopodobieństwem:

X	Y	Prawdopodobieństwo pary	Strata $(Y-2)^2$	Wkład do średniej straty
A	0	0,450	4	1,800
A	2	0,225	0	0
A	4	0,075	4	0,300
B	0	0,025	4	0,100
B	2	0,075	0	0
B	4	0,150	4	0,600
Razem		1		2,800

Sumując prawdopodobieństwa par prowadzących do tej samej straty, otrzymujemy jej rozkład:

$$\mathbb{P}((Y-2)^2=0)=0{,}3, \qquad \mathbb{P}((Y-2)^2=4)=0{,}7.$$

Jej wartość oczekiwana wynosi zatem $0\cdot 0{,}3+4\cdot 0{,}7=2{,}8$ – ten sam wynik daje suma ostatniej kolumny tabeli. Otrzymana średnia strata, 2,8, to **ryzyko** reguły f. W pojedynczym dniu strata wynosi tu 0 albo 4. Ryzyko opisuje przeciętny wynik stosowania tej reguły w populacji dni określonej przez nasz model.

W notacji z poprzedniego rozdziału zapisujemy to jako

$$R(f)=\mathbb{E}\big[L(Y,f(X))\big]. \tag{2.1}$$

Strata $L(Y,f(X))$ jest funkcją losowej pary (X,Y), a więc sama jest zmienną losową. Ryzyko jest jej wartością oczekiwaną.

Ryzyko zależy więc od trzech rzeczy: rozkładu danych, funkcji straty oraz predyktora. Aby porównanie dwóch predyktorów miało sens, oceniamy je przy tym samym rozkładzie i tej samej stracie.

Wartość 2,8 nie oznacza ani 2,8% pomyłek, ani przeciętnej pomyłki o 2,8 sztuki. Jest to średni **kwadrat** pomyłki, mierzony w kwadratach jednostki popytu. Interpretacja ryzyka zależy od straty. Dopiero przy stracie 0–1 ryzyko będzie prawdopodobieństwem błędu.

2.2. Ryzyko liczone w dwóch krokach

Spróbujmy innej reguły stałej: $f(A)=f(B)=1{,}5$. Dlaczego właśnie 1,5? Tyle wynosi średni popyt w całej populacji. Zsumowanie prawdopodobieństw par z poprzedniej tabeli daje

$$\mathbb{P}(Y=0)=0{,}475, \qquad \mathbb{P}(Y=2)=0{,}300, \qquad \mathbb{P}(Y=4)=0{,}225,$$

a zatem $\mathbb{E}[Y]=0\cdot 0{,}475+2\cdot 0{,}300+4\cdot 0{,}225=1{,}5$. Ryzyko tej prognozy wynosi

$$R(f)=0{,}475\cdot(0-1{,}5)^2+0{,}300\cdot(2-1{,}5)^2+0{,}225\cdot(4-1{,}5)^2=2{,}55.$$

Jest mniejsze niż ryzyko prognozy 2.

Przyjrzyjmy się teraz stracie prognozy 1,5 **przy ustalonym rodzaju dnia**. Zaczniemy od zwykłych dni, czyli warunku $X=A$. Korzystamy wtedy z rozkładu warunkowego $Y \mid X=A$: wartości popytu mają prawdopodobieństwa podane w wierszu A tabeli modelu. Każdej wartości popytu odpowiada określona strata:

Popyt y	$\mathbb{P}(Y = y \mid X = A)$	Strata $(y - 1{,}5)^2$
0	0,6	2,25
2	0,3	0,25
4	0,1	6,25

Wszystkie trzy wartości straty są różne, więc ostatnia kolumna wraz z prawdopodobieństwami opisuje rozkład straty pod warunkiem $X = A$. Jej warunkowa wartość oczekiwana wynosi

$$\mathbb{E}\big[(Y - 1{,}5)^2 \mid X = A\big] = 0{,}6 \cdot 2{,}25 + 0{,}3 \cdot 0{,}25 + 0{,}1 \cdot 6{,}25 = 2{,}05.$$

Dla dni wydarzenia wartości straty pozostają takie same, ale zmieniają się ich prawdopodobieństwa. Korzystając z wiersza B tabeli modelu, otrzymujemy

$$\mathbb{E}\big[(Y - 1{,}5)^2 \mid X = B\big] = 0{,}1 \cdot 2{,}25 + 0{,}3 \cdot 0{,}25 + 0{,}6 \cdot 6{,}25 = 4{,}05.$$

Te dwie warunkowe wartości oczekiwane nazywamy **ryzykami warunkowymi**: opisują przeciętną stratę prognozy osobno dla każdego rodzaju dnia.

Co otrzymamy, gdy uśrednimy je po rozkładzie X? Zwykłe dni mają prawdopodobieństwo 0,75, a dni wydarzenia 0,25, zatem

$$0{,}75 \cdot 2{,}05 + 0{,}25 \cdot 4{,}05 = 2{,}55.$$

Otrzymaliśmy ryzyko obliczone wcześniej bezpośrednio. Ta zgodność wynika ze **wzoru na iterowaną wartość oczekiwaną**:

$$\mathbb{E}\big[(Y - 1{,}5)^2\big] = \mathbb{E}\Big[\mathbb{E}\big[(Y - 1{,}5)^2 \mid X\big]\Big].$$

Najpierw obliczamy wartość oczekiwaną straty przy ustalonym rodzaju dnia, a następnie uśredniamy otrzymane wartości po rozkładzie rodzajów dni.

Wprowadźmy zapis, który pozwoli powtórzyć ten rachunek dla dowolnej prognozy a i dowolnych cech $\mathbf{x}$:

$$r(a \mid \mathbf{x}) = \mathbb{E}\big[L(Y, a) \mid \mathbf{X} = \mathbf{x}\big]. \tag{2.2}$$

W tym wyrażeniu $\mathbf{x}$ i a są ustalone. Uśredniamy po możliwych wynikach Y wśród obiektów o cechach $\mathbf{x}$. Przy skończenie wielu wynikach jest to po prostu suma

$$r(a \mid \mathbf{x}) = \sum_{y} L(y, a)\mathbb{P}(Y = y \mid \mathbf{X} = \mathbf{x}).$$

W przykładzie pojedynczą cechą jest rodzaj dnia, więc piszemy $r(a \mid A)$ i $r(a \mid B)$.

Dla dowolnej reguły f otrzymujemy

$$R(f) = 0{,}75\, r(f(A) \mid A) + 0{,}25\, r(f(B) \mid B).$$

Ogólny zapis tej samej zasady to

$$R(f) = \mathbb{E}\big[r(f(\mathbf{X}) \mid \mathbf{X})\big] = \mathbb{E}\Big[\mathbb{E}\big[L(Y, f(\mathbf{X})) \mid \mathbf{X}\big]\Big]. \tag{2.3}$$

Jest to zastosowanie wzoru na iterowaną wartość oczekiwaną z rozdziału 1.

Gdy cechy i odpowiedź przyjmują skończenie wiele wartości, przejście to można zobaczyć bezpośrednio w sumach:

$$\begin{aligned} R(f) &= \sum_{\mathbf{x}} \sum_{y} L(y, f(\mathbf{x})) \mathbb{P}(\mathbf{X} = \mathbf{x}, Y = y) \\ &= \sum_{\mathbf{x}} \sum_{y} L(y, f(\mathbf{x})) \mathbb{P}(\mathbf{X} = \mathbf{x}) \mathbb{P}(Y = y \mid \mathbf{X} = \mathbf{x}) \\ &= \sum_{\mathbf{x}} \mathbb{P}(\mathbf{X} = \mathbf{x}) \underbrace{\sum_{y} L(y, f(\mathbf{x})) \mathbb{P}(Y = y \mid \mathbf{X} = \mathbf{x})}_{r(f(\mathbf{x})|\mathbf{x})} . \end{aligned}$$

Sumujemy tu po wartościach $\mathbf{x}$ o dodatnim prawdopodobieństwie. W drugim wierszu rozpisaliśmy prawdopodobieństwo łączne jako iloczyn prawdopodobieństwa cech i prawdopodobieństwa warunkowego odpowiedzi. W trzecim wyłączyliśmy przed wewnętrzną sumę czynnik $\mathbb{P}(\mathbf{X} = \mathbf{x})$, który nie zależy od y. Wewnętrzna suma jest ryzykiem warunkowym, a zewnętrzna uśrednia je po rozkładzie cech.

2.3. Minimalizacja punktowa

Dotąd ocenialiśmy gotowe reguły. Teraz chcemy regułę wybrać. W przykładzie sklepu oznacza to wybór dwóch liczb: prognozy a_A na zwykły dzień i prognozy a_B na dzień wydarzenia. Ich ryzyko wynosi

$$0{,}75\, r(a_A \mid A) + 0{,}25\, r(a_B \mid B).$$

Ryzyko warunkowe $r(a_A \mid A)$ jest średnią straty prognozy a_A liczoną według rozkładu popytu w zwykłe dni. Ten rozkład nie zależy od naszych prognoz, więc pierwszy składnik zależy wyłącznie od a_A, a drugi z tego samego powodu wyłącznie od a_B. Wagi 0,75 i 0,25 też są ustalone. Możemy więc wybrać najlepszą odpowiedź w każdej grupie osobno. Zmniejszenie straty w grupie A nie wymaga pogorszenia prognozy w grupie B.

To rozumowanie nie zależy od straty kwadratowej ani od liczby grup. Prowadzi do wspólnej zasady dla regresji i klasyfikacji.

Twierdzenie 2.1 (Zasada minimalizacji punktowej)**.** *Jeżeli dla każdej rozważanej wartości cech* $\mathbf{x}$ *wybierzemy odpowiedź* $f^*(\mathbf{x})$ *minimalizującą ryzyko warunkowe* $r(a \mid \mathbf{x})$ *i wybory te wyznaczają dopuszczalny predyktor, to* f^* *minimalizuje ryzyko* $R(f)$ *wśród wszystkich predyktorów.*

Dowód. Niech f będzie dowolnym innym predyktorem. Dla każdej wartości cech mamy $r(f^*(\mathbf{x}) \mid \mathbf{x}) \le r(f(\mathbf{x}) \mid \mathbf{x})$. Uśrednienie tej nierówności po rozkładzie cech daje

$$R(f^*) = \mathbb{E}\big[r(f^*(\mathbf{X}) \mid \mathbf{X})\big] \le \mathbb{E}\big[r(f(\mathbf{X}) \mid \mathbf{X})\big] = R(f).$$

□ □

Słowo *punktowa* oznacza, że wybieramy odpowiedź osobno dla każdej wartości cech. Zamiast od razu szukać całej funkcji, rozwiązujemy prostszy problem: **przy tych cechach, którą odpowiedź opłaca się podać?** Jest to podstawowa zasada statystycznej teorii decyzji (Hastie i in. 2009, rozdz. 2.4).

Istotny jest zakres swobody. Jeśli wymagamy, aby prognoza była stała, to $a_A = a_B$ i nie możemy już wybierać tych liczb niezależnie. Podobnie, wymagając, aby prognozy leżały na jednej prostej,

wiążemy odpowiedzi w różnych punktach. Najlepszy predyktor w ograniczonej klasie może zatem mieć większe ryzyko niż optimum punktowe.

Warto też rozdzielić role prawdopodobieństw. O najlepszej odpowiedzi w grupie decyduje rozkład wyniku **w tej grupie**. Częstość grupy określa natomiast jej udział w całkowitym ryzyku. Przy niezmienionych rozkładach warunkowych zmiana proporcji grup nie zmienia ich punktowych optimów, ale może zmienić ryzyko oraz najlepszą regułę stałą.

> **Uwaga o zakresie twierdzenia**
>
> Dla cech dyskretnych wystarczy rozpatrywać wartości o dodatnim prawdopodobieństwie. W ogólnym przypadku rozkłady warunkowe i predyktory optymalne określamy z dokładnością do zbiorów cech o prawdopodobieństwie zero. Zakładamy też mierzalność wybranego predyktora, aby jego ryzyko było określone. Wystarczy więc, aby punktowa nierówność zachodziła prawie wszędzie względem rozkładu cech. W przykładach skończonych te zastrzeżenia nie wymagają dodatkowych rachunków.

2.4. Regresja: najlepsza prognoza liczbowa

Wróćmy do straty kwadratowej. W zwykłym dniu średni popyt wynosi

$$m_A = 0 \cdot 0{,}6 + 2 \cdot 0{,}3 + 4 \cdot 0{,}1 = 1,$$

a w dniu wydarzenia

$$m_B = 0 \cdot 0{,}1 + 2 \cdot 0{,}3 + 4 \cdot 0{,}6 = 3.$$

Sprawdźmy, dlaczego właśnie te liczby są najlepszymi prognozami. Dla zwykłego dnia ryzyko warunkowe odpowiedzi a jest równe

$$\begin{aligned} r(a \mid A) &= 0{,}6a^2 + 0{,}3(2-a)^2 + 0{,}1(4-a)^2 \\ &= a^2 - 2a + 2{,}8 = 1{,}8 + (a-1)^2. \end{aligned}$$

Najmniejszą wartością jest 1,8, osiąganą dla $a = 1$. Analogicznie $r(a \mid B) = 1{,}8 + (a-3)^2$, z minimum przy $a = 3$.

2.4.1. Dlaczego średnia?

Rachunek z przykładu można przeprowadzić dla dowolnego rozkładu wyniku. Ustalmy cechy $\mathbf{x}$ i oznaczmy średnią warunkową przez $m = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$. Różnicę między wynikiem a prognozą rozpisujemy jako

$$Y - a = (Y - m) + (m - a).$$

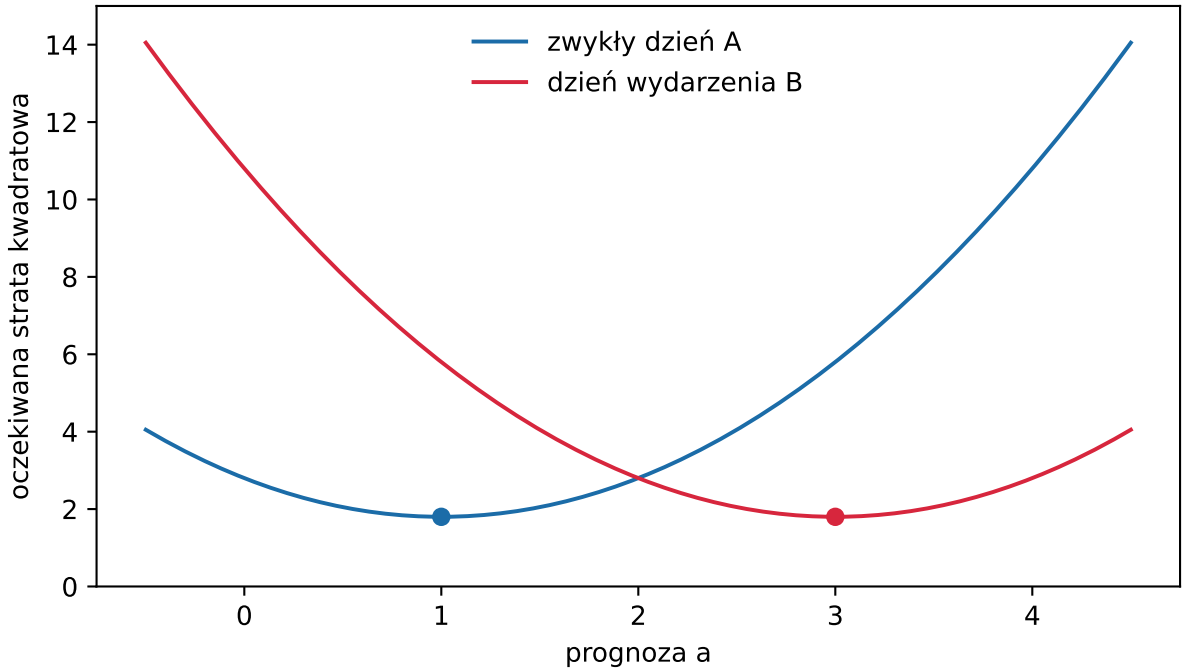
Po podniesieniu do kwadratu i uśrednieniu otrzymujemy

$$\begin{aligned} \mathbb{E}[(Y-a)^2 \mid \mathbf{X} = \mathbf{x}] = \mathbb{E}[(Y-m)^2 \mid \mathbf{X} = \mathbf{x}] \\ + 2(m-a)\mathbb{E}[Y - m \mid \mathbf{X} = \mathbf{x}] + (m-a)^2. \end{aligned}$$

Środkowy składnik znika, bo średnie odchylenie od średniej wynosi zero. Pierwszy składnik to wariancja warunkowa. Zatem

$$r(a \mid \mathbf{x}) = \operatorname{Var}(Y \mid \mathbf{X} = \mathbf{x}) + (m-a)^2. \tag{2.4}$$

Wariancja nie zależy od naszej prognozy. Drugi składnik jest nieujemny i zeruje się dokładnie dla $a = m$. W każdej grupie najlepszą odpowiedzią jest więc jej średnia. Minimalizacja punktowa daje wynik dla całego predyktora.



Rysunek 2.1.: Ryzyko warunkowe prognozy popytu przy stracie kwadratowej. W każdej grupie wybieramy minimum odpowiedniej krzywej. Oba minima są dodatnie.

Twierdzenie 2.2 (Optymalność funkcji regresji)**.** *Jeżeli* $\mathbb{E}[Y^2] < \infty$*, to przy stracie kwadratowej* $L(y,a) = (y-a)^2$ *ryzyko minimalizuje* ***funkcja regresji***

$$f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]. \tag{2.5}$$

W naszym przykładzie jest to reguła $f^*(A) = 1$, $f^*(B) = 3$. Jej ryzyko wynosi $0{,}75 \cdot 1{,}8 + 0{,}25 \cdot 1{,}8 = 1{,}8$. Możemy ją teraz porównać z innymi regułami:

Reguła	$f(A)$	$f(B)$	Ryzyko w A	Ryzyko w B	Ryzyko całkowite
Stała prognoza 2	2	2	2,8	2,8	2,8
Najlepsza stała	1,5	1,5	2,05	4,05	2,55
Prognozy skrajne	0	4	2,8	2,8	2,8
Predyktor optymalny	1	3	1,8	1,8	1,8

Najlepszą prognozą stałą jest średnia całej populacji, $\mathbb{E}[Y] = 1{,}5$. Dowód jest taki sam jak powyżej, tylko bez warunkowania. Znajomość rodzaju dnia pozwala zastąpić jedną średnią dwiema średnimi warunkowymi i obniżyć ryzyko z 2,55 do 1,8.

Samo korzystanie z cechy nie gwarantuje poprawy: reguła $(0, 4)$ jest gorsza od najlepszej stałej. Natomiast **najlepsza** reguła wykorzystująca cechę nie może być gorsza od najlepszej stałej, ponieważ zawsze może tę cechę zignorować.

Popyt przyjmuje tu tylko trzy wartości, ale nadal mamy do czynienia z regresją: przewidujemy wielkość liczbową, a różnica między wynikiem i prognozą ma znaczenie. Prognoza średniej nie musi być możliwą realizacją popytu. Jeśli chcielibyśmy na jej podstawie ustalić całkowitą liczbę sztuk do zamówienia, potrzebowalibyśmy dodatkowo opisu kosztów niedoboru i nadmiaru zapasu.

2.5. Klasyfikacja: najlepsza odpowiedź tak lub nie

Sklep może postawić inne pytanie: **czy popyt wyniesie co najmniej** 2 **sztuki?** Zachowujemy ten sam rozkład danych, lecz przewidujemy teraz klasę

$$Z = \mathbb{1}(Y \geq 2).$$

Litera Y nadal oznacza wielkość popytu, a Z – odpowiedź na nowe pytanie. Klasyfikator g ma zwracać 0 albo 1. Każdą pomyłkę oceniamy stratą 1, trafną odpowiedź stratą 0.

Z Tabela 2.1 odczytujemy

$$\mathbb{P}(Z = 1 \mid X = A) = 0{,}3 + 0{,}1 = 0{,}4, \qquad \mathbb{P}(Z = 1 \mid X = B) = 0{,}3 + 0{,}6 = 0{,}9.$$

Porównajmy obie odpowiedzi w każdej grupie:

Rodzaj dnia	Ryzyko odpowiedzi 0	Ryzyko odpowiedzi 1	Najlepsza odpowiedź
A	0,4	0,6	0
B	0,9	0,1	1

Na przykład w grupie A odpowiedź 0 jest błędna wtedy, gdy $Z = 1$, a więc z prawdopodobieństwem 0,4. Odpowiedź 1 jest błędna z prawdopodobieństwem 0,6. Wybieramy pierwszą z nich.

Wykonaliśmy te same kroki co w regresji: ustaliliśmy cechy, policzyliśmy oczekiwaną stratę możliwych odpowiedzi i wybraliśmy najlepszą. Minimalizacja punktowa mówi, że złożenie tych odpowiedzi w regułę $g(A) = 0$, $g(B) = 1$ daje minimum ryzyka całkowitego:

$$R(g) = 0{,}75 \cdot 0{,}4 + 0{,}25 \cdot 0{,}1 = 0{,}325.$$

Tym razem liczba ma interpretację prawdopodobieństwa: reguła myli się w 32,5% przypadków według założonego rozkładu.

2.5.1. Najbardziej prawdopodobna klasa

Uogólnijmy rachunek. W ogólnym problemie klasyfikacji wracamy do standardowego oznaczenia odpowiedzi przez $Y \in \{1, \ldots, K\}$. Niech $\eta_k(\mathbf{x}) = \mathbb{P}(Y = k \mid \mathbf{X} = \mathbf{x})$. Ryzyko warunkowe wskazania klasy a przy stracie 0–1 wynosi

$$r(a \mid \mathbf{x}) = \mathbb{P}(Y \neq a \mid \mathbf{X} = \mathbf{x}) = 1 - \eta_a(\mathbf{x}).$$

Najmniejsze ryzyko daje zatem klasa o największym prawdopodobieństwie. Ponownie stosujemy zasadę minimalizacji punktowej.

Twierdzenie 2.3 (Optymalność reguły Bayesa)**.** *Przy stracie* 0–1 *ryzyko minimalizuje* ***klasyfikator bayesowski***

$$g^*(\mathbf{x}) = \arg\max_k \eta_k(\mathbf{x}). \tag{2.6}$$

Jeśli kilka klas ma takie samo największe prawdopodobieństwo, można wybrać dowolną z nich.

Nazwa nie oznacza, że przyjęliśmy rozkład na parametrach modelu. Opisuje regułę wybierającą najbardziej prawdopodobną klasę przy danych cechach. Jej ryzyko nazywamy **błędem bayesowskim**:

$$R^* = \mathbb{E}\Big[1 - \max_k \eta_k(\mathbf{X})\Big]. \tag{2.7}$$

W każdym punkcie wybieramy najlepszą klasę, a następnie uśredniamy jej prawdopodobieństwo pomyłki po rozkładzie cech.

W przykładzie sklepu $\mathbb{P}(Z = 1) = 0{,}525$, więc najlepszy klasyfikator stały zawsze wskazuje 1. Jego błąd to 0,475. Dla porównania możemy wypisać wszystkie cztery reguły:

$g(A)$	$g(B)$	Ryzyko	Interpretacja
0	0	0,525	zawsze przewidujemy niski popyt
1	1	0,475	najlepsza reguła stała
0	1	0,325	reguła Bayesa
1	0	0,675	reguła odwrotna

Informacja o rodzaju dnia obniża najmniejsze możliwe prawdopodobieństwo błędu o 0,15, czyli o 15 punktów procentowych.

2.5.2. Jeden schemat, dwa zastosowania

Krok	Regresja ze stratą kwadratową	Klasyfikacja ze stratą 0–1
Ustalamy cechy	$\mathbf{X} = \mathbf{x}$	$\mathbf{X} = \mathbf{x}$
Rozważamy odpowiedź	liczba a	klasa a
Liczymy przeciętną stratę	$\mathbb{E}[(Y-a)^2 \mid \mathbf{X} = \mathbf{x}]$	$1 - \eta_a(\mathbf{x})$
Wybieramy minimum	średnia warunkowa	najbardziej prawdopodobna klasa
Liczymy ryzyko optimum	uśredniamy wariancje warunkowe	uśredniamy najmniejsze prawdopodobieństwa pomyłki

W obu zadaniach potrzebujemy opisu rozkładu odpowiedzi przy danych cechach. Różnią się możliwe odpowiedzi i sposób mierzenia pomyłek. Z tego powodu wartości 1,8 i 0,325 nie służą do porównania, które z tych dwóch zadań rozwiązaliśmy „lepiej”: mają inne znaczenie oraz inną jednostkę.

2.6. Dlaczego optimum ma dodatnie ryzyko?

Najlepsza prognoza popytu w zwykłym dniu wynosi 1, choć rzeczywisty popyt przyjmuje wartości 0, 2 i 4. Żadna pojedyncza liczba nie może jednocześnie trafić we wszystkie te wyniki. Podobnie najlepsza klasyfikacja zwykłego dnia to „popyt poniżej 2", ale w 40% takich dni popyt wynosi co najmniej 2.

Pozostaje więc niepewność, której nie usunie zmiana reguły opartej wyłącznie na rodzaju dnia. W sekcji 1.6 nazwaliśmy najmniejsze ryzyko osiągalne przy danych cechach i danej stracie **błędem nieredukowalnym**, a nadwyżkę ryzyka predyktora ponad to minimum – **błędem redukowalnym**. Teraz możemy oba składniki obliczyć.

Dla straty kwadratowej podstawiamy $a = f(\mathbf{x})$ do (2.4) i uśredniając po cechach, otrzymujemy

$$R(f) = \underbrace{\mathbb{E}\big[(f(\mathbf{X}) - f^*(\mathbf{X}))^2\big]}_{\text{błąd redukowalny}} + \underbrace{\mathbb{E}\big[\operatorname{Var}(Y \mid \mathbf{X})\big]}_{\text{błąd nieredukowalny}}. \tag{2.8}$$

Drugi składnik jest ryzykiem funkcji regresji. Pierwszy mierzy, jak daleko nasza reguła odbiega od niej w średnim kwadracie.

W przykładzie sklepu dla dowolnych prognoz a_A, a_B:

$$R(f) = 1{,}8 + 0{,}75(a_A - 1)^2 + 0{,}25(a_B - 3)^2.$$

Stała prognoza 1,5 ma nadwyżkę ryzyka $0{,}75 \cdot 0{,}5^2 + 0{,}25 \cdot (-1{,}5)^2 = 0{,}75$. Jej ryzyko 2,55 składa się więc z 1,8 nieusuwalnej zmienności oraz 0,75, które tracimy przez nieuwzględnienie rodzaju dnia.

W klasyfikacji rolę dolnej granicy pełni błąd bayesowski. W naszym przykładzie wynosi 0,325. Żadna reguła korzystająca wyłącznie z X nie obniży go, ponieważ w każdej grupie już wybraliśmy najmniejsze prawdopodobieństwo pomyłki. Odpowiednik rozkładu (2.8) dla straty 0–1 podajemy w sekcji 2.10.

Jak zaznaczyliśmy w rozdziale 1, przymiotnik „nieredukowalny" odnosi się do ustalonego zestawu cech. W przykładzie sklepu dodatkowa cecha, na przykład liczba wcześniejszych rezerwacji produktu, mogłaby rozróżnić dni, które dotąd traktowaliśmy jednakowo, i obniżyć optimum. Większa liczba dni w próbie uczącej pomaga natomiast dokładniej oszacować rozkład przy obecnych cechach; sama nie usuwa jego zmienności.

W rzeczywistym zastosowaniu nie znamy na ogół ani predyktora optymalnego, ani jego ryzyka. Samo wypłaszczenie poprawy wyników nie wystarcza więc do stwierdzenia, że osiągnęliśmy granicę możliwości. Może też świadczyć o ograniczeniach wybranej metody.

2.7. Inna strata, inna najlepsza prognoza

Dotąd w regresji używaliśmy straty kwadratowej, a w klasyfikacji straty 0–1. Wybór straty jest częścią sformułowania zadania: określa, jakie pomyłki uznajemy za szczególnie dotkliwe. Sprawdźmy, co się stanie po jego zmianie.

2.7.1. Strata absolutna i mediana

Strata absolutna $L(y, a) = |y - a|$ mierzy wielkość pomyłki w jednostce wyniku. Pomyłka o 4 sztuki jest przy niej dwa razy kosztowniejsza niż pomyłka o 2; przy stracie kwadratowej była cztery razy kosztowniejsza. Przy stracie kwadratowej jedna pomyłka o 10 sztuk kosztuje tyle co sto pomyłek o jedną sztukę, a przy stracie absolutnej – tyle co dziesięć.

W zwykłym dniu prognoza 0 ma przeciętną stratę absolutną

$$0{,}6 \cdot 0 + 0{,}3 \cdot 2 + 0{,}1 \cdot 4 = 1.$$

Prognoza równa średniej, czyli 1, daje natomiast

$$0{,}6 \cdot 1 + 0{,}3 \cdot 1 + 0{,}1 \cdot 3 = 1{,}2.$$

Średnia przestała być najlepszą odpowiedzią. W grupie A najlepsza jest mediana 0, a w grupie B mediana 4.

Przypomnijmy: mediana to liczba m, dla której co najmniej połowa prawdopodobieństwa leży na lewo od m lub w m i co najmniej połowa na prawo od m lub w m. Mediana nie musi być jedyna. Jej związek ze stratą absolutną można zrozumieć przez przesuwanie prognozy. Gdy przesuwamy ją w prawo, oddalamy się od wyników po lewej stronie, a zbliżamy do wyników po prawej. Przy stracie absolutnej liczy się ich prawdopodobieństwo, a nie to, jak daleko już się znajdują. Dopóki po prawej jest więcej niż połowa prawdopodobieństwa, przesunięcie w tę stronę zmniejsza przeciętną stratę. Minimum osiągamy w medianie.

Twierdzenie 2.4 (Optymalność mediany warunkowej)**.** *Jeżeli $\mathbb{E}[|Y|] < \infty$, to przy stracie absolutnej $L(y, a) = |y - a|$ ryzyko minimalizuje predyktor wybierający medianę rozkładu warunkowego:*

$$f^*(\mathbf{x}) = \operatorname{med}(Y \mid \mathbf{X} = \mathbf{x}). \tag{2.9}$$

W przykładzie sklepu porównanie wygląda następująco:

Reguła	Prognozy dla (A, B)	Ryzyko kwadratowe	Ryzyko absolutne
Średnie warunkowe	$(1, 3)$	1,8	1,2
Mediany warunkowe	$(0, 4)$	2,8	1,0

W każdej kolumnie inna reguła jest lepsza. Porównujemy reguły **w obrębie jednej kolumny**, ponieważ każda kolumna odpowiada innemu kryterium. Symbol f^* zawsze oznacza optimum przy określonej stracie. Gdy w dalszych rozdziałach mówimy o funkcji regresji, mamy na myśli średnią warunkową, niezależnie od tego, jaką inną stratę można rozważać.

2.7.2. Którą stratę wybrać?

Średnia i mediana różnią się najbardziej wtedy, gdy rozkład wyniku ma długi ogon. Zmieńmy w zwykłym dniu jedną wartość: zamiast popytu 4 z prawdopodobieństwem 0,1 niech zdarza się duże zamówienie na 20 sztuk. Średnia warunkowa rośnie wtedy z 1 do

$$0 \cdot 0{,}6 + 2 \cdot 0{,}3 + 20 \cdot 0{,}1 = 2{,}6,$$

choć w 90% zwykłych dni popyt nadal wynosi 0 albo 2. Mediana pozostaje równa 0. Optimum przy stracie absolutnej zależy od tego, ile prawdopodobieństwa leży po każdej stronie prognozy,

a nie od tego, jak daleko leżą wyniki. Przy stracie kwadratowej rzadkie zamówienie waży bardzo dużo: pomyłka o 18 sztuk kosztuje 324.

Ta sama różnica dotyczy oszacowań z próby. Kilka nietypowych obserwacji potrafi mocno przesunąć średnią, a medianę – niewiele. Mediana jest **odporna** na obserwacje odstające.

Żadna z tych strat nie jest „dokładniejsza". Wybór zależy od tego, ile kosztują pomyłki w zastosowaniu. Wróćmy do kosztów niedoboru i nadmiaru zapasu. Jeśli każda brakująca i każda nadmiarowa sztuka kosztuje tyle samo, koszt pomyłki rośnie liniowo z jej wielkością i dobrze opisuje go strata absolutna. Jeśli duże pomyłki są nieproporcjonalnie dotkliwe, bo na przykład niedobór kilkunastu sztuk oznacza utratę stałego klienta, bliższa jest strata kwadratowa. Gdy niedobór kosztuje inaczej niż nadmiar, optimum przesuwa się od mediany do innego kwantyla rozkładu warunkowego (Zadanie 2.10).

2.8. Od prawdopodobieństw do decyzji

W klasyfikacji zmiana straty może być potrzebna, gdy dwa rodzaje pomyłek mają różne konsekwencje. W przykładzie sklepu nadal $Z = 1$ oznacza popyt co najmniej 2 sztuk. Załóżmy, że przeoczenie takiego dnia kosztuje 3 jednostki, a fałszywy alarm kosztuje 1. Trafne decyzje mają koszt zerowy.

Dla grupy, w której prawdopodobieństwo $Z = 1$ wynosi p, koszt oczekiwany odpowiedzi 0 jest równy $3p$, a odpowiedzi 1 – $1 - p$. Dostajemy więc:

Rodzaj dnia	p	Koszt odpowiedzi 0	Koszt odpowiedzi 1	Najlepsza odpowiedź
A	0,4	1,2	0,6	1
B	0,9	2,7	0,1	1

Teraz w obu grupach wybieramy 1. W zwykłym dniu wysoki popyt jest mniej prawdopodobny niż niski, ale koszt jego przeoczenia przeważa nad częstszym, mniej kosztownym fałszywym alarmem.

Ryzyko nowej reguły wynosi $0{,}75 \cdot 0{,}6 + 0{,}25 \cdot 0{,}1 = 0{,}475$. Poprzednia reguła $(0, 1)$ ma przy tych kosztach ryzyko $0{,}75 \cdot 1{,}2 + 0{,}25 \cdot 0{,}1 = 0{,}925$. Zmiana zwiększa prawdopodobieństwo błędu z 32,5% do 47,5%, a jednocześnie zmniejsza oczekiwany koszt z 0,925 do 0,475. To dwie różne miary jakości tej samej decyzji.

2.8.1. Próg decyzyjny

Odpowiedź 1 opłaca się, gdy $1 - p \leq 3p$, czyli gdy $p \geq 1/4$. Zmiana kosztów przesunęła próg z $1/2$ do $1/4$. Ogólniej, jeśli koszt fałszywie ujemnej decyzji to $c_{10} > 0$, a koszt fałszywie dodatniej to $c_{01} > 0$, przy zerowych kosztach trafnych decyzji wybieramy klasę 1, gdy

$$p \geq \frac{c_{01}}{c_{01} + c_{10}}.$$

Jest to próg minimalizujący oczekiwany koszt (Elkan 2001). Przy równości obie decyzje kosztują przeciętnie tyle samo.

Dla wielu klas ten sam rachunek można zapisać za pomocą tabeli kosztów c_{ka}: kosztu odpowiedzi a, gdy prawdziwa klasa to k. Ryzyko warunkowe odpowiedzi a wynosi $\sum_k c_{ka}\eta_k(\mathbf{x})$. Zasada minimalizacji punktowej daje więc

$$f^*(\mathbf{x}) = \arg\min_a \sum_k c_{ka}\eta_k(\mathbf{x}). \tag{2.10}$$

To ta sama zasada, którą stosowaliśmy wcześniej; zmienił się sposób wyceniania odpowiedzi.

> **Dobry model, zły próg**
>
> Prawdopodobieństwa wynikają z rozkładu danych, a koszty z zastosowania. W naszym przykładzie prawdopodobieństwa 0,4 i 0,9 nie zmieniły się po zmianie kosztów. Zmieniły się decyzje podejmowane na ich podstawie. Dlatego warto rozdzielać oszacowanie prawdopodobieństwa od wyboru progu. Sama etykieta klasy nie zawiera informacji wystarczającej do ponownego wyboru decyzji przy innych kosztach.

2.9. Od znanego rozkładu do uczenia z danych

W przykładzie sklepu potrafiliśmy wyznaczyć optymalne prognozy, ponieważ podaliśmy cały rozkład w tabeli. W zastosowaniu rzeczywistym mamy obserwacje (x_i, y_i), a prawdopodobieństwa i średnie są nieznane. Wyprowadzone reguły mówią jednak, **czego szukać w danych**.

Jeżeli każda grupa występuje wielokrotnie, średni popyt możemy oszacować średnią zaobserwowanych wyników w tej grupie. Prawdopodobieństwo wysokiego popytu oszacujemy odsetkiem dni, w których wystąpił. Otrzymamy predyktor $\hat{f}$ lub klasyfikator $\hat{g}$. Daszek przypomina, że zależą od konkretnej próby. Inna próba może dać inne oszacowania.

Przy cechach ciągłych, takich jak temperatura, powierzchnia mieszkania czy dochód, dokładne powtórzenia całego zestawu cech zwykle nie występują. Nie możemy po prostu utworzyć licznej grupy dla każdej wartości $\mathbf{x}$. Musimy korzystać z innych obserwacji: na przykład z podobnych obiektów albo z zależności opisanej wspólnym wzorem. Pierwszą możliwość rozwiniemy w rozdziale 3.

Także ryzyka nie obliczymy zazwyczaj dokładnie, bo nie znamy rozkładu. Dla ustalonej reguły f możemy je oszacować na niezależnych nowych przypadkach, obliczając średnią strat

$$\frac{1}{N}\sum_{i=1}^{N} L(y_i, f(\mathbf{x}_i)).$$

Ta liczba zmienia się między próbami. Nawet dla optymalnej reguły zaobserwowany odsetek błędów może być niższy lub wyższy od błędu bayesowskiego. Nie przeczy to optymalności: dolna granica dotyczy ryzyka, a nie każdego wyniku skończonego eksperymentu.

Jeśli do oceny używamy danych, na których regułę dobrano, powstaje jeszcze inny problem: reguła mogła dopasować się do przypadkowych własności tych danych. Dlatego trzeba odróżniać ryzyko, jego ocenę na nowych przypadkach i błąd treningowy. Wrócimy do tego w rozdziałach 4 i 5.

Wspólny cel pozostaje prosty: przy danych cechach wybierać odpowiedź o najmniejszej oczekiwanej stracie. Poznane metody będą różnić się przede wszystkim sposobem, w jaki odtwarzają potrzebne informacje z ograniczonej próby.

2.10. Rozszerzenia: inne decyzje i ciągłe cechy

Materiał nieobowiązkowy

Poniższe ramki nie są wymagane w tekście głównym ani w zadaniach podstawowych. Narzędzia potrzebne w każdej z nich podano na jej początku.

Uzupełnienia rozwijają wspólny schemat w kilku kierunkach.

Ocena prawdopodobieństw

Model może zwracać prawdopodobieństwo klasy, zamiast od razu wybierać etykietę. Dla klas $Y \in \{0,1\}$ prognozę $p \in [0,1]$ można oceniać **stratą Briera** $L_{\mathrm{B}}(y,p) = (y-p)^2$ (Brier 1950). Ponieważ $\mathbb{E}[Y \mid \mathbf{X}=\mathbf{x}] = \eta(\mathbf{x})$, optymalność średniej daje od razu najlepszą prognozę $p = \eta(\mathbf{x})$.
Innym kryterium jest strata logarytmiczna:

$$L_{\log}(y,p) = \begin{cases} -\ln p, & y = 1, \\ -\ln(1-p), & y = 0. \end{cases}$$

Jej ryzyko warunkowe dla $0 < p < 1$ wynosi $-\eta \ln p - (1-\eta)\ln(1-p)$. Jeśli $0 < \eta < 1$, pochodna jest równa $(p-\eta)/(p(1-p))$, więc minimum przypada przy $p = \eta$. Dla $\eta = 0$ lub 1 minimum osiągamy na odpowiednim końcu przedziału, przyjmując zerową stratę dla pewnej, trafnej prognozy. Pewna błędna prognoza daje stratę nieskończoną.
Obie straty nagradzają podanie prawdziwego prawdopodobieństwa. Są przykładami **strat właściwych** (Gneiting i Raftery 2007). Ocena prawdopodobieństw i ocena decyzji przy określonych kosztach to dwa różne zadania. Dobre oszacowanie prawdopodobieństwa można następnie wykorzystać przy różnych progach.

Odmowa odpowiedzi

Możemy dopuścić dodatkowe działanie: odmowę, na przykład przekazanie przypadku do dodatkowej oceny. Niech trafna klasyfikacja kosztuje 0, pomyłka 1, a odmowa stałą kwotę $d \in (0,1)$.
Najlepsza klasa ma ryzyko warunkowe $1 - \max_k \eta_k(\mathbf{x})$, odmowa ma ryzyko d. Wystarczy porównać te dwie liczby:

$$f^*(\mathbf{x}) = \begin{cases} g^*(\mathbf{x}), & 1 - \max_k \eta_k(\mathbf{x}) \le d, \\ \text{odmowa}, & 1 - \max_k \eta_k(\mathbf{x}) > d. \end{cases} \tag{2.11}$$

Jest to **reguła Chowa** (Chow 1970). W przykładzie sklepu przy $d = 0{,}2$ odmawiamy w zwykłe dni, a w dni wydarzenia odpowiadamy 1. Ryzyko wynosi $0{,}75 \cdot 0{,}2 + 0{,}25 \cdot 0{,}1 = 0{,}175$. Nie jest to odsetek pomyłek: uwzględnia też koszt odmowy w 75% dni. Zmiana zbioru działań i straty zmieniła problem optymalizacji.

Nadwyżka ryzyka w klasyfikacji

Dla dowolnego klasyfikatora g przy stracie 0–1:

$$R(g) = R^* + \mathbb{E}\Big[\max_k \eta_k(\mathbf{X}) - \eta_{g(\mathbf{X})}(\mathbf{X})\Big]. \tag{2.12}$$

Wynika to z dodania i odjęcia $\max_k \eta_k(\mathbf{x})$ w wyrażeniu $1 - \eta_{g(\mathbf{x})}(\mathbf{x})$, a następnie uśrednienia po cechach. Nadwyżka mierzy prawdopodobieństwo trafienia utracone wskutek wyboru klasy innej niż najbardziej prawdopodobna. Jest nieujemna. Dla dwóch klas wynosi $\mathbb{E}[|2\eta(\mathbf{X}) - 1| \mathbb{1}(g(\mathbf{X}) \neq g^*(\mathbf{X}))]$: wybór gorszej klasy jest mniej kosztowny tam, gdzie obie klasy są prawie równie prawdopodobne.

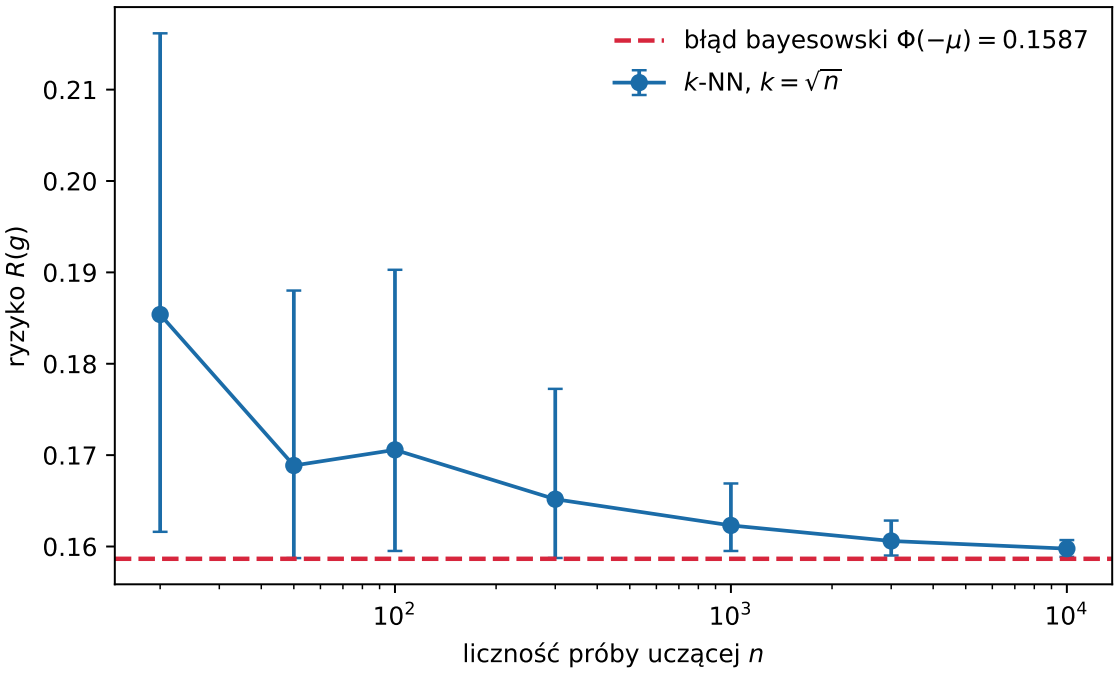
Przykład z ciągłą cechą: dwie klasy normalne

Wymagane są gęstość i dystrybuanta rozkładu normalnego. Eksperyment z metodą najbliższych sąsiadów można przeczytać po rozdziale 3. Zachowujemy go jako punkt odniesienia dla analizy tej metody i zaawansowanych zadań.
Rozważmy dwie równoliczne klasy, $\pi_0 = \pi_1 = \frac{1}{2}$, i jedną cechę X, która w klasie 0 ma rozkład $\mathcal{N}(-\mu, 1)$, a w klasie 1 rozkład $\mathcal{N}(\mu, 1)$, $\mu > 0$. Oznaczając przez φ gęstość, a przez Φ dystrybuantę rozkładu normalnego standardowego, mamy $p(x \mid Y = 0) = \varphi(x + \mu)$ i $p(x \mid Y = 1) = \varphi(x - \mu)$. Cecha jest ciągła, a klasa dyskretna, więc $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$ wyznaczamy ze wzoru Bayesa (1.2):

$$\eta(x) = \frac{\varphi(x - \mu)}{\varphi(x - \mu) + \varphi(x + \mu)} = \frac{1}{1 + e^{-2\mu x}}.$$

Zatem $\eta(x) > \frac{1}{2}$ dokładnie dla $x > 0$, reguła bayesowska to $g^*(x) = \mathbb{1}(x > 0)$, a błąd bayesowski wynosi

$$R^* = \mathbb{P}(\mathcal{N}(\mu, 1) < 0) = \Phi(-\mu).$$



Rysunek 2.2.: Ryzyko klasyfikatora k-NN przybliżone całkowaniem numerycznym, w zależności od liczności próby uczącej; cecha ma w klasach rozkłady $\mathcal{N}(-1, 1)$ i $\mathcal{N}(1, 1)$. Punkty to średnie z 25 niezależnych prób uczących, wąsy – kwantyle rzędu 0,1 i 0,9. Błąd bayesowski $\Phi(-1) \approx 0{,}1587$ wyznacza poziom, poniżej którego nie schodzi żaden klasyfikator, niezależnie od liczby obserwacji.

Wykres porównuje ryzyko reguł wyuczonych z różnych prób ze znanym błędem bayesowskim. Uśrednienie dotyczy tutaj także losowości próby uczącej. Ryzyko każdej dopasowanej reguły przybliżamy całkowaniem numerycznym; unikamy szumu zbioru testowego, ale pozostaje błąd numeryczny. Teoretyczna dolna granica dotyczy dokładnego ryzyka. W przykładzie wzrost liczności próby przybliża wyniki do optimum. Tempo tej poprawy zależy od rozkładu i metody.

Uwagi bibliograficzne

Przystępne wprowadzenie do predykcji, funkcji regresji i błędu bayesowskiego przedstawiają James i in. (2023). Szersze ujęcie wspólnego schematu minimalizacji oczekiwanej straty zawiera podręcznik Hastie i in. (2009). Statystyczną teorię decyzji, z rozróżnieniem przewidywania wyniku oraz wyboru działania, rozwijają także Bishop (2006) i Murphy (2022).

Czytelnik zainteresowany ścisłą teorią klasyfikacji znajdzie ją w monografii Devroye i in. (1996), a teorię regresji nieparametrycznej w książce Györfi i in. (2002). Są to lektury wymagające większego przygotowania probabilistycznego niż główny tekst tego rozdziału.

Koszty niesymetryczne i ich wpływ na próg klasyfikacji omawia Elkan (2001). Straty do oceny prognoz probabilistycznych systematycznie przedstawiają Gneiting i Raftery (2007); źródłową pracą dotyczącą straty kwadratowej dla prawdopodobieństw jest Brier (1950). Regułę klasyfikacji z możliwością odmowy bada Chow (1970).

Zadania

Pierwsze zadania prowadzą od obliczenia ryzyka do samodzielnego wyboru reguły. Następnie pojawiają się zmiana kosztów, wnioskowanie z informacji pośredniej i własności ogólne. Zadania oznaczone **Rozszerzenie** można pominąć przy pierwszej lekturze; wskazujemy w nich dodatkowe potrzebne narzędzia.

Zadanie 2.1. Od straty do ryzyka. Zespół wsparcia technicznego przewiduje liczbę zgłoszeń podczas wieczornego dyżuru. Przed rozpoczęciem dyżuru wiadomo, czy będzie to zwykły wieczór ($X = A$), czy wieczór po wdrożeniu nowej wersji systemu ($X = B$). W uproszczonym modelu liczba zgłoszeń Y przyjmuje tylko wartości 0, 1 i 3. Rozkład opisuje poniższa tabela.

x	$\mathbb{P}(X = x)$	$\mathbb{P}(Y = 0 \mid X = x)$	$\mathbb{P}(Y = 1 \mid X = x)$	$\mathbb{P}(Y = 3 \mid X = x)$
A	0,6	0,5	0,4	0,1
B	0,4	0,1	0,2	0,7

W kolejnych zadaniach będziemy wracać do tego rozkładu.

a) Wypisz sześć prawdopodobieństw łącznych $\mathbb{P}(X = x, Y = y)$. Sprawdź, że sumują się do 1.
b) Pierwsza reguła przewiduje zawsze jedno zgłoszenie: $f(A) = f(B) = 1$. Wypisz stratę kwadratową przy każdej parze (x, y) i oblicz ryzyko.
c) Druga reguła przewiduje zero zgłoszeń w zwykły wieczór, a trzy po wdrożeniu: $h(A) = 0$, $h(B) = 3$. Powtórz dla niej rachunek. Która reguła ma mniejsze ryzyko kwadratowe?

d) Wyjaśnij różnicę między stratą w pojedynczym wieczorze a ryzykiem. Co ryzyko mówi o błędach prognoz w wielu takich wieczorach? W jakiej jednostce wyrażone są obie wielkości?

Zadanie 2.2. Dwa etapy uśredniania. Dla obu reguł z Zadanie 2.1:

a) Oblicz ryzyko warunkowe osobno w grupach A i B.
b) Odzyskaj ryzyko całkowite jako średnią ważoną. Dlaczego zwykła średnia arytmetyczna ryzyk grup byłaby tu niewłaściwa?
c) Zmień proporcje grup na $\mathbb{P}(X = A) = 0{,}2$, $\mathbb{P}(X = B) = 0{,}8$, pozostawiając rozkłady warunkowe bez zmian. Oblicz nowe ryzyka.
d) Wskaż, które elementy rachunku zmieniły się w punkcie c), a które pozostały takie same. Czy ranking reguł się zmienił?

Zadanie 2.3. Najlepsza prognoza liczbowa. Korzystaj z rozkładu z Zadanie 2.1 z pierwotnymi proporcjami grup.

a) Oblicz średnią i wariancję warunkową w każdej grupie.
b) Podaj predyktor optymalny przy stracie kwadratowej i jego ryzyko.
c) Znajdź najlepszą regułę stałą i oblicz jej ryzyko. Ile zyskujemy dzięki informacji o rodzaju dyżuru?
d) Zapisz ryzyko dowolnej reguły (a_A, a_B) jako sumę ryzyka optymalnego i dwóch nieujemnych składników. Wykorzystaj ten zapis do sprawdzenia wyników Zadanie 2.1.

Zadanie 2.4. To samo zjawisko, inne pytanie. W rozkładzie z Zadanie 2.1 niech $Z = \mathbb{1}(Y \geq 1)$.

a) Oblicz prawdopodobieństwo klasy 1 w obu grupach.
b) W każdej grupie porównaj ryzyka odpowiedzi 0 i 1 przy stracie 0–1. Czy optimum jest w obu grupach jednoznaczne?
c) Znajdź najmniejsze ryzyko całkowite i porównaj je z ryzykiem najlepszego klasyfikatora stałego.
d) Czy informacja o X zmienia prawdopodobieństwa klas? Czy musi dzięki temu poprawiać najlepszą decyzję przy stracie 0–1? Porównaj z jej rolą w regresji w Zadanie 2.3.

Zadanie 2.5. Zmiana kryterium. Korzystaj z rozkładu z Zadanie 2.1.

a) Znajdź wszystkie mediany warunkowe. W grupie A sprawdź również liczby między 0 a 1.
b) Wybierz po jednej medianie w każdej grupie i oblicz ryzyko absolutne otrzymanej reguły.
c) Oblicz ryzyko absolutne reguły średnich warunkowych.
d) Wybierz mediany 0 i 3, oblicz też ich ryzyko kwadratowe i zestaw obie reguły pod obiema stratami. Czy jedna z nich jest najlepsza niezależnie od sposobu oceny?

Zadanie 2.6. Symulacja: od ryzyka do wyniku eksperymentu. Wykorzystaj rozkład i optymalny predyktor kwadratowy z Zadanie 2.3.

a) Wylosuj $N = 100$ niezależnych przypadków: najpierw rodzaj dyżuru, potem liczbę zgłoszeń z właściwego rozkładu warunkowego. Ustal ziarno generatora, aby wynik dało się odtworzyć.
b) Oblicz średnią strat ustalonego predyktora i porównaj z jego dokładnym ryzykiem. Nie ucz predyktora na wylosowanych danych.
c) Powtórz eksperyment 200 razy, a następnie wykonaj go dla $N = 1000$. Porównaj rozrzut otrzymanych średnich strat.

d) Czy średnia strata na próbie może spaść poniżej ryzyka optimum? Wyjaśnij, dlaczego nie narusza to zasady minimalizacji punktowej.

Zadanie 2.7. Koszt a częstość pomyłek. W przykładzie sklepu pominięcie wysokiego popytu kosztuje dziesięć razy więcej niż fałszywy alarm. Trafne decyzje mają koszt zerowy, fałszywy alarm kosztuje 1.

a) Oblicz oczekiwany koszt obu odpowiedzi w każdej grupie.
b) Wyznacz próg decyzyjny i optymalną regułę.
c) Porównaj tę regułę z regułą Bayesa dla straty 0–1: podaj prawdopodobieństwa obu typów błędu i całkowite ryzyko kosztowe.
d) Zilustruj wyniki symulacją na niezależnych dniach. Co tracimy, oceniając obie reguły wyłącznie odsetkiem pomyłek?

Zadanie 2.8. Oto klasyczny problem taksówek Kahnemana i Tversky'ego (Kahneman 2011, rozdz. 16). W mieście jeżdżą taksówki dwóch przedsiębiorstw: 85% z nich należy do spółki Zielony, 15% do spółki Niebieski. Jedna z taksówek spowodowała wypadek i odjechała. Świadek zeznaje, że była niebieska. Test wiarygodności wykazał, że w warunkach takich jak w chwili wypadku świadek myli kolor w 20% przypadków, niezależnie od tego, jaki kolor widzi. Potraktujmy zeznanie świadka jako cechę X, a przedsiębiorstwo – jako klasę Y, z klasą pozytywną Niebieski.

a) Wyznacz $\eta(x) = \mathbb{P}(Y = \text{Niebieski} \mid X = x)$ dla obu możliwych zeznań i porównaj obie wartości z prawdopodobieństwem a priori $\mathbb{P}(Y = \text{Niebieski}) = 0{,}15$. W którą stronę i jak mocno każde z zeznań przesuwa ocenę, że wypadek spowodowała taksówka niebieska?
b) Wyznacz klasyfikator bayesowski przy stracie 0–1 i jego błąd. Porównaj go z błędem reguły „wierz świadkowi" oraz klasyfikatora stałego. Jak pogodzić wynik z odpowiedzią z punktu a)?
c) Przy jakim prawdopodobieństwie pomyłki świadka jego zeznanie zaczyna zmieniać decyzję klasyfikatora bayesowskiego przy stracie 0–1?
d) Załóżmy, że niesłuszne oczyszczenie spółki Niebieski kosztuje c razy więcej niż niesłuszne obwinienie. Korzystając z (2.10), wyznacz najmniejsze c, przy którym zeznanie „niebieska" prowadzi do decyzji Niebieski. Odnieś wynik do ramki „Dobry model, zły próg".

Zadanie 2.9. Zmiana wag. W przykładzie sklepu zachowaj rozkłady warunkowe, ale zastąp proporcje dni przez $\mathbb{P}(X = A) = q$, $\mathbb{P}(X = B) = 1 - q$, gdzie $0 < q < 1$.

a) Znajdź optymalny predyktor kwadratowy, jego ryzyko oraz najlepszą prognozę stałą w zależności od q.
b) Powtórz analizę dla klasyfikacji wysokiego popytu przy stracie 0–1. Które wielkości zależą od proporcji dni?
c) **Rozszerzenie.** Wykaż, że przy ryzyku ważonym $\mathbb{E}[w(\mathbf{X})(Y - f(\mathbf{X}))^2]$, gdzie $w(\mathbf{x}) > 0$ i $\mathbb{E}[w(\mathbf{X})Y^2] < \infty$, średnia warunkowa nadal jest optymalna (zakładamy też $\mathbb{E}[|Y|] < \infty$). Skorzystaj z minimalizacji punktowej. Wyjaśnij, dlaczego wagi mogą zmieniać wartość ryzyka, nie zmieniając optimum punktowego.

Zadanie 2.10. Rozszerzenie: kwantyle. Potrzebna jest znajomość dystrybuanty i pochodnych. Rozważ **stratę pinball** (kwantylową) o parametrze $\tau \in (0, 1)$:

$$L_\tau(y, a) = \begin{cases} \tau(y - a), & y \geq a, \\ (1 - \tau)(a - y), & y < a. \end{cases}$$

Załóż, że przy ustalonych cechach rozkład wyniku ma ciągłą dystrybuantę F i skończony pierwszy moment. Wykaż, że pochodna ryzyka warunkowego względem a wynosi $F(a) - \tau$. Wywnioskuj,

że minimum osiąga kwantyl rzędu τ. Wskazówka: rozpatrz osobno wyniki mniejsze i większe od a. Dla $\tau = 1/2$ strata pinball jest połową straty absolutnej; sprawdź zgodność optimum z Twierdzenie 2.4.

Zadanie 2.11. Rozszerzenie: rozkłady normalne. Wymagane są gęstość, dystrybuanta i wzór Bayesa.

Dla dwóch klas o rozkładach $\mathcal{N}(-\mu, \sigma^2)$ i $\mathcal{N}(\mu, \sigma^2)$ z równymi prawdopodobieństwami a priori wyprowadź wzór na błąd bayesowski w zależności od μ i σ. Dla jakiej wartości μ/σ błąd bayesowski spada poniżej 1%?

Zadanie 2.12. Rozszerzenie: klasy niezrównoważone. Wymagane są rozkłady normalne oraz metoda k-NN z rozdziału 3.

Zmodyfikuj eksperyment z Rysunek 2.2 tak, aby klasy miały prawdopodobieństwa a priori $\pi_0 = 0{,}9$ i $\pi_1 = 0{,}1$ (klasa 0 to ta, w której $X \sim \mathcal{N}(-\mu, 1)$). Wyznacz nowy błąd bayesowski i porównaj go z błędem klasyfikatora trywialnego, który zawsze wskazuje klasę częstszą. Kiedy k-NN zaczyna być od niego lepszy?

Zadanie 2.13. Rozszerzenie: zmiana populacji. Wymagane są wzór Bayesa i rachunek na szansach.

Korekta prawdopodobieństw a priori. Model klasyfikacyjny uczono na próbie, w której klasy występowały z częstościami π'_k, na przykład na próbie zbalansowanej. Model zwraca więc oszacowania $\eta'_k(\mathbf{x}) = \mathbb{P}'(Y = k \mid \mathbf{X} = \mathbf{x})$. W populacji, w której model będzie stosowany, klasy występują z częstościami π_k, a rozkłady cech w obrębie klas $p(\mathbf{x} \mid Y = k)$ są takie same jak w próbie. Korzystając ze wzoru Bayesa, wykaż, że

$$\eta_k(\mathbf{x}) = \frac{\eta'_k(\mathbf{x})\,\pi_k/\pi'_k}{\sum_{j=1}^{K} \eta'_j(\mathbf{x})\,\pi_j/\pi'_j}.$$

Pokaż, że w przypadku dwuklasowym korekta sprowadza się do pomnożenia szans $\eta(\mathbf{x})/(1-\eta(\mathbf{x}))$ przez stałą, i wyznacz tę stałą. Model wykrywania oszustw uczono na próbie zbalansowanej, a w populacji oszustwa stanowią 1% transakcji. Dla pewnej transakcji model zwrócił 0,8. Jakie jest prawdopodobieństwo oszustwa po korekcie? Wyjaśnij, dlaczego tej korekty nie da się przeprowadzić dla modelu zwracającego wyłącznie etykiety (por. ramka „Dobry model, zły próg").

Zadanie 2.14. Rozszerzenie: własności średniej i mediany. Wymagane są nierówność Jensena i pojęcie rozstępu międzykwartylowego.

Wykaż, że dla dowolnego rozkładu o skończonej wariancji średnia μ i mediana m spełniają $|\mu - m| \le \sigma$. (Wskazówka: skorzystaj z Twierdzenie 2.4 i nierówności Jensena.) Podaj rozkład, dla którego ta różnica jest bliska σ. Następnie pokaż, że przy ustalonym rozstępie międzykwartylowym różnica $|\mu - m|$ może być dowolnie duża. Co to mówi o odporności obu predyktorów?

3. Metoda k najbliższych sąsiadów

W rozdziale 2 ustaliliśmy, czego szukamy. Przy stracie kwadratowej optymalnym predyktorem jest funkcja regresji $f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$, a przy stracie 0–1 – klasyfikator bayesowski, który wskazuje klasę o największym prawdopodobieństwie warunkowym $\eta_c(\mathbf{x})$ klasy c. Obie wielkości odwołują się jednak do nieznanego rozkładu P. Ten rozdział przedstawia, jak oszacować je z danych niemal wprost z definicji.

Gdyby w próbie było wiele obserwacji o cechach dokładnie równych $\mathbf{x}$, moglibyśmy uśrednić ich wyniki i otrzymać próbkowy odpowiednik średniej warunkowej. Przy cechach ciągłych taka sytuacja praktycznie nie występuje: w zbiorze uczącym zwykle nie ma ani jednej obserwacji z $\mathbf{X} = \mathbf{x}$. Metoda k najbliższych sąsiadów (k-NN, ang. *k nearest neighbors*) zastępuje więc warunek „$\mathbf{X} = \mathbf{x}$” słabszym warunkiem „$\mathbf{X}$ blisko $\mathbf{x}$” i uśrednia wyniki obserwacji leżących najbliżej. Ta jedna idea daje zarówno metodę regresji, jak i klasyfikacji.

Metoda nie narzuca parametrycznej postaci f^* ani η_c, a mimo to przy odpowiednio rosnącej liczbie sąsiadów może zbliżać się do optimum z poprzedniego rozdziału. Zobaczymy jednak również, gdzie leży jej granica: w wielu wymiarach „blisko” przestaje znaczyć to, co podpowiada intuicja. Przy okazji k-NN poznamy też pojęcia, które wrócą przy każdej kolejnej metodzie: dobór stopnia wygładzenia, rolę skali cech i przekleństwo wymiarowości.

3.1. Uśrednianie lokalne

Wróćmy do sklepu z poprzedniego rozdziału. Tym razem zamiast dwóch typów dni mamy cechę ciągłą: temperaturę. W pięciu dniach zaobserwowano:

Temperatura x (°C)	12	16	19	23	28
Popyt y (sztuki)	4	6	10	8	15

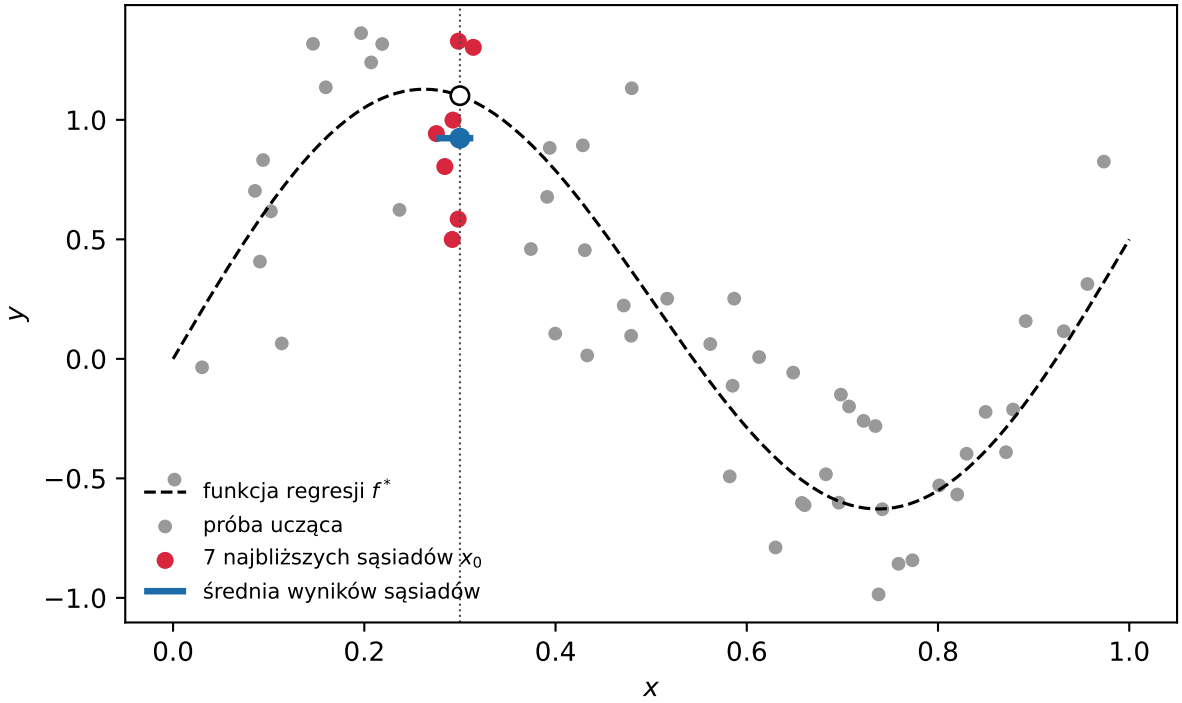
Chcemy przewidzieć popyt przy temperaturze 20°C. Weźmy k dni o temperaturach najbliższych 20°C; liczbę k ustalamy z góry. Dla $k = 3$ są to dni o temperaturach 19, 23 i 16°C: dzielą je od punktu, o który pytamy odpowiednio 1, 3 i 4 stopnie. Średnia ich wyników wynosi

$$\hat{f}(20) = \frac{10 + 8 + 6}{3} = 8.$$

Tych samych trzech sąsiadów możemy użyć do klasyfikacji. Umówmy się, że popyt jest wysoki, gdy wynosi co najmniej 10 sztuk, i przewidujmy tylko, czy taki będzie. Każdy dzień dostaje wtedy etykietę „wysoki” albo „niski”. Wśród sąsiadów popyt był wysoki tylko w dniu o temperaturze 19°C, więc prawdopodobieństwo wysokiego popytu przy 20°C szacujemy jako 1/3, a niskiego jako 2/3. Przy stracie 0–1 wybieramy klasę bardziej prawdopodobną: przewidujemy popyt niski. W regresji uśredniamy wyniki sąsiadów, w klasyfikacji liczymy, jaka część z nich należy do każdej klasy.

Rachunek opiera się na założeniu, że dni o podobnej temperaturze mają podobne rozkłady popytu. Sama bliskość liczb nie gwarantuje podobieństwa wyników: znaczenie mogą mieć także dzień tygodnia czy promocja. Wybór cech jest zatem częścią budowy modelu.

Rysunek 3.1 pokazuje lokalne uśrednianie na danych symulowanych, dla których znamy funkcję regresji i możemy porównać z nią predykcję.



Rysunek 3.1.: Uśrednianie lokalne. Szare punkty to próba ucząca, przerywana krzywa – prawdziwa funkcja regresji f^*. Aby przewidzieć wynik w punkcie x_0, wybieramy $k = 7$ obserwacji o cechach najbliższych x_0 (zaznaczone na czerwono) i uśredniamy ich wyniki. Pozioma kreska pokazuje tę średnią na przedziale zajmowanym przez sąsiadów.

Średnia wyników sąsiadów (niebieski punkt) jest bliska prawdziwej wartości $f^*(x_0)$ (pusty punkt), choć nie jest jej równa. Rozbieżność ma dwie przyczyny. Pierwsza to szum: siedem obserwacji to mało, by uśrednić losowe odchylenia wyników. Druga to szerokość otoczenia: sąsiedzi leżą w pewnym przedziale wokół x_0, a funkcja regresji nie jest na nim stała, więc uśredniamy wartości z jej okolicy, a nie z samego punktu x_0. Zwiększenie k pozwala lepiej uśrednić szum, ale zwykle poszerza otoczenie i może zwiększyć drugi efekt. Do tego problemu wrócimy w sekcji 3.4.

Otoczenie punktu x_0 można wyznaczyć na dwa sposoby. Możemy ustalić promień h i uśredniać wszystkie obserwacje odległe od x_0 o mniej niż h. Możemy też ustalić liczbę obserwacji k i pozwolić, by promień wynikał z danych. Metoda k-NN wybiera drugą możliwość. Tam, gdzie danych jest dużo, otoczenie jest wąskie, a tam, gdzie mało – szerokie, ale nigdy puste. Przy ustalonym promieniu w obszarach o małej gęstości predykcja mogłaby opierać się na jednej obserwacji albo nie dać się wyznaczyć wcale.

3.2. Reguła k najbliższych sąsiadów

Niech $\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)\}$ będzie zbiorem uczącym, w którym każda obserwacja jest opisana p cechami liczbowymi, $\mathbf{x}_i \in \mathbb{R}^p$, a $1 \leq k \leq n$. Niech d będzie odległością w $\mathbb{R}^p$. Dla punktu $\mathbf{x}$ porządkujemy obserwacje uczące według odległości $d(\mathbf{x}_i, \mathbf{x})$ i przez $N_k(\mathbf{x})$ oznaczamy zbiór indeksów k obserwacji leżących najbliżej.

W regresji predykcją jest średnia wyników sąsiadów:

$$\hat{f}(\mathbf{x}) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x})} y_i. \tag{3.1}$$

Jest to próbkowy odpowiednik średniej warunkowej: średnią po rozkładzie $Y \mid \mathbf{X} = \mathbf{x}$ zastąpiliśmy średnią z próby po obserwacjach o cechach bliskich $\mathbf{x}$. Ta sama zamiana działa dla innych strat. Przy stracie absolutnej optimum jest mediana warunkowa (Twierdzenie 2.4), więc jej lokalnym oszacowaniem jest mediana wyników sąsiadów (Zadanie 3.4).

W klasyfikacji szacujemy prawdopodobieństwa klas. Za $\eta_c(\mathbf{x}) = \mathbb{P}(Y = c \mid \mathbf{X} = \mathbf{x})$ podstawiamy częstość klasy c wśród sąsiadów:

$$\hat{\eta}_c(\mathbf{x}) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x})} \mathbb{1}(y_i = c). \tag{3.2}$$

Jest to szczególny przypadek (3.1): częstość klasy to średnia zmiennej wskaźnikowej $\mathbb{1}(Y = c)$, a jej wartość oczekiwana warunkowa to właśnie $\eta_c(\mathbf{x})$. Klasyfikator k-NN wskazuje klasę najczęstszą wśród sąsiadów:

$$\hat{g}(\mathbf{x}) = \arg\max_c \ \hat{\eta}_c(\mathbf{x}). \tag{3.3}$$

Porównanie (3.3) z regułą bayesowską (2.6) pokazuje, że k-NN ma tę samą postać, tylko z nieznanym prawdopodobieństwem warunkowym zastąpionym jego oszacowaniem. Taką konstrukcję nazywamy **regułą podstawienia** (ang. *plug-in rule*). Pierwsze takie reguły nieparametryczne, w tym regułę najbliższego sąsiada, zaproponowali i zbadali Fix i Hodges (1951).

Metodę k-NN opisuje ta sama zasada co predyktory optymalne. Ryzyko warunkowe $r(a \mid \mathbf{x})$ z (2.2) to średnia strata odpowiedzi a po rozkładzie $Y \mid \mathbf{X} = \mathbf{x}$. Jego oszacowaniem jest średnia strata tej odpowiedzi na sąsiadach:

$$\hat{r}(a \mid \mathbf{x}) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x})} L(y_i, a).$$

Przy stracie kwadratowej minimum tej wielkości daje średnia wyników sąsiadów. Wynika to z tego samego rachunku co Twierdzenie 2.2, zastosowanego do rozkładu, w którym każdy sąsiad ma prawdopodobieństwo $1/k$. Przy stracie 0–1 mamy $\hat{r}(a \mid \mathbf{x}) = 1 - \hat{\eta}_a(\mathbf{x})$, więc minimum daje klasa najczęstsza wśród sąsiadów. Reguły (3.1) i (3.3) są zatem minimalizacją punktową, w której nieznany rozkład warunkowy zastąpiliśmy rozkładem wyników sąsiadów.

Trening opisany w sekcji 1.8 przebiega inaczej. Tam z klasy modeli $\mathcal{F}$ wybieramy jedną funkcję, minimalizując ryzyko empiryczne na całym zbiorze uczącym, więc predykcje w różnych punktach są ze sobą powiązane przez wspólne parametry. Metoda k-NN niczego z ustalonej klasy nie wybiera: w każdym punkcie rozwiązuje osobny, mały problem na własnych sąsiadach. Średni błąd na całej próbie nie służy więc do dopasowania. Potrzebny jest dopiero do wyboru k, i to liczony na danych, których nie użyto jako sąsiadów (sekcja 3.4).

Ponieważ (3.2) daje prawdopodobieństwa, a nie tylko etykiety, można je podstawić do dowolnej reguły decyzyjnej z sekcji 2.8: do progu kosztowego (2.10) albo do reguły Chowa z opcją odmowy.

Oszacowanie jest jednak grube. Przyjmuje tylko $k+1$ wartości $0, 1/k, \ldots, 1$, więc progi leżące między dwiema kolejnymi wielokrotnościami $1/k$ dają te same decyzje (Zadanie 3.5). Przy $k = 5$ progi 0,65 i 0,75 prowadzą do tej samej reguły, bo między nimi nie leży żadna wielokrotność $1/5$.

Remisy

Reguła (3.3) nie zawsze wskazuje jedną klasę. Dla dwóch klas remis w głosowaniu jest możliwy tylko przy parzystym k, dlatego często wybiera się k nieparzyste. Przy większej liczbie klas remisu w ten sposób się nie uniknie. Druga możliwość to remis w odległościach: k-ty i $(k+1)$-szy sąsiad leżą w tej samej odległości od $\mathbf{x}$ i zbiór $N_k(\mathbf{x})$ nie jest wyznaczony jednoznacznie. Przy danych z gęstością w przestrzeni euklidesowej zdarza się to z prawdopodobieństwem zero, ale przy cechach dyskretnych bywa częste.
W tym rozdziale przy remisie w odległościach wybieramy obserwację o mniejszym indeksie, bez zaglądania do jej wyniku. Przy remisie w głosowaniu wybieramy pierwszą klasę w ustalonym porządku. Rozróżnienie jest istotne: wyboru sąsiadów nie wolno uzależniać od ich etykiet. Także w dokumentacji scikit-learn zwrócono uwagę, że przy równych odległościach wynik może zależeć od kolejności danych uczących.

3.3. Co znaczy „blisko”

Reguła k-NN wymaga odległości d, a jej wybór należy do modelu tak samo jak wybór k. Najczęściej używa się odległości euklidesowej

$$d(\mathbf{x}, \mathbf{x}') = \Big(\sum_{j=1}^{p} (x_j - x'_j)^2 \Big)^{1/2},$$

rzadziej odległości miejskiej (Manhattan) $\sum_j |x_j - x'_j|$. Obie są szczególnymi przypadkami odległości Minkowskiego $\big(\sum_j |x_j - x'_j|^q \big)^{1/q}$, dla $q = 2$ i $q = 1$.

Każda z tych odległości sumuje różnice w poszczególnych cechach i dlatego zależy od jednostek, w których cechy wyrażono. Rozważmy mieszkania opisane metrażem w m² i liczbą pokoi. Mieszkania o metrażach 50 i 52 m² mające 2 i 4 pokoje dzieli odległość euklidesowa $\sqrt{2^2 + 2^2} \approx 2{,}8$. Mieszkania o metrażach 50 i 56 m² z tą samą liczbą pokoi dzieli odległość 6. Pierwsza para jest więc „bliższa”, choć różni się układem mieszkania. Jeśli metraż zapiszemy w cm², różnica dwóch metrów kwadratowych urośnie do 20 000 i liczba pokoi przestanie mieć jakikolwiek wpływ na wybór sąsiadów. Zmiana jednostek, która nie zmienia żadnej informacji w danych, zmienia predykcje k-NN.

Skali cech nie da się więc pozostawić przypadkowi. Najprostszym rozwiązaniem jest **standaryzacja**: od każdej cechy odejmujemy jej średnią i dzielimy przez odchylenie standardowe, tak by wszystkie cechy miały porównywalny rozrzut. Jeśli x_{ij} oznacza wartość j-tej cechy i-tej obserwacji uczącej, to dla każdej cechy $j = 1, \ldots, p$ wyznaczamy

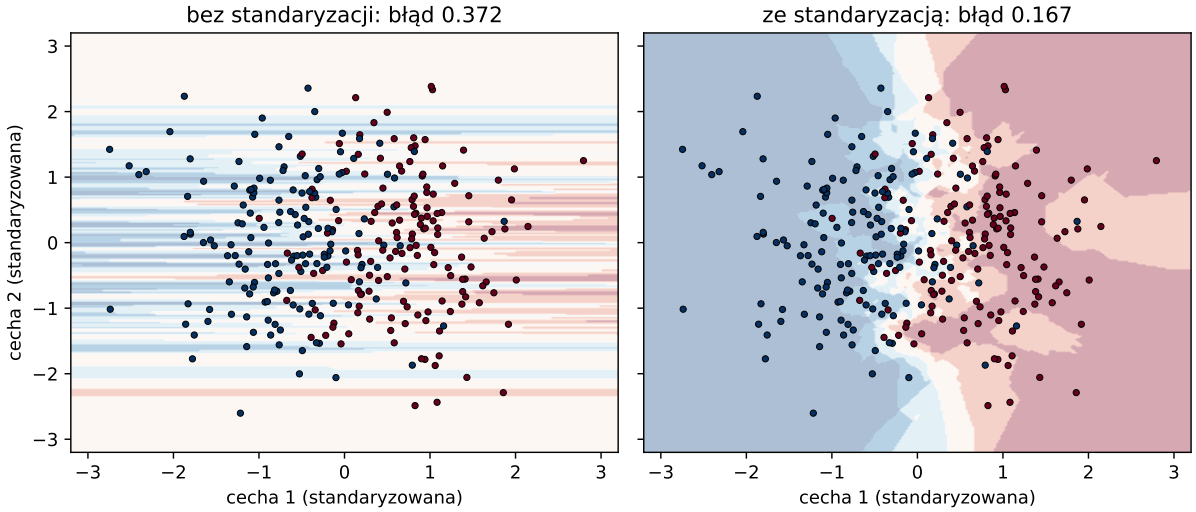
$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^{n} x_{ij}, \qquad s_j = \Big(\frac{1}{n} \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2 \Big)^{1/2}$$

i zastępujemy cechę x_j dowolnego punktu $\mathbf{x}$ wartością

$$\tilde{x}_j = \frac{x_j - \bar{x}_j}{s_j}. \tag{3.4}$$

Zakładamy $s_j > 0$; cechę stałą w próbie pomijamy przy liczeniu odległości. Po tym przekształceniu każda pozostała cecha ma w zbiorze uczącym średnią 0 i odchylenie standardowe 1, a odległości liczymy między punktami $\tilde{\mathbf{x}}$. Wielkości $\bar{x}_j$ i s_j wyznaczamy tylko na zbiorze uczącym i tymi samymi wartościami przekształcamy nowe obserwacje. Wyznaczenie ich na danych, na których oceniamy model, byłoby subtelną formą podglądania danych testowych. Wrócimy do tego w rozdziale 5.

Rysunek 3.2 pokazuje skutek pominięcia standaryzacji. Klasę wyznacza tylko pierwsza cecha, o odchyleniu standardowym rzędu 1. Druga cecha nie niesie informacji o klasie, ale jej odchylenie standardowe wynosi 100.



Rysunek 3.2.: Klasyfikator 5-NN bez standaryzacji (po lewej) i ze standaryzacją (po prawej), $n = 300$. Klasę wyznacza tylko cecha 1. Cecha 2 jest szumem o odchyleniu standardowym 100, więc bez standaryzacji to ona decyduje o tym, kto jest czyim sąsiadem. Oba panele narysowano w zmiennych standaryzowanych; tło pokazuje oszacowanie $\hat{\eta}(\mathbf{x})$, a w tytule podano błąd na dużym zbiorze testowym.

Bez standaryzacji o wyborze sąsiadów decyduje niemal wyłącznie cecha 2, która nie niesie informacji o klasie. Sąsiedzi są więc dobierani tak, jakby klasy nie było. Tło lewego panelu układa się w poziome pasy: oszacowanie $\hat{\eta}$ zmienia się wraz z cechą nieistotną, a prawie nie zmienia wraz z istotną. Po standaryzacji obie cechy ważą tyle samo i granica decyzyjna wyraźnie zależy od cechy 1.

Prawy panel pokazuje jednak także drugi problem. Cecha 2 nadal jest szumem i nadal wpływa na odległości, choć już nie dominuje: granica nie jest pionowa, lecz poszarpana. Przy jednej takiej cesze strata jest niewielka, a błąd jest bliski błędowi bayesowskiemu $\Phi(-1) \approx 0{,}159$. Standaryzacja wyrównuje jednak tylko skale. Nie potrafi odróżnić cech istotnych od nieistotnych: z punktu widzenia odległości każda cecha jest równie ważna. Z każdą kolejną cechą nieistotną problem się nasila, co omówimy w sekcji 3.5.

Cechy jakościowe wymagają osobnej decyzji. Typowym rozwiązaniem jest zakodowanie każdej kategorii osobną zmienną zero-jedynkową. Odległość między dwiema obserwacjami zależy wtedy od liczby cech, w których się różnią. Przy pełnym kodowaniu zero-jedynkowym odległość euklidesowa wynosi $\sqrt{2m}$, gdzie m jest liczbą różniących się cech jakościowych, a względną wagę cech jakościowych i ilościowych trzeba ustalić świadomie.

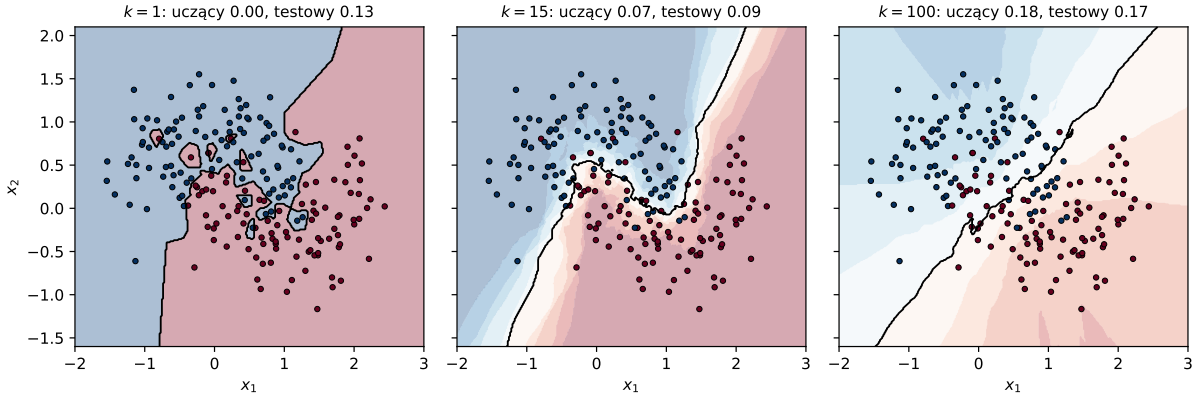
3.4. Rola liczby sąsiadów

Parametr k jest **hiperparametrem**: nie jest wyznaczany z danych w trakcie uczenia, tylko ustalany przed nim (por. Zadanie 1.5). Jego wpływ najłatwiej zrozumieć na przypadkach skrajnych.

Dla $k = 1$ predykcją jest wynik jednej, najbliższej obserwacji. Dla punktów ze zbioru uczącego najbliższym sąsiadem jest sam punkt (zakładamy brak powtórzeń cech), więc błąd na zbiorze uczącym wynosi zero (Zadanie 1.6). Nie wynika z tego nic dobrego o ryzyku. Predykcja w nowym punkcie przejmuje cały szum jednej obserwacji, a granica decyzyjna otacza każdy punkt uczący, także taki, którego klasa jest w swoim otoczeniu nietypowa.

Dla $k = n$ sąsiadami każdego punktu jest cały zbiór uczący. Predykcja nie zależy wtedy od $\mathbf{x}$: w regresji jest średnią wszystkich wyników, w klasyfikacji – klasą najczęstszą w próbie (Zadanie 3.3). Taki predyktor jest bardzo stabilny, ale ignoruje cechy.

Między tymi skrajnościami k reguluje stopień **wygładzenia**. Rysunek 3.3 pokazuje to na klasycznym zbiorze dwóch półksiężyców.



Rysunek 3.3.: Klasyfikator k-NN dla $k = 1, 15, 100$ na zbiorze dwóch półksiężyców ($n = 200$, szum 0,30). Tło pokazuje oszacowanie $\hat{\eta}(\mathbf{x})$, czarna linia – granicę decyzyjną $\hat{\eta}(\mathbf{x}) = 1/2$. W tytułach podano błąd na zbiorze uczącym i na dużym zbiorze testowym z tego samego rozkładu.

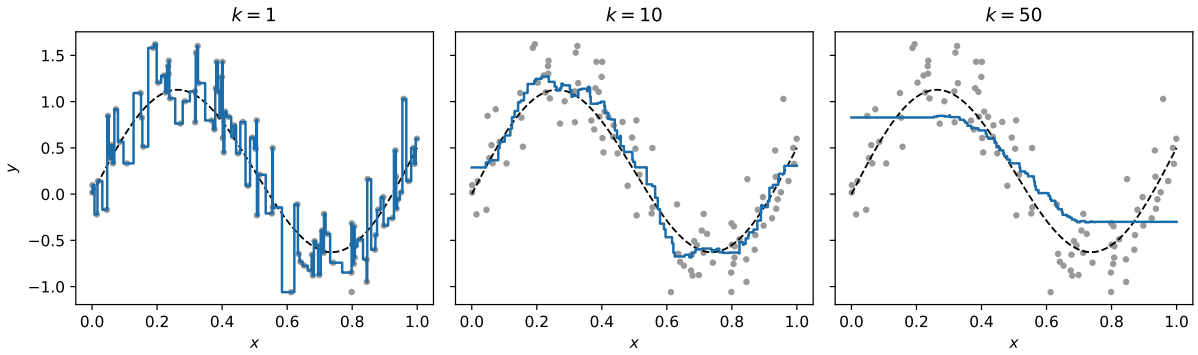
Dla $k = 1$ granica jest poszarpana i tworzy wysepki wokół pojedynczych punktów. Błąd uczący wynosi zero, ale błąd testowy jest wyraźnie większy niż dla $k = 15$. Granica dla $k = 15$ oddaje kształt półksiężyców i nie reaguje na pojedyncze obserwacje. Dla $k = 100$, czyli połowy próby, otoczenia są tak szerokie, że sięgają do drugiego półksiężyca, granica się wypłaszcza, a błąd znów rośnie – tym razem zarówno testowy, jak i uczący.

To samo widać w regresji (Rysunek 3.4). Wykres predyktora (3.1) jest funkcją schodkową: zmienia wartość tylko wtedy, gdy zmienia się zbiór sąsiadów. Przy małym k schodki są gęste i podążają za szumem, przy dużym – predyktor spłaszcza funkcję regresji, najmocniej przy krańcach przedziału, gdzie sąsiedzi leżą tylko po jednej stronie punktu.

Zależność ryzyka od k można w tym przykładzie wyznaczyć numerycznie, bo rozkład znamy. Cecha ma rozkład jednostajny na $[0, 1]$, więc rozkład ryzyka (2.8) przyjmuje postać

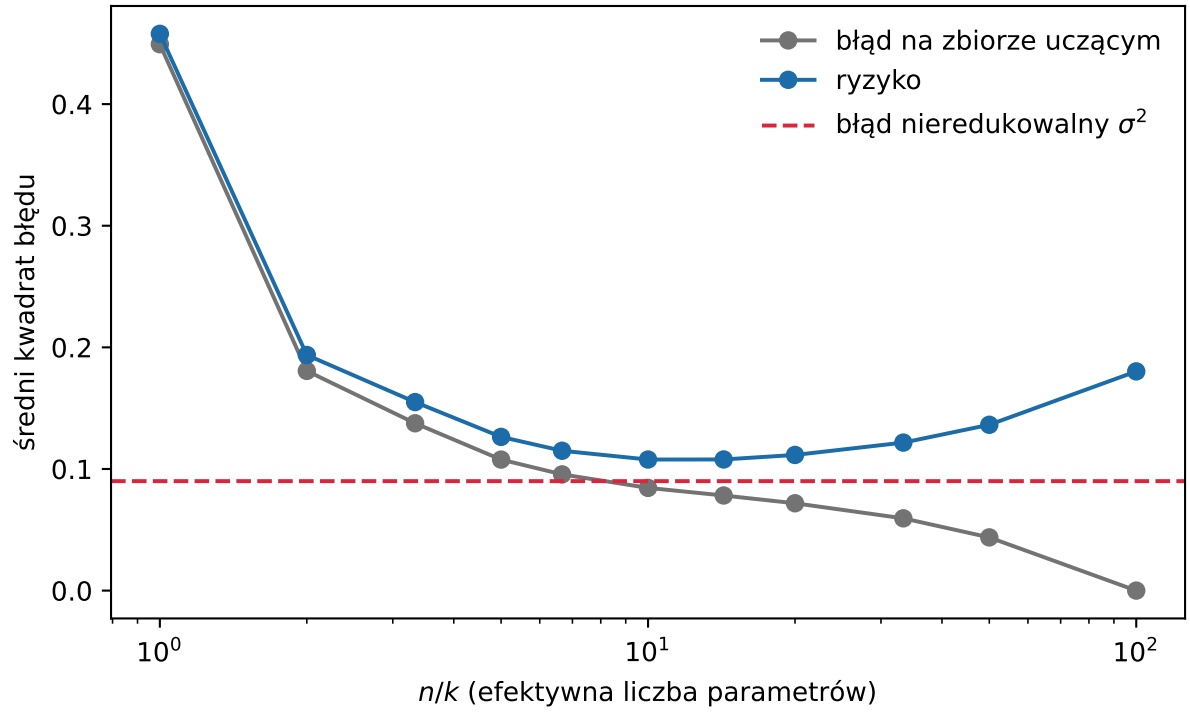
$$R(\hat{f}) = \int_0^1 \left(f^*(x) - \hat{f}(x)\right)^2 dx + \sigma^2,$$

a całkę liczymy numerycznie. Rysunek 3.5 zestawia tak policzone ryzyko z błędem na zbiorze uczącym. Oś poziomą opisaliśmy wielkością n/k. Przybliża ona liczbę grup obserwacji, w obrębie



Rysunek 3.4.: Regresja k-NN dla $k = 1, 10, 50$ na tej samej próbie ($n = 100$). Przerywana krzywa to funkcja regresji f^*, niebieska – predyktor $\hat{f}$.

których predyktor uśrednia, i bywa nazywana **efektywną liczbą parametrów** metody (Hastie i in. 2009, rozdz. 2.3). W prawo rośnie więc elastyczność modelu.



Rysunek 3.5.: Błąd na zbiorze uczącym i ryzyko regresji k-NN w zależności od n/k ($n = 100$). Ryzyko przybliżono przez całkowanie numeryczne po znanym rozkładzie. Punkty to średnie z 50 niezależnych prób uczących. Przerywana linia to błąd nieredukowalny σ^2.

Na wykresie średni błąd uczący maleje wraz ze wzrostem elastyczności i dla $k = 1$ spada do zera. Ryzyko zachowuje się inaczej: najpierw maleje, potem rośnie, a najmniejsze jest przy pośredniej wartości k. Na lewym krańcu wykresu predyktor jest zbyt sztywny, by odtworzyć kształt f^*, na prawym – odtwarza głównie szum. Krzywa w kształcie litery U to obraz kompromisu, który w rozdziale 4 rozłożymy na dwa składniki: obciążenie i wariancję.

W zastosowaniach nie znamy rozkładu, więc nie możemy narysować takiej krzywej ryzyka. Sam błąd uczący nie wystarcza: $k = 1$ osiąga zero, choć może źle przewidywać nowe wyniki. Nie znaczy to, że $k = 1$ zawsze jest złym wyborem; znaczy, że ocena na próbie uczącej tego nie

rozstrzyga.

Najprostsze rozwiązanie polega na podziale danych. Na **zbiorze uczącym** wyznaczamy skalowanie i zapamiętujemy obserwacje. Na osobnym **zbiorze walidacyjnym** porównujemy kilka wartości k, licząc średnią stratę odpowiednią dla zadania. Wybieramy wartość z najmniejszym błędem walidacyjnym. **Zbiór testowy** służy dopiero do końcowej oceny wybranej procedury. Jeśli wybieramy k według błędu testowego, ten zbiór zaczyna pełnić rolę walidacyjnego i nie daje już niezależnej oceny wyboru.

Ta sama zasada dotyczy wyboru cech, skali i odległości. Szczegóły podziału danych oraz walidację krzyżową omówimy w rozdziale 5.

3.4.1. Gdy danych przybywa

Dwa źródła błędu z Rysunek 3.1 inaczej reagują na wzrost próby. Gdy zwiększamy k, uśredniamy więcej wyników i szum ma coraz mniejsze znaczenie. Gdy jednocześnie k rośnie wolniej niż n, sąsiedzi stanowią coraz mniejszą część próby, więc ich otoczenie kurczy się wokół $\mathbf{x}$. Przy $k = \sqrt{n}$ dla $n = 100$ uśredniamy 10 obserwacji, czyli 10% próby, a dla $n = 10\,000$ – 100 obserwacji, czyli 1% próby.

Jeśli k rośnie nieograniczenie, a k/n maleje do zera, ryzyko k-NN zbliża się do ryzyka predyktora optymalnego z rozdziału 2: funkcji regresji w regresji i klasyfikatora bayesowskiego w klasyfikacji. Zachodzi to dla każdego rozkładu danych, bez założeń o kształcie f^* (C. J. Stone 1977). Optimum, którego nie umieliśmy wyznaczyć bez znajomości rozkładu, można więc osiągać w granicy, mając same dane. Wynik nie mówi jednak, ile danych do tego potrzeba. Odpowiedź zależy od liczby cech.

3.5. Przekleństwo wymiarowości

Metoda k-NN opiera się na założeniu, że w zbiorze uczącym są obserwacje **bliskie** punktowi $\mathbf{x}$, i że dla takich obserwacji f^* lub η mają podobne wartości. W jednym czy dwóch wymiarach łatwiej znaleźć małe otoczenie z dostateczną liczbą danych. Wraz z liczbą cech p staje się to trudniejsze, nawet przy bardzo dużych próbach. Zjawisko to nazywamy **przekleństwem wymiarowości** (ang. *curse of dimensionality*). Najpierw policzymy, ile danych wymaga małe otoczenie, a następnie sprawdzimy skutek dodawania cech nieistotnych.

3.5.1. Otoczenie przestaje być lokalne

Niech cechy mają rozkład jednostajny w kostce $[0,1]^p$. Chcemy, aby otoczenie punktu obejmowało ułamek r wszystkich obserwacji, na przykład $r = 0{,}01$ przy $k = 10$ i $n = 1000$. Jeśli otoczenie jest mniejszą kostką o boku b, w całości zawartą w $[0,1]^p$, to ma prawdopodobieństwo b^p i zawiera średnio nb^p obserwacji. Zatem

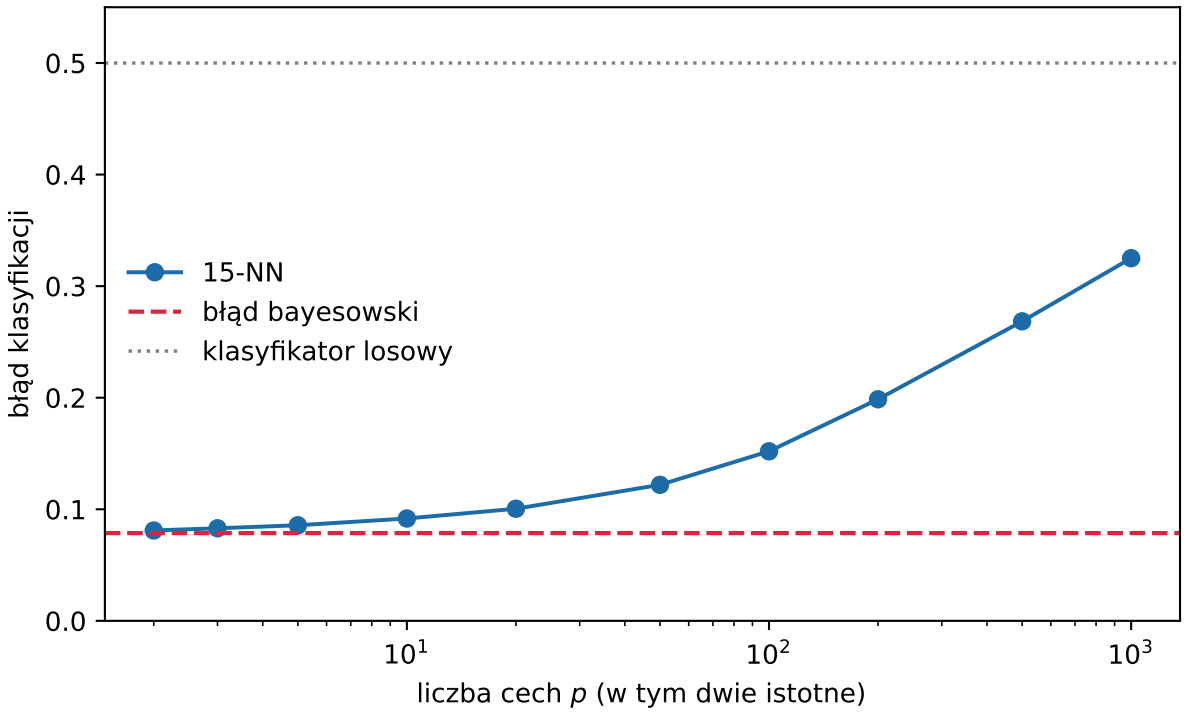
$$b = r^{1/p}. \tag{3.5}$$

W jednym wymiarze bok wynosi 0,01, czyli otoczenie jest naprawdę lokalne. W dwóch – 0,1. W dziesięciu wymiarach bok wynosi już $0{,}01^{1/10} \approx 0{,}63$: aby zebrać 1% danych, musimy objąć 63% zakresu **każdej** cechy. W stu wymiarach bok wynosi 0,955. „Otoczenie" obejmuje wtedy prawie cały zakres każdej zmiennej, a uśrednianie po nim przestaje być lokalne (Hastie i in. 2009, rozdz. 2.5).

Odwracając rachunek: aby otoczenie miało bok $b = 0{,}1$ i zawierało średnio 10 obserwacji, potrzebujemy $n = 10 \cdot 10^p$ obserwacji. Dla $p = 2$ to tysiąc, dla $p = 10$ – sto miliardów (Zadanie 3.7). Liczba potrzebnych obserwacji rośnie wykładniczo z wymiarem.

3.5.2. Skutek dla klasyfikacji

Połączmy te obserwacje z problemem z Rysunek 3.2. Weźmy dwie cechy istotne, w których klasy są dobrze rozdzielone, i dołączajmy do nich kolejne cechy będące czystym szumem, o tej samej skali. W eksperymencie klasy mają w cechach istotnych środki $(1, 1)$ i $(-1, -1)$, każda cecha ma odchylenie standardowe 1, a cechy szumowe mają rozkład $\mathcal{N}(0, 1)$. Klasyfikator bayesowski ignoruje szum, więc błąd bayesowski się nie zmienia. Metoda k-NN szumu zignorować nie potrafi, bo każda cecha wnosi swój wkład do odległości. Rysunek 3.6 pokazuje wynik.



Rysunek 3.6.: Błąd klasyfikatora 15-NN w zależności od łącznej liczby cech p ($n = 500$, średnia z 5 prób uczących, błąd na zbiorze testowym liczności 10 000). Klasy różnią się tylko w dwóch pierwszych cechach, pozostałe $p - 2$ cech to szum. Linie poziome: błąd bayesowski, który nie zależy od cech nieistotnych, oraz błąd klasyfikatora losowego.

Kilka cech szumowych prawie nie szkodzi. Przy stu cechach błąd jest już około dwukrotnie większy od bayesowskiego, a przy tysiącu pokonał ponad połowę drogi od błędu bayesowskiego do zgadywania. Tymczasem informacja potrzebna do dobrej klasyfikacji jest w danych cały czas obecna i zawsze w tych samych dwóch kolumnach. Metoda po prostu nie ma sposobu, by się o tym dowiedzieć.

Skąd taki przebieg? Kwadrat odległości euklidesowej między dwoma punktami jest sumą kwadratów różnic w poszczególnych cechach. W cesze szumowej obie wartości są niezależne i mają rozkład $\mathcal{N}(0, 1)$, więc ich różnica ma średnią 0 i wariancję 2, a średni kwadrat różnicy wynosi 2. W cesze istotnej tyle samo daje para punktów z tej samej klasy. Dla pary z różnych klas środki są odległe o 2, więc średni kwadrat różnicy wynosi $2 + 2^2 = 6$. Przy m cechach szumowych średni

kwadrat odległości wynosi zatem $4 + 2m$ dla punktów z tej samej klasy i $12 + 2m$ dla punktów z różnych klas.

Różnica tych średnich, równa 8, nie zależy od m: szum dodaje do obu odległości przeciętnie tyle samo. Rośnie natomiast rozrzut. Każda cecha szumowa dodaje do kwadratu odległości losowy składnik o odchyleniu standardowym $\sqrt{8} \approx 2{,}8$. Składniki są niezależne, więc odchylenie standardowe ich sumy wynosi $\sqrt{8m}$. Przy $m = 8$ wahania są tego samego rzędu co różnica 8, przy $m = 98$ są od niej mniej więcej 3,5 raza większe, a przy $m = 998$ – około 11 razy. O tym, który punkt uczący okaże się najbliższy, decydują wtedy głównie przypadkowe wartości cech szumowych. Klasy sąsiadów coraz mniej mówią o klasie punktu, dla którego przewidujemy.

Standaryzacja niczego tu nie zmienia, bo wszystkie cechy mają już tę samą skalę. Pomóc może tylko wybór cech, czyli decyzja, których kolumn nie uwzględniać w odległości. Ogólniejszą postać tego zjawiska, koncentrację odległości, opisuje rozszerzenie o geometrii wysokich wymiarów.

3.5.3. Co z tego wynika

Przekleństwo wymiarowości nie przeczy zbieżności k-NN do optimum. Gwarancja nadal obowiązuje, ale liczba obserwacji, przy której otoczenia stają się naprawdę małe, rośnie z wymiarem wykładniczo i przy wielu cechach bywa nieosiągalna. Twierdzenie, szkic jego uzasadnienia i przypadek $k = 1$ omawiamy w opcjonalnej sekcji 3.8. Metoda, która nie zakłada nic o postaci zależności, musi każdą jej cechę „odkryć” w danych, a w wielu wymiarach na to brakuje danych.

Wyjściem są **założenia strukturalne**. Model liniowy zakłada, że wpływ każdej cechy jest stały i addytywny. Dzięki temu szacuje $p + 1$ współczynników zamiast wypełniać obserwacjami całą przestrzeń cech. Jeśli założenie jest w przybliżeniu prawdziwe, model liniowy wygrywa z k-NN już przy umiarkowanym p (James i in. 2023, rozdz. 3.5). Od tego zaczyna się część II książki (Rozdział 6).

Dlaczego k-NN mimo to bywa skuteczny

Rachunek objętości dotyczy danych jednostajnych w kostce, a eksperyment z szumem – niezależnych cech normalnych. Dane rzeczywiste rzadko tak wyglądają. Cechy są zwykle silnie skorelowane, a obserwacje skupiają się w pobliżu struktur o znacznie mniejszym wymiarze niż p: zdjęcia twarzy zajmują znikomą część przestrzeni wszystkich obrazów o danej liczbie pikseli. O trudności zadania decyduje wtedy ten **wymiar wewnętrzny**, a nie liczba kolumn. Do wyznaczania takich struktur służą metody z części V (Rozdział 14).

3.6. Metoda k-NN w praktyce

Koszt obliczeniowy. Uczenie k-NN polega na zapamiętaniu zbioru uczącego, co wymaga pamięci rzędu np i czasu na zapis danych. Budowa struktury do wyszukiwania sąsiadów wymaga dodatkowych obliczeń. Koszt przenosi się na predykcję: naiwne wyszukanie sąsiadów jednego punktu wymaga obliczenia n odległości w p wymiarach, czyli czasu rzędu np. Przy dużych zbiorach stosuje się struktury danych przyspieszające wyszukiwanie, takie jak drzewa k-d i drzewa kul (w scikit-learn parametr `algorithm`). W małej liczbie wymiarów działają one znacznie szybciej niż przegląd wszystkich punktów, w dużej – z powodów opisanych w sekcji 3.5 – tracą przewagę. W bardzo dużych zbiorach używa się wyszukiwania przybliżonego, które zwraca punkty bliskie, choć niekoniecznie najbliższe.

Model to dane. W sekcji 1.9 zauważyliśmy, że opis dopasowanego modelu k-NN obejmuje cały zbiór uczący. Ma to konsekwencje praktyczne: model zajmuje tyle pamięci co dane, a jego udostępnienie oznacza udostępnienie danych, co bywa wykluczone, gdy dotyczą one osób.

Ważenie sąsiadów. We wzorze (3.1) wszyscy sąsiedzi ważą tyle samo, także ten, który ledwo zmieścił się w otoczeniu. Często stosowanym wariantem jest ważenie wyników odwrotnością odległości (w scikit-learn `weights="distance"`). Przy takim ważeniu punkt uczący pokrywający się z $\mathbf{x}$ przejmuje całą wagę, więc błąd na zbiorze uczącym wynosi zero niezależnie od k, o ile nie ma obserwacji o tych samych cechach i różnych wynikach.

Typowe użycie. Standaryzację i klasyfikator łączymy w potok (`Pipeline`). Potok gwarantuje, że parametry standaryzacji wyznaczane są wyłącznie na danych przekazanych do `fit`, a przy predykcji stosowane bez zmian. Poniższy przykład porównuje oba warianty na zbiorze danych o nowotworach piersi dołączonym do scikit-learn: 569 obserwacji i 30 cech mierzonych w bardzo różnych skalach.

```
rozrzut cech (odchylenia standardowe): od 0.00231 do 577
bez standaryzacji: błąd na zbiorze testowym 0.076
ze standaryzacją : błąd na zbiorze testowym 0.064
[[1.  0. ]
 [0.1 0.9]
 [1.  0. ]]
```

Metoda `predict_proba` zwraca oszacowania (3.2), które można podstawić do reguły kosztowej zamiast używać domyślnego progu $1/2$. Wartość $k = 10$ przyjęliśmy tu arbitralnie. Jak ją wybrać na podstawie danych i jak rzetelnie ocenić błąd tak wybranego modelu, omówimy w rozdziale 5.

3.7. Rozszerzenie: geometria wysokich wymiarów

Materiał nieobowiązkowy

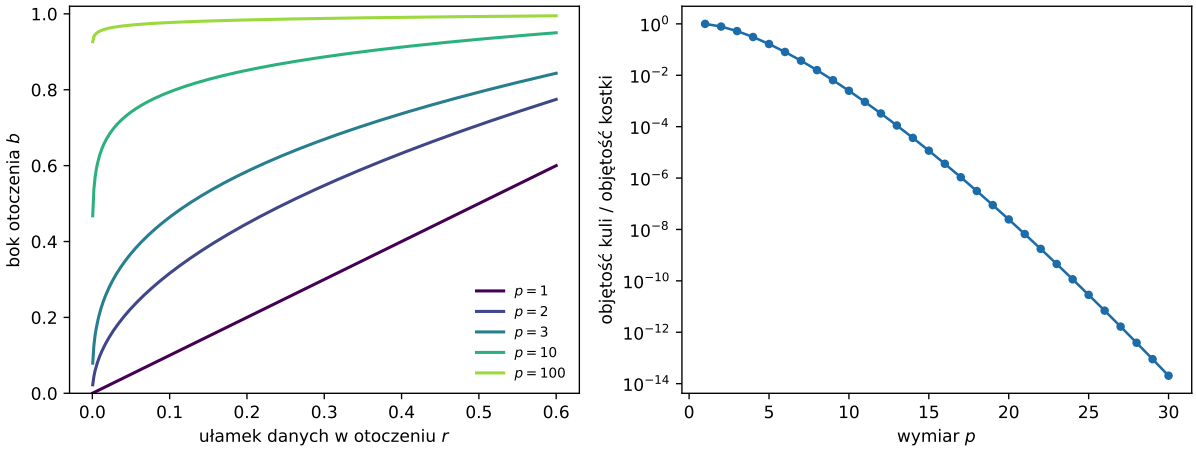
Wymagany jest rachunek objętości z sekcji 3.5. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

3.7.1. Objętość poza kulą wpisaną i blisko brzegu

W jednym wymiarze odcinek $[-\frac{1}{2}, \frac{1}{2}]$ i „kula” o promieniu $\frac{1}{2}$ to ten sam zbiór. W dwóch wymiarach koło wpisane w kwadrat zajmuje $\pi/4 \approx 79\%$ jego pola, w trzech kula wpisana w sześcian – 52% objętości. W dziesięciu wymiarach ten udział spada do 0,25%, a w dwudziestu do około $2{,}5 \cdot 10^{-8}$ (Zadanie 3.6). Niemal cała objętość kostki leży poza kulą wpisaną. Nie oznacza to, że punkty skupiają się w małych otoczeniach samych wierzchołków.

Podobnie jest z brzegami. W kuli o promieniu 1 warstwa przy powierzchni o grubości ε zajmuje ułamek $1 - (1 - \varepsilon)^p$ objętości. Dla $\varepsilon = 0{,}05$ jest to 5% w jednym wymiarze, 40% w dziesięciu i ponad 99% w stu. Punkty losowane jednostajnie leżą więc prawie wszystkie blisko brzegu, a predykcja w punkcie przy brzegu opiera się na sąsiadach leżących tylko po jednej jego stronie – jak na krańcach przedziału w Rysunek 3.4.

Rysunek 3.7 zestawia oba zjawiska.



Rysunek 3.7.: Geometria wysokich wymiarów. Po lewej: bok kostki-otoczenia, które obejmuje ułamek r danych jednostajnych w $[0,1]^p$, według wzoru $b = r^{1/p}$. Po prawej: ułamek objętości kostki zajmowany przez kulę wpisaną (oś pionowa w skali logarytmicznej).

3.7.2. Odległości przestają się różnić

Kolejne zjawisko dotyczy odległości między obserwacjami. Wylosujmy n punktów jednostajnie z kostki $[0,1]^p$ i dla nowego punktu porównajmy odległość do najbliższego i najdalszego z nich. W jednym wymiarze najbliższy punkt jest setki razy bliżej niż najdalszy. Wraz ze wzrostem p iloraz tych odległości zbliża się do jedności (Rysunek 3.8): wszystkie punkty są od nowego punktu mniej więcej tak samo daleko. Zjawisko to, nazywane **koncentracją odległości**, zachodzi dla szerokiej klasy rozkładów, w których cechy nie są silnie zależne (Beyer i in. 1999). Gdy wszyscy są niemal równo odlegli, „najbliższy sąsiad" może być wyznaczony głównie przez różnice w cechach nieistotnych. Sama koncentracja odległości nie dowodzi jeszcze braku informacji o klasie; zależy to także od związku cech z wynikiem.

3.8. Rozszerzenie: zbieżność do optimum

Materiał nieobowiązkowy

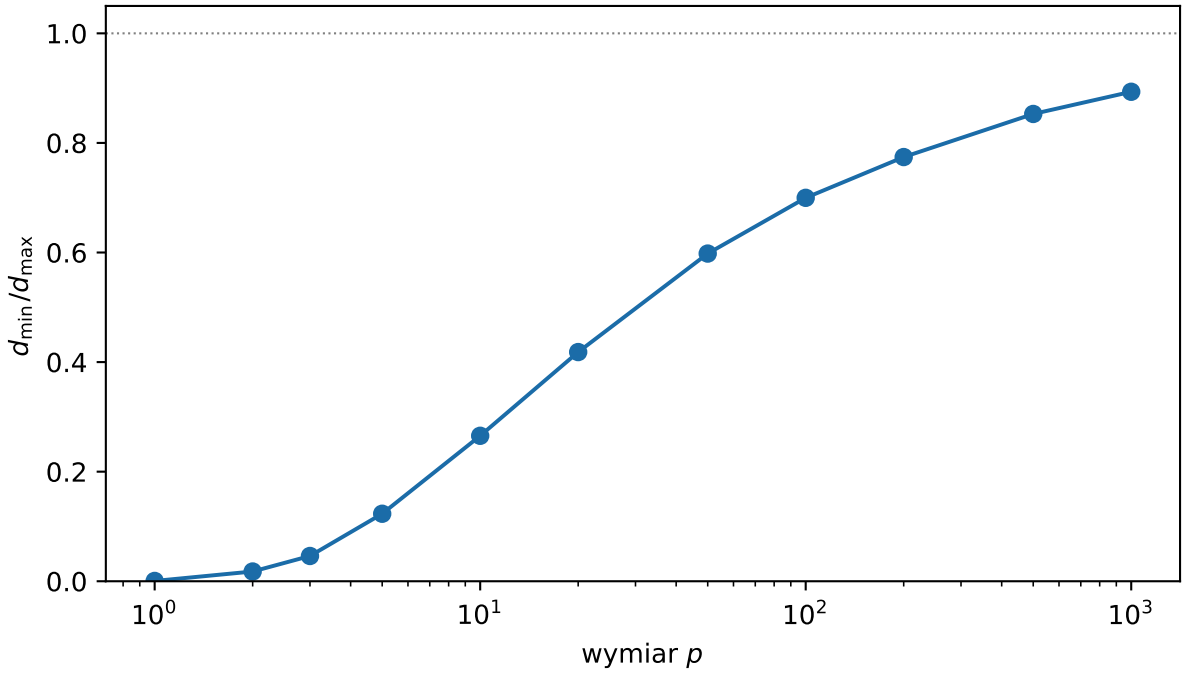
Wymagane są granice ciągów i wartość oczekiwana, a w dowodzie nierówność Jensena. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

W Rysunek 2.2 ryzyko klasyfikatora k-NN z $k = \sqrt{n}$ zbliżało się do błędu bayesowskiego wraz ze wzrostem próby. Nie był to przypadek wybranego rozkładu. Dla obu zadań, regresji i klasyfikacji, zachodzi następujący wynik (C. J. Stone 1977).

Twierdzenie 3.1 (Zgodność uniwersalna k-NN)**.** *Niech liczba sąsiadów $k = k_n$ zależy od liczności próby n tak, że*

$$k_n \to \infty \qquad \text{oraz} \qquad \frac{k_n}{n} \to 0 \qquad \text{przy } n \to \infty.$$

*Zakładamy próbę i.i.d., cechy w ustalonej przestrzeni $\mathbb{R}^p$, odległość euklidesową i rozstrzyganie remisów w odległościach według indeksów, niezależnie od wyników. W klasyfikacji liczba klas jest skończona. Wtedy dla **każdego** rozkładu $(\mathbf{X}, Y)$:*



Rysunek 3.8.: Koncentracja odległości. Dla $n = 1000$ punktów jednostajnych w $[0,1]^p$ i losowego punktu zapytania pokazano iloraz odległości do najbliższego i najdalszego punktu (średnia z 50 punktów zapytania). Gdy iloraz zbliża się do 1, najbliższy i najdalszy sąsiad są od punktu niemal tak samo odlegli.

a) w klasyfikacji ryzyko klasyfikatora (3.3) dąży do błędu bayesowskiego, $\mathbb{E}[R(\hat{g}_n)] \to R(g^*)$*;*
b) w regresji, jeśli $\mathbb{E}[Y^2] < \infty$*, ryzyko predyktora (3.1) przy stracie kwadratowej dąży do ryzyka funkcji regresji,* $\mathbb{E}[R(\widehat{f}_n)] \to R(f^*)$*.*

Wartość oczekiwana $\mathbb{E}$ *dotyczy tu losowości zbioru uczącego.*

Dowód wymaga sporo techniki i go pomijamy; pełne ujęcie podają Devroye i in. (1996) dla klasyfikacji i Györfi i in. (2002) dla regresji. Rolę obu warunków omówiliśmy w podsekcji „Gdy danych przybywa”; wybór $k = \sqrt{n}$ spełnia oba.

Siła twierdzenia leży w słowie „każdego”. Nie zakładamy ciągłości funkcji regresji, postaci rozkładów klas ani istnienia gęstości. Metodę o tej własności nazywamy **uniwersalnie zgodną**.

Co się dzieje, gdy k nie rośnie? Dla reguły jednego najbliższego sąsiada odpowiedź podali Cover i Hart (1967).

Twierdzenie 3.2 (Twierdzenie Covera–Harta)**.** *Rozważmy dwie klasy i niech* R^* *oznacza błąd bayesowski. Przy łagodnych założeniach o regularności rozkładu ryzyko reguły jednego najbliższego sąsiada, uśrednione po próbach uczących, dąży przy* $n \to \infty$ *do granicy*

$$R_{1NN} = \mathbb{E}\big[\,2\,\eta(\mathbf{X})(1-\eta(\mathbf{X}))\big], \tag{3.6}$$

która spełnia

$$R^* \;\le\; R_{1NN} \;\le\; 2R^*(1-R^*) \;\le\; 2R^*. \tag{3.7}$$

Dowód. Podajemy szkic, pomijając część techniczną. Przy rosnącym n najbliższy sąsiad punktu $\mathbf{x}$ leży coraz bliżej $\mathbf{x}$, więc jego prawdopodobieństwo klasy zbliża się do $\eta(\mathbf{x})$. Etykieta sąsiada

i nieznana etykieta punktu $\mathbf{x}$ są niezależnymi losowaniami z tego samego rozkładu dwupunktowego. Różnią się z prawdopodobieństwem

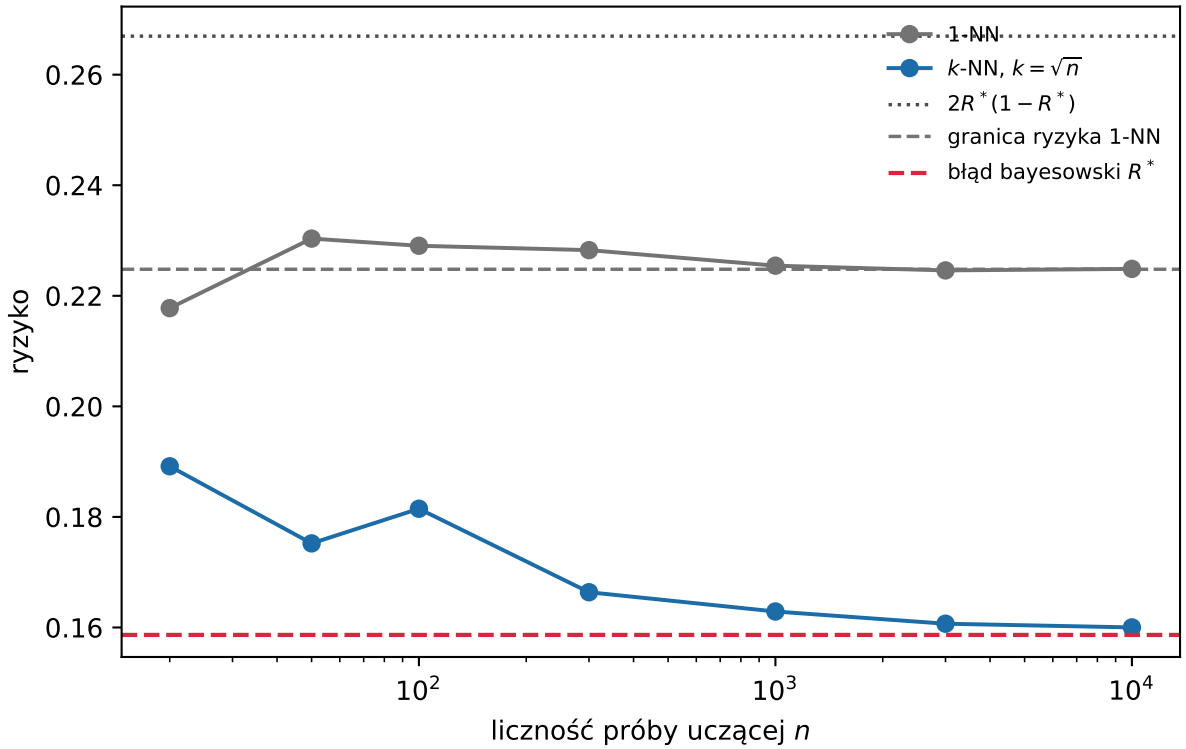
$$\eta(\mathbf{x})(1-\eta(\mathbf{x})) + (1-\eta(\mathbf{x}))\eta(\mathbf{x}) = 2\,\eta(\mathbf{x})(1-\eta(\mathbf{x})).$$

Uśrednienie po rozkładzie $\mathbf{X}$ daje (3.6).

Do nierówności oznaczmy $r(\mathbf{x}) = \min\big(\eta(\mathbf{x}), 1-\eta(\mathbf{x})\big)$; z (2.7) $R^* = \mathbb{E}[r(\mathbf{X})]$. Ponieważ $2\eta(1-\eta) = 2r(1-r)$, mamy $R_{1\mathrm{NN}} = \mathbb{E}[2r(\mathbf{X})(1-r(\mathbf{X}))]$. Lewa nierówność wynika z $r \le \frac{1}{2}$, czyli $2(1-r) \ge 1$. Dla prawej zauważmy, że $\mathbb{E}[2r(1-r)] = 2\mathbb{E}[r] - 2\mathbb{E}[r^2]$, a z nierówności Jensena $\mathbb{E}[r^2] \ge (\mathbb{E}[r])^2$, więc $R_{1\mathrm{NN}} \le 2R^* - 2(R^*)^2$. □ □

Wynik ma prostą interpretację. Reguła, która nie uśrednia niczego, myli się asymptotycznie co najwyżej dwa razy częściej niż reguła optymalna. Nie oznacza to jednak zgodności uniwersalnej 1-NN. Różnica między jej granicznym ryzykiem a błędem bayesowskim wynosi $\mathbb{E}[r(\mathbf{X})(1-2r(\mathbf{X}))]$, gdzie $r(\mathbf{x}) = \min(\eta(\mathbf{x}), 1-\eta(\mathbf{x}))$. Jest dodatnia, jeśli z dodatnim prawdopodobieństwem $0 < r(\mathbf{X}) < 1/2$. Może natomiast wynosić zero także przy dodatnim błędzie bayesowskim, na przykład gdy $\eta(\mathbf{x}) = 1/2$ wszędzie: wtedy żadna reguła nie przewiduje lepiej niż losowanie.

Rysunek 3.9 sprawdza oba twierdzenia na rozkładzie z Rysunek 2.2: dwie równoliczne klasy $\mathcal{N}(\pm 1, 1)$, dla których $R^* = \Phi(-1) \approx 0{,}159$. Granicę (3.6) można tu policzyć numerycznie: wynosi około 0,225, a ograniczenie górne (3.7) – około 0,267.



Rysunek 3.9.: Ryzyko reguły 1-NN i reguły k-NN z $k = \sqrt{n}$ w zależności od liczności próby, dla dwóch klas $\mathcal{N}(\pm 1, 1)$. Ryzyko przybliżono przez całkowanie numeryczne po znanym rozkładzie; punkty to średnie z 25 prób uczących. Linie poziome: błąd bayesowski R^*, granica ryzyka 1-NN z twierdzenia Covera–Harta i jej ograniczenie górne $2R^*(1-R^*)$.

Ryzyko 1-NN szybko stabilizuje się na poziomie granicy (3.6) i dalsze dane już go nie zmniejszają. Ryzyko reguły z $k = \sqrt{n}$ schodzi poniżej tej granicy i powoli zbliża się do R^*, zgodnie z Twierdzenie 3.1.

⚠ Zbieżność nie znaczy „szybko”

Twierdzenie 3.1 mówi, dokąd zmierza ryzyko, ale nie mówi, jak szybko. Bez założeń o rozkładzie żadnej gwarancji tempa być nie może: dla dowolnej reguły klasyfikacji i dowolnie wolno malejącego ciągu istnieją rozkłady, dla których ryzyko zbliża się do R^* jeszcze wolniej (Devroye i in. 1996, rozdz. 7). Uniwersalność ma swoją cenę.
Gdy funkcja regresji jest gładka, tempo da się oszacować, ale zależy ono od liczby cech p i maleje wraz z nią. W przykładzie jednowymiarowym z powyższego rysunku kilkaset obserwacji daje już ryzyko bliskie optimum. W wielu wymiarach potrzebna liczba obserwacji rośnie tak szybko, że gwarancja asymptotyczna traci praktyczne znaczenie. Mechanizm ten opisaliśmy w sekcji 3.5.

Uwagi bibliograficzne

Metodę k najbliższych sąsiadów w ujęciu bliskim temu rozdziałowi przedstawiają James i in. (2023, rozdz. 2.2) oraz Hastie i in. (2009, rozdz. 2.3). W drugiej z tych książek można też znaleźć analizę przekleństwa wymiarowości dla metod lokalnych (Hastie i in. 2009, rozdz. 2.5) i omówienie klasyfikatorów k-NN w zastosowaniach (Hastie i in. 2009, rozdz. 13.3). Porównanie regresji k-NN z regresją liniową w zależności od liczby cech zawiera James i in. (2023, rozdz. 3.5).

Ścisłą teorię reguł najbliższych sąsiadów w klasyfikacji, z dowodami twierdzenia Stone'a i twierdzenia Covera–Harta oraz wynikami o braku uniwersalnego tempa zbieżności, wykładają Devroye i in. (1996). Analogiczną teorię dla regresji, łącznie z tempem zbieżności dla funkcji gładkich i jego zależnością od wymiaru, podają Györfi i in. (2002).

Regułę najbliższego sąsiada wprowadzili w raporcie z 1951 roku Fix i Hodges (1951), którzy wykazali też jej zgodność przy rosnącym k. Raport przedrukowano w 1989 roku w *International Statistical Review*. Cover i Hart (1967) udowodnili ograniczenie przez podwojony błąd bayesowski, a C. J. Stone (1977) – zgodność uniwersalną szerokiej klasy reguł uśredniania lokalnego, obejmującej k-NN. Zjawisko koncentracji odległości i jego skutki dla wyszukiwania najbliższych sąsiadów badają Beyer i in. (1999).

Zadania

Zadanie 3.1. Zbiór uczący składa się z sześciu obserwacji o dwóch cechach:

i	x_1	x_2	klasa	y
1	1	1	A	2,0
2	2	1	A	2,5
3	4	3	B	5,0
4	5	4	B	6,5
5	2	3	B	4,0
6	3	2	A	3,5

a) Dla punktu $\mathbf{x} = (1, 3)$ wyznacz odległości euklidesowe do wszystkich obserwacji i zbiory $N_1(\mathbf{x})$, $N_3(\mathbf{x})$.
b) Podaj predykcję klasy dla $k = 1$ i $k = 3$ oraz oszacowanie $\hat{\eta}_{\mathrm{B}}(\mathbf{x})$ dla $k = 3$.

c) Traktując y jako zmienną wynikową, podaj predykcję regresji k-NN dla $k = 1$ i $k = 3$.
d) Powtórz punkt a) dla odległości miejskiej. Czy zbiory sąsiadów się zmieniają? Jak rozstrzygnąć ewentualny remis?

Zadanie 3.2. W zbiorze z Zadanie 3.1 cecha x_2 jest mierzona w metrach. Przelicz ją na centymetry i powtórz punkt b) tego zadania. Następnie standaryzuj obie cechy (średnie i odchylenia wyznacz na zbiorze uczącym) i powtórz obliczenia raz jeszcze. Która z trzech wersji daje „właściwych" sąsiadów? Podaj przykład sytuacji, w której standaryzacja pogarsza wynik k-NN. (Wskazówka: Rysunek 3.2.)

Zadanie 3.3. Wykaż, że dla $k = n$ regresja k-NN przewiduje w każdym punkcie średnią $\bar{y}$, a klasyfikacja – klasę najczęstszą w próbie. Dla dwóch klas z $\pi = \mathbb{P}(Y = 1) > \frac{1}{2}$ wyznacz granicę ryzyka tego klasyfikatora przy $n \to \infty$ i porównaj ją z błędem bayesowskim, zapisanym przez η. Kiedy oba błędy są równe? Odnieś wynik do Zadanie 2.12.

Zadanie 3.4. Zmodyfikuj przykład z Rysunek 3.4 tak, aby 10% wyników zastąpić wartościami odstającymi, na przykład $y_i + 5$. Zaimplementuj regresję k-NN, która zamiast średniej zwraca medianę wyników sąsiadów, i porównaj ją z (3.1) dla $k = 15$: na wykresie oraz pod względem ryzyka przy stracie kwadratowej i absolutnej, liczonego względem rozkładu bez obserwacji odstających. Wyjaśnij wynik, odwołując się do Twierdzenie 2.4.

Zadanie 3.5. Klasyfikator k-NN z $k = 5$ zwraca oszacowania $\hat{\eta}(\mathbf{x}) \in \{0, \frac{1}{5}, \dots, 1\}$.

a) Pominięcie przypadku pozytywnego kosztuje dziesięć razy więcej niż fałszywy alarm. Korzystając z (2.10), wyznacz próg i zapisz otrzymaną regułę w postaci „klasa 1, jeśli wśród pięciu sąsiadów jest co najmniej j przypadków pozytywnych".
b) Ile różnych reguł decyzyjnych można otrzymać, zmieniając próg w przedziale $(0, 1)$? Wskaż przedziały progów dających tę samą regułę.
c) Jak zmienia się odpowiedź dla $k = 50$? Jaki wniosek płynie stąd dla doboru k, gdy oszacowania $\hat{\eta}$ mają służyć regule kosztowej lub regule Chowa?

Zadanie 3.6. Rozszerzenie: geometria. Wymagane są funkcja gamma i wzór Stirlinga.

Objętość kuli o promieniu ρ w $\mathbb{R}^p$ wynosi $V_p(\rho) = \dfrac{\pi^{p/2}}{\Gamma(p/2+1)}\,\rho^p$.

a) Wyznacz ułamek objętości kostki $[-\frac{1}{2}, \frac{1}{2}]^p$ zajmowany przez kulę wpisaną i sprawdź wartości podane w sekcji 3.5 dla $p = 2, 3, 10$.
b) Korzystając ze wzoru Stirlinga, wykaż, że ten ułamek dąży do zera przy $p \to \infty$, i to szybciej niż dowolny ciąg geometryczny.
c) Wyznacz odległość od środka kostki do jej wierzchołka. Jak zmienia się ona z p w porównaniu z promieniem kuli wpisanej?

Zadanie 3.7. Dane mają rozkład jednostajny w $[0, 1]^p$. Rozważaj kostki w całości zawarte w tym obszarze, z punktem zapytania w ich środku.

a) Ilu obserwacji potrzeba, aby kostka o boku 0,1 wokół punktu zawierała średnio 10 obserwacji? Podaj wynik dla $p = 1, 2, 5, 10$.
b) Przy $n = 10^6$ i $k = 10$ wyznacz bok otoczenia (3.5) dla $p = 2, 10, 50$.
c) Zakładając, że funkcja regresji spełnia $|f^*(\mathbf{x}) - f^*(\mathbf{x}')| \leq L \max_j |x_j - x'_j|$, oszacuj z góry błąd, jaki wnosi do predykcji samo uśrednianie po otoczeniu o boku b. Co ten rachunek mówi o k-NN dla $p = 50$?

Zadanie 3.8. Rozszerzenie: graniczne ryzyko. Wymagane są rozkład normalny, całkowanie numeryczne i nierówność Jensena.

Rozważ dwie równoliczne klasy $\mathcal{N}(-\mu, 1)$ i $\mathcal{N}(\mu, 1)$ na prostej.

a) Wyznacz $\eta(x)$ i wykaż, że $2\eta(x)(1-\eta(x)) = \dfrac{1}{2\cosh^2(\mu x)}$. (Wskazówka: zapisz η przez funkcję logistyczną.)
b) Policz numerycznie granicę (3.6) oraz ograniczenie $2R^*(1-R^*)$ dla $\mu \in \{0{,}25;\ 0{,}5;\ 1;\ 2;\ 3\}$. Dla jakich μ ograniczenie jest bliskie granicy, a dla jakich luźne?
c) Sprawdź wynik symulacyjnie, modyfikując kod Rysunek 3.9.
d) Podaj rozkład, dla którego w (3.7) zachodzi równość $R_{1\mathrm{NN}} = 2R^*(1-R^*)$. (Wskazówka: kiedy nierówność Jensena jest równością?)

4. Kompromis obciążenie–wariancja

Dlaczego model, który bardzo dobrze dopasował się do danych, może źle przewidywać nowe wyniki? W rozdziale 3 widzieliśmy to dla metody k-NN: mała liczba sąsiadów pozwala odtworzyć szczegóły próby, ale część tych szczegółów jest przypadkowa. Gdybyśmy zebrali inne dane, otrzymalibyśmy inną regułę przewidywania.

W tym rozdziale rozdzielimy dwa źródła błędu uczenia. **Obciążenie** opisuje systematyczne odchylenie przeciętnej predykcji od funkcji regresji. **Wariancja** opisuje zmienność predykcji między zbiorami uczącymi. Zaczniemy od porównania dopasowań do różnych prób, a następnie pokażemy, jak oba składniki łączą się z błędem nieredukowalnym z rozdziału 2.

Przykładami będą znana już metoda k-NN i regresja wielomianowa. Zobaczymy, kiedy pomaga prostszy model, kiedy więcej danych, a kiedy trzeba zmienić klasę modeli. Główny rachunek dotyczy regresji ze stratą kwadratową. Na końcu wyjaśnimy, dlaczego w klasyfikacji te same pojęcia nie dają równie prostego rozkładu błędu. Szczegółowe porównanie z błędem aproksymacji i rachunek tempa zbieżności znajdą się w rozszerzeniach.

4.1. Błąd uczący a ryzyko

W sekcji 1.8 zauważyliśmy, że dostatecznie bogata klasa modeli pozwala niemal zapamiętać zbiór uczący, łącznie z przypadkowymi odchyleniami wyników. Aby zbadać to zjawisko, potrzebujemy metod, których elastyczność można regulować. Jedną już znamy: w metodzie k-NN elastyczność rośnie, gdy k maleje, a miarą tej elastyczności jest efektywna liczba parametrów n/k.

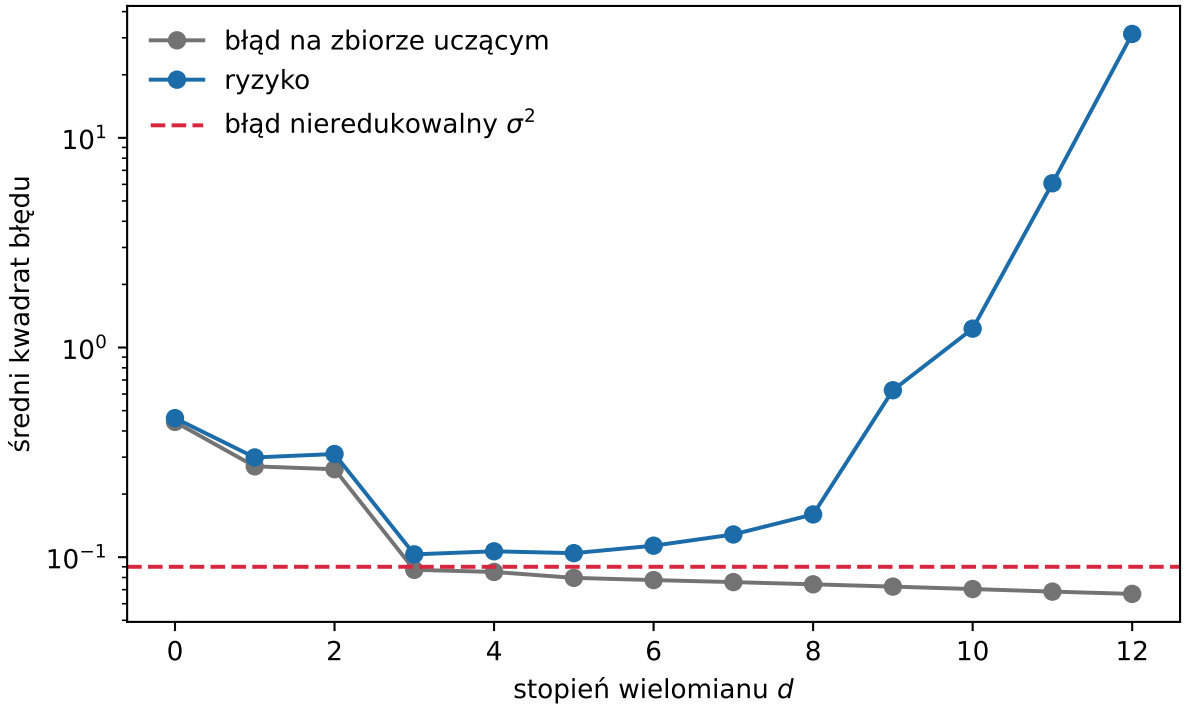
Drugą jest **regresja wielomianowa**. Dla cechy $x \in \mathbb{R}$ i ustalonego stopnia d rozważamy klasę wielomianów

$$\mathcal{F}_d = \{\, f(x) = \beta_0 + \beta_1 x + \cdots + \beta_d x^d : \beta_0, \ldots, \beta_d \in \mathbb{R} \,\}$$

i wybieramy z niej predyktor metodą najmniejszych kwadratów, czyli minimalizujemy ryzyko empiryczne przy stracie kwadratowej (1.11). Jak to zrobić rachunkowo, omawia sekcja 6.2; tu korzystamy z gotowej funkcji biblioteki NumPy. Przy ustalonym d jest to metoda parametryczna z $d+1$ współczynnikami, a stopień d pełni rolę hiperparametru, podobnie jak k w metodzie k-NN.

Klasy wielomianów są zagnieżdżone: $\mathcal{F}_0 \subset \mathcal{F}_1 \subset \mathcal{F}_2 \subset \cdots$, bo każdy wielomian stopnia co najwyżej d należy też do klasy wielomianów stopnia co najwyżej $d+1$. Minimum ryzyka empirycznego po większym zbiorze nie może być większe niż po mniejszym, więc **błąd na zbiorze uczącym nie rośnie wraz z** d – dla każdej próby, a nie tylko przeciętnie. Jeśli wszystkie x_i są różne, to dla $d = n - 1$ istnieje wielomian przechodzący przez wszystkie punkty i błąd uczący spada do zera. Powtarzające się wartości x_i z różnymi wynikami y_i uniemożliwiają takie dokładne dopasowanie.

Rysunek 4.1 pokazuje błąd uczący i ryzyko dla wielomianów stopni od 0 do 12, dopasowanych do $n = 50$ obserwacji. Dane pochodzą z tego samego rozkładu co w rozdziale 3: X ma rozkład jednostajny na $[0, 1]$, $Y = f^*(X) + \varepsilon$, gdzie $f^*(x) = \sin(2\pi x) + x/2$, a szum ma odchylenie



Rysunek 4.1.: Błąd na zbiorze uczącym i ryzyko regresji wielomianowej w zależności od stopnia wielomianu d ($n = 50$). Ryzyko przybliżono przez całkowanie numeryczne po znanym rozkładzie; punkty to średnie z 1000 niezależnych prób uczących. Oś pionowa w skali logarytmicznej. Przerywana linia to błąd nieredukowalny σ^2.

standardowe $\sigma = 0{,}3$. Ryzyko przybliżamy numerycznie, całkując po znanym rozkładzie, tak jak na rysunku 3.5.

Obraz jest taki sam jak na rysunku 3.5, choć metoda jest zupełnie inna. Czytelnik, który rozwiązał zadanie 1.14, widział go już na własnej symulacji. Błąd uczący maleje monotonicznie i schodzi poniżej błędu nieredukowalnego, czego ryzyko nie może zrobić nigdy. Ryzyko najpierw spada, osiąga minimum przy stopniu 3–5, a potem rośnie, i to gwałtownie: przy $d = 12$ jest o rzędy wielkości większe niż w minimum.

Dwa krańce wykresu mają swoje nazwy. Model zbyt sztywny, jak prosta ($d = 1$), ma duży błąd uczący i duże ryzyko, przy czym obie wielkości są sobie bliskie. Mówimy wtedy o **niedopasowaniu** (ang. *underfitting*): model nie jest w stanie odtworzyć zależności nawet na danych, które widział. Model zbyt elastyczny ma mały błąd uczący i duże ryzyko. To **nadmierne dopasowanie** (ang. *overfitting*), o którym mówiliśmy w sekcji 1.8: model dopasował się do przypadkowych odchyleń w próbie, których nie da się przewidzieć dla nowych obiektów.

Różnicę między ryzykiem a błędem uczącym nazywa się czasem **optymizmem** błędu uczącego (Hastie i in. 2009, rozdz. 7.4). Bierze się ona stąd, że predykcja $\widehat{f}(x_i)$ zależy od wyniku y_i, z którym ją porównujemy: model był dobierany tak, by wypadać dobrze właśnie na tych obserwacjach. Dla metody k-NN optymizm da się policzyć dokładnie (Zadanie 4.4). Błąd uczący nie mówi więc, dlaczego ryzyko po prawej stronie wykresu rośnie. Aby to zrozumieć, musimy zobaczyć, jak dopasowany predyktor zależy od zbioru uczącego.

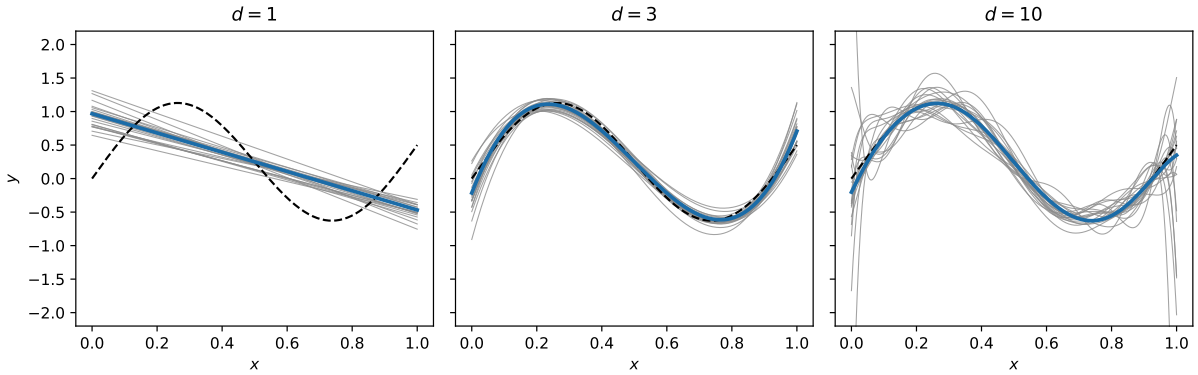
4.2. Zbiór uczący jest losowy

W sekcji 1.5 przyjęliśmy, że obserwacje $(\mathbf{X}_1, Y_1), \ldots, (\mathbf{X}_n, Y_n)$ są niezależnymi losowaniami z rozkładu P. Zbiór uczący $\mathcal{D}$ jest więc losowy, a wraz z nim losowy jest wyznaczony z niego predyktor. Będziemy go oznaczać $\hat{f}_{\mathcal{D}}$, gdy zechcemy tę zależność podkreślić. W każdym ustalonym punkcie $\mathbf{x}$ wartość $\hat{f}_{\mathcal{D}}(\mathbf{x})$ jest zmienną losową: jej losowość pochodzi wyłącznie z losowania zbioru uczącego.

Średnią i wariancję względem tego losowania oznaczamy $\mathbb{E}_{\mathcal{D}}$ i $\mathrm{Var}_{\mathcal{D}}$. Szczególną rolę odgrywa **predyktor przeciętny**

$$\bar{f}(\mathbf{x}) = \mathbb{E}_{\mathcal{D}}[\hat{f}_{\mathcal{D}}(\mathbf{x})], \tag{4.1}$$

czyli średnia predykcji w punkcie $\mathbf{x}$ po wszystkich zbiorach uczących liczności n, jakie mogliśmy wylosować. Jest to konstrukcja myślowa: w praktyce mamy jeden zbiór uczący i jeden predyktor. W symulacji, gdzie rozkład P znamy, możemy jednak wylosować wiele zbiorów uczących i zobaczyć, jak bardzo różnią się dopasowane do nich predyktory. Robi to Rysunek 4.2.



Rysunek 4.2.: Wielomiany stopni $d = 1, 3, 10$ dopasowane do 20 niezależnych prób uczących liczności $n = 50$ (cienkie linie). Gruba niebieska linia to predyktor przeciętny $\bar{f}$, oszacowany z 1000 prób, przerywana – funkcja regresji f^*.

Trzy panele pokazują trzy różne sytuacje. Proste ($d = 1$) dopasowane do różnych prób są do siebie podobne, ale wszystkie mijają się z funkcją regresji w ten sam sposób. Ich średnia również jest prostą i również nie oddaje kształtu f^*. Błąd jest **systematyczny**: nie zniknąłby, nawet gdybyśmy uśrednili nieskończenie wiele dopasowań. Wielomiany stopnia 10 zachowują się odwrotnie. Ich średnia niemal pokrywa się z f^*, ale pojedyncze dopasowania rozchodzą się w różne strony, najmocniej przy krańcach przedziału, gdzie danych jest mało, a wielomian wysokiego stopnia łatwo „ucieka". Błąd jest **losowy**: zależy od tego, jaki zbiór uczący akurat wylosowaliśmy. Wielomiany stopnia 3 leżą pośrodku: ich średnia jest bliska f^*, a rozrzut niewielki.

Ryzyko na rysunku 4.1 łączy oba rodzaje błędu. Aby je rozdzielić, potrzebujemy dwóch pojęć z teorii estymacji.

4.3. Obciążenie i wariancja estymatora

Zacznijmy od małego przykładu. Przy ustalonej temperaturze prawdziwy średni popyt wynosi 10 sztuk. Dwie metody, zależnie od wylosowanego zbioru uczącego, dają następujące prognozy. Dla uproszczenia każda z trzech możliwości ma prawdopodobieństwo 1/3.

Metoda	Możliwe prognozy	Średnia prognoza	Obciążenie	Wariancja	Średni kwadrat odległości od 10
A	$7, 8, 9$	8	-2	$2/3$	$14/3$
B	$7, 10, 13$	10	0	6	6

Metoda A przeciętnie zaniża popyt o dwie sztuki. Jej prognozy są jednak skupione blisko swojej średniej: ich wariancja to $[(-1)^2 + 0^2 + 1^2]/3 = 2/3$. Średni kwadrat odległości od prawdziwej wartości 10 wynosi $[(-3)^2 + (-2)^2 + (-1)^2]/3 = 14/3$. Metoda B trafia przeciętnie dokładnie w 10, ale jej prognozy mają większy rozrzut. Przy ocenie średnim kwadratem błędu wygrywa metoda A: $14/3 < 6$. Sam brak obciążenia nie wystarcza do dobrej predykcji.

Na razie porównujemy prognozę ze średnim popytem, a nie z wynikiem nowego dnia. Zmienność tego wyniku uwzględnimy w następnej sekcji. Teraz zapiszmy rachunek w ogólnej postaci.

Definicja 4.1 (Obciążenie i błąd średniokwadratowy)**.** Niech $\hat{\theta}$ będzie estymatorem nieznanej liczby θ, czyli zmienną losową obliczaną z próby. Jego **obciążeniem** (ang. *bias*) nazywamy różnicę

$$\mathrm{b}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta,$$

a jego **błędem średniokwadratowym** (ang. *mean squared error*) – wielkość $\mathrm{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2]$. Estymator o zerowym obciążeniu nazywamy **nieobciążonym**.

Obciążenie mówi, gdzie estymator trafia przeciętnie, wariancja $\operatorname{Var}\hat{\theta}$ – jak bardzo jego wartości rozrzucone są wokół tej przeciętnej. Błąd średniokwadratowy łączy oba składniki:

$$\mathrm{MSE}(\hat{\theta}) = \mathrm{b}(\hat{\theta})^2 + \operatorname{Var}\hat{\theta}. \tag{4.2}$$

Jest to ta sama tożsamość, którą wyprowadziliśmy w dowodzie twierdzenia 2.2 jako (2.4): średni kwadrat odległości zmiennej losowej od stałej to jej wariancja plus kwadrat odległości jej średniej od tej stałej. Wystarczy zapisać $\hat{\theta} - \theta = (\hat{\theta} - \mathbb{E}[\hat{\theta}]) + (\mathbb{E}[\hat{\theta}] - \theta)$ i zauważyć, że iloczyn mieszany ma średnią zero.

W przykładzie metoda A ma obciążenie -2, więc jej błąd wynosi $(-2)^2 + 2/3 = 14/3$. Metoda B ma obciążenie zero i błąd równy wariancji, czyli 6. Wzór wyjaśnia, dlaczego **estymator obciążony może być lepszy od nieobciążonego**: wzrost kwadratu obciążenia może być mniejszy niż spadek wariancji.

Tę zasadę wykorzystuje **ściąganie** oszacowań do zera. Niech niezależne $Y_1, \ldots, Y_n$ mają średnią μ i wariancję σ^2. Średnia $\bar{Y}$ jest nieobciążona i ma wariancję σ^2/n. Pomnóżmy ją przez $c = 1 - h$, gdzie $0 < h \le 1$. Estymator $c\bar{Y}$ ma obciążenie $-h\mu$ i wariancję $(1-h)^2\sigma^2/n$, więc

$$\mathrm{MSE}(c\bar{Y}) = h^2\mu^2 + (1-h)^2\frac{\sigma^2}{n} = \frac{\sigma^2}{n} - h\Big[2\frac{\sigma^2}{n} - h\Big(\mu^2 + \frac{\sigma^2}{n}\Big)\Big].$$

Dla dostatecznie małego h wyrażenie w nawiasie kwadratowym jest dodatnie, więc $c\bar{Y}$ ma mniejszy błąd niż $\bar{Y}$ – przy każdym μ, σ i n. Niewielkie ściągnięcie zawsze się opłaca: kwadrat obciążenia rośnie jak h^2, a wariancja maleje w przybliżeniu proporcjonalnie do h.

Nie wynika stąd gotowy przepis. Zakres opłacalnych h i najlepsze h zależą od nieznanego μ (Zadanie 4.1), a zbyt mocne ściąganie szkodzi: przy $c = 0$ błąd wynosi μ^2. Siłę ściągania trzeba więc dobierać na podstawie danych, czym zajmuje się rozdział 5. Na tej samej zasadzie działa

regresja grzbietowa z rozdziału 7: ściąga współczynniki modelu liniowego do zera, zmniejszając wariancję kosztem obciążenia. W rozdziale 10 zobaczymy, że takie ściąganie wynika z rozkładu a priori.

Wróćmy do predykcji. Ustalmy punkt $\mathbf{x}_0$ i potraktujmy predykcję $\hat{f}_{\mathcal{D}}(\mathbf{x}_0)$ jako estymator liczby $\theta = f^*(\mathbf{x}_0)$. Jego obciążenie i wariancja to

$$b(\mathbf{x}_0) = \bar{f}(\mathbf{x}_0) - f^*(\mathbf{x}_0), \qquad v(\mathbf{x}_0) = \operatorname{Var}_{\mathcal{D}} \hat{f}_{\mathcal{D}}(\mathbf{x}_0). \tag{4.3}$$

Na rysunku 4.2 obciążenie to różnica wysokości grubej niebieskiej linii i linii przerywanej, z uwzględnieniem znaku, a wariancja opisuje rozrzut cienkich linii wokół niebieskiej. Obie wielkości są funkcjami punktu $\mathbf{x}_0$: wielomian stopnia 10 ma dużą wariancję przy krańcach przedziału i znacznie mniejszą w środku.

4.4. Rozkład oczekiwanego błędu predykcji

Możemy teraz połączyć obie warstwy losowości: losowość nowej obserwacji, którą przewidujemy, i losowość zbioru uczącego, z którego wyznaczyliśmy predyktor. W przykładzie popytu przyjmijmy, że wynik nowego dnia ma średnią 10 i wariancję 4, niezależnie od danych użytych do uczenia. Oczekiwany błąd predykcji metody A wynosi wtedy $4 + 14/3 = 26/3$, a metody B – $4 + 6 = 10$. Do obu błędów dochodzi ten sam składnik: zmienność wyniku, której nie da się przewidzieć na podstawie dostępnych cech. Ogólnie otrzymujemy następujący wzór.

Twierdzenie 4.1 (Rozkład na obciążenie i wariancję)**.** *Niech $\hat{f}_{\mathcal{D}}$ będzie predyktorem wyznaczonym z losowego zbioru uczącego $\mathcal{D}$, a $\mathbf{x}_0$ – ustalonym punktem. Niech Y_0 ma rozkład warunkowy $Y \mid \mathbf{X} = \mathbf{x}_0$, będzie niezależne od $\mathcal{D}$ i niech $\mathbb{E}[Y_0^2] < \infty$ oraz $\mathbb{E}_{\mathcal{D}}[\hat{f}_{\mathcal{D}}(\mathbf{x}_0)^2] < \infty$. Wtedy*

$$\mathbb{E}\big[(Y_0 - \hat{f}_{\mathcal{D}}(\mathbf{x}_0))^2\big] = \underbrace{\operatorname{Var}(Y \mid \mathbf{X} = \mathbf{x}_0)}_{\text{błąd nieredukowalny}} + \underbrace{b(\mathbf{x}_0)^2}_{\text{obciążenie}^2} + \underbrace{v(\mathbf{x}_0)}_{\text{wariancja}}, \tag{4.4}$$

gdzie wartość oczekiwana po lewej stronie dotyczy łącznie Y_0 i $\mathcal{D}$, a b i v są określone wzorem (4.3).

Dowód. Rozłóżmy błąd predykcji na trzy różnice:

$$Y_0 - \hat{f}_{\mathcal{D}}(\mathbf{x}_0) = \underbrace{\big(Y_0 - f^*(\mathbf{x}_0)\big)}_{A} + \underbrace{\big(f^*(\mathbf{x}_0) - \bar{f}(\mathbf{x}_0)\big)}_{B} + \underbrace{\big(\bar{f}(\mathbf{x}_0) - \hat{f}_{\mathcal{D}}(\mathbf{x}_0)\big)}_{C}.$$

Składnik A zależy tylko od Y_0 i ma średnią zero, bo $f^*(\mathbf{x}_0) = \mathbb{E}[Y_0]$. Składnik B jest stałą równą $-b(\mathbf{x}_0)$. Składnik C zależy tylko od $\mathcal{D}$ i również ma średnią zero, z definicji $\bar{f}$. Po podniesieniu sumy do kwadratu i uśrednieniu iloczyny mieszane znikają: $\mathbb{E}[AB] = B\,\mathbb{E}[A] = 0$, $\mathbb{E}[BC] = B\,\mathbb{E}[C] = 0$, a $\mathbb{E}[AC] = \mathbb{E}[A] \cdot \mathbb{E}[C] = 0$ dzięki niezależności Y_0 i $\mathcal{D}$. Zostają $\mathbb{E}[A^2] = \operatorname{Var}(Y \mid \mathbf{X} = \mathbf{x}_0)$, $B^2 = b(\mathbf{x}_0)^2$ i $\mathbb{E}[C^2] = v(\mathbf{x}_0)$. □ □

Pierwszy składnik zależy tylko od rozkładu $Y \mid \mathbf{X} = \mathbf{x}_0$ i żaden predyktor go nie zmniejszy. Dwa pozostałe to rozbity na części błąd redukowalny w punkcie $\mathbf{x}_0$, uśredniony po zbiorach uczących. Obciążenie jest błędem systematycznym, wariancja – losowym, w znaczeniu z rysunku 4.2.

Rozkład w jednym punkcie łatwo przenieść na całe ryzyko. Niech nowa obserwacja $(\mathbf{X}_0, Y_0)$ ma rozkład P i będzie niezależna od $\mathcal{D}$. Uśredniając (4.4) po rozkładzie $\mathbf{X}_0$ i pomijając po uśrednieniu indeks 0, otrzymujemy

$$\mathbb{E}_{\mathcal{D}}[R(\hat{f}_{\mathcal{D}})] = \mathbb{E}\big[\operatorname{Var}(Y \mid \mathbf{X})\big] + \mathbb{E}\big[b(\mathbf{X})^2\big] + \mathbb{E}[v(\mathbf{X})]. \tag{4.5}$$

Jest to rozkład (2.8) z rozdziału 2, uśredniony po zbiorach uczących, w którym błąd redukowalny rozpadł się na średni kwadrat obciążenia i średnią wariancję. Najpierw podnosimy obciążenie do kwadratu w każdym punkcie, a dopiero potem uśredniamy: dodatnie i ujemne odchylenia nie znoszą się w tej ocenie.

Trzy uśrednienia

We wzorze (4.5) występują trzy źródła losowości i łatwo je pomylić:

- **wynik Y przy ustalonych cechach** – jego zmienność to błąd nieredukowalny $\mathrm{Var}(Y \mid \mathbf{X})$, cecha zjawiska i zestawu cech;
- **zbiór uczący $\mathcal{D}$** – jego zmienność odpowiada za wariancję $v(\mathbf{x})$ i wyznacza predyktor przeciętny $\bar{f}$, cecha metody i liczności próby;
- **punkt X, w którym przewidujemy** – po nim uśredniamy na końcu, ważąc punkty rozkładem cech.

W szczególności „wariancja” w nazwie kompromisu to wariancja **predyktora** po zbiorach uczących, a nie wariancja szumu $\mathrm{Var}(Y \mid \mathbf{X})$. Model może mieć bardzo małą wariancję przy bardzo zaszumionych danych: predyktor stały $\hat{f} = 0$ ma wariancję zero niezależnie od szumu.

Ryzyko modelu a ryzyko metody

Ryzyko $R(\hat{f}_{\mathcal{D}})$ dopasowanego modelu jest liczbą zależną od tego, jaki zbiór uczący wylosowaliśmy – inną dla każdego zbioru. Wielkość $\mathbb{E}_{\mathcal{D}}[R(\hat{f}_{\mathcal{D}})]$ po lewej stronie (4.5) jest już własnością **metody uczenia** zastosowanej do prób liczności n, a nie konkretnego modelu. Rozkład na obciążenie i wariancję mówi więc, jak dobra jest procedura, a nie jak dobry jest model, który właśnie dopasowaliśmy. Rozróżnienie to wróci w rozdziale 5: walidacja krzyżowa szacuje raczej drugą z tych wielkości niż pierwszą (Hastie i in. 2009, rozdz. 7.12).

Twierdzenie 4.1 jest tożsamością: zachodzi dla każdej metody uczenia i każdej liczności próby, o ile spełnione są założenia o niezależności i skończonych drugich momentach. Sam w sobie nie mówi nic o kompromisie. Kompromis to obserwacja dotycząca tego, jak oba składniki zależą od elastyczności metody: zwiększając elastyczność, zwykle zmniejszamy obciążenie i zwiększamy wariancję. Sprawdźmy to na obu naszych metodach.

4.5. Ilustracja: k-NN i regresja wielomianowa

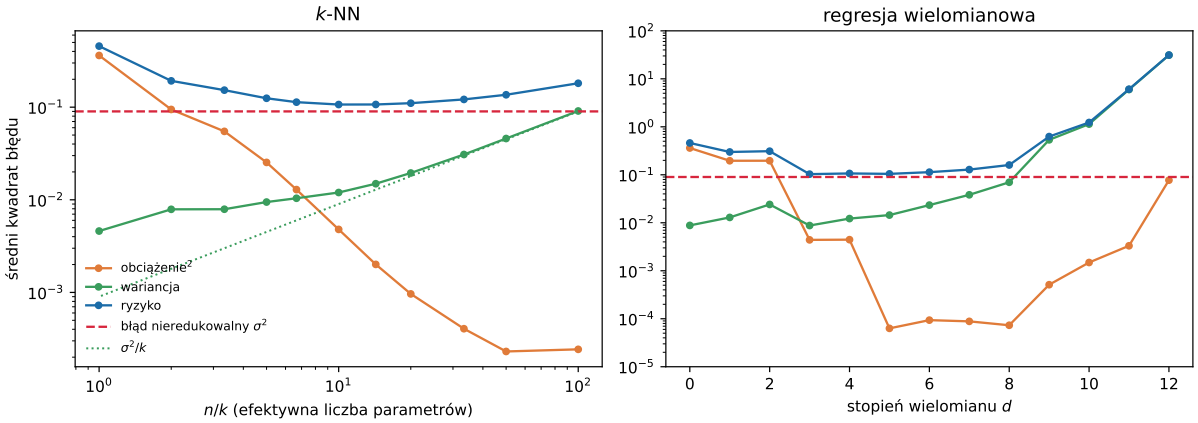
Dla metody k-NN oba składniki można wypisać jawnie, jeśli przyjmiemy uproszczenie: punkty $\mathbf{x}_1, \dots, \mathbf{x}_n$ są ustalone, a losowe są tylko wyniki $Y_i = f^*(\mathbf{x}_i) + \varepsilon_i$, z niezależnymi szumami o średniej zero i wariancji σ^2. Taki **ustalony układ** (ang. *fixed design*) upraszcza rachunki, bo zbiór sąsiadów $N_k(\mathbf{x}_0)$ zależy tylko od położenia punktów, a nie od wyników. Predykcja (3.1) jest wtedy średnią k niezależnych zmiennych losowych o wartościach oczekiwanych $f^*(\mathbf{x}_i)$ i wariancjach σ^2, więc

$$b(\mathbf{x}_0) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x}_0)} f^*(\mathbf{x}_i) - f^*(\mathbf{x}_0), \qquad v(\mathbf{x}_0) = \frac{\sigma^2}{k}. \tag{4.6}$$

Oba wzory odpowiadają dwóm źródłom błędu z rysunku 3.1. Wariancja maleje jak $1/k$: im więcej wyników uśredniamy, tym mniej znaczy szum każdego z nich. Obciążenie to różnica między średnią wartości f^* w otoczeniu a wartością w samym punkcie. Poszerzanie otoczenia

może zwiększać jego wartość bezwzględną, jeśli uśredniamy coraz bardziej różniące się wartości funkcji. Nie jest to jednak reguła monotoniczna: dla funkcji stałej obciążenie wynosi zero przy każdym k, a w innych przypadkach odchylenia mogą się znosić. Dla $k = 1$ wariancja wynosi σ^2. Jeśli najbliższy sąsiad ma też wartość funkcji regresji bliską $f^*(\mathbf{x}_0)$, obciążenie jest małe, a oczekiwany błąd predykcji jest bliski $2\sigma^2$: po jednym składniku szumu pochodzi z wyniku sąsiada i z nowej obserwacji. Dla $k = n$ wariancja maleje do σ^2/n, ale predyktor uśrednia wyniki ze wszystkich punktów i może słabo oddawać lokalny kształt funkcji.

Dla regresji wielomianowej takich prostych wzorów nie ma, ale oba składniki można oszacować symulacyjnie: wylosować wiele zbiorów uczących, w każdym punkcie siatki policzyć średnią i wariancję predykcji, a potem scałkować po rozkładzie X. Rysunek 4.3 pokazuje wynik dla obu metod. Przy k-NN cechy są losowe, jak na rysunku 3.5, a nie ustalone.



Rysunek 4.3.: Rozkład ryzyka na obciążenie do kwadratu, wariancję i błąd nieredukowalny. Po lewej: regresja k-NN w zależności od n/k ($n = 100$, 500 prób uczących); kropkowana linia to wariancja σ^2/k z ustalonego układu (4.6). Po prawej: regresja wielomianowa w zależności od stopnia d ($n = 50$, 1000 prób uczących, te same co na rysunku 4.1). Ryzyko jest sumą trzech składników. Dla wysokich stopni oszacowanie obciążenia jest niedokładne z powodu dużej wariancji predykcji. Oś pionowa w skali logarytmicznej.

W obu panelach widać typowy kompromis: wraz ze wzrostem elastyczności obciążenie na ogół maleje, a wariancja rośnie. Najmniejsze ryzyko otrzymujemy tam, gdzie suma kwadratu obciążenia i wariancji jest najmniejsza. Nie wymaga to ani równości obu składników, ani ich ścisłej monotoniczności. Metoda k-NN i regresja wielomianowa nie mają ze sobą nic wspólnego poza tym, że obie mają regulowaną elastyczność i uczą się ze skończonej próby. Kompromis obciążenie–wariancja nie jest więc własnością konkretnego algorytmu, tylko uczenia z ograniczonej liczby danych.

Przy k-NN wariancja jest bliska σ^2/k dla małych k, ale przy dużych k jest od niej wyraźnie większa: przy losowych cechach zmienia się od próby do próby także zbiór sąsiadów, a z nim średnia wartości f^* w otoczeniu, i ten składnik nie maleje jak $1/k$. Najmniejsze ryzyko przypada na k rzędu 7–10, gdzie obciążenie i wariancja są porównywalne.

Przy wielomianach obciążenie maleje schodkami. Przejście od prostej do stopnia 2 prawie go nie zmienia; tak samo przejście od stopnia 3 do 4 i od 5 do 6.[1] Wariancja przy każdym takim

[1] Schodki wynikają z symetrii przykładu. Po podstawieniu $t = x - \frac{1}{2}$ mamy $f^*(x) - \frac{1}{4} = \frac{t}{2} - \sin(2\pi t)$, czyli funkcję nieparzystą w t, a rozkład X jest symetryczny względem $\frac{1}{2}$. Najlepsze przybliżenie takiej funkcji wielomianem jest więc również nieparzyste, a człon t^{2m} nic do niego nie wnosi. Najlepszy wielomian stopnia $2m$ pokrywa się z najlepszym wielomianem stopnia $2m-1$. W innym przykładzie bezużyteczne mogą być inne współczynniki, ale zasada jest ta sama.

kroku jednak rośnie: od $d = 1$ do $d = 2$ z około 0,013 do 0,024, od $d = 3$ do $d = 4$ z 0,009 do 0,012. Dodatkowy współczynnik nie poprawił przybliżenia funkcji regresji, ale jego oszacowanie zmienia się od próby do próby i dokłada własny rozrzut. Dlatego stopień 4 ma większe ryzyko niż stopień 3, a stopień 6 – niż stopień 5. Odwrotnie przy przejściu od stopnia 2 do 3: wariancja spada, z 0,024 do 0,009. Przy losowych cechach model zbyt ubogi ma dodatkową zmienność, bo jego dopasowanie zależy od tego, gdzie w danej próbie wypadły punkty.

Wniosek sięga dalej niż ten przykład: **parametr, który nie zmniejsza obciążenia, nie jest neutralny, tylko zwiększa wariancję**. Większa elastyczność opłaca się wtedy, gdy zmniejsza obciążenie bardziej, niż zwiększa wariancję. Podobnie szkodziły cechy szumowe w metodzie k-NN (Rysunek 3.6), choć mechanizm był tam inny. Wrócimy do tego przy wyborze predyktorów w rozdziale 7.

Od stopnia 5 błąd aproksymacji jest praktycznie zerowy, więc każdy kolejny stopień dokłada już tylko wariancji. Powyżej stopnia 8 wariancja rośnie gwałtownie, bo dopasowania przy krańcach przedziału coraz częściej „uciekają” (Rysunek 4.2).

Krzywą obciążenia dla wysokich stopni trzeba czytać ostrożnie. Predyktor przeciętny szacujemy z tysiąca prób. Gdy pojedyncze predykcje mają dużą wariancję, ich średnia również jest niedokładna. Oszacowanie kwadratu obciążenia jest przez to zawyżone, przeciętnie o wariancję podzieloną przez liczbę powtórzeń. Sam wzrost tej krzywej nie dowodzi więc wzrostu rzeczywistego obciążenia metody.

> **i** Podwójne zejście
>
> Obraz z rysunku 4.3, w którym wariancja rośnie wraz z liczbą parametrów, nie jest prawem natury. Twierdzenie 4.1 jest tożsamością, a kompromis – tylko typowym zachowaniem metod. Belkin i in. (2019) opisali sytuację, w której to zachowanie się zmienia: **podwójne zejście** (ang. *double descent*). Gdy liczba parametrów przekracza liczbę obserwacji, model może dopasować dane dokładnie na nieskończenie wiele sposobów. W naszym przykładzie odpowiadałoby to wielomianom stopnia wyższego niż $n - 1 = 49$. Jeśli algorytm wybiera spośród tych dopasowań rozwiązanie w pewnym sensie najprostsze, na przykład o najmniejszej normie współczynników, ryzyko po przejściu przez maksimum w progu interpolacji może znów maleć. Rozkład na obciążenie i wariancję nadal obowiązuje. Zmienia się tylko to, jak wariancja zależy od liczby parametrów. Do tego zjawiska wrócimy przy sieciach neuronowych (rozdział 12), które często mają więcej parametrów niż obserwacji.

4.6. Błąd aproksymacji i błąd estymacji

W sekcji 1.6 zapowiedzieliśmy rozbicie błędu redukowalnego na część wynikającą ze zbyt ubogiej klasy modeli i część wynikającą ze skończoności próby. Rozkład na obciążenie i wariancję jest do tego bliski, ale nie identyczny. Obciążenie mierzymy względem predyktora przeciętnego $\bar{f}$, który zależy od liczności próby i od metody, a nie tylko od klasy. Zapowiedziany rozkład wygląda inaczej.

Niech metoda wybiera predyktor z ustalonej klasy $\mathcal{F}$. Załóżmy, że istnieje w niej predyktor o najmniejszym ryzyku, i niech

$$f_{\mathcal{F}} \in \arg\min_{f \in \mathcal{F}} R(f)$$

będzie najlepszym predyktorem w tej klasie, czyli tym, który wybralibyśmy, znając rozkład P. Dla dowolnego $\hat{f} \in \mathcal{F}$ zachodzi

$$R(\hat{f}) = \underbrace{R(f^*)}_{\text{błąd nieredukowalny}} + \underbrace{R(f_{\mathcal{F}}) - R(f^*)}_{\text{błąd aproksymacji}} + \underbrace{R(\hat{f}) - R(f_{\mathcal{F}})}_{\text{błąd estymacji}}. \tag{4.7}$$

Wzór otrzymaliśmy przez dodanie i odjęcie tego samego ryzyka. Jego składniki odpowiadają dwóm różnym ograniczeniom uczenia. **Błąd aproksymacji** mówi, ile tracimy, ograniczając się do klasy $\mathcal{F}$. Nie zależy od danych ani od n, tylko od klasy i od rozkładu. **Błąd estymacji** mówi, ile tracimy dlatego, że zamiast najlepszego elementu klasy wybraliśmy na podstawie skończonej próby inny. Jest losowy, bo zależy od $\mathcal{D}$, i z definicji $f_{\mathcal{F}}$ nieujemny. Poszerzenie klasy nie zwiększa błędu aproksymacji – minimum po większym zbiorze nie jest większe – ale zwykle zwiększa błąd estymacji, bo przy tej samej liczbie danych trudniej trafić w najlepszy element bogatszej klasy. Jest to ten sam kompromis w innym języku; bywa nazywany kompromisem aproksymacja–estymacja (Shalev-Shwartz i Ben-David 2014, rozdz. 5).

Rozkład (4.7) ma dwie zalety. Działa dla każdej straty, także dla straty 0–1, i nie wymaga uśredniania po zbiorach uczących. Ma też ograniczenie: wymaga ustalonej klasy $\mathcal{F}$. Metoda k-NN, jak zauważyliśmy w sekcji 3.2, niczego z ustalonej klasy nie wybiera, więc dla niej naturalny jest rozkład na obciążenie i wariancję.

Obciążenie nie jest jednak tym samym co błąd aproksymacji, a wariancja nie jest tym samym co błąd estymacji. Pierwszy rozkład pyta, gdzie leży przeciętny predyktor i jak bardzo zmieniają się dopasowania. Drugi pyta, jak dobra jest wybrana klasa i jak daleko jesteśmy od jej najlepszego elementu.

Gdy metoda wybiera predyktor z klasy takiej jak wielomiany stopnia co najwyżej d, oba rozkłady różnią się jednym składnikiem: średnim kwadratem odległości predyktora przeciętnego $\bar{f}$ od najlepszego elementu klasy $f_{\mathcal{F}}$,

$$\|\bar{f} - f_{\mathcal{F}}\|^2 = \mathbb{E}[(\bar{f}(\mathbf{X}) - f_{\mathcal{F}}(\mathbf{X}))^2].$$

Rozkład na obciążenie i wariancję zalicza go do obciążenia, rozkład na aproksymację i estymację – do błędu estymacji:

$$\text{obciążenie}^2 = \text{błąd aproksymacji} + \|\bar{f} - f_{\mathcal{F}}\|^2, \qquad \text{oczekiwany błąd estymacji} = \|\bar{f} - f_{\mathcal{F}}\|^2 + \text{wariancja}.$$

Dowód podajemy w rozszerzeniu 4.10.

Dla metody najmniejszych kwadratów ten składnik jest zwykle znikomy i maleje, gdy danych przybywa. W naszym przykładzie z wielomianami jest kilkadziesiąt do kilkuset razy mniejszy od wariancji. Wtedy obciążenie do kwadratu jest w praktyce równe błędowi aproksymacji, a wariancja – błędowi estymacji. Z tego przybliżenia skorzystamy, czytając krzywe uczenia.

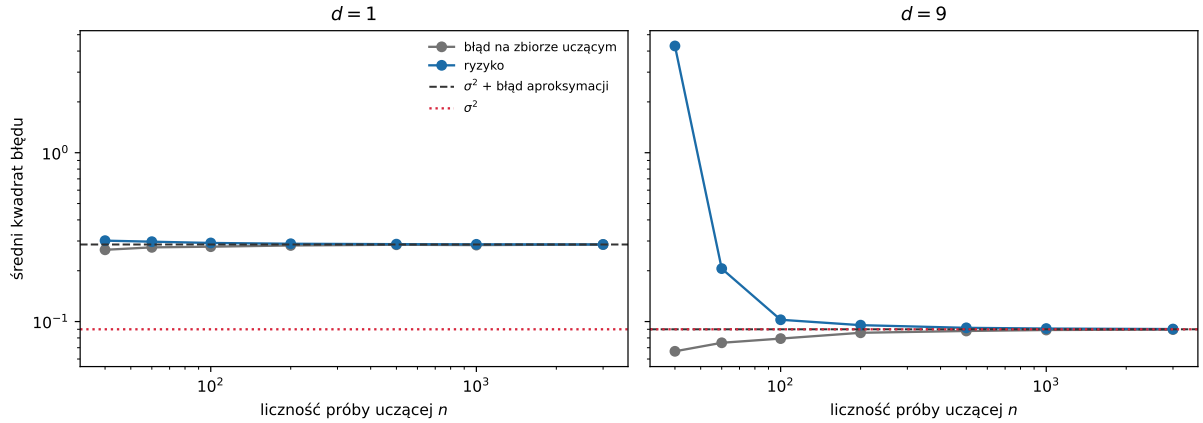
Inaczej jest w metodach, które celowo odsuwają predyktor od $f_{\mathcal{F}}$. Estymator ściągający $c\bar{Y}$ i regresja grzbietowa wybierają predyktor z tej samej klasy co zwykłe dopasowanie, więc nie zmieniają błędu aproksymacji. Mimo to mają obciążenie, i leży ono właśnie w składniku $\|\bar{f} - f_{\mathcal{F}}\|^2$. Dlatego przy regularyzacji trzeba mówić o obciążeniu, a nie o błędzie aproksymacji.

4.7. Krzywe uczenia

Dotąd zmienialiśmy elastyczność przy ustalonej liczności próby. Zmieńmy teraz liczność próby przy ustalonej metodzie. Wykres ryzyka i błędu uczącego w zależności od n nazywamy **krzywą uczenia** (ang. *learning curve*).

Dla ustalonej klasy modeli błąd aproksymacji nie zależy od n. Jeśli metoda wraz ze wzrostem próby coraz lepiej przybliża najlepszy element klasy, jej oczekiwany błąd estymacji maleje do zera. Ryzyko zbliża się wtedy do $R(f_{\mathcal{F}})$, czyli sumy błędu nieredukowalnego i błędu aproksymacji.

Ryzyko zbliża się do tej granicy od góry. Błąd uczący zachowuje się odwrotnie. Przy małej próbie jest niski, bo model łatwo dopasowuje się do niewielu punktów razem z ich szumem. Gdy danych przybywa, zwykle rośnie i zbliża się do tej samej granicy od dołu. Różnica między krzywymi, czyli optymizm błędu uczącego z sekcji 4.1, zmniejsza się więc z obu stron. Dla trafnego modelu liniowego z p cechami widać to dokładnie: oczekiwany błąd uczący wynosi $\sigma^2(1-(p+1)/n)$ i rośnie do σ^2 (rozdział 6). Nie oznacza to, że każda kolejna obserwacja musi poprawiać konkretny dopasowany model; porównujemy średnie po wielu próbach. Rysunek 4.4 pokazuje wynik dla prostej ($d=1$) i wielomianu stopnia 9.



Rysunek 4.4.: Krzywe uczenia regresji wielomianowej stopnia $d=1$ (po lewej) i $d=9$ (po prawej): błąd na zbiorze uczącym i ryzyko w zależności od liczności próby n. Punkty to średnie z 300 prób uczących. Linia przerywana: granica ryzyka przy $n\to\infty$, równa sumie błędu nieredukowalnego i błędu aproksymacji. Linia kropkowana: błąd nieredukowalny σ^2. Obie osie w skali logarytmicznej.

Dwa panele pokazują dwa typowe obrazy. Prosta szybko osiąga swoją granicę $\sigma^2+0{,}196\approx 0{,}286$, gdzie 0,196 to błąd aproksymacji, i dalsze dane już nic nie dają. Krzywe błędu uczącego i ryzyka są blisko siebie, a obie leżą wysoko nad σ^2. Tak wygląda model, którego ryzyko zdominowało obciążenie. Wielomian stopnia 9 przy małym n ma ogromne ryzyko i wielką szczelinę między ryzykiem a błędem uczącym. Tak wygląda model, którego ryzyko zdominowała wariancja. Z rosnącym n szczelina się zamyka, a obie krzywe zbiegają do granicy praktycznie równej σ^2, bo błąd aproksymacji wielomianu stopnia 9 jest znikomy.

Z porównania paneli wynika rzecz ważna dla praktyki: **najlepsza elastyczność zależy od liczności próby**. Przy $n=40$ prosta ma ryzyko ponad dziesięć razy mniejsze niż wielomian stopnia 9, a już przy $n=100$ – mniej więcej trzy razy większe. Nie ma modelu „właściwie złożonego” w oderwaniu od ilości danych.

Krzywe uczenia pomagają zdecydować, co zmienić w modelowaniu. Duża różnica między ryzykiem a błędem uczącym, malejąca przy większym n, sugeruje, że warto zebrać więcej danych lub sprawdzić prostszy model. Gdy obie krzywe się wypłaszczają i zbliżają do siebie, samo zwiększenie próby może już niewiele dać.

Płaskie krzywe nie mówią jednak, czy osiągnęliśmy granicę wynikającą z szumu, czy ogranicza nas klasa modeli. W symulacji znamy błąd nieredukowalny i możemy go zaznaczyć. W praktyce warto porównać klasy: jeśli bogatsza klasa daje niższy błąd na nowych danych, dotychczasowa

była zbyt uboga. Brak poprawy w kilku sprawdzonych klasach nie dowodzi jeszcze, że osiągnęliśmy najlepsze możliwe ryzyko. Warto wtedy rozważyć zmianę cech: błąd nieredukowalny odnosi się do ustalonego zestawu cech (sekcja 2.6), a nowa cecha niosąca informację o wyniku może go obniżyć.

Na wykresie z osią logarytmiczną odległość między krzywymi pokazuje stosunek błędów, a nie ich różnicę. Przy ocenie wielkości poprawy trzeba więc sprawdzić wartości liczbowe. W rzeczywistym problemie ryzyka nie znamy: zastępujemy je oceną na niezależnych danych. Sposoby uzyskania takiej oceny poznamy w rozdziale 5.

4.8. Co pomaga zmniejszyć błąd

Gdybyśmy znali rozkład P, wybralibyśmy po prostu funkcję regresji f^* z rozdziału 2 i nie byłoby czego równoważyć. Kompromis bierze się z uczenia ze skończonej próby w ograniczonej klasie modeli. Przy ustalonej liczności próby i ustalonej rodzinie modeli zmiana elastyczności pozwala tylko wybrać najlepszy punkt krzywej ryzyka. Zwykle wymienia przy tym obciążenie na wariancję, choć nie każda poprawa jednego składnika pogarsza drugi: przejście od stopnia 2 do 3 zmniejszyło oba. Aby zejść poniżej minimum tej krzywej, trzeba zmienić coś innego niż elastyczność. Warto rozróżnić dwa sposoby poprawy.

Pierwszy to **więcej danych**. Pozwalają one dokładniej dopasować model, a często także bezpiecznie zwiększyć jego elastyczność. W metodzie k-NN możemy wówczas uśredniać więcej wyników, a jednocześnie wybierać sąsiadów z mniejszego otoczenia. W ten sposób zmniejszamy wpływ szumu i błąd wynikający z uśredniania odległych wartości funkcji regresji.

Drugi to **trafne założenie o zależności**. Jeśli funkcja regresji jest liniowa, nie musimy szukać jej wśród wszystkich możliwych funkcji. Regresja liniowa z p cechami ma wtedy zerowy błąd aproksymacji, a jej wariancja, uśredniona po punktach zbioru uczącego, wynosi $\sigma^2(p+1)/n$ (rozdział 6). Maleje więc jak $1/n$, a wymiar wpływa tylko na stałą: aby zmniejszyć ją o połowę, wystarczy podwoić liczbę obserwacji, bez względu na p.

Metoda lokalna, która niczego o kształcie zależności nie zakłada, płaci za to wolniejszym uczeniem, tym wolniejszym, im więcej cech. Aby zmniejszyć otoczenie i zachować w nim dość obserwacji, trzeba zwiększać próbę znacznie szybciej niż w jednym wymiarze. To poznane już przekleństwo wymiarowości. Przybliżony rachunek w rozszerzeniu 4.11 pokazuje skalę: dla k-NN przy dziesięciu cechach zmniejszenie nadwyżki ryzyka o połowę wymaga mniej więcej sześćdziesięcioczterokrotnie większej próby.

Trafne założenie zastępuje więc dane. Nietrafne wprowadza błąd aproksymacji, którego żadna liczba danych nie usunie. Wybór między modelem o mocnych założeniach a metodą elastyczną jest wyborem między tymi dwoma ryzykami. Do tego wyboru będziemy wracać przy każdej kolejnej klasie modeli.

4.9. Obciążenie i wariancja w klasyfikacji

Przy stracie 0–1 rozkład tak prosty jak (4.4) nie istnieje. Zobaczmy dlaczego. Ograniczmy się do dwóch klas i reguły podstawienia $\hat{g}_{\mathcal{D}}(\mathbf{x}) = \mathbb{1}(\hat{\eta}_{\mathcal{D}}(\mathbf{x}) > \frac{1}{2})$, takiej jak klasyfikator k-NN.

Ustalmy punkt $\mathbf{x}$. Klasyfikator wskazujący w nim klasę 1 myli się z prawdopodobieństwem $1-\eta(\mathbf{x})$, wskazujący klasę 0 – z prawdopodobieństwem $\eta(\mathbf{x})$. Klasyfikator bayesowski wybiera

mniejszą z tych liczb. Jeśli $\hat{g}$ wskazuje w punkcie $\mathbf{x}$ inną klasę niż g^*, płaci więc nadwyżkę równą różnicy obu liczb, $|2\eta(\mathbf{x}) - 1|$. Uśredniając po $\mathbf{X}$, dostajemy

$$R(\hat{g}) - R(g^*) = \mathbb{E}\Big[\, |2\eta(\mathbf{X}) - 1| \, \mathbb{1}(\hat{g}(\mathbf{X}) \neq g^*(\mathbf{X}))\Big], \tag{4.8}$$

a po uśrednieniu po zbiorach uczących

$$\mathbb{E}_{\mathcal{D}}[R(\hat{g}_{\mathcal{D}})] - R(g^*) = \mathbb{E}\Big[\, |2\eta(\mathbf{X}) - 1| \, \mathbb{P}_{\mathcal{D}}(\hat{g}_{\mathcal{D}}(\mathbf{X}) \neq g^*(\mathbf{X}))\Big].$$

Przy $\eta(\mathbf{x}) = 0{,}7$ decyzja bayesowska to klasa 1 i jej ryzyko warunkowe wynosi 0,3. Wybór klasy 0 daje ryzyko 0,7, czyli o 0,4 większe. Zarówno oszacowanie 0,55, jak i 0,9 prowadzi do tej samej, optymalnej decyzji. Oszacowanie 0,45 prowadzi do decyzji przeciwnej. Dla straty 0–1 liczy się strona progu, a nie sama odległość oszacowania od prawdziwego prawdopodobieństwa.

Wynika stąd wniosek dotyczący obciążenia. Przypuśćmy, że oszacowania prawdopodobieństwa skupiają się wokół 0,9, choć prawdziwa wartość wynosi 0,7. Są wyraźnie obciążone, a mimo to prowadzą do decyzji bayesowskiej. Przy stracie 0–1 obciążenie oszacowania $\hat{\eta}$ nic nie kosztuje, dopóki nie przesunie go na drugą stronę progu. Model może więc źle szacować prawdopodobieństwa i mimo to dobrze klasyfikować. W ten sposób J. H. Friedman (1997) tłumaczy skuteczność prostych klasyfikatorów opartych na mocnych, często nietrafnych założeniach. Przykładem jest naiwny klasyfikator Bayesa z rozdziału 11: zakłada niezależność cech w obrębie klasy, więc jego oszacowania prawdopodobieństw bywają mocno obciążone, ale to samo założenie zmniejsza liczbę parametrów, a z nią wariancję.

Wariancja działa tu inaczej niż w regresji. Mała wariancja pomaga, gdy oszacowania skupiają się po właściwej stronie progu. Jeżeli skupiają się po złej stronie, stabilność tylko utrwala złą decyzję. Nie możemy więc przenieść do klasyfikacji prostej reguły „mniejsza wariancja to mniejszy błąd".

Tolerancja na obciążenie ma jednak granicę: dotyczy decyzji przy ustalonym progu 1/2. Dobra klasyfikacja przy tym progu nie gwarantuje dobrych oszacowań prawdopodobieństw. Po zmianie kosztów błędów zmienia się próg decyzji, a oszacowania, które wystarczały przy progu 1/2, mogą prowadzić do gorszych wyborów. Dotyczy to także reguł z opcją odmowy z sekcji 2.8. Przy takich decyzjach obciążenie oszacowań znów kosztuje.

i Rozszerzenie: normalne przybliżenie oszacowań

Wymagana jest dystrybuanta standardowego rozkładu normalnego Φ. Poniższy rachunek jest ilustracją lokalną: rozkład normalny może jedynie przybliżać oszacowanie prawdopodobieństwa ograniczone do $[0, 1]$.
Niech na przykład $\eta(\mathbf{x}) > \frac{1}{2}$ i niech $\hat{\eta}_{\mathcal{D}}(\mathbf{x})$ ma w przybliżeniu rozkład normalny o średniej $\bar{\eta}(\mathbf{x})$ i odchyleniu standardowym $s(\mathbf{x})$. Wtedy

$$\mathbb{P}_{\mathcal{D}}(\hat{g}_{\mathcal{D}}(\mathbf{x}) \neq g^*(\mathbf{x})) \approx \Phi\Big(\frac{\frac{1}{2} - \bar{\eta}(\mathbf{x})}{s(\mathbf{x})}\Big). \tag{4.9}$$

Obciążenie i wariancja nie dodają się tu, tylko oddziałują (J. H. Friedman 1997). Jeśli przeciętne oszacowanie leży po właściwej stronie progu ($\bar{\eta}(\mathbf{x}) > \frac{1}{2}$), licznik jest ujemny i wzrost wariancji zwiększa prawdopodobieństwo błędu. Samo obciążenie nie określa więc jakości decyzji: znaczenie ma położenie całego rozkładu oszacowań względem progu. Jeśli przeciętne oszacowanie leży po złej stronie, licznik jest dodatni i wzrost wariancji prawdopodobieństwo błędu **zmniejsza**, bo częściej wyrzuca $\hat{\eta}$ na właściwą stronę (Zadanie 4.10).

4.10. Rozszerzenie: porównanie dwóch rozkładów błędu

Materiał nieobowiązkowy

Wymagane są przestrzenie liniowe funkcji, iloczyn skalarny i rzut ortogonalny. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

Gdy oba rozkłady mają sens, są ze sobą ściśle związane. Oznaczmy $\|g\|^2 = \mathbb{E}[g(\mathbf{X})^2]$, gdzie średnią liczymy po rozkładzie cech. Z (2.8) przy stracie kwadratowej $R(f) - R(f^*) = \|f - f^*\|^2$, więc $f_{\mathcal{F}}$ jest elementem $\mathcal{F}$ najbliższym f^* w tej normie.

Twierdzenie 4.2 (Obciążenie a błąd aproksymacji)**.** *Niech strata będzie kwadratowa, a $\mathcal{F}$ – skończenie wymiarową przestrzenią liniową funkcji, taką jak $\mathcal{F}_d$. Niech $\hat{f}_{\mathcal{D}} \in \mathcal{F}$ dla każdego zbioru uczącego, a wszystkie występujące niżej średnie niech będą skończone. Wtedy*

$$\underbrace{\mathbb{E}[b(\mathbf{X})^2]}_{\text{obciążenie}^2} = \underbrace{\|f_{\mathcal{F}} - f^*\|^2}_{\text{błąd aproksymacji}} + \|\bar{f} - f_{\mathcal{F}}\|^2, \tag{4.10}$$

$$\underbrace{\mathbb{E}_{\mathcal{D}}[R(\hat{f}_{\mathcal{D}}) - R(f_{\mathcal{F}})]}_{\text{oczekiwany błąd estymacji}} = \|\bar{f} - f_{\mathcal{F}}\|^2 + \underbrace{\mathbb{E}[v(\mathbf{X})]}_{\text{wariancja}}. \tag{4.11}$$

Dowód. Norma $\|\cdot\|$ pochodzi od iloczynu skalarnego $\langle g, h\rangle = \mathbb{E}[g(\mathbf{X})h(\mathbf{X})]$, a $f_{\mathcal{F}}$ jest rzutem ortogonalnym f^* na podprzestrzeń $\mathcal{F}$. Różnica $f^* - f_{\mathcal{F}}$ jest więc ortogonalna do każdego elementu $\mathcal{F}$: gdyby $\langle f^* - f_{\mathcal{F}}, g\rangle \neq 0$ dla pewnego $g \in \mathcal{F}$, przesunięcie $f_{\mathcal{F}}$ o mały krok w kierunku g zmniejszyłoby odległość od f^*.

Predyktor przeciętny należy do $\mathcal{F}$: jeśli $\hat{f}_{\mathcal{D}} = \sum_j \hat{\beta}_j \varphi_j$ w pewnej bazie $\varphi_1, \ldots, \varphi_m$ przestrzeni $\mathcal{F}$, to $\bar{f} = \sum_j \mathbb{E}_{\mathcal{D}}[\hat{\beta}_j]\, \varphi_j$. Zatem $\bar{f} - f_{\mathcal{F}} \in \mathcal{F}$ jest ortogonalne do $f_{\mathcal{F}} - f^*$ i z twierdzenia Pitagorasa

$$\mathbb{E}[b(\mathbf{X})^2] = \|\bar{f} - f^*\|^2 = \|f_{\mathcal{F}} - f^*\|^2 + \|\bar{f} - f_{\mathcal{F}}\|^2.$$

Tak samo $\hat{f}_{\mathcal{D}} - f_{\mathcal{F}} \in \mathcal{F}$, więc $R(\hat{f}_{\mathcal{D}}) - R(f_{\mathcal{F}}) = \|\hat{f}_{\mathcal{D}} - f^*\|^2 - \|f_{\mathcal{F}} - f^*\|^2 = \|\hat{f}_{\mathcal{D}} - f_{\mathcal{F}}\|^2$. Uśredniając po $\mathcal{D}$ i rozkładając $\hat{f}_{\mathcal{D}} - f_{\mathcal{F}} = (\hat{f}_{\mathcal{D}} - \bar{f}) + (\bar{f} - f_{\mathcal{F}})$ tak jak w (4.2), dostajemy (4.11), bo $\mathbb{E}_{\mathcal{D}}[\|\hat{f}_{\mathcal{D}} - \bar{f}\|^2] = \mathbb{E}[v(\mathbf{X})]$. □ □

Twierdzenie uzasadnia dwie równości podane w sekcji 4.6. Poniższe zestawienie sprawdza je dla wielomianów z rysunku 4.3. Najlepszy wielomian $f_{\mathcal{F}_d}$ wyznaczyliśmy, dopasowując wielomian metodą najmniejszych kwadratów do samej funkcji f^* na gęstej siatce.

d	aproksymacja	obciążenie^2	||f_bar - f_F||^2	wariancja
0	0.36168	0.36168	0.00000	0.00882
1	0.19604	0.19610	0.00006	0.01293
2	0.19604	0.19641	0.00038	0.02410
3	0.00439	0.00440	0.00001	0.00876
4	0.00439	0.00445	0.00006	0.01223
5	0.00002	0.00006	0.00004	0.01447
6	0.00002	0.00009	0.00008	0.02336
7	0.00000	0.00009	0.00009	0.03827
8	0.00000	0.00007	0.00007	0.06986

Kolumny „aproksymacja” i „obciążenie^2” zgadzają się do trzeciego miejsca po przecinku, a składnik $\|\bar{f} - f_{\mathcal{F}}\|^2$ jest kilkadziesiąt do kilkuset razy mniejszy od wariancji. Część tej różnicy to zresztą błąd symulacji, bo $\bar{f}$ szacujemy z tysiąca prób.

4.11. Rozszerzenie: tempo uczenia w wielu wymiarach

Materiał nieobowiązkowy

Wymagane są różniczkowanie i porównywanie rzędów wielkości. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

Jak kosztowne bywa uczenie przy słabych założeniach, pokazuje prosty rachunek dla metody k-NN. Niech cechy mają rozkład jednostajny w kostce $[0,1]^p$, szum ma wariancję σ^2, a funkcja regresji spełnia warunek Lipschitza $|f^*(\mathbf{x}) - f^*(\mathbf{x}')| \le L \max_j |x_j - x'_j|$, czyli nie zmienia się zbyt szybko. Rachunek jest przybliżony, ale jego wynik daje się uściślić (Györfi i in. 2002).

Z (3.5) otoczenie zawierające k z n punktów jest w przybliżeniu obszarem o objętości k/n. Dla punktu we wnętrzu $[0,1]^p$ zastąpmy ten obszar kostką o boku $(k/n)^{1/p}$, wyśrodkowaną w $\mathbf{x}$. Sąsiedzi leżą wtedy w odległości (w metryce maksimum) około połowy jej boku lub mniejszej, a wartości f^* różnią się od $f^*(\mathbf{x})$ najwyżej o L razy tyle. Z (4.6)

$$b(\mathbf{x})^2 + v(\mathbf{x}) \;\lesssim\; \frac{L^2}{4}\Big(\frac{k}{n}\Big)^{2/p} + \frac{\sigma^2}{k}. \tag{4.12}$$

Pierwszy składnik rośnie z k, drugi maleje. Minimalizując prawą stronę względem k, otrzymujemy optymalną liczbę sąsiadów rzędu $k^* \sim n^{2/(p+2)}$ i nadwyżkę ryzyka nad σ^2 rzędu

$$n^{-2/(p+2)}$$

(Zadanie 4.9). Optymalne k^* rośnie z n, ale wolniej niż n, dokładnie tak, jak wymagają założenia twierdzenia 3.1.

Wykładnik $2/(p+2)$ maleje z wymiarem. Dla $p = 1$ nadwyżka ryzyka maleje jak $n^{-2/3}$, dla $p = 10$ – jak $n^{-1/6}$. Aby zmniejszyć ją o połowę, trzeba pomnożyć liczbę obserwacji przez $2^{(p+2)/2}$: niecałe trzy razy dla $p = 1$, cztery razy dla $p = 2$, 64 razy dla $p = 10$, ponad 2000 razy dla $p = 20$. Jest to przekleństwo wymiarowości z sekcji 3.5 w języku tego rozdziału: w wielu wymiarach otoczenia muszą być szerokie, żeby zawierały dość punktów, a szerokie otoczenia oznaczają duże obciążenie. Nie jest to uniwersalne tempo dla każdej funkcji z osobna. Opisuje ono trudność uczenia w najgorszym przypadku w rozważanej klasie. Przy standardowych założeniach tego modelu nie można zagwarantować szybszego tempa jednostajnie w całej klasie funkcji o ustalonej stałej Lipschitza (C. J. Stone 1982). Ceną są słabe założenia o funkcji, a nie słabość metody k-NN. Model liniowy, jeśli jest trafny, osiąga tempo $1/n$ niezależnie od p, ze stałą proporcjonalną do $p + 1$ – stąd przewaga, o której pisaliśmy pod koniec sekcji 3.5.

Uwagi bibliograficzne

Kompromis obciążenie–wariancja w ujęciu bliskim temu rozdziałowi przedstawiają James i in. (2023, rozdz. 2.2) oraz Hastie i in. (2009, rozdz. 2.9 i 7.3). Druga z tych książek omawia też optymizm błędu uczącego (Hastie i in. 2009, rozdz. 7.4), różnicę między ryzykiem dopasowanego modelu a ryzykiem oczekiwanym metody (Hastie i in. 2009, rozdz. 7.2) oraz przykład, w którym przy stracie 0–1 składniki nie sumują się (Hastie i in. 2009, rozdz. 7.3). Bishop (2006, rozdz. 3.2) wyprowadza rozkład dla regresji z funkcjami bazowymi i podkreśla jego ograniczoną wartość praktyczną: wymaga uśredniania po wielu zbiorach uczących, podczas gdy w praktyce mamy jeden.

Nazwę „dylemat obciążenie–wariancja” rozpowszechnili Geman i in. (1992), którzy pokazali, że ten sam kompromis rządzi estymatorami jądrowymi, metodą najbliższych sąsiadów i sieciami

neuronowymi. Rozkład na błąd aproksymacji i błąd estymacji, centralny w teorii uczenia, wykładają Shalev-Shwartz i Ben-David (2014, rozdz. 5). Ścisłą analizę tempa zbieżności nieparametrycznych estymatorów regresji, w tym metody k-NN, zawiera Györfi i in. (2002). Optymalność tempa $n^{-2/(p+2)}$ dla funkcji Lipschitza, w ogólniejszej postaci dla klas funkcji gładkich, udowodnił C. J. Stone (1982).

Oddziaływanie obciążenia i wariancji przy stracie 0–1 i jego związek z przekleństwem wymiarowości analizuje J. H. Friedman (1997). Zjawisko podwójnego zejścia i jego miejsce względem klasycznego kompromisu opisują Belkin i in. (2019).

Zadania

Pierwsze zadania to rachunki na małych przykładach: obciążenie, wariancja i rozkład błędu. Dalej pojawiają się symulacje dla k-NN i wielomianów oraz krzywe uczenia. Zadania oznaczone **Rozszerzenie** można pominąć przy pierwszej lekturze; wskazujemy w nich dodatkowe potrzebne narzędzia.

Zadanie 4.1. Na początek w przykładzie metod A i B zastąp prognozy metody A wartościami $8, 9, 10$, nadal jednakowo prawdopodobnymi. Oblicz obciążenie, wariancję i średni kwadrat odległości od prawdziwej wartości 10. Czy porównanie z metodą B się zmieniło?

Następnie zbadaj ogólniejszy sposób zmniejszania wariancji. Niech $Y_1, \dots, Y_n$ będzie próbą z rozkładu o średniej $\mu \neq 0$ i wariancji $\sigma^2 > 0$, a $\hat{\mu}_c = c\bar{Y}$ dla $c \in \mathbb{R}$.

a) Wyznacz obciążenie, wariancję i błąd średniokwadratowy $\hat{\mu}_c$.
b) Wykaż, że błąd średniokwadratowy jest najmniejszy dla $c^* = \mu^2/(\mu^2 + \sigma^2/n)$, i wyznacz jego wartość w minimum. Dla $\mu = 1$, $\sigma = 3$ i $n = 10$ porównaj wynik ze średnią $\bar{Y}$. Wyznacz też wszystkie $h = 1 - c \in (0, 1]$, dla których $c\bar{Y}$ ma mniejszy błąd niż $\bar{Y}$, i porównaj ten zakres dla $\mu = 1$ oraz $\mu = 10$ przy $\sigma = 3$ i $n = 10$.
c) Wyraź c^* przez stosunek sygnału do szumu $\mu^2/(\sigma^2/n)$. Kiedy ściąganie daje duży zysk, a kiedy prawie żaden?
d) Dlaczego $\hat{\mu}_{c^*}$ nie jest estymatorem, którego można użyć w praktyce? Co by się stało, gdyby w miejsce μ podstawić $\bar{Y}$?

Zadanie 4.2.

a) Wskaż miejsce w dowodzie twierdzenia 4.1, w którym korzystamy z niezależności Y_0 od zbioru uczącego. Rozważ regułę jednego najbliższego sąsiada i „nową” obserwację, która jest w istocie jedną z obserwacji uczących: $\mathbf{x}_0 = \mathbf{x}_i$, $Y_0 = y_i$. Ile wynosi wtedy lewa strona (4.4), a ile prawa? Skąd bierze się różnica?
b) Wyprowadź (4.5) z (4.4). Jakiego założenia o $\mathbf{X}_0$ potrzebujesz?
c) Szumy mają stałą wariancję σ^2, a punkty uczące są ustalone i parami różne. Wyznacz obciążenie, wariancję i oczekiwany błąd predykcji w punkcie $\mathbf{x}_0$ pokrywającym się z jednym z punktów uczących dla dwóch skrajnych predyktorów: stałego $\hat{f} \equiv 0$ oraz reguły jednego najbliższego sąsiada. Kiedy predyktor stały jest lepszy?

Zadanie 4.3. Punkty uczące leżą na siatce $x_i = i/n$, $i = 1, \dots, n$, a $Y_i = f^*(x_i) + \varepsilon_i$ z niezależnymi szumami o średniej zero i wariancji σ^2. Rozważ regresję k-NN z $k = 2m + 1$ w punkcie $x_0 = x_j$ leżącym na tyle daleko od krańców, by sąsiedzi leżeli symetrycznie.

a) Wykaż, że dla $f^*(x) = ax + c$ obciążenie w x_0 jest zerowe. Co się zmienia, gdy $x_0 = x_1$ leży na krańcu przedziału?

b) Wykaż, że dla $f^*(x) = x^2$ obciążenie wynosi $m(m+1)/(3n^2)$. (Wskazówka: $\sum_{j=-m}^{m} j^2 = m(m+1)(2m+1)/3$.)
c) Dla $n = 100$ i $\sigma = 0{,}1$ wyznacz numerycznie m minimalizujące oczekiwany błąd predykcji w x_0 dla $f^*(x) = x^2$. Jak zmienia się wynik, gdy $f^*(x) = 10x^2$? Wyjaśnij kierunek zmiany.

Zadanie 4.4. W sytuacji z zadania 4.3 (ustalone, parami różne punkty x_i) niech Y_i' będzie nową, niezależną obserwacją wyniku w punkcie x_i, o tym samym rozkładzie co Y_i. Wykaż, że dla regresji k-NN

$$\mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^{n}(Y_i' - \hat{f}(x_i))^2\Big] - \mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^{n}(Y_i - \hat{f}(x_i))^2\Big] = \frac{2\sigma^2}{k}.$$

(Wskazówka: każdy punkt x_i należy do swojego własnego otoczenia; rozpisz $\operatorname{Cov}(Y_i, \hat{f}(x_i))$.) Sprawdź wynik dla $k = 1$ (por. Zadanie 1.6). Co ten wzór mówi o błędzie uczącym jako ocenie ryzyka przy małym k?

Zadanie 4.5. Rozszerzenie: błąd aproksymacji. Wymagane są całkowanie i porównanie rozkładów błędu z sekcji 4.10.

Rozważ klasę funkcji stałych $\mathcal{F}_0$ i rozkład z tego rozdziału: X jednostajny na $[0,1]$, $f^*(x) = \sin(2\pi x) + x/2$, szum o wariancji σ^2. Predyktorem jest średnia $\bar{Y}$ z próby.

a) Wyznacz $f_{\mathcal{F}_0}$ i błąd aproksymacji. Wykaż, że ten drugi jest równy $\operatorname{Var} f^*(X) = \frac{1}{2} + \frac{1}{48} - \frac{1}{2\pi} \approx 0{,}362$.
b) Wyznacz $\bar{f}$ i oczekiwany błąd estymacji. Wykaż, że składnik $\|\bar{f} - f_{\mathcal{F}_0}\|^2$ z twierdzenia 4.2 jest tu równy zeru.
c) Wyznacz obciążenie $b(x)$ w punkcie. Jest ono duże w niektórych punktach, choć $\bar{f} = f_{\mathcal{F}_0}$. Jak to pogodzić z twierdzeniem 4.2?
d) Porównaj wyniki z pierwszymi wierszami zestawienia w sekcji 4.10 dla $n = 50$ i $\sigma = 0{,}3$.

Zadanie 4.6. Rozwiń symulację z zadania 1.14. Dla $n = 30$ i stopni $d = 1, \ldots, 10$:

a) wylosuj 500 zbiorów uczących i w punktach $x_0 = 0{,}5$ oraz $x_0 = 0{,}95$ oszacuj obciążenie, wariancję i oczekiwany błąd predykcji $\mathbb{E}[(Y_0 - \hat{f}(x_0))^2]$, losując Y_0 niezależnie;
b) sprawdź, że suma obciążenia do kwadratu, wariancji i σ^2 zgadza się z oczekiwanym błędem predykcji z dokładnością do błędu symulacji;
c) porównaj optymalne stopnie w obu punktach i wyjaśnij różnicę, odwołując się do rysunku 4.2.

Zadanie 4.7. Narysuj krzywe uczenia regresji k-NN dla rozkładu z tego rozdziału, dla n od 20 do 5000, w dwóch wariantach: ze stałym $k = 5$ i z $k = \lceil \sqrt{n} \rceil$.

a) Do jakiej granicy dąży ryzyko w każdym wariancie? (Wskazówka: dla stałego k obciążenie znika przy $n \to \infty$, a wariancja nie.)
b) Który składnik ryzyka odpowiada za to, że przy dodatniej wariancji szumu reguła ze stałym k nie zbliża się do ryzyka optymalnego? Wyjaśnij, dlaczego samo przybliżanie sąsiadów do punktu predykcji nie wystarcza.
c) Jak zachowuje się szczelina między ryzykiem a błędem uczącym w obu wariantach?

Zadanie 4.8. Mamy B predyktorów $\hat{f}_1, \ldots, \hat{f}_B$ o tym samym rozkładzie, z których każdy w punkcie $\mathbf{x}_0$ ma obciążenie b i wariancję v. Rozważ ich średnią $\hat{f}_{\text{sr}} = \frac{1}{B}\sum_{j=1}^{B} \hat{f}_j$.

a) Wyznacz obciążenie i wariancję $\hat{f}_{\text{sr}}(\mathbf{x}_0)$, gdy predyktory wyznaczono z niezależnych zbiorów uczących.
b) Powtórz rachunek przy założeniu, że każde dwa predyktory mają w punkcie $\mathbf{x}_0$ współczynnik korelacji $\rho > 0$. Wykaż, że wariancja średniej wynosi $\rho v + (1-\rho)v/B$ i nie spada poniżej ρv niezależnie od B.
c) W praktyce mamy jeden zbiór uczący. Predyktory można wyznaczyć z próbek losowanych z niego ze zwracaniem (metoda bootstrap, rozdział 5). Dlaczego będą one skorelowane? Dla której z metod tego rozdziału, wielomianów niskiego czy wysokiego stopnia, spodziewasz się większego zysku z uśredniania?

Zadanie 4.9. Rozszerzenie: tempo uczenia. Wymagane są różniczkowanie i rachunek z sekcji 4.11.

a) Wyznacz k minimalizujące prawą stronę (4.12), traktując k jako zmienną ciągłą. Wykaż, że k^* jest rzędu $n^{2/(p+2)}$, a oba składniki w optimum – rzędu $n^{-2/(p+2)}$.
b) Wykaż, że $k^* \to \infty$ i $k^*/n \to 0$ przy $n \to \infty$. Porównaj z założeniami twierdzenia 3.1.
c) O ile trzeba zwiększyć n, aby nadwyżka ryzyka spadła o połowę? Podaj wynik dla $p = 1, 2, 5, 10, 20$.
d) Zastąp warunek Lipschitza warunkiem $|f^*(\mathbf{x}) - f^*(\mathbf{x}')| \le L$ dla wszystkich $\mathbf{x}, \mathbf{x}'$ (funkcja ograniczona, ale dowolnie nieregularna). Co rachunek mówi wtedy o tempie? Odnieś wynik do uwagi „Zbieżność nie znaczy »szybko«" z rozdziału 3.

Zadanie 4.10. Rozszerzenie: obciążenie w klasyfikacji. Wykorzystaj normalne przybliżenie z sekcji 4.9 i dystrybuantę rozkładu normalnego.

W punkcie $\mathbf{x}$ prawdziwe prawdopodobieństwo klasy 1 wynosi $\eta(\mathbf{x}) = 0{,}7$, a oszacowanie $\hat{\eta}_{\mathcal{D}}(\mathbf{x})$ ma w przybliżeniu rozkład normalny o średniej $\bar{\eta}$ i odchyleniu standardowym s. Granicę dla $s \to \infty$ traktuj wyłącznie jako własność tego przybliżenia, nie oszacowania ograniczonego do $[0, 1]$.

a) Dla $\bar{\eta} \in \{0{,}65;\ 0{,}55;\ 0{,}45\}$ i $s \in \{0{,}05;\ 0{,}1;\ 0{,}2\}$ oblicz prawdopodobieństwo, że klasyfikator $\mathbb{1}(\hat{\eta} > \frac{1}{2})$ wskaże w $\mathbf{x}$ inną klasę niż klasyfikator bayesowski, oraz błąd średniokwadratowy $\mathbb{E}\big[(\hat{\eta} - \eta)^2\big]$.
b) Wskaż pary oszacowań, w których mniejszy błąd średniokwadratowy idzie w parze z większym prawdopodobieństwem złej klasyfikacji.
c) Dla $\bar{\eta} = 0{,}45$ wyznacz granicę prawdopodobieństwa błędnej decyzji przy $s \to \infty$ i przy $s \to 0$. Zinterpretuj wynik.
d) Sprawdź symulacyjnie, że opisane zjawisko występuje dla klasyfikatora k-NN, wybierając punkt, w którym przy dużym k oszacowanie $\bar{\eta}$ przechodzi na złą stronę progu.

5. Ocena modeli w praktyce

Mamy jedną próbę pomiarów i chcemy rozpoznawać klasę nowych obiektów klasyfikatorem k-NN. Rozważamy $k = 3, 9, 21$. Którą wartość wybrać i jaki odsetek pomyłek podać jako ocenę wybranego klasyfikatora? To dwa różne pytania: dane, które pomogły dokonać wyboru, nie są już niezależnym sprawdzianem jego wyniku.

W rozdziale 4 znaliśmy rozkład danych i mogliśmy obliczyć ryzyko. Teraz nauczymy się je szacować z jednej próby. Przejdziemy od oceny ustalonego modelu przez wybór ustawień do oceny całej procedury. Przykład k-NN domkniemy na danych o nowotworach piersi. Osobne eksperymenty z wielomianami pozwolą sprawdzić jakość oszacowań, bo znamy w nich rozkład i możemy numerycznie obliczać ryzyko.

5.1. Dopasowanie, wybór i ocena

Praca z danymi obejmuje trzy czynności.

1. **Dopasowanie.** Dla ustalonego k tworzymy predyktor z danych uczących. W k-NN oznacza to zapamiętanie pomiarów i klas oraz ustalenie przygotowania cech, na przykład parametrów standaryzacji.
2. **Wybór.** Porównujemy kandydatów dla $k = 3, 9, 21$ na danych, których nie użyliśmy do ich dopasowania, i wybieramy k.
3. **Ocena.** Sprawdzamy wybrany model na obserwacjach, które nie uczestniczyły ani w dopasowaniu, ani w wyborze.

Wybór i ocena stawiają oszacowaniu ryzyka różne wymagania. Do wyboru wystarczy uporządkować kandydatów: jeśli oszacowanie zawyża ryzyko o podobną wielkość u wszystkich, na przykład dlatego, że każdego uczymy na części danych, kolejność się nie zmienia i liczy się tylko dokładność oszacowania różnic ryzyk. Przy ocenie potrzebna jest wartość ryzyka, więc takie przesunięcie jest błędem.

Dlaczego nie wystarczy błąd uczący? Jak widzieliśmy w sekcji 4.1, model korzysta z wyników tych samych obserwacji, na których mierzymy jego skuteczność. Błąd uczący bywa przez to zaniżony, szczególnie przy elastycznych metodach. Dla 1-NN bez powtarzających się punktów wynosi zero, choć nowe obiekty nadal możemy klasyfikować błędnie. Nie daje więc uczciwej podstawy do wyboru k ani oceny przyszłych pomyłek.

Rozróżnijmy też **model** i **metodę**. Możemy pytać o ryzyko jednego, już dopasowanego predyktora albo o to, jak metoda uczenia sprawdzałaby się przeciętnie, gdybyśmy zbierali nowe próby i za każdym razem uczyli ją od początku. Zbiór testowy pozwala odpowiedzieć na pierwsze pytanie. Przy walidacji krzyżowej wrócimy do drugiego.

5.2. Zbiór testowy

Ustalony klasyfikator pomylił się 10 razy na 100 nowych obserwacjach. Oszacowanie ryzyka wynosi $10/100 = 0{,}10$, czyli 10%. Inna setka może dać inny wynik, mimo że model pozostanie ten sam. W regresji liczymy analogicznie średnią strat kwadratowych: jeśli przewidujemy sprzedaż w złotych, taki wynik ma jednostkę zł^2. Pierwiastek z niego (RMSE) ma jednostkę złotych.

Uogólnijmy ten rachunek. Predyktor $\hat{f}$ jest już ustalony: dopasowaliśmy go do zbioru uczącego $\mathcal{D}$ i więcej go nie zmieniamy. Mamy też **zbiór testowy** – m nowych obserwacji $(\mathbf{X}'_1, Y'_1), \ldots, (\mathbf{X}'_m, Y'_m)$, niezależnych od siebie i od $\mathcal{D}$, z tego samego rozkładu P. Ryzyko szacujemy średnią stratą na zbiorze testowym:

$$\widehat{R}_{\text{test}} = \frac{1}{m} \sum_{j=1}^{m} L(Y'_j, \hat{f}(\mathbf{X}'_j)). \tag{5.1}$$

Jest to ryzyko empiryczne (1.9), tyle że liczone na danych, których predyktor nie widział. W rozdziale 1 zauważyliśmy, że dla predyktora ustalonego niezależnie od danych taka średnia jest nieobciążonym oszacowaniem ryzyka. Teraz możemy to powiedzieć dokładniej.

Zwrot **„przy ustalonym zbiorze uczącym"** oznacza, że nie uczymy modelu ponownie. Wyobrażamy sobie tylko losowanie kolejnych zbiorów testowych dla tego samego predyktora. Taki sens ma warunkowanie względem $\mathcal{D}$ w poniższym twierdzeniu.

Twierdzenie 5.1 (Własności oszacowania testowego)**.** *Niech zbiór testowy będzie niezależny od $\mathcal{D}$, a jego obserwacje niezależne i o rozkładzie P. Oznaczmy $\tau^2 = \operatorname{Var}\left(L(Y, \hat{f}(\mathbf{X})) \,\middle|\, \mathcal{D}\right)$ skończoną wariancję straty na nowej obserwacji przy ustalonym predyktorze. Wtedy*

$$\mathbb{E}\left[\widehat{R}_{\text{test}} \,\middle|\, \mathcal{D}\right] = R(\hat{f}), \qquad \operatorname{Var}\left(\widehat{R}_{\text{test}} \,\middle|\, \mathcal{D}\right) = \frac{\tau^2}{m}.$$

Przy stracie 0–1 liczba błędów $m\widehat{R}_{\text{test}}$ ma, przy ustalonym $\mathcal{D}$, rozkład dwumianowy z parametrami m i $R(\hat{f})$, a $\tau^2 = R(\hat{f})(1 - R(\hat{f}))$.

Dowód. Przy ustalonym $\mathcal{D}$ predyktor $\hat{f}$ jest ustaloną funkcją, a straty $L_j = L(Y'_j, \hat{f}(\mathbf{X}'_j))$ są niezależnymi zmiennymi losowymi o tym samym rozkładzie, ze średnią $R(\hat{f})$ i wariancją τ^2. Średnia m takich zmiennych ma tę samą wartość oczekiwaną i wariancję τ^2/m. Przy stracie 0–1 każda strata L_j jest zmienną zero-jedynkową z prawdopodobieństwem sukcesu $R(\hat{f})$, więc ich suma ma rozkład dwumianowy. Ponieważ $L_j^2 = L_j$, wariancja pojedynczej straty wynosi $\mathbb{E}L_j - (\mathbb{E}L_j)^2 = R(\hat{f})(1 - R(\hat{f}))$. □ □

Założenie niezależności od $\mathcal{D}$ jest tu wszystkim. Gdyby obserwacje testowe trafiły choć częściowo do zbioru uczącego, straty L_j nie miałyby średniej $R(\hat{f})$ – mielibyśmy z powrotem optymizm błędu uczącego. Zwróćmy też uwagę, co twierdzenie szacuje: ryzyko **tego** predyktora, $R(\hat{f}_{\mathcal{D}})$, a nie ryzyko uśrednione po ponownych dopasowaniach do innych prób.

5.2.1. Niepewność oszacowania

Pierwiastek z wariancji, $\tau/\sqrt{m}$, to **błąd standardowy** oszacowania testowego. W klasyfikacji $\tau^2 = R(1 - R)$ jest wariancją zmiennej zero-jedynkowej, a τ^2/m – wariancją odsetka błędów,

czyli zmiennej o rozkładzie dwumianowym podzielonej przez m. Błąd standardowy szacujemy, podstawiając oszacowanie w miejsce ryzyka:

$$\widehat{\mathrm{se}} = \sqrt{\frac{\widehat{R}_{\mathrm{test}}\,(1-\widehat{R}_{\mathrm{test}})}{m}}. \tag{5.2}$$

Przedział $\widehat{R}_{\mathrm{test}} \pm 1{,}96\,\widehat{\mathrm{se}}$ jest **przybliżonym** przedziałem ufności na poziomie 95%. Przybliżenie normalne wymaga dostatecznie wielu błędów i trafień, nie tylko dużego m; przy zerowej lub bardzo małej liczbie błędów zawodzi. Poziom 95% opisuje częstość pokrywania ryzyka przez tak budowane przedziały w powtarzanych próbach. W regresji wariancję τ^2 szacujemy wariancją z próby strat testowych, a błąd standardowy wynosi $s_L/\sqrt{m}$. Silna skośność kwadratów błędów może wymagać większej próby, zanim przybliżenie normalne będzie dobre.

Wzór (5.2) szybko studzi zaufanie do małych zbiorów testowych. Przy błędzie rzędu 10% i $m = 100$ błąd standardowy wynosi 0,03, więc przedział ufności rozciąga się od około 4% do 16%. Aby połowa szerokości przedziału wynosiła h, potrzeba

$$m \approx \frac{1{,}96^2\, R(1-R)}{h^2}$$

obserwacji. Dla $R = 0{,}1$ i $h = 0{,}01$ to około 3500 obserwacji, dla $h = 0{,}005$ – około 14 000. Dokładność rośnie jak $\sqrt{m}$: dwukrotne zawężenie przedziału kosztuje czterokrotnie więcej danych. Dlatego w kontrolowanych symulacjach korzystamy czasem z całkowania po znanym rozkładzie: nawet przy 20 000 obserwacjach testowych i ryzyku 0,16 błąd standardowy oceny to jeszcze $\sqrt{0{,}16 \cdot 0{,}84/20\,000} \approx 0{,}0026$.

5.2.2. Porównanie dwóch modeli

Modele A i B warto oceniać na **tych samych obserwacjach**. Oba dostają wtedy te same łatwe i trudne przypadki. Dla każdej obserwacji odejmujemy stratę modelu B od straty modelu A, a potem uśredniamy te różnice. To porównanie sparowane; zwykle daje dokładniejszą ocenę różnicy ryzyk niż ocena modeli na dwóch osobnych próbach.

W klasyfikacji obserwacja, na której oba modele trafiają lub oba się mylą, wnosi do różnicy zero. Jeśli na 100 przypadkach tylko A myli się 3 razy, a tylko B – 7 razy, różnica oszacowań ryzyka wynosi $(3-7)/100 = -0{,}04$, czyli 4 punkty procentowe na korzyść A. Sama różnica nie rozstrzyga jeszcze, czy przewaga powtórzy się na nowych danych. O tym, który model jest lepszy, świadczy tylko 10 obserwacji spornych. Gdyby modele miały równe ryzyko, każdy spór przypadałby na niekorzyść A albo B z prawdopodobieństwem 1/2, jak w rzucie monetą. Przy 10 sporach podział 3 do 7 lub bardziej skrajny, w którąkolwiek stronę, zdarza się wtedy z prawdopodobieństwem około 0,34, więc nie jest niczym niezwykłym. Podział 10 do 30 przy 40 sporach ma już prawdopodobieństwo około 0,002 i jest mocnym argumentem za modelem A. O pewności porównania decydują liczba sporów i ich podział; obserwacje zgodne nic tu nie wnoszą. Rachunek niepewności i test McNemara (Dietterich 1998) omawia rozszerzenie 5.11.

5.2.3. Cena odłożenia danych

Zbiór testowy nie jest za darmo. Obserwacje odłożone do oceny nie biorą udziału w uczeniu, więc oceniamy model uczony na $n-m$ zamiast n obserwacjach. Krzywe uczenia z sekcji 4.7 mówią, ile to kosztuje. Jeśli krzywa jest przy $n-m$ już płaska, niewiele. Jeśli stromo opada, model uczony na wszystkich danych byłby wyraźnie lepszy niż ten, który oceniliśmy. Mamy więc konflikt: duże m daje dokładną ocenę słabszego modelu, małe m – niedokładną ocenę lepszego.

Druga cena jest mniej oczywista. Zbiór testowy zachowuje swoje własności tylko wtedy, gdy wynik na nim nie wpływa na model. Jeśli po obejrzeniu błędu testowego zmienimy cechy, hiperparametry czy metodę, a potem ocenimy nowy model na tym samym zbiorze, zbiór testowy stał się częścią procedury uczenia. Każde takie spojrzenie zużywa go po trochu (sekcja 5.6).

Po ocenie możemy dołączyć obserwacje testowe do uczenia, ale ponowne dopasowanie tworzy **inny model**. Dotychczasowy wynik testowy pozostaje oceną wcześniejszego predyktora; nie jest niezależną oceną nowego.

5.3. Zbiór walidacyjny

Dopasowaliśmy trzech kandydatów do tego samego zbioru uczącego. Na osobnych 100 obserwacjach dostaliśmy następujące wyniki. Tabela jest przykładem dydaktycznym, a nie wynikiem obliczeń na danych z późniejszej sekcji praktycznej.

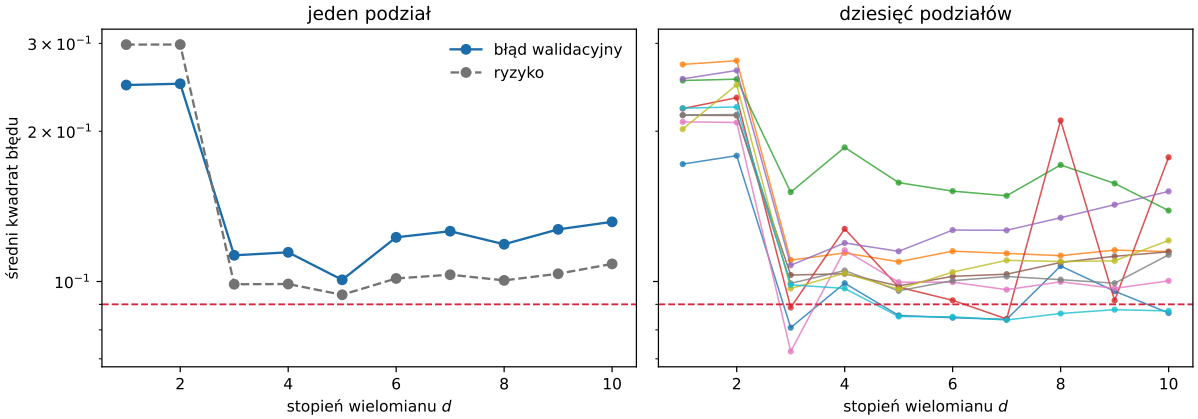
Liczba sąsiadów k	Liczba pomyłek	Błąd walidacyjny
3	14	14%
9	10	10%
21	12	12%

Najmniejszy wynik wskazuje $k = 9$. Obserwacje użyte do tego wyboru tworzą **zbiór walidacyjny**. Wyniku 10% nie traktujemy jeszcze jako końcowej oceny: właśnie na jego podstawie wybraliśmy model. Mechanizm zaniżenia wyniku zwycięzcy policzymy w sekcji 5.6.

Część danych	Czynność	Wynik czynności
ucząca	dopasowujemy kandydatów	trzy predyktory
walidacyjna	porównujemy ich straty	wybór $k = 9$
testowa	oceniamy wybrany predyktor	niezależne oszacowanie jego ryzyka

Podział na zbiór uczący i walidacyjny ma dwie wady. Obie widać na rysunku 5.1. Wzięliśmy próbę $n = 100$ obserwacji z rozkładu z rozdziału 4: X jednostajne na $[0, 1]$, $f^*(x) = \sin(2\pi x)+x/2$, szum o odchyleniu standardowym $\sigma = 0{,}3$. Połowę obserwacji przeznaczyliśmy do uczenia wielomianów stopni 1–10, połowę – do walidacji.

Lewy panel pokazuje, że błąd walidacyjny dobrze oddaje kształt krzywej ryzyka: obie gwałtownie spadają między stopniem 2 a 3, mają minimum w okolicy stopnia 5 i dalej powoli rosną. Do selekcji to wystarcza. Prawy panel pokazuje pierwszą wadę: wynik zależy od tego, które obserwacje trafiły do której części. Różne podziały tej samej próby dają krzywe przesunięte względem siebie i wskazują różne stopnie jako najlepsze. Zbiór walidacyjny liczy 50 obserwacji, a jak widzieliśmy w sekcji 5.2, przy takiej liczności oszacowanie ma duży błąd standardowy. Druga wada to marnotrawstwo: wielomiany uczymy na połowie danych, więc oceniamy modele gorsze niż te, które moglibyśmy dopasować do całej próby. Przy stromej krzywej uczenia błąd walidacyjny przeszacowuje wtedy ryzyko, a przy stopniach wysokich, których wariancja najsilniej zależy od n, przeszacowuje je najbardziej. Przesunięcie nie jest więc wspólne dla kandydatów i może zmienić ich kolejność. Wybieramy przez to model zwykle prostszy niż ten, który byłby najlepszy po dopasowaniu do całej próby.



Rysunek 5.1.: Błąd na zbiorze walidacyjnym regresji wielomianowej w zależności od stopnia d. Próba liczności $n = 100$ podzielona losowo na połowę uczącą i połowę walidacyjną. Po lewej: jeden podział; szara linia to ryzyko tych samych wielomianów, policzone całkowaniem po znanym rozkładzie. Po prawej: dziesięć różnych podziałów tej samej próby. Oś pionowa w skali logarytmicznej.

5.4. Walidacja krzyżowa

Zamiast odkładać na stałe jedną część do walidacji, możemy zmieniać jej rolę. Weźmy 12 obserwacji i podzielmy je na trzy części po cztery. Dla klasyfikatora 3-NN otrzymaliśmy poniższy dydaktyczny wynik.

Krok	Obserwacje uczące	Obserwacje oceniane	Liczba błędów
1	części 2 i 3: razem 8	część 1: 4	1
2	części 1 i 3: razem 8	część 2: 4	0
3	części 1 i 2: razem 8	część 3: 4	2

Łącznie mamy $1+0+2 = 3$ błędy w 12 ocenianych predykcjach, czyli $3/12 = 25\%$. Każda obserwacja otrzymała jedną predykcję z dopasowania, które jej nie widziało. **Uśredniamy straty, nie predykcje trzech modeli.**

Definicja 5.1 (Walidacja krzyżowa)**.** Podzielmy indeksy $\{1, \ldots, n\}$ losowo na K rozłącznych części $F_1, \ldots, F_K$ możliwie równej liczności. Niech $\hat{f}^{(-r)}$ oznacza predyktor dopasowany do wszystkich obserwacji poza częścią F_r. **K-krotną walidacją krzyżową** (ang. *K-fold cross-validation*, CV) nazywamy oszacowanie

$$\mathrm{CV}_K = \frac{1}{n} \sum_{r=1}^{K} \sum_{i \in F_r} L(y_i, \hat{f}^{(-r)}(\mathbf{x}_i)). \tag{5.3}$$

Duże K oznacza liczbę części, małe k – liczbę sąsiadów w k-NN. Indeks r wskazuje część. Wewnętrzna suma dodaje straty w jednej części, a zewnętrzna – we wszystkich częściach. Dzielimy przez liczbę ocenianych obserwacji n. Jeśli części mają nierówne liczności, nie wolno zastąpić tego rachunku nieważoną średnią odsetków błędów: część zawierająca więcej obserwacji powinna mieć większą wagę.

Każda obserwacja jest oceniana raz i bierze udział w uczeniu $K-1$ razy. Koszt to K dopasowań zamiast jednego. Ujęcie walidacji krzyżowej jako ogólnej metody wyboru i oceny predyktorów zawdzięczamy M. Stone (1974).

Aby wybrać k, powtarzamy rachunek dla każdego kandydata **na tym samym podziale** i porównujemy wyniki. To ponownie porównanie sparowane: każdy kandydat dostaje te same przypadki. Ręczne obliczenie takiego wyboru proponuje Zadanie 5.9.

5.4.1. Co jest uczone i co jest oceniane

Przy $K = 5$ każde dopasowanie wykorzystuje 80% danych. Żaden z tych pięciu modeli nie jest modelem dopasowanym do całej próby. Oceniamy powtarzane zastosowania tej samej **metody**, a nie jeden gotowy model. Gdybyśmy losowali wiele prób liczności n i w każdej od nowa dopasowywali predyktor, średnia ich ryzyk byłaby ryzykiem oczekiwanym metody:

$$\overline{R}_n = \mathbb{E}_{\mathcal{D}}[R(\hat{f}_{\mathcal{D}})]. \tag{5.4}$$

Wewnętrzne $R(\hat{f}_{\mathcal{D}})$ uśrednia stratę na nowych obserwacjach dla jednego modelu; zewnętrzne oczekiwanie uśrednia te ryzyka po zbiorach uczących.

Dla niezależnych obserwacji z jednego rozkładu, ustalonej metody oraz równych części losowanych niezależnie od wartości danych mamy

$$\mathbb{E}[\mathrm{CV}_K] = \overline{R}_{n(K-1)/K}. \tag{5.5}$$

Każdy oceniany przypadek jest bowiem niezależny od próby, która posłużyła do jego predykcji, a próba ta liczy $n(K-1)/K$ obserwacji. Równość dotyczy średniej po powtórzeniach całego badania i nie obejmuje minimum wybranego spośród wielu wyników CV (sekcja 5.6). Wynik CV z jednej próby słabo informuje, czy model dopasowany do tej próby wyszedł lepszy, czy gorszy od przeciętnego: szacuje raczej ryzyko metody niż ryzyko tego modelu (ramka „Ryzyko modelu a ryzyko metody" w rozdziale 4). Symulację pokazuje rozszerzenie 5.13.

Jeżeli ryzyko metody maleje wraz z licznością uczenia, CV ma względem $\overline{R}_n$ **pesymistyczne** przesunięcie: ocenia uczenie na mniejszej próbie.

5.4.2. Ile części

Typowy wybór to $K = 5$ lub $K = 10$ (James i in. 2023, rozdz. 5.1). Wtedy każde dopasowanie wykorzystuje odpowiednio 80% lub 90% próby, a koszt wynosi pięć lub dziesięć dopasowań na kandydata. Przy $K = 2$ do uczenia zostaje tylko połowa danych. Wybór K jest kompromisem: im mniejsze K, tym mniejsze zbiory uczące i większe pesymistyczne przesunięcie; im większe, tym więcej dopasowań i tym silniej pokrywają się zbiory uczące. Przy $K = 5$ lub $K = 10$ pesymizm jest zwykle niewielki. Skrajny przypadek $K = n$ to **walidacja „pozostaw jeden"** (LOOCV): uczymy na $n-1$ obserwacjach i oceniamy na jednej, kolejno dla wszystkich obserwacji. Wymaga to zwykle n dopasowań. Dla niektórych metod rachunek można uprościć; pokazuje to rozszerzenie 5.12.

Większe K nie gwarantuje mniejszej wariancji oszacowania. Zależy ona od tego pokrycia, a także od stabilności metody. Symulacje i dokładniejszą analizę odkładamy do rozszerzenia 5.13.

5.4.3. Błąd standardowy walidacji krzyżowej

Wynik CV, podobnie jak oszacowanie testowe, jest średnią n strat. Błąd standardowy liczymy więc tak, jakby były to straty testowe: odchylenie standardowe n strat dzielimy przez $\sqrt{n}$. Dla straty 0–1 daje to praktycznie wzór (5.2) z wynikiem CV w miejscu oszacowania testowego:

$$\widehat{\mathrm{se}}_{\mathrm{CV}} = \sqrt{\frac{\mathrm{CV}_K\,(1-\mathrm{CV}_K)}{n}}.$$

Straty z różnych części nie są jednak niezależne, bo modele korzystają ze wspólnych obserwacji uczących. Ta miara jest więc naiwna i zwykle zaniżona, ale wystarcza jako orientacyjna skala różnic przy wyborze. Ponowne losowanie podziału pokazuje wrażliwość na podział, ale **nie tworzy nowych obserwacji** i nie mierzy całej niepewności wynikającej z posiadania jednej próby.

Taką przybliżoną miarę wykorzystuje **reguła jednego błędu standardowego** (Hastie i in. 2009, rozdz. 7.10). Rozważmy inną, większą próbę i dydaktyczną tabelę:

Liczba sąsiadów k	Wynik CV
1	0,12
5	0,10
15	0,11
51	0,14

Niech próba liczy $n = 225$ obserwacji. Błąd standardowy przy minimum wynosi wtedy $\sqrt{0{,}10 \cdot 0{,}90/225} = 0{,}02$. Minimum wskazuje $k = 5$. Reguła dopuszcza wyniki nie większe niż $0{,}10 + 0{,}02 = 0{,}12$, czyli $k = 1, 5, 15$, i wybiera spośród nich model najmniej elastyczny. Dla k-NN jest to największe k, tutaj 15.

Ogólnie próg stanowi najmniejszy wynik CV powiększony o jego oszacowany błąd standardowy. Wybieramy najmniej elastycznego kandydata mieszczącego się pod progiem. To **heurystyka** skłaniająca do prostszego modelu przy małych różnicach wyników, a nie test równoważności kandydatów. Porządek od mniej do bardziej elastycznych modeli trzeba określić przed użyciem tej reguły.

5.4.4. Walidacja krzyżowa w klasyfikacji

W klasyfikacji części zwykle losujemy **warstwowo** (ang. *stratified*), zachowując w przybliżeniu proporcje klas. Przy rzadkiej klasie zmniejsza to ryzyko uzyskania części bez jej przedstawicieli. Nie zastępuje jednak zebrania dostatecznie wielu takich obserwacji; liczba części musi być dostosowana do liczności najmniejszej klasy.

Stratę dobieramy do celu. Strata 0–1 mierzy częstość pomyłek, ale nie ocenia jakości podawanych prawdopodobieństw: nie odróżnia modelu, który pomylił się, podając $\hat{\eta} = 0{,}51$, od modelu, który podał 0,99. Jeśli potrzebujemy prawdopodobieństw, na przykład do reguły z progiem kosztowym z sekcji 2.8, możemy użyć straty Briera $(y-\hat{\eta})^2$ lub logarytmicznej $-y \log \hat{\eta} - (1-y)\log(1-\hat{\eta})$. Są to **straty właściwe** (Gneiting i Raftery 2007): w populacji premiują podawanie prawdziwego prawdopodobieństwa klasy. Uzasadnienie zawiera rozszerzenie 2.10, ale do użycia CV wystarczy ustalić wybraną stratę przed porównywaniem kandydatów.

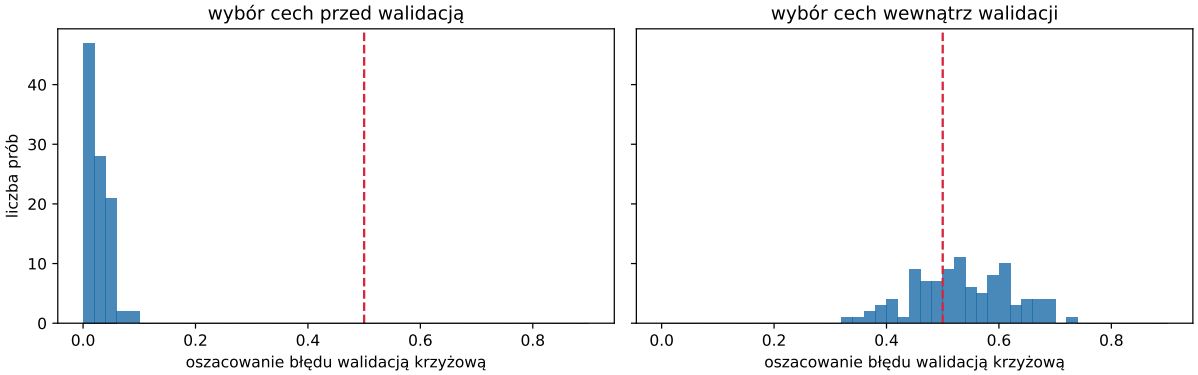
Przy stracie logarytmicznej trzeba uważać na skrajne prawdopodobieństwa: k-NN może podać $\hat{\eta} = 0$ albo 1, a błędna predykcja z taką pewnością daje nieskończoną stratę. Sposób wygładzania prawdopodobieństw, jeśli go stosujemy, również musi być częścią ocenianej procedury.

5.5. Wyciek informacji

Wybieramy cechy najbardziej związane z klasą, a dopiero potem rozdzielamy dane do uczenia i oceny. Co już zdradziły przyszłe obserwacje oceniające? Ich **klasy** pomogły zdecydować, które cechy zachować. Nawet jeśli klasyfikator nie zobaczy ich podczas dopasowania, korzysta z informacji, której nie miałby dla nowych obiektów.

Błędna kolejność	Poprawna kolejność w każdym kroku CV
wybierz cechy na całej próbie	odłóż część oceniającą
podziel dane na części	wybierz cechy tylko na pozostałych danych
dopasuj model bez części oceniającej	dopasuj model na tych danych
oceń na odłożonej części	użyj wybranych cech do predykcji na odłożonej części

Rozważmy przykład z Hastie i in. (2009, rozdz. 7.10.2). Mamy $n = 50$ obserwacji z dwóch równolicznych klas i $p = 5000$ cech, które są czystym szumem: nie zależą od klasy. Każdy klasyfikator ma tu ryzyko 1/2. Procedura jest następująca: wybieramy 100 cech najsilniej skorelowanych z klasą, a na nich budujemy klasyfikator jednego najbliższego sąsiada. Procedurę oceniamy pięciokrotną walidacją krzyżową na dwa sposoby. W **złym** wybór cech robimy raz, na całej próbie, a walidacji poddajemy tylko klasyfikator. W **dobrym** wybór cech powtarzamy w każdej części, na jej danych uczących.



Rysunek 5.2.: Oszacowania błędu procedury „wybór 100 cech najsilniej skorelowanych z klasą + klasyfikator 1-NN" pięciokrotną walidacją krzyżową, dla 100 prób ($n = 50$, $p = 5000$ cech niezależnych od klasy). Po lewej: wybór cech na całej próbie, przed walidacją. Po prawej: wybór cech wewnątrz każdej części. Czerwona linia: prawdziwe ryzyko 1/2.

```
średnie oszacowanie: zły sposób 0.017, dobry sposób 0.525
```

Zły sposób przekonuje, że klasyfikator niemal się nie myli, choć w danych nie ma żadnej informacji o klasie. Mechanizm jest prosty. Wśród 5000 cech szumu przy 50 obserwacjach zawsze znajdą się takie, które przypadkiem silnie korelują z klasą. Wybierając je na całej próbie, wybieramy cechy dopasowane także do klas obserwacji, które później posłużą do oceny. Klasyfikator „wie" o nich coś, czego w nowych danych nie będzie. Dobry sposób daje oszacowania rozrzucone wokół 1/2, jak być powinno. Ten błąd metodologiczny nie jest wymyślony: Ambroise i McLachlan (2002) pokazali, że w opublikowanych analizach danych z mikromacierzy, gdzie cech są tysiące,

a obserwacji kilkadziesiąt, prowadził on do raportowania błędów bliskich zera dla klasyfikatorów bez wartości predykcyjnej.

To **wyciek informacji** (ang. *data leakage*). Oceniana obserwacja nie może wpływać na żaden etap budowy predyktora: wybór cech, parametry standaryzacji (3.4), uzupełnianie braków ani dopasowanie. Skala wycieku zależy od procedury i danych. Przy standaryzacji jest zwykle niewielka: średnia i odchylenie standardowe nie korzystają z odpowiedzi, a liczone z n zamiast z $n(K-1)/K$ obserwacji zmieniają się nieznacznie. Wybór cech korzysta natomiast z klas obserwacji oceniających i dlatego może zaniżyć oszacowanie tak silnie jak w przykładzie powyżej. Brak widocznego spadku błędu nie dowodzi jednak poprawności postępowania, więc standaryzację także dopasowujemy osobno w każdej części.

W bibliotece scikit-learn przed tym błędem chroni potok (`Pipeline`), o którym mówiliśmy w sekcji 3.6. Funkcje walidacji krzyżowej wywołują `fit` całego potoku osobno w każdej części, więc standaryzacja, wybór cech i model widzą tylko jej dane uczące.

Wyciek ma też źródła, przed którymi potok nie chroni, bo dotyczą samego podziału na części. Walidacja krzyżowa zakłada, że obserwacje są niezależne, a nowe dane pochodzą z tego samego rozkładu. Gdy to założenie zawodzi, losowy podział może odpowiadać na inne pytanie i dawać ocenę zbyt optymistyczną:

- **Obserwacje zgrupowane.** Jeśli mamy po kilka pomiarów każdego pacjenta, a model ma działać dla nowych pacjentów, to losowy podział pomiarów pozwala ocenić model na pacjencie, którego inne pomiary widział. Dzielić trzeba całe grupy (w scikit-learn `GroupKFold`).
- **Dane uporządkowane w czasie.** Jeśli model ma przewidywać sprzedaż w przyszłym dniu, ocenia się go tylko na obserwacjach późniejszych niż te, na których się uczył (`TimeSeriesSplit`). Losowy podział pozwala „przewidywać” przeszłość na podstawie przyszłości.
- **Duplikaty.** Te same lub prawie te same obserwacje w części uczącej i oceniającej działają jak obserwacje testowe w zbiorze uczącym. Do tej kategorii należy też powielanie obserwacji rzadkiej klasy przeprowadzone przed podziałem.
- **Cechy z przyszłości.** Cecha zarejestrowana po zdarzeniu, które przewidujemy – na przykład kod zabiegu wykonywanego tylko u chorych – daje świetne wyniki w walidacji i jest niedostępna w momencie, gdy predykcja jest potrzebna.

Ogólna zasada jest taka: podział na część uczącą i oceniającą ma naśladować sytuację, w której model będzie używany. Jeśli przyszłe dane będą pochodzić z innego szpitala, innego roku albo innej populacji niż próba, żaden podział próby tego nie odtworzy. Walidacja krzyżowa szacuje ryzyko w populacji, z której pochodzi próba, a wiarygodność tej oceny, jak zauważyliśmy w rozdziale 1, zależy od sposobu zebrania danych.

5.6. Selekcja modelu a ocena modelu

W tabeli z sekcji 5.3 wybraliśmy $k = 9$, bo miał najmniejszy błąd walidacyjny: 10%. Wynik zależy jednak od jakości modelu **i** od przypadkowego zestawu łatwych i trudnych obserwacji. Wybór minimum premiuje również korzystny przypadek. Dlatego liczba, która pozwoliła wygrać, może zbyt dobrze przedstawiać jakość zwycięzcy.

5.6.1. Mały rachunek optymizmu

Dwaj kandydaci A i B mają rzeczywiste ryzyko 15%. Przyjmijmy uproszczony model ich oszacowań: każde z nich niezależnie wynosi 10% albo 20%, z prawdopodobieństwem 1/2. To **model błędów oszacowania**, a nie wynik k-NN na rzeczywistych danych. Cztery możliwości są jednakowo prawdopodobne:

Oszacowanie A	Oszacowanie B	Najmniejszy wynik	Ryzyko wybranego kandydata
10%	10%	10%	15%
10%	20%	10%	15%
20%	10%	10%	15%
20%	20%	20%	15%

Każde oszacowanie z osobna ma średnią $(10 + 20)/2 = 15\%$. Natomiast średnia najmniejszego wyniku to

$$\frac{10 + 10 + 10 + 20}{4}\% = 12{,}5\%,$$

choć ryzyko wybranego kandydata zawsze wynosi 15%. Zaniżenie wynosi przeciętnie 2,5 punktu procentowego. W ostatnim wierszu oszacowanie **zawyża** ryzyko: optymizm dotyczy średniej po powtórzeniach, nie każdej realizacji. Niezależność pozwoliła łatwo rozpisać tabelę; wyniki modeli na wspólnych danych zwykle są zależne. Ogólna nierówność poniżej nie wymaga niezależności oszacowań.

5.6.2. Wynik zwycięzcy, jego ryzyko i najlepsze ryzyko

Gdy kandydaci mają różne ryzyka, dochodzi drugi problem. Na ilustracji 5.3 najmniejszy wynik to **21%**, rzeczywiste ryzyko wybranego kandydata to **28%**, a najmniejsze ryzyko wśród wszystkich kandydatów to **24%**. Zatem wynik zwycięzcy zaniża jego ryzyko, a wybrany kandydat jest gorszy od rzeczywiście najlepszego. To dwie osobne konsekwencje niedokładnej oceny. Liczby na rysunku dobrano do ilustracji; nie pochodzą z obliczeń na danych.

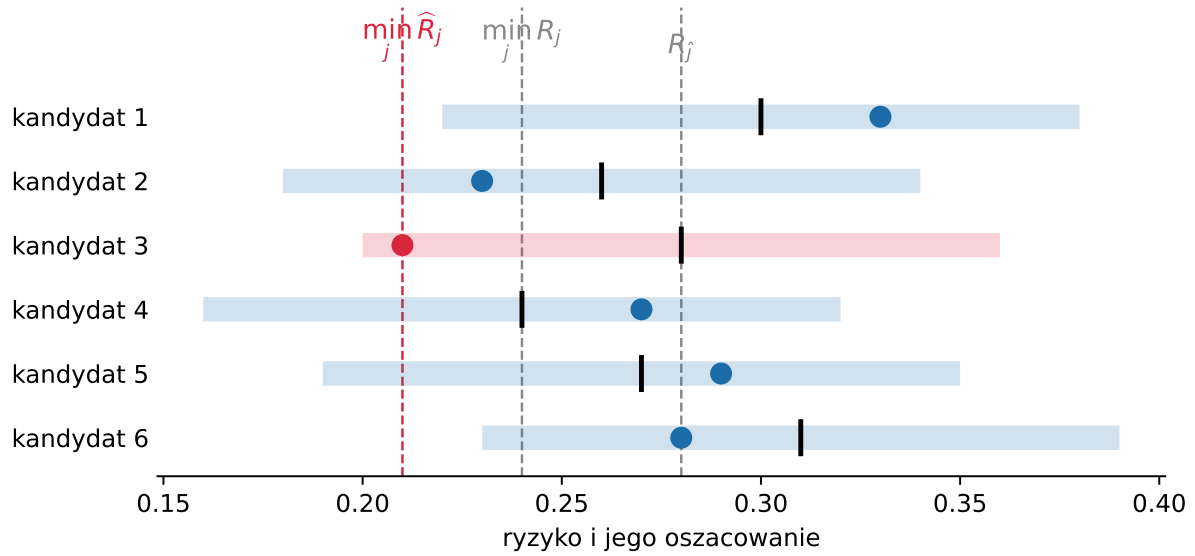
Dopiero teraz zapiszmy te trzy znaczenia symbolami: najmniejszy wynik to $\widehat{R}_{\hat{\jmath}}$, najmniejsze ryzyko kandydatów to $\min_j R_j$, a ryzyko zwycięzcy to $R_{\hat{\jmath}}$. Indeks $\hat{\jmath}$ wskazuje kandydata wybranego według oszacowania.

Twierdzenie 5.2 (Optymizm wyboru)**.** *Niech $\widehat{R}_1, \dots, \widehat{R}_M$ będą oszacowaniami ryzyk $R_1, \dots, R_M$ kandydatów, nieobciążonymi: $\mathbb{E}[\widehat{R}_j] = R_j$. Niech $\hat{\jmath}$ będzie indeksem najmniejszego oszacowania. Ryzyka R_j są tu liczbami, a losowe są oszacowania i wraz z nimi indeks $\hat{\jmath}$, więc także $R_{\hat{\jmath}}$. Wtedy*

$$\mathbb{E}[\widehat{R}_{\hat{\jmath}}] = \mathbb{E}\Big[\min_j \widehat{R}_j\Big] \le \min_j R_j \le \mathbb{E}[R_{\hat{\jmath}}].$$

Gdy kandydaci są dopasowani do zbioru uczącego $\mathcal{D}$, a oceniani na niezależnym zbiorze walidacyjnym, twierdzenie stosujemy przy ustalonym $\mathcal{D}$, z wartościami oczekiwanymi warunkowymi względem $\mathcal{D}$.

Lewy człon nierówności jest średnim wynikiem zwycięzcy, środkowy – najmniejszym rzeczywistym ryzykiem, prawy – średnim ryzykiem wybranego kandydata; wszystkie trzy są średnimi po powtórzeniach oszacowań i wyboru.



Rysunek 5.3.: Dydaktyczna ilustracja oszacowań dla sześciu kandydatów. Pasek: typowy rozrzut oszacowania $\widehat{R}_j$ (dwa błędy standardowe w każdą stronę), kreska: ryzyko R_j, kropka: przykładowe oszacowanie. Najmniejsze oszacowanie (czerwone) wypadło na lewym krańcu rozrzutu kandydata 3 i leży na lewo od wszystkich ryzyk, także od najmniejszego, które ma kandydat 4. Wybrany kandydat nie jest najlepszy, więc jego ryzyko $R_{\hat{j}}$ przekracza $\min_j R_j$.

Dowód nierówności wyboru

Wymagane są liniowość wartości oczekiwanej i własność średniej ważonej.

Dowód. Dla każdego l zachodzi $\min_j \widehat{R}_j \le \widehat{R}_l$. Biorąc wartość oczekiwaną, dostajemy $\mathbb{E}[\min_j \widehat{R}_j] \le R_l$ dla każdego l, a więc także dla tego, przy którym R_l jest najmniejsze. Zmienna $R_{\hat{j}}$ zależy od danych tylko przez indeks $\hat{j}$, więc

$$\mathbb{E}[R_{\hat{j}}] = \sum_{j=1}^{M} R_j \, P(\hat{j} = j).$$

Jest to średnia ważona ryzyk $R_1, \ldots, R_M$, a średnia ważona nie jest mniejsza od najmniejszego ze składników. Stąd druga nierówność. □ □

Twierdzenie zakłada ustalone ryzyka kandydatów i nieobciążone oszacowania. W CV kandydatów uczymy na mniejszych próbach, co przy opadającej krzywej uczenia zawyża ich oszacowania; ten pesymizm i optymizm wyboru działają w przeciwne strony, więc łączny błąd minimum CV nie musi mieć jednego znaku.

5.6.3. Wybór przez CV i osobny test

Najprostsze rozwiązanie polega na odłożeniu testu **przed wyborem**. Na pozostałych danych przeprowadzamy CV, wybieramy k, po czym **dopasowujemy wybrany potok ponownie do wszystkich danych przeznaczonych do uczenia**. Dopiero ten predyktor raz oceniamy na odłożonym teście.

Etap	Użyte dane	Co robimy
wybór	dane uczące dzielone w CV	porównujemy wartości k
ponowne dopasowanie	całe dane uczące	wyznaczamy standaryzację i dopasowujemy wybrane k
końcowa ocena	odłożony test	liczymy średnią stratę gotowego predyktora

Modele z części CV były pomocnicze: każdy widział tylko fragment danych uczących. Ponowne dopasowanie pozwala wykorzystać je wszystkie. Parametry standaryzacji też ustalamy od nowa, bez testu. W tym wariancie niezależny test wystarcza do końcowej oceny; wyniku testowego nie używamy już do poprawiania procedury.

5.6.4. Zagnieżdżenie krok po kroku

Jeśli nie chcemy opierać oceny na jednym stałym podziale, możemy powtórzyć całe powyższe rozwiązanie, za każdym razem odkładając inną część do oceny. To **zagnieżdżona walidacja krzyżowa** (Varma i Simon 2006). Zewnętrzny podział służy ocenie, wewnętrzny – wyborowi.

Mamy 200 obserwacji, pięć części zewnętrznych i cztery wewnętrzne. Jeden krok wygląda tak:

1. Odkładamy 40 obserwacji do oceny. Na razie ich nie używamy.
2. Pozostałe 160 dzielimy na cztery części po 40. Dla każdego $k \in \{3, 9, 21\}$ wykonujemy cztery dopasowania na 120 obserwacjach i oceny na 40.
3. Wybieramy k według średniej strat ze 160 wewnętrznych predykcji.
4. Wybraną wersję potoku dopasowujemy od nowa na wszystkich 160 obserwacjach. Obejmuje to także ponowne wyznaczenie standaryzacji.
5. Liczymy błąd na 40 obserwacjach odłożonych w punkcie 1.
6. Powtarzamy cały proces dla każdej części zewnętrznej.

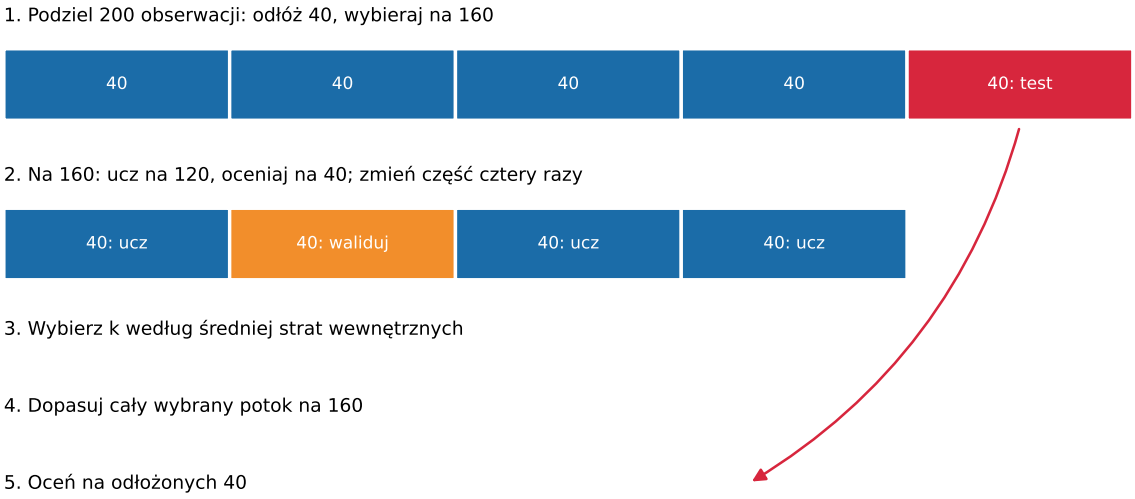
Całe przygotowanie danych powtarzamy **wewnątrz odpowiednich podziałów**. Wyniki zewnętrzne nie służą do zmieniania listy kandydatów, cech ani reguły wyboru; taka zmiana ponownie użyłaby danych oceniających do wyboru.

5.6.5. Co uśredniamy i jaki model zostaje

Przypuśćmy, że otrzymaliśmy poniższe wyniki. To tabela dydaktyczna, nie wynik wykonanej symulacji.

Część zewnętrzna	Wybrane k	Liczność testu	Liczba błędów
1	9	40	4
2	21	40	5
3	9	40	3
4	3	40	6
5	21	40	2

Wynik oceny wynosi $(4 + 5 + 3 + 6 + 2)/200 = 10\%$. Uśredniamy **straty na zewnętrznych częściach**. Nie wybieramy części z najmniejszym błędem, nie uśredniamy wybranych k i nie głosujemy nad nimi. Różne k są dopuszczalne, bo badamy regułę „wybierz k i dopasuj model".



Rysunek 5.4.: Jeden z pięciu kroków zewnętrznych dla 200 obserwacji. Odkładamy 40 do oceny, a na 160 wykonujemy czterokrotną CV. Każdy kandydat jest cztery razy uczony na 120 i oceniany na 40 obserwacjach. Po wyborze dopasowujemy cały potok na 160 i oceniamy na odłożonych 40.

Po zakończeniu oceny uruchamiamy **tę samą regułę na wszystkich** 200 **obserwacjach**: wybieramy k czterokrotną CV i dopasowujemy wybrany potok do całych danych. Dopiero to daje model do dalszego używania. Ocena zewnętrzna opisuje procedurę uczoną na 160 obserwacjach; nie jest niezależnym pomiarem ryzyka konkretnego końcowego dopasowania na 200. Jako ocenę modelu końcowego podajemy więc 10% z opisem, że jest to ocena procedury, którą ten model zbudowano. Gdy krzywa uczenia jeszcze opada, wynik ten jest zwykle lekko pesymistyczny, bo w krokach zewnętrznych procedura miała 160 obserwacji zamiast 200. Te role danych warto przećwiczyć w Zadanie 5.10.

Przy dużej liczbie danych prościej odłożyć test na początku, jak w wariancie z osobnym testem; ocenia on konkretny model, którego potem używamy. Przy 200 obserwacjach taki test liczyłby kilkadziesiąt przypadków: dla 40 obserwacji i błędu rzędu 10% błąd standardowy wynosi około 0,05 (sekcja 5.2), a zagnieżdżenie wykorzystuje do oceny każdą obserwację.

i Formalny zapis zagnieżdżonej walidacji krzyżowej

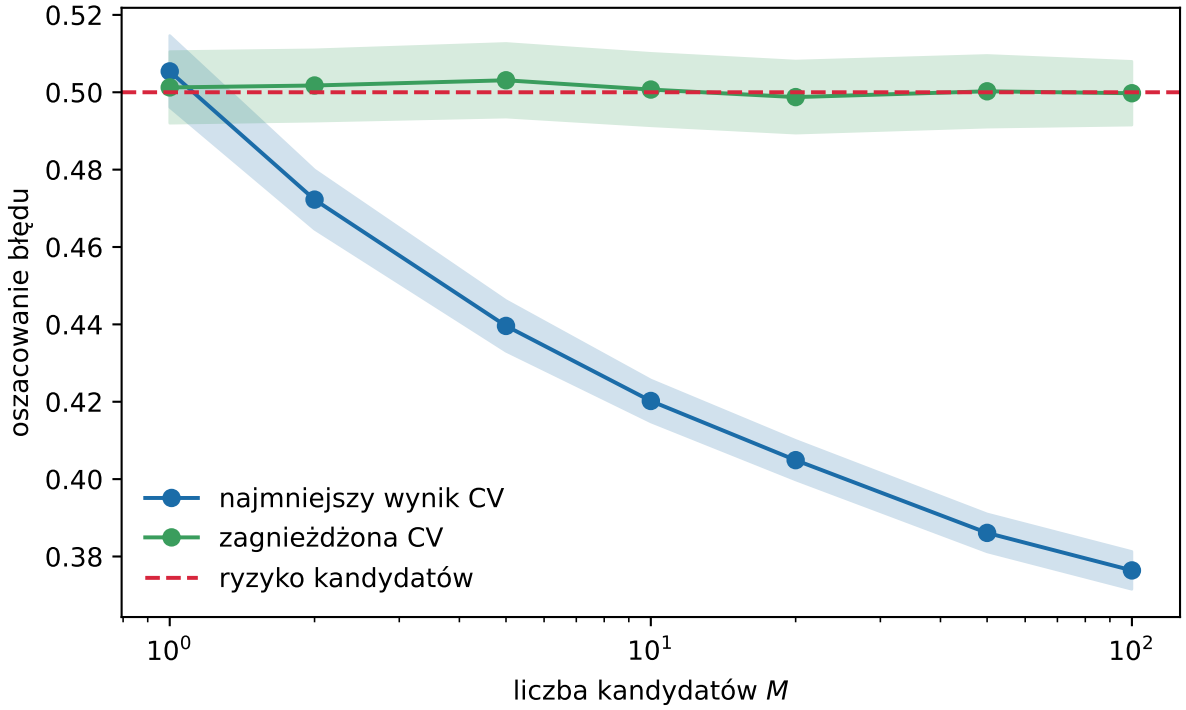
Wymagane są zapis funkcji złożonej i indeksowanie części próby. Niech $\mathcal{W}(\mathcal{D}')$ oznacza wykonanie na danych $\mathcal{D}'$ całej reguły: wybór kandydata wewnętrzną CV, a następnie ponowne dopasowanie do całego $\mathcal{D}'$. Wynikiem $\mathcal{W}$ jest predyktor. Dla części zewnętrznych $F_1, \dots, F_K$ niech $\mathcal{D}^{(-r)}$ oznacza dane poza F_r. Wtedy

$$\mathrm{CV}_K^{\mathrm{zagn}} = \frac{1}{n} \sum_{r=1}^{K} \sum_{i \in F_r} L(y_i, \mathcal{W}(\mathcal{D}^{(-r)})(\mathbf{x}_i)).$$

Najpierw $\mathcal{W}$ tworzy predyktor bez części F_r, następnie predyktor podaje wynik dla $\mathbf{x}_i$, a strata porównuje go z y_i. To zwykły wzór CV zastosowany do całej procedury wyboru i dopasowania.

5.6.6. Jak duży może być efekt wyboru

Rysunek 5.5 pokazuje skalę zjawiska na danych bez żadnej informacji. Mamy $n = 100$ obserwacji z $p = 10$ cechami i klasą wylosowaną niezależnie od cech, więc każdy klasyfikator ma ryzyko 1/2. Kandydatami są klasyfikatory k-NN o dziesięciu różnych wartościach k, uczone na dziesięciu różnych losowych trójkach cech – razem 100 kandydatów. Porównujemy dwie liczby: najmniejszy wynik pięciokrotnej walidacji krzyżowej spośród pierwszych M kandydatów i wynik zagnieżdżonej walidacji krzyżowej procedury wybierającej spośród nich.



Rysunek 5.5.: Optymizm wyboru. Dane bez informacji o klasie ($n = 100$, $p = 10$), kandydaci to klasyfikatory k-NN na losowych trójkach cech. Niebieska linia: najmniejsze oszacowanie pięciokrotną walidacją krzyżową wśród M kandydatów. Zielona linia: zagnieżdżona walidacja krzyżowa procedury wyboru (5 części zewnętrznych, 5 wewnętrznych). Średnie z 200 prób; pas to ± 2 błędy standardowe średniej. Czerwona linia: ryzyko każdego kandydata.

Przy jednym kandydacie nie ma wyboru, obie metody są zwykłą walidacją krzyżową i trafiają w 1/2. Z każdym kolejnym kandydatem minimum wyników walidacji krzyżowej spada, a przy stu kandydatach procedura bez żadnej wartości predykcyjnej „osiąga” błąd poniżej 40%. Zagnieżdżona walidacja krzyżowa pozostaje przy 1/2 niezależnie od M. Spadek minimum jest przy tym wolniejszy, niż byłby dla niezależnych oszacowań (Zadanie 5.6), bo kandydaci o podobnych k albo wspólnych cechach mają silnie skorelowane wyniki.

Ten efekt nazywamy **klątwą zwycięzcy**: najmniejszy wynik zawiera korzystny błąd oszacowania. Optymizm rośnie z liczbą kandydatów, bo więcej jest okazji, by któryś dostał wyjątkowo korzystny błąd, oraz z rozrzutem oszacowań, na przykład przy małym zbiorze walidacyjnym, bo wtedy same błędy są większe. Maleje, gdy jeden kandydat ma wyraźnie mniejsze ryzyko od pozostałych: wygrywa wtedy niemal zawsze, także z niekorzystnym błędem oszacowania, więc wynik zwycięzcy mało zależy od szczęścia. W tym eksperymencie kandydaci są równi, więc wybór niczego nie poprawia, a każdy kolejny kandydat tylko obniża raportowane minimum.

Cawley i Talbot (2010) pokazali, że przy wielu hiperparametrach i małych próbach zniekształcenie oceny przez wybór może być porównywalne z różnicami między metodami. Dlatego porównując metody, z których każdą stroimy osobno, nie zestawiamy ich najmniejszych wyników walidacji krzyżowej: metoda z większą liczbą hiperparametrów albo gęstszą siatką ma więcej kandydatów i dostaje większą premię za wybór. Każdą metodę razem z jej strojeniem oceniamy niezależnie, na osobnym zbiorze testowym albo zagnieżdżoną walidacją krzyżową.

Zagnieżdżenie usuwa wykorzystanie części oceniającej do wyboru, ale nie niepewność małej próby: wykres pokazuje średnie z 200 prób, a pojedyncze badanie może dać wynik daleki od 1/2.

5.7. Strojenie hiperparametrów

Hiperparametr to ustawienie metody wybierane przed jej dopasowaniem, na przykład liczba sąsiadów k albo stopień wielomianu. Wybór takich ustawień na podstawie walidacji to **strojenie**. Przy jednym ustawieniu wystarcza zwykle krótka lista kandydatów. Przy kilku liczba kombinacji szybko rośnie.

Przeszukiwanie siatki sprawdza wszystkie kombinacje z ustalonych list. **Przeszukiwanie losowe** losuje konfiguracje z wcześniej określonych zakresów. Różnicę pokazuje prosty schemat dla dwóch parametrów, z których pierwszy silniej wpływa na wynik (Bergstra i Bengio 2012).

Sposób	Dziewięć sprawdzanych konfiguracji	Wartości pierwszego parametru
siatka 3×3	każdy z trzech poziomów łączymy z trzema poziomami drugiego parametru	3 różne, każda sprawdzona 3 razy
losowanie z ciągłych zakresów	dziewięć niezależnie wylosowanych par	zwykle 9 różnych

Losowanie pozwala szerzej zbadać ważny parametr przy tym samym budżecie. Koszt strojenia to liczba kandydatów pomnożona przez liczbę części CV; w zagnieżdżeniu wykonujemy ten wybór od nowa w każdym kroku zewnętrznym.

Metody **sekwencyjne** wykorzystują wyniki już sprawdzonych konfiguracji, aby zdecydować, co sprawdzić dalej. Pozwalają oszczędzać kosztowne dopasowania, lecz nadal korzystają z tych samych danych walidacyjnych.

Skuteczniejsze szukanie może silniej dopasować wybór do szumu w walidacji; działa tu mechanizm optymizmu z sekcji 5.6. Dlatego budżet szukania i regułę wyboru traktujemy jako części procedury, a jej ocenę przeprowadzamy na osobnym teście albo zewnętrzną CV.

5.8. Ocena modeli w praktyce

Wróćmy do danych o nowotworach piersi z sekcji 3.6. Tam przyjęliśmy $k = 10$ arbitralnie. Teraz ustalamy listę kandydatów, regułę wyboru minimum błędu i podziały, oceniamy całą procedurę, a na końcu tworzymy model do używania.

5.8.1. Przygotowanie potoku

Standaryzacja należy do potoku, więc w każdym dopasowaniu wykorzysta tylko dostępne w nim dane uczące. Wewnętrzna CV ma cztery części, zewnętrzna – pięć, tak jak w przykładzie z poprzedniej sekcji.

5.8.2. Ocena procedury wyboru

`cross_validate` dopasuje od nowa całe `strojenie` wewnątrz każdej części zewnętrznej. `GridSearchCV` domyślnie ponownie dopasowuje zwycięski potok do wszystkich danych dostępnych w danym kroku. Zwracany wynik dotyczy zewnętrznych obserwacji, które nie brały udziału w tym wyborze.

```
Błąd procedury wyboru minimum: 0.0316
Naiwny błąd standardowy: 0.0073
k wybrane w częściach zewnętrznych: [7, 11, 5, 7, 3]
```

Pierwsza liczba odpowiada na pytanie o częstość pomyłek **procedury wybierającej minimum**, gdy dostaje około 80% naszej próby: 0,0316, czyli 18 pomyłek na 569 obserwacjach. Naiwny błąd standardowy, liczony jak w podsekcji o błędzie standardowym walidacji krzyżowej, wynosi 0,0073, więc przybliżony przedział 95% to około $\pm 1{,}4$ punktu procentowego, od 1,7% do 4,6%. Lista wybranych k pokazuje wrażliwość wyboru na dane. Części różnią się licznością najwyżej o jedną obserwację, więc średnia ich odsetków pomyłek praktycznie pokrywa się ze średnią po obserwacjach z definicji (5.3).

5.8.3. Końcowy wybór i dopasowanie

Po ocenie uruchamiamy tę samą procedurę na wszystkich danych.

```
  k   błąd CV na wszystkich danych
  1   0.0510
  3   0.0351
  5   0.0386
  7   0.0334
  9   0.0369
 11   0.0351
 15   0.0387
 21   0.0422
 31   0.0422
 51   0.0492
Końcowe k: 7
```

Krzywa jest płaska: k od 3 do 15 daje wyniki od 3,3% do 3,9%, czyli od 19 do 22 pomyłek. Różnice wynoszą 1–3 pomyłki, więc rozstrzyga je przewaga kilku obserwacji spornych, a przy tak małej liczbie sporów o zwycięzcy w dużej mierze decyduje przypadek (sekcja 5.2). Dlatego w częściach zewnętrznych wygrywały różne wartości: $7, 11, 5, 7, 3$. Wszystkie leżą jednak na płaskim dnie krzywej, więc niestabilny jest wybór konkretnego k, a jakość wybranego modelu zmienia się niewiele.

Tabela służy końcowemu **wyborowi**, a `model_koncowy` jest potokiem już dopasowanym do całej próby. Najmniejsza liczba z tabeli nie jest nową niezależną oceną. Tutaj jest nawet nieco większa od wyniku zewnętrznego: 0,0334 wobec 0,0316. Obie liczby pochodzą z różnych podziałów i różnią się o jedną pomyłkę, znacznie mniej niż błąd standardowy, więc ich porównanie nie mierzy optymizmu wyboru.

5.8.4. Osobny wariant: reguła jednego błędu standardowego

Na tej samej tabeli można zilustrować inną regułę wyboru. Błąd standardowy przy minimalnym wyniku b liczymy jak w podsekcji o błędzie standardowym walidacji krzyżowej: $\sqrt{b(1-b)/n}$, gdzie n to liczba wszystkich obserwacji.

```
Próg reguły 1 SE: 0.0409; wybrane k: 15
```

Pod progiem 0,0409 mieści się jeszcze $k = 15$ z wynikiem 0,0387, czyli model gładszy od $k = 7$ przy ocenie gorszej o trzy pomyłki na 569 obserwacji. Ocena zewnętrzna z poprzedniej podsekcji dotyczy wyboru minimum; aby ocenić regułę jednego błędu standardowego, powtarzamy zagnieżdżoną walidację, stosując tę regułę wewnątrz każdego kroku zewnętrznego.

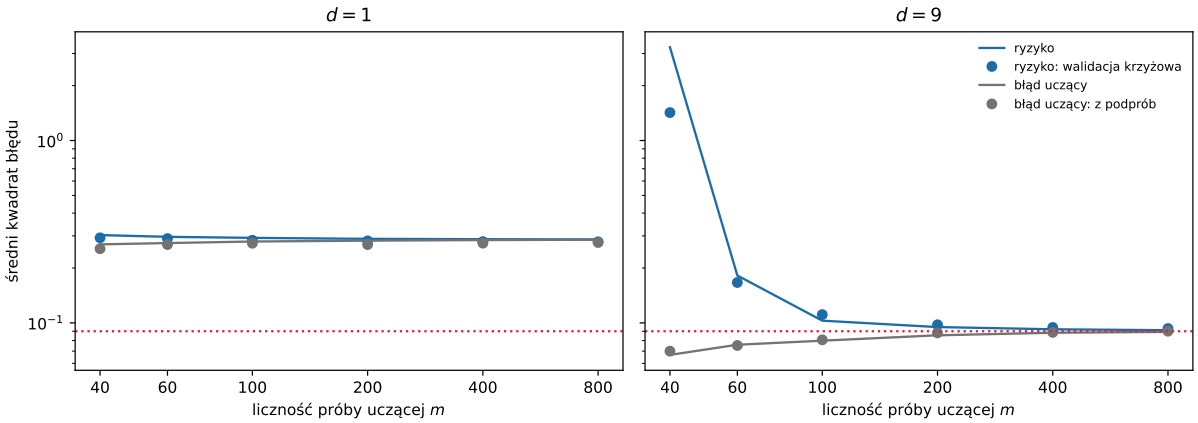
5.9. Krzywe uczenia z danych

W sekcji 4.7 krzywe uczenia rysowaliśmy, znając ryzyko. Z danych szacuje się je tak samo jak każde ryzyko: walidacją krzyżową. Dla każdej części F_r i każdej liczności m mniejszej niż liczność zbioru uczącego losujemy z danych spoza F_r podpróbę liczności m, dopasowujemy do niej model i liczymy jego błąd na F_r oraz na samej podpróbie. Losowanie podpróby powtarzamy kilkakrotnie i uśredniamy. W bibliotece scikit-learn robi to funkcja `learning_curve`. Rysunek 5.6 porównuje tak oszacowane krzywe z prawdziwymi dla wielomianów stopnia 1 i 9 z rysunku 4.4, przy jednej próbie liczności $N = 1000$.

```
d = 1: walidacja krzyżowa [0.293 0.29  0.284 0.282 0.279 0.278]
       prawdziwe ryzyko    [0.303 0.296 0.293 0.289 0.288 0.287]
d = 9: walidacja krzyżowa [1.423 0.167 0.111 0.098 0.094 0.093]
       prawdziwe ryzyko    [3.249 0.182 0.103 0.095 0.092 0.091]
```

Oszacowane krzywe odtwarzają obraz z sekcji 4.7: dla prostej szczelina między krzywymi jest wąska, a obie leżą wysoko nad σ^2; dla wielomianu stopnia 9 szczelina jest szeroka przy małych licznościach i zamyka się, gdy danych przybywa. W symulacji znamy σ^2, więc wiemy, że prosta pozostawia dużą część błędu możliwą do usunięcia przez zmianę metody. W rzeczywistych danych tego poziomu zwykle nie znamy, więc płaskie krzywe nie mówią, czy ogranicza nas szum, czy klasa modeli; pomaga wtedy porównanie klas i rozważenie nowych cech (sekcja 4.7). Największa rozbieżność występuje dla $d = 9$ przy najmniejszej liczności. Ryzyko oczekiwane jest tam średnią zdominowaną przez nieliczne próby, w których wielomian wysokiego stopnia „ucieka” przy krańcu przedziału. Sto dopasowań z podprób jednej próby takie rzadkie zdarzenia łapie nieregularnie, więc w tym punkcie oszacowanie jest niedokładne.

Krzywa uczenia oszacowana z danych kończy się na liczności zbioru uczącego w walidacji krzyżowej, czyli $N(K-1)/K$. Czy dodanie danych pomoże, ocenia się więc, ekstrapolując jej przebieg poza zakres obserwacji. Jeśli krzywa ryzyka przy największych licznościach nadal wyraźnie



Rysunek 5.6.: Krzywe uczenia regresji wielomianowej stopnia $d = 1$ (po lewej) i $d = 9$ (po prawej) oszacowane z jednej próby liczności $N = 1000$ pięciokrotną walidacją krzyżową, z 20 podpróbami dla każdej części i liczności (punkty), na tle prawdziwych krzywych z 300 prób z populacji (linie). Linia kropkowana: błąd nieredukowalny σ^2. Obie osie w skali logarytmicznej.

opada, więcej danych prawdopodobnie pomoże; jeśli jest już płaska, można oczekiwać niewielkiej korzyści z podobnych danych, choć poza obserwowanym zakresem krzywa może zmienić przebieg.

5.10. Bootstrap

Poza ryzykiem często potrzebujemy niepewności innych wielkości obliczonych z próby: współczynnika modelu, predykcji w danym punkcie, a także samego oszacowania błędu. Gdybyśmy znali rozkład P, losowalibyśmy z niego nowe próby i oglądali rozrzut tej wielkości, jak rozrzut dopasowanych wielomianów na rysunku 4.2 w rozdziale 4.

Weźmy najprostszy przypadek: pięć pomiarów $2, 4, 4, 6, 9$ o średniej 5. Chcemy oszacować, jak zmieniałaby się średnia, gdybyśmy ponownie zbierali po pięć pomiarów. Nie znamy jednak populacji. Możemy spróbować ją przybliżyć, wielokrotnie losując **ze zwracaniem** z posiadanej próby. Każde losowanie wybiera jeden z pięciu zapisów; oba zapisy wartości 4 są osobnymi obserwacjami. Oto trzy przykładowe replikacje:

Próba ze zwracaniem	Średnia
$2, 2, 4, 6, 6$	4,0
$4, 4, 6, 9, 9$	6,4
$2, 4, 4, 6, 9$	5,0

Średnie są różne, choć żadna replikacja nie zawiera nowej informacji z populacji. Rozrzut średnich z wielu takich replikacji wykorzystamy jako przybliżenie niepewności średniej z naszej próby. Trzy wypisane próby tylko ilustrują pomysł; do obliczeń używamy znacznie większej liczby replikacji.

Bootstrap (Efron 1979) zastępuje nieznany rozkład P przybliżeniem z danych: **rozkładem empirycznym** $\widehat{P}_n$, który każdej z n obserwacji próby przypisuje prawdopodobieństwo $1/n$. Losowanie n obserwacji z $\widehat{P}_n$ to losowanie n obserwacji z próby **ze zwracaniem**. Taką **próbę**

bootstrapową $\mathcal{D}^*$ wykorzystujemy do naśladowania ponownego zbierania danych; nie jest ona nową próbą z populacji.

> **Błąd standardowy metodą bootstrap**
>
> Niech $\hat{\theta} = s(\mathcal{D})$ będzie wielkością obliczoną z próby.
>
> 1. Dla $b = 1, \ldots, B$ wylosuj z próby ze zwracaniem n obserwacji, tworząc próbę $\mathcal{D}_b^*$, i oblicz $\hat{\theta}_b^* = s(\mathcal{D}_b^*)$.
> 2. Oszacowaniem błędu standardowego $\hat{\theta}$ jest odchylenie standardowe liczb $\hat{\theta}_1^*, \ldots, \hat{\theta}_B^*$.
> 3. Kwantyle rzędu 0,025 i 0,975 tych liczb wyznaczają **przedział percentylowy**, używany jako przybliżony przedział ufności na poziomie 95%.

Dla pięciu pomiarów z początku sekcji granicę przy $B \to \infty$ można obliczyć dokładnie. Średnia n niezależnych losowań z $\widehat{P}_n$ ma wariancję $\hat{\sigma}^2/n$, gdzie $\hat{\sigma}^2 = 28/5 = 5{,}6$ to wariancja próby z dzieleniem przez n, więc odchylenie standardowe średnich bootstrapowych dąży do $\sqrt{5{,}6/5} \approx 1{,}06$. Klasyczny wzór $s/\sqrt{n}$ z $s^2 = 28/4 = 7$ daje $\sqrt{7/5} \approx 1{,}18$. Bootstrap odtwarza więc znany błąd standardowy średniej, z dzieleniem przez n zamiast $n-1$; przy większym n różnica zanika. Jego wartość polega na tym, że ten sam przepis działa dla wielkości, dla których wzoru nie mamy, np. dla predykcji wielomianu na rysunku 5.7.

Ten prosty bootstrap zakłada niezależne obserwacje z tego samego rozkładu; przy zależnościach czasowych lub grupach potrzebny jest inny schemat losowania. Przy małych próbach, estymatorach nieregularnych albo dużym obciążeniu pokrycie przedziału percentylowego może mocno odbiegać od 95% (Efron i Tibshirani 1993).

Metoda zawiera dwa przybliżenia. Pierwsze, statystyczne, to zastąpienie P przez $\widehat{P}_n$; jego jakość zależy od n i od tego, jak gładko $\hat{\theta}$ zależy od danych. Drugie, numeryczne, to skończone B; to przybliżenie poprawiamy po prostu, zwiększając B. Do błędu standardowego wystarcza zwykle B rzędu kilkuset, do kwantyli w przedziale – kilku tysięcy. Większe B wygładza wynik obliczeń, ale nie zastępuje większego n: tysiące replikacji pięciu pomiarów nadal opierają się na wiedzy zawartej w pięciu pomiarach.

Próba bootstrapowa zawiera niektóre obserwacje wielokrotnie, a innych wcale. Prawdopodobieństwo, że ustalona obserwacja nie zostanie wylosowana w żadnym z n losowań, wynosi

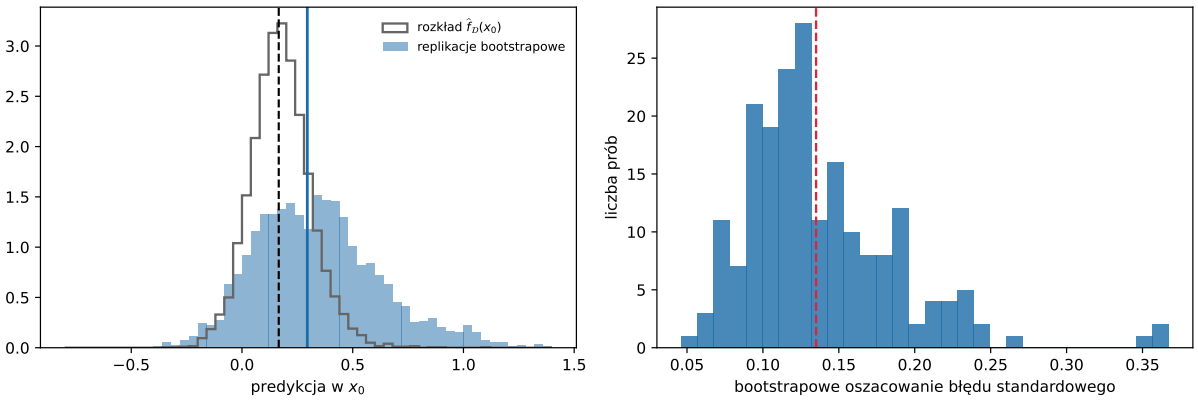
$$\left(1 - \frac{1}{n}\right)^n \xrightarrow[n\to\infty]{} e^{-1} \approx 0{,}368. \tag{5.6}$$

Próba bootstrapowa zawiera więc przeciętnie około 63,2% różnych obserwacji z próby, a pozostałe 36,8% w niej nie występują (Zadanie 5.4).

Rysunek 5.7 pokazuje działanie metody na przykładzie, w którym znamy prawdziwy rozkład. Szacujemy błąd standardowy predykcji wielomianu stopnia 3 w punkcie $x_0 = 0{,}95$, blisko krańca przedziału, gdzie dopasowania są szczególnie niestabilne.

```
prawdziwy błąd standardowy:          0.135
bootstrap w jednej próbie:           0.293
przedział percentylowy:              [-0.14   1.016]
mediana oszacowań w 200 próbach:     0.125
kwantyle 10% i 90% oszacowań:        [0.087 0.198]
```

Lewy panel pokazuje najważniejszą własność bootstrapu. Replikacje rozkładają się wokół predykcji $\hat{f}(x_0)$ z naszej próby, a nie wokół prawdziwej wartości $f^*(x_0)$: próba bootstrapowa „nie



Rysunek 5.7.: Bootstrap dla predykcji $\hat{f}(x_0)$ wielomianu stopnia 3 w punkcie $x_0 = 0{,}95$ ($n = 50$). Po lewej: dla jednej próby rozkład 2000 replikacji bootstrapowych (niebieski) na tle prawdziwego rozkładu $\hat{f}_{\mathcal{D}}(x_0)$ po 5000 próbach z populacji (szary kontur); pionowe linie: $\hat{f}(x_0)$ z tej próby (niebieska) i $f^*(x_0)$ (przerywana). Po prawej: bootstrapowe oszacowania błędu standardowego ($B = 200$) dla 200 różnych prób; czerwona linia to prawdziwy błąd standardowy.

wie" więcej o populacji niż próba, z której ją wylosowano. Same replikacje nie usuwają więc obciążenia względem $f^*(x_0)$; tutaj służą do oceny **rozrzutu** predykcji. W tej akurat próbie odtwarza go źle: replikacje są ponad dwa razy szersze niż prawdziwy rozkład. Prawy panel pokazuje, że to próba nietypowa. Oszacowania błędu standardowego skupiają się w pobliżu prawdziwej wartości, z medianą nieco poniżej niej, a w osiemdziesięciu procentach prób różnią się od niej o mniej niż połowę. Rozkład oszacowań jest jednak prawostronnie skośny, a próba z lewego panelu leży w jego dalekim ogonie. W takich próbach przy krańcu przedziału jest mało punktów i wielomiany dopasowane do prób bootstrapowych mocno się tam rozchodzą. Bootstrap jest zawodny dokładnie tam, gdzie estymator jest niestabilny.

Ocena ryzyka wymaga ponadto rozdzielenia obserwacji uczących i ocenianych. Bootstrapowe rozwiązania tego problemu, w tym estymatory .632 i .632+, omawia rozszerzenie 5.14.

5.11. Rozszerzenie: porównania sparowane

Materiał nieobowiązkowy

Wymagane są kowariancja, wariancja sumy i rozkład dwumianowy. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

Częściej niż wartość ryzyka interesuje nas, który z dwóch modeli, A czy B, jest lepszy. Naturalnym oszacowaniem różnicy ryzyk jest różnica oszacowań testowych. Jeśli oba modele oceniamy na **tym samym** zbiorze testowym, różnica ta jest średnią różnic strat $D_j = L_j^A - L_j^B$ na poszczególnych obserwacjach, a jej wariancja wynosi

$$\frac{\operatorname{Var}(L^A - L^B)}{m} = \frac{\tau_A^2 + \tau_B^2 - 2\operatorname{Cov}(L^A, L^B)}{m}.$$

Straty podobnych modeli bywają dodatnio skorelowane: oba mylą się na trudnych przypadkach i oba trafiają na łatwych. Dodatnia kowariancja odejmuje się wtedy od sumy wariancji, więc porównanie jest dokładniejsze niż przy niezależnych zbiorach testowych tej samej liczności. Przy

silnej korelacji różnica bywa oszacowana dokładniej niż każde z ryzyk z osobna. Porównując modele, należy zatem korzystać z par strat na tych samych obserwacjach, a nie z dwóch oddzielnych przedziałów ufności.

Przy stracie 0–1 rachunek ma prostą postać. Obserwacje, na których oba modele się mylą albo oba trafiają, nic nie mówią o różnicy. Liczą się tylko obserwacje sporne: n_{AB} takich, na których myli się tylko A, i n_{BA} takich, na których myli się tylko B. Jeśli oba modele mają to samo ryzyko, to każda obserwacja sporna jest z równym prawdopodobieństwem jednego lub drugiego rodzaju. Warunkowo przy ustalonej liczbie sporów n_{AB} ma więc rozkład dwumianowy z parametrami $n_{AB}+n_{BA}$ i $1/2$. Na tym opiera się **test McNemara**, polecany do porównywania dwóch klasyfikatorów na jednym zbiorze testowym (Dietterich 1998). Przykład: na $m = 1000$ obserwacjach model A myli się 100 razy, a model B – 120 razy. Dwa oddzielne przedziały ufności wyraźnie na siebie nachodzą: różnica 0,02 to tylko około 1,4 błędu standardowego różnicy dwóch niezależnych oszacowań. Jeśli jednak modele różnią się na 40 obserwacjach, z których na 30 myli się tylko B, a na 10 tylko A, to przy równości ryzyk wynik tak skrajny jak 10 do 30 ma prawdopodobieństwo około 0,002. Przewaga modelu A jest dobrze udokumentowana (Zadanie 5.3).

5.12. Rozszerzenie: LOOCV i liniowe wygładzanie

Materiał nieobowiązkowy

Wymagane są rachunek algebraiczny i zapis macierzowy predykcji. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

Błąd uczący zaniża ryzyko, bo każdy punkt uczący wpływa na własną predykcję. W regresji k-NN (3.1) ten wpływ ma prostą postać: wynik y_i wchodzi do predykcji w $\mathbf{x}_i$ z wagą $1/k$. Pozwala to wyrazić resztę „pozostaw jeden” przez resztę na zbiorze uczącym. Niech wszystkie odległości między punktami będą różne, aby nie było remisów, i niech $k > 1$. Każdy punkt uczący $\mathbf{x}_i$ należy do swojego otoczenia $N_k(\mathbf{x}_i)$, bo sam od siebie ma odległość zero. Predykcja w punkcie uczącym to więc

$$\hat{f}(\mathbf{x}_i) = \frac{1}{k}\Big(y_i + \sum_{j \in N_k(\mathbf{x}_i),\, j \neq i} y_j\Big) = \frac{1}{k}\, y_i + \frac{k-1}{k}\, \hat{f}^{(-i)}(\mathbf{x}_i),$$

gdzie $\hat{f}^{(-i)}(\mathbf{x}_i)$ jest średnią wyników $k-1$ pozostałych sąsiadów. Te $k-1$ punktów to dokładnie najbliżsi sąsiedzi $\mathbf{x}_i$ po usunięciu obserwacji i ze zbioru uczącego, więc $\hat{f}^{(-i)}$ jest predyktorem $(k-1)$-NN dopasowanym bez obserwacji i. Odejmując obie strony od y_i, dostajemy

$$y_i - \hat{f}(\mathbf{x}_i) = \frac{k-1}{k}\,(y_i - \hat{f}^{(-i)}(\mathbf{x}_i)). \tag{5.7}$$

Reszta na zbiorze uczącym jest więc resztą „pozostaw jeden” pomniejszoną o czynnik $(k-1)/k$. Stąd błąd LOOCV reguły $(k-1)$-NN jest równy błędowi uczącemu reguły k-NN pomnożonemu przez $\big(k/(k-1)\big)^2$ (Zadanie 5.5). Dla dużego k ten czynnik wynosi w przybliżeniu $1 + 2/k$, co zgadza się z wynikiem zadania 4.4: optymizm błędu uczącego reguły k-NN jest rzędu $2\sigma^2/k$.

Zapis $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$ oznacza, że predykcje na zbiorze uczącym są liniowymi kombinacjami wyników. Element S_{ii} jest wagą, jaką predykcja dla obserwacji i przypisuje jej własnemu wynikowi. Dla regresji k-NN wynosi $1/k$. Wyprowadzony wyżej wzór ma więc mianownik $1-S_{ii}$, ale po usunięciu obserwacji ocenia regułę $(k-1)$-NN.

W metodzie najmniejszych kwadratów, w tym regresji wielomianowej z rozdziału 4, reszta „pozostaw jeden” także wynosi

$$\frac{y_i - \hat{f}(\mathbf{x}_i)}{1 - S_{ii}}.$$

Tutaj po usunięciu obserwacji dopasowujemy tę samą rodzinę modeli, o ile nadal jest to możliwe jednoznacznie i $S_{ii} < 1$. Tożsamość wynika z własności dopasowania najmniejszych kwadratów (Hastie i in. 2009, rozdz. 7.10); samo istnienie macierzy $\mathbf{S}$ nie wystarcza, by gwarantowała ją dowolna metoda liniowego wygładzania.

Dzielenie przez $1 - S_{ii}$ pokazuje wpływ własnej obserwacji: przy dużym S_{ii} reszta ucząca może być dużo mniejsza od reszty „pozostaw jeden". Pozwala też obliczyć LOOCV z jednego dopasowania zamiast n. Do macierzy $\mathbf{S}$ i tego wzoru wrócimy przy regresji liniowej.

5.13. Rozszerzenie: co dokładniej szacuje CV

Materiał nieobowiązkowy

Wymagane są wariancja, kowariancja i wartości oczekiwane warunkowe. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

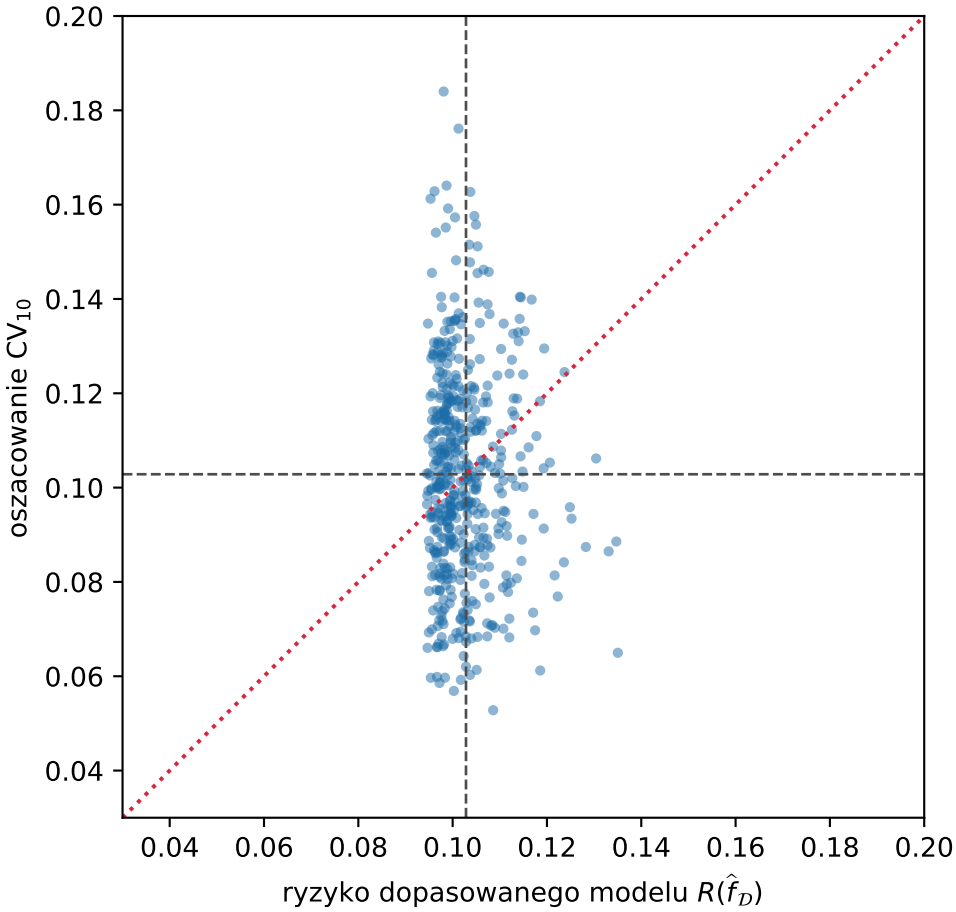
Wariancja CV zależy zarówno od nakładania się zbiorów uczących, jak i od stabilności metody. Przy dużym K zbiory te pokrywają się prawie całkowicie. Predyktory $\widehat{f}^{(-r)}$ korzystają więc z podobnych danych, a straty z różnych części mogą być zależne. Przy dodatnich kowariancjach średnia ma większą wariancję niż średnia niezależnych wielkości o tych samych wariancjach (1). Z tego powodu często mówi się, że LOOCV ma dużą wariancję. Z drugiej strony przy dużym K każdy predyktor dostaje więcej danych, a przy $K = n$ wynik nie zależy od losowania podziału. Który efekt przeważa, zależy od metody. Sprawdźmy to na naszym przykładzie: dla wielomianu stopnia 3 i $n = 50$ wylosowaliśmy 500 prób i w każdej policzyliśmy CV_K dla $K = 2, 5, 10, 50$ oraz, całkowaniem, prawdziwe ryzyko dopasowanego modelu.

```
ryzyko oczekiwane przy n = 50: 0.1028
 K   uczących   E[R] przy n(K-1)/K   średnia CV   odch. std. CV
 2         25               0.1176       0.1143          0.0349
 5         40               0.1057       0.1041          0.0233
10         45               0.1043       0.1029          0.0221
50         49               0.1034       0.1020          0.0215
```

Średnie oszacowań układają się zgodnie z (5.5). Dla $K = 2$ średnia jest bliska ryzyku metody uczonej na 25 obserwacjach i wyraźnie wyższa niż ryzyko przy $n = 50$. Dla $K \geq 5$ pesymizm jest już mały w porównaniu z rozrzutem oszacowania. Odchylenie standardowe maleje z K, ale dla $K = 5, 10, 50$ jest prawie takie samo. W tym przykładzie LOOCV nie ma więc większej wariancji niż walidacja dziesięciokrotna. Wariancja LOOCV bywa duża przy metodach niestabilnych, których dopasowanie zmienia się skokowo przy niewielkiej zmianie danych (Arlot i Celisse 2010). Przy małym K niestabilność dotyka też walidacji krzyżowej: wielomian wysokiego stopnia uczony na połowie próby czasem „ucieka" przy krańcach przedziału, jak na rysunku 4.2, i pojedyncza część daje wtedy ogromny błąd.

5.13.1. Co szacuje walidacja krzyżowa

Z (5.5) wynika, że walidacja krzyżowa jest oszacowaniem ryzyka oczekiwanego metody, a nie ryzyka modelu dopasowanego do naszej próby. Można by jednak sądzić, że skoro oszacowanie liczymy z naszej próby, to przynajmniej podąża za ryzykiem naszego modelu: w próbach, z których wyszedł model gorszy niż przeciętny, powinno być wyższe. Rysunek 5.8 pokazuje, że w tym przykładzie taki związek jest słaby.



Rysunek 5.8.: Oszacowanie dziesięciokrotną walidacją krzyżową a ryzyko dopasowanego modelu $R(\hat{f}_{\mathcal{D}})$ dla 500 prób liczności $n = 50$ (wielomian stopnia 3). Linie przerywane: ryzyko oczekiwane metody $\overline{R}_n$. Linia kropkowana: prosta $y = x$.

```
odch. std. ryzyka modelu:  0.0090
odch. std. CV_10:          0.0221
korelacja:                 -0.022
```

Chmura punktów jest wydłużona w pionie i nie układa się wzdłuż przekątnej. Ryzyko dopasowanego modelu zmienia się od próby do próby niewiele, a oszacowanie walidacją krzyżową – ponad dwa razy bardziej, i obie wielkości są praktycznie nieskorelowane. Większość rozrzutu oszacowania pochodzi z szumu w n obserwacjach, na których je liczymy, a nie z różnic między dopasowanymi modelami. Środek chmury leży blisko przecięcia linii przerywanych, bo przy $K = 10$ ryzyka oczekiwane dla 45 i 50 obserwacji są tutaj zbliżone. Wynik CV słabo informuje jednak, czy model z konkretnej próby jest lepszy, czy gorszy od przeciętnego. Podobny obraz w przykładzie klasyfikacyjnym przedstawiają Hastie i in. (2009, rozdz. 7.12). Bates i in. (2024, tw. 1) pokazują dokładniejszy wynik dla modelu liniowego z niezależnym szumem normalnym o stałej wariancji, dopasowanego metodą najmniejszych kwadratów i ocenianego stratą kwadratową: przy ustalonej macierzy cech wynik CV jest niezależny od ryzyka dopasowanego modelu. Nie jest to twierdzenie o każdej metodzie i każdym rozkładzie danych. Nasza symulacja ilustruje słaby związek obu wielkości, ale nie dowodzi spełnienia tych założeń. Także równość (5.5) dotyczy liczności $n(K-1)/K$, a nie n. Niezależny test pozwala bezpośrednio ocenić konkretny, ustalony predyktor.

5.13.2. Ograniczenia prostych oszacowań niepewności

Wynik walidacji krzyżowej podaje się zwykle z błędem standardowym. Najprostszy przepis traktuje n strat z (5.3) jak straty na zbiorze testowym i dzieli ich odchylenie standardowe przez $\sqrt{n}$. Te straty nie są jednak niezależne: każda para obserwacji z różnych części ma wspólną większość zbioru uczącego. Bengio i Grandvalet (2004) wykazali, że na podstawie jednego wyniku K-krotnej walidacji nie da się zbudować uniwersalnego estymatora jej wariancji, nieobciążonego dla wszystkich rozkładów. Wynik ten nie wyklucza estymacji przy dodatkowych założeniach. Naiwny błąd standardowy jest zwykle zaniżony. W symulacji z rysunku 5.8 wygląda to tak:

```
rzeczywiste odch. std. CV_10:      0.0221
średni naiwny błąd standardowy:    0.0202
pokrycie przedziału +- 1,96 se:    0.890
```

Naiwny błąd standardowy jest tu zaniżony o około 10%, a przedział, zbudowany jako wynik CV plus/minus 1,96 naiwnych błędów standardowych, obejmuje przybliżone $\overline{R}_{50}$ w około 89% prób. W tym porównaniu oprócz oszacowania wariancji znaczenie ma różnica między licznościami uczenia 45 i 50. Przy metodach mniej stabilnych różnica bywa większa. Poprawne przedziały ufności dla walidacji krzyżowej wymagają dodatkowej pracy obliczeniowej (Bates i in. 2024). Naiwna miara może służyć orientacji przy wyborze, ale nie zastępuje uzasadnienia przedziału ufności ani testu różnicy ryzyk.

5.14. Rozszerzenie: bootstrapowe oszacowania ryzyka

Materiał nieobowiązkowy

Wymagane są podstawy bootstrapu i rozróżnienie ryzyka modelu oraz metody. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

Bootstrap można też wykorzystać do szacowania ryzyka. Pierwszy pomysł – uczyć predyktor na próbie bootstrapowej i oceniać go na całej próbie – jest optymistyczny, bo około 63% obserwacji oceniających było w zbiorze uczącym. Poprawka nasuwa się sama: każdą obserwację i oceniać tylko predyktorami z tych prób bootstrapowych, które jej nie zawierają. Średnia takich strat po wszystkich obserwacjach to **bootstrap „pozostaw jeden”**, oznaczany $\widehat{R}^{(1)}$. Oceniana obserwacja nie wpływa wtedy na dopasowanie, ale predyktor uczy się na około $0{,}632n$ różnych obserwacjach, więc $\widehat{R}^{(1)}$ bywa pesymistyczne.

Efron (1983) zaproponował, by oba błędy zrównoważyć, łącząc pesymistyczne $\widehat{R}^{(1)}$ z optymistycznym błędem uczącym $\overline{\mathrm{err}}$:

$$\widehat{R}^{(.632)} = 0{,}368\,\overline{\mathrm{err}} + 0{,}632\,\widehat{R}^{(1)}.$$

Waga 0,632 to przeciętny odsetek obserwacji wylosowanych do próby bootstrapowej (5.6); jej uzasadnienie jest przybliżone (Hastie i in. 2009, rozdz. 7.11). Estymator ten zawodzi przy metodach, które silnie dopasowują się do próby. Dla reguły jednego najbliższego sąsiada $\overline{\mathrm{err}} = 0$, więc nawet przy danych bez żadnej informacji, gdy ryzyko wynosi 1/2, dostajemy około $0{,}632 \cdot 0{,}5 \approx 0{,}32$. Wersja **.632+** (Efron i Tibshirani 1997) przesuwa wagę w stronę $\widehat{R}^{(1)}$, gdy różnica między $\widehat{R}^{(1)}$ a $\overline{\mathrm{err}}$ jest duża w porównaniu z błędem klasyfikatora bezwartościowego. Dla dwóch klas błędem tym jest $\hat{\gamma} = \hat{p}_1(1-\hat{q}_1) + (1-\hat{p}_1)\hat{q}_1$, gdzie $\hat{p}_1$ to odsetek klasy 1 w próbie, a $\hat{q}_1$ – odsetek obserwacji, którym predyktor przypisuje klasę 1. Względny stopień nadmiernego dopasowania $\widehat{R} = (\widehat{R}^{(1)} - \overline{\mathrm{err}})/(\hat{\gamma} - \overline{\mathrm{err}})$, obcięty do przedziału $[0,1]$, wyznacza wagę

$$\widehat{w} = \frac{0{,}632}{1 - 0{,}368\,\widehat{R}}, \qquad \widehat{R}^{(.632+)} = (1-\widehat{w})\,\overline{\mathrm{err}} + \widehat{w}\,\widehat{R}^{(1)}.$$

Bez nadmiernego dopasowania ($\widehat{R} = 0$) jest to estymator .632, przy skrajnym ($\widehat{R} = 1$) – sam $\widehat{R}^{(1)}$.

Porównajmy te estymatory z dziesięciokrotną walidacją krzyżową na zbiorze dwóch półksiężyców z rozdziału 3, dla klasyfikatorów 1-NN i 15-NN uczonych na $n = 100$ obserwacjach. Prawdziwe ryzyko dopasowanego modelu szacujemy na 20 000 obserwacjach testowych; jego błąd standardowy jest rzędu 0,002.

1-NN	średnia	odch. std.	pierwiastek ze śr. kw. błędu
prawdziwe ryzyko	0.132	0.015	0.000
błąd uczący	0.000	0.000	0.133
bootstrap (1)	0.144	0.035	0.032
.632	0.091	0.022	0.045
.632+	0.103	0.028	0.038
CV, K = 10	0.140	0.039	0.036

15-NN	średnia	odch. std.	pierwiastek ze śr. kw. błędu
prawdziwe ryzyko	0.097	0.006	0.000
błąd uczący	0.094	0.026	0.025
bootstrap (1)	0.122	0.026	0.036
.632	0.112	0.025	0.028
.632+	0.112	0.025	0.029
CV, K = 10	0.111	0.030	0.033

Wyniki potwierdzają, że żaden estymator nie wygrywa zawsze. Dla 1-NN błąd uczący jest zerowy, a .632 wyraźnie zaniża ryzyko. Wersja .632+ poprawia go, ale nie do końca, a $\widehat{R}^{(1)}$ i walidacja

krzyżowa są lekko pesymistyczne. Dla 15-NN, który dopasowuje się do próby słabo, sam błąd uczący jest bliski ryzyku, a pozostałe estymatory nieco je zawyżają. W obu przypadkach odchylenia standardowe oszacowań są wyraźnie większe niż odchylenie standardowe samego ryzyka, a dla 15-NN – kilkakrotnie. Każdy estymator trafia przeciętnie mniej więcej we właściwe miejsce, ale pojedyncze oszacowanie z próby liczności 100 jest niepewne – to ten sam wniosek, który dał rysunek 5.8. W praktyce dominuje walidacja krzyżowa, bo jest prostsza, nie wymaga poprawek zależnych od metody i nie zakłada nic o stracie; estymatory bootstrapowe bywają przydatne przy bardzo małych próbach.

Uwagi bibliograficzne

Zbiór walidacyjny, walidację krzyżową i bootstrap na poziomie tego rozdziału przedstawiają James i in. (2023, rozdz. 5). Pełniejsze omówienie, z analizą optymizmu błędu uczącego, walidacji krzyżowej, estymatorów bootstrapowych .632 i .632+ oraz różnicy między ryzykiem modelu a ryzykiem metody, zawiera Hastie i in. (2009, rozdz. 7); przykład z wyborem cech przed walidacją pochodzi z Hastie i in. (2009, rozdz. 7.10.2). Przegląd wariantów walidacji krzyżowej i ich własności teoretycznych, z zaleceniami co do wyboru K, dają Arlot i Celisse (2010).

Walidację krzyżową jako ogólną metodę wyboru i oceny predyktorów sformułował M. Stone (1974). Pytanie, co właściwie szacuje, i jak budować dla niej poprawne przedziały ufności, analizują Bates i in. (2024). Brak uniwersalnego nieobciążonego estymatora wariancji z pojedynczej CV wykazali Bengio i Grandvalet (2004), a testy statystyczne do porównywania klasyfikatorów, w tym test McNemara, omawia Dietterich (1998).

Optymizm wyniku walidacji krzyżowej po wyborze modelu i zagnieżdżoną walidację krzyżową opisali Varma i Simon (2006), a skalę tego zjawiska przy porównywaniu metod – Cawley i Talbot (2010). Klasycznym przykładem wycieku przez wybór cech jest praca Ambroise i McLachlan (2002). Korzyści z przeszukiwania losowego w porównaniu z siatką analizują Bergstra i Bengio (2012).

Rozszerzenia tego rozdziału rozwijają rachunek porównań sparowanych, LOOCV i niepewności CV oraz bootstrapowych oszacowań ryzyka. Bootstrap wprowadził Efron (1979). Estymator .632 zaproponował Efron (1983) w pracy o szacowaniu błędu reguł predykcyjnych, a wersję .632+ podali Efron i Tibshirani (1997). Systematyczny wykład metody, z przedziałami ufności i wieloma przykładami, zawiera podręcznik Efron i Tibshirani (1993).

Zadania

Na początek wykonaj Zadanie 5.9 po sekcji 5.4 oraz Zadanie 5.10 po sekcji 5.6. Następnie przejdź do oceny testowej, błędów procedury i bootstrapu. W zadaniach 5.3 i 5.4 można najpierw pominąć podpunkty oznaczone jako rozszerzenia. Zadania 5.5 i 5.6 są w całości rozszerzeniami. Dwa zadania laboratoryjne 5.7 i 5.8 prowadzą od pojedynczej próby do powtarzanych symulacji.

Zadanie 5.1. Ustalony klasyfikator popełnił 16 błędów na 200 niezależnych obserwacjach testowych.

a) Oblicz oszacowanie ryzyka i jego błąd standardowy. Podaj przybliżony przedział ufności na poziomie 95% i wyjaśnij, co oznacza ten poziom.
b) Zakładając ryzyko około 8%, oszacuj, ile obserwacji testowych potrzeba, aby połowa szerokości takiego przedziału wynosiła 0,01. A 0,002? Dlaczego pięciokrotna poprawa dokładności wymaga dwudziestopięciokrotnie większej próby?

c) Wykaż, że $R(1-R) \leq 1/4$, i podaj liczność wystarczającą w przybliżeniu normalnym dla zadanej szerokości niezależnie od ryzyka. Ile razy jest ona większa od wyniku z punktu b)?
d) Klasa 1 stanowi 1% populacji. Interesuje nas czułość, czyli odsetek jej obserwacji rozpoznanych poprawnie. Najpierw oblicz, **ile obserwacji klasy 1** potrzeba do oszacowania czułości około 0,9 z dokładnością $\pm 0{,}02$ na poziomie 95%. Jak dużą próbę z populacji trzeba zebrać, aby oczekiwana liczba obserwacji tej klasy była taka? Czy gwarantuje to uzyskanie wymaganej liczby przypadków klasy 1?

Zadanie 5.2. Każda z opisanych procedur zawiera błąd metodologiczny. Wskaż go, wyjaśnij, jak może zniekształcić ocenę, i zaproponuj poprawkę. Nie zakładaj, że każdy błąd daje widoczny efekt o tym samym kierunku w każdej próbie.

a) Wszystkie cechy standaryzujemy na całej próbie, a następnie przeprowadzamy dziesięciokrotną walidację krzyżową klasyfikatora k-NN.
b) Dzielimy dane na zbiór uczący i testowy. Dla $k = 1, \ldots, 50$ uczymy klasyfikator k-NN na zbiorze uczącym, wybieramy k o najmniejszym błędzie testowym i ten błąd podajemy jako ocenę modelu.
c) Dane zawierają po kilka wizyt każdego pacjenta; obserwacją jest wizyta, czyli wyniki badań i postawiona diagnoza. Model ma diagnozować pacjentów, których dotąd nie badaliśmy. Jego błąd dla takich pacjentów szacujemy pięciokrotną walidacją krzyżową, dzieląc wizyty losowo na pięć części.
d) Model prognozuje dzienną sprzedaż na podstawie sprzedaży z poprzednich dni. Obserwacją jest dzień t: cechami są wartości sprzedaży z dni $t-1, \ldots, t-7$, odpowiedzią sprzedaż w dniu t. Tak zbudowane obserwacje dzielimy losowo na dziesięć części i oceniamy model dziesięciokrotną walidacją krzyżową.
e) Klasa 1 jest rzadka, więc przed walidacją krzyżową powielamy jej obserwacje, aż klasy staną się równoliczne.

Zadanie 5.3. Dwa klasyfikatory oceniono na tym samym zbiorze testowym liczności $m = 1000$. Model A pomylił się 100 razy, model B – 120 razy. Na 70 obserwacjach pomyliły się oba.

a) Wyznacz liczby n_{AB} i n_{BA} obserwacji, na których myli się tylko jeden model. Na ilu oba trafiły? Oblicz różnicę oszacowań ryzyka.
b) Wyjaśnij, dlaczego przypadki, na których modele są zgodne, nie wpływają na tę różnicę. Co zmieni się w liczbie sporów, gdy oba modele pomylą się na 90 obserwacjach, zachowując te same łączne liczby błędów?
c) **Rozszerzenie: test McNemara.** Wymagane są rozkład dwumianowy i rozszerzenie 5.11. Przy równych ryzykach wyznacz prawdopodobieństwo wyniku co najmniej tak skrajnego jak obserwowany podział sporów (w dowolną stronę). Powtórz dla wariantu z punktu b). Dlaczego ta sama różnica odsetków daje inny wynik testu?
d) **Rozszerzenie: wariancja porównania sparowanego.** Wymagane są wariancja i kowariancja. Oblicz błąd standardowy różnicy ryzyk z par strat i porównaj go z wynikiem otrzymanym przy potraktowaniu ocen jako niezależnych. Wyprowadź estymator wariancji różnicy strat wyrażony przez n_{AB}, n_{BA} i m.

Zadanie 5.4. Mamy pięć obserwacji o indeksach $1, 2, 3, 4, 5$. Wylosowane ze zwracaniem indeksy jednej próby bootstrapowej to $2, 2, 5, 1, 2$.

a) Ile różnych obserwacji zawiera ta próba? Które zostały pominięte? Czy kolejne tysiąc replikacji zwiększa liczbę danych z populacji?
b) Dla próby liczności n wykaż, że prawdopodobieństwo pominięcia ustalonej obserwacji wynosi $(1-1/n)^n$ i dąży do e^{-1}. Oblicz je dla $n = 10, 50, 1000$.

c) Wyznacz oczekiwaną liczbę różnych obserwacji w próbie bootstrapowej. Sprawdź wyniki b) i c) symulacją.
d) **Rozszerzenie: wspólne obserwacje replikacji.** Wymagane są niezależność warunkowa losowań przy ustalonej próbie i rachunek prawdopodobieństwa. Wyznacz prawdopodobieństwo, że ustalona obserwacja znajdzie się w obu z dwóch niezależnie wylosowanych replikacji. Odnieś wynik do podpunktu c) w

   1.

Zadanie 5.5. Rozszerzenie: LOOCV dla najbliższych sąsiadów. Wymagane są rachunek algebraiczny, rozkład błędu kwadratowego i rozszerzenie 5.12.

a) Wyprowadź (5.7) i wywnioskuj z niego, że błąd LOOCV reguły $(k-1)$-NN jest równy błędowi uczącemu reguły k-NN pomnożonemu przez $\big(k/(k-1)\big)^2$. Gdzie korzystasz z założenia, że odległości są różne?
b) Sprawdź tę równość numerycznie: dla danych z rozdziału 4 ($n = 100$) i $k = 2, 5, 20$ porównaj wynik `cross_val_score` z `LeaveOneOut()` dla `KNeighborsRegressor(n_neighbors=k-1)` z przeskalowanym błędem uczącym `KNeighborsRegressor(n_neighbors=k)`.
c) Dlaczego ta sztuczka nie daje LOOCV reguły k-NN, lecz $(k-1)$-NN? Co z niej wynika dla $k = 1$?
d) W ustalonym układzie z zadania 4.3, przy zerowym obciążeniu, oblicz wartość oczekiwaną błędu uczącego reguły k-NN i przeskaluj ją jak w punkcie a). Porównaj wynik z oczekiwanym błędem predykcji reguły $(k-1)$-NN w punktach uczących, wyznaczonym z (4.6).

Zadanie 5.6. Rozszerzenie: minimum losowych oszacowań. Wymagane są rozkład normalny, wartość oczekiwana maksimum i całkowanie. Punktem wyjścia jest rachunek optymizmu w sekcji 5.6.

Mamy M kandydatów o tym samym ryzyku R, a ich oszacowania $\widehat{R}_1, \dots, \widehat{R}_M$ są niezależne i mają rozkład normalny $\mathcal{N}(R, s^2)$.

a) Wykaż, że $\mathbb{E}[\min_j \widehat{R}_j] = R - s\,c_M$, gdzie c_M to wartość oczekiwana maksimum M niezależnych zmiennych o rozkładzie $\mathcal{N}(0,1)$.
b) Wyznacz c_2 analitycznie. (Wskazówka: $\max(Z_1, Z_2) = \frac{1}{2}(Z_1 + Z_2) + \frac{1}{2}|Z_1 - Z_2|$.)
c) Oszacuj symulacyjnie c_M dla $M = 5, 10, 100$. Przyjmując $s = 0{,}05$, porównaj otrzymany optymizm z rysunkiem 5.5.
d) Powtórz symulację dla oszacowań skorelowanych: każde dwa mają współczynnik korelacji $\rho \in [0,1]$. (Wskazówka: $\widehat{R}_j = R + s(\sqrt{\rho}\,Z_0 + \sqrt{1-\rho}\,Z_j)$.) Jak optymizm zależy od ρ? Wyjaśnij, dlaczego krzywa na rysunku 5.5 opada wolniej niż w punkcie c).

Zadanie 5.7. Rozwiń symulację z rysunku 5.2. Najpierw wykonaj oba sposoby na jednej próbie: wskaż, kiedy błędny sposób wykorzystuje klasy obserwacji oceniających, i porównaj wyniki. Następnie:

a) Zbadaj, jak średnie oszacowanie przy złym sposobie zależy od liczby wybieranych cech $q \in \{1, 10, 100, 1000\}$ i od liczby cech $p \in \{100, 1000, 5000\}$, sprawdzając tylko kombinacje $q \le p$. Wyjaśnij obserwowane zależności.
b) Zbuduj poprawną procedurę w scikit-learn jako potok `make_pipeline(SelectKBest(f_classif, k=100), KNeighborsClassifier(n_neighbors=1))` i oceń ją funkcją `cross_val_score`. Sprawdź, że wynik zgadza się z dobrym sposobem.
c) Zastąp wybór cech standaryzacją wyznaczaną na całej próbie i sprawdź, czy ten wyciek ma mierzalny wpływ na oszacowanie.

Zadanie 5.8. Dane pochodzą z rozkładu dwóch półksiężyców z szumem 0,30 (`make_moons`), $n = 200$. Prawdziwe ryzyko szacuj na zbiorze testowym liczności 20 000.

a) Dla jednej próby narysuj na jednym wykresie wynik dziesięciokrotnej walidacji krzyżowej i ryzyko klasyfikatora k-NN dla $k = 1, 3, \ldots, 99$. Zaznacz k wybrane walidacją krzyżową, regułą jednego błędu standardowego i k o najmniejszym ryzyku.
b) Powtórz punkt a) dla 100 prób. Narysuj histogram wybranych k. Oblicz średnią stratę wynikającą z wyboru, czyli różnicę między ryzykiem wybranego modelu a najmniejszym ryzykiem wśród kandydatów, dla obu reguł wyboru.
c) Oblicz średnią różnicę między najmniejszym wynikiem walidacji krzyżowej a ryzykiem wybranego modelu. Odnieś wynik do twierdzenia 5.2. Wskaż różnicę między założeniami twierdzenia a tym eksperymentem: CV uczy na mniejszych próbach, a ryzyko mierzymy po dopasowaniu do wszystkich danych.

Zadanie 5.9. Dwanaście obserwacji podzielono na trzy części po cztery. Tabela podaje liczby błędów kandydatów w ocenianych częściach; każdy model uczono na pozostałych ośmiu obserwacjach.

Liczba sąsiadów k	Część 1	Część 2	Część 3
1	1	2	1
3	1	0	2
5	0	1	1

a) Oblicz wynik CV każdego kandydata i wybierz k według minimum. Ile dopasowań wykonano łącznie? Co uśredniasz: predykcje czy straty?
b) Dla wybranego k wskaż, na ilu obserwacjach uczono model, który przewidział klasę pierwszej obserwacji z części 2. Czy widział jej klasę?
c) W innym podziale części liczą $3, 4, 5$ obserwacji, a ustalony kandydat popełnia w nich $0, 1, 2$ błędy. Oblicz wynik CV po obserwacjach i porównaj go z nieważoną średnią trzech odsetków. Który rachunek odpowiada definicji 5.1?
d) Czy najmniejszy wynik tabeli jest niezależną końcową oceną wybranego modelu? Na ilu obserwacjach dopasujesz go po zakończeniu wyboru?

Zadanie 5.10. Mamy 200 obserwacji, pięć części zewnętrznych i cztery wewnętrzne. Procedura wybiera minimum błędu CV spośród $k = 3, 9, 21$ i dopasowuje potok ze standaryzacją.

a) Przejdź przez jeden krok zewnętrzny. Ile obserwacji odkładasz do oceny, ile zostaje do wyboru, na ilu uczysz pojedynczego kandydata w części wewnętrznej, a na ilu go walidujesz?
b) Wskaż dane używane do wyznaczenia parametrów standaryzacji w jednym dopasowaniu wewnętrznym. Co dopasowujesz od nowa po wyborze k i na jakich danych, zanim ocenisz wynik zewnętrzny?
c) W częściach zewnętrznych wybrano $k = 9, 21, 9, 3, 21$ i popełniono odpowiednio $4, 5, 3, 6, 2$ błędy. Oblicz ocenę procedury. Dlaczego nie wybieramy k z części o najmniejszym błędzie?
d) Jak uzyskasz końcowy model na wszystkich 200 obserwacjach? Czy wynik z punktu c) jest niezależną oceną tego konkretnego modelu?
e) Po obejrzeniu wyników zewnętrznych rozszerzasz listę kandydatów i zachowujesz wariant z mniejszą oceną zewnętrzną. Co stało się z rolą tych danych? Jak należałoby zaplanować ocenę takiej procedury?

Część II.

Modele liniowe

6. Regresja liniowa

Regresja liniowa pojawiała się w tej książce kilka razy, zawsze jako punkt odniesienia. W sekcji 1.9 była przykładem metody parametrycznej: niezależnie od liczby obserwacji szacujemy w niej tyle samo współczynników. W rozdziale 4 dopasowywaliśmy wielomiany gotową funkcją biblioteki NumPy, a w sekcji 4.8 stwierdziliśmy, że trafne założenie liniowości daje predyktor nieobciążony o wariancji rzędu $\sigma^2(p+1)/n$, bez względu na to, jak trudna byłaby ta sama zależność dla metody k-NN. W tym rozdziale wyprowadzamy te fakty.

Model liniowy służy jednak nie tylko predykcji. Jego współczynniki mają prostą interpretację, a przy dodatkowych założeniach umiemy policzyć, jak bardzo zmieniłyby się, gdybyśmy wylosowali inną próbę. Daje to narzędzia wnioskowania w sensie sekcji 1.7: przedziały ufności i testy hipotez. Będziemy je rozwijać na przykładzie danych *Advertising* (James i in. 2023, rozdz. 2.1). Dla 200 rynków zbiór podaje budżety reklamy produktu w telewizji (`TV`), radiu (`radio`) i prasie (`newspaper`), w tysiącach dolarów, oraz sprzedaż produktu (`sales`) w tysiącach sztuk. Interesują nas trzy pytania: czy wydatki na reklamę w ogóle wiążą się ze sprzedażą, które media się do tego przyczyniają i jak dokładnie możemy przewidzieć sprzedaż przy zadanym budżecie. Odpowiedź na każde z nich wymaga nie tylko dopasowania modelu, ale też oceny, ile w dopasowaniu jest przypadku.

Wnioskowanie opiera się na założeniach o modelu i błędach. Dlatego po nim rozszerzamy model o cechy jakościowe, interakcje i składniki nieliniowe (sekcje 6.6 i 6.7), a w sekcji 6.8 sprawdzamy na resztach, czy dane te założenia spełniają.

6.1. Model liniowy

Niech $\mathbf{X} = (X_1, \dots, X_p)$ będzie wektorem cech, a Y wynikiem. **Model regresji liniowej** zakłada, że

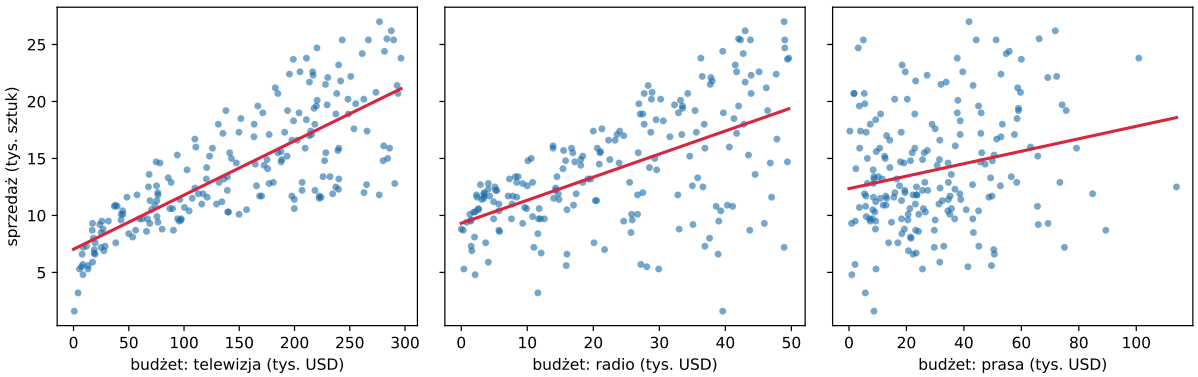
$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon, \qquad \mathbb{E}[\varepsilon \mid \mathbf{X}] = 0, \tag{6.1}$$

czyli że funkcja regresji $f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ jest funkcją liniową (ściślej: afiniczną) cech. Liczby $\beta_0, \dots, \beta_p$ są nieznanymi parametrami. Współczynnik β_0 nazywamy **wyrazem wolnym** (ang. *intercept*), a β_j dla $j \geq 1$ – **współczynnikiem regresji** dla cechy X_j.

Założenie (6.1) można czytać na dwa sposoby. Pierwsze odczytanie traktuje je jako twierdzenie o świecie: funkcja regresji naprawdę jest liniowa. Wtedy błąd aproksymacji z sekcji 4.6 jest zerowy, a cały błąd redukowalny pochodzi ze skończoności próby. Drugie odczytanie nie wymaga tej wiary. Jakakolwiek jest funkcja f^*, wśród funkcji liniowych cech istnieje taka, która przybliża ją najlepiej w sensie średniego kwadratu, i to ona jest celem estymacji. Metoda najmniejszych kwadratów z sekcji 6.2 ma sens przy obu odczytaniach. Wyniki z sekcji 6.3 i 6.5 opierają się na pierwszym.

Liniowość dotyczy parametrów, a nie cech. Regresja wielomianowa z rozdziału 4 jest modelem liniowym z cechami $x, x^2, \dots, x^d$: predykcja jest kombinacją liniową współczynników, choć jest nieliniową funkcją x. Wszystko, co wyprowadzimy dla modelu (6.1), stosuje się więc do niej bez zmian.

Wróćmy do danych *Advertising* ze wstępu do rozdziału. Rysunek 6.1 pokazuje sprzedaż na 200 rynkach w zależności od każdego z trzech budżetów osobno.



Rysunek 6.1.: Dane *Advertising*: sprzedaż w zależności od budżetu reklamy w telewizji, radiu i prasie dla 200 rynków. Linie to proste regresji sprzedaży względem każdego medium osobno.

Sprzedaż wyraźnie rośnie z budżetem telewizyjnym, słabiej z radiowym, a z prasowym ledwie. Rozrzut wokół prostej dla telewizji rośnie przy tym z budżetem. Każdy z wykresów pokazuje jednak tylko jedną cechę naraz, a budżety na różne media nie są od siebie niezależne. Wszystkie trzy uwzględnia model

$$\texttt{sales} = \beta_0 + \beta_1\,\texttt{TV} + \beta_2\,\texttt{radio} + \beta_3\,\texttt{newspaper} + \varepsilon. \tag{6.2}$$

! Współczynnik opisuje porównanie, nie interwencję

Współczynnik β_j mówi, o ile zmienia się średni wynik, gdy cecha X_j rośnie o jednostkę, **a pozostałe cechy się nie zmieniają**. W modelu (6.2) β_3 porównuje rynki, których budżety prasowe różnią się o tysiąc dolarów, a budżety telewizyjny i radiowy są takie same: na pierwszych sprzedaż jest przeciętnie o $1000\,\beta_3$ sztuk większa. Nachylenie prostej z prawego panelu rysunku 6.1 odpowiada na inne pytanie – porównuje rynki o różnym budżecie prasowym bez względu na pozostałe budżety. Dla danych *Advertising* obie liczby porównujemy w sekcji 6.2.1.

Obie opisują zależność w populacji, a **nie skutek interwencji**. Czy podniesienie budżetu prasowego na danym rynku zwiększyłoby sprzedaż o $1000\,\beta_3$ sztuk, zależy od tego, co jeszcze różni rynki o różnych budżetach – liczba mieszkańców, siła nabywcza, konkurencja – a tych cech model nie widzi.

6.2. Metoda najmniejszych kwadratów

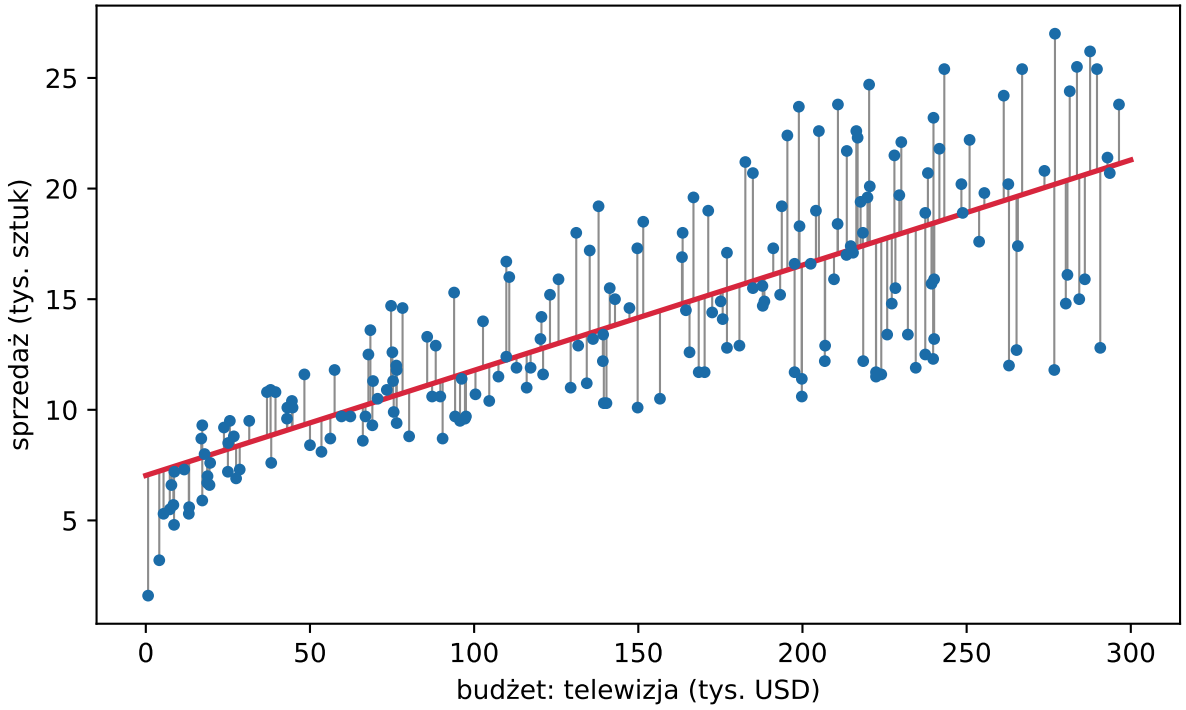
Zacznijmy od jednej cechy, budżetu telewizyjnego. Przez chmurę punktów z lewego panelu rysunku 6.1 można poprowadzić wiele prostych $\beta_0 + \beta_1 x$. Każda przewiduje dla rynku i sprzedaż $\beta_0 + \beta_1 x_i$ i myli się o $y_i - \beta_0 - \beta_1 x_i$, czyli o pionową odległość punktu od prostej. Którą prostą wybrać?

Kryterium znamy z sekcji 4.1, gdzie tak samo dopasowywaliśmy wielomiany: przy stracie kwadratowej minimalizujemy błąd na zbiorze uczącym, czyli ryzyko empiryczne (1.11). Dla prostej

jest on równy RSS/n, gdzie

$$\mathrm{RSS}(\beta_0, \beta_1) = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

jest **sumą kwadratów reszt**. **Metoda najmniejszych kwadratów** (ang. *ordinary least squares*, OLS) wybiera współczynniki minimalizujące RSS. Rysunek 6.2 pokazuje wybraną w ten sposób prostą i reszty, czyli pionowe odcinki, których kwadraty sumujemy.



Rysunek 6.2.: Regresja sprzedaży względem budżetu telewizyjnego metodą najmniejszych kwadratów. Pionowe odcinki to reszty $e_i = y_i - \hat{y}_i$; prosta minimalizuje sumę ich kwadratów.

Przyrównując do zera pochodne RSS względem β_0 i β_1, otrzymujemy dwa równania:

$$\sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) = 0, \qquad \sum_{i=1}^{n} x_i \, (y_i - \beta_0 - \beta_1 x_i) = 0.$$

Ich rozwiązaniem jest

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2}, \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \tag{6.3}$$

(Zadanie 6.1). Współczynnik kierunkowy to iloraz kowariancji z próby przez wariancję z próby, czyli próbkowy odpowiednik $\mathrm{Cov}(X, Y)/\mathrm{Var}\, X$. Tyle wynosi nachylenie prostej, która najlepiej przybliża funkcję regresji w drugim odczytaniu modelu. Wzór na $\hat{\beta}_0$ mówi, że prosta regresji przechodzi przez punkt $(\bar{x}, \bar{y})$. Z samych równań wynika, że reszty dopasowanej prostej, $e_i = y_i - \hat{y}_i$, sumują się do zera i są w próbie nieskorelowane z x_i.

Dla danych z rysunku 6.2 otrzymujemy $\hat{\beta}_0 \approx 7{,}03$ i $\hat{\beta}_1 \approx 0{,}0475$. Każdy dodatkowy tysiąc dolarów budżetu telewizyjnego wiąże się przeciętnie z 47,5 sztukami sprzedanego produktu więcej. Wyraz wolny to przewidywana sprzedaż przy zerowym budżecie telewizyjnym. Tutaj ma on sens, bo w danych są rynki z budżetem bliskim zera.

6.2.1. Regresja względem trzech mediów

Przy p cechach kryterium jest to samo. Suma kwadratów reszt

$$\mathrm{RSS}(\beta) = \sum_{i=1}^{n} \left(y_i - \beta_0 - \beta_1 x_{i1} - \cdots - \beta_p x_{ip}\right)^2 \tag{6.4}$$

jest funkcją wektora współczynników $\beta = (\beta_0, \ldots, \beta_p)^\top$, a OLS wybiera minimalizujący ją wektor $\widehat{\beta}$. Wzór na rozwiązanie podamy w następnej podsekcji; na razie liczy je funkcja `dopasuj`. Dopasujmy model (6.2) ze wszystkimi trzema mediami i porównajmy jego współczynniki ze współczynnikami trzech regresji z jedną cechą.

	regresja z jedną cechą	regresja z trzema cechami
TV	0.0475	0.0458
radio	0.2025	0.1885
newspaper	0.0547	-0.0010

Współczynniki przy telewizji i radiu prawie się nie zmieniają. Przy prasie zmienia się wszystko: w regresji z jedną cechą tysiąc dolarów wiąże się z 55 sztukami więcej, w regresji z trzema cechami – z praktycznie zerową zmianą, a nawet z lekkim spadkiem. Obie liczby są poprawne, ale odpowiadają na różne pytania. Pierwsza porównuje rynki o różnym budżecie prasowym bez względu na pozostałe budżety. Druga porównuje rynki o różnym budżecie prasowym i **tych samych** budżetach telewizyjnym i radiowym. Korelacja budżetów prasowego i radiowego w próbie wynosi 0,35: tam, gdzie dużo wydaje się na radio, wydaje się też więcej na prasę. W regresji z jedną cechą prasa przejmuje więc część zasługi radia. Współczynnik w regresji wielokrotnej jest równy współczynnikowi regresji $\mathbf{y}$ względem tej części cechy, której nie da się liniowo przewidzieć z pozostałych cech (Zadanie 6.9).

6.2.2. Zapis macierzowy

Rachunki dla p cech wygodnie prowadzić na macierzach. **Macierz projektowa $\mathbf{X}$** ma n wierszy i $p+1$ kolumn. Jej i-ty wiersz to $\tilde{\mathbf{x}}_i^\top = (1, x_{i1}, \ldots, x_{ip})$: cechy obserwacji i poprzedzone jedynką, która odpowiada wyrazowi wolnemu. Wyniki tworzą wektor $\mathbf{y} = (y_1, \ldots, y_n)^\top$. Dla modelu (6.2) pierwsze rynki z danych *Advertising* dają

$$\mathbf{X} = \begin{pmatrix} 1 & 230{,}1 & 37{,}8 & 69{,}2 \\ 1 & 44{,}5 & 39{,}3 & 45{,}1 \\ 1 & 17{,}2 & 45{,}9 & 69{,}3 \\ \vdots & \vdots & \vdots & \vdots \end{pmatrix}, \qquad \mathbf{y} = \begin{pmatrix} 22{,}1 \\ 10{,}4 \\ 9{,}3 \\ \vdots \end{pmatrix},$$

a kolumny $\mathbf{X}$ to kolejno jedynki, `TV`, `radio` i `newspaper`. Współrzędna i wektora $\mathbf{X}\beta$ to $\tilde{\mathbf{x}}_i^\top \beta = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}$, czyli predykcja dla obserwacji i. Ten sam wektor jest kombinacją liniową kolumn $\mathbf{X}$ o wagach $\beta_0, \ldots, \beta_p$:

$$\mathbf{X}\beta = \beta_0 \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} + \beta_1 \begin{pmatrix} x_{11} \\ \vdots \\ x_{n1} \end{pmatrix} + \cdots + \beta_p \begin{pmatrix} x_{1p} \\ \vdots \\ x_{np} \end{pmatrix}. \tag{6.5}$$

Zbiór wszystkich takich kombinacji, czyli podprzestrzeń $\mathbb{R}^n$ rozpiętą na kolumnach $\mathbf{X}$, oznaczamy $\mathcal{C}(\mathbf{X})$.

Suma kwadratów reszt (6.4) to $\mathrm{RSS}(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2$. Rozpisując kwadrat normy,

$$\mathrm{RSS}(\beta) = \mathbf{y}^\top\mathbf{y} - 2\beta^\top\mathbf{X}^\top\mathbf{y} + \beta^\top\mathbf{X}^\top\mathbf{X}\beta.$$

Jest to funkcja kwadratowa β, a jej gradient wynosi $-2\mathbf{X}^\top\mathbf{y} + 2\mathbf{X}^\top\mathbf{X}\beta$. Przyrównując go do zera, otrzymujemy **równania normalne**

$$\mathbf{X}^\top\mathbf{X}\,\beta = \mathbf{X}^\top\mathbf{y}. \tag{6.6}$$

Dla jednej cechy są to dwa równania z początku sekcji.

Twierdzenie 6.1 (Estymator najmniejszych kwadratów)**.** *Jeśli kolumny macierzy* $\mathbf{X}$ *są liniowo niezależne, to macierz* $\mathbf{X}^\top\mathbf{X}$ *jest odwracalna, a* RSS *ma dokładnie jedno minimum w punkcie*

$$\hat{\beta} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}. \tag{6.7}$$

Funkcja RSS jest wypukła, bo jest kwadratem normy funkcji afinicznej β, więc punkt zerowania gradientu jest jej minimum. Dowód odwracalności $\mathbf{X}^\top\mathbf{X}$ i jednoznaczności minimum podaje rozszerzenie 6.9.

Liniowa niezależność kolumn wymaga w szczególności, by $n \geq p + 1$. Gdy cech jest więcej niż obserwacji, równania normalne mają nieskończenie wiele rozwiązań i wiele z nich daje $\mathrm{RSS} = 0$. Tak było z wielomianami w sekcji 4.1: gdy $d + 1$ osiągało liczbę różnych wartości x_i, wielomian przechodził przez wszystkie punkty.

> **Wzór to nie algorytm**
>
> Wzór (6.7) opisuje rozwiązanie, ale nie służy do jego obliczania. Funkcja `dopasuj` wywołuje `np.linalg.lstsq`, która rozwiązuje zadanie najmniejszych kwadratów bez tworzenia i odwracania macierzy $\mathbf{X}^\top\mathbf{X}$. Gdy kolumny $\mathbf{X}$ są bliskie liniowej zależności, na przykład dla kolejnych potęg x w regresji wielomianowej, obliczenie wprost ze wzoru gubi w zaokrągleniach większość cyfr znaczących. W kodzie używamy więc `lstsq` albo gotowych funkcji, takich jak `OLS` z pakietu `statsmodels` czy `Polynomial.fit`. Przyczynę i przykład podaje rozszerzenie 6.9.

6.2.3. Reszty i dźwignie

Oznaczmy wektor predykcji $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$ i wektor reszt $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$. Równania normalne zapisane jako

$$\mathbf{X}^\top\mathbf{e} = \mathbf{0} \tag{6.8}$$

mówią, że wektor reszt jest prostopadły do każdej kolumny $\mathbf{X}$. Dla kolumny jedynek oznacza to, że reszty sumują się do zera, a dla kolumny cechy – że w próbie są nieskorelowane z tą cechą. Reszty są też prostopadłe do każdego wektora z $\mathcal{C}(\mathbf{X})$, bo $(\mathbf{X}\mathbf{v})^\top\mathbf{e} = \mathbf{v}^\top\mathbf{X}^\top\mathbf{e} = 0$, w szczególności do wektora predykcji $\hat{\mathbf{y}}$. W resztach nie zostaje więc nic, co dałoby się liniowo przewidzieć z cech.

Wektor predykcji jest liniową funkcją wyników, $\hat{\mathbf{y}} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$. Predykcja dla obserwacji i jest więc ważoną sumą wszystkich wyników:

$$\hat{y}_i = \sum_{j=1}^{n} h_{ij}\,y_j, \qquad h_{ij} = \tilde{\mathbf{x}}_i^\top(\mathbf{X}^\top\mathbf{X})^{-1}\tilde{\mathbf{x}}_j. \tag{6.9}$$

Wagi h_{ij} tworzą macierz $\mathbf{H}$, nazywaną **macierzą daszkową** (ang. *hat matrix*), bo $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ „nakłada daszek" na $\mathbf{y}$. Element przekątny h_{ii} to waga, jaką predykcja $\hat{y}_i$ przypisuje własnemu wynikowi y_i; nazywa się go **dźwignią** obserwacji i. Dźwignia leży między 0 a 1. Gdy jest bliska 1, predykcja w punkcie $\mathbf{x}_i$ zależy głównie od samego y_i. Dużą dźwignię mają obserwacje o nietypowych cechach, położone daleko od środka chmury punktów uczących (Zadanie 6.2). Dźwignie sumują się do liczby współczynników,

$$\sum_{i=1}^{n} h_{ii} = p + 1, \tag{6.10}$$

więc średnio wynoszą $(p+1)/n$ (dowód w rozszerzeniu 6.9). Z dźwigni skorzystamy przy wariancji predykcji i w diagnostyce modelu.

6.3. Własności estymatora OLS

Współczynniki z sekcji 6.2 dopasowaliśmy do jednej próby 200 rynków. Inne rynki dałyby inną prostą i inne $\hat{\beta}$. Jak daleko oszacowanie może leżeć od β? Do odpowiedzi potrzebny jest model losowości. Tak jak w sekcji 4.4 przy metodzie k-NN, przyjmujemy **ustalony układ**: punkty $\mathbf{x}_1, \ldots, \mathbf{x}_n$ traktujemy jako ustalone, a losowe są tylko wyniki. Formalnie oznacza to warunkowanie względem cech; wszystkie wartości oczekiwane w tej sekcji liczymy przy danym $\mathbf{X}$.

Definicja 6.1 (Założenia modelu liniowego)**.** Wektor wyników ma postać $\mathbf{y} = \mathbf{X}\beta + \varepsilon$, gdzie macierz $\mathbf{X}$ jest ustalona, ma liniowo niezależne kolumny, oraz

- (Z1) $\mathbb{E}\varepsilon = \mathbf{0}$,
- (Z2) $\operatorname{Cov}\varepsilon = \sigma^2\mathbf{I}$, czyli błędy są nieskorelowane i mają jednakową wariancję σ^2.

Założenie (Z1) to pierwsze odczytanie modelu z sekcji 6.1: funkcja regresji jest liniowa. Założenie (Z2) wyklucza między innymi sytuację z rysunku 6.1, w której rozrzut wokół prostej rośnie z budżetem.

Rysunek 6.3 pokazuje, jak dopasowanie zmienia się między próbami. Punkty x_i, $n = 30$, wylosowaliśmy raz z rozkładu jednostajnego na $[0, 10]$ i trzymamy je ustalone. W każdej z 10 000 prób losujemy nowe wyniki $y_i = 1 + 0{,}5\,x_i + \varepsilon_i$, z $\varepsilon_i \sim \mathcal{N}(0, 1{,}5^2)$, i dopasowujemy prostą.

Proste z kolejnych prób rozchodzą się wokół prawdziwej prostej, najmocniej na krańcach przedziału, a nachylenia skupiają się wokół $\beta_1 = 0{,}5$. Średnią i rozrzut tego rozkładu podaje twierdzenie 6.2; o kształcie rozkładu nie mówi ono nic. Histogram jest normalny, bo błędy w symulacji są normalne.

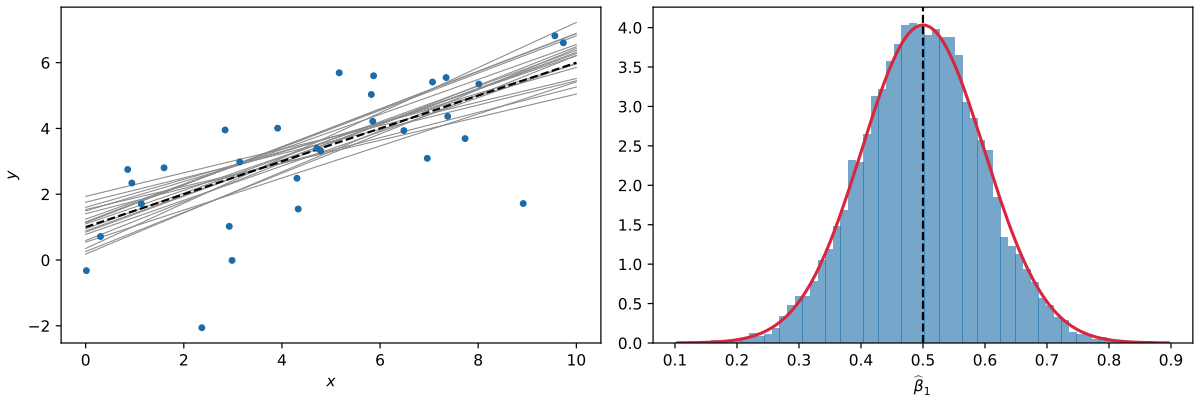
Twierdzenie 6.2 (Średnia i macierz kowariancji estymatora OLS)**.** *Przy założeniach (Z1)–(Z2)*

$$\mathbb{E}\hat{\beta} = \beta, \qquad \operatorname{Cov}\hat{\beta} = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}. \tag{6.11}$$

Nieobciążoność widać po podstawieniu modelu do wzoru (6.7):

$$\hat{\beta} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top(\mathbf{X}\beta + \varepsilon) = \beta + \mathbf{A}\varepsilon, \qquad \mathbf{A} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top.$$

Estymator jest sumą prawdziwego wektora współczynników i kombinacji liniowych błędów o ustalonych wagach. Błędy mają średnią zero, więc $\mathbb{E}\hat{\beta} = \beta$. Rachunek macierzy kowariancji podaje rozszerzenie 6.10.



Rysunek 6.3.: Estymator OLS w 10 000 próbach z modelu $y_i = 1 + 0{,}5\,x_i + \varepsilon_i$ przy ustalonych punktach x_i ($n = 30$, $\sigma = 1{,}5$). Po lewej: proste dopasowane do 20 prób (cienkie linie), prawdziwa prosta (przerywana) i punkty pierwszej próby. Po prawej: histogram $\hat{\beta}_1$ na tle gęstości rozkładu normalnego o średniej β_1 i wariancji z (6.12).

Rozrzut estymatora zależy od poziomu szumu σ^2 i od układu punktów, zapisanego w $\mathbf{X}^\top\mathbf{X}$. Dla jednej cechy, odwracając macierz 2×2, otrzymujemy

$$\operatorname{Var}\hat{\beta}_1 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \qquad \operatorname{Var}\hat{\beta}_0 = \sigma^2\Big(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\Big) \tag{6.12}$$

(Zadanie 6.1). Przy ustalonym poziomie szumu nachylenie jest wyznaczone tym dokładniej, im szerzej rozrzucone są punkty x_i. Gdy wszystkie leżą blisko siebie, niewielki szum w wynikach wystarcza, by mocno przechylić prostą. Ponieważ $\sum_i (x_i - \bar{x})^2 = n s_x^2$, gdzie s_x^2 jest wariancją z próby, odchylenie standardowe $\hat{\beta}_1$ maleje jak $\sigma/(s_x\sqrt{n})$. W symulacji średnia $\hat{\beta}_1$ po próbach jest równa β_1 z dokładnością do szumu symulacji, a histogram pokrywa się z gęstością o wariancji (6.12).

6.3.1. Wariancja predykcji

Predykcja w punkcie $\mathbf{x}_0$ to $\hat{f}(\mathbf{x}_0) = \tilde{\mathbf{x}}_0^\top \hat{\beta}$, gdzie $\tilde{\mathbf{x}}_0 = (1, \mathbf{x}_0)$ jest wektorem cech uzupełnionym o jedynkę. Z twierdzenia 6.2 jest ona nieobciążonym estymatorem $f^*(\mathbf{x}_0) = \tilde{\mathbf{x}}_0^\top \beta$ o wariancji

$$\operatorname{Var}\hat{f}(\mathbf{x}_0) = \sigma^2\, \tilde{\mathbf{x}}_0^\top (\mathbf{X}^\top\mathbf{X})^{-1} \tilde{\mathbf{x}}_0. \tag{6.13}$$

W punkcie uczącym $\mathbf{x}_i$ forma kwadratowa w tym wzorze to dźwignia h_{ii} z (6.9), więc wariancja predykcji wynosi $\sigma^2 h_{ii}$. Jest największa w punktach o dużej dźwigni, daleko od środka chmury punktów, stąd szerszy wachlarz prostych na krańcach rysunku 6.3. Uśredniona po n punktach uczących wariancja predykcji wynosi, z (6.10),

$$\frac{1}{n}\sum_{i=1}^n \operatorname{Var}\hat{f}(\mathbf{x}_i) = \frac{\sigma^2}{n}\sum_{i=1}^n h_{ii} = \sigma^2\,\frac{p+1}{n}. \tag{6.14}$$

Na tę średnią powoływaliśmy się w sekcji 4.8. Jeśli model liniowy jest trafny, predyktor OLS nie ma obciążenia, a jego wariancja uśredniona po punktach uczących maleje jak $1/n$ ze stałą proporcjonalną do liczby współczynników. W nowym punkcie z tego samego rozkładu co cechy uczące wariancja jest nieco większa, ale przy dużym n również bliska $\sigma^2(p+1)/n$ (rozszerzenie 6.10). Dla porównania wariancja σ^2/k regresji k-NN (4.6) to $\sigma^2(n/k)/n$, z efektywną liczbą parametrów n/k w miejscu $p+1$.

6.3.2. Estymacja wariancji błędu

Wzory (6.11) i (6.13) zawierają nieznane σ^2. Naturalnym kandydatem na jego estymator są reszty, ale są one systematycznie mniejsze od błędów. Współczynniki $\widehat{\beta}$ dobrano tak, by suma kwadratów reszt na tych samych danych była najmniejsza, więc $\mathrm{RSS}(\widehat{\beta}) \leq \mathrm{RSS}(\beta) = \sum_i \varepsilon_i^2$.

Twierdzenie 6.3 (Wartość oczekiwana sumy kwadratów reszt)**.** *Przy założeniach (Z1)–(Z2)*

$$\mathbb{E}\,\mathrm{RSS}(\widehat{\beta}) = \sigma^2(n-p-1),$$

więc

$$\hat{\sigma}^2 = \frac{\mathrm{RSS}(\widehat{\beta})}{n-p-1} \tag{6.15}$$

jest nieobciążonym estymatorem σ^2.

Suma kwadratów błędów ma wartość oczekiwaną $n\sigma^2$, a suma kwadratów reszt – o $(p+1)\sigma^2$ mniejszą, czyli o σ^2 na każdy dopasowany współczynnik. Liczbę $n-p-1$ tłumaczą równania (6.8). Reszty spełniają $p+1$ równań liniowych $\mathbf{X}^\top\mathbf{e} = \mathbf{0}$, więc nie mogą przyjmować dowolnych wartości: po ustaleniu odpowiednio wybranych $n-p-1$ reszt pozostałe $p+1$ wynikają z tych równań. Dla $p=0$ jest to warunek $\sum_i (y_i - \bar{y}) = 0$: odchylenia od średniej sumują się do zera, więc ostatnie wynika z $n-1$ pozostałych. Liczbę $n-p-1$ nazywa się **resztowymi stopniami swobody**. Wariancja z próby z mianownikiem $n-1$ to estymator $\hat{\sigma}^2$ dla $p=0$ (Zadanie 6.6). Dowód twierdzenia podaje rozszerzenie 6.10.

Błąd na zbiorze uczącym, RSS/n, ma wartość oczekiwaną $\sigma^2(1-(p+1)/n)$, czyli zaniża nawet błąd nieredukowalny. To jest optymizm błędu uczącego z sekcji 4.1, który dla OLS można policzyć dokładnie (Zadanie 6.5).

6.3.3. Twierdzenie Gaussa–Markowa

Estymator OLS jest **liniowy**, czyli ma postać $\mathbf{Cy}$ z macierzą $\mathbf{C} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$ zależną tylko od $\mathbf{X}$. Twierdzenie Gaussa–Markowa mówi, że przy założeniach (Z1)–(Z2) estymator OLS ma najmniejszą wariancję wśród estymatorów liniowych nieobciążonych, także dla każdej kombinacji liniowej współczynników, w tym predykcji w dowolnym punkcie; jest więc **najlepszym liniowym estymatorem nieobciążonym** (ang. *best linear unbiased estimator*, BLUE) (Hastie i in. 2009, rozdz. 3.2.2). Twierdzenie 6.4 z dowodem podaje rozszerzenie 6.10, a przypadek średniej z próby – Zadanie 6.7.

i Czego twierdzenie nie mówi

Twierdzenie porównuje OLS tylko z estymatorami liniowymi i nieobciążonymi. W sekcji 4.3 widzieliśmy, że estymator ściągający $c\bar{Y}$, obciążony, może mieć wyraźnie mniejszy błąd średniokwadratowy niż nieobciążona średnia $\bar{Y}$. Ten sam mechanizm działa dla współczynników regresji. Założenie (Z2) też jest istotne: gdy błędy mają różne wariancje, lepiej ważyć obserwacje odwrotnościami tych wariancji, a OLS traktuje wszystkie jednakowo.

6.4. Jakość dopasowania

Zanim zapytamy, czy związek cech z wynikiem można odróżnić od szumu, opiszmy, jak dobrze model odtwarza wyniki w próbie. Służą do tego dwie miary.

Pierwsza to $\hat{\sigma} = \sqrt{\mathrm{RSS}/(n-p-1)}$, nazywana w pakietach **resztowym błędem standardowym** (ang. *residual standard error*, RSE). Szacuje odchylenie standardowe błędu, czyli typową odległość wyniku od prostej regresji, w jednostkach Y. W regresji sprzedaży względem telewizji $\hat{\sigma} \approx 3{,}26$ tysiąca sztuk przy średniej sprzedaży 14,0 tysiąca, więc predykcja myli się typowo o mniej więcej jedną czwartą.

Druga miara jest bezwymiarowa. Model zawiera wyraz wolny, więc wektor $\bar{y}\,\mathbf{1}$ leży w $\mathcal{C}(\mathbf{X})$, a wraz z nim $\hat{\mathbf{y}} - \bar{y}\,\mathbf{1}$. Reszty są do $\mathcal{C}(\mathbf{X})$ prostopadłe (6.8), zatem z twierdzenia Pitagorasa

$$\underbrace{\sum_{i=1}^{n}(y_i-\bar{y})^2}_{\mathrm{TSS}} = \underbrace{\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2}_{\mathrm{ESS}} + \underbrace{\sum_{i=1}^{n}(y_i-\hat{y}_i)^2}_{\mathrm{RSS}}\,. \tag{6.16}$$

Całkowita zmienność wyniku rozkłada się na część odtworzoną przez model i część resztową. **Współczynnik determinacji**

$$R^2 = 1 - \frac{\mathrm{RSS}}{\mathrm{TSS}} = \frac{\mathrm{ESS}}{\mathrm{TSS}} \tag{6.17}$$

to odsetek zmienności y w próbie odtworzony przez model; leży w przedziale $[0,1]$. Dla jednej cechy jest równy kwadratowi współczynnika korelacji z próby, $R^2 = r^2$ (Zadanie 6.1).

	RSS	R^2	skorygowany R^2	RSE
TV	2102.5306	0.6119	0.6099	3.2587
TV + radio	556.9140	0.8972	0.8962	1.6814
TV + radio + newspaper	556.8253	0.8972	0.8956	1.6855

Dodanie radia podnosi R^2 z 0,61 do 0,90 i zmniejsza $\hat{\sigma}$ o połowę. Dodanie prasy zmienia RSS dopiero na trzecim miejscu znaczącym, a $\hat{\sigma}$ nawet nieco rośnie, bo spadek licznika nie równoważy utraty stopnia swobody w mianowniku.

Iloraz $1 - R^2 = (\mathrm{RSS}/n)/(\mathrm{TSS}/n)$ to błąd uczący podzielony przez wariancję y z próby, która od modelu nie zależy. Błąd uczący nie rośnie po dodaniu cechy, bo klasy modeli są zagnieżdżone, a minimum po większej klasie nie jest większe (sekcja 4.1), więc R^2 nigdy nie maleje. R^2 ma zatem wszystkie wady błędu uczącego i nie nadaje się do wyboru modelu. **Skorygowany** R^2,

$$R^2_{\mathrm{adj}} = 1 - \frac{\mathrm{RSS}/(n-p-1)}{\mathrm{TSS}/(n-1)},$$

dzieli obie sumy kwadratów przez ich liczby stopni swobody; licznik jest wtedy równy $\hat{\sigma}^2$. Dodanie cechy nie zwiększa RSS, ale zmniejsza $n-p-1$, więc R^2_{adj} może zmaleć, jak w ostatnim wierszu tabeli. Poprawka usuwa jednak tylko obciążenie $\hat{\sigma}^2$ dla jednego, z góry ustalonego modelu. Gdy porównujemy wiele modeli i wybieramy najlepszy, pojawia się optymizm wyboru z sekcji 5.6, którego żadna poprawka stopni swobody nie usuwa.

R^2 nie jest też własnością samej zależności. Dla jednej cechy $\mathbb{E}[\mathrm{ESS}]$ rośnie z rozrzutem x_i przy tym samym β_1 i tym samym σ (Zadanie 6.1). Ten sam model z tym samym szumem da więc wysokie R^2 na próbie o szerokim zakresie cechy i niskie na próbie o wąskim. Do porównań między próbami lepiej nadaje się $\hat{\sigma}$, wyrażone w jednostkach wyniku.

6.5. Wnioskowanie o parametrach

Proste na rysunku 6.3 pochodzą z tego samego modelu, a mają różne nachylenia. W danych *Advertising* mamy jedną próbę i jedno oszacowanie każdego współczynnika. Jak daleko może ono leżeć od prawdziwej wartości i czy da się je odróżnić od zera?

Samo dopasowanie OLS nie wymaga założeń o błędach, a nieobciążoność i wzory na wariancję z sekcji 6.3 – tylko (Z1)–(Z2). Dokładne rozkłady statystyk, z których biorą się przedziały ufności i p-wartości, wymagają trzeciego założenia:

- (Z3) $\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I})$, czyli błędy są niezależne i mają rozkład normalny.

Przy (Z3) estymator $\hat{\beta} = \beta + \mathbf{A}\varepsilon$, kombinacja liniowa błędów normalnych, ma rozkład normalny; stąd kształt histogramu na rysunku 6.3. Gdy błędy nie są normalne, ale (Z1)–(Z2) zachodzą, rozkłady statystyk t i F podane niżej są przybliżeniami, zwykle dobrymi przy dużym n (Zadanie 6.8).

6.5.1. Błędy standardowe i przedziały ufności

Z twierdzenia 6.2 wariancja $\hat{\beta}_j$ to $\sigma^2 v_{jj}$, gdzie v_{jj} jest j-tym elementem przekątnej $(\mathbf{X}^\top\mathbf{X})^{-1}$ (numerując od zera). Odchylenie standardowe $\sigma\sqrt{v_{jj}}$ to szerokość histogramu z rysunku 6.3: mówi, o ile oszacowanie typowo zmienia się między próbami. Zastępując nieznane σ przez $\hat{\sigma}$ z (6.15), otrzymujemy **błąd standardowy**

$$\mathrm{SE}(\hat{\beta}_j) = \hat{\sigma}\sqrt{v_{jj}}.$$

Pakiet `statsmodels` podaje błędy standardowe razem z pozostałymi wielkościami omawianymi w tej sekcji. Dla modelu z trzema mediami:

	coef	**std err**	**t**	**P> |t|**	**[0.025**	**0.975]**
const	2.9389	0.312	9.422	0.000	2.324	3.554
TV	0.0458	0.001	32.809	0.000	0.043	0.049
radio	0.1885	0.009	21.893	0.000	0.172	0.206
newspaper	-0.0010	0.006	-0.177	0.860	-0.013	0.011

Współczynnik przy telewizji, 0,0458, ma błąd standardowy około 0,0014 (kolumna `std err`): o tyle typowo różniłyby się od β_1 oszacowania z innych prób 200 rynków o tych samych budżetach.

Statystyka

$$T_j = \frac{\hat{\beta}_j - \beta_j}{\mathrm{SE}(\hat{\beta}_j)} \tag{6.18}$$

mierzy błąd oszacowania w błędach standardowych. Gdyby w mianowniku stało znane $\sigma\sqrt{v_{jj}}$, przy (Z1)–(Z3) miałaby rozkład $\mathcal{N}(0,1)$. Oszacowanie $\hat{\sigma}$ też jest losowe i dokłada zmienności: przy (Z1)–(Z3) statystyka T_j ma **rozkład t Studenta** z $n-p-1$ stopniami swobody (uzasadnienie w rozszerzeniu 6.10). Rozkład ten nie zależy od nieznanych β i σ, więc

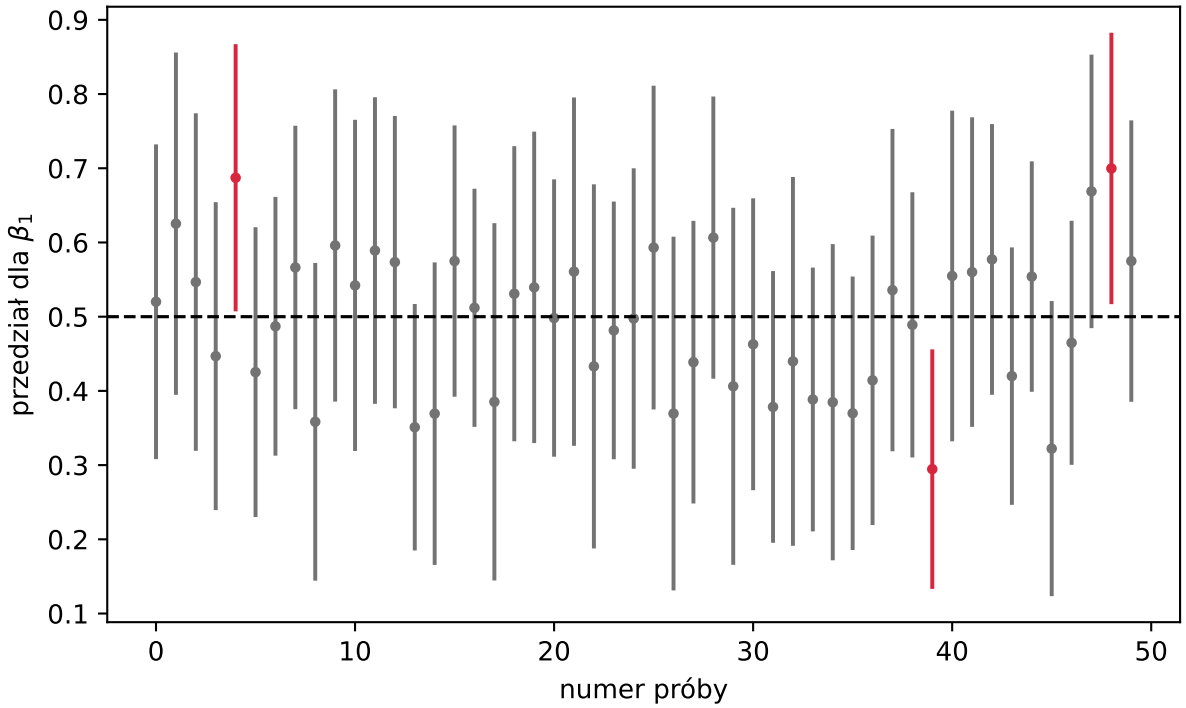
$$\mathbb{P}(|T_j| \le t_{n-p-1}) = 1-\alpha,$$

gdzie t_{n-p-1} oznacza kwantyl rzędu $1-\alpha/2$ tego rozkładu. Przekształcając nierówność, dostajemy **przedział ufności** dla β_j na poziomie $1-\alpha$:

$$\left[\hat{\beta}_j - t_{n-p-1}\,\mathrm{SE}(\hat{\beta}_j),\ \hat{\beta}_j + t_{n-p-1}\,\mathrm{SE}(\hat{\beta}_j)\right]. \tag{6.19}$$

Kwantyl jest większy od 1,96, bo rozkład t ma grubsze ogony niż normalny: przy 28 stopniach swobody wynosi 2,05, przy 196 – 1,97.

Losowy jest przedział, a nie β_j. Poziom ufności 95% oznacza, że w 95% prób procedura daje przedział zawierający β_j. O jednym obliczonym przedziale nie mówi nic więcej: β_j albo w nim leży, albo nie. Rysunek 6.4 pokazuje przedziały z 50 pierwszych prób symulacji z rysunku 6.3.



Rysunek 6.4.: Przedziały ufności 95% dla β_1 z 50 prób symulacji z rysunku 6.3. Czerwone przedziały nie zawierają prawdziwej wartości $\beta_1 = 0{,}5$ (linia przerywana).

```
odsetek przedziałów pokrywających beta1 we wszystkich próbach: 0.953
```

We wszystkich 10 000 próbach przedział pokrył β_1 w około 95% przypadków, zgodnie z założeniami (Z1)–(Z3), które symulacja spełnia. Co się dzieje, gdy nie są spełnione, sprawdza Zadanie 6.8.

Przedział 95% dla telewizji w tabeli (kolumny `[0.025` i `0.975]`) to [0,043; 0,049]: przy tych samych budżetach radiowym i prasowym tysiąc dolarów więcej na telewizję wiąże się przeciętnie z 43 do 49 sztukami sprzedaży więcej.

6.5.2. Test t i p-wartość

Drugie pytanie ze wstępu dotyczy tego, które media przyczyniają się do sprzedaży. Dla medium j sprawdzamy hipotezę $H_0\colon \beta_j = 0$: przy ustalonych pozostałych budżetach budżet na to medium

nie wiąże się ze średnią sprzedażą. Przy H_0 statystyka (6.18) ma postać $t = \hat{\beta}_j/\mathrm{SE}(\hat{\beta}_j)$ i rozkład t z $n-p-1$ stopniami swobody. **p-wartość**

$$p = \mathbb{P}_{H_0}(|T| \geq |t_{\mathrm{obs}}|)$$

to prawdopodobieństwo, że przy prawdziwej H_0 statystyka wypadłaby co najmniej tak daleko od zera jak w naszej próbie. Mała p-wartość oznacza, że tak odległe od zera oszacowanie byłoby przy H_0 rzadkie, i jest podstawą do odrzucenia H_0. Nie jest prawdopodobieństwem, że H_0 jest prawdziwa, i nie mierzy siły związku: przy dużym n nawet mały niezerowy współczynnik daje zwykle małą p-wartość. Duża p-wartość nie dowodzi, że $\beta_j = 0$, a tylko, że dane są z tą wartością zgodne. Test na poziomie α odrzuca H_0 wtedy i tylko wtedy, gdy przedział ufności (6.19) na poziomie $1-\alpha$ nie zawiera zera.

W tabeli powyżej telewizja i radio mają statystyki $t \approx 33$ i 22, a p-wartości tak małe, że tabela zaokrągla je do zera. Prasa ma $t \approx -0{,}18$ i $p \approx 0{,}86$. Przy ustalonych pozostałych budżetach sprzedaż wiąże się więc z reklamą w telewizji i w radiu, a w danych nie ma śladu związku z reklamą w prasie. Przedział dla prasy, $[-0{,}013;\ 0{,}011]$, zawiera zero, ale też wartości około jednej czwartej współczynnika przy telewizji, więc słabego związku nie wyklucza.

W regresji z samą prasą ten sam współczynnik ma $t \approx 3{,}3$ i $p \approx 0{,}001$. Nie ma tu sprzeczności, bo hipotezy są różne. Pierwsza mówi, że prasa nie wnosi nic, gdy znamy budżety telewizyjny i radiowy. Druga – że sprzedaż nie zależy od budżetu prasowego w ogóle.

6.5.3. Test F

Pierwsze pytanie ze wstępu, czy wydatki na reklamę w ogóle wiążą się ze sprzedażą, dotyczy wszystkich cech naraz: $H_0\colon \beta_1 = \cdots = \beta_p = 0$. Nie możemy na nie odpowiedzieć, wykonując p testów t. Każdy z nich na poziomie 5% myli się przy prawdziwej H_0 z prawdopodobieństwem 0,05, więc przy 100 cechach niemal na pewno któryś odrzuci hipotezę. Symulacja ze 100 cechami niezależnymi od wyniku pokazuje to wprost:

```
średnia liczba istotnych testów t:      4.9 na 100
odsetek prób z co najmniej jednym:      0.968
odsetek prób, w których test F odrzuca: 0.054
```

Przeciętnie około pięć cech wychodzi „istotnych”, a prawie w każdej próbie co najmniej jedna. Jeden test hipotezy o wszystkich współczynnikach, opisany niżej, odrzuca ją w około 5% prób, tak jak powinien.

Przy H_0 najlepszym modelem jest sama średnia $\bar{y}$ o sumie kwadratów reszt TSS. Różnica $\mathrm{TSS}-\mathrm{RSS}$ to z rozkładu zmienności (6.16) suma ESS, a statystyka testu

$$F = \frac{\mathrm{ESS}/p}{\mathrm{RSS}/(n-p-1)} = \frac{R^2/p}{(1-R^2)/(n-p-1)}$$

porównuje **zmienność odtworzoną przez model na jeden stopień swobody** ze **zmiennością resztową na jeden stopień swobody**. Mianownik to $\hat{\sigma}^2$. Przy H_0 oba modele, z samą średnią i z cechami, są trafne, więc z twierdzenia 6.3 $\mathbb{E}\,\mathrm{TSS} = \sigma^2(n-1)$ i $\mathbb{E}\,\mathrm{RSS} = \sigma^2(n-p-1)$. Licznik ESS/p ma wtedy, tak jak mianownik, średnią σ^2, a F przyjmuje wartości bliskie 1. Gdy H_0 jest fałszywa, do licznika dochodzi sygnał, więc duże wartości świadczą przeciw H_0. Przy (Z1)–(Z3) statystyka F ma **rozkład** F z p i $n-p-1$ stopniami swobody, z którego liczy się p-wartość.

R^2 mówi, jaką część zmienności w próbie odtworzył model. Test F sprawdza, czy poprawa względem przewidywania samą średnią jest większa, niż można oczekiwać od szumu przy założeniach (Z1)–(Z3). Przy ustalonym R^2 statystyka F rośnie proporcjonalnie do $n-p-1$, więc w dużej próbie nawet małe R^2 daje bardzo małą p-wartość.

Dla modelu z trzema mediami $F \approx 570$, a p-wartość jest rzędu 10^{-96}. Wydatki na reklamę wiążą się ze sprzedażą.

Ten sam rachunek działa dla grupy q cech, na przykład zmiennych kodujących jedną cechę jakościową (sekcja 6.6). Model M_0 bez tych cech ma $\mathrm{RSS}_0 \geq \mathrm{RSS}$, bo klasy modeli są zagnieżdżone. Pytamy, czy spadek $\mathrm{RSS}_0 - \mathrm{RSS}$ jest większy, niż dałby sam szum. Statystyka

$$F = \frac{(\mathrm{RSS}_0 - \mathrm{RSS})/q}{\mathrm{RSS}/(n-p-1)} \tag{6.20}$$

ma przy hipotezie, że ich współczynniki są zerowe, licznik o średniej σ^2, bo $\mathbb{E}\,\mathrm{RSS}_0 - \mathbb{E}\,\mathrm{RSS} = \sigma^2 q$. Przy (Z1)–(Z3) ma rozkład F z q i $n-p-1$ stopniami swobody (Seber i Lee 2003, rozdz. 4); wyprowadzenie podaje rozszerzenie 6.10. Test wszystkich cech to przypadek M_0 z samym wyrazem wolnym, $\mathrm{RSS}_0 = \mathrm{TSS}$ i $q = p$.

Dla $q = 1$ test F i test t sprawdzają tę samą hipotezę i są równoważne: $F = t^2$ (Zadanie 6.9). Sprawdźmy to dla prasy:

```
F = 0.0312,  t^2 = 0.0312,  p = 0.860
```

6.5.4. Przedział dla średniej i przedział predykcji

Trzecie pytanie ze wstępu, jak dokładnie przewidujemy sprzedaż przy zadanym budżecie, ma dwa znaczenia. Pytanie „jaka jest przeciętna sprzedaż na rynkach o budżecie $\mathbf{x}_0$?" dotyczy liczby $f^*(\mathbf{x}_0) = \tilde{\mathbf{x}}_0^\top \beta$. Jej estymator $\tilde{\mathbf{x}}_0^\top \hat{\beta}$ ma wariancję (6.13), a przedział ufności buduje się tak samo jak (6.19), z $\mathrm{SE}^2 = \hat{\sigma}^2\, \tilde{\mathbf{x}}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \tilde{\mathbf{x}}_0$. Pytanie „ile sprzeda się na **jednym** nowym rynku o budżecie $\mathbf{x}_0$?" dotyczy zmiennej losowej $Y_0 = \tilde{\mathbf{x}}_0^\top \beta + \varepsilon_0$. Błąd ε_0 nowej obserwacji jest niezależny od próby, więc

$$\mathrm{Var}\,(Y_0 - \tilde{\mathbf{x}}_0^\top \hat{\beta}) = \sigma^2 + \sigma^2\, \tilde{\mathbf{x}}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \tilde{\mathbf{x}}_0.$$

Jest to rozkład z rozdziału 2 w małej skali: pierwszy składnik to błąd nieredukowalny, drugi – redukowalny, który dla nieobciążonego estymatora składa się z samej wariancji. **Przedział predykcji** ma w miejscu SE^2 sumę obu składników, z σ^2 zastąpionym przez $\hat{\sigma}^2$. Przy rosnącym n przedział ufności dla średniej kurczy się do punktu, a przedział predykcji nie zejdzie poniżej $\pm 1{,}96\,\sigma$. Zależy on od rozkładu samego ε_0, więc przy błędach nienormalnych duże n go nie naprawia.

	mean	mean_se	mean_ci_lower	mean_ci_upper	obs_ci_lower	obs_ci_upper
0	11.26	0.14	10.99	11.53	7.93	14.58

Dla rynku z budżetem telewizyjnym 100 i radiowym 20 tysięcy dolarów model z dwiema cechami przewiduje sprzedaż 11,26 tysiąca sztuk. Przeciętna sprzedaż na takich rynkach leży z ufnością 95% między 10,99 a 11,53 tysiąca (kolumny `mean_ci`), ale sprzedaż na konkretnym rynku – między 7,93 a 14,58 tysiąca (kolumny `obs_ci`). Średnią sprzedaż znamy więc z dokładnością około $\pm 0{,}3$ tysiąca sztuk, a sprzedaż na jednym rynku – tylko około $\pm 3{,}3$ tysiąca.

6.6. Cechy jakościowe

Dotąd wszystkie cechy były liczbami. Zbiór *Credit* (James i in. 2023, rozdz. 3.3.1) opisuje 400 klientów banku. Wynikiem jest średnie saldo zadłużenia na karcie kredytowej (`Balance`, w dolarach), a wśród cech są zarówno liczby – dochód (`Income`, w tysiącach dolarów), limit kredytowy (`Limit`), ocena kredytowa (`Rating`), wiek (`Age`) – jak i cechy jakościowe: czy klient ma dom (`Own`), czy jest studentem (`Student`) i z jakiego regionu pochodzi (`Region`: `East`, `South` albo `West`).

Cechę o dwóch wartościach zastępujemy **zmienną zero-jedynkową** $x_i = 1$, gdy i-ty klient ma dom, i $x_i = 0$ w przeciwnym razie. Model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ mówi wtedy, że średnie saldo wynosi β_0 w grupie bez domu i $\beta_0 + \beta_1$ w grupie z domem. Współczynnik β_1 jest różnicą średnich obu grup, a jego estymatorem OLS – różnica średnich z próby (Zadanie 6.10).

	coef	**std err**	**t**	**P> |t|**	**[0.025**	**0.975]**
const	509.8031	33.128	15.389	0.000	444.675	574.931
Own_Yes	19.7331	46.051	0.429	0.669	-70.801	110.267

Klienci bez domu mają przeciętnie saldo 509,80 dolara, a klienci z domem o 19,73 dolara wyższe. Przy $p \approx 0{,}67$ dane nie świadczą jednak o żadnej różnicy.

Cecha o K wartościach wymaga $K-1$ zmiennych zero-jedynkowych. Jedną wartość wybieramy jako **poziom odniesienia**, a dla każdej z pozostałych tworzymy zmienną równą 1 na tym poziomie i 0 poza nim. Wyraz wolny jest wtedy średnią na poziomie odniesienia, a współczynnik przy zmiennej poziomu k – różnicą średnich poziomu k i poziomu odniesienia. Gdybyśmy dodali zmienne dla wszystkich K poziomów, ich suma byłaby równa kolumnie jedynek. Kolumny $\mathbf{X}$ byłyby liniowo zależne, a równania normalne miałyby nieskończenie wiele rozwiązań (twierdzenie 6.1): dowolną stałą można przenieść z wyrazu wolnego do wszystkich zmiennych zero-jedynkowych naraz.

Wybór poziomu odniesienia, a ogólniej sposób kodowania, zmienia współczynniki, ale nie zmienia dopasowania. Przy każdym poprawnym kodowaniu model może nadać każdemu poziomowi cechy dowolną własną stałą, więc wszystkie kodowania opisują ten sam zbiór funkcji. Metoda najmniejszych kwadratów wybiera z niego tę samą funkcję o najmniejszym RSS; w modelu z samą cechą jakościową jest to średnia wyniku w każdej grupie. Predykcje, RSS i R^2 są więc takie same, a różnią się tylko współczynniki, którymi tę funkcję zapisujemy (Zadanie 6.10).

```
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const        531.0000     46.319     11.464      0.000     439.939     622.061
South        -12.5025     56.681     -0.221      0.826    -123.935      98.930
West         -18.6863     65.021     -0.287      0.774    -146.515     109.142
==============================================================================
F = 0.043,  p = 0.957
```

Średnie saldo na wschodzie wynosi 531 dolarów, na południu jest o 12,50, a na zachodzie o 18,69 dolara niższe. Testy t dla obu zmiennych zero-jedynkowych porównują te regiony ze wschodem, więc ich wyniki zależą od poziomu odniesienia. Gdyby nim był zachód, testowalibyśmy inne różnice i dostali inne p-wartości. Na pytanie, czy region w ogóle wiąże się z saldem, odpowiada test F hipotezy, że oba współczynniki są zerowe ($q = K - 1 = 2$). Jego wynik nie zależy od

kodowania, bo zależy tylko od RSS i RSS_0. Tutaj $F \approx 0{,}04$ przy $p \approx 0{,}96$: region nie różnicuje sald.

6.7. Interakcje i nieliniowość

Model (6.1) jest **addytywny**: zmiana X_1 o jednostkę zmienia średni wynik o β_1 bez względu na wartości pozostałych cech. W danych *Advertising* to założenie jest wątpliwe. Reklama w telewizji i w radiu może się wzajemnie wzmacniać, tak że tysiąc dolarów wydany na telewizję daje więcej, gdy budżet radiowy jest duży. Prostym sposobem uwzględnienia takiego efektu jest **interakcja**, czyli dodanie iloczynu cech jako nowej cechy:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \varepsilon = \beta_0 + (\beta_1 + \beta_3 X_2)\, X_1 + \beta_2 X_2 + \varepsilon. \tag{6.21}$$

Nachylenie względem X_1 wynosi teraz $\beta_1 + \beta_3 X_2$ i zmienia się z X_2. Model pozostaje liniowy w parametrach, więc cała teoria z poprzednich sekcji stosuje się bez zmian; iloczyn $X_1 X_2$ jest jeszcze jedną kolumną $\mathbf{X}$.

```
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const          6.7502      0.248     27.233      0.000       6.261       7.239
TV             0.0191      0.002     12.699      0.000       0.016       0.022
radio          0.0289      0.009      3.241      0.001       0.011       0.046
TV_radio       0.0011   5.24e-05     20.727      0.000       0.001       0.001
==============================================================================
R^2 = 0.968,  RSE = 0.944
```

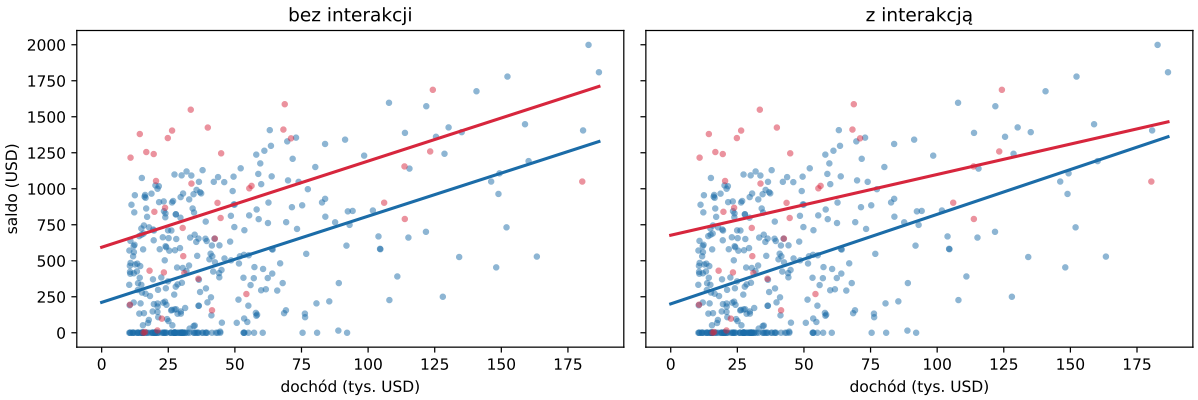
Statystyka t dla interakcji przekracza 20, a R^2 rośnie z 0,897 w modelu addytywnym do 0,968; $\hat{\sigma}$ spada z 1,68 do 0,94. Tysiąc dolarów budżetu telewizyjnego wiąże się teraz z $19{,}1 + 1{,}09 \cdot$ `radio` sztukami więcej: przy zerowym budżecie radiowym z 19 sztukami, przy budżecie radiowym 40 tysięcy dolarów – z 63.

Przy interakcji zostawiamy w modelu oba efekty główne, nawet gdy ich testy t nie są istotne. Bez $\beta_1 X_1$ model wymusza zerowe nachylenie względem X_1 w punkcie $X_2 = 0$, a położenie zera na skali X_2 bywa umowne. Z tego samego powodu β_1 w modelu (6.21) jest nachyleniem przy $X_2 = 0$, a nie przeciętnym nachyleniem. Wyśrodkowanie cech zmienia jego sens, ale nie zmienia dopasowania (Zadanie 6.11).

Interakcja cechy ilościowej z jakościową ma prosty obraz. W modelu salda względem dochodu i statusu studenta bez interakcji zmienna zero-jedynkowa przesuwa prostą w górę lub w dół: dostajemy dwie **równoległe** proste. Interakcja dochodu ze zmienną zero-jedynkową pozwala prostym mieć różne nachylenia. Taki model jest równoważny dopasowaniu dwóch osobnych prostych, po jednej w każdej grupie, z tą różnicą, że obie korzystają ze wspólnego oszacowania σ^2.

W modelu bez interakcji studenci mają przy tym samym dochodzie saldo wyższe o 383 dolary, a każdy tysiąc dolarów dochodu wiąże się z saldem wyższym o 5,98 dolara w obu grupach. Z interakcją nachylenie wynosi 6,22 dla pozostałych klientów i 4,22 dla studentów. Różnica nachyleń ma jednak $p \approx 0{,}25$, a studentów jest w próbie tylko 40: dane nie przeczą prostym równoległym.

Druga droga wyjścia poza model liniowy w cechach to ich przekształcenia. Zbiór *Auto* (James i in. 2023, rozdz. 3.3.2) opisuje 392 samochody (po usunięciu pięciu z brakującymi danymi). Zużycie



Rysunek 6.5.: Saldo karty kredytowej w zależności od dochodu dla studentów (czerwone) i pozostałych klientów (niebieskie). Po lewej: model bez interakcji, dwie równoległe proste. Po prawej: model z interakcją dochodu i statusu studenta, proste o różnych nachyleniach.

paliwa, wyrażone w milach na galon (`mpg`), maleje z mocą silnika (`horsepower`) wyraźnie po krzywej. Dodając kwadrat mocy jako cechę, dostajemy model $\texttt{mpg} = \beta_0 + \beta_1\,\texttt{hp} + \beta_2\,\texttt{hp}^2 + \varepsilon$ – regresję wielomianową z rozdziału 4, liniową w parametrach.

Składnik kwadratowy podnosi R^2 z 0,61 do 0,69, a jego statystyka t wynosi około 10. Wybór przekształceń – które potęgi, logarytmy, interakcje – jest jednak wyborem klasy modeli i podlega kompromisowi z rozdziału 4: każda dodana kolumna zmniejsza RSS na próbie i zwiększa wariancję. O tym, ile złożoności się opłaca, rozstrzyga walidacja z rozdziału 5.

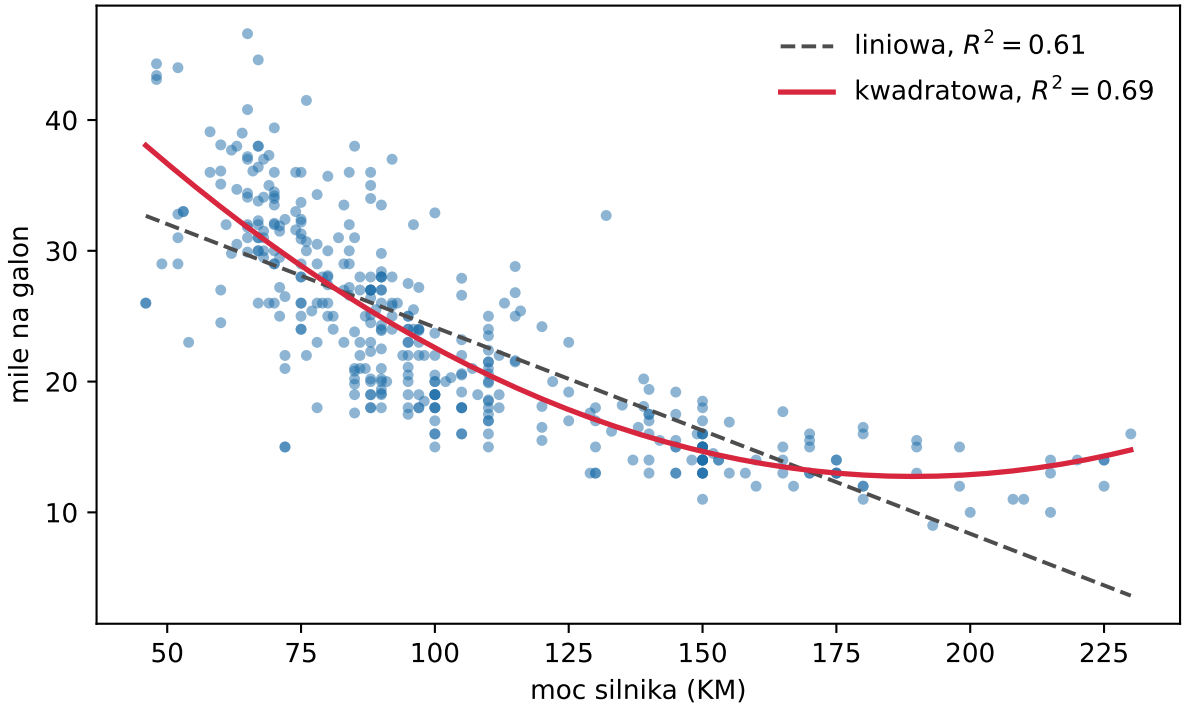
6.8. Diagnostyka modelu

Wnioskowanie z sekcji 6.5 opiera się na założeniach (Z1)–(Z3). Nie obserwujemy błędów ε_i, więc założenia sprawdzamy na resztach. Reszty nie są jednak kopiami błędów. Predykcja $\hat{y}_i$ zawiera własny wynik y_i z wagą h_{ii} (6.9) i przejmuje część błędu ε_i, więc przy (Z1)–(Z2) $\operatorname{Var} e_i = \sigma^2(1 - h_{ii})$ (rachunek w rozszerzeniu 6.11). Najmniejszą wariancję mają więc reszty obserwacji o dużej dźwigni. **Reszta standaryzowana** $r_i = e_i/(\hat{\sigma}\sqrt{1 - h_{ii}})$ to reszta podzielona przez oszacowanie swojego odchylenia standardowego, więc reszty wszystkich obserwacji mają w niej tę samą skalę. Gdy n jest duże w porównaniu z p, dźwignie są małe, średnio $(p + 1)/n$ (6.10), i same reszty zachowują się prawie jak błędy.

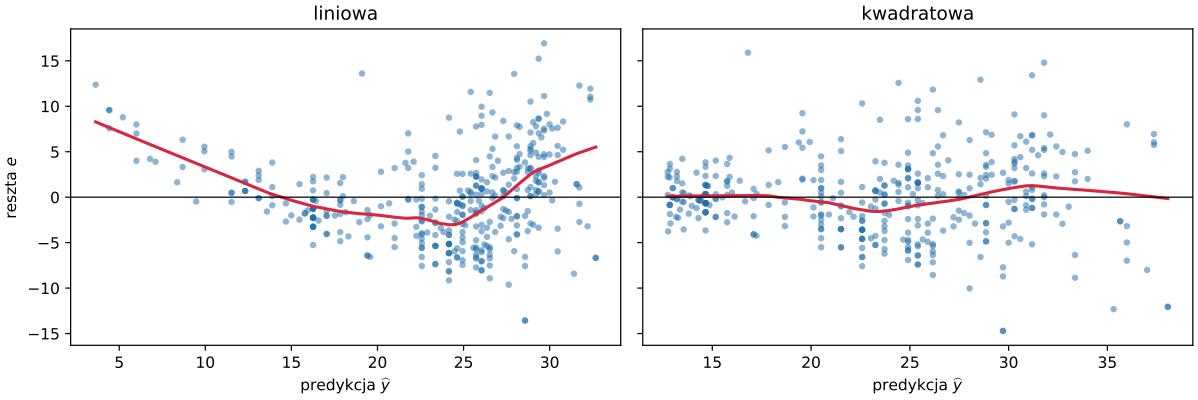
6.8.1. Brak liniowości

Reszty każdego modelu sumują się do zera i są w próbie nieskorelowane z predykcjami $\hat{y}_i$ (6.8). Na wykresie reszt względem predykcji szukamy więc kształtu, nie trendu: przy trafnym modelu punkty tworzą bezkształtny pas stałej szerokości wokół zera. Wykres względem predykcji, a nie względem każdej cechy, działa dla dowolnej liczby cech.

W modelu liniowym reszty układają się w wyraźny łuk: dla małych i dużych predykcji są przeważnie dodatnie, dla średnich – ujemne. Łuk oznacza, że średnia reszt zależy od $\hat{y}$: funkcja regresji nie jest liniowa w użytych cechach, więc założenie (Z1) nie jest spełnione. Skutkiem są systematyczne błędy predykcji. Model zawyża zasięg samochodów o średniej mocy i zaniża go na krańcach, a jedno nachylenie uśrednia zależność, która przy małej mocy jest stroma, a przy



Rysunek 6.6.: Zasięg na galonie paliwa w zależności od mocy silnika dla 392 samochodów. Linia przerywana: regresja liniowa; linia ciągła: regresja z kwadratem mocy.



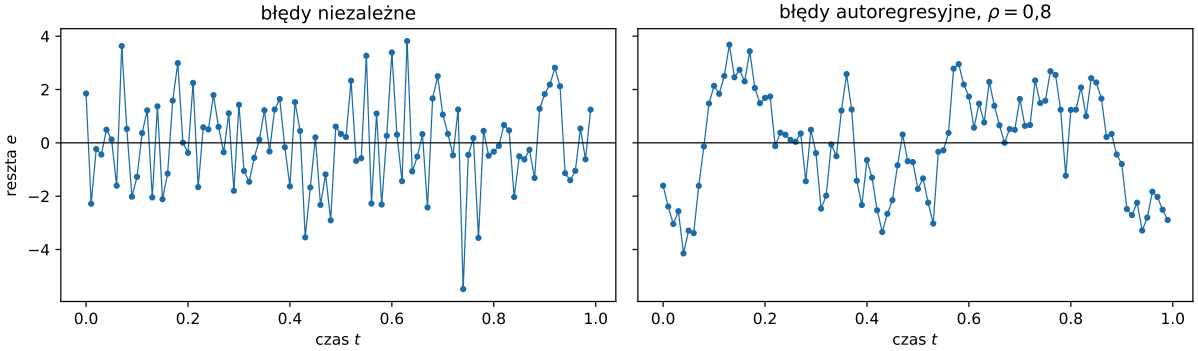
Rysunek 6.7.: Reszty w zależności od predykcji dla danych *Auto*. Po lewej: regresja liniowa względem mocy; po prawej: regresja z kwadratem mocy. Czerwona linia to wygładzenie lokalną regresją (LOWESS).

dużej łagodna. Pomagają przekształcenia cech lub interakcje z sekcji 6.7: po dodaniu kwadratu mocy łuk prawie znika.

Na prawym wykresie widać inną strukturę, lejek: wygładzenie leży blisko zera, więc postać średniej jest trafna, ale rozrzut reszt rośnie z predykcją. Lejek świadczy, że wariancja błędów nie jest stała, czyli podważa założenie (Z2). Jego skutki omawia podsekcja o heteroskedastyczności.

6.8.2. Skorelowane błędy

Założenie (Z2) wymaga też, by błędy były nieskorelowane. Typowo nie są, gdy obserwacje są uporządkowane w czasie – błąd w jednym miesiącu jest podobny do błędu w poprzednim – albo zgrupowane, jak pomiary tego samego pacjenta czy uczniowie tej samej klasy. Wykres reszt względem predykcji tego nie pokazuje; reszty trzeba narysować w kolejności czasu albo w podziale na grupy, jak na rysunku 6.8.



Rysunek 6.8.: Reszty regresji prostej $y_i = 1 + 2t_i + \varepsilon_i$ dla $n = 100$ pomiarów w chwilach $t_i = i/n$, w kolejności czasu. Po lewej: błędy niezależne; po prawej: błędy autoregresyjne $\varepsilon_i = 0{,}8\,\varepsilon_{i-1} + z_i$ z niezależnymi, standardowymi normalnymi z_i, o tej samej wariancji co po lewej.

Przy dodatnio skorelowanych błędach sąsiednie reszty mają podobne wartości i tworzą długie serie powyżej i poniżej zera.

Estymator $\hat{\beta}$ pozostaje nieobciążony, bo nieobciążoność wymaga tylko (Z1). Wzór $\sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}$ na jego macierz kowariancji wymaga jednak (Z2). Dodatnio skorelowane obserwacje częściowo powtarzają tę samą informację, więc klasyczne błędy standardowe, liczone jak dla obserwacji niezależnych, są za małe, przedziały ufności za wąskie, a p-wartości za małe. Skalę pokazuje rachunek dla średniej z próby (Zadanie 6.17): gdy korelacja sąsiednich błędów wynosi $\rho = 0{,}8$, jak na rysunku 6.8, sto obserwacji niesie tyle informacji co około jedenaście niezależnych, a klasyczny błąd standardowy jest około trzy razy za mały. Dla nachylenia prostej symulacja w rozszerzeniu 6.11 daje ten sam czynnik.

Zależność można opisać w modelu (szeregi czasowe, efekty grup) albo zostać przy OLS i użyć błędów standardowych dopuszczających korelację w czasie lub w obrębie grupy, w `statsmodels` przez `cov_type="HAC"` lub `cov_type="cluster"` w metodzie `fit`.

6.8.3. Heteroskedastyczność

Założenie (Z2) wymaga też jednakowej wariancji błędów (**homoskedastyczności**). Jej brak, widoczny jako lejek na wykresie reszt, nazywamy **heteroskedastycznością**. W danych *Advertising*

wariancja rośnie z budżetem telewizyjnym (rysunek 6.2), a w danych *Auto* – z predykcją (rysunek 6.7). Skutki są takie jak przy skorelowanych błędach: $\widehat{\beta}$ pozostaje nieobciążony, klasyczne błędy standardowe są niepoprawne, a OLS przestaje być najlepszym liniowym estymatorem nieobciążonym.

Najprościej zostać przy OLS i zmienić błędy standardowe. **Odporne błędy standardowe** (ang. *heteroskedasticity-consistent*, HC) (White 1980) zastępują wspólne $\widehat{\sigma}^2$ kwadratami reszt poszczególnych obserwacji. Pojedyncze e_i^2 źle szacuje wariancję i-tego błędu, ale wariancja $\widehat{\beta}_j$ zależy od sumy n takich składników, w której ich przypadkowe odchylenia się uśredniają. Wariant HC3 (MacKinnon i White 1985), lepszy w małych próbach, powiększa kwadraty reszt obserwacji o dużej dźwigni, bo ich reszty mają najmniejszą wariancję. W `statsmodels` wystarczy wywołać `fit(cov_type="HC3")`; wzory podaje rozszerzenie 6.11.

Sprawdźmy oba rodzaje przedziałów na symulacji. Niech cecha ma rozkład jednostajny na $[-5, 5]$, $y_i = 1 + 0{,}5\,x_i + \varepsilon_i$, a odchylenie standardowe błędu wynosi $0{,}2\,x_i^2$, czyli rośnie ku krańcom przedziału.

```
n =   30:  pokrycie klasyczne 0.843,  HC3 0.940
n =  100:  pokrycie klasyczne 0.812,  HC3 0.941
n = 1000:  pokrycie klasyczne 0.807,  HC3 0.952
```

Klasyczny przedział pokrywa nachylenie w około 80% prób i nie zbliża się do 95% przy rosnącym n, bo klasyczny wzór szacuje inną wielkość niż rzeczywista wariancja nachylenia. Przedział z błędem HC3 trzyma poziom bliski 95%. Różnica jest tu duża, bo wariancja błędu jest największa w punktach skrajnych, które najmocniej wyznaczają nachylenie.

Porównajmy oba rodzaje błędów standardowych w modelu z telewizją i radiem dla danych *Advertising*.

	klasyczny	HC3
const	0.29449	0.31418
TV	0.00139	0.00195
radio	0.00804	0.01020

Odporny błąd standardowy przy telewizji wynosi 0,00195 zamiast 0,00139, a przy radiu 0,0102 zamiast 0,0080. Przedziały są szersze, ale wnioski o obu mediach się nie zmieniają.

Zamiast poprawiać błędy standardowe, można zmienić model. Gdy rozrzut rośnie z poziomem wyniku, jak w danych *Auto*, często pomaga modelowanie $\log Y$ zamiast Y (Zadanie 6.18). Gdy wariancje błędów są znane z dokładnością do stałej, obserwacje można ważyć.

i Ważona metoda najmniejszych kwadratów

Wymagane jest twierdzenie Gaussa–Markowa w postaci podanej w sekcji 6.3.
Niech wariancje błędów wynoszą $\sigma_i^2 = \sigma^2 w_i$ ze znanymi liczbami $w_i > 0$. Po podzieleniu y_i i całego wiersza $\tilde{\mathbf{x}}_i^\top$ przez $\sqrt{w_i}$ błędy $\varepsilon_i/\sqrt{w_i}$ mają jednakową wariancję σ^2, więc nowe dane spełniają (Z2). OLS dla nich minimalizuje ważoną sumę kwadratów

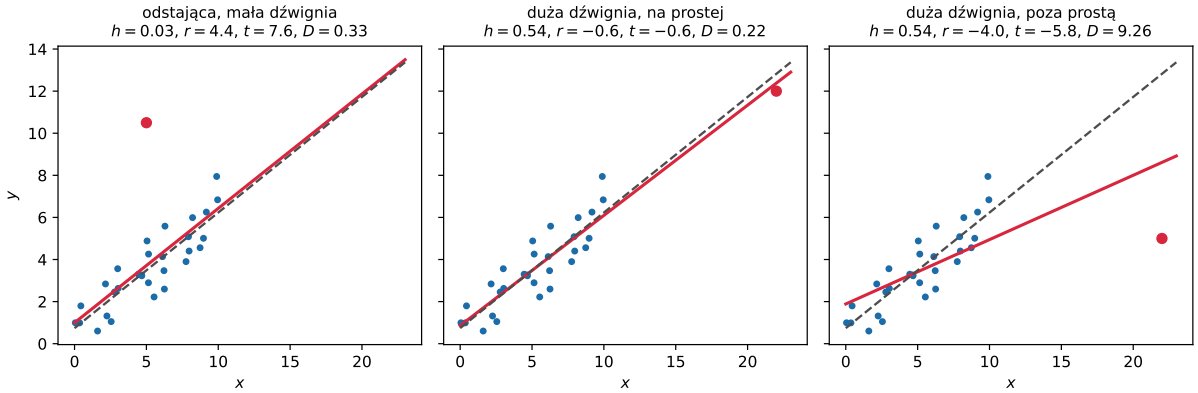
$$\sum_{i=1}^{n} \frac{(y_i - \tilde{\mathbf{x}}_i^\top \beta)^2}{w_i}$$

i z twierdzenia Gaussa–Markowa jest najlepszym liniowym estymatorem nieobciążonym. Tę metodę nazywamy **ważoną metodą najmniejszych kwadratów** (ang. *weighted least*

squares, WLS). Obserwacje o dużej wariancji dostają w niej małą wagę; przypadek średniej z próby rozważa punkt d) zadania 6.7. W praktyce wagi trzeba zwykle oszacować, na przykład z zależności kwadratów reszt od predykcji. W `statsmodels` służy do tego klasa `WLS` z argumentem `weights` równym $1/w_i$.

6.8.4. Obserwacje odstające i wpływowe

Pojedyncza obserwacja może być nietypowa na dwa sposoby. **Obserwacja odstająca** ma nietypowy wynik: leży daleko od dopasowania, czyli ma dużą resztę. **Obserwacja o dużej dźwigni** ma nietypowe cechy: leży daleko od pozostałych w przestrzeni cech. Dla jednej cechy $h_{ii} = 1/n + (x_i - \bar{x})^2 / \sum_k (x_k - \bar{x})^2$ (Zadanie 6.2), więc dźwignia rośnie z odległością od średniej. Średnia dźwignia wynosi $(p+1)/n$ (6.10); według częstej reguły kciuka za dużą uznaje się dźwignię przekraczającą dwukrotność średniej (Belsley i in. 1980). Obserwacja jest **wpływowa**, jeśli jej usunięcie wyraźnie zmienia dopasowanie (rysunek 6.9).



Rysunek 6.9.: Trzy rodzaje nietypowych obserwacji, dodanych (czerwony punkt) do 30 obserwacji z modelu $y = 1{+}0{,}5\,x{+}\varepsilon$. Linia ciągła: prosta OLS ze wszystkimi obserwacjami; przerywana: bez czerwonego punktu. W tytułach: dźwignia h, reszta standaryzowana r, reszta studentyzowana t i odległość Cooka D dodanego punktu.

W pierwszym panelu punkt leży daleko nad prostą, ale blisko średniej x, więc podnosi prostą tylko nieznacznie. W drugim punkt ma dużą dźwignię, ale zgadza się z pozostałymi danymi i prawie nic nie zmienia. W trzecim duża dźwignia i niedopasowanie razem przechylają prostą, więc jedna z 31 obserwacji zmienia nachylenie, a z nim predykcje i wnioski o zależności.

Obserwacje odstające rozpoznajemy po dużych resztach standaryzowanych. Odstająca obserwacja zawyża jednak $\hat{\sigma}$, a tym samym zaniża własną resztę standaryzowaną. **Reszta studentyzowana** t_i różni się od standaryzowanej tylko tym, że σ szacuje się w niej z dopasowania bez obserwacji i; w pierwszym panelu reszta standaryzowana wynosi 4,4, a studentyzowana 7,6. Przy (Z1)–(Z3) t_i ma rozkład t z $n-p-2$ stopniami swobody (rozszerzenie 6.11), więc wartości $|t_i| > 3$ są podejrzane. Przy wielu obserwacjach kilka wartości powyżej 2 jest jednak normalne, jak kilka „istotnych” cech-szumów w sekcji 6.5.

Wpływ obserwacji mierzy **odległość Cooka** D_i (Cook 1977): suma kwadratów zmian predykcji $\hat{y}_1, \ldots, \hat{y}_n$ po usunięciu obserwacji i, podzielona przez $(p+1)\,\hat{\sigma}^2$. Nie trzeba jej liczyć z n dopasowań, bo

$$D_i = \frac{r_i^2}{p+1} \cdot \frac{h_{ii}}{1-h_{ii}}$$

(wyprowadzenie w rozszerzeniu 6.11). Pierwszy czynnik rośnie z resztą, drugi z dźwignią, więc duży wpływ wymaga obu naraz. Na rysunku 6.9 sama duża reszta albo sama duża dźwignia dają D około 0,3 i 0,2, a ich połączenie – $D \approx 9$. Według reguły kciuka uwagi wymagają obserwacje z D_i bliskim 1 lub większym oraz te, których D_i wyraźnie odstaje od pozostałych.

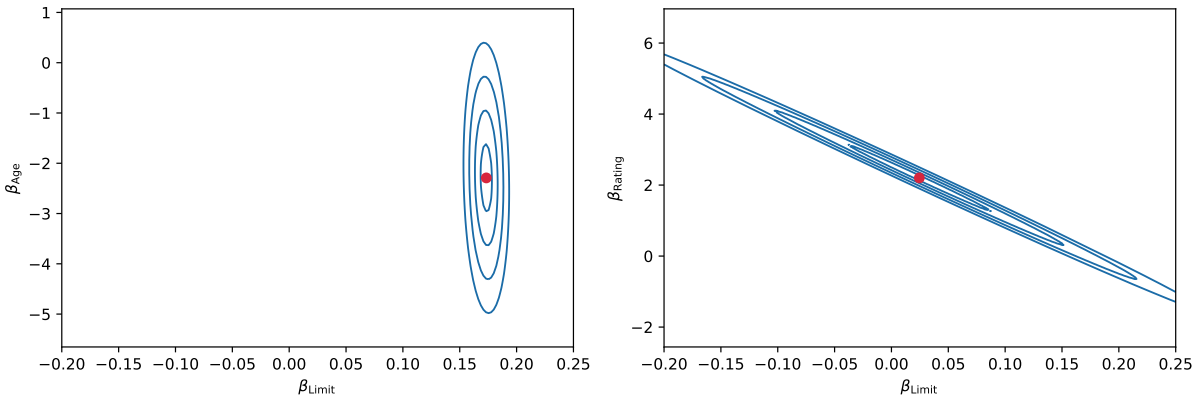
Wykrytej obserwacji nie należy automatycznie usuwać, tylko ustalić, skąd się wzięła. Błąd zapisu poprawiamy lub usuwamy. Prawdziwa, ale nietypowa obserwacja może świadczyć, że model nie obowiązuje w całym zakresie cech, na przykład że zależność zakrzywia się na krańcach. Wtedy pokazujemy wyniki z tą obserwacją i bez niej albo zawężamy zakres wniosków.

6.8.5. Współliniowość

Silną zależność liniową między cechami nazywamy **współliniowością**. W danych *Credit* limit kredytowy i ocena kredytowa mają korelację 0,997: ocena jest w praktyce liniową funkcją limitu. Porównajmy dwa modele salda: z limitem i wiekiem oraz z limitem i oceną.

		wsp
Limit + Age	Limit	0.1
	Age	-2.2
Limit + Rating	Limit	0.0
	Rating	2.2

Oba modele dopasowują się tak samo dobrze ($R^2 \approx 0{,}75$). Błąd standardowy współczynnika przy limicie jest jednak w drugim modelu prawie trzynaście razy większy, a sam limit przestaje być istotny ($p \approx 0{,}70$), choć w pierwszym modelu ma statystykę t ponad 30. Rysunek 6.10 pokazuje przyczynę.



Rysunek 6.10.: Poziomice RSS jako funkcji dwóch współczynników regresji salda dla danych *Credit* (wyraz wolny dobrany optymalnie dla każdej pary). Po lewej: limit i wiek; po prawej: limit i ocena kredytowa. Punkt: minimum RSS. Poziomice odpowiadają wzrostowi RSS o $1, 4, 9$ i 16 wartości $\hat{\sigma}^2$. Oś pozioma ma w obu panelach tę samą skalę.

Przy limicie i wieku poziomice są małymi elipsami, więc oba współczynniki są dobrze wyznaczone. Przy limicie i ocenie tworzą długą, wąską dolinę: zwiększenie współczynnika przy limicie i odpowiednie zmniejszenie współczynnika przy ocenie prawie nie zmienia predykcji, bo obie cechy są niemal proporcjonalne. Dane wyznaczają dokładnie pewną kombinację obu współczynników, ale nie każdy z nich z osobna.

Współliniowość utrudnia więc interpretację współczynników, ale nie psuje predykcji: w obu modelach predykcje dla klientów podobnych do tych z próby są prawie takie same. To sytuacja z sekcji 1.7, w której metraż i liczba pokoi pozwalają dobrze przewidywać cenę, ale nie pozwalają rozdzielić ich wpływu.

Skalę problemu mierzy **czynnik inflacji wariancji** (ang. *variance inflation factor*)

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2},$$

gdzie R_j^2 jest współczynnikiem determinacji regresji cechy j względem pozostałych cech. Do oszacowania β_j służy tylko ta część cechy j, której pozostałe cechy nie przewidują liniowo (Zadanie 6.9), a jej zmienność stanowi ułamek $1 - R_j^2$ zmienności całej cechy. Dlatego wariancja $\hat{\beta}_j$ jest VIF_j razy większa niż wtedy, gdy cecha j jest w próbie nieskorelowana z pozostałymi, a błąd standardowy – $\sqrt{\mathrm{VIF}_j}$ razy (rachunek w rozszerzeniu 6.11). VIF wykrywa też współliniowość kilku cech niewidoczną w korelacjach par (Zadanie 6.16), bo R_j^2 mierzy zależność od wszystkich pozostałych cech naraz.

```
Limit     160.59
Age         1.01
Rating    160.67
Name: VIF, dtype: float64
```

Wartości VIF rzędu 160 dla limitu i oceny oznaczają, że wariancje ich współczynników są około 160 razy większe niż przy cechach nieskorelowanych, a błędy standardowe – około 13 razy większe, jak w porównaniu obu modeli. Wiek, prawie niezależny od obu, ma VIF bliski 1. Według reguły kciuka VIF powyżej 5 lub 10 sygnalizuje kłopotliwą współliniowość (James i in. 2023, rozdz. 3.3.3). Typowe rozwiązania to usunięcie jednej z cech, zastąpienie ich wspólną cechą albo ściąganie współczynników, jak w przypadku estymatora $c\bar{Y}$ z sekcji 4.3.

6.9. Rozszerzenie: geometria i obliczanie MNK

Materiał nieobowiązkowy

Wymagane są podprzestrzenie liniowe, rzut ortogonalny i ślad macierzy. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

W sekcji 6.2 estymator OLS wyznaczyliśmy z równań normalnych $\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}^\top\mathbf{y}$, a predykcje w punktach uczących zapisaliśmy jako $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$, z dźwigniami h_{ii} na przekątnej macierzy $\mathbf{H}$. Tu pokazujemy geometryczny sens tych rachunków, dowodzimy twierdzenia 6.1 i równości (6.10) oraz wyjaśniamy, dlaczego OLS oblicza się inaczej, niż podaje wzór (6.7).

6.9.1. Rzut ortogonalny

Z (6.5) wektor $\mathbf{X}\beta$ jest kombinacją liniową kolumn $\mathbf{X}$, więc gdy β przebiega $\mathbb{R}^{p+1}$, wektor $\mathbf{X}\beta$ przebiega podprzestrzeń $\mathcal{C}(\mathbf{X})$. Przy liniowo niezależnych kolumnach jej wymiar to $p+1$. Minimalizacja $\|\mathbf{y} - \mathbf{X}\beta\|$ jest więc szukaniem punktu tej podprzestrzeni najbliższego $\mathbf{y}$, czyli **rzutu ortogonalnego** $\mathbf{y}$ na $\mathcal{C}(\mathbf{X})$. Warunek $\mathbf{X}^\top\mathbf{e} = \mathbf{0}$ z (6.8) jest warunkiem rzutu: wektor $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$, który łączy $\mathbf{y}$ z jego rzutem, jest prostopadły do podprzestrzeni. Ponieważ $\hat{\mathbf{y}}$ i $\mathbf{e}$ są prostopadłe, zachodzi twierdzenie Pitagorasa: $\|\mathbf{y}\|^2 = \|\hat{\mathbf{y}}\|^2 + \|\mathbf{e}\|^2$. Na tym samym twierdzeniu opiera się dowód twierdzenia 6.1.

Dowód. Dla dowolnego wektora $\mathbf{v}$ mamy $\mathbf{v}^\top\mathbf{X}^\top\mathbf{X}\mathbf{v} = \|\mathbf{X}\mathbf{v}\|^2$. Jeśli $\mathbf{X}^\top\mathbf{X}\mathbf{v} = \mathbf{0}$, to $\|\mathbf{X}\mathbf{v}\|^2 = 0$, czyli $\mathbf{X}\mathbf{v} = \mathbf{0}$, a z liniowej niezależności kolumn $\mathbf{v} = \mathbf{0}$. Macierz $\mathbf{X}^\top\mathbf{X}$ jest więc odwracalna, a $\hat{\beta}$ z (6.7) spełnia równania normalne.

Dla dowolnego β zapiszmy $\mathbf{y} - \mathbf{X}\beta = (\mathbf{y} - \mathbf{X}\hat{\beta}) + \mathbf{X}(\hat{\beta} - \beta)$. Pierwszy składnik to wektor reszt, prostopadły do $\mathcal{C}(\mathbf{X})$, a drugi leży w $\mathcal{C}(\mathbf{X})$. Z twierdzenia Pitagorasa

$$\mathrm{RSS}(\beta) = \mathrm{RSS}(\hat{\beta}) + \|\mathbf{X}(\hat{\beta} - \beta)\|^2.$$

Drugi składnik jest dodatni dla $\beta \neq \hat{\beta}$, bo kolumny $\mathbf{X}$ są liniowo niezależne. □

6.9.2. Macierz daszkowa

Macierz $\mathbf{H}$ o elementach h_{ij} z (6.9) to

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top, \qquad \hat{\mathbf{y}} = \mathbf{H}\mathbf{y}. \tag{6.22}$$

Jest macierzą rzutu ortogonalnego na $\mathcal{C}(\mathbf{X})$: symetryczną ($\mathbf{H}^\top = \mathbf{H}$) i idempotentną ($\mathbf{H}^2 = \mathbf{H}$), bo rzut wektora, który już leży w podprzestrzeni, nic nie zmienia. Macierz $\mathbf{I} - \mathbf{H}$ rzutuje na dopełnienie ortogonalne $\mathcal{C}(\mathbf{X})$ i daje reszty, $\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{y}$. Ślad $\mathbf{H}$ jest równy wymiarowi podprzestrzeni, na którą rzutuje:

$$\operatorname{tr}\mathbf{H} = \operatorname{tr}\left((\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\right) = \operatorname{tr}\mathbf{I}_{p+1} = p + 1, \tag{6.23}$$

gdzie skorzystaliśmy z równości $\operatorname{tr}(\mathbf{AB}) = \operatorname{tr}(\mathbf{BA})$. Ślad to suma elementów przekątnych, czyli dźwigni, co dowodzi równości (6.10). Pozostałe własności $\mathbf{H}$, w tym $0 \le h_{ii} \le 1$, wyprowadza Zadanie 6.3.

Ślad ma ogólniejszy sens. Gdy predykcje są liniowymi kombinacjami wyników, możemy zapisać $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$: element S_{ij} jest wagą wyniku y_j w predykcji dla obserwacji i. W metodzie najmniejszych kwadratów $\mathbf{S} = \mathbf{H}$. Związek tego zapisu z LOOCV omawia rozszerzenie 5.12. Dla regresji k-NN na przekątnej $\mathbf{S}$ stoi $1/k$, więc $\operatorname{tr}\mathbf{S} = n/k$ – to dokładnie efektywna liczba parametrów, którą w rozdziale 4 mierzyliśmy elastyczność tej metody. Dla OLS ślad to $p + 1$, czyli liczba współczynników. Ślad macierzy $\mathbf{S}$ jest więc wspólną miarą elastyczności metod liniowych względem $\mathbf{y}$ (Hastie i in. 2009, rozdz. 7.6).

6.9.3. Obliczanie estymatora

Utworzenie macierzy $\mathbf{X}^\top\mathbf{X}$ podnosi do kwadratu jej wskaźnik uwarunkowania, czyli czynnik, o jaki błędy zaokrągleń mogą się wzmocnić przy rozwiązywaniu układu równań. Biblioteki rozkładają więc $\mathbf{X}$, a nie $\mathbf{X}^\top\mathbf{X}$. W rozkładzie QR, $\mathbf{X} = \mathbf{Q}\mathbf{R}$ z ortonormalnymi kolumnami $\mathbf{Q}$ i górnotrójkątną macierzą $\mathbf{R}$, mamy $\mathbf{X}^\top\mathbf{X} = \mathbf{R}^\top\mathbf{R}$ i $\mathbf{X}^\top\mathbf{y} = \mathbf{R}^\top\mathbf{Q}^\top\mathbf{y}$, więc równania normalne sprowadzają się do układu trójkątnego $\mathbf{R}\beta = \mathbf{Q}^\top\mathbf{y}$. Funkcja `np.linalg.lstsq` korzysta z rozkładu według wartości osobliwych (SVD).

Dla wielomianu stopnia 10 na 50 punktach z przedziału $[0, 1]$ różnica jest duża:

```
uwarunkowanie X:     2.0e+07
uwarunkowanie X^T X: 4.1e+14
```

Przy podwójnej precyzji, czyli około 16 cyfrach znaczących, wskaźnik rzędu 10^{14} zostawia w rozwiązaniu najwyżej dwie wiarygodne cyfry. Dlatego w rozdziale 4 używaliśmy funkcji `Polynomial.fit`, która przed dopasowaniem przeskalowuje x do przedziału $[-1, 1]$.

6.10. Rozszerzenie: własności OLS i podstawy wnioskowania

Materiał nieobowiązkowy

Wymagane są macierz kowariancji wektora losowego, ślad macierzy i macierz daszkowa z rozszerzenia 6.9, a w dwóch ostatnich podsekcjach wielowymiarowy rozkład normalny i rozkłady χ^2, t i F. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

W sekcji 6.3 podaliśmy własności estymatora OLS w modelu $\mathbf{y} = \mathbf{X}\beta + \varepsilon$ z ustaloną macierzą $\mathbf{X}$ o liniowo niezależnych kolumnach, przy założeniach (Z1) $\mathbb{E}\varepsilon = \mathbf{0}$ i (Z2) $\operatorname{Cov}\varepsilon = \sigma^2\mathbf{I}$. Tu je dowodzimy. Rachunki wychodzą od dwóch zapisów. Pierwszy to

$$\hat{\beta} = \beta + \mathbf{A}\varepsilon, \qquad \mathbf{A} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top,$$

z ustaloną macierzą $\mathbf{A}$. Drugi to wektor reszt $\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{y}$, gdzie $\mathbf{H}$ jest macierzą daszkową (6.22).

6.10.1. Macierz kowariancji estymatora

Dla ustalonej macierzy $\mathbf{A}$ i wektora losowego ε o średniej zero

$$\operatorname{Cov}(\mathbf{A}\varepsilon) = \mathbb{E}[\mathbf{A}\varepsilon\varepsilon^\top\mathbf{A}^\top] = \mathbf{A}\operatorname{Cov}(\varepsilon)\mathbf{A}^\top.$$

Stąd druga część twierdzenia 6.2.

Dowód. Przy (Z2)

$$\operatorname{Cov}\hat{\beta} = \operatorname{Cov}(\mathbf{A}\varepsilon) = \sigma^2\mathbf{A}\mathbf{A}^\top = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1} = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}.$$

□

Wariancja predykcji w nowym punkcie wynika z tego samego wzoru. Niech $\tilde{\mathbf{X}}_0$ będzie losowym wektorem cech uzupełnionym o jedynkę, niezależnym od próby, i niech $\Sigma_0 = \mathbb{E}[\tilde{\mathbf{X}}_0\tilde{\mathbf{X}}_0^\top]$. Liczba jest równa swojemu śladowi, a $\operatorname{tr}(\mathbf{AB}) = \operatorname{tr}(\mathbf{BA})$, więc

$$\mathbb{E}[\tilde{\mathbf{X}}_0^\top(\mathbf{X}^\top\mathbf{X})^{-1}\tilde{\mathbf{X}}_0] = \operatorname{tr}\left((\mathbf{X}^\top\mathbf{X})^{-1}\Sigma_0\right).$$

Gdy cechy uczące pochodzą z tego samego rozkładu co $\mathbf{X}_0$, przy dużym n mamy $\mathbf{X}^\top\mathbf{X} = \sum_i \tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top \approx n\Sigma_0$, więc średnia wariancja predykcji w nowym punkcie jest bliska $\sigma^2 \operatorname{tr}\mathbf{I}_{p+1}/n = \sigma^2(p+1)/n$.

6.10.2. Suma kwadratów reszt

Dowód twierdzenia 6.3 korzysta z własności macierzy $\mathbf{H}$ z rozszerzenia 6.9.

Dowód. Ponieważ $(\mathbf{I} - \mathbf{H})\mathbf{X} = \mathbf{0}$, wektor reszt to $\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{y} = (\mathbf{I} - \mathbf{H})\varepsilon$. Macierz $\mathbf{I} - \mathbf{H}$ jest symetryczna i idempotentna, więc $\mathrm{RSS} = \mathbf{e}^\top\mathbf{e} = \varepsilon^\top(\mathbf{I} - \mathbf{H})\varepsilon$. Dla ustalonej macierzy $\mathbf{M}$ mamy $\mathbb{E}[\varepsilon^\top\mathbf{M}\varepsilon] = \sum_{i,j} M_{ij}\mathbb{E}[\varepsilon_i\varepsilon_j] = \sigma^2 \operatorname{tr}\mathbf{M}$, a $\operatorname{tr}(\mathbf{I} - \mathbf{H}) = n - (p+1)$ z (6.23). □

Dowód ma prosty obraz geometryczny. Wektor błędów ma n współrzędnych, a w każdym z n wzajemnie prostopadłych kierunków jego składowa ma przeciętnie kwadrat σ^2. Składowa $\mathbf{H}\varepsilon$ w $(p+1)$-wymiarowej podprzestrzeni $\mathcal{C}(\mathbf{X})$ przechodzi do predykcji, a w resztach zostaje składowa w dopełnieniu ortogonalnym, które ma wymiar $n - p - 1$. Z tego samego zapisu wynika macierz kowariancji reszt: $\operatorname{Cov}\mathbf{e} = (\mathbf{I} - \mathbf{H})\,\sigma^2\mathbf{I}\,(\mathbf{I} - \mathbf{H})^\top = \sigma^2(\mathbf{I} - \mathbf{H})$.

6.10.3. Optymalność wśród estymatorów liniowych

Estymator $\tilde{\beta}$ nazywamy **liniowym**, jeśli $\tilde{\beta} = \mathbf{C}\mathbf{y}$ dla macierzy $\mathbf{C}$ zależnej tylko od $\mathbf{X}$. Estymator OLS jest liniowy, z $\mathbf{C} = \mathbf{A}$.

Twierdzenie 6.4 (Gaussa–Markowa)**.** *Przy założeniach (Z1)–(Z2) niech $\tilde{\beta} = \mathbf{C}\mathbf{y}$ będzie dowolnym liniowym estymatorem β nieobciążonym dla każdej wartości β. Wtedy macierz* $\operatorname{Cov}\tilde{\beta} - \operatorname{Cov}\hat{\beta}$ *jest dodatnio półokreślona. W szczególności dla każdego wektora* $\mathbf{c}$

$$\operatorname{Var}(\mathbf{c}^\top\tilde{\beta}) \geq \operatorname{Var}(\mathbf{c}^\top\hat{\beta}).$$

Dowód. Niech $\mathbf{D} = \mathbf{C} - \mathbf{A}$. Nieobciążoność oznacza $\mathbb{E}\tilde{\beta} = \mathbf{C}\mathbf{X}\beta = \beta$ dla każdego β, czyli $\mathbf{C}\mathbf{X} = \mathbf{I}$. Ponieważ $\mathbf{A}\mathbf{X} = \mathbf{I}$, mamy $\mathbf{D}\mathbf{X} = \mathbf{0}$. Stąd $\mathbf{A}\mathbf{D}^\top = (\mathbf{X}^\top\mathbf{X})^{-1}(\mathbf{D}\mathbf{X})^\top = \mathbf{0}$ i

$$\operatorname{Cov}\tilde{\beta} = \sigma^2\mathbf{C}\mathbf{C}^\top = \sigma^2(\mathbf{A}+\mathbf{D})(\mathbf{A}+\mathbf{D})^\top = \sigma^2\mathbf{A}\mathbf{A}^\top + \sigma^2\mathbf{D}\mathbf{D}^\top = \operatorname{Cov}\hat{\beta} + \sigma^2\mathbf{D}\mathbf{D}^\top.$$

Macierz $\mathbf{D}\mathbf{D}^\top$ jest dodatnio półokreślona, bo $\mathbf{c}^\top\mathbf{D}\mathbf{D}^\top\mathbf{c} = \|\mathbf{D}^\top\mathbf{c}\|^2 \geq 0$. □

Dla $\mathbf{c} = \tilde{\mathbf{x}}_0$ nierówność dotyczy predykcji $\tilde{\mathbf{x}}_0^\top\hat{\beta}$ w dowolnym punkcie $\mathbf{x}_0$. Dla modelu z samym wyrazem wolnym twierdzenie mówi, że średnia z próby jest najlepszą nieobciążoną średnią ważoną obserwacji (Zadanie 6.7). Dowód korzysta z (Z2) w równości $\operatorname{Cov}\tilde{\beta} = \sigma^2\mathbf{C}\mathbf{C}^\top$. Gdy błędy mają różne wariancje, znane z dokładnością do stałej, najlepszym estymatorem liniowym nieobciążonym jest ważona metoda najmniejszych kwadratów z sekcji 6.8.

6.10.4. Rozkłady przy normalnych błędach

W sekcji 6.5 korzystaliśmy z tego, że przy założeniach (Z1)–(Z3) statystyka t ma rozkład t, a statystyka F – rozkład F. Pierwszy fakt wynika wprost z następującego twierdzenia, drugi – z tego samego rozumowania co jego dowód.

Twierdzenie 6.5 (Rozkłady w modelu liniowym z normalnymi błędami)**.** *Przy założeniach (Z1)–(Z3):*

a) $\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1})$*;*
b) RSS/σ^2 *ma rozkład* χ^2 *z* $n-p-1$ *stopniami swobody;*
c) $\hat{\beta}$ *i* RSS *są niezależne.*

szkic. Część (a): $\hat{\beta} = \beta + \mathbf{A}\varepsilon$ jest przekształceniem liniowym wektora gaussowskiego, więc ma rozkład normalny, a jego parametry podaje twierdzenie 6.2.

Części (b) i (c) wynikają z geometrii. Wybierzmy bazę ortonormalną $\mathbb{R}^n$, w której pierwsze $p+1$ wektorów rozpina $\mathcal{C}(\mathbf{X})$, a pozostałe $n-p-1$ – jej dopełnienie ortogonalne. Niech $\mathbf{Q}$ będzie macierzą ortogonalną o tych wektorach w kolumnach, a $\mathbf{z} = \mathbf{Q}^\top\varepsilon$ wektorem współrzędnych błędów w nowej bazie. Rozkład $\mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I})$ jest sferycznie symetryczny, więc obrót go nie zmienia: $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I})$, czyli współrzędne $z_1, \ldots, z_n$ są niezależne. Składowa $\mathbf{H}\varepsilon$ zależy tylko od $z_1, \ldots, z_{p+1}$, a reszty $\mathbf{e} = (\mathbf{I}-\mathbf{H})\varepsilon$ – tylko od $z_{p+2}, \ldots, z_n$. Stąd $\mathrm{RSS} = \|\mathbf{e}\|^2 = z_{p+2}^2 + \cdots + z_n^2$ jest sumą kwadratów $n-p-1$ niezależnych zmiennych $\mathcal{N}(0, \sigma^2)$, co daje (b). Ponadto $\hat{\beta} - \beta = \mathbf{A}\varepsilon = \mathbf{A}\mathbf{H}\varepsilon$ (bo $\mathbf{X}^\top\mathbf{H} = \mathbf{X}^\top$) zależy tylko od $z_1, \ldots, z_{p+1}$, co daje (c). Szczegółowy wykład zawierają Seber i Lee (2003, rozdz. 2–3). □

Statystykę (6.18) można zapisać jako

$$T_j = \frac{(\hat{\beta}_j - \beta_j)/(\sigma\sqrt{v_{jj}})}{\sqrt{\mathrm{RSS}/(\sigma^2(n-p-1))}}.$$

Z części (a) licznik ma rozkład $\mathcal{N}(0,1)$, z części (b) mianownik jest pierwiastkiem ze zmiennej χ^2_{n-p-1} podzielonej przez liczbę stopni swobody, a z części (c) licznik i mianownik są niezależne. Taki iloraz ma z definicji rozkład t Studenta z $n-p-1$ stopniami swobody.

6.10.5. Rozkład statystyki F

Niech model M_0 o macierzy $\mathbf{X}_0$ powstaje z modelu M przez usunięcie q cech. Podprzestrzeń $\mathcal{C}(\mathbf{X}_0)$ jest zawarta w $\mathcal{C}(\mathbf{X})$. Wektor $\mathbf{y}-\hat{\mathbf{y}}_0$ rozkłada się na $(\mathbf{y}-\hat{\mathbf{y}})+(\hat{\mathbf{y}}-\hat{\mathbf{y}}_0)$, przy czym pierwszy składnik jest prostopadły do $\mathcal{C}(\mathbf{X})$, a drugi w niej leży. Z twierdzenia Pitagorasa

$$\mathrm{RSS}_0 = \mathrm{RSS} + \|\hat{\mathbf{y}} - \hat{\mathbf{y}}_0\|^2.$$

Jeśli H_0 jest prawdziwa, to $\mathbf{X}\beta \in \mathcal{C}(\mathbf{X}_0)$, więc $\hat{\mathbf{y}} - \hat{\mathbf{y}}_0$ jest rzutem samego szumu ε na q-wymiarową podprzestrzeń: część $\mathcal{C}(\mathbf{X})$ prostopadłą do $\mathcal{C}(\mathbf{X}_0)$. Rozumowanie ze szkicu dowodu twierdzenia 6.5, z bazą dopasowaną do trzech wzajemnie prostopadłych podprzestrzeni, daje $\|\hat{\mathbf{y}} - \hat{\mathbf{y}}_0\|^2/\sigma^2 \sim \chi^2_q$, niezależne od RSS. Statystyka (6.20) jest więc przy H_0 ilorazem dwóch niezależnych zmiennych χ^2 podzielonych przez swoje stopnie swobody, czyli ma rozkład F z q i $n-p-1$ stopniami swobody. Ten sam rozkład wektora ε na składowe w trzech podprzestrzeniach pokazuje, dlaczego przy H_0 licznik ma średnią σ^2: każdy z q kierunków wnosi przeciętnie σ^2.

6.11. Rozszerzenie: rachunek diagnostyki

Materiał nieobowiązkowy

Wymagane są macierz kowariancji wektora losowego, macierz daszkowa z rozszerzenia 6.9, reszta „pozostaw jeden” z zadania 6.4, a w części o reszcie studentyzowanej i odległości Cooka – rozkłady t i F oraz twierdzenie 6.5. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

Sekcja podaje rachunki do diagnostyki z sekcji 6.8: najpierw wzory dla reszt, odległości Cooka i czynnika VIF, potem macierz kowariancji estymatora przy błędach skorelowanych lub o różnych wariancjach. Model ma postać $\mathbf{y} = \mathbf{X}\beta + \varepsilon$ z ustaloną macierzą $\mathbf{X}$ o liniowo niezależnych kolumnach, a estymator OLS – postać

$$\hat{\beta} = \beta + \mathbf{A}\varepsilon, \qquad \mathbf{A} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top.$$

Klasyczne wzory zakładają (Z1) $\mathbb{E}\varepsilon = \mathbf{0}$ i (Z2) $\operatorname{Cov}\varepsilon = \sigma^2\mathbf{I}$.

6.11.1. Reszty, odległość Cooka i VIF

Predykcje w punktach uczących to $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$, gdzie $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$ jest macierzą daszkową (6.22) o elementach h_{ij} z (6.9). Ponieważ $\mathbf{H}\mathbf{X} = \mathbf{X}$, wektor reszt to $\mathbf{e} = (\mathbf{I}-\mathbf{H})\mathbf{y} = (\mathbf{I}-\mathbf{H})\varepsilon$. Macierz kowariancji reszt wyprowadziliśmy po dowodzie twierdzenia 6.3 w rozszerzeniu 6.10; przy (Z1)–(Z2)

$$\operatorname{Cov}\mathbf{e} = \sigma^2(\mathbf{I}-\mathbf{H}), \qquad \operatorname{Var} e_i = \sigma^2(1-h_{ii}). \tag{6.24}$$

Reszty są więc skorelowane i mają różne wariancje, nawet gdy błędy są niezależne i jednakowe. Mechanizm widać we współrzędnej i: $e_i = (1-h_{ii})\varepsilon_i - \sum_{j\neq i} h_{ij}\varepsilon_j$, czyli ułamek h_{ii} własnego błędu przechodzi do predykcji $\hat{y}_i$.

Reszta standaryzowana $r_i = e_i/(\hat{\sigma}\sqrt{1-h_{ii}})$ dzieli e_i przez oszacowanie jego odchylenia standardowego. Odstająca obserwacja i sama zawyża jednak $\hat{\sigma}$. Reszta studentyzowana

$$t_i = \frac{e_i}{\hat{\sigma}_{(-i)}\sqrt{1-h_{ii}}} \tag{6.25}$$

używa oszacowania $\hat{\sigma}_{(-i)}$ z dopasowania bez obserwacji i. Z zadania 6.4 reszta „pozostaw jeden" wynosi $y_i - \tilde{\mathbf{x}}_i^\top \hat{\beta}^{(-i)} = e_i/(1-h_{ii})$, a jej wariancja to $\sigma^2/(1-h_{ii})$ (Zadanie 6.13). Zatem t_i jest błędem predykcji y_i z modelu dopasowanego bez obserwacji i, podzielonym przez oszacowanie jego odchylenia standardowego z tego samego dopasowania. Z tego zapisu wynika rozkład t_i przy (Z1)–(Z3). Licznik $y_i - \tilde{\mathbf{x}}_i^\top \hat{\beta}^{(-i)}$ jest liniową funkcją błędów, więc ma rozkład normalny o średniej zero. Zależy tylko od ε_i i $\hat{\beta}^{(-i)}$, a $\hat{\sigma}_{(-i)}$ liczymy z pozostałych $n-1$ obserwacji, więc jest niezależne od ε_i, a od $\hat{\beta}^{(-i)}$ – na mocy twierdzenia 6.5 zastosowanego do tych obserwacji. Tak jak statystyka (6.18), iloraz ma więc rozkład t z $(n-1)-(p+1) = n-p-2$ stopniami swobody.

Odległość Cooka definiujemy przez zmianę wektora predykcji w punktach uczących po usunięciu obserwacji i:

$$D_i = \frac{\|\mathbf{X}(\hat{\beta} - \hat{\beta}^{(-i)})\|^2}{(p+1)\,\hat{\sigma}^2} = \frac{e_i^2}{(p+1)\,\hat{\sigma}^2}\cdot\frac{h_{ii}}{(1-h_{ii})^2} = \frac{r_i^2}{p+1}\cdot\frac{h_{ii}}{1-h_{ii}}. \tag{6.26}$$

Druga postać wynika ze wzoru na $\hat{\beta}-\hat{\beta}^{(-i)}$ z zadania 6.4, bo $\|\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\tilde{\mathbf{x}}_i\|^2 = \tilde{\mathbf{x}}_i^\top(\mathbf{X}^\top\mathbf{X})^{-1}\tilde{\mathbf{x}}_i = h_{ii}$, a trzecia – z definicji r_i (Zadanie 6.15). Dzielnik pochodzi z obszaru ufności dla β. Przy (Z1)–(Z3) statystyka $(\hat{\beta}-\beta)^\top\mathbf{X}^\top\mathbf{X}(\hat{\beta}-\beta)/((p+1)\hat{\sigma}^2)$ ma rozkład F z $p+1$ i $n-p-1$ stopniami swobody, co wynika z twierdzenia 6.5 tak jak rozkład statystyki F. Licznik D_i ma tę samą postać, z $\hat{\beta}^{(-i)}$ w miejscu β. Cook (1977) zaproponował więc porównywać D_i z kwantylami tego rozkładu. Wartość D_i równa jego medianie, około 0,7 dla $p=1$ i bliżej 1 przy większej liczbie cech, oznacza, że usunięcie obserwacji przesuwa estymator na brzeg 50-procentowego obszaru ufności. Stąd reguła kciuka $D_i \gtrsim 1$.

Wzór na VIF wynika z zadania 6.9, w którym wyprowadzamy $\operatorname{Var}\hat{\beta}_j = \sigma^2/\|\mathbf{r}_j\|^2$, gdzie $\mathbf{r}_j$ to reszty z regresji cechy j względem pozostałych cech z wyrazem wolnym. W tej regresji $\mathrm{TSS} = \sum_i (x_{ij}-\bar{x}_j)^2$ i $\mathrm{RSS} = \|\mathbf{r}_j\|^2$, więc z (6.17) $\|\mathbf{r}_j\|^2 = (1-R_j^2)\sum_i(x_{ij}-\bar{x}_j)^2$ i

$$\operatorname{Var}\hat{\beta}_j = \frac{\sigma^2}{\sum_{i=1}^n (x_{ij}-\bar{x}_j)^2}\cdot\frac{1}{1-R_j^2}. \tag{6.27}$$

Pierwszy czynnik to wariancja, jaką $\hat{\beta}_j$ miałby, gdyby cecha j była w próbie nieskorelowana z pozostałymi (wtedy $R_j^2 = 0$), na przykład w regresji prostej. Drugi czynnik to VIF_j.

6.11.2. Błędy skorelowane i estymator kanapkowy

Nieobciążoność wymaga tylko (Z1), bo $\mathbb{E}\hat{\beta} = \beta + \mathbf{A}\,\mathbb{E}\varepsilon = \beta$. Niech teraz $\operatorname{Cov}\varepsilon = \Sigma$ będzie dowolną macierzą kowariancji. Dla ustalonej macierzy $\mathbf{A}$ mamy $\operatorname{Cov}(\mathbf{A}\varepsilon) = \mathbf{A}\Sigma\mathbf{A}^\top$, więc

$$\operatorname{Cov}\hat{\beta} = \mathbf{A}\Sigma\mathbf{A}^\top = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\Sigma\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}. \tag{6.28}$$

Wzór nazywa się **kanapkowym**: macierz $\mathbf{X}^\top\Sigma\mathbf{X}$ leży w nim między dwoma czynnikami $(\mathbf{X}^\top\mathbf{X})^{-1}$. Tylko przy $\Sigma = \sigma^2\mathbf{I}$ upraszcza się do $\sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}$, więc w ogólności klasyczne błędy standardowe szacują niewłaściwą wielkość.

Sprawdźmy skalę błędu na układzie z rysunku 6.8: $n = 100$ pomiarów w chwilach $t_i = i/n$, prosta $y_i = 1 + 2t_i + \varepsilon_i$ i błędy autoregresyjne $\varepsilon_i = 0{,}8\,\varepsilon_{i-1} + z_i$, gdzie z_i są niezależne i standardowe normalne. Dla takich błędów $\operatorname{Cov}(\varepsilon_s, \varepsilon_t)$ jest proporcjonalna do $0{,}8^{|s-t|}$, więc Σ nie jest diagonalna.

```
średnia nachylenia:              2.032
odchylenie std. nachylenia:      1.626
średni klasyczny błąd std.:      0.529
pokrycie przedziału 95%:         0.475
```

Nachylenie jest szacowane bez obciążenia, ale jego odchylenie standardowe w próbach, około 1,63, jest około trzy razy większe od średniego klasycznego błędu standardowego, około 0,53. Przedział „95%” pokrywa prawdziwą wartość w mniej niż połowie prób. Czynnik zgadza się z rachunkiem dla średniej z próby w zadaniu 6.17: przy $\rho = 0{,}8$ wariancja średniej jest w przybliżeniu $(1+\rho)/(1-\rho) = 9$ razy większa niż dla niezależnych obserwacji, a odchylenie standardowe – trzy razy.

Przy niezależnych błędach o różnych wariancjach σ_i^2 macierz Σ jest diagonalna, a środek wzoru (6.28) ma postać $\mathbf{X}^\top\Sigma\mathbf{X} = \sum_i \sigma_i^2\,\tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top$. White (1980) pokazał, że zastąpienie σ_i^2 przez e_i^2 daje zgodny estymator $\operatorname{Cov}\hat\beta$:

$$(\mathbf{X}^\top\mathbf{X})^{-1}\Big(\sum_{i=1}^{n} e_i^2\,\tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top\Big)(\mathbf{X}^\top\mathbf{X})^{-1}.$$

Każde e_i^2 osobno bardzo źle szacuje σ_i^2, ale środkowa macierz jest sumą n składników wymiaru $(p+1)\times(p+1)$, w której te błędy się uśredniają. Reszty są jednak systematycznie mniejsze od błędów: przy stałej wariancji $\operatorname{Var} e_i = \sigma^2(1-h_{ii})$ (6.24), najmniej dla obserwacji o dużej dźwigni. Wariant HC3 zastępuje więc e_i^2 przez $e_i^2/(1-h_{ii})^2$, czyli kwadrat reszty „pozostaw jeden” z zadania 6.4. Poprawka jest duża dla obserwacji o dużej dźwigni i mała, gdy wszystkie dźwignie są bliskie średniej $(p+1)/n$.

Ten sam wzór (6.28) z estymatorem Σ, który dopuszcza korelację sąsiednich obserwacji w czasie albo obserwacji z tej samej grupy, daje błędy standardowe odporne na skorelowanie błędów (`cov_type="HAC"` i `cov_type="cluster"` w `statsmodels`).

Uwagi bibliograficzne

Regresję liniową w ujęciu bliskim temu rozdziałowi wykładają James i in. (2023, rozdz. 3.1–3.2), także na danych *Advertising*. Hastie i in. (2009, rozdz. 3.2) podają geometrię najmniejszych kwadratów, twierdzenie Gaussa–Markowa (Hastie i in. 2009, rozdz. 3.2.2) oraz interpretację współczynników regresji wielokrotnej przez kolejne regresje na resztach, wykorzystaną w zadaniu 6.9 (Hastie i in. 2009, rozdz. 3.2.3). Geometryczny obraz OLS jako rzutu ortogonalnego rysuje też Bishop (2006, rozdz. 3.1), który wyprowadza OLS jako metodę największej wiarygodności przy normalnych błędach. Ślad macierzy wygładzającej jako efektywną liczbę parametrów omawiają Hastie i in. (2009, rozdz. 7.6).

Pełne dowody faktów, które w rozszerzeniu 6.10 tylko naszkicowaliśmy – rozkładów $\hat\beta$ i RSS, ich niezależności, testu F dla dowolnych hipotez liniowych – zawierają Seber i Lee (2003). Rozkład

normalny wielowymiarowy i formy kwadratowe wykładają w rozdz. 2, estymację w rozdz. 3, a testowanie hipotez w rozdz. 4.

Cechy jakościowe, interakcje, przekształcenia cech i przegląd problemów modelu liniowego, od nieliniowości po współliniowość, omawiają James i in. (2023, rozdz. 3.3). Diagnostykę wpływu pojedynczych obserwacji i współliniowości systematycznie wykładają Belsley i in. (1980); odległość Cooka pochodzi od Cook (1977). Estymator kowariancji odporny na heteroskedastyczność wprowadził White (1980), a jego warianty o lepszych własnościach w małych próbach, w tym HC3, porównali MacKinnon i White (1985).

Zadania

Zadanie 6.1. Rozważ regresję z jedną cechą, $p = 1$.

a) Z równań normalnych wyprowadź wzory (6.3).
b) Niech r będzie współczynnikiem korelacji z próby, a s_x, s_y – odchyleniami standardowymi z próby. Wykaż, że $\hat{\beta}_1 = r\, s_y / s_x$. Wyraź prostą regresji w zmiennych standaryzowanych $(x-\bar{x})/s_x$ i $(y-\bar{y})/s_y$. Dlaczego przy $|r| < 1$ przewidywane odchylenie wyniku od średniej, mierzone w odchyleniach standardowych, jest zawsze mniejsze niż odchylenie cechy?
c) Wykaż, że $R^2 = r^2$.
d) Odwracając macierz $\mathbf{X}^\top\mathbf{X}$ wymiaru 2×2, wyprowadź (6.12).
e) Niech para (X, Y) ma skończone drugie momenty i $\operatorname{Var} X > 0$. Znajdź a, b minimalizujące $\mathbb{E}[(Y - a - bX)^2]$ i porównaj wynik z (6.3).
f) Przy założeniach (Z1)–(Z2) wykaż, że $\mathbb{E}[\mathrm{ESS}] = \beta_1^2 \sum_i (x_i - \bar{x})^2 + \sigma^2$. (Wskazówka: $\mathrm{ESS} = \hat{\beta}_1^2 \sum_i (x_i - \bar{x})^2$.) Jak zmienia się typowa wartość R^2, gdy rozrzut x_i rośnie, a β_1 i σ są ustalone?

Zadanie 6.2. Niech h_{ii} będzie dźwignią obserwacji i z (6.9). Dla jednej cechy wykaż, że $h_{ii} = \frac{1}{n} + \frac{(x_i-\bar{x})^2}{\sum_k (x_k-\bar{x})^2}$. Które obserwacje mają największy wpływ na własne dopasowanie?

Zadanie 6.3. Rozszerzenie: macierz daszkowa. Wymagany jest zapis (6.22) i $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$ z rozszerzenia 6.9. Niech $\mathbf{H}$ będzie macierzą daszkową o elementach h_{ij} z (6.9).

a) Wykaż, że $\mathbf{H}^\top = \mathbf{H}$, $\mathbf{H}^2 = \mathbf{H}$ i $\mathbf{H}\mathbf{X} = \mathbf{X}$. Wywnioskuj, że $\mathbf{H}\mathbf{1} = \mathbf{1}$, czyli że każda predykcja $\hat{y}_i$ jest kombinacją wyników $y_1, \ldots, y_n$ o wagach sumujących się do jedynki. Czy wagi te muszą być nieujemne?
b) Korzystając z punktu a), wykaż, że $0 \le h_{ii} \le 1$. (Wskazówka: z $\mathbf{H} = \mathbf{H}^2 = \mathbf{H}^\top\mathbf{H}$ wynika $h_{ii} = \sum_j h_{ij}^2$.)
c) Porównaj własności z punktów a)–b) z macierzą $\mathbf{S}$ regresji k-NN: $S_{ij} = 1/k$, gdy punkt j należy do k najbliższych sąsiadów punktu i (włącznie z nim samym), a poza tym $S_{ij} = 0$. Czym różnią się wagi w obu metodach? Zapis ten omawia też rozszerzenie 5.12.

Zadanie 6.4. Rozszerzenie: reszta „pozostaw jeden”. Wymagane są wzór Shermana–Morrisona i zapis macierzowy MNK. Niech $\hat{\beta}^{(-i)}$ będzie estymatorem OLS wyznaczonym bez obserwacji i, a $\tilde{\mathbf{x}}_i^\top$ – i-tym wierszem $\mathbf{X}$.

a) Korzystając ze wzoru Shermana–Morrisona $(\mathbf{M} - \mathbf{u}\mathbf{u}^\top)^{-1} = \mathbf{M}^{-1} + \frac{\mathbf{M}^{-1}\mathbf{u}\mathbf{u}^\top\mathbf{M}^{-1}}{1-\mathbf{u}^\top\mathbf{M}^{-1}\mathbf{u}}$, wykaż, że

$$\hat{\beta} - \hat{\beta}^{(-i)} = \frac{(\mathbf{X}^\top\mathbf{X})^{-1}\tilde{\mathbf{x}}_i\, e_i}{1 - h_{ii}}.$$

b) Wywnioskuj, że reszta „pozostaw jeden" wynosi $y_i - \tilde{\mathbf{x}}_i^\top \hat{\beta}^{(-i)} = e_i/(1-h_{ii})$, i zapisz błąd LOOCV metody najmniejszych kwadratów przez reszty i dźwignie jednego dopasowania. Jest to wzór, na który powołaliśmy się w rozszerzeniu 5.12.
c) Sprawdź wynik numerycznie dla regresji sprzedaży względem `TV` i `radio`, porównując go z n jawnymi dopasowaniami.
d) Które obserwacje mają resztę „pozostaw jeden" najbardziej różną od zwykłej reszty?

Zadanie 6.5. Przy założeniach (Z1)–(Z2) niech Y_i' będzie nową obserwacją wyniku w punkcie $\mathbf{x}_i$, niezależną od próby i o tym samym rozkładzie co Y_i. Predykcję $\hat{y}_i = \sum_{j=1}^n h_{ij} Y_j$ traktujemy tu jako zmienną losową, funkcję $Y_1, \dots, Y_n$.

a) Wykaż, że $\sum_{i=1}^n \operatorname{Cov}(Y_i, \hat{y}_i) = \sigma^2(p+1)$.
b) Wykaż, że

$$\mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^n (Y_i' - \hat{y}_i)^2\Big] = \sigma^2\Big(1 + \frac{p+1}{n}\Big), \qquad \mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^n (Y_i - \hat{y}_i)^2\Big] = \sigma^2\Big(1 - \frac{p+1}{n}\Big),$$

więc optymizm błędu uczącego wynosi $2\sigma^2(p+1)/n$.
c) Porównaj wynik z zadaniem 4.4, zapisując optymizm metody k-NN przez efektywną liczbę parametrów n/k.
d) Ile cech można dodać do modelu przy $n = 100$, żeby błąd uczący zaniżał błąd na nowych obserwacjach w tych samych punktach o nie więcej niż 10% wartości σ^2?

Zadanie 6.6.

a) **Rozszerzenie: forma kwadratowa błędów.** Wymagany jest ślad macierzy; rachunek jest krokiem dowodu twierdzenia 6.3 w rozszerzeniu 6.10. Niech ε ma średnią $\mathbf{0}$ i macierz kowariancji $\sigma^2\mathbf{I}$, a $\mathbf{M}$ będzie ustaloną macierzą. Wykaż, że $\mathbb{E}[\varepsilon^\top \mathbf{M} \varepsilon] = \sigma^2 \operatorname{tr} \mathbf{M}$. Czy potrzebna jest normalność?
b) Wykaż, że dla modelu z samym wyrazem wolnym ($p = 0$) estymator (6.15) jest wariancją z próby z mianownikiem $n-1$.
c) Przeprowadź symulację z rysunku 6.3 dla modelu wielomianowego stopnia $d = 1, 5, 15$ przy $n = 30$, w którym prawdziwa funkcja regresji jest prostą. Porównaj średnie RSS/n i $\mathrm{RSS}/(n-d-1)$ po próbach z σ^2.

Zadanie 6.7. Niech $Y_i = \mu + \varepsilon_i$, $i = 1, \dots, n$, z nieskorelowanymi błędami o średniej zero.

a) Wykaż, że estymatorem OLS parametru μ jest $\bar{Y}$.
b) Estymator liniowy $\sum_i c_i Y_i$ jest nieobciążony wtedy i tylko wtedy, gdy $\sum_i c_i = 1$. Przy $\operatorname{Var} \varepsilon_i = \sigma^2$ wykaż bezpośrednio, bez twierdzenia 6.4, że jego wariancja jest najmniejsza dla $c_i = 1/n$.
c) Estymator $c\bar{Y}$ z sekcji 4.3 może mieć mniejszy błąd średniokwadratowy niż $\bar{Y}$. Dlaczego nie przeczy to twierdzeniu Gaussa–Markowa?
d) Niech teraz $\operatorname{Var} \varepsilon_i = \sigma_i^2$ będą różne i znane. Znajdź najlepszy liniowy estymator nieobciążony μ. Ile razy mniejszą wariancję ma od $\bar{Y}$, gdy połowa obserwacji ma wariancję 1, a połowa 9?

Zadanie 6.8. Przyjmij układ z rysunku 6.3: ustalone x_i z rozkładu jednostajnego na $[0, 10]$, $y_i = 1 + 0{,}5\, x_i + \varepsilon_i$. Dla $n = 20$ i $n = 500$ oszacuj na 10 000 próbach, jak często przedział (6.19) na poziomie 95% zawiera β_1, gdy

a) $\varepsilon_i \sim \mathcal{N}(0, 1{,}5^2)$;

b) ε_i ma scentrowany rozkład wykładniczy o odchyleniu standardowym 1,5 (rozkład silnie skośny);
c) $\varepsilon_i \sim \mathcal{N}(0, (0{,}3\, x_i)^2)$, czyli wariancja błędu rośnie z x, jak w danych *Advertising*.

Które z założeń (Z1)–(Z3) jest naruszone w każdym przypadku? Dlaczego w przypadku (b) zwiększenie n pomaga, a w przypadku (c) nie? Porównaj w przypadku (c) odchylenie standardowe $\hat{\beta}_1$ z symulacji ze średnią $\mathrm{SE}(\hat{\beta}_1)$ podawaną przez wzór.

Zadanie 6.9. Niech $\mathbf{x}_j$ będzie kolumną j macierzy $\mathbf{X}$, $\mathbf{X}_{-j}$ – macierzą bez tej kolumny, a $\mathbf{r}_j$ – wektorem reszt z regresji $\mathbf{x}_j$ względem kolumn $\mathbf{X}_{-j}$.

a) Dla danych *Advertising* wyznacz reszty z regresji `newspaper` względem `TV` i `radio`, a potem współczynnik kierunkowy regresji `sales` względem tych reszt. Porównaj go ze współczynnikiem przy `newspaper` w modelu z trzema mediami.
b) Wykaż w ogólności, że $\hat{\beta}_j = \langle \mathbf{r}_j, \mathbf{y} \rangle / \|\mathbf{r}_j\|^2$. (Wskazówka: zapisz $\mathbf{y} = \mathbf{X}_{-j}\hat{\gamma} + \hat{\beta}_j \mathbf{x}_j + \mathbf{e}$ i pomnóż skalarnie przez $\mathbf{r}_j$. Wektor $\mathbf{r}_j$ jest prostopadły do kolumn $\mathbf{X}_{-j}$ i leży w $\mathcal{C}(\mathbf{X})$.)
c) Wywnioskuj, że $\operatorname{Var} \hat{\beta}_j = \sigma^2 / \|\mathbf{r}_j\|^2$. Co się dzieje z dokładnością oszacowania β_j, gdy cechę X_j da się dobrze przewidzieć z pozostałych cech? Odnieś to do przykładu z metrażem i liczbą pokoi z sekcji 1.7.
d) Wykaż, że $\mathrm{RSS}_0 - \mathrm{RSS} = \hat{\beta}_j^2 \|\mathbf{r}_j\|^2$, gdzie RSS_0 dotyczy modelu bez cechy j, i wywnioskuj, że statystyka (6.20) dla $q = 1$ jest kwadratem statystyki t.

Zadanie 6.10. Niech cecha binarna dzieli próbę na grupy 0 i 1 o licznościach n_0, n_1 i średnich wyników $\bar{y}_0$, $\bar{y}_1$.

a) Przy kodowaniu 0/1 wykaż, że $\hat{\beta}_0 = \bar{y}_0$ i $\hat{\beta}_1 = \bar{y}_1 - \bar{y}_0$.
b) Wyznacz współczynniki przy kodowaniu $-1/+1$ i wykaż, że predykcje są takie same. Sprawdź oba kodowania dla cechy `Own` w danych *Credit*.
c) Dla cechy o K poziomach wskaż niezerowy wektor $\mathbf{v}$, dla którego $\mathbf{X}\mathbf{v} = \mathbf{0}$, gdy w modelu jest wyraz wolny i K zmiennych zero-jedynkowych. Co oznaczają współczynniki modelu bez wyrazu wolnego, z K zmiennymi zero-jedynkowymi?
d) Wykaż, że statystyka t dla β_1 z punktu (a) jest statystyką testu t dla dwóch prób z łączną wariancją.

Zadanie 6.11. Rozważ model z interakcją (6.21) i podstaw $X_1 = \tilde{X}_1 + c_1$, $X_2 = \tilde{X}_2 + c_2$.

a) Wyraź współczynniki modelu w zmiennych $\tilde{X}_1$, $\tilde{X}_2$ przez $\beta_0, \ldots, \beta_3$. Wykaż, że współczynnik interakcji się nie zmienia, a przy $\tilde{X}_1$ stoi $\beta_1 + \beta_3 c_2$.
b) Jak interpretować współczynnik przy $\tilde{X}_1$, gdy c_2 jest średnią X_2 w próbie?
c) Dopasuj model z interakcją dla danych *Advertising* z wyśrodkowanymi budżetami. Porównaj współczynniki, błędy standardowe i predykcje z modelem bez wyśrodkowania. Które wielkości się zmieniły, a które nie?

Zadanie 6.12.

a) Dlaczego reszta studentyzowana używa $\hat{\sigma}_{(-i)}$, a nie $\hat{\sigma}$? Rozważ próbę z jedną bardzo odległą obserwacją odstającą.
b) Wylosuj $n = 50$ obserwacji z modelu spełniającego (Z1)–(Z3) i policz reszty studentyzowane. Ile z nich przekracza co do modułu 2, a ile powinno przekraczać przeciętnie?

Zadanie 6.13. Rozszerzenie: wariancja reszt. Wymagane są macierz daszkowa z rozszerzenia 6.9 i wynik zadania 6.4.

a) Wyprowadź (6.24). Dlaczego reszta obserwacji o dźwigni bliskiej 1 jest bliska zera bez względu na jej wynik?

b) Wykaż, że wariancja reszty „pozostaw jeden" $y_i - \tilde{\mathbf{x}}_i^\top \hat{\beta}^{(-i)}$ wynosi $\sigma^2/(1-h_{ii})$. Wywnioskuj, że reszta „pozostaw jeden" podzielona przez swoje odchylenie standardowe to $e_i/(\sigma\sqrt{1-h_{ii}})$.

Zadanie 6.14. Dla regresji salda względem dochodu, limitu i statusu studenta w danych *Credit* policz odległości Cooka ze wzoru z sekcji 6.8 i porównaj z `get_influence().cooks_distance` z pakietu `statsmodels`. Obejrzyj pięć najbardziej wpływowych obserwacji. Co je łączy?

Zadanie 6.15. Rozszerzenie: wzór na odległość Cooka. Wymagane są definicja (6.26) z rozszerzenia 6.11 i wynik zadania 6.4.

a) Wyprowadź drugą równość w (6.26).

b) Wykaż, że $D_i = \frac{r_i^2}{p+1} \cdot \frac{h_{ii}}{1-h_{ii}}$, gdzie r_i jest resztą standaryzowaną.

Zadanie 6.16.

a) **Rozszerzenie: wyprowadzenie VIF.** Wymagany jest wzór (6.27) z rozszerzenia 6.11. Wykaż, że $\|\mathbf{r}_j\|^2 = (1-R_j^2)\sum_i (x_{ij}-\bar{x}_j)^2$, i wyprowadź (6.27) z zadania 6.9.

b) Wykaż, że dla dwóch cech $\mathrm{VIF} = 1/(1-r^2)$, gdzie r jest ich korelacją z próby. Przy jakiej korelacji VIF przekracza 10?

c) Policz VIF dla limitu, wieku i oceny w danych *Credit*, wyznaczając R_j^2 z trzech regresji pomocniczych, i porównaj z wynikiem funkcji `variance_inflation_factor`.

d) Niech X_1, X_2, X_3 będą niezależne o rozkładzie $\mathcal{N}(0,1)$, a $X_4 = X_1 + X_2 + X_3 + 0{,}1\,Z$ z niezależnym $Z \sim \mathcal{N}(0,1)$. Wyznacz korelacje par cech i VIF cechy X_4. Sprawdź wynik na symulacji.

Zadanie 6.17. Niech $Y_t = \mu + \varepsilon_t$, $t = 1, \ldots, n$, gdzie $\mathrm{Cov}(\varepsilon_s, \varepsilon_t) = \sigma^2 \rho^{|s-t|}$ dla $|\rho| < 1$.

a) Wykaż, że $\operatorname{Var} \bar{Y} = \frac{\sigma^2}{n}\left[1 + 2\sum_{k=1}^{n-1}\left(1 - \frac{k}{n}\right)\rho^k\right]$, i że dla dużego n jest to w przybliżeniu $\frac{\sigma^2}{n} \cdot \frac{1+\rho}{1-\rho}$.

b) **Efektywną licznością próby** nazwijmy liczbę niezależnych obserwacji, których średnia ma tę samą wariancję. Ile wynosi ona dla $n = 100$ i $\rho = 0{,}8$? A dla $\rho = -0{,}5$?

c) Przyjmij bez dowodu, że dla dużego n wariancja z próby s^2 jest bliska σ^2. Ile razy klasyczny błąd standardowy $s/\sqrt{n}$ zaniża odchylenie standardowe $\bar{Y}$ przy $\rho = 0{,}8$? Porównaj z czynnikiem dla nachylenia prostej podanym w sekcji 6.8.

Zadanie 6.18. Niech $\log Y = \beta_0 + \beta_1 x + \varepsilon$, gdzie $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ jest niezależne od x.

a) Wykaż, że mediana Y przy danym x wynosi $e^{\beta_0+\beta_1 x}$, a wzrost x o jednostkę mnoży ją przez e^{β_1}. Dlaczego dla małych β_1 można to czytać jako wzrost o $100\,\beta_1$ procent?

b) Wykaż, że $\mathbb{E}[Y \mid x] = e^{\beta_0+\beta_1 x+\sigma^2/2}$. Co się dzieje, gdy prognozę $\mathbb{E}[Y \mid x]$ liczymy jako $e^{\widehat{\beta}_0+\widehat{\beta}_1 x}$?

c) Wykaż, że w tym modelu odchylenie standardowe Y przy danym x jest proporcjonalne do $\mathbb{E}[Y \mid x]$. Jakiego wzoru reszt modelu dla Y (zamiast $\log Y$) należy się wtedy spodziewać?

d) Dopasuj regresję log(`mpg`) względem mocy dla danych *Auto* i narysuj reszty względem predykcji. Porównaj z rysunkiem 6.7.

7. Selekcja i regularyzacja

W danych *Credit* z rozdziału 6 limit kredytu (`Limit`) i ocena zdolności kredytowej (`Rating`) niosą bardzo podobną informację. Gdy uwzględniamy obie cechy, ich współczynniki są znacznie mniej dokładnie wyznaczone niż przy każdej z nich osobno. Czy powinniśmy usunąć jedną z tych cech? A może zachować obie, ale ograniczyć wielkość ich współczynników?

To dwa sposoby zmniejszenia swobody modelu. **Selekcja predyktorów** wybiera podzbiór cech, a pozostałym przypisuje współczynniki równe zero. **Regularyzacja** ogranicza dopasowanie przez karę za wielkość współczynników. W obu przypadkach możemy pogorszyć dopasowanie do próby, a poprawić przewidywanie nowych wyników. Mechanizm znamy z rozdziału 4: godzimy się na obciążenie, jeśli zmniejszenie wariancji daje większą korzyść.

W tym rozdziale najpierw nauczymy się wybierać podzbiory cech, potem przejdziemy do płynnego ściągania współczynników w regresji grzbietowej i LASSO. Na końcu porównamy całe procedury na danych *Credit*. Prostszy opis i dobra predykcja są dwoma celami: zbiór cech wygodny w interpretacji może dawać inne przewidywania niż model wybrany wyłącznie według błędu.

7.1. Dlaczego mniej predyktorów bywa lepiej

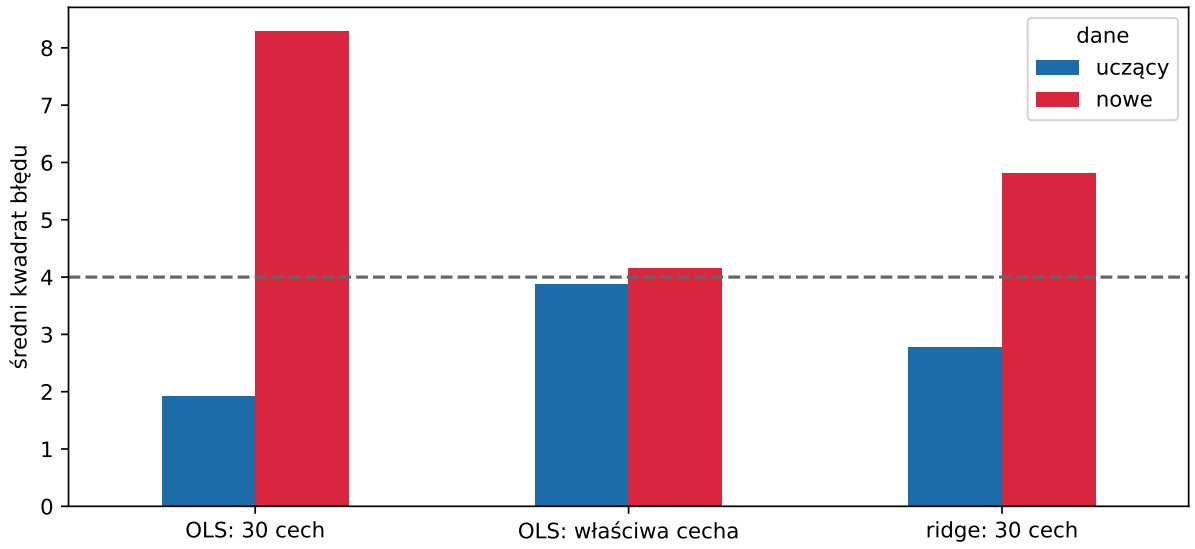
Rozważmy dodanie jednej cechy do regresji liniowej. Każda funkcja ze starego modelu nadal jest dostępna: wystarczy nadać nowemu współczynnikowi wartość zero. Dlatego najmniejsza osiągalna suma kwadratów reszt RSS nie rośnie. W konsekwencji zwykłe R^2 nie maleje. To własność dopasowania do tych samych danych, na których szukaliśmy współczynników (sekcja 6.4).

Nowa cecha wymaga jednak oszacowania kolejnego współczynnika. Jeśli niesie mało dodatkowej informacji o wyniku, jej dopasowanie może przede wszystkim odtwarzać szum. W kolejnej próbie uzyskamy inny współczynnik i inne predykcje. Dodawanie cech może więc zmniejszać błąd uczący i jednocześnie zwiększać błąd na nowych obserwacjach.

Pokazuje to kontrolowany eksperyment na rysunku 7.1. Losujemy $n = 60$ obserwacji i $p = 30$ cech. Wynik zależy tylko od pierwszej: $Y = 3X_1 + \varepsilon$, gdzie $\varepsilon \sim \mathcal{N}(0, 2^2)$. Pierwsza i druga cecha są silnie skorelowane; pozostałe są niezależnym szumem. Porównujemy OLS z wszystkimi cechami, OLS z pierwszą cechą oraz ridge z ustaloną z góry karą. Model z jedną cechą zna tutaj właściwy podzbiór dzięki konstrukcji eksperymentu; w zastosowaniu musielibyśmy go dopiero wybrać.

Pełny model osiąga najmniejszy błąd uczący, lecz płaci za szacowanie wielu zbędnych współczynników. Ridge częściowo ogranicza ten koszt, a model z właściwą cechą unika go prawie w całości. Gdy wiele cech niesie informację, ich usuwanie może kosztować więcej, niż oszczędza na wariancji.

Współliniowość dodatkowo utrudnia rozdzielenie efektów cech. Duże zmiany ich współczynników nie muszą jednak oznaczać równie dużych zmian predykcji w obszarze danych: wzrost jednego współczynnika może być równoważony spadkiem drugiego.



Rysunek 7.1.: Cechy szumowe i ściąganie: średni błąd uczący oraz błąd na niezależnych obserwacjach w 200 próbach. Model z jedną cechą otrzymuje właściwą cechę z konstrukcji eksperymentu. Przerywana linia oznacza wariancję błędu 4.

Przy wielu kolumnach pojawia się także problem jednoznaczności MNK. Jeśli macierz projektu z wyrazem wolnym ma więcej kolumn niż wierszy, nie ma pełnego rzędu kolumnowego. Współczynniki nie są wtedy wyznaczone jednoznacznie. Zerowy RSS wymaga dodatkowo, aby $\mathbf{y}$ należał do przestrzeni kolumn tej macierzy. Pełny rząd wierszowy zapewnia to dla każdego $\mathbf{y}$, ale sama duża liczba cech nie wystarcza: wielokrotne kopie tej samej kolumny nie pozwalają odtworzyć dowolnych wyników.

7.2. Selekcja podzbioru predyktorów

7.2.1. Przegląd zupełny

Zacznijmy od trzech cech *Credit*: `Income`, `Limit`, `Rating`. Przewidujemy `Balance`, czyli saldo zadłużenia w dolarach. Dla każdej cechy decydujemy, czy ją włączyć, zatem mamy $2^3 = 8$ podzbiorów. **Model pusty** ma wyraz wolny i przewiduje średnią wyników uczących. W tabeli 7.1 dopasowujemy wszystkie modele.

Aby później niezależnie ocenić wybraną procedurę, już teraz odkładamy 100 z 400 obserwacji jako test. Wszystkie dalsze ilustracje ścieżek i kryteriów na *Credit* wykorzystują wyłącznie pozostałe 300.

Tabela 7.1.: Wszystkie podzbiory trzech cech Credit, dopasowane na 300 obserwacjach uczących. Liczba d obejmuje wyraz wolny. RSS podano w tysiącach dolarów kwadratowych.

	cechy	d	RSS / 1000
0	tylko średnia	1	62840.13
1	Income	2	48947.16
2	Limit	2	15953.25
3	Rating	2	15840.31
4	Income, Limit	3	7885.97
5	Income, Rating	3	7710.39

Tabela 7.1.: Wszystkie podzbiory trzech cech Credit, dopasowane na 300 obserwacjach uczących. Liczba d obejmuje wyraz wolny. RSS podano w tysiącach dolarów kwadratowych.

	cechy	d	RSS / 1000
6	Limit, Rating	3	15812.82
7	Income, Limit, Rating	4	7612.20

Przegląd zupełny (ang. *best subset selection*) rozdziela dwa pytania. Najpierw, dla każdej liczby k cech, wybieramy podzbiór o najmniejszym RSS. Potem spośród otrzymanych $p+1$ kandydatów wybieramy wielkość modelu według kryterium uwzględniającego jego złożoność lub według walidacji. Sam RSS wybrałby pełny model.

W każdym rozmiarze k mamy $\binom{p}{k}$ podzbiorów, a łącznie 2^p. Dla $p = 20$ to ponad milion modeli; dla $p = 40$ – ponad bilion. Przegląd znajduje najlepszy podzbiór według kryterium na przeszukanej liście. Nie zapewnia najmniejszego nieznanego ryzyka ani odkrycia właściwych zmiennych w populacji.

7.2.2. Metoda schodów w przód i wstecz

Przy większej liczbie cech można zbudować krótszą listę kandydatów. **Selekcja w przód** (ang. *forward stepwise selection*) zaczyna od modelu pustego. W pierwszym kroku dodaje cechę dającą najmniejszy RSS. W kolejnym wybiera najlepsze rozszerzenie tego właśnie modelu o jedną cechę. Cech już wybranych nie usuwa. Buduje w ten sposób zagnieżdżoną ścieżkę modeli o $0, 1, \ldots, p$ cechach.

Selekcja wstecz (ang. *backward stepwise selection*) zaczyna od pełnego modelu. Usuwa cechę, której usunięcie najmniej zwiększa RSS, i powtarza ten krok aż do modelu pustego. W klasycznej wersji wymagamy pełnego rzędu kolumnowego dopasowywanych modeli, więc start z pełnego modelu jest problematyczny, gdy cech jest zbyt wiele względem n.

W przód sprawdzamy najwyżej $p + (p-1) + \cdots + 1 = p(p+1)/2$ rozszerzeń. Oszczędność ma cenę: najlepsza para cech nie musi zawierać cechy, która osobno była najlepsza. Pierwszy krok może więc zamknąć drogę do najlepszego podzbioru danej wielkości. Podobnie jest wstecz. Krok wyboru przećwiczymy w Zadanie 7.2.

Liczba cech na ścieżce jest ustawieniem procedury. Gdy wybieramy ją przez CV, **całą ścieżkę budujemy ponownie w części uczącej każdego podziału**. Wybranie podzbiorów na całej próbie, a dopiero potem ocenianie tych ustalonych podzbiorów przez CV ujawnia procedurze wyniki z przyszłych części walidacyjnych (sekcja 5.5).

> **i** Zmienna a kolumna modelu
>
> Zmienna jakościowa o czterech poziomach daje zwykle trzy kolumny kodowania. Przy selekcji całych zmiennych włączamy lub usuwamy ten blok razem; w karach za liczbę parametrów liczymy trzy współczynniki. Dla interakcji zwykle zachowujemy odpowiadające im efekty główne, aby model miał interpretację zgodną z rozdziałem 6. Zwykłe LASSO opisane dalej wybiera pojedyncze kolumny, więc nie wymusza ani wyboru całego bloku, ani tej zasady dla interakcji.

7.3. Kryteria wyboru modelu

Ile musi zmaleć RSS, aby warto było dodać parametr? Jedną odpowiedzią jest dopisanie kary za złożoność. Inną – pomiar błędu na danych niewykorzystanych przy dopasowaniu. Najpierw rozważymy pierwszą drogę.

We wzorach tej sekcji d oznacza liczbę współczynników **łącznie z wyrazem wolnym**, a n – liczbę obserwacji użytych w dopasowaniu. Porównujemy OLS na tych samych obserwacjach i dla tego samego wyniku, przy pełnym rzędzie kolumnowym macierzy projektu, a więc $d \leq n$. Zakładamy ponadto $d < n$ i dodatni RSS; przy $d = n$ model odtwarza wyniki uczące dokładnie. Liczby parametrów nie należy tu zastępować liczbą nazw zmiennych.

7.3.1. Skorygowany współczynnik determinacji

Skorygowany R^2 z sekcji 6.4 ma postać

$$\overline{R}^2 = 1 - \frac{\mathrm{RSS}/(n-d)}{\mathrm{TSS}/(n-1)}. \tag{7.1}$$

Zwiększenie d zmniejsza mianownik $n-d$. RSS musi więc odpowiednio spaść, aby poprawił się cały wynik. Wybieramy **największy** $\overline{R}^2$. Korekta osłabia nagradzanie rozbudowy modelu, ale nadal wykorzystuje te same dane do dopasowania i wyboru.

7.3.2. Kryterium Cp Mallowsa

Kryterium C_p (Mallows 1973) porównuje RSS z oszacowaniem wariancji błędu $\hat{\sigma}^2$:

$$C_p = \frac{\mathrm{RSS}}{\hat{\sigma}^2} - n + 2d. \tag{7.2}$$

Mimo historycznego indeksu p we wzorze liczymy parametry przez d, zgodnie z przyjętą konwencją. Wybieramy **najmniejsze** C_p. Wspólną estymatę $\hat{\sigma}^2$ zwykle wyznaczamy z dostatecznie bogatego modelu, dzieląc jego RSS przez resztowe stopnie swobody.

Skąd kara $2d$? Porównajmy w tych samych punktach $\mathbf{x}_1, \ldots, \mathbf{x}_n$ błąd na wynikach uczących z błędem dla nowych wyników Y_i^{nowe}, których błędy są niezależne od uczących i mają tę samą wariancję σ^2. Oznaczmy przez $b_i = f^*(\mathbf{x}_i) - \mathbb{E}\hat{y}_i$ obciążenie predykcji w punkcie i; nie zakładamy, że jest zerem. Predykcja $\hat{y}_i$ ma wariancję $\sigma^2 h_{ii}$ (sekcja 6.3), a reszta $y_i - \hat{y}_i$ – wariancję $\sigma^2(1-h_{ii})$ (sekcja 6.8). Stąd

$$\mathbb{E}(y_i - \hat{y}_i)^2 = \sigma^2(1-h_{ii}) + b_i^2, \qquad \mathbb{E}(Y_i^{\text{nowe}} - \hat{y}_i)^2 = \sigma^2 + \sigma^2 h_{ii} + b_i^2.$$

Nowy wynik jest niezależny od $\hat{y}_i$, więc wariancje się dodają. Wynik uczący wchodzi natomiast do $\hat{y}_i$ z wagą h_{ii} i predykcja częściowo za nim podąża. Różnica wynosi $2\sigma^2 h_{ii}$, a po zsumowaniu, z (6.10), $2\sigma^2 d$. Zatem $\mathrm{RSS} + 2d\sigma^2$ ma tę samą wartość oczekiwaną co suma kwadratów błędów dla nowych wyników. C_p to ta wielkość podzielona przez σ^2 i pomniejszona o stałą n; nieznane σ^2 zastępujemy oszacowaniem.

Gdy model służący do wyznaczenia $\hat{\sigma}^2$ pomija ważną strukturę średniej, reszty zawierają także niedopasowanie i oszacowanie może być zawyżone. Gdy brak resztowych stopni swobody, ten sposób jego uzyskania w ogóle nie działa. Rachunek dotyczy ustalonego modelu; kara nie usuwa optymizmu wynikającego z przeszukiwania wielu modeli (twierdzenie 5.2).

7.3.3. AIC i BIC

Kryterium informacyjne Akaikego, **AIC** (Akaike 1974), opiera się na maksimum logarytmu wiarygodności $\ell(\hat{\theta})$:

$$\mathrm{AIC} = -2\ell(\hat{\theta}) + 2q,$$

gdzie q jest liczbą wszystkich szacowanych parametrów modelu probabilistycznego. Logarytm wiarygodności mierzy, jak dobrze model przypisuje prawdopodobieństwo obserwowanym danym. Dla regresji z niezależnymi normalnymi błędami i nieznaną wspólną wariancją mamy $q = d + 1$: d współczynników i wariancję. Po oszacowaniu wariancji przez RSS/n i pominięciu składników wspólnych wszystkim porównywanym modelom otrzymujemy

$$\mathrm{AIC}_{\mathrm{por}} = n \log(\mathrm{RSS}/n) + 2d. \tag{7.3}$$

Możemy używać tej postaci do wyboru: minimum jest takie samo. To nie jest wersja dla znanej wariancji; przy znanej σ^2 składnik dopasowania jest proporcjonalny do RSS/σ^2.

Kryterium Schwarza, **BIC** (Schwarz 1978), zastępuje karę $2q$ karą $q \log n$. W tej samej rodzinie normalnych modeli liniowych porównujemy

$$\mathrm{BIC}_{\mathrm{por}} = n \log(\mathrm{RSS}/n) + d \log n. \tag{7.4}$$

Oba kryteria **minimalizujemy**. Dla $n \geq 8$ kara za parametr w BIC jest większa niż w AIC. AIC służy przybliżaniu jakości modelu jako opisu nowych wyników przez logarytm wiarygodności; BIC wywodzi się z porównania probabilistycznych modeli przy innych założeniach. Różne kary i cele mogą dawać różne wybory. Żadne z tych kryteriów nie zapewnia w każdej próbie najmniejszego błędu kwadratowego predykcji.

Na *Credit* możemy policzyć wszystkie kryteria dla tych samych ośmiu podzbiorów. Wariancję do C_p szacujemy tu z modelu trzech cech; jest to założenie ilustracji, które może być nietrafne: nie uwzględniamy jeszcze choćby statusu studenta.

Tabela 7.2.: Kryteria dla podzbiorów trzech cech. AIC i BIC pomijają wspólne stałe. Do Cp użyto wariancji resztowej modelu trzech cech.

	cechy	skorygowany R^2	Cp	AIC	BIC
0	tylko średnia	0.000	2145.534	3677.697	3681.400
1	Income	0.218	1607.307	3604.741	3612.148
2	Limit	0.745	324.341	3268.417	3275.825
3	Rating	0.747	319.949	3266.286	3273.693
4	Income, Limit	0.874	12.646	3059.044	3070.155
5	Income, Rating	0.876	5.818	3052.289	3063.400
6	Limit, Rating	0.747	320.880	3267.765	3278.876
7	Income, Limit, Rating	0.878	4.000	3050.444	3065.259

Skorygowany R^2, C_p i AIC wybierają wszystkie trzy cechy. BIC wskazuje `Income` i `Rating`: dodanie `Limit` obniża RSS z około 7,71 do 7,61 miliona, lecz poprawa nie rekompensuje większej kary BIC.

7.3.4. Walidacja krzyżowa i cel wyboru

CV porównuje średnie straty poza częścią uczącą, powtarzając dopasowanie w kolejnych podziałach. Pozwala tym samym językiem ocenić selekcję, ridge i LASSO. Przepis znamy z sekcji 5.4; zastosujemy go w sekcji 7.6. Liczba cech na ścieżce, siła kary i wybór samej metody są ustawieniami procedury. Ich ustalanie wymaga danych do wyboru, a końcowa ocena – osobnych danych lub zagnieżdżenia (sekcja 5.6).

Wybór podzbioru nie jest jeszcze wnioskowaniem o jego współczynnikach. Klasyczne testy i przedziały z rozdziału 6 traktują postać modelu jako ustaloną. Jeśli najpierw na tym samym wyniku wybieramy cechy, a potem stosujemy te wzory jak dla z góry określonego modelu, nie uwzględniamy etapu selekcji. Zwykła p-wartość po takim postępowaniu nie ma automatycznie deklarowanej interpretacji (Berk i in. 2013).

7.4. Regresja grzbietowa

Selekcja podejmuje decyzję: współczynnik może być dopasowany swobodnie albo musi być zerem. **Regresja grzbietowa** (ang. *ridge regression*) (Hoerl i Kennard 1970) pozwala go stopniowo zmniejszać. Do RSS dodajemy karę kwadratową:

$$(\hat{\beta}_{0,\lambda}, \hat{\beta}_\lambda) \in \arg\min_{\beta_0,\beta} \left\{ \sum_{i=1}^{n} (y_i - \beta_0 - \mathbf{x}_i^\top \beta)^2 + \lambda \sum_{j=1}^{p} \beta_j^2 \right\}, \qquad \lambda \geq 0. \tag{7.5}$$

Kara zniechęca do dużych współczynników. Dla $\lambda = 0$ jest to zadanie MNK; zwiększając λ, mocniej ograniczamy dopasowanie. **Wyrazu wolnego nie karzemy**: poziom wyniku zależy od umownego początku skali i nie chcemy ściągać go do zera.

7.4.1. Dlaczego skala ma znaczenie

Niech `Income` oznacza dochód w tysiącach dolarów. Po przeliczeniu go na dolary wartości cechy rosną tysiąckrotnie, a współczynnik tej samej funkcji predykcji maleje tysiąckrotnie. Jego kwadrat maleje milion razy. Przy tych samych predykcjach kara zależy więc od jednostki. OLS nie ma tego problemu, bo minimalizuje tylko RSS.

Przed regularyzacją zwykle standaryzujemy kolumny: odejmujemy średnią i dzielimy przez odchylenie standardowe wyznaczone **na danych uczących**. Współczynnik opisuje wtedy zmianę predykcji na jedno odchylenie cechy, a kary nie zależą od pierwotnych jednostek. Dla stałej kolumny trzeba zrezygnować ze skalowania lub ją usunąć. Te same wyuczone przekształcenia stosujemy do nowych obserwacji; nie wyznaczamy dla nich nowych średnich.

Skalowanie nie rozwiązuje wszystkich decyzji dotyczących reprezentacji. Dla cech jakościowych trzeba ustalić kodowanie i sposób traktowania kolumn zero-jedynkowych. Po ich standaryzacji kara dotyczy zmiany o jedno odchylenie kolumny; dla rzadkiego poziomu odpowiada to innej zmianie w jednostkach oryginalnych. Wybór poziomu odniesienia przy wielu kategoriach również może zmienić karę. Reprezentacja jest częścią metody.

7.4.2. Rozwiązanie i mechanizm ściągania

Oznaczmy średnie uczące przez $\bar{y}$ i $\bar{\mathbf{x}}$. Dla ustalonego β najlepszy niekarany wyraz wolny wynosi

$$\hat{\beta}_0 = \bar{y} - \bar{\mathbf{x}}^\top \beta. \tag{7.6}$$

Możemy więc odjąć średnie od $\mathbf{y}$ i każdej kolumny $\mathbf{X}$, rozwiązać zadanie bez wyrazu wolnego, a następnie odzyskać go z tego wzoru. W kolejnych rachunkach $\mathbf{X}$ i $\mathbf{y}$ oznaczają właśnie wycentrowane dane; macierz $\mathbf{X}$ ma p kolumn i nie zawiera kolumny jedynek.

Pochodna funkcji $\|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda\beta^\top\beta$ względem β to $-2\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\beta) + 2\lambda\beta$. Przyrównując ją do zera, otrzymujemy układ $(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})\beta = \mathbf{X}^\top\mathbf{y}$.

Twierdzenie 7.1 (Rozwiązanie regresji grzbietowej)**.** *Dla wycentrowanych danych i $\lambda > 0$ zadanie (7.5) ma dokładnie jedno rozwiązanie*

$$\hat{\beta}_\lambda = (\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^\top\mathbf{y}, \tag{7.7}$$

także wtedy, gdy kolumny $\mathbf{X}$ są liniowo zależne.

Dla $\lambda > 0$ macierz układu jest dodatnio określona: $\mathbf{v}^\top(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})\mathbf{v} = \|\mathbf{X}\mathbf{v}\|^2 + \lambda\|\mathbf{v}\|^2 > 0$ dla $\mathbf{v} \neq \mathbf{0}$. Jest więc odwracalna, a funkcja celu jest ściśle wypukła, zatem punkt zerowania gradientu jest jedynym minimum. W obliczeniach rozwiązujemy układ równań, zamiast jawnie liczyć odwrotność. Dla $\lambda = 0$ pozostaje zadanie MNK, które może mieć wiele rozwiązań.

W jednej wycentrowanej cesze oznaczmy $s = \sum_i x_i^2 > 0$ oraz $z = \sum_i x_i y_i$. OLS daje $\hat{\beta}_{\mathrm{OLS}} = z/s$, a ridge

$$\hat{\beta}_\lambda = \frac{z}{s + \lambda} = \frac{s}{s + \lambda}\hat{\beta}_{\mathrm{OLS}}. \tag{7.8}$$

Mnożymy oszacowanie OLS przez liczbę między zerem a jednością. Gdy $s = 10$ i OLS daje 3, kary $\lambda = 0, 10, 30$ dają odpowiednio 3, 1,5 i 0,75. Większa kara oznacza mocniejsze **ściąganie**. Po ponownym losowaniu błędów cały rozrzut oszacowań jest mnożony przez ten sam czynnik, więc wariancja jest mnożona przez jego kwadrat. Przy niezerowym prawdziwym współczynniku pojawia się za to obciążenie.

Przy wielu skorelowanych cechach mechanizm działa wspólnie na wektor współczynników. Pojedynczy współczynnik nie musi maleć monotonicznie co do modułu (rysunek 7.2). Ridge nie ma jednak mechanizmu progowania do zera: zwykle zachowuje wszystkie cechy. Dokładne zero może wystąpić np. przez szczególną strukturę danych. Gdy $\lambda \to \infty$, wszystkie nachylenia dążą do zera, a model przewiduje $\bar{y}$.

Liczba kolumn nie opisuje już całej swobody modelu: te same kolumny przy małej i dużej karze dają bardzo różne dopasowania. Dlatego kar za liczbę parametrów z sekcji 7.3, podanych dla OLS, nie przenosimy do ridge przez mechaniczne wpisanie liczby kolumn. Rachunek efektywnych stopni swobody rozwija sekcja 7.7.

7.5. LASSO i geometria regularyzacji

7.5.1. Kara bezwzględna i dokładne zera

LASSO (ang. *least absolute shrinkage and selection operator*) (Tibshirani 1996) zastępuje sumę kwadratów sumą modułów:

$$(\hat{\beta}_{0,\lambda}, \hat{\beta}_\lambda) \in \operatorname*{arg\,min}_{\beta_0,\beta} \left\{ \sum_{i=1}^{n} (y_i - \beta_0 - \mathbf{x}_i^\top\beta)^2 + \lambda \sum_{j=1}^{p} |\beta_j| \right\}. \tag{7.9}$$

Wyraz wolny pozostaje niekarany, a reguły skalowania i centrowania są takie jak w ridge. Zmiana kary ma duży skutek: część współczynników może być **dokładnie równa zero**. LASSO łączy zatem ściąganie z selekcją.

Zobaczmy to dla jednej wycentrowanej cechy, przy oznaczeniach s, z z sekcji 7.4. Pomijając składnik niezależny od β, minimalizujemy

$$s\beta^2 - 2z\beta + \lambda|\beta|.$$

Dla $\beta > 0$ pochodna wynosi $2s\beta - 2z + \lambda$, więc kandydatem jest $(z - \lambda/2)/s$, o ile jest dodatni. Dla $\beta < 0$ dostajemy $(z + \lambda/2)/s$, o ile jest ujemny. Jeśli $|z| \le \lambda/2$, funkcja maleje do zera od lewej i rośnie od zera w prawo; minimum wypada w zerze. Razem:

Twierdzenie 7.2 (Miękkie progowanie)**.** *Dla jednej wycentrowanej cechy z* $s = \sum_i x_i^2 > 0$ *i* $z = \sum_i x_i y_i$ *zadanie (7.9) ma rozwiązanie*

$$\widehat{\beta}_\lambda = \frac{\operatorname{sign}(z)(|z| - \lambda/2)_+}{s}, \qquad (a)_+ = \max(a, 0). \tag{7.10}$$

To **miękkie progowanie**: zmniejszamy moduł z o $\lambda/2$, a wartości niewiększe od progu zastępujemy zerem. Liczba $1/2$ wynika z naszej konwencji RSS plus kara. Gdy $s = 10$ i $z = 30$, OLS daje 3; LASSO dla $\lambda = 10, 30, 60$ daje 2,5, 1,5 i 0. Porównaj z ridge w Zadanie 7.5.

7.5.2. Ścieżki współczynników na Credit

Wróćmy do *Credit*. Na rysunku 7.2 uwzględniamy `Income`, `Limit`, `Rating` oraz status studenta zapisany jako 0/1. Po skalowaniu współczynniki są wyrażone w dolarach salda na jedno odchylenie standardowe cechy. Zwiększanie kary w LASSO kolejno zeruje część współczynników; w ridge zmiana jest płynna bez takiego progu.

W kodzie trzeba uważać na definicję kary. Według dokumentacji `Ridge` minimalizuje RSS $+\alpha\|\beta\|_2^2$, natomiast `Lasso` minimalizuje $\mathrm{RSS}/(2n) + \alpha\|\beta\|_1$. Dlatego w naszej konwencji

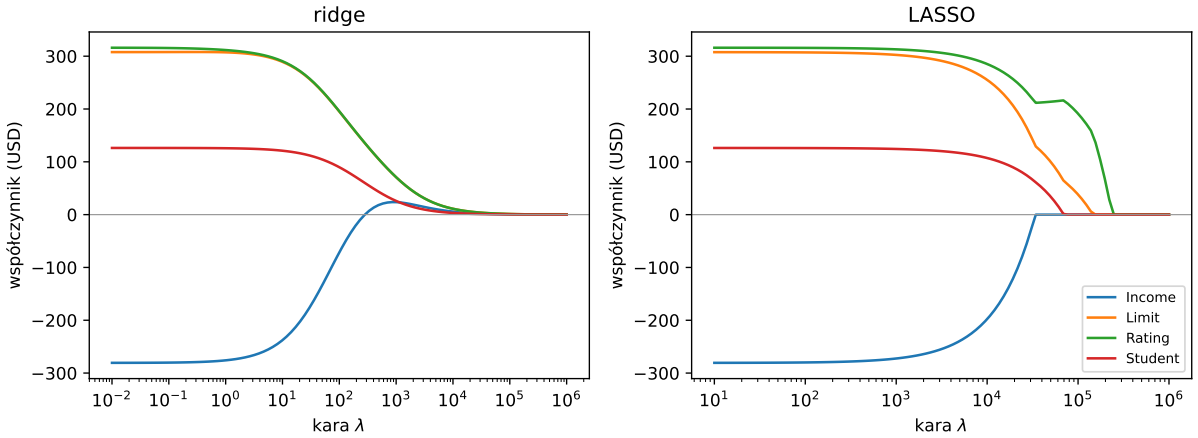
$$\lambda_{\text{ridge}} = \alpha_{\text{Ridge}}, \qquad \lambda_{\text{LASSO}} = 2n\alpha_{\text{Lasso}}. \tag{7.11}$$

Te same liczby `alpha` w obu klasach nie oznaczają tych samych współczynników przy RSS. Również same kary kwadratowa i bezwzględna mają inne skale, więc na rysunku każda rodzina ma własną oś.

Przy znikomej karze ridge daje współczynniki bliskie OLS: 308 przy `Limit` i 316 przy `Rating`. Już przy $\lambda \approx 10$ oba są praktycznie równe i dalej maleją razem. Kara $\beta_L^2 + \beta_R^2$ przy ustalonej sumie $\beta_L + \beta_R$ jest najmniejsza dla równych składników, a dla dwóch prawie identycznych cech predykcje zależą niemal wyłącznie od sumy.

Współczynnik `Income` zmienia znak przy $\lambda \approx 280$: z -281 do około $+24$ przy $\lambda = 1000$. Gdy λ jest duże w porównaniu z elementami $\mathbf{X}^\top\mathbf{X}$, wzór (7.7) daje $\widehat{\beta}_\lambda \approx \mathbf{X}^\top\mathbf{y}/\lambda$. Każdy współczynnik jest wtedy proporcjonalny do zwykłej korelacji cechy z wynikiem, a dla `Income` wynosi ona 0,47. Przy małej karze współczynnik opisuje natomiast związek przy ustalonych pozostałych cechach: przy tym samym limicie i ocenie wyższy dochód idzie w parze z niższym saldem.

LASSO zeruje kolejno `Income` ($\lambda \approx 3{,}4\cdot 10^4$), `Student` ($7\cdot 10^4$), `Limit` ($1{,}5\cdot 10^5$) i `Rating`. Ostatni próg wynika z (7.10). Gdy pozostałe współczynniki są zerami, cecha j widzi wycentrowane wyniki i pozostaje zerem, dopóki $|\sum_i x_{ij} y_i| \le \lambda/2$. Wszystkie współczynniki znikają więc od $\lambda = 2\max_j |\sum_i x_{ij} y_i| \approx 2{,}37 \cdot 10^5$. `Rating` wygrywa z `Limit` minimalnie: suma $\sum_i x_{ij} y_i$ wynosi 118 743 wobec 118 600. Wybór między prawie identycznymi cechami rozstrzyga tu niewielka różnica w próbie.



Rysunek 7.2.: Ścieżki współczynników na uczącej części Credit, po standaryzacji czterech cech. Każda rodzina ma własny zakres lambda w konwencji RSS plus kara.

7.5.3. Kara jako budżet

Można też minimalizować RSS przy ograniczeniu wielkości wektora:

$$\sum_{j=1}^{p} \beta_j^2 \le t \quad \text{(ridge)}, \qquad \sum_{j=1}^{p} |\beta_j| \le t \quad \text{(LASSO)}. \tag{7.12}$$

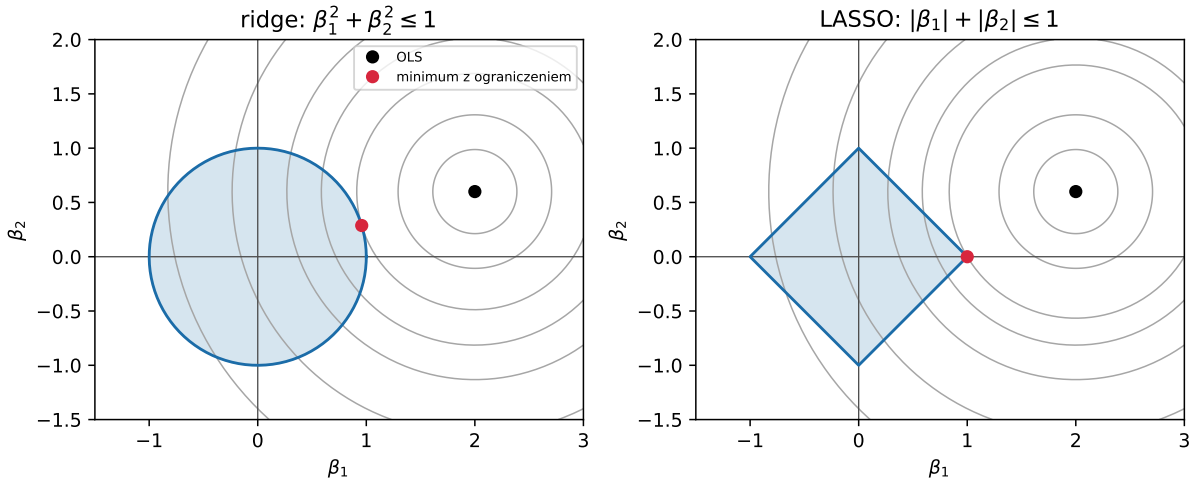
Liczba t to **budżet** na współczynniki. Duży budżet dopuszcza rozwiązanie MNK; mniejszy wymusza lepszy pod względem RSS punkt w ograniczonym zbiorze. Kara i budżet są dwoma sposobami opisu regularyzacji: rozwiązaniu dla danej dodatniej kary odpowiada budżet równy osiągniętej wielkości wektora. Dla dodatnich budżetów można dobrać odpowiadającą karę; nie jest to ogólnie relacja jeden do jednego. Budżet zerowy może wymagać granicy $\lambda \to \infty$, jak w ridge.

Dla dwóch współczynników budżet ridge wyznacza koło, a LASSO – romb. Poziomice RSS są elipsami wokół rozwiązania OLS (w tym przykładzie okręgami). Szukamy najmniejszej poziomicy, która spotyka zbiór dopuszczalny. Na rysunku 7.3 kontakt z rombem wypada na osi, zatem jeden współczynnik jest zerem. Załamanie granicy daje cały zakres kierunków poziomic, dla których zachodzi taki kontakt. Przy gładkim brzegu koła kontakt na osi wymaga szczególnego ułożenia danych.

7.5.4. Co oznacza wybranie cechy

Zerowy współczynnik LASSO oznacza, że przy danej próbie, reprezentacji i karze procedura nie wykorzystuje tej kolumny. Nie dowodzi braku związku cechy z wynikiem. Dwie cechy mogą zastępować się informacyjnie, a niewielka zmiana próby może zmienić wybraną reprezentantkę. Dlatego warto osobno badać stabilność wyboru i stabilność predykcji (Zadanie 7.8).

Przy zależnych kolumnach współczynniki LASSO mogą być niejednoznaczne. Na przykład dla dwóch identycznych kolumn rozdzielenie dodatniego współczynnika między nie nie zmienia ani RSS, ani sumy modułów. Liczba niezerowych współczynników nie musi też zmieniać się monotonicznie na całej ścieżce kar. Selekcja do predykcji nie identyfikuje przyczyn zjawiska, podobnie jak zwykła regresja.



Rysunek 7.3.: Minimalizacja tej samej funkcji RSS przy dwóch ograniczeniach. Punkt czarny oznacza minimum bez ograniczeń (OLS), a czerwony – minimum w dopuszczalnym zbiorze. Budżety dobrano dla czytelności mechanizmu.

> **Rozszerzenie: elastic net**
>
> Wymagane są wyłącznie pojęcia ridge i LASSO z tego rozdziału. Można połączyć obie kary, dodając do RSS $\lambda_1 \sum_j |\beta_j| + \lambda_2 \sum_j \beta_j^2$. Dodatnia kara kwadratowa zapewnia jednoznaczność wektora współczynników, a kara bezwzględna zachowuje możliwość zerowania. Taka metoda nazywa się *elastic net* (Zou i Hastie 2005). Dwa parametry wymagają ustalonej procedury strojenia; nie włączamy ich do poniższego porównania.

7.6. Dobór regularyzacji i porównanie metod

7.6.1. Kandydaci i role danych

Pozostaje dobrać siłę kary. Błąd uczący skłaniałby do jej osłabiania, więc do wyboru użyjemy pięciokrotnej CV. Test odłożony na początku rozdziału posłuży dopiero do końcowej oceny. Wybór metody – tak samo jak wybór jej ustawień – zostanie zamknięty przed obejrzeniem testu. Przy małej próbie odpowiednikiem tego postępowania jest zagnieżdżenie opisane w sekcji 5.6.

Porównamy OLS, selekcję w przód, ridge i LASSO. Z góry ograniczamy listę kandydatów do siedmiu cech: sześciu liczbowych oraz `Student`, kodowanego jako 0/1. Pozostałych cech jakościowych nie wykorzystujemy w tym przykładzie. Pozwala to skupić się na regularyzacji bez rozbudowy kodu wybierającego całe bloki kategorii.

Selekcję w przód zdefiniujemy dokładnie tak jak w sekcji 7.2: w każdym kroku wybieramy najmniejszy **uczący RSS**, a liczba kroków jest ustawieniem wybieranym przez CV. Poniższa klasa dopasowuje całą ścieżkę do żądanej długości przy każdym wywołaniu `fit`. Dzięki temu wewnątrz CV wybiera cechy wyłącznie z aktualnej części uczącej.

Dla modelu pustego użyjemy osobno `DummyRegressor`; pozwala to wybrać również zero cech. Wszystkie przekształcenia wymagające uczenia, w tym standaryzacja, są częścią potoku poddanego CV. Zapisanie mapowania `No`/`Yes` jako 0/1 nie wymaga wyznaczania parametrów na danych.

	metoda	MSE CV	ustawienie
0	ridge	10001.63	alpha = 1
1	LASSO	10120.03	alpha = 1.47e-05
2	selekcja w przód	10120.03	liczba cech = 7
3	OLS	10120.03	bez strojenia
4	średnia	211356.25	bez strojenia

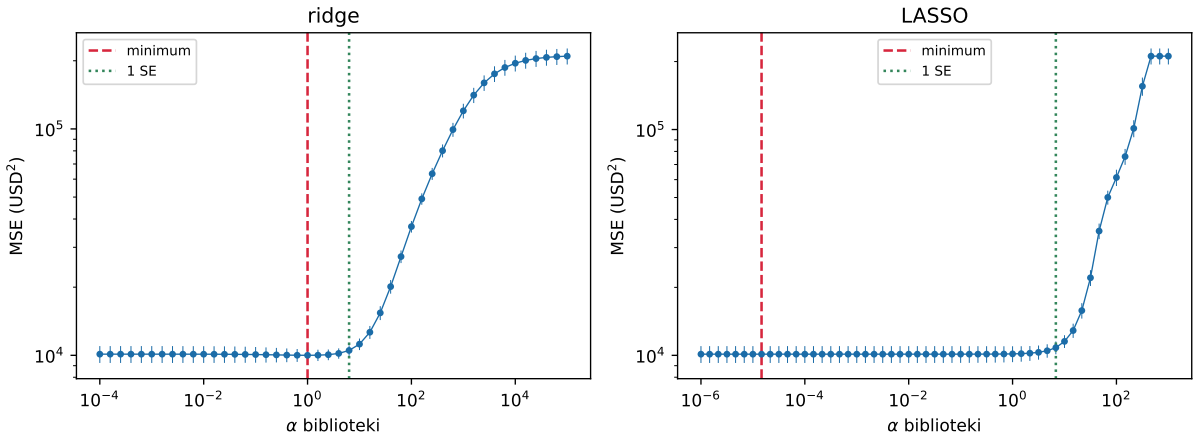
Wspólny podział daje każdej metodzie te same łatwe i trudne przypadki. Poszukiwanie kar odbywa się na skali logarytmicznej: interesują nas zmiany rzędu wielkości, a nie stały krok. Gdy minimum wypada na brzegu, przed oceną testową trzeba sprawdzić szerszy zakres.

Krzywa CV dla LASSO jest płaska dla α poniżej około 1 (rysunek 7.4). W tym zakresie MSE CV pokrywa się z wynikiem OLS do dwóch miejsc po przecinku, więc położenie minimum na tym odcinku wynika z dokładności obliczeń i nie niesie informacji o danych. LASSO z karą wybraną przez CV jest tu praktycznie modelem OLS: dane nie wskazują korzyści z wyraźnego progowania.

W LASSO stroimy biblioteczne `alpha`, czyli współczynnik kary przy **średniej** stracie, zgodnie z dokumentacją i wzorem (7.11). Po ponownym dopasowaniu na większym zbiorze zachowujemy to samo `alpha`; odpowiadające mu $\lambda = 2n\alpha$ w konwencji RSS rośnie z n. W `Ridge` jest odwrotnie: `alpha` jest samym λ, a sumy $s_j = \sum_i x_{ij}^2$ rosną z n. Czynnik $s_j/(s_j+\lambda)$ jest więc po dopasowaniu na 300 obserwacjach bliższy jedności niż w częściach uczących CV liczących 240 obserwacji: ta sama wartość `alpha` ściąga słabiej.

Nie wystarczyłoby dopasować skaler na wszystkich 300 obserwacjach, a dopiero potem przekazać przeskalowane dane do CV. Potok musi być przekazany **do procedury strojenia**, tak jak powyżej. Ta sama uwaga dotyczy połączenia skalera z estymatorem, który ma własną wewnętrzną CV: skaler umieszczony przed nim nie jest automatycznie uczony od nowa w jego wewnętrznych podziałach.

7.6.2. Krzywe błędu i reguła jednego błędu standardowego



Rysunek 7.4.: Wybór kary na uczącej części Credit. Punkty oznaczają średnie MSE z pięciu części, a pionowe kreski przybliżony błąd standardowy liczony z rozrzutu wyników części. Linia przerywana wskazuje minimum, kropkowana – wybór reguły 1 SE. Oś kary podaje biblioteczne alpha, o różnych normalizacjach dla obu rodzin.

Tabela 7.4.: Biblioteczne alpha wybrane przez minimum CV i przez regułę 1 SE (rysunek 7.4).

rodzina	alpha minimum	alpha 1 SE
ridge	1	6.31
LASSO	1.47e-05	6.81

Reguła jednego błędu standardowego z sekcji 5.4 pozwala wybrać mocniejszą karę, jeżeli jej wynik mieści się w ustalonym zakresie ponad minimum. Tutaj roboczo użyliśmy odchylenia wyników części podzielonego przez $\sqrt{5}$. Części nie są niezależnymi powtórzeniami, ponieważ ich zbiory uczące się nakładają. Ta skala nie daje gwarantowanego przedziału ufności, a reguła pozostaje heurystyką, nie testem równoważności. W podstawowym porównaniu stosujemy ustaloną wcześniej regułę minimum. Wariant 1 SE ilustrujemy osobno; do jego użycia trzeba ponownie dopasować potok z wybraną karą.

7.6.3. Końcowa ocena i model do używania

`GridSearchCV` z `refit=True` dopasował każdą wybraną konfigurację na wszystkich 300 obserwacjach uczących. Możemy teraz wykorzystać test. MSE mierzymy w dolarach kwadratowych, a RMSE, jego pierwiastek, w dolarach. Dla ustalonego dopasowania przybliżony błąd standardowy testowego MSE wyznaczamy z rozrzutu 100 indywidualnych strat kwadratowych: $\mathrm{sd}(L_i)/\sqrt{100}$. Nie jest to niepewność minimum CV.

Tabela 7.5.: Ocena pięciu wcześniej ustalonych procedur na 100 odłożonych obserwacjach. Ustawienia i wybór głównej metody pochodzą wyłącznie z CV na części uczącej. SE dotyczy testowego MSE przy ustalonym dopasowaniu.

metoda	MSE	SE MSE	RMSE (USD)
OLS	10968.85	1471.82	104.73
selekcja w przód	10968.85	1471.82	104.73
ridge	11069.12	1409.60	105.21
LASSO	10968.85	1471.82	104.73
średnia	215219.36	25728.30	463.92

CV wybrała metodę **ridge**. Jej testowe RMSE wynosi **105,2 USD**, a MSE **11069,1 USD²** z przybliżonym błędem standardowym **1409,6 USD²**.

Selekcja w przód zachowała wszystkie siedem cech, a LASSO przy wybranej bardzo małej karze nie wyzerowało żadnego współczynnika. OLS, wybrany model selekcji i LASSO dają więc niemal identyczne predykcje. Ridge wybrany przez CV z $\alpha = 1$ ma na teście nieco większe MSE: około 11069 wobec 10969 dla OLS. Tabeli testowej nie używamy do zmiany wyboru: CV wskazała ridge i ten wybór pozostaje.

Średnia różnica strat ridge i OLS wynosi **100,3 USD²**, a jej błąd standardowy **174,0 USD²**.

Obie metody oceniamy na tych samych 100 obserwacjach, więc niepewność różnicy szacujemy z różnic strat $L_i^{\mathrm{ridge}} - L_i^{\mathrm{OLS}}$ (sekcja 5.2). Błąd standardowy różnicy jest ponad ośmiokrotnie mniejszy niż błąd standardowy pojedynczego MSE (około 1400): obserwacje trudne dla jednej

metody są trudne i dla drugiej, więc ich rozrzut w dużej części się znosi. Mimo to różnica nie odróżnia się od zera.

Tabela 7.6.: Współczynniki OLS i ridge wybranego przez CV, na skali standaryzowanych cech: dolary salda na jedno odchylenie standardowe cechy.

	OLS	ridge
Income	-279.2	-274.5
Limit	451.7	363.7
Rating	170.9	254.3
Cards	19.1	15.4
Age	-5.4	-5.4
Education	-7.9	-7.2
Student	127.7	126.7

Możemy teraz odpowiedzieć na pytanie z początku rozdziału. Ridge z $\alpha = 1$ prawie nie zmienia większości współczynników, za to wyraźnie przesuwa wagę między `Limit` a `Rating`: z 452 i 171 do 364 i 254. Suma obu współczynników prawie się nie zmienia (623 i 618), a ich różnica maleje z 281 do 109.

W części uczącej korelacja `Limit` i `Rating` wynosi 0,997. Predykcje zależą więc głównie od sumy współczynników, a różnica odpowiada kombinacji cech, która w próbie prawie się nie zmienia. Dane słabo ją wyznaczają; to ta sama niedokładność, którą w rozdziale 6 mierzył VIF. Kara $\beta_L^2 + \beta_R^2 = \frac{1}{2}[(\beta_L + \beta_R)^2 + (\beta_L - \beta_R)^2]$ obciąża różnicę tak samo jak sumę, ale zmiana różnicy prawie nie zwiększa RSS. Ridge ściąga więc przede wszystkim różnicę. Na pytanie, czy usunąć jedną z cech, CV odpowiada: nie usuwać, tylko ściągnąć ich różnicę. W rachunku rozszerzenia 7.7 ta różnica odpowiada kierunkowi o $s \approx 0{,}64$, z czynnikiem $0{,}64/1{,}64 \approx 0{,}39$, i rzeczywiście $281 \cdot 0{,}39 \approx 109$. Dla następnego kierunku czynnik wynosi już 0,99.

Na tych danych kilka metod może działać podobnie: mamy umiarkowaną liczbę cech względem 300 obserwacji, a silna kara może usuwać użyteczną informację. Symulacja z początku rozdziału pokazywała trudniejszą sytuację pod względem liczby parametrów. Regularyzacja jest narzędziem kontroli dopasowania, a jej przydatność trzeba sprawdzić dla konkretnego problemu.

Obiekt `model_do_uzywania` zawiera również wyuczone skalowanie i może przewidywać nowe wiersze z tym samym porządkiem i kodowaniem cech. Jeśli po zamknięciu oceny dołączymy test i ponownie dobierzemy ustawienia lub dopasujemy model, otrzymamy inne dopasowanie. Dotychczasowy wynik testowy nie jest niezależną oceną tego nowego modelu.

7.7. Rozszerzenie: geometria ściągania i efektywne stopnie swobody

Materiał nieobowiązkowy

Wymagane są algebra macierzowa, wartości własne i ślad macierzy. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

7.7.1. Kierunki o różnej dokładności

Dla wycentrowanego $\mathbf{X}$ zapiszmy $\mathbf{X}^\top\mathbf{X} = \mathbf{V}\,\mathrm{diag}(s_1, \dots, s_p)\mathbf{V}^\top$, gdzie $\mathbf{V}$ jest ortogonalna, a $s_j \geq 0$. Obrót przez $\mathbf{V}$ zamienia skorelowane współczynniki na współrzędne związane z ortogonalnymi kierunkami. We współrzędnej o $s_j > 0$ ridge mnoży rozwiązanie OLS przez

$$\frac{s_j}{s_j + \lambda}.$$

Małe s_j oznacza mało informacji o odpowiadającej kombinacji współczynników. Właśnie te kierunki są tłumione mocniej. Na standaryzowanych siedmiu cechach *Credit* najmniejsze s_j wynosi 0,64, a odpowiadający mu kierunek to prawie dokładnie $(\mathrm{Limit} - \mathrm{Rating})/\sqrt{2}$; następne s_j to już 79. Przy $\lambda = 1$ czynnik ściągania wynosi więc 0,39 dla różnicy tych cech i co najmniej 0,99 dla pozostałych kierunków. Współczynnik przy oryginalnej cesze jest mieszaniną obróconych współrzędnych, co wyjaśnia brak monotonicznego zmniejszania każdego jego modułu. Przy $s_j = 0$ ridge wybiera współrzędną równą zero.

Przy modelu liniowym z wariancją błędów $\sigma^2\mathbf{I}$ i ustalonym $\mathbf{X}$ wariancja współrzędnej OLS wynosi σ^2/s_j, natomiast ridge $\sigma^2 s_j/(s_j + \lambda)^2$. Jeśli prawdziwa współrzędna to b_j, obciążenie ridge wynosi $-\lambda b_j/(s_j + \lambda)$. Zmniejszenie wariancji ma zatem konkretną cenę; korzystny wybór kary zależy od nieznanych b_j, poziomu szumu i celu predykcji.

7.7.2. Macierz wygładzania i stopnie swobody

Zapis $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$ i ślad $\mathbf{S}$ jako miarę elastyczności metody liniowej poznaliśmy w rozszerzeniu 6.9: dla OLS ślad wynosi $p + 1$, a dla k-NN n/k. Niech $\mathbf{X}$ nadal ma wycentrowane kolumny, a $\mathbf{J} = \mathbf{1}\mathbf{1}^\top/n$. Predykcje na próbie, z uwzględnieniem niekaranego wyrazu wolnego, wynoszą

$$\hat{\mathbf{y}} = \mathbf{S}_\lambda \mathbf{y}, \qquad \mathbf{S}_\lambda = \mathbf{J} + \mathbf{X}(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^\top. \tag{7.13}$$

Efektywne stopnie swobody tej liniowej procedury to

$$\mathrm{df}(\lambda) = \mathrm{tr}(\mathbf{S}_\lambda) = 1 + \sum_{j=1}^{p} \frac{s_j}{s_j + \lambda}, \qquad \lambda > 0. \tag{7.14}$$

Jedynka pochodzi z wyrazu wolnego. Dla pełnego rzędu kolumnowego granica przy $\lambda \downarrow 0$ wynosi $p + 1$, a przy $\lambda \to \infty$ – 1. Przy niepełnym rzędzie pierwsza granica to $1 + \mathrm{rank}(\mathbf{X})$. Wymiar pośredni nie musi być całkowity: każda dodatnia kara ogranicza swobodę dopasowania bez usuwania kolumn.

Dla ustalonej kary, przy niezależnych błędach o wariancji σ^2, średni optymizm RSS wobec predykcji niezależnego wektora odpowiedzi w tych samych punktach wynosi $2\sigma^2\,\mathrm{tr}(\mathbf{S}_\lambda)$. Dlatego liczba kolumn nie jest właściwym zamiennikiem złożoności ridge w rachunku kar typu C_p. Gdy wybieramy samą karę z danych, pojawia się ponadto koszt tego wyboru.

Dla ustalonych λ i skali kolumn wzór na LOOCV liniowego wygładzania z sekcji 5.12 daje

$$\mathrm{CV}_{\mathrm{LOO}} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{y_i - \hat{y}_i}{1 - (\mathbf{S}_\lambda)_{ii}}\right)^2.$$

Skala musi tu być z góry ustalona: jeśli każde usunięcie obserwacji zmienia standaryzację, zmienia się również kara w oryginalnych współrzędnych i prosty wzór nie opisuje już takiej procedury.

7.8. Rozszerzenie: obliczanie LASSO przez aktualizację współrzędnych

Materiał nieobowiązkowy

Wymagane są różniczkowanie i zapis macierzowy. Tekst główny i zadania podstawowe z tej sekcji nie korzystają.

Wzór (7.10) można wykorzystać wielokrotnie. Przy ustalonych pozostałych współczynnikach zdefiniujmy **resztę częściową**

$$r_i^{(j)} = y_i - \sum_{k \neq j} x_{ik}\beta_k.$$

Dla wycentrowanych danych wyraz wolny pomijamy. Minimalizacja względem samego β_j ma postać jednowymiarowego zadania z $s_j = \sum_i x_{ij}^2$ i $z_j = \sum_i x_{ij} r_i^{(j)}$. Aktualizujemy

$$\beta_j \leftarrow \frac{\operatorname{sign}(z_j)(|z_j| - \lambda/2)_+}{s_j}. \tag{7.15}$$

Przechodzimy kolejno przez wszystkie kolumny i powtarzamy cykle (J. Friedman i in. 2007). Kolumny o zerowej zmienności usuwamy. Każda aktualizacja minimalizuje funkcję celu po jednej współrzędnej; nie zwiększa więc wartości celu. W przeciwieństwie do niezależnego zastosowania progu do oszacowań OLS, reszta częściowa uwzględnia aktualne współczynniki pozostałych cech.

Poniższy kod ilustruje cykle dla małego zadania. Przechowuje wartości celu i zatrzymuje się przy małej zmianie współczynników. Jest narzędziem dydaktycznym; biblioteczne solvery dodatkowo kontrolują dokładność warunków optymalności, m.in. przez lukę dualną.

```
Liczba cykli: 3464
```

Tabela 7.7.: Aktualizacja współrzędnych i biblioteczne LASSO dla tego samego zadania. Kolumny danych są wycentrowane; lambda wynosi 20.

	cecha	aktualizacje	Lasso
0	Income	-273.12912	-273.12912
1	Limit	229.88159	229.88159
2	Rating	383.92089	383.92089

Warunek małych zmian współczynników sam w sobie nie jest uniwersalnym certyfikatem dokładności. W przykładzie porównujemy także rozwiązanie z biblioteką przy zgodnej normalizacji kary. Dla silnie skorelowanych cech zbieżność może wymagać wielu cykli; to inny problem niż statystyczny wybór siły regularyzacji.

Uwagi bibliograficzne

Selekcję podzbiorów, metody schodów i kryteria C_p, AIC i BIC przedstawiają James i in. (2023, rozdz. 6.1), a ridge i LASSO – James i in. (2023, rozdz. 6.2). Ten sam rozdział podręcznika zawiera przykłady obliczeniowe. Pełniejszy wykład dają Hastie i in. (2009): selekcję podzbiorów

w rozdz. 3.3, ridge, LASSO i ich geometrię w rozdz. 3.4, a aktualizację współrzędnych w rozdz. 3.8. Kryteria C_p i AIC wyprowadzają jako oszacowania błędu predykcji w rozdz. 7.5, efektywną liczbę parametrów omawiają w rozdz. 7.6, a BIC w rozdz. 7.7.

Kryterium C_p omawia Mallows (1973). AIC wprowadził Akaike (1974), a kryterium BIC – Schwarz (1978). Kryteria te wynikają z różnych sposobów porównywania modeli probabilistycznych; ich wzory dla regresji normalnej wymagają konsekwentnego liczenia parametrów i tej samej próby danych. Nie zastępują oddzielenia wyboru od końcowej oceny procedury z rozdziału 5. Problem wnioskowania o współczynnikach modelu wybranego na tych samych danych oraz konstrukcję przedziałów, które uwzględniają etap selekcji, opisują Berk i in. (2013).

Klasyczna praca o regresji grzbietowej to artykuł Hoerl i Kennard (1970), a metodę LASSO zaproponował Tibshirani (1996). Zależność wyników od skali cech i stabilność wyboru przy podobnych predyktorach są częścią interpretacji tych metod, a nie tylko szczegółami obliczeń. W praktyce trzeba też sprawdzić normalizację funkcji celu w używanym oprogramowaniu, jak w porównaniu klas `Ridge` i `Lasso` powyżej. Połączenie obu kar, czyli elastic net, zaproponowali Zou i Hastie (2005). Algorytm aktualizacji współrzędnych dla LASSO opisują J. Friedman i in. (2007).

Zadania

Zadania od Zadanie 7.1 do Zadanie 7.8 korzystają z tekstu głównego. Dwa ostatnie zadania rozwijają materiał rozszerzeń.

Zadanie 7.1. Rozważ trzy cechy A, B, C. Poniższa tabela jest przykładem dydaktycznym; RSS dotyczy dopasowania na jednej próbie, a MSE CV obliczono przez powtarzanie całej selekcji wewnątrz części uczących.

Podzbiór	RSS
pusty	200
A	140
B	150
C	170
A, B	120
A, C	125
B, C	110
A, B, C	100

Liczba cech	MSE CV procedury przeglądu zupełnego
0	12
1	9
2	8
3	10

a) Dla każdej liczby cech wskaż podzbiór o najmniejszym RSS.
b) Wybierz wielkość modelu według CV. Jaki podzbiór zostanie dopasowany na całej próbie po tym wyborze?
c) Dlaczego najmniejszy RSS nie prowadzi do tego samego wyboru?

d) Wyjaśnij, dlaczego nie wolno wybrać podzbiorów z pierwszej tabeli na całej próbie, a dopiero potem traktować ich jako ustalonych kandydatów przy wyznaczaniu CV.

Zadanie 7.2. Korzystając z tabeli RSS w Zadanie 7.1:

a) Wypisz ścieżkę selekcji w przód, od modelu pustego do pełnego.
b) Wypisz ścieżkę selekcji wstecz.
c) Czy obie ścieżki zawierają najlepszy podzbiór dwóch cech?
d) Ile modeli trzeba dopasować w przeglądzie zupełnym przy $p = 10$, a ile rozszerzeń ocenić w pełnej ścieżce w przód? Model początkowy policz osobno.

Zadanie 7.3. Na tych samych $n = 100$ obserwacjach porównujemy dwa ustalone modele OLS. Pierwszy ma $d = 3$ parametry i RSS równy 100, drugi ma $d = 4$ parametry oraz RSS równy 97. Dane mają TSS równy 200, a wspólna estymata wariancji do C_p wynosi 1.

a) Oblicz skorygowany R^2 i C_p dla obu modeli.
b) Oblicz AIC i BIC w postaciach do porównania (7.3) i (7.4).
c) Wyjaśnij ewentualną różnicę wyboru AIC i BIC. Jak duży spadek RSS kompensuje koszt jednego parametru w każdym z nich?
d) Dlaczego do obliczania tych kryteriów nie można bez zmiany rachunku użyć modelu ridge i wpisać za d liczby jego kolumn?

Zadanie 7.4. Model z cechą X wyrażoną w tysiącach dolarów ma współczynnik $\beta = 2$. Wprowadzamy cechę $X' = 1000X$ wyrażoną w dolarach.

a) Jaki współczynnik przy X' daje tę samą funkcję predykcji?
b) Jak zmieniają się kary $\lambda\beta^2$ i $\lambda|\beta|$ przy tym samym λ?
c) Pokaż, że standaryzacja X i X' na tej samej próbie daje identyczne wartości, gdy odchylenie standardowe jest dodatnie.
d) Które obserwacje wyznaczają średnią i odchylenie w jednym kroku CV? Jak przekształcamy obserwacje walidacyjne?

Zadanie 7.5. Dla jednej wycentrowanej cechy mamy $s = \sum_i x_i^2 = 10$ oraz $z = \sum_i x_i y_i = 30$.

a) Oblicz OLS oraz ridge i LASSO dla $\lambda = 0, 10, 30, 60$.
b) Od jakiej wartości kary współczynnik LASSO jest zerem? Czy ridge osiąga zero dla skończonej kary w tych danych?
c) Jeżeli wariancja OLS przy ustalonej cesze wynosi v, jaka jest wariancja ridge dla $\lambda = 10$? Wyjaśnij koszt takiej redukcji, gdy prawdziwy współczynnik wynosi 3.
d) Jakie `alpha` trzeba przekazać do `Ridge` i `Lasso`, aby przy $n = 100$ uzyskać $\lambda = 30$ w konwencji rozdziału?

Zadanie 7.6. Dla dwóch współczynników nieograniczona funkcja RSS, po pominięciu stałej, wynosi $(\beta_1 - 2)^2 + (\beta_2 - 0{,}6)^2$.

a) Narysuj jej poziomice oraz zbiory $\beta_1^2 + \beta_2^2 \le 1$ i $|\beta_1| + |\beta_2| \le 1$.
b) Wskaż na rysunku rozwiązania obu zadań. Które ma zerową współrzędną?
c) Co stanie się, gdy ograniczenie przestanie wykluczać punkt OLS?
d) Wyjaśnij, dlaczego interpretacja rombu nie oznacza, że LASSO zawsze usuwa co najmniej jedną cechę.

Zadanie 7.7. Powtórz porównanie na *Credit* z sekcji 7.6, zachowując ten sam zbiór testowy i tę samą listę cech.

a) Wyjaśnij role każdej części danych w jednym kroku CV dla selekcji w przód i dla LASSO. Co jest wybierane, a co dopasowywane?
b) Na danych uczących wyznacz dla ridge i LASSO minimum CV i wariant reguły 1 SE. Dopasuj warianty na całej części uczącej i porównaj współczynniki oraz liczbę zer. Test pozostaw do końca.
c) Oceń wcześniej ustalone warianty na teście; podaj MSE, jego błąd standardowy i RMSE. Wyjaśnij, dlaczego wybranie zwycięzcy po obejrzeniu tej tabeli zmieniłoby rolę testu.
d) Wskaż błąd w postępowaniu: „najpierw wybieram trzy cechy najlepiej związane z saldem na wszystkich danych, potem używam potoku skalowanie plus LASSO w CV". Czy sam potok naprawia ten błąd?

Zadanie 7.8. Wykorzystaj generator `proba_liniowa` z rysunku 7.1. Z góry ustal liczbę obserwacji $n = 60$ i kary: `Ridge(alpha=30)` oraz `Lasso(alpha=0.5)`, każdorazowo po standaryzacji na próbie uczącej.

a) Wygeneruj 200 niezależnych prób uczących. Dla każdej dopasuj ridge i LASSO; zapisz współczynniki w oryginalnych jednostkach (podziel współczynniki po skalowaniu przez wyuczone odchylenia).
b) Jak często LASSO wybiera pierwszą, drugą i każdą z pozostałych cech? Jak często wybiera co najmniej jedną z pierwszych dwóch?
c) Na jednym dużym niezależnym zbiorze cech porównaj zmienność predykcji obu metod po próbach oraz ich średni błąd wobec prawdziwej funkcji $3X_1$. Odróżnij to od błędu wobec nowego Y.
d) Powtórz eksperyment dla korelacji pierwszej pary równej 0 oraz 0,999. Czy niestabilność współczynników i listy cech zawsze idzie w parze z równie dużą niestabilnością predykcji?

Zadanie 7.9. Rozszerzenie: efektywne stopnie swobody ridge. Wymagane są algebra macierzowa, wartości własne i ślad macierzy.

Dla wycentrowanego $\mathbf{X}$ dodatnie wartości własne $\mathbf{X}^\top\mathbf{X}$ wynoszą $1, 10, 100$, a pozostałe są zerowe. Wyraz wolny nie podlega karze.

a) Oblicz efektywne stopnie swobody dla $\lambda = 1, 10, 100$.
b) Wyznacz granice przy $\lambda \downarrow 0$ i $\lambda \to \infty$.
c) Który kierunek jest najmocniej tłumiony przy $\lambda = 10$?
d) Dla ogólnego $\mathbf{X}$ uzasadnij wzór (7.14) przez własność $\operatorname{tr}(AB) = \operatorname{tr}(BA)$.

Zadanie 7.10. Rozszerzenie: aktualizacja współrzędnych LASSO. Wymagane są różniczkowanie i zapis macierzowy.

Wycentrowane dane spełniają

$$\mathbf{X}^\top\mathbf{X} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}, \qquad \mathbf{X}^\top\mathbf{y} = \begin{pmatrix} 4 \\ 3 \end{pmatrix}, \qquad \lambda = 2.$$

a) Zacznij od $(0, 0)$ i wykonaj dwa cykle aktualizacji, najpierw pierwszej, potem drugiej współrzędnej.
b) Jak obliczysz z_j z samych $\mathbf{X}^\top\mathbf{X}$, $\mathbf{X}^\top\mathbf{y}$ i aktualnych współczynników, bez odtwarzania całego wektora reszt?
c) Sprawdź, że każda aktualizacja nie zwiększa funkcji celu; pomiń nieznaną stałą $\mathbf{y}^\top\mathbf{y}$.
d) Wyjaśnij, dlaczego niezależne progowanie współczynników OLS nie zastępuje tych aktualizacji dla skorelowanych kolumn.

8. Regresja logistyczna

Rozdział w przygotowaniu.

9. Uogólnione modele liniowe i regresja Poissona

Rozdział w przygotowaniu.

Część III.

Podejście probabilistyczne

10. Paradygmat bayesowski

Rozdział w przygotowaniu.

11. Modele generatywne: LDA, QDA i naiwny Bayes

Rozdział w przygotowaniu.

Część IV.

Poza liniowość

12. Perceptron wielowarstwowy i propagacja wsteczna

Rozdział w przygotowaniu.

13. Maszyny wektorów nośnych

Rozdział w przygotowaniu.

Część V.

Uczenie nienadzorowane

14. Analiza składowych głównych

Rozdział w przygotowaniu.

15. Grupowanie: k-średnich, GMM i algorytm EM

Rozdział w przygotowaniu.

Bibliografia

Akaike, H. 1974. „A new look at the statistical model identification". *IEEE Transactions on Automatic Control* 19 (6): 716–23. https://doi.org/10.1109/tac.1974.1100705.

Ambroise, Christophe i Geoffrey J. McLachlan. 2002. „Selection Bias in Gene Extraction on the Basis of Microarray Gene-Expression Data". *Proceedings of the National Academy of Sciences* 99 (10): 6562–66. https://doi.org/10.1073/pnas.102102699.

Arlot, Sylvain i Alain Celisse. 2010. „A Survey of Cross-Validation Procedures for Model Selection". *Statistics Surveys* 4: 40–79. https://doi.org/10.1214/09-SS054.

Bates, Stephen, Trevor Hastie i Robert Tibshirani. 2024. „Cross-Validation: What Does It Estimate and How Well Does It Do It?" *Journal of the American Statistical Association* 119 (546): 1434–45. https://doi.org/10.1080/01621459.2023.2197686.

Belkin, Mikhail, Daniel Hsu, Siyuan Ma i Soumik Mandal. 2019. „Reconciling Modern Machine-Learning Practice and the Classical Bias–Variance Trade-Off". *Proceedings of the National Academy of Sciences* 116 (32): 15849–54. https://doi.org/10.1073/pnas.1903070116.

Belsley, David A., Edwin Kuh i Roy E. Welsch. 1980. *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. Wiley Series in Probability and Statistics. Wiley. https://doi.org/10.1002/0471725153.

Bengio, Yoshua i Yves Grandvalet. 2004. „No Unbiased Estimator of the Variance of K-Fold Cross-Validation". *Journal of Machine Learning Research* 5: 1089–105.

Bergstra, James i Yoshua Bengio. 2012. „Random Search for Hyper-Parameter Optimization". *Journal of Machine Learning Research* 13: 281–305.

Berk, Richard, Lawrence Brown, Andreas Buja, Kai Zhang i Linda Zhao. 2013. „Valid Post-Selection Inference". *The Annals of Statistics* 41 (2): 802–37. https://doi.org/10.1214/12-AOS1077.

Beyer, Kevin, Jonathan Goldstein, Raghu Ramakrishnan i Uri Shaft. 1999. „When Is »Nearest Neighbor« Meaningful?" *Database Theory – ICDT'99*, Lecture Notes in Computer Science, 217–35. https://doi.org/10.1007/3-540-49257-7_15.

Bishop, Christopher M. 2006. *Pattern Recognition and Machine Learning*. Information Science and Statistics. Springer.

Box, George E. P. 1976. „Science and Statistics". *Journal of the American Statistical Association* 71 (356): 791–99. https://doi.org/10.1080/01621459.1976.10480949.

Box, George E. P. i Norman R. Draper. 1987. *Empirical Model-Building and Response Surfaces*. Wiley Series in Probability and Mathematical Statistics. Wiley.

Brier, Glenn W. 1950. „Verification of Forecasts Expressed in Terms of Probability". *Monthly Weather Review* 78 (1): 1–3. https://doi.org/10.1175/1520-0493(1950)078%3C0001:VOFEIT%3E2.0.CO;2.

Caruana, Rich, Yin Lou, Johannes Gehrke, Paul Koch, Marc Sturm i Noémie Elhadad. 2015. „Intelligible Models for HealthCare: Predicting Pneumonia Risk and Hospital 30-day Readmission". *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1721–30. https://doi.org/10.1145/2783258.2788613.

Cawley, Gavin C. i Nicola L. C. Talbot. 2010. „On Over-Fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation". *Journal of Machine Learning Research* 11: 2079–107.

Chow, C. K. 1970. „On Optimum Recognition Error and Reject Tradeoff". *IEEE Transactions on Information Theory* 16 (1): 41–46. https://doi.org/10.1109/TIT.1970.1054406.

Cook, R. Dennis. 1977. „Detection of Influential Observation in Linear Regression". *Technometrics* 19 (1): 15–18. https://doi.org/10.1080/00401706.1977.10489493.

Cover, Thomas M. i Peter E. Hart. 1967. „Nearest Neighbor Pattern Classification". *IEEE Transactions on Information Theory* 13 (1): 21–27. https://doi.org/10.1109/TIT.1967.1053964.

Devroye, Luc, László Györfi i Gábor Lugosi. 1996. *A Probabilistic Theory of Pattern Recognition*. Stochastic Modelling and Applied Probability 31. Springer. https://doi.org/10.1007/978-1-4612-0711-5.

Dietterich, Thomas G. 1998. „Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms". *Neural Computation* 10 (7): 1895–923. https://doi.org/10.1162/089976698300017197.

Efron, Bradley. 1979. „Bootstrap Methods: Another Look at the Jackknife". *The Annals of Statistics* 7 (1): 1–26. https://doi.org/10.1214/aos/1176344552.

Efron, Bradley. 1983. „Estimating the Error Rate of a Prediction Rule: Improvement on Cross-Validation". *Journal of the American Statistical Association* 78 (382): 316–31. https://doi.org/10.1080/01621459.1983.10477973.

Efron, Bradley i Robert Tibshirani. 1993. *An Introduction to the Bootstrap*. Monographs on Statistics and Applied Probability 57. Chapman & Hall. https://doi.org/10.1201/9780429246593.

Efron, Bradley i Robert Tibshirani. 1997. „Improvements on Cross-Validation: The .632+ Bootstrap Method". *Journal of the American Statistical Association* 92 (438): 548–60. https://doi.org/10.1080/01621459.1997.10474007.

Elkan, Charles. 2001. „The Foundations of Cost-Sensitive Learning". *Proceedings of the Seventeenth International Joint Conference on Artificial Intelligence (IJCAI)*, 973–78.

Fix, Evelyn i J. L. Hodges Jr. 1951. *Discriminatory Analysis. Nonparametric Discrimination: Consistency Properties*. Report 4, Project 21-49-004. USAF School of Aviation Medicine.

Friedman, Jerome H. 1997. „On Bias, Variance, 0/1–Loss, and the Curse-of-Dimensionality". *Data Mining and Knowledge Discovery* 1 (1): 55–77. https://doi.org/10.1023/A:1009778005914.

Friedman, Jerome, Trevor Hastie, Holger Höfling i Robert Tibshirani. 2007. „Pathwise Coordinate Optimization". *The Annals of Applied Statistics* 1 (2): 302–32. https://doi.org/10.1214/07-AOAS131.

Geman, Stuart, Elie Bienenstock i René Doursat. 1992. „Neural Networks and the Bias/Variance Dilemma". *Neural Computation* 4 (1): 1–58. https://doi.org/10.1162/neco.1992.4.1.1.

Gneiting, Tilmann i Adrian E. Raftery. 2007. „Strictly Proper Scoring Rules, Prediction, and Estimation". *Journal of the American Statistical Association* 102 (477): 359–78. https://doi.org/10.1198/016214506000001437.

Györfi, László, Michael Kohler, Adam Krzyżak i Harro Walk. 2002. *A Distribution-Free Theory of Nonparametric Regression*. Springer Series in Statistics. Springer. https://doi.org/10.1007/b97848.

Hastie, Trevor, Robert Tibshirani i Jerome Friedman. 2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2. wyd. Springer.

Hoerl, Arthur E. i Robert W. Kennard. 1970. „Ridge Regression: Biased Estimation for Nonorthogonal Problems". *Technometrics* 12 (1): 55–67. https://doi.org/10.1080/00401706.1970.10488634.

James, Gareth, Daniela Witten, Trevor Hastie, Robert Tibshirani i Jonathan Taylor. 2023. *An Introduction to Statistical Learning with Applications in Python*. Springer Texts in Statistics. Springer.

Kahneman, Daniel. 2011. *Thinking, Fast and Slow*. Farrar, Straus and Giroux.

MacKinnon, James G. i Halbert White. 1985. „Some Heteroskedasticity-Consistent Covariance Matrix Estimators with Improved Finite Sample Properties". *Journal of Econometrics* 29 (3): 305–25. https://doi.org/10.1016/0304-4076(85)90158-7.

Mallows, C. L. 1973. „Some Comments on C_p". *Technometrics* 15 (4): 661–75. https://doi.org/10.1080/00401706.1973.10489103.

Murphy, Kevin P. 2022. *Probabilistic Machine Learning: An Introduction*. MIT Press.

Rudin, Cynthia. 2019. „Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead". *Nature Machine Intelligence* 1 (5): 206–15. https://doi.org/10.1038/s42256-019-0048-x.

Schwarz, Gideon. 1978. „Estimating the Dimension of a Model". *The Annals of Statistics* 6 (2): 461–64. https://doi.org/10.1214/aos/1176344136.

Seber, George A. F. i Alan J. Lee. 2003. *Linear Regression Analysis*. 2. wyd. Wiley Series in Probability and Statistics. Wiley. https://doi.org/10.1002/9780471722199.

Shalev-Shwartz, Shai i Shai Ben-David. 2014. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press. https://doi.org/10.1017/CBO9781107298019.

Stone, Charles J. 1977. „Consistent Nonparametric Regression". *The Annals of Statistics* 5 (4): 595–620. https://doi.org/10.1214/aos/1176343886.

Stone, Charles J. 1982. „Optimal Global Rates of Convergence for Nonparametric Regression". *The Annals of Statistics* 10 (4): 1040–53. https://doi.org/10.1214/aos/1176345969.

Stone, M. 1974. „Cross-Validatory Choice and Assessment of Statistical Predictions". *Journal of the Royal Statistical Society: Series B (Methodological)* 36 (2): 111–33. https://doi.org/10.1111/j.2517-6161.1974.tb00994.x.

Tibshirani, Robert. 1996. „Regression Shrinkage and Selection Via the Lasso". *Journal of the Royal Statistical Society Series B: Statistical Methodology* 58 (1): 267–88. https://doi.org/10.1111/j.2517-6161.1996.tb02080.x.

Varma, Sudhir i Richard Simon. 2006. „Bias in Error Estimation When Using Cross-Validation for Model Selection". *BMC Bioinformatics* 7: 91. https://doi.org/10.1186/1471-2105-7-91.

White, Halbert. 1980. „A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity". *Econometrica* 48 (4): 817–38. https://doi.org/10.2307/1912934.

Zou, Hui i Trevor Hastie. 2005. „Regularization and Variable Selection Via the Elastic Net". *Journal of the Royal Statistical Society Series B: Statistical Methodology* 67 (2): 301–20. https://doi.org/10.1111/j.1467-9868.2005.00503.x.