Modele analizy danych

Podręcznik do przedmiotu

Tomasz Rodak

2026-10-26

Spis treści

Przedmowa **1**
Kod w książce . . . 1
Literatura . . . 1
Konwencje notacyjne . . . 1

I. Fundamenty **3**

1. Czym jest model? **5**
1.1. Pojęcie modelu . . . 5
1.2. Model w analizie danych . . . 6
1.3. Uczenie nadzorowane i nienadzorowane . . . 7
1.4. Regresja i klasyfikacja . . . 8
1.5. Probabilistyczny opis danych . . . 10
1.5.1. Regresja . . . 13
1.5.2. Klasyfikacja . . . 15
1.6. Jak mierzymy jakość predykcji . . . 16
1.6.1. Błąd redukowalny i nieredukowalny . . . 18
1.7. Dwa cele modelowania: predykcja i wnioskowanie . . . 18
1.8. Trening modelu . . . 20
1.9. Metody parametryczne i nieparametryczne . . . 22
1.10. Kompromis między interpretowalnością a dokładnością . . . 24
Zadania . . . 26

2. Predyktory optymalne i błąd nieredukowalny **31**
2.1. Sformułowanie problemu . . . 31
2.2. Redukcja do problemu punktowego . . . 32
2.3. Regresja: strata kwadratowa i strata absolutna . . . 33
2.3.1. Funkcja regresji . . . 33
2.3.2. Strata absolutna . . . 33
2.3.3. Rozkład ryzyka przy stracie kwadratowej . . . 35
2.4. Klasyfikacja: strata 0–1 i klasyfikator bayesowski . . . 35
2.5. Od prawdopodobieństw do decyzji . . . 37
2.5.1. Predykcja probabilistyczna . . . 37
2.5.2. Straty niesymetryczne i próg decyzyjny . . . 38
2.5.3. Opcja odmowy . . . 39
2.6. Nieosiągalność optimum . . . 39
Uwagi bibliograficzne . . . 41
Zadania . . . 41

3. Metoda k najbliższych sąsiadów **43**
3.1. Uśrednianie lokalne . . . 43
3.2. Reguła k najbliższych sąsiadów . . . 45
3.3. Co znaczy „blisko” . . . 46

3.4. Rola liczby sąsiadów . . . 47
3.5. Zbieżność do optimum . . . 49
3.6. Przekleństwo wymiarowości . . . 52
3.6.1. Otoczenie przestaje być lokalne . . . 52
3.6.2. Objętość ucieka do narożników i brzegów . . . 52
3.6.3. Odległości przestają się różnić . . . 53
3.6.4. Skutek dla klasyfikacji . . . 53
3.6.5. Co z tego wynika . . . 55
3.7. Metoda k-NN w praktyce . . . 55
Uwagi bibliograficzne . . . 56
Zadania . . . 56

4. Kompromis obciążenie–wariancja **59**
4.1. Błąd uczący a ryzyko . . . 59
4.2. Zbiór uczący jest losowy . . . 61
4.3. Obciążenie i wariancja estymatora . . . 62
4.4. Rozkład oczekiwanego błędu predykcji . . . 63
4.5. Ilustracja: k-NN i regresja wielomianowa . . . 64
4.6. Błąd aproksymacji i błąd estymacji . . . 65
4.7. Krzywe uczenia . . . 67
4.8. Dlaczego kompromis jest nieusuwalny . . . 68
4.8.1. Ile kosztuje elastyczność w wielu wymiarach . . . 69
4.9. Obciążenie i wariancja w klasyfikacji . . . 69
Uwagi bibliograficzne . . . 70
Zadania . . . 71

5. Ocena modeli w praktyce **75**
5.1. Trzy pytania . . . 75
5.2. Zbiór testowy . . . 76
5.2.1. Niepewność oszacowania . . . 77
5.2.2. Porównanie dwóch modeli . . . 77
5.2.3. Cena odłożenia danych . . . 78
5.3. Zbiór walidacyjny . . . 78
5.4. Walidacja krzyżowa . . . 78
5.4.1. Błąd uczący a LOOCV . . . 79
5.4.2. Ile części . . . 80
5.4.3. Co szacuje walidacja krzyżowa . . . 81
5.4.4. Błąd standardowy walidacji krzyżowej . . . 81
5.4.5. Walidacja krzyżowa w klasyfikacji . . . 83
5.5. Wyciek informacji . . . 83
5.6. Selekcja modelu a ocena modelu . . . 85
5.7. Strojenie hiperparametrów . . . 87
5.8. Bootstrap . . . 89
5.8.1. Bootstrap a ocena ryzyka . . . 91
5.9. Krzywe uczenia z danych . . . 92
5.10. Ocena modeli w praktyce . . . 93
Uwagi bibliograficzne . . . 94
Zadania . . . 94

II. Modele liniowe **97**

6. Regresja liniowa **99**
6.1. Model liniowy . . . 99
6.2. Metoda najmniejszych kwadratów . . . 100
6.2.1. Geometria najmniejszych kwadratów . . . 101
6.2.2. Dopasowanie do danych *Advertising* . . . 102
6.3. Własności estymatora MNK . . . 103
6.3.1. Wariancja predykcji . . . 105
6.3.2. Estymacja wariancji błędu . . . 105
6.3.3. Twierdzenie Gaussa–Markowa . . . 106
6.4. Wnioskowanie o parametrach . . . 106
6.4.1. Błędy standardowe i przedziały ufności . . . 107
6.4.2. Test istnienia relacji . . . 109
6.5. Jakość dopasowania . . . 110
6.6. Cechy jakościowe . . . 111
6.7. Interakcje i nieliniowość . . . 112
6.8. Diagnostyka modelu . . . 114
6.8.1. Brak liniowości . . . 114
6.8.2. Skorelowane błędy . . . 115
6.8.3. Heteroskedastyczność . . . 116
6.8.4. Obserwacje odstające i wpływowe . . . 117
6.8.5. Współliniowość . . . 118
Uwagi bibliograficzne . . . 119
Zadania . . . 120

7. Selekcja i regularyzacja **125**

8. Regresja logistyczna **127**

9. Uogólnione modele liniowe i regresja Poissona **129**

III. Podejście probabilistyczne **131**

10. Paradygmat bayesowski **133**

11. Modele generatywne: LDA, QDA i naiwny Bayes **135**

IV. Poza liniowość **137**

12. Perceptron wielowarstwowy i propagacja wsteczna **139**

13. Maszyny wektorów nośnych **141**

V. Uczenie nienadzorowane **143**

14. Analiza składowych głównych **145**

15. Grupowanie: k-średnich, GMM i algorytm EM **147**

Bibliografia **149**

Przedmowa

Podręcznik powstaje na bazie kursu *Modele analizy danych* prowadzonego na studiach magisterskich kierunku Analiza Danych. Materiał wykładowy z lat poprzednich został potraktowany jako punkt wyjścia, ale jest pisany na nowo: część wątków rozszerzono, część przeredagowano, dodano nowe przykłady i ćwiczenia.

Kod w książce

Fragmenty kodu są w pełni reprodukowalne: wszystkie losowania mają ustalone ziarno. Kod każdego rysunku można rozwinąć i skopiować. Do jego uruchomienia wystarczy Python 3.12 z pakietami `numpy`, `scipy`, `pandas`, `matplotlib`, `scikit-learn` i `statsmodels`. Pliki z danymi, z których korzystają przykłady, są w katalogu `dane/` repozytorium książki.

Literatura

Pierwsze dwie pozycje reprezentują ujęcie statystyczne, dwie kolejne – probabilistyczne, w dużej mierze oparte na metodach bayesowskich.

- **ISLP** (James i in. 2023) – podstawowy podręcznik uzupełniający, z przykładami w Pythonie.
- **ESL** (Hastie i in. 2009) – szerszy zakres i głębsze, bardziej precyzyjne ujęcie tego samego materiału.
- **PRML** (Bishop 2006) i **PML** (Murphy 2022) – uczenie maszynowe budowane konsekwentnie na modelach probabilistycznych i wnioskowaniu bayesowskim.
- Devroye i in. (1996) i Györfi i in. (2002) – teoria klasyfikacji i regresji nieparametrycznej dla Czytelników zainteresowanych ścisłymi dowodami.

Konwencje notacyjne

Oznaczenie	Znaczenie
$\mathbb{R}$	zbiór liczb rzeczywistych
$\mathbf{x}$, $\mathbf{X}$	wektor cech (mała pogrubiona), macierz projektowa lub wektor losowy cech (duża pogrubiona)
Y, y	zmienna objaśniana i jej realizacja
$\mathbb{E}$, $\mathbb{P}$	wartość oczekiwana, prawdopodobieństwo
Var, Cov	wariancja, kowariancja
$\mathcal{N}(\mu, \sigma^2)$	rozkład normalny
$\mathbb{1}(\cdot)$	funkcja wskaźnikowa
$L(y, a)$, $R(f)$	funkcja straty, ryzyko predyktora

Oznaczenie	Znaczenie
f^*, g^*	predyktor optymalny, klasyfikator bayesowski
$\hat{\cdot}$	wielkość estymowana z danych
n, p	liczba obserwacji, liczba cech
$\mathcal{D}$	zbiór danych, $\{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)\}$

Rozkład warunkowy zapisujemy $Y \mid \mathbf{X} = \mathbf{x}$, a wartości oczekiwane względem niego – $\mathbb{E}[\cdot \mid \mathbf{X} = \mathbf{x}]$.

Część I.

Fundamenty

1. Czym jest model?

1.1. Pojęcie modelu

Ogólny termin *model* oznacza abstrakcyjny, uproszczony obraz pewnego fragmentu rzeczywistości. Prostym przykładem jest mapa – model geograficzny reprezentujący terytorium. Uproszczenie sprawia, że model nie jest wierną kopią rzeczywistości, lecz w pewien sposób ją zniekształca. Jest ono jednak konieczne: model doskonale wierny musiałby być kompletną kopią modelowanej rzeczywistości, a wskutek tego byłby równie przeładowany nieistotnymi szczegółami i równie trudny do zrozumienia jak ona sama.

Model jest więc kompromisem między wiernością a użytecznością – narzędziem poznawczym, które pozwala lepiej zrozumieć rzeczywistość właśnie dzięki temu, że ją upraszcza. Myśl tę wyraził George Box (Box 1976), a powtarzane dziś przy tej okazji powiedzenie brzmi: „wszystkie modele są błędne, ale niektóre są użyteczne" (Box i Draper 1987).

Uproszczenie ma jeszcze jedną konsekwencję. Ponieważ każdy model pomija pewne aspekty rzeczywistości, żaden nie jest jej doskonale wiernym obrazem. Może być natomiast mniej lub bardziej trafny oraz użyteczny w określonym kontekście. Doskonała wierność nie może więc stanowić praktycznego kryterium oceny modelu. Zastępują ją kryteria trafności, zakresu stosowalności i użyteczności.

Poniższa lista zbiera własności, które w praktyce charakteryzują dobry model.

- **Celowość.** Model nie powstaje bez określonego celu – jest projektowany pod konkretne pytanie lub klasę zadań. Ten sam obiekt rzeczywisty, na przykład miasto, ma zupełnie inny model dla urbanisty, inny dla epidemiologa, a jeszcze inny dla nawigacji satelitarnej.

- **Selektywność i jawne granice.** Model określa, co znajduje się wewnątrz analizowanego systemu, a co zostaje pominięte. Przebieg tej granicy jest wyborem badacza i powinien być przedstawiony wprost – to, co model pomija, może później ujawnić się jako źródło jego błędu.

- **Zachowanie istotnych relacji.** Choć model odrzuca wiele szczegółów, powinien zachowywać te własności i relacje między elementami, które są istotne ze względu na jego cel. Mapa drogowa powinna na przykład poprawnie przedstawiać połączenia między miejscami, ale nie musi wiernie oddawać wszystkich odległości ani kształtów terenu. O wartości modelu decyduje więc nie liczba uwzględnionych szczegółów, lecz trafność zachowanej struktury.

- **Użyteczność.** Dobry model pozwala wykonać zadanie, do którego został zbudowany: opisać lub wyjaśnić zjawisko, dokonać przewidywania albo przeprowadzić eksperyment typu *„co, jeśli…"* bez ponoszenia kosztów i ryzyka działania w świecie rzeczywistym.

- **Redukcja złożoności poznawczej.** Model sprowadza złożoność otoczenia do rozmiaru, który człowiek lub komputer jest w stanie przetworzyć i zrozumieć.

- **Ograniczony zakres stosowalności.** Każdy model działa w określonym zakresie i przy pewnych założeniach. Nowe dane lub zmiana warunków mogą ujawnić jego ograniczenia i wymusić jego modyfikację. Modelowanie jest zatem procesem iteracyjnym, a nie jednorazowym aktem.

1.2. Model w analizie danych

W analizie danych *modelem* nazywamy sformalizowany opis prawidłowości dotyczących badanego zjawiska, konstruowany i oceniany na podstawie danych. Model nie opisuje bezpośrednio całej rzeczywistości, lecz wybrane, zarejestrowane cechy badanych obiektów oraz relacje między nimi. Pozwala przejść od zbioru pojedynczych obserwacji do bardziej ogólnego opisu, który można zastosować również do nowych przypadków.

Najczęściej model opisuje zależność między:

- **zmiennymi wejściowymi**, nazywanymi również cechami;
- **zmienną wyjściową**, nazywaną zmienną objaśnianą, odpowiedzią albo zmienną docelową.

Działanie modelu możemy schematycznie zapisać jako

$$\hat{y} = \hat{f}(\mathbf{x}),$$

gdzie $\mathbf{x}$ oznacza zestaw cech opisujących obiekt, a $\hat{y}$ – wynik zwracany przez model. Daszek zaznacza, że mamy do czynienia z wielkością wyznaczoną z danych: $\hat{f}$ jest zależnością odtworzoną na ich podstawie, a nie rzeczywistym mechanizmem badanego zjawiska. Obserwowany rzeczywisty wynik (*ground truth*) będziemy oznaczać przez y. Przykładowo $\mathbf{x}$ może zawierać wiek, masę ciała i wyniki badań pacjenta, natomiast y może oznaczać obecność choroby.

W analizie danych zmienne wejściowe nie muszą jednoznacznie wyznaczać obserwowanego wyniku, ponieważ zwykle nie zawierają pełnej informacji o badanym zjawisku. Dwóch pacjentów o takich samych wartościach zarejestrowanych cech może mieć różny stan zdrowia: u jednego rozpoznano chorobę, u drugiego nie. Wynika to między innymi z wpływu czynników nieuwzględnionych w danych, błędów pomiarowych oraz przypadkowej zmienności badanego zjawiska.

Nie oznacza to jednak, że sam model musi być niedeterministyczny. Model jest zwykle funkcją: dla tych samych wartości wejściowych zwraca zawsze ten sam wynik. Obiektom opisanym identycznym wektorem cech przypisze więc identyczną predykcję, chociaż ich rzeczywiste wyniki mogą się różnić.

Nie ma w tym sprzeczności, ponieważ wyniku zwracanego przez model nie należy traktować jako pewnego rozstrzygnięcia o pojedynczym przypadku: z wymienionych wyżej powodów takie rozstrzygnięcie jest nieosiągalne. Skoro obiekty o identycznych cechach mają różne wyniki, żadna pojedyncza odpowiedź nie będzie trafna dla wszystkich. Model opisuje raczej to, czego można się spodziewać wśród obiektów o danych cechach, niż to, co wydarzy się w pojedynczym przypadku. Przewidując czas hospitalizacji, może zwracać wartość przeciętną dla pacjentów o danym profilu, ewentualnie uzupełnioną o przedział, w którym wynik powinien się mieścić. Rozpoznając chorobę, może zamiast jednoznacznej diagnozy podawać oszacowanie ryzyka jej wystąpienia. W obu przypadkach model przypisuje pojedynczemu obiektowi opis regularności obserwowanej w całej grupie obiektów do niego podobnych.

Model może mieć postać wzoru matematycznego, zestawu reguł, drzewa decyzyjnego lub bardziej złożonej struktury obliczeniowej. Słowo *model* jest przy tym używane w dwóch powiązanych

znaczeniach. Może oznaczać **klasę modeli**, czyli zbiór dopuszczalnych zależności różniących się parametrami, a niekiedy także strukturą. Przykładowo regresja logistyczna określa ogólną postać zależności między cechami a prawdopodobieństwem wyniku, ale nie wyznacza jeszcze konkretnych wartości współczynników.

Słowo *model* może również oznaczać **model dopasowany**, czyli konkretny element wybranej klasy, otrzymany na podstawie danych. Regresja logistyczna dopasowana do danych pasażerów *Titanica* jest więc konkretnym modelem należącym do klasy modeli regresji logistycznej. Ma już określone zmienne wejściowe oraz konkretne wartości współczynników.

Model jest czymś innym od **algorytmu uczenia**. Algorytm uczenia jest procedurą, która na podstawie danych treningowych wybiera lub konstruuje konkretny model. W przypadku modeli parametrycznych, opisanych ustaloną liczbą współczynników (zob. Sekcja 1.9), polega to zazwyczaj na wyznaczeniu wartości parametrów, natomiast w innych przypadkach może obejmować również wybór struktury modelu. Proces prowadzący do otrzymania konkretnego modelu nazywamy jego dopasowaniem, uczeniem albo treningiem. Rezultatem tego procesu jest model dopasowany, który można następnie zastosować do nowych obserwacji.

Nie wszystkie modele w analizie danych opisują zależność między wejściem a z góry określonym wynikiem. Niektóre służą przede wszystkim do odkrywania struktury samych danych, na przykład podziału obserwacji na podobne grupy, wykrywania nietypowych przypadków albo redukcji liczby zmiennych. W każdym przypadku zadaniem modelu pozostaje jednak uchwycenie wybranych regularności w postaci prostszej i bardziej użytecznej niż pierwotny zbiór obserwacji.

1.3. Uczenie nadzorowane i nienadzorowane

Podstawowy podział problemów uczenia wynika ze sposobu sformułowania zadania oraz z roli, jaką pełnią w nim obserwowane zmienne. W **uczeniu nadzorowanym** wyróżniamy zmienne wejściowe oraz zmienną wyjściową, a celem jest opisanie zależności między nimi. Dla każdego badanego obiektu obserwujemy zatem parę

$$(\mathbf{x}_i, y_i),$$

gdzie $\mathbf{x}_i$ jest wektorem cech obiektu, a y_i – odpowiadającym mu wynikiem. Zbiór danych ma postać

$$\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)\}.$$

Taka struktura danych odzwierciedla przyjęty sposób opisu zjawiska: zakładamy, że istnieje wynik, który chcemy wyjaśniać lub przewidywać na podstawie pozostałych zmiennych. Dopiero po tak sformułowanym zadaniu wybieramy klasę modeli i algorytm służący do jej dopasowania.

Celem uczenia nadzorowanego jest uchwycenie zależności między cechami a wynikiem. Otrzymany model można następnie zastosować do nowego obiektu, dla którego znamy $\mathbf{x}$, ale nie znamy jeszcze y. Przykładowo na podstawie danych pacjentów o znanym rozpoznaniu możemy zbudować model szacujący ryzyko choroby u kolejnych pacjentów. Podobnie, dysponując informacjami o pasażerach *Titanica* i ich losach, możemy próbować przewidywać przeżycie na podstawie wieku, płci, klasy biletu i innych cech.

Określenie *nadzorowane* nie oznacza, że ktoś bezpośrednio kontroluje każdy krok działania algorytmu. Nadzór polega na obecności zmiennej wyjściowej w danych treningowych. Dzięki niej wynik zwracany przez model można porównać z wynikiem rzeczywiście zaobserwowanym.

W **uczeniu nienadzorowanym** żadna ze zmiennych nie pełni roli z góry określonego wyniku. Każdy obiekt jest opisany jedynie przez wektor cech $\mathbf{x}_i$, a dane mają postać

$$\mathcal{D} = \{\mathbf{x}_1, \ldots, \mathbf{x}_n\}.$$

Celem analizy jest wówczas opisanie struktury występującej w samych cechach, na przykład podobieństwa między obserwacjami, występowania grup albo głównych kierunków zmienności.

Metody nienadzorowane mogą służyć między innymi do:

- podziału obserwacji na grupy obiektów o podobnych cechach;
- przedstawienia danych za pomocą mniejszej liczby zmiennych;
- wykrywania nietypowych obserwacji;
- opisu zależności i geometrycznej struktury danych.

Przykładowo możemy próbować podzielić pacjentów na grupy o podobnych profilach wyników badań, nie określając wcześniej, jakie grupy mają zostać odnalezione. Możemy również zastąpić dużą liczbę silnie powiązanych pomiarów kilkoma zmiennymi syntetycznymi, które zachowują najważniejszą część informacji zawartej w danych.

Brak znanych odpowiedzi sprawia, że wynik uczenia nienadzorowanego jest zwykle trudniejszy do jednoznacznej oceny. Ten sam zbiór obserwacji może mieć kilka użytecznych opisów struktury, zależnie od celu analizy, przyjętej miary podobieństwa i założeń metody. Podział na uczenie nadzorowane i nienadzorowane dotyczy więc nie tylko użytego algorytmu, lecz przede wszystkim sposobu sformułowania zadania i informacji dostępnych podczas uczenia.

W dalszej części skoncentrujemy się głównie na uczeniu nadzorowanym.

1.4. Regresja i klasyfikacja

W uczeniu nadzorowanym wyróżniamy dwa podstawowe rodzaje zadań: **regresję** i **klasyfikację**. Podział ten wynika przede wszystkim z charakteru zmiennej wyjściowej oraz z rodzaju wyniku, który chcemy otrzymać. Nie zależy natomiast od postaci zmiennych wejściowych – te same cechy mogą zostać wykorzystane zarówno w zadaniu regresji, jak i klasyfikacji.

W **regresji** zmienna wyjściowa ma charakter ilościowy. Jej wartości są liczbami, dla których znaczenie mają wielkość, porządek oraz różnice między wartościami. Zadaniem modelu jest przewidywanie wartości liczbowej:

$$\hat{y} = \hat{f}(\mathbf{x}).$$

Przykładami regresji są przewidywanie ceny mieszkania, czasu trwania hospitalizacji, stężenia substancji we krwi albo wielkości plonu. Wynikiem modelu może być pojedyncza wartość, ale model może również opisywać niepewność predykcji, na przykład za pomocą przedziału predykcji lub rozkładu możliwych wartości.

W **klasyfikacji** zmienna wyjściowa ma charakter jakościowy: określa przynależność obiektu do jednej z ustalonych kategorii, nazywanych **klasami**. Jeżeli możliwe są dwie klasy, mówimy o klasyfikacji binarnej. Przykładem jest rozpoznawanie obecności albo braku choroby. Gdy klas jest więcej, mamy do czynienia z klasyfikacją wieloklasową, na przykład przy rozpoznawaniu gatunku rośliny na podstawie jej cech.

Klasy mogą być oznaczone liczbami, nie nadaje im to jednak charakteru ilościowego. Jeżeli brak choroby oznaczymy przez 0, a jej obecność przez 1, różnica między tymi wartościami nie opisuje wielkości choroby. Liczby pełnią tutaj jedynie funkcję etykiet.

W typowych zadaniach podział na regresję i klasyfikację jest związany z podziałem zmiennych na ciągłe i dyskretne. Ciągłą zmienną wyjściową modelujemy na ogół za pomocą regresji, natomiast jakościowa zmienna wyjściowa, przyjmująca wartości z dyskretnego zbioru klas, prowadzi do zadania klasyfikacji. Dlatego podział ten przedstawia się niekiedy w uproszczonej postaci: regresja dotyczy zmiennych ciągłych, a klasyfikacja – dyskretnych.

Rzeczywista różnica leży jednak nie w ciągłości zmiennej, lecz w jej charakterze. Wartości ilościowej zmiennej wyjściowej są uporządkowane i mają skalę, więc sensowne jest pytanie o przeciętny wynik – o „środek" jego rozkładu – oraz o to, jak daleko predykcja od niego odbiega. Klasy nie mają ani porządku, ani skali: średnia z dwóch gatunków rośliny nie jest żadnym gatunkiem, a pomyłka między klasami nie jest „mała" ani „duża". Dlatego model regresyjny podaje charakterystyki rozkładu wyniku, na przykład wartość przeciętną, a model klasyfikacyjny – prawdopodobieństwa poszczególnych klas.

Z tego powodu utożsamienie zmiennych ciągłych z regresją, a dyskretnych z klasyfikacją nie jest ścisłe. Zmienna dyskretna nie musi być zmienną jakościową. Może być również zmienną ilościową, jeżeli jej wartości mają znaczenie liczbowe. W takim przypadku mamy do czynienia z regresją, mimo że zmienna wyjściowa jest dyskretna.

Przykładem jest liczba wizyt pacjenta w szpitalu w ciągu roku. Zmienna ta przyjmuje wartości $0, 1, 2, ...$, jest więc dyskretna, ale jej wartości pozostają liczbami: pacjent z pięcioma wizytami trafiał do szpitala częściej niż pacjent z dwiema, a różnica między nimi daje się zmierzyć. Naturalnym pytaniem jest tutaj, ilu wizyt można się spodziewać u pacjenta o danych cechach – a nie, do której z kategorii „0", „1", „2" pacjent należy. Jest to więc zadanie regresji, mimo że zmienna wyjściowa jest dyskretna. Istnieją metody regresyjne przystosowane do zmiennych zliczeniowych, na przykład regresja Poissona.

Podział na zmienne ciągłe i dyskretne nie pokrywa się więc dokładnie z podziałem na regresję i klasyfikację. Przewidywanie liczby zdarzeń zwykle zaliczamy do regresji, choć przewidywana zmienna jest dyskretna; przewidywanie rodzaju zdarzenia – do klasyfikacji.

Model klasyfikacyjny często nie zwraca bezpośrednio etykiety klasy, lecz oszacowania prawdopodobieństw poszczególnych klas:

$$\hat{\eta}_k(\mathbf{x}) \approx \mathbb{P}(Y = k \mid \mathbf{X} = \mathbf{x}).$$

Na ich podstawie można następnie przypisać obiekt do jednej z klas, na przykład wybierając klasę o największym oszacowanym prawdopodobieństwie. Rozdzielenie tych dwóch etapów jest ważne: ten sam model może prowadzić do różnych decyzji zależnie od przyjętej reguły decyzyjnej. W diagnostyce medycznej próg wymagany do rozpoznania choroby można na przykład ustalić inaczej niż standardowe 0,5, jeżeli przeoczenie choroby jest znacznie bardziej kosztowne niż wynik fałszywie dodatni.

Regresja i klasyfikacja są rodzajami zadań, a nie rozłącznymi rodzinami algorytmów. Drzewa decyzyjne, metody najbliższych sąsiadów czy sieci neuronowe mogą występować zarówno w wersji regresyjnej, jak i klasyfikacyjnej. O charakterze zadania decyduje zmienna wyjściowa i cel analizy. Z tego powodu regresja logistyczna, mimo swojej nazwy, jest metodą klasyfikacji: opisuje prawdopodobieństwo przynależności do klasy, a nie wartość ilościowej zmiennej wyjściowej.

1.5. Probabilistyczny opis danych

Wróćmy do wcześniejszego spostrzeżenia: obiekty opisane tym samym wektorem cech mogą mieć różne wartości zmiennej odpowiedzi. Model przypisuje im wszystkim jedną predykcję, nie ma więc jednej „prawidłowej odpowiedzi", z którą można by ją zestawić. Zanim powiemy, co znaczy, że model jest dobry, musimy odpowiedzieć na dwa pytania:

1. **Z czym porównujemy predykcję**, skoro pojedynczy zaobserwowany wynik nie jest właściwym punktem odniesienia?
2. **Jak wycenić rozbieżność** między predykcją a tym, co zaobserwowaliśmy?

Pierwszemu poświęcona jest ta sekcja, drugiemu – Sekcja 1.6.

Aby odpowiedzieć na pierwsze pytanie, posłużymy się probabilistycznym opisem danych. Przyjmujemy, że zarówno cechy, jak i wynik są losowe: $\mathbf{X}$ jest wektorem losowym cech, Y – losową zmienną wyjściową, a para $(\mathbf{X}, Y)$ ma pewien **rozkład łączny** P. Próbę opisujemy parami $(\mathbf{X}_1, Y_1), \ldots, (\mathbf{X}_n, Y_n)$, niezależnymi i o tym samym rozkładzie P; zaobserwowane dane $(\mathbf{x}_i, y_i)$ są realizacjami tych par. Rozkład P opisuje populację, z której pochodzą dane: określa prawdopodobieństwa wartości cech i wyniku oraz zależności między nimi. W przyjętym opisie cała informacja o danych jest zawarta w P. Wiedza o znaczeniu zmiennych i kontekście ich pomiaru pozostaje poza tym opisem, o ile nie wprowadzimy jej do niego za pomocą dodatkowych założeń. Rozkład P nie jest nam znany – dysponujemy jedynie obserwacjami pochodzącymi z tego rozkładu.

Warto od razu zaznaczyć, że niezależność kolejnych obserwacji jest **założeniem**, a nie własnością danych. Bywa ono naruszone, na przykład gdy obserwacje są uporządkowane w czasie, pochodzą z sąsiadujących lokalizacji albo dotyczą powtarzanych pomiarów tego samego pacjenta. W dalszym ciągu przyjmujemy je milcząco, wskazując w razie potrzeby konsekwencje jego złamania.

Rozkład P opisujemy za pomocą funkcji prawdopodobieństwa lub gęstości, zależnie od rodzaju zmiennych. Oznaczmy tę funkcję przez $p(\mathbf{x}, y)$, a funkcję opisującą rozkład samych cech – przez $p(\mathbf{x})$. Dla $p(\mathbf{x}) > 0$ zachodzi

$$p(\mathbf{x}, y) = p(\mathbf{x}) \cdot p(y \mid \mathbf{x}), \tag{1.1}$$

gdzie $p(y \mid \mathbf{x})$ jest funkcją prawdopodobieństwa lub gęstością warunkową wyniku przy ustalonych cechach.

> **Przypomnienie: zmienna losowa**
>
> **Intuicja.** Wyobraźmy sobie, że losujemy jeden obiekt z populacji – na przykład pacjenta – i mierzymy na nim pewną wielkość, powiedzmy ciśnienie krwi. Zanim losowanie się odbędzie, nie wiemy, jaki wynik otrzymamy; wiemy jedynie, które wyniki są możliwe i jak często się pojawiają. **Zmienna losowa** to właśnie ten pomiar rozważany *przed* losowaniem: reguła, która każdemu możliwemu wynikowi losowania przypisuje liczbę. Opis tego, jak często pojawiają się poszczególne wartości, nazywamy **rozkładem** zmiennej.
> Losowanie obiektu nie jest jedynym źródłem niepewności. Ciśnienie konkretnego, znanego nam pacjenta również nie jest z góry ustalone: zmienia się w ciągu dnia, zależy od warunków pomiaru, a sam pomiar obarczony jest błędem. Zmienną losową możemy więc rozumieć ogólniej – jako wielkość, której wartości nie znamy przed obserwacją, a rozkład – jako opis tego, które wartości są bardziej, a które mniej prawdopodobne.
> **Zmienna a jej realizacja.** Wielką literą oznaczamy zmienną losową, małą – wartość,

którą przyjęła w konkretnym losowaniu, czyli jej **realizację**. Y to „ciśnienie pacjenta, którego dopiero wylosujemy", y to konkretna liczba odczytana z aparatu. Tak samo $\mathbf{X}$ jest wektorem losowym cech, a $\mathbf{x}$ – ustalonym wektorem liczb. Zapis $\mathbb{P}(Y \le y)$ łączy oba obiekty: pyta o prawdopodobieństwo, że zmienna Y przyjmie wartość nie większą od ustalonej liczby y.

Funkcje zmiennych losowych. Jeżeli Y jest zmienną losową, a g – zwykłą funkcją, to $g(Y)$ również jest zmienną losową: najpierw losujemy obiekt, potem odczytujemy Y, a na końcu obliczamy g. Z tego prostego spostrzeżenia będziemy stale korzystać. Na przykład $f^*(\mathbf{X})$ jest zmienną losową, choć f^* jest ustaloną funkcją, a strata $L(Y, f(\mathbf{X}))$ z sekcji 1.6 jest zmienną losową, bo zależy od wylosowanej pary $(\mathbf{X}, Y)$. Wartość oczekiwana takiej zmiennej jest już liczbą.

i Przypomnienie: rozkłady dyskretne i ciągłe

Rozkład dyskretny. Zmienna Y ma rozkład dyskretny, jeżeli przyjmuje wartości ze zbioru $\mathcal{Y}$ skończonego lub przeliczalnego, zwanego **nośnikiem**. Rozkład opisuje wtedy **funkcja prawdopodobieństwa**

$$p(y) = \mathbb{P}(Y = y), \qquad y \in \mathcal{Y},$$

spełniająca $p(y) > 0$ oraz $\sum_{y \in \mathcal{Y}} p(y) = 1$. Prawdopodobieństwo dowolnego zbioru wartości otrzymujemy poprzez sumowanie: $\mathbb{P}(Y \in A) = \sum_{y \in A} p(y)$.

Rozkład ciągły. Zmienna Y ma rozkład ciągły, jeżeli istnieje funkcja $p \ge 0$, zwana **gęstością**, taka że dla każdego zbioru A

$$\mathbb{P}(Y \in A) = \int_A p(y)\, dy,$$

przy czym $\int_{-\infty}^{\infty} p(y)\, dy = 1$. Biorąc $A = \{y_0\}$, otrzymujemy natychmiast $\mathbb{P}(Y = y_0) = 0$: całka po zbiorze jednopunktowym jest zerem. Pojedyncze wartości nie mają więc dodatnich prawdopodobieństw, choć zmienna jakąś z nich przyjmuje.

Gęstość nie jest prawdopodobieństwem. Wartość $p(y)$ nie musi nawet należeć do przedziału $[0, 1]$ – dla rozkładu jednostajnego na [0; 0,1] gęstość jest wszędzie równa 10. Sens probabilistyczny ma dopiero prawdopodobieństwo przedziału: jeżeli gęstość jest ciągła w punkcie y, to dla małych $h > 0$

$$\mathbb{P}(y \le Y \le y + h) \approx p(y)\, h.$$

Gęstość mierzy więc nie prawdopodobieństwo samej wartości y, lecz jego zagęszczenie w otoczeniu tej wartości – stąd jej nazwa. Gęstości wolno porównywać między sobą, bo mówią, gdzie skupia się większa masa prawdopodobieństwa, ale nie wolno ich czytać jako prawdopodobieństw.

Dystrybuanta. Wspólnym opisem obu przypadków jest **dystrybuanta**

$$F(y) = \mathbb{P}(Y \le y),$$

określona dla każdej zmiennej losowej rzeczywistej. W przypadku dyskretnym jest funkcją schodkową ze skokami w punktach nośnika, w ciągłym – funkcją ciągłą, będącą całką z gęstości.

i Przypomnienie: rozkład łączny, brzegowy i warunkowy

Literą p oznaczamy, tak jak wyżej, funkcję prawdopodobieństwa albo gęstość – zależnie od tego, czy zmienna jest dyskretna, czy ciągła.
Rozkład łączny opisuje parę $(\mathbf{X}, Y)$ traktowaną jako całość: przypisuje prawdopodobieństwa zdarzeniom dotyczącym cech i wyniku naraz. Dla zmiennych dyskretnych $p(\mathbf{x}, y) = \mathbb{P}(\mathbf{X} = \mathbf{x}, Y = y)$; w przypadku ciągłym $p(\mathbf{x}, y)$ jest gęstością, a prawdopodobieństwa otrzymujemy przez całkowanie.
Rozkład brzegowy opisuje same cechy, z pominięciem zmiennej wyjściowej. Jego funkcję prawdopodobieństwa lub gęstość otrzymujemy przez zsumowanie albo scałkowanie $p(\mathbf{x}, y)$ po y:

$$p(\mathbf{x}) = \sum_y p(\mathbf{x}, y) \qquad \text{albo} \qquad p(\mathbf{x}) = \int p(\mathbf{x}, y)\, dy.$$

Rozkład warunkowy opisuje wynik przy ustalonych cechach. Jego funkcję prawdopodobieństwa lub gęstość definiujemy dla $p(\mathbf{x}) > 0$ wzorem

$$p(y \mid \mathbf{x}) = \frac{p(\mathbf{x}, y)}{p(\mathbf{x})}.$$

Przy ustalonym $\mathbf{x}$ funkcja ta jest nieujemna i sumuje się (całkuje) po y do jedynki, opisuje więc rozkład prawdopodobieństwa zmiennej Y. Dla zmiennych dyskretnych $p(y \mid \mathbf{x})$ jest zwykłym prawdopodobieństwem warunkowym $\mathbb{P}(Y = y \mid \mathbf{X} = \mathbf{x})$; gdy cechy są ciągłe, zdarzenie $\{\mathbf{X} = \mathbf{x}\}$ ma prawdopodobieństwo zero i definicja wymaga ostrożności – wracamy do tego na końcu sekcji.
Skąd bierze się wzór (1.1). Wystarczy pomnożyć ostatnią równość przez $p(\mathbf{x})$. Wzór ten nie jest więc twierdzeniem o strukturze rozkładu, lecz przekształceniem podanego wzoru na funkcję prawdopodobieństwa lub gęstość warunkową. Cała jego treść leży w interpretacji obu czynników i w tym, że zależność, która nas interesuje, mieści się wyłącznie w drugim z nich.
Przypadek mieszany. W klasyfikacji cechy są często ciągłe, a wynik dyskretny. Funkcja $p(\mathbf{x}, y)$ jest wtedy gęstością względem $\mathbf{x}$ i prawdopodobieństwem względem y:

$$\mathbb{P}(\mathbf{X} \in A,\, Y = y) = \int_A p(\mathbf{x}, y)\, d\mathbf{x}.$$

Rozkład brzegowy cech dostajemy, sumując po y: $p(\mathbf{x}) = \sum_y p(\mathbf{x}, y)$, a rozkład wyniku – całkując po $\mathbf{x}$: $\mathbb{P}(Y = y) = \int p(\mathbf{x}, y)\, d\mathbf{x}$. Taki rozkład najłatwiej zadać w kolejności odwrotnej niż w (1.1): przez prawdopodobieństwa klas $\pi_y = \mathbb{P}(Y = y)$ i gęstości cech w obrębie klas $p(\mathbf{x} \mid Y = y)$,

$$p(\mathbf{x}, y) = \pi_y\, p(\mathbf{x} \mid Y = y).$$

Podstawienie tego iloczynu do definicji rozkładu warunkowego daje wzór Bayesa

$$p(y \mid \mathbf{x}) = \frac{\pi_y\, p(\mathbf{x} \mid Y = y)}{\sum_{y'} \pi_{y'}\, p(\mathbf{x} \mid Y = y')}. \tag{1.2}$$

Pierwszy czynnik, $p(\mathbf{x})$, opisuje **rozkład brzegowy** cech. Mówi, gdzie w przestrzeni cech znajdują się obiekty i jak gęsto. Jeśli na przykład obiektami są pacjenci, a cechami ich wiek i wyniki badań, rozkład ten opisuje, jaki jest typowy wiek pacjenta, jakie kombinacje wyników badań występują często, a jakie prawie wcale. O zależności między cechami a wynikiem nie mówi natomiast nic.

Drugi czynnik, $p(y \mid \mathbf{x})$, opisuje **rozkład warunkowy** zmiennej Y przy ustalonych cechach, oznaczany

$$Y \mid \mathbf{X} = \mathbf{x}.$$

Określa on, jakie wartości zmiennej Y mogą wystąpić wśród obiektów o cechach $\mathbf{x}$ i z jakim prawdopodobieństwem; dla zmiennej ciągłej opisuje go gęstość warunkowa, dla dyskretnej – prawdopodobieństwa poszczególnych wartości. To właśnie w nim zawarta jest cała zależność wyniku od cech, i to on odpowiada na pierwsze z pytań postawionych na początku sekcji: predykcję porównujemy nie z jedną wartością, lecz z całym rozkładem możliwych wyników.

W samym rozkładzie warunkowym możemy wyróżnić część **systematyczną**, związaną z obserwowanymi cechami, oraz **szum**, czyli zmienność wyniku niewyjaśnioną przez te cechy. Słowa *szum* używamy w szerokim znaczeniu. Może on wynikać z błędów pomiarowych, z wpływu czynników nieuwzględnionych w danych albo z rzeczywistej losowości badanego zjawiska. Nie oznacza więc, że dane zostały zebrane nieprawidłowo.

> **i** Po co nam ten podział
>
> Modelując zależność, interesujemy się drugim czynnikiem. Optymalna predykcja w punkcie $\mathbf{x}$ – w sensie, który sprecyzujemy w sekcji 1.6 – zależy wyłącznie od rozkładu warunkowego – rozkład brzegowy cech nie wpływa na nią w żaden sposób. Wpływa natomiast na to, jak bardzo opłaca się być dokładnym w danym obszarze przestrzeni cech, bo obszary rzadko odwiedzane wnoszą do przeciętnej straty niewiele. Do tej obserwacji wracamy w rozdziale 2.
> Wzdłuż tego samego podziału przebiega też granica między dwiema rodzinami metod. Modele **dyskryminacyjne**, takie jak regresja logistyczna, opisują wyłącznie $p(y \mid \mathbf{x})$ i o rozkładzie cech nie mówią nic. Modele **generatywne**, takie jak analiza dyskryminacyjna czy naiwny klasyfikator bayesowski, opisują cały rozkład łączny, docierając do zależności okrężną drogą – przez rozkłady cech wewnątrz klas. Różnicę tę omówimy szczegółowo w rozdziale 11.

1.5.1. Regresja

W przypadku regresji część systematyczną opisujemy za pomocą warunkowej wartości oczekiwanej, nazywanej **funkcją regresji**:

$$f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]. \tag{1.3}$$

Oznacza ona przeciętną wartość zmiennej wyjściowej wśród obiektów o cechach $\mathbf{x}$. Gwiazdka oznacza predyktor optymalny – w jakim sensie, wyjaśniamy niżej – a więc wielkość teoretyczną, opisującą badaną populację, a nie funkcję wyznaczoną z danych; symbolu f bez gwiazdki będziemy używać dla dowolnego predyktora, a $\hat{f}$ – dla predyktora dopasowanego do konkretnego zbioru obserwacji.

> **i** Przypomnienie: warunkowa wartość oczekiwana
>
> Wartość oczekiwana rozkładu warunkowego $Y \mid \mathbf{X} = \mathbf{x}$ to średnia wartość Y wśród obiektów o cechach $\mathbf{x}$:

$$\mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}] = \sum_y y\, p(y \mid \mathbf{x}) \qquad \text{albo} \qquad \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}] = \int y\, p(y \mid \mathbf{x})\, dy.$$

Jest to **liczba** zależna od $\mathbf{x}$, a więc funkcja zmiennej $\mathbf{x}$ – i właśnie tę funkcję nazywamy funkcją regresji.

Dwa zapisy, dwa różne obiekty. Podstawiając w miejsce $\mathbf{x}$ losowy wektor $\mathbf{X}$, otrzymujemy $\mathbb{E}[Y \mid \mathbf{X}] = f^*(\mathbf{X})$, czyli **zmienną losową**: jej wartość zmienia się wraz z wylosowanym obiektem. Wzór (1.3) mówi o liczbie przypisanej ustalonym cechom, natomiast warunek $\mathbb{E}[\varepsilon \mid \mathbf{X}] = 0$ we wzorze (1.4) jest równością zmiennych losowych – znaczy tyle, że dla **każdego** $\mathbf{x}$ zachodzi $\mathbb{E}[\varepsilon \mid \mathbf{X} = \mathbf{x}] = 0$.

Prawo iterowanej wartości oczekiwanej. Uśrednienie funkcji $f^*(\mathbf{X})$ po rozkładzie cech odtwarza zwykłą wartość oczekiwaną:

$$\mathbb{E}\big[\mathbb{E}[Y \mid \mathbf{X}]\big] = \mathbb{E}[Y].$$

Średnia warunkowych średnich jest więc średnią globalną – z wagami danymi przez rozkład brzegowy cech. Ta tożsamość pozwala rozbijać rachunki na dwa kroki: najpierw uśredniamy przy ustalonych cechach, potem po cechach. Będziemy z niej korzystać przy rachunkach dotyczących ryzyka.

Wybór warunkowej wartości oczekiwanej nie jest przypadkowy. W rozdziale 2 pokażemy, że funkcja f^* jest **najlepszym możliwym** predyktorem, jeżeli błędy wyceniamy stratą kwadratową. Przy innej stracie wyróżniona byłaby inna charakterystyka rozkładu warunkowego, na przykład mediana. To, jaką charakterystykę rozkładu warto przewidywać, zależy więc od sposobu wyceniania błędów.

Zdefiniujmy odchylenie wyniku od jego średniej warunkowej jako $\varepsilon = Y - f^*(\mathbf{X})$. Wówczas, przy ustalonych cechach, jego wartość oczekiwana wynosi

$$\mathbb{E}[\varepsilon \mid \mathbf{X}] = \mathbb{E}[Y \mid \mathbf{X}] - f^*(\mathbf{X}) = 0.$$

Zmienną wyjściową możemy więc przedstawić w postaci addytywnej

$$Y = f^*(\mathbf{X}) + \varepsilon, \qquad \mathbb{E}[\varepsilon \mid \mathbf{X}] = 0. \tag{1.4}$$

Składnik ε opisuje odchylenie obserwowanego wyniku od części systematycznej. Dwa obiekty o takich samych wartościach cech otrzymują tę samą wartość $f^*(\mathbf{x})$, ale ich rzeczywiste wyniki mogą się różnić ze względu na różne realizacje ε. Warunek $\mathbb{E}[\varepsilon \mid \mathbf{X}] = 0$ wynika z definicji ε i oznacza, że odchylenia przy ustalonych cechach przeciętnie się znoszą.

Przykładowo model może opisywać zależność między czasem hospitalizacji a wiekiem pacjenta, rozpoznaniem i wynikami badań. Pacjenci o takich samych wartościach zarejestrowanych cech nie muszą jednak przebywać w szpitalu dokładnie tyle samo dni. Na czas hospitalizacji wpływają również czynniki, których model nie uwzględnia, oraz zdarzenia, których nie da się przewidzieć na podstawie dostępnych informacji.

Funkcja f^* opisuje zależność występującą w badanej populacji, ale zazwyczaj nie jest znana. Na podstawie danych treningowych wyznaczamy jej oszacowanie $\hat{f}$, a predykcja dla obiektu o cechach $\mathbf{x}$ ma postać

$$\hat{y} = \hat{f}(\mathbf{x}).$$

1.5.2. Klasyfikacja

W klasyfikacji podział na zależność systematyczną i szum ma ten sam sens, ale nie da się go zapisać addytywnie. Suma etykiety klasy i odchylenia nie byłaby etykietą klasy, więc rozkład (1.4) traci tu zastosowanie. Opisujemy zatem rozkład warunkowy wprost.

Jeżeli zmienna wyjściowa przyjmuje wartości w zbiorze klas $\{1, \dots, K\}$, część systematyczną opisują prawdopodobieństwa warunkowe

$$\eta_k(\mathbf{x}) = \mathbb{P}(Y = k \mid \mathbf{X} = \mathbf{x}), \qquad k = 1, \dots, K, \tag{1.5}$$

spełniające dla każdego $\mathbf{x}$ warunek $\sum_{k=1}^{K} \eta_k(\mathbf{x}) = 1$. W klasyfikacji binarnej wystarczy jedna funkcja $\eta(\mathbf{x}) = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$, a rozkład wyniku przy ustalonych cechach zapisujemy jako

$$Y \mid \mathbf{X} = \mathbf{x} \sim \text{Bernoulli}\,(\eta(\mathbf{x})).$$

Funkcja η pełni więc wobec klasyfikacji tę samą rolę, co f^* wobec regresji: opisuje systematyczną zależność wyniku od cech. Aby na podstawie prawdopodobieństw wybrać przewidywaną klasę, potrzebujemy reguły decyzyjnej. W przypadku binarnym możemy na przykład wybierać klasę 1, gdy $\eta(\mathbf{x}) > 1/2$, a klasę 0 w przeciwnym razie. Jeżeli jednak $0 < \eta(\mathbf{x}) < 1$, obie klasy są możliwe przy tych samych cechach, więc nawet dokładna znajomość $\eta(\mathbf{x})$ nie gwarantuje bezbłędnej klasyfikacji. W praktyce dochodzi do tego drugie źródło błędów: nie znamy $\eta(\mathbf{x})$ i musimy ją oszacować na podstawie danych.

> **i** Jeden opis, dwie charakterystyki
>
> Warto zauważyć, jak niewiele różni oba przypadki. Wspólnym punktem wyjścia jest rozkład warunkowy $Y \mid \mathbf{X} = \mathbf{x}$; różnica polega wyłącznie na tym, co z niego odczytujemy.
> W problemie regresji wygodną charakterystyką jest odpowiednio rozumiany środek rozkładu – na przykład średnia warunkowa $f^*(\mathbf{x})$ lub mediana warunkowa. W problemie klasyfikacji mówienie o „środku" nie ma sensu – klasy nie mają porządku ani skali – więc podajemy cały rozkład, czyli wektor $(\eta_1(\mathbf{x}), \dots, \eta_K(\mathbf{x}))$.
> Dla zmiennej binarnej z klasami zakodowanymi jako 0 i 1 oba opisy pokrywają się: $\mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}] = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$, a więc $f^* = \eta$. Przy innym kodowaniu dwiema różnymi liczbami średnia warunkowa nadal jednoznacznie wyznacza prawdopodobieństwa klas, ale nie jest już wprost jednym z nich.

W praktyce funkcje η_k, podobnie jak f^*, nie są znane i zastępujemy je oszacowaniami $\hat{\eta}_k$ wyznaczonymi z danych. W obu zadaniach mamy więc do czynienia z tym samym układem: nieznaną zależnością występującą w populacji, jej oszacowaniem zbudowanym na skończonej próbie oraz zmiennością wyniku, która pozostaje nawet po ustaleniu wszystkich dostępnych cech.

> **i** Dla Czytelników z przygotowaniem z teorii miary
>
> Zapis wprowadzony w tej sekcji jest uproszczony w kilku miejscach.
> **Zmienna losowa.** Formalnie zmienna losowa to funkcja mierzalna $Y \colon \Omega \to \mathbb{R}$ określona na przestrzeni probabilistycznej $(\Omega, \mathcal{F}, \mathbb{P})$; wektor losowy $\mathbf{X}$ przyjmuje wartości w $\mathbb{R}^p$. Elementy Ω odpowiadają wynikom losowania, a rozkład zmiennej Y to miara $\mathbb{P} \circ Y^{-1}$ na $\mathbb{R}$. W całej książce przestrzeń Ω pozostaje w tle: wszystkie rozważane wielkości zależą od niej wyłącznie przez łączny rozkład rozważanych zmiennych.
> **Rozkład warunkowy.** Gdy zmienna $\mathbf{X}$ ma rozkład ciągły, zdarzenie $\{\mathbf{X} = \mathbf{x}\}$ ma praw-

dopodobieństwo zero i rozkładu $Y \mid \mathbf{X} = \mathbf{x}$ nie można zdefiniować wzorem $\mathbb{P}(\cdot \mid A) = \mathbb{P}(\cdot \cap A)/\mathbb{P}(A)$. Właściwą konstrukcją jest regularny rozkład warunkowy, który dla zmiennych o wartościach w $\mathbb{R}^p$ zawsze istnieje, ale jest wyznaczony jednoznacznie jedynie **z dokładnością do zbioru miary zero** względem rozkładu $\mathbf{X}$. To samo dotyczy funkcji f^* oraz η_k: ściśle biorąc nie są one funkcjami, lecz klasami równoważności funkcji. Konsekwentnie, wszystkie stwierdzenia postaci „dla każdego $\mathbf{x}$" należy w dalszym ciągu czytać jako „dla prawie każdego $\mathbf{x}$".

Symbol p. We wzorze (1.1) litera p oznacza gęstość względem miary, która nie jest ta sama dla obu zmiennych: dla cech ciągłych jest to miara Lebesgue'a, dla jakościowej zmiennej wyjściowej – miara licząca. Formalnie chodzi o gęstość rozkładu łącznego względem miary produktowej. Zapis $p(\cdot)$ jest więc wygodnym skrótem obejmującym gęstości i prawdopodobieństwa punktowe naraz; stosujemy go w całej książce.

Dlaczego pomijamy te zastrzeżenia. Wielkości, którymi będziemy oceniać predyktory (Sekcja 1.6), są wartościami oczekiwanymi, czyli całkami. Dwie wersje funkcji f^* różniące się na zbiorze miary zero dają więc identyczne wartości tych wielkości. Obiekt niejednoznaczny nigdy nie występuje samodzielnie – zawsze pod znakiem wartości oczekiwanej, która tej niejednoznaczności nie widzi.

Ścisłe ujęcie znajdzie Czytelnik w monografii Devroye i in. (1996) dla klasyfikacji oraz Györfi i in. (2002) dla regresji nieparametrycznej.

Odpowiedzieliśmy w ten sposób na pierwsze z pytań postawionych na początku sekcji. Wiemy już, z czym porównujemy predykcję: z rozkładem warunkowym $Y \mid \mathbf{X} = \mathbf{x}$, którego część systematyczną opisuje f^* albo η_k, a resztę stanowi szum.

1.6. Jak mierzymy jakość predykcji

Wróćmy do drugiego z pytań postawionych w sekcji 1.5: co znaczy, że predykcja jest bliska rzeczywistemu wynikowi? Odpowiedź wymaga określenia kosztu błędu danej wielkości. Koszt ten zależy od celu i kontekstu zastosowania modelu; nie wynika z samego rozkładu danych.

Potrzebne będą dwa pojęcia. Pierwsze wycenia pojedynczy błąd, drugie uśrednia ten koszt po całej populacji.

Funkcją straty nazywamy funkcję $L(y, \hat{y}) \geq 0$ określającą koszt predykcji $\hat{y}$, gdy rzeczywistą wartością okazało się y. Naturalnie zakładamy $L(y, y) = 0$: trafna predykcja nie kosztuje nic.

W regresji standardowym wyborem jest **strata kwadratowa**

$$L(y, \hat{y}) = (y - \hat{y})^2, \tag{1.6}$$

karząca duże pomyłki nieproporcjonalnie mocniej niż małe: jeden błąd o wartości 10 kosztuje tyle, co sto błędów o wartości 1. W klasyfikacji najprostszą stratą jest **strata 0–1**

$$L(y, \hat{y}) = \mathbb{1}(y \neq \hat{y}), \tag{1.7}$$

wyceniająca każdą pomyłkę na jednostkę, niezależnie od tego, jakich klas dotyczy. Oba wybory są domyślne, ale nie są jedyne możliwe ani zawsze właściwe – do konsekwencji zmiany straty wrócimy w rozdziale 2.

i Przypomnienie: funkcja wskaźnikowa

Symbol $\mathbb{1}(A)$ oznacza **funkcję wskaźnikową** warunku A:

$$\mathbb{1}(A) = \begin{cases} 1, & \text{gdy warunek } A \text{ jest spełniony,} \\ 0, & \text{w przeciwnym razie.} \end{cases}$$

We wzorze (1.7) warunkiem jest $y \neq \hat{y}$. Strata wynosi więc 1, gdy przewidywana klasa różni się od rzeczywistej, oraz 0, gdy klasy są zgodne.

Strata mówi o pojedynczej obserwacji. Interesuje nas natomiast zachowanie modelu na całej populacji, z której pochodzą dane.

Definicja 1.1 (Ryzyko)**. Ryzykiem** predyktora f nazywamy oczekiwaną stratę

$$R(f) = \mathbb{E}[L(Y, f(\mathbf{X}))], \tag{1.8}$$

gdzie wartość oczekiwaną liczymy względem łącznego rozkładu pary $(\mathbf{X}, Y)$.

Definicja 1.1 jest wspólna dla regresji i klasyfikacji – różni je wyłącznie podstawiona strata. Dla straty kwadratowej ryzyko jest **błędem średniokwadratowym**

$$R(f) = \mathbb{E}[(Y - f(\mathbf{X}))^2],$$

a dla straty 0–1, ponieważ wartość oczekiwana wskaźnika jest prawdopodobieństwem zdarzenia – **prawdopodobieństwem błędnej klasyfikacji**:

$$R(f) = \mathbb{E}[\mathbb{1}(Y \neq f(\mathbf{X}))] = \mathbb{P}(f(\mathbf{X}) \neq Y).$$

Rachunek jest w obu przypadkach ten sam; zmienia się tylko interpretacja wyniku. Dwie wielkości, które w kursach statystyki wprowadza się zwykle osobno i różnymi wzorami, okazują się jednym pojęciem z dwoma różnymi podstawieniami.

! Ryzyko a błąd na danych treningowych

Wartość oczekiwana we wzorze (1.8) jest liczona względem rozkładu całej populacji, a nie względem zbioru obserwacji, którym dysponujemy. Wielkość, którą faktycznie umiemy obliczyć, to **ryzyko empiryczne**

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^{n} L(y_i, f(\mathbf{x}_i)). \tag{1.9}$$

Są to dwie różne rzeczy. Na $R(f)$ nam zależy, ale nie umiemy jej obliczyć, bo nie znamy rozkładu populacji. $\widehat{R}_n(f)$ umiemy obliczyć, lecz jeżeli te same dane posłużyły do dopasowania modelu, jest ona systematycznie zaniżona: model był dobierany tak, aby na nich wypadać dobrze. Dla predyktora ustalonego niezależnie od danych średnia ta byłaby nieobciążonym oszacowaniem ryzyka.
Do rzetelnego szacowania ryzyka wracamy w rozdziale 5.

Ryzyko określa przeciętny koszt błędów predyktora w populacji. Chcemy, by koszt ten był jak najmniejszy, dlatego pytamy: **która funkcja f minimalizuje $R(f)$?** Zauważmy, że pytanie to

nie dotyczy żadnego konkretnego algorytmu ani klasy modeli – minimalizujemy po **wszystkich** funkcjach. Odpowiedź wyznacza więc granicę osiągalności, do której metody uczenia mogą się jedynie zbliżać.

Okaże się, że odpowiedź zależy wyłącznie od wybranej straty. Przy stracie kwadratowej (1.6) optymalna jest funkcja regresji (1.3). Przy stracie 0–1 (1.7) optymalna jest reguła wskazująca klasę o największym prawdopodobieństwie $\eta_k(\mathbf{x})$. Wyprowadzenie obu wyników, wraz z konsekwencjami dla praktyki, jest treścią rozdziału 2.

1.6.1. Błąd redukowalny i nieredukowalny

Ryzyko pozwala rozdzielić dwa źródła błędów predykcji. Rozróżnienie to dotyczy zarówno regresji, jak i klasyfikacji.

W obu zadaniach istnieje najmniejsze ryzyko osiągalne przy ustalonych cechach i wybranej funkcji straty. Nazywamy je **błędem nieredukowalnym**. W regresji ze stratą kwadratową wynika ono ze zmienności wyników wokół średniej warunkowej; w klasyfikacji ze stratą 0–1 – z możliwości występowania różnych klas przy tych samych cechach. Może być dodatnie nawet wtedy, gdy dokładnie znamy rozkład danych i stosujemy optymalną regułę predykcji.

Błąd redukowalny to nadwyżka ryzyka naszego predyktora ponad to minimum. Może wynikać z ograniczeń wybranej klasy modeli lub z niedokładnego dopasowania na podstawie skończonej próby. Możemy go zmniejszać przez wybór odpowiedniejszej metody, lepsze dopasowanie lub zwiększenie liczby obserwacji, przy zachowaniu tego samego zestawu cech.

Rozróżnienie to pozwala ocenić, jaka część ryzyka może zostać zmniejszona przez doskonalenie predyktora przy dostępnych cechach.

> **i** Nieredukowalny – ale względem czego
>
> Przymiotnik „nieredukowalny” odnosi się do **ustalonego zestawu cech**, a nie do zjawiska w ogóle. Zmienność Y przy ustalonym $\mathbf{X}$ może wynikać z wpływu czynników, których nie zmierzyliśmy. Dodanie cechy dostarczającej nowej informacji o wyniku może zmniejszyć błąd dotąd nieredukowalny: część zmienności niewyjaśnionej przez dotychczasowe cechy staje się możliwa do przewidzenia.
> Praktyczna konsekwencja: czego nie da się poprawić modelowaniem, często daje się poprawić pomiarem.

W rozdziale 2 wyznaczymy optymalne reguły predykcji dla regresji i klasyfikacji, a dla każdej z nich także konkretną postać obu składników. Przy stracie kwadratowej (Sekcja 2.3.3) błąd redukowalny będzie średnim kwadratem różnicy między predyktorem a funkcją regresji, a nieredukowalny – średnią wariancją warunkową wyniku. Przy stracie 0–1 błąd nieredukowalny okaże się ryzykiem najlepszego możliwego klasyfikatora, tzw. błędem bayesowskim, a redukowalny – średnim prawdopodobieństwem trafienia utraconym przez wybór gorszej klasy.

1.7. Dwa cele modelowania: predykcja i wnioskowanie

Opis zależności między cechami a wynikiem może służyć różnym celom. Możemy wykorzystywać model do przewidywania wyników dla nowych obiektów albo do szacowania określonych charakterystyk badanej populacji. Cele te nazywamy odpowiednio **predykcją** i **wnioskowaniem**. Mogą one korzystać z tego samego modelu, ale wymagają różnych kryteriów oceny.

W szerokim znaczeniu wnioskowanie statystyczne obejmuje wykorzystanie danych z próby do formułowania wniosków o populacji, w tym również uczenie predyktora. W tej sekcji używamy tego terminu w węższym znaczeniu: szacowania i badania określonych charakterystyk populacji wraz z oceną niepewności.

Rozważmy zbiór danych zawierający ceny sprzedaży mieszkań oraz ich cechy, takie jak metraż, lokalizacja i liczba pokoi. Na podstawie tych danych możemy szukać odpowiedzi na dwa różne pytania. Pytanie predykcyjne brzmi: „Jaką cenę przewidujemy dla mieszkania o powierzchni 60 m^2 w danej lokalizacji?". Pytanie dotyczące wnioskowania może brzmieć: „O ile różni się przeciętna cena mieszkań o powierzchni 60 m^2 od przeciętnej ceny mieszkań o powierzchni 50 m^2 w tej samej lokalizacji?". W pierwszym przypadku wynikiem jest przewidywana cena konkretnego mieszkania, w drugim – oszacowanie różnicy między średnimi cenami dwóch grup mieszkań w populacji, wraz z oceną niepewności tego oszacowania. Sam fakt, że model zwraca przewidywania, nie przesądza więc o celu analizy: różnica dwóch przewidywanych średnich może służyć oszacowaniu interesującej nas zależności w populacji.

O sukcesie predykcyjnym decyduje **generalizacja**, czyli zdolność modelu do skutecznego przewidywania wyników dla nowych przypadków z populacji, do której chcemy go stosować. Dobre dopasowanie do danych uczących samo w sobie jej nie zapewnia. Jakość generalizacji szacujemy na danych niewykorzystanych do dopasowania modelu, na przykład na zbiorze walidacyjnym. Wynik na takim zbiorze jest oszacowaniem jakości w danej populacji, a jego wiarygodność zależy od sposobu zebrania i wykorzystania danych. Do zasad tej oceny wrócimy w rozdziale 5.

Miarę jakości predykcyjnej dobieramy do zadania. Może nią być średnia strata, jak przy ocenie błędu średniokwadratowego, ale stosuje się też miary, które nie są średnią strat liczonych osobno dla każdej obserwacji. Na przykład w klasyfikacji binarnej miara ROC AUC ocenia, na ile model przypisuje wyższe wyniki przypadkom klasy dodatniej niż przypadkom klasy ujemnej. Niezależnie od wyboru miary pytamy o jakość przewidywania na nowych danych.

We wnioskowaniu oceniamy dokładność oszacowania wybranej wielkości oraz wiarygodność towarzyszącej mu oceny niepewności. Możemy w tym celu badać parametry modelu lub charakterystyki wyznaczone z jego odpowiedzi, takie jak różnica średnich cen. Interpretacja tych wielkości wymaga uzasadnienia założeń, na których opiera się zastosowana procedura.

Dobra jakość predykcji nie gwarantuje jednak dokładnego oszacowania każdej interesującej nas zależności. Załóżmy, że w danych o mieszkaniach większemu metrażowi niemal zawsze towarzyszy większa liczba pokoi. Model może dobrze przewidywać ceny kolejnych mieszkań, w których te dwie cechy są powiązane w podobny sposób. Trudniej natomiast ustalić, jak średnia cena wiąże się z metrażem przy ustalonej liczbie pokoi: w danych jest niewiele mieszkań, które pozwalają na takie porównanie. Różne modele mogą więc podobnie przewidywać ceny typowych mieszkań, a jednocześnie wskazywać wyraźnie różne zależności ceny od metrażu przy ustalonej liczbie pokoi. Sam mały błąd predykcji nie rozstrzyga, które oszacowanie tej zależności jest trafne.

Warto przy tym odróżnić **precyzję oszacowania** od jego **dokładności**. Precyzja dotyczy rozrzutu oszacowań, które otrzymywalibyśmy, powtarzając badanie na próbach tej samej wielkości, dobieranych w ten sam sposób, i stosując tę samą metodę. Im mniejszy ten rozrzut, tym większa precyzja. Dokładność dotyczy bliskości oszacowań do rzeczywistej wartości szacowanej wielkości. Oszacowania mogą być precyzyjne, a mimo to systematycznie odbiegać od tej wartości. Na przykład duża próba mieszkań wyłącznie z rynku pierwotnego może pozwolić precyzyjnie oszacować średnią cenę na tym rynku, ale użycie tej średniej jako oszacowania średniej ceny wszystkich mieszkań może prowadzić do systematycznego błędu. Sam wąski przedział ufności nie gwarantuje więc wiarygodnego wnioskowania: jego uzasadnienie zależy od założeń metody i sposobu doboru próby.

Interpretacja wyników wymaga uwzględnienia założeń modelu i sposobu zebrania danych. Jeżeli przyjmujemy, że średnia cena mieszkania zależy liniowo od metrażu, to współczynnik przy metrażu opisuje w tym modelu różnicę średnich cen przypadającą na dodatkowy metr kwadratowy, przy ustalonych wartościach pozostałych uwzględnionych cech. Jego znaczenie zależy więc także od tego, jakie cechy włączymy do modelu: porównanie mieszkań o różnym metrażu ogółem jest innym porównaniem niż zestawienie ich w obrębie tej samej lokalizacji. Zarówno przy wnioskowaniu, jak i przy predykcji musimy też określić, do jakiej populacji odnosimy wyniki i co uzasadnia wykorzystanie w tym celu dostępnej próby.

Osobnego rozróżnienia wymagają **zależność statystyczna i przyczynowość**. Jeżeli mieszkania po remoncie mają przeciętnie wyższe ceny, nie oznacza to jeszcze, że zaobserwowana różnica jest skutkiem samego remontu. Obie grupy mogą różnić się także lokalizacją, metrażem czy standardem budynku. Pytanie o skutek remontu dotyczy natomiast porównania ceny tego samego mieszkania w dwóch sytuacjach: gdy przeprowadzimy remont i gdy go nie przeprowadzimy. Dla danego mieszkania obserwujemy tylko jedną z tych sytuacji, więc nie możemy bezpośrednio wyznaczyć jego indywidualnego skutku remontu. Zwykle celem badania jest oszacowanie **przeciętnego skutku remontu w określonej populacji mieszkań**. Wymaga to odpowiedniego sposobu zaplanowania badania lub dodatkowych założeń pozwalających uzasadnić porównanie mieszkań remontowanych i nieremontowanych. Oszacowanie przeciętnego skutku nie oznacza jednak poznania skutku dla każdego mieszkania z osobna. Samo dopasowanie modelu opisującego zależność cen od cech mieszkań nie dostarcza uzasadnienia dla interpretacji przyczynowej.

Niepewność towarzyszy zarówno wnioskowaniu, jak i predykcji, lecz może dotyczyć różnych wielkości. **Przedział ufności dla średniej ceny** mieszkań o ustalonych cechach wyraża niepewność oszacowania tej średniej na podstawie próby. **Przedział predykcji dla ceny pojedynczego mieszkania** musi dodatkowo uwzględniać zróżnicowanie cen mieszkań o tych samych obserwowanych cechach. Możemy więc precyzyjnie oszacować średnią cenę w danej grupie, a mimo to przewidywać cenę konkretnego mieszkania z dużą niepewnością. Zwiększanie liczby obserwacji może poprawiać precyzję oszacowania średniej, ale samo w sobie nie usuwa zmienności cen wokół niej – tej samej, którą wcześniej wiązaliśmy z błędem nieredukowalnym.

Ten sam model może służyć obu celom: oszacowana funkcja średniej ceny pozwala zarówno przewidywać ceny mieszkań, jak i porównywać średnie ceny przy różnych wartościach cech. Każde zastosowanie wymaga jednak oceny według kryteriów właściwych dla danego celu.

1.8. Trening modelu

Wiemy już, jakie zadania może spełniać model i jak oceniać jego predykcje. Pozostaje pytanie, jak na podstawie danych wyznaczyć regułę predykcji $\hat{f}$, która nowym obserwacjom przypisze przewidywaną wartość lub klasę. Chcielibyśmy wyznaczyć predyktor o możliwie małym ryzyku $R(f)$. Nie znamy jednak rozkładu populacji P, względem którego ryzyko jest zdefiniowane. Dysponujemy jedynie zbiorem treningowym $\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)\}$. **Trening modelu** polega na wykorzystaniu tej próby do wyznaczenia reguły, którą będziemy stosować także do nowych obserwacji. Poniżej opiszemy ten proces z perspektywy zadania predykcyjnego.

Najpierw określamy klasę modeli $\mathcal{F}$ (por. Sekcja 1.2), czyli zbiór dopuszczalnych predyktorów. Każda funkcja $f \in \mathcal{F}$ przypisuje wektorowi cech $\mathbf{x}$ przewidywany wynik: w regresji jest to liczba, a w klasyfikacji – etykieta klasy. Wybór $\mathcal{F}$ wyraża założenie o tym, jakie zależności chcemy odtwarzać: możemy dopuścić na przykład tylko zależności liniowe albo również funkcje o bardziej złożonym przebiegu. Klasa zbyt wąska może nie zawierać funkcji, która dobrze opisuje interesującą nas zależność. Samo poszerzanie klasy nie gwarantuje jednak lepszego wyniku uczenia.

Aby porównać dopuszczalne predyktory, potrzebujemy **kryterium dopasowania**. Podstawowym wyborem jest ryzyko empiryczne zdefiniowane wzorem (1.9):

$$\widehat{R}_n(f) = \frac{1}{n}\sum_{i=1}^{n} L(y_i, f(\mathbf{x}_i)).$$

Dla każdego kandydata f obliczamy predykcje na danych treningowych, porównujemy je z zaobserwowanymi wynikami i uśredniamy poniesione straty. Przy stracie kwadratowej otrzymujemy średni kwadrat błędu na próbie, $\frac{1}{n}\sum_{i=1}^{n}(y_i - f(\mathbf{x}_i))^2$. Przy stracie 0–1 otrzymujemy odsetek błędnie sklasyfikowanych obserwacji, $\frac{1}{n}\sum_{i=1}^{n}\mathbb{1}(y_i \neq f(\mathbf{x}_i))$. W obu przypadkach mniejsza wartość oznacza lepsze dopasowanie według wybranego kryterium.

Prowadzi to do **zasady minimalizacji ryzyka empirycznego**:

$$\hat{f} \in \arg\min_{f \in \mathcal{F}} \widehat{R}_n(f). \tag{1.10}$$

Równoważnie możemy zapisać:

$$\hat{f} \in \mathcal{F} \qquad \text{oraz} \qquad \widehat{R}_n(\hat{f}) \leq \widehat{R}_n(f) \quad \text{dla każdego } f \in \mathcal{F}.$$

Wybrany predyktor $\hat{f}$ należy więc do klasy $\mathcal{F}$ i ma ryzyko empiryczne nie większe niż jakikolwiek inny predyktor z tej klasy.

Operator $\arg\min$ wskazuje argumenty, dla których minimalizowane wyrażenie osiąga najmniejszą wartość. Tutaj szukamy funkcji $f \in \mathcal{F}$. Minimum może być osiągane przez więcej niż jedną funkcję; $\hat{f}$ wybieramy spośród nich. Zakładamy tu, że minimum w wybranej klasie jest osiągane. Wzór określa zasadę wyboru modelu, ale nie podaje jeszcze sposobu jego znalezienia. W praktyce procedura obliczeniowa może zwracać jedynie rozwiązanie przybliżone.

Tę procedurę nazywamy algorytmem uczenia (por. Sekcja 1.2). Klasa $\mathcal{F}$ określa, jakie predyktory dopuszczamy, kryterium mówi, jak je porównujemy, a algorytm opisuje, jak na podstawie danych wyznaczamy konkretny model. Ta sama klasa i to samo kryterium mogą być obsługiwane przez różne algorytmy. Mogą one różnić się kosztem obliczeń, a przy dopasowaniu przybliżonym także otrzymanym wynikiem.

Minimalizacja ryzyka empirycznego jest ważnym schematem uczenia, ale nie każda metoda bezpośrednio minimalizuje stratę, którą później oceniamy predykcje. Typowy przykład daje klasyfikacja przebiegająca w dwóch etapach z sekcji 1.4. Model prawdopodobieństw klas dopasowujemy, minimalizując na danych treningowych średnią **straty logarytmicznej**, czyli ujemnego logarytmu prawdopodobieństwa przypisanego zaobserwowanej klasie. Etykiety otrzymane po zastosowaniu reguły decyzyjnej oceniamy natomiast stratą 0–1. Strata 0–1 słabo nadaje się do dopasowania: mała zmiana parametrów zwykle nie zmienia liczby błędów, więc nie wskazuje, w którą stronę poprawiać model. Strata logarytmiczna reaguje na każdą zmianę prawdopodobieństw. Dlaczego jej minimalizacja prowadzi do sensownych prawdopodobieństw, wyjaśnimy w rozdziale 2.

Inne metody w ogóle nie minimalizują jawnego kryterium, tylko konstruują predykcję według ustalonej reguły, choćby na podstawie wyników obserwacji podobnych do przewidywanego przypadku. Dlatego opis metody powinien wskazywać zarówno sposób dopasowania, jak i kryterium oceny otrzymanego modelu.

Małe ryzyko empiryczne świadczy o dopasowaniu do próby, lecz nie zapewnia dobrej generalizacji. Dostatecznie bogata klasa może pozwolić niemal zapamiętać wyniki treningowe, łącznie z przypadkowymi odchyleniami, których nie da się przewidzieć dla nowych obiektów. Takie **nadmierne dopasowanie** może dać bardzo mały błąd treningowy i duży błąd na nowych danych. W uczeniu musimy więc uwzględniać złożoność dopuszczalnych modeli i oceniać ich działanie na danych niewykorzystanych do dopasowania. Do sposobów ograniczania złożoności i oceny generalizacji wrócimy w rozdziałach 4 i 5.

Podobny schemat występuje w uczeniu nienadzorowanym. Dysponujemy wtedy zbiorem $\mathcal{D} = \{\mathbf{x}_1, \ldots, \mathbf{x}_n\}$, bez zmiennej docelowej, więc kryterium nie porównuje predykcji ze znanymi odpowiedziami. Nadal określamy jednak dopuszczalną postać modelu, sposób oceny dopasowania oraz algorytm. W grupowaniu możemy na przykład ustalić liczbę grup i szukać takiego podziału obserwacji oraz takich środków grup, aby suma kwadratów odległości obserwacji od przypisanych im środków była jak najmniejsza. Kryterium wyraża wówczas przyjęte rozumienie dobrej struktury grup, a nie zgodność z etykietami dostarczonymi w danych.

Zarówno w uczeniu nadzorowanym, jak i nienadzorowanym trzeba zatem określić, jaką postać może przyjąć model i jak dane wpływają na jego dopasowanie.

1.9. Metody parametryczne i nieparametryczne

W poprzedniej sekcji punktem wyjścia do uczenia był wybór klasy modeli $\mathcal{F}$. Możemy ustalić postać zależności i na podstawie danych wyznaczyć jedynie pewną liczbę współczynników. Możemy też dopuścić, aby wraz z napływem danych opis zależności stawał się coraz bardziej szczegółowy. Rozróżnienie to prowadzi do **metod parametrycznych** i **nieparametrycznych**. Omówimy je na przykładzie przewidywania wartości liczbowej.

W podejściu parametrycznym przyjmujemy rodzinę funkcji

$$\mathcal{F} = \{f_\theta : \theta \in \Theta\}, \qquad \Theta \subseteq \mathbb{R}^d,$$

gdzie θ jest wektorem parametrów, a jego wymiar d jest ustalony i nie rośnie wraz z liczbą obserwacji n. Przy ustalonym zestawie cech i wybranej rodzinie funkcji trening polega na oszacowaniu θ. Otrzymujemy $\hat{\theta}$, a wraz z nim dopasowany predyktor $\hat{f} = f_{\hat{\theta}}$. Większa próba dostarcza więcej informacji do oszacowania tych samych parametrów.

Prostym przykładem jest **regresja liniowa** z jedną cechą:

$$f_\theta(x) = \beta_0 + \beta_1 x, \qquad \theta = (\beta_0, \beta_1).$$

Jeżeli x oznacza powierzchnię mieszkania, a wynikiem jest jego cena, model przypisuje każdemu dodatkowemu metrowi kwadratowemu taki sam przyrost przewidywanej ceny, równy β_1. Wyraz β_0 ustala położenie prostej; jego wartość dla $x = 0$ nie musi mieć praktycznej interpretacji, jeśli mieszkania o takim metrażu nie należą do zakresu stosowalności modelu. Przy stracie kwadratowej dobieramy oba współczynniki, minimalizując średni kwadrat błędu na danych treningowych. Niezależnie od tego, czy mamy sto, czy dziesięć tysięcy obserwacji, szacujemy dwa współczynniki. Dane zmieniają położenie i nachylenie prostej, ale nie pozwalają jej się zakrzywić.

W podejściu nieparametrycznym nie ograniczamy opisu zależności do rodziny wyznaczonej przez ustaloną, skończoną liczbę parametrów. Złożoność opisu może rosnąć wraz z liczbą obserwacji: dodatkowe dane mogą pozwalać odtwarzać coraz drobniejsze szczegóły zależności. Nie oznacza to,

że model dopasowany do skończonej próby ma nieskończony rozmiar. Jego zapis jest skończony, lecz rozmiar ten nie musi być ograniczony z góry niezależnie od wielkości próby.

Przykładem jest **regresja k najbliższych sąsiadów**. Aby przewidzieć cenę mieszkania o metrażu x, wybieramy k mieszkań z próby treningowej, których metraże są najbliższe x, i uśredniamy ich ceny:

$$\hat{f}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i,$$

gdzie $N_k(x)$ oznacza zbiór indeksów tych obserwacji. Przy jednej cesze bliskość możemy mierzyć odległością $|x_i - x|$. W odróżnieniu od regresji liniowej nie wyznaczamy jednej prostej obowiązującej w całym zakresie metrażu. Dla każdego przewidywanego przypadku korzystamy z odpowiedniego fragmentu próby. Gdy zmienia się x, może zmieniać się również zestaw sąsiadów, a więc i przewidywana cena. Opis dopasowanego modelu obejmuje dane treningowe potrzebne do wyszukiwania sąsiadów, zamiast sprowadzać się do dwóch współczynników. Metodę najbliższych sąsiadów w zadaniu klasyfikacji omówimy w rozdziale 3.

> **i** Nieparametryczny nie znaczy „bez parametrów” ani „bez założeń”
>
> Metoda nieparametryczna może mieć wielkości sterujące jej działaniem, takie jak liczba sąsiadów k. Może też wymagać oszacowania wielu współczynników. O nazwie decyduje brak ograniczenia rodziny modeli do ustalonej, skończenie wymiarowej parametryzacji. Pozostają również założenia o odtwarzanej zależności. Uśrednianie wyników sąsiadów jest użyteczne, gdy funkcja regresji $f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ zmienia się niewiele przy niewielkiej zmianie $\mathbf{x}$ – wtedy wyniki sąsiadów mówią coś o średnim wyniku w punkcie $\mathbf{x}$. Znaczenie ma więc wybór cech, sposobu mierzenia odległości i wielkości sąsiedztwa. Zastąpienie prostej lokalnym uśrednianiem zmienia założenia modelu, ale ich nie usuwa.

W tym miejscu warto rozróżnić **parametry modelu** i **hiperparametry**. Współczynniki β_0 i β_1 są parametrami regresji liniowej: wyznaczamy je podczas dopasowania w ustalonej klasie modeli. Liczba sąsiadów k jest natomiast hiperparametrem metody k-NN: określa sposób konstruowania predykcji. Przy małym k odpowiedź zależy od niewielu bliskich obserwacji, a przy dużym – od średniej w szerszym otoczeniu. Hiperparametry ustalamy dla danego dopasowania, ale możemy je dobierać na podstawie danych, porównując wyniki różnych ustawień na zbiorze walidacyjnym. Do zasad takiego doboru wrócimy w rozdziale 5. Sam fakt, że pewna wielkość została dobrana z użyciem danych, nie przesądza więc, czy nazywamy ją parametrem, czy hiperparametrem; istotna jest jej rola w procedurze.

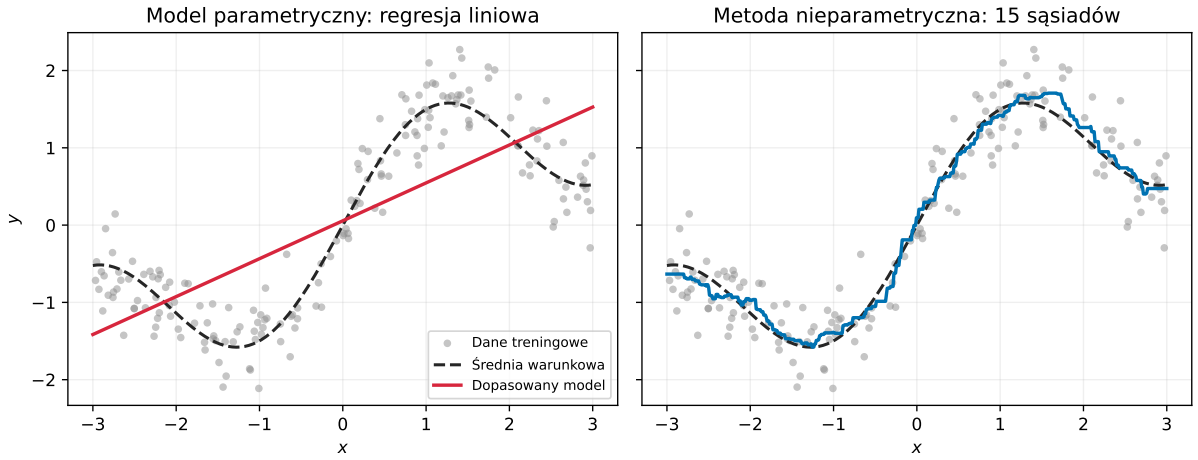
Wybór podejścia ma konsekwencje dla tego, czego możemy nauczyć się z dostępnej próby. Prosta rodzina parametryczna silnie ogranicza dopuszczalne zależności. Jeżeli ograniczenia dobrze odpowiadają problemowi, mogą ułatwić uczenie nawet przy niewielu obserwacjach. Jeśli jednak średnia cena zmienia się z metrażem w sposób wyraźnie zakrzywiony, żadna liczba obserwacji nie sprawi, że pojedyncza prosta wiernie odtworzy ten przebieg. Takie ograniczenie może prowadzić do **niedopasowania**: model jest zbyt mało elastyczny, aby uchwycić istotną zależność.

Metoda nieparametryczna daje większą swobodę odtwarzania kształtu zależności, ale potrzebuje danych tam, gdzie chcemy poznać jej lokalny przebieg. Przy wielu cechach znalezienie dostatecznie licznej grupy rzeczywiście podobnych obiektów może wymagać bardzo dużej próby. Zbyt małe sąsiedztwo sprawia natomiast, że predykcja silnie reaguje na przypadkowe odchylenia pojedynczych wyników, co sprzyja nadmiernemu dopasowaniu. Zbyt duże sąsiedztwo może zacierać istotne zmiany zależności i prowadzić do niedopasowania. Elastycznością trzeba więc sterować

również w metodach nieparametrycznych. Związek między elastycznością, wielkością próby i zmiennością dopasowania rozwiniemy w rozdziale 4.

Podział na metody parametryczne i nieparametryczne nie jest przy tym podziałem na modele liniowe i nieliniowe ani na proste i złożone. Na przykład rodzina funkcji $f_\theta(x) = a\exp(bx)$ ma dwa parametry, choć opisuje zależność nieliniową. Sieć neuronowa o ustalonej architekturze i ustalonej liczbie wag także jest modelem parametrycznym, nawet jeśli tych wag są miliony. Z kolei metoda nieparametryczna z silnym wygładzaniem może odtwarzać jedynie bardzo ogólny przebieg zależności. Sama nazwa podejścia nie przesądza zatem o elastyczności konkretnego dopasowania ani o jakości jego predykcji.

Na Rysunek 1.1 porównujemy oba podejścia na tych samych danych symulowanych. Średnia warunkowa wyniku ma zakrzywiony przebieg, a obserwacje odchylają się od niej wskutek szumu. Do próby dopasowujemy prostą oraz regresję k najbliższych sąsiadów z $k = 15$.



Rysunek 1.1.: Regresja liniowa i lokalne uśrednianie na tej samej próbie. Linia przerywana przedstawia średnią warunkową, znaną dzięki symulacji. Prosta nie odtwarza jej zakrzywienia; metoda najbliższych sąsiadów może za nim podążać, ale jej przebieg zależy także od lokalnych odchyleń w próbie.

Regresja liniowa wybiera jedną prostą jako przybliżenie całej zależności. Lokalne uśrednianie pozwala odtworzyć jej zakrzywienia, ale daje też drobne uskoki: przy zmianie zestawu sąsiadów zmienia się średnia ich wyników. Rysunek ilustruje różnicę w dopuszczalnej postaci predykcji. Nie stanowi ogólnego argumentu za przewagą jednej metody. Gdyby średnia warunkowa była liniowa, ograniczenie do prostych mogłoby być korzystne. W rzeczywistym zadaniu nie znamy tej średniej, a jakość obu metod musimy ocenić na danych niewykorzystanych do ich dopasowania i doboru hiperparametrów.

1.10. Kompromis między interpretowalnością a dokładnością

Porównanie z Rysunek 1.1 można odczytać także z innej strony. Działanie dopasowanej prostej da się streścić jednym zdaniem: każdy dodatkowy metr kwadratowy zwiększa przewidywaną cenę o $\widehat{\beta}_1$. Dla regresji k najbliższych sąsiadów takiego zdania nie ma. Aby opisać, jak przewidywana cena zmienia się z metrażem, trzeba pokazać cały wykres dopasowania albo wskazać dane treningowe, z których powstaje. Większa elastyczność pozwoliła odtworzyć zakrzywienie zależności, ale opis modelu przestał być zwięzły. Napięcie między zdolnością modelu do odtwarzania złożonych zależności a możliwością zrozumienia jego działania nazywa się **kompromisem między interpretowalnością a dokładnością**.

Model nazywamy **interpretowalnym**, jeżeli z jego struktury można odczytać, jak predykcja zależy od cech, bez obliczania jej dla wielu przykładowych obiektów. W regresji liniowej

$$f(\mathbf{x}) = \beta_0 + \beta_1 x_1 + ... + \beta_p x_p$$

predykcje dla dwóch obiektów różniących się jedynie wartością cechy x_j o jednostkę różnią się o β_j, niezależnie od wartości pozostałych cech. Całą zależność opisuje $p + 1$ liczb, a wkład każdej cechy można rozpatrywać osobno. Na tę przejrzystość składa się kilka własności:

- **addytywność** – predykcja jest sumą wkładów poszczególnych cech, więc wpływ jednej cechy nie zależy od wartości pozostałych;
- **prosta postać wkładów** – na przykład liniowa lub monotoniczna;
- **rzadkość** – model korzysta z niewielu cech; współczynniki przy trzech cechach można objąć jednym spojrzeniem, przy trzystu już nie.

Własności te można zachowywać w różnym stopniu. **Model addytywny**

$$f(\mathbf{x}) = \beta_0 + g_1(x_1) + ... + g_p(x_p)$$

dopuszcza nieliniowe funkcje g_j, na przykład zakrzywioną zależność ceny od metrażu, ale zachowuje addytywność: wkład każdej cechy można przedstawić jako osobną krzywą. Addytywność tracimy, gdy dopuszczamy **interakcje**, czyli sytuacje, w których wpływ jednej cechy zależy od wartości innej. Jeżeli dodatkowy metr kwadratowy podnosi cenę bardziej w centrum miasta niż na jego obrzeżach, pytanie „o ile rośnie cena wraz z metrażem?" nie ma jednej odpowiedzi. Odpowiedź zależy od lokalizacji, a przy wielu wzajemnie oddziałujących cechach – od ich kombinacji.

Warto odróżnić interpretację **globalną**, opisującą zachowanie modelu w całym zakresie cech, od **lokalnej**, wyjaśniającej pojedynczą predykcję. Regresja k najbliższych sąsiadów jest lokalnie przejrzysta: przewidywana cena jest średnią cen k wskazanych mieszkań, które możemy obejrzeć. Globalnie nie ma zwięzłego opisu. Przy wielu cechach również lokalne wyjaśnienie staje się mniej oczywiste, bo to, które mieszkania uznajemy za podobne, zależy od wyboru odległości i skal poszczególnych cech.

Popularne metody można schematycznie uporządkować od najbardziej do najmniej interpretowalnych (por. James i in. 2023, rozdz. 2):

1. regresja liniowa z niewielką liczbą niezerowych współczynników, na przykład dopasowana metodą lasso, która część współczynników ustawia dokładnie na zero;
2. regresja liniowa ze wszystkimi cechami;
3. modele addytywne;
4. drzewa decyzyjne, w których predykcję wyznacza ciąg pytań o wartości cech, na przykład „czy metraż przekracza 55 m²?";
5. zespoły wielu drzew oraz sieci neuronowe.

W tej samej kolejności rośnie zwykle elastyczność. Uporządkowanie jest jednak przybliżone: płytkie drzewo z kilkoma pytaniami jest czytelniejsze niż regresja liniowa z setkami cech, a drzewo o tysiącach liści – mniej czytelne niż model addytywny.

Kompromis jest tendencją, a nie prawem. Dokładność, o którą chodzi, to jakość predykcji na nowych danych, a nie dopasowanie do próby treningowej. Bogatsza klasa modeli pozwala dopasować się do próby co najmniej równie dobrze jak uboższa, ale – jak zauważyliśmy w sekcji 1.8

– może przy tym odtwarzać przypadkowe odchylenia. Jeżeli średnia warunkowa jest liniowa, prosta nie traci niczego na niedopasowaniu, a metoda najbliższych sąsiadów płaci za swoją swobodę większą wrażliwością na losowość próby. Prostszy model jest wtedy jednocześnie czytelniejszy i dokładniejszy. Rudin (2019) zwraca uwagę, że w wielu zadaniach na danych tabelarycznych z sensownie określonymi cechami różnica dokładności między dobrze dopasowanymi modelami interpretowalnymi a złożonymi jest niewielka. Wyraźną przewagę elastyczne modele osiągają zwykle wtedy, gdy pojedyncze cechy nie mają osobnego znaczenia, a istotna informacja tkwi w ich złożonych układach – jak w obrazach, dźwięku czy tekście, gdzie pojedynczy piksel lub znak niewiele mówi. Część elastyczności można też przenieść do doboru cech: logarytm ceny lub metraż podniesiony do kwadratu pozwalają modelowi liniowemu opisać zakrzywioną zależność bez utraty addytywności. Czy kompromis rzeczywiście występuje w danym zadaniu, trzeba więc sprawdzić, porównując modele na danych niewykorzystanych do ich dopasowania.

Czytelny nie znaczy trafny. Łatwość odczytania współczynnika nie gwarantuje, że odczytana wartość opisuje interesującą nas zależność. Jak zauważyliśmy w sekcji 1.7, β_j opisuje różnicę średnich przy ustalonych wartościach pozostałych cech *uwzględnionych w modelu*. Dodanie lub usunięcie cechy może zmienić zarówno wartość współczynnika, jak i jego znaczenie. Gdy metraż i liczba pokoi są silnie powiązane, oszacowania obu współczynników bywają niestabilne: niewielka zmiana próby może przesunąć „wpływ" z jednej cechy na drugą, choć predykcje prawie się nie zmieniają. Jeżeli zaś rzeczywista zależność jest zakrzywiona, nachylenie dopasowanej prostej jest jej uśrednionym podsumowaniem, a jego wartość zależy od tego, jakie metraże przeważają w próbie. Wreszcie żaden, nawet najprostszy, model zależności statystycznej nie uzasadnia sam przez się interpretacji przyczynowej. Interpretowalny model daje prostą odpowiedź, ale trzeba osobno uzasadnić, że jest to odpowiedź na zadane pytanie.

Wybór zależy od celu i kontekstu. Jeżeli celem jest predykcja, najważniejsza jest jakość przewidywań i model elastyczny jest uzasadniony wtedy, gdy rzeczywiście przewiduje lepiej. Jeżeli celem jest wnioskowanie, potrzebujemy modelu, którego wielkości odpowiadają na postawione pytanie i pozwalają ocenić niepewność ich oszacowania; przemawia to za prostszymi strukturami, o ile ich założenia są uzasadnione. Poza samym celem analizy liczy się też sposób użycia modelu. Gdy model wspiera decyzje dotyczące ludzi – przyznanie kredytu, kwalifikację do leczenia – często trzeba uzasadnić pojedynczą decyzję, poddać model zewnętrznej kontroli lub spełnić wymagania prawne.

Interpretowalność pomaga również wykryć, że model nauczył się zależności prawdziwej w danych, lecz bezużytecznej lub szkodliwej w zastosowaniu. Caruana i in. (2015) opisują model ryzyka zgonu pacjentów z zapaleniem płuc, który miał wspierać decyzje o hospitalizacji. Jedna z odczytanych z niego reguł głosiła, że astma *obniża* ryzyko. W danych tak właśnie było: pacjentów z astmą od razu kierowano na intensywną terapię, a intensywne leczenie zmniejszało ich śmiertelność. Model zastosowany zgodnie z przeznaczeniem kierowałby jednak do leczenia domowego właśnie tych chorych, którzy potrzebowali najintensywniejszej opieki. Regułę zauważono, bo model był czytelny. Najdokładniejszym modelem w tamtym badaniu okazała się sieć neuronowa, ale uznano ją za zbyt ryzykowną: mogła nauczyć się tej samej zależności, a nie dało się tego sprawdzić. Przykład pokazuje, że dobra ocena na danych pochodzących z tego samego źródła co dane treningowe nie wykrywa modelu dokładnego z niewłaściwych powodów.

Zadania

Zadanie 1.1. Wybierz model spoza analizy danych, na przykład schemat linii metra, mapę pogody w prognozie telewizyjnej albo manekina używanego w testach zderzeniowych. Wskaż jego cel, pominięte szczegóły, zachowane relacje oraz sytuację, w której przestaje być użyteczny (Sekcja 1.1).

Zadanie 1.2. Dla każdej sytuacji rozstrzygnij, czy jest to zadanie uczenia nadzorowanego, czy nienadzorowanego, a w pierwszym przypadku – czy jest to regresja, czy klasyfikacja. Uzasadnij odpowiedź i wskaż przypadki, w których rozstrzygnięcie zależy od celu analizy (Sekcja 1.4).

a) Przewidywanie liczby wizyt pacjenta w przychodni w ciągu roku.
b) Przewidywanie oceny filmu w skali od 1 do 5 gwiazdek.
c) Przewidywanie województwa zamieszkania klienta na podstawie jego historii zakupów.
d) Podział klientów sklepu internetowego na grupy o podobnych zwyczajach zakupowych.
e) Szacowanie prawdopodobieństwa, że kredytobiorca spłaci kredyt.

Zadanie 1.3. Dla każdej sytuacji rozstrzygnij, czy celem jest predykcja, czy wnioskowanie, i zaproponuj, jak oceniać jakość modelu (Sekcja 1.7).

a) Bank chce automatycznie odrzucać wnioski kredytowe o wysokim ryzyku niespłacenia.
b) Ministerstwo chce wiedzieć, o ile zmienią się wyniki egzaminów, jeśli zmniejszy liczebność klas.
c) Sklep chce zaplanować zapasy na przyszły tydzień.

W której z tych sytuacji zaobserwowana w danych zależność nie wystarcza do odpowiedzi na postawione pytanie? Dlaczego?

Zadanie 1.4. Dla regresji liniowej i regresji k najbliższych sąsiadów wskaż osobno klasę modeli, model dopasowany i algorytm uczenia. Który z tych elementów zmienia się po dołączeniu nowych obserwacji do zbioru treningowego, a który pozostaje taki sam?

Zadanie 1.5. Metoda k najbliższych sąsiadów jest nieparametryczna. Wskaż jej hiperparametry i założenia, które przyjmujemy, stosując ją (Sekcja 1.9). Czy regresja wielomianowa, w której stopień wielomianu dobieramy na podstawie danych, jest metodą parametryczną? Uzasadnij odpowiedź.

Zadanie 1.6. Wykaż, że w regresji jednego najbliższego sąsiada ryzyko empiryczne (1.9) obliczone na zbiorze treningowym jest równe zeru, o ile w zbiorze tym nie ma dwóch obserwacji o tych samych cechach. Czy wynika stąd cokolwiek o ryzyku tego predyktora? Co się zmienia, jeżeli w zbiorze występują obserwacje o jednakowych cechach i różnych wynikach?

Zadanie 1.7. Podaj przykład zadania predykcyjnego, w którym dodanie jednej cechy zmniejsza błąd nieredukowalny, oraz przykład, w którym zwiększenie liczby obserwacji nie zmniejsza ryzyka dopasowanego modelu. Wyjaśnij każdy z nich w kategoriach błędu redukowalnego i nieredukowalnego.

Zadanie 1.8. Zmienna $X \in \{1, 2, 3\}$ i binarna zmienna Y mają rozkład łączny

$p(x, y)$	$x = 1$	$x = 2$	$x = 3$
$y = 0$	0,24	0,12	0,06
$y = 1$	0,06	0,28	0,24

a) Wyznacz rozkład brzegowy X oraz $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$.
b) Reguła wskazuje klasę 1, gdy $\eta(x) > 1/2$. Wyznacz jej prawdopodobieństwo błędu. Korzystając z faktu, że reguła ta jest optymalna przy stracie 0–1 (Sekcja 1.6), podaj wartość błędu nieredukowalnego.

c) Oblicz $\mathbb{P}(Y = 1)$ bezpośrednio z tabeli oraz jako $\sum_x \eta(x)\, p(x)$. Jaką tożsamość w ten sposób sprawdzasz?
d) Jaki błąd popełnia klasyfikator, który zawsze wskazuje klasę 1? Który składnik błędu jest tu większy niż dla reguły z punktu b)?

Zadanie 1.9. W klasyfikacji binarnej zakodujmy klasy jako -1 i 1, a przez $\eta(\mathbf{x})$ oznaczmy $\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$. Wyraź $\mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ przez $\eta(\mathbf{x})$ i odwrotnie. Jak wygląda ta zależność przy kodowaniu klas dowolnymi liczbami $a \neq b$?

Zadanie 1.10. Zmienna $X \in \{0, 1, 2\}$ ma rozkład $p(0) = \frac{1}{4}$, $p(1) = \frac{1}{2}$, $p(2) = \frac{1}{4}$. Przy $X = 0$ zawsze $Y = 0$; przy $X = 1$ zmienna Y ma rozkład jednostajny na $\{0, 1, 2, 3\}$; przy $X = 2$ przyjmuje wartości 2 i 3 z jednakowymi prawdopodobieństwami.

a) Zapisz tabelę rozkładu łącznego $p(x, y)$.
b) Wyznacz $f^*(x) = \mathbb{E}[Y \mid X = x]$ oraz możliwe wartości $\varepsilon = Y - f^*(X)$ przy każdym x.
c) Sprawdź, że $\mathbb{E}[\varepsilon \mid X = x] = 0$ dla każdego x, i oblicz $\mathrm{Var}(\varepsilon \mid X = x)$. Czy ε jest niezależny od X? Co to mówi o warunku w (1.4)?
d) Oblicz ryzyko kwadratowe predyktora f^* oraz predyktora stałego $f(x) = \mathbb{E}[Y]$. Różnica tych wartości jest ceną za pominięcie cechy.

Zadanie 1.11. Niech X ma rozkład jednostajny na $[0, 1]$.

a) Wyznacz gęstość zmiennej $U = X^2$ i sprawdź, że przyjmuje ona wartości większe od 1, a nawet dowolnie duże. Dlaczego nie prowadzi to do sprzeczności?
b) Niech $Y \mid X = x \sim \mathcal{N}(x^2, \sigma^2)$. Podaj funkcję regresji f^* i wyznacz $\mathbb{E}[Y]$, korzystając z prawa iterowanej wartości oczekiwanej.
c) Oblicz ryzyko kwadratowe predyktora f^* oraz najlepszego predyktora stałego. Jaka część ryzyka tego drugiego wynika z pominięcia cechy X?

Zadanie 1.12. Urna U1 zawiera 5 kul białych i 2 czarne, urna U2 – 3 białe i 1 czarną. Najpierw losujemy urnę: U1 z prawdopodobieństwem 0,4, U2 z prawdopodobieństwem 0,6. Następnie z wylosowanej urny losujemy jedną kulę. Niech Y oznacza urnę, a X – kolor kuli. Obserwujemy tylko kolor.

a) Rozkład łączny jest tu zadany w postaci $p(y)\, p(x \mid y)$, a nie $p(x)\, p(y \mid x)$ jak w (1.1). Zapisz tabelę $p(x, y)$, a następnie wyznacz rozkład brzegowy $p(x)$ i rozkład warunkowy $p(y \mid x)$. Ile wynosi $\mathbb{P}(Y = \mathrm{U2} \mid X = \text{czarna})$?
b) Zasymuluj N powtórzeń doświadczenia w Pythonie, losując w każdym powtórzeniu najpierw urnę, potem kulę. Oszacuj $p(x, y)$ częstościami w próbie, a $\mathbb{P}(Y = \mathrm{U2} \mid X = \text{czarna})$ – frakcją powtórzeń z urną U2 wśród tych, w których wylosowano kulę czarną. Porównaj wyniki z punktem a) dla $N = 100$, 10^4 i 10^6.
c) Niech $n(x, y)$ oznacza liczbę powtórzeń z wynikiem (x, y), a $n(x)$ – liczbę powtórzeń, w których kula miała kolor x. Wykaż, że

$$n(x) = \sum_y n(x, y), \qquad \frac{n(x, y)}{N} = \frac{n(x, y)}{n(x)} \cdot \frac{n(x)}{N}.$$

Które wzory z sekcji 1.5 przybliżają te tożsamości? Dlaczego oszacowania z punktu b) muszą je spełniać dokładnie, niezależnie od N?

Zadanie 1.13. Niech $Y = X_1 + X_2 + \varepsilon$, gdzie X_1, X_2 i ε są niezależne, $X_1, X_2 \sim \mathcal{N}(0, 1)$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

a) Wyznacz funkcję regresji i błąd nieredukowalny przy stracie kwadratowej, gdy dostępne są obie cechy, oraz gdy dostępna jest tylko X_1.
b) Sprawdź oba wyniki symulacją w Pythonie: wygeneruj dużą próbę i oblicz średnią stratę kwadratową obu funkcji regresji.
c) Powtórz rachunek dla przypadku, w którym X_1 i X_2 mają współczynnik korelacji ρ. Jak błąd nieredukowalny przy samej cesze X_1 zależy od ρ? Zinterpretuj przypadki $\rho = 0$ i $|\rho| \to 1$.

Zadanie 1.14. Wygeneruj $n = 30$ obserwacji z modelu $Y = \sin(2\pi X) + \varepsilon$, gdzie X ma rozkład jednostajny na $[0, 1]$, a $\varepsilon \sim \mathcal{N}(0,\, 0{,}3^2)$. Dopasuj metodą najmniejszych kwadratów wielomiany stopni od 1 do 12 (np. funkcją `numpy.polynomial.Polynomial.fit`). Dla każdego stopnia oblicz ryzyko empiryczne na zbiorze treningowym oraz przybliż ryzyko średnią stratą na nowej próbie liczącej 100 000 obserwacji. Przedstaw obie wielkości na jednym wykresie razem z poziomem błędu nieredukowalnego.

a) Dlaczego ryzyko empiryczne maleje wraz ze stopniem wielomianu?
b) Czy którakolwiek krzywa spada poniżej błędu nieredukowalnego? Wyjaśnij, dlaczego tak jest.
c) Jak zmienia się obraz przy $n = 300$?

2. Predyktory optymalne i błąd nieredukowalny

W sekcji 1.7 wyróżniliśmy dwa cele modelowania: predykcję i wnioskowanie. Ten rozdział dotyczy pierwszego z nich. W regresji predykcja polega na podaniu na podstawie wektora cech $\mathbf{x}$ wartości $\hat{y}$, która ma być bliska nieznanemu y, w klasyfikacji – na wskazaniu klasy. Jak wycenić taką predykcję, ustaliliśmy w sekcji 1.6: funkcją straty, której wartość oczekiwana to ryzyko. Lepsza jest reguła o mniejszym ryzyku, a najlepsza – ta, której ryzyko jest najmniejsze. Tam też postawiliśmy pytanie, na które ten rozdział odpowiada: **która funkcja f minimalizuje $R(f)$?**

Gdy funkcja straty jest ustalona, optymalną regułę można **wyprowadzić**: wystarczy w każdym punkcie $\mathbf{x}$ zminimalizować oczekiwaną stratę. O tym, czego szukamy, decyduje więc strata, nie algorytm. Na przykład w regresji strata kwadratowa prowadzi do średniej warunkowej Y przy danym $\mathbf{X}$, a strata absolutna – do mediany warunkowej. Dla tego samego rozkładu są to na ogół różne funkcje.

Wszystkie wyniki tego rozdziału zakładają, że rozkład łączny $(\mathbf{X}, Y)$ jest znany. Wskazują więc, czego szukamy, ale nie mówią, jak to znaleźć: oszacowanie potrzebnych wielkości z danych to osobne zadanie. Jego ogólny schemat opisaliśmy w sekcji 1.8, a konkretnym metodom poświęcona jest dalsza część książki. W literaturze ten materiał nosi nazwę statystycznej teorii decyzji (Hastie i in. 2009, rozdz. 2.4). My słowa „decyzja" używamy w węższym znaczeniu z sekcji 1.4: jako wyboru działania na podstawie prawdopodobieństw klas, na przykład ustalenia progu albo odmowy odpowiedzi. Tym zajmujemy się w sekcji 2.5.

Rozdział buduje ten aparat od podstaw. Wynikiem będą fakty, do których wracamy przez całą książkę: funkcja regresji jako optymalny predyktor przy stracie kwadratowej i klasyfikator bayesowski przy stracie 0–1, a dla obu tych strat – konkretna postać rozkładu ryzyka na błąd redukowalny i nieredukowalny, wprowadzonego ogólnie w sekcji 1.6.

2.1. Sformułowanie problemu

Przyjmujemy opis probabilistyczny z sekcji 1.5: para $(\mathbf{X}, Y)$ ma nieznany rozkład łączny P, a jej wartości leżą w $\mathcal{X} \times \mathcal{Y}$. W regresji $\mathcal{Y} = \mathbb{R}$, w klasyfikacji $\mathcal{Y} = \{1, \dots, K\}$. Predyktor to dowolna (mierzalna) funkcja $f : \mathcal{X} \to \mathcal{Y}$, a strata $L(y, \hat{y})$ i ryzyko są takie jak w Definicja 1.1:

$$R(f) = \mathbb{E}[L(Y, f(\mathbf{X}))]. \tag{2.1}$$

Ryzyko jest wielkością teoretyczną: liczymy je względem nieznanego rozkładu P, a nie na zbiorze uczącym.

Symbol $\mathbb{E}$ będzie w tym rozdziale oznaczał średnie po różnych rozkładach, dlatego ustalmy konwencję. Zapis $\mathbb{E}[\cdots]$ bez warunku to średnia względem rozkładu wszystkich zmiennych losowych występujących w nawiasie: we wzorze (2.1) – pary $(\mathbf{X}, Y)$, a gdy wyrażenie zależy tylko od $\mathbf{X}$ – rozkładu cech. Zapis $\mathbb{E}[\cdots \mid \mathbf{X} = \mathbf{x}]$ to średnia względem rozkładu warunkowego $Y \mid \mathbf{X} = \mathbf{x}$, przy ustalonym $\mathbf{x}$.

2.2. Redukcja do problemu punktowego

Wzór (2.1) wygląda na trudny do minimalizacji: szukamy funkcji, a nie liczby, i to w przestrzeni wszystkich funkcji mierzalnych. Poniższa obserwacja sprowadza go do zadania, które rozwiązujemy osobno w każdym punkcie $\mathbf{x}$ – i to ona jest właściwym silnikiem tego rozdziału.

Skorzystajmy z prawa iterowanej wartości oczekiwanej (Sekcja 1.5): średnią po parze $(\mathbf{X}, Y)$ można policzyć w dwóch krokach, najpierw uśredniając przy ustalonych cechach, potem po cechach. Dla ryzyka daje to

$$R(f) = \underbrace{\mathbb{E}\Big[\ \underbrace{\mathbb{E}\big[L(Y, f(\mathbf{X})) \,\big|\, \mathbf{X}\big]}_{\text{średnia po } Y \text{ przy ustalonym } \mathbf{X}}\ \Big]}_{\text{średnia po } \mathbf{X}}. \tag{2.2}$$

Wewnętrzna średnia to przeciętna strata wśród obiektów o tych samych cechach. Zależy ona od cech, więc jest zmienną losową – funkcją $\mathbf{X}$, tak jak $\mathbb{E}[Y \mid \mathbf{X}]$ w sekcji 1.5. Zewnętrzna średnia uśrednia ją po rozkładzie cech.

Wprowadźmy **ryzyko warunkowe** w punkcie $\mathbf{x}$ dla wartości a, którą rozważamy jako predykcję w tym punkcie:

$$r(a \mid \mathbf{x}) = \mathbb{E}\big[L(Y, a) \,\big|\, \mathbf{X} = \mathbf{x}\big]. \tag{2.3}$$

Punkt $\mathbf{x}$ i wartość a są tu ustalone, losowe jest tylko Y, a średnią liczymy względem rozkładu warunkowego $Y \mid \mathbf{X} = \mathbf{x}$:

$$r(a \mid \mathbf{x}) = \sum_{y} L(y, a)\, p(y \mid \mathbf{x}) \qquad \text{albo} \qquad r(a \mid \mathbf{x}) = \int L(y, a)\, p(y \mid \mathbf{x})\, dy.$$

Ryzyko warunkowe jest więc **liczbą**: mówi, ile przeciętnie kosztuje predykcja a dla obiektów o cechach $\mathbf{x}$. Wewnętrzna średnia w (2.2) to ta sama wielkość z $a = f(\mathbf{x})$, obliczona w wylosowanym punkcie: $\mathbb{E}[L(Y, f(\mathbf{X})) \mid \mathbf{X}] = r(f(\mathbf{X}) \mid \mathbf{X})$.

Twierdzenie 2.1 (Zasada minimalizacji punktowej)**.** *Jeżeli dla każdego $\mathbf{x}$ istnieje wartość $f^*(\mathbf{x})$ minimalizująca $r(\cdot \mid \mathbf{x})$, to funkcja f^* minimalizuje ryzyko R w klasie **wszystkich** predyktorów.*

Dowód. Niech f będzie dowolnym predyktorem. Z definicji $f^*(\mathbf{x})$ jako minimalizatora zachodzi $r(f^*(\mathbf{x}) \mid \mathbf{x}) \le r(f(\mathbf{x}) \mid \mathbf{x})$ dla każdego $\mathbf{x}$. Podstawiając $\mathbf{X}$ w miejsce $\mathbf{x}$, otrzymujemy nierówność między zmiennymi losowymi $r(f^*(\mathbf{X}) \mid \mathbf{X})$ i $r(f(\mathbf{X}) \mid \mathbf{X})$. Nierówność ta zachowuje się przy uśrednianiu po rozkładzie $\mathbf{X}$, więc na mocy (2.2)

$$R(f^*) = \mathbb{E}\big[r(f^*(\mathbf{X}) \mid \mathbf{X})\big] \ \le\ \mathbb{E}\big[r(f(\mathbf{X}) \mid \mathbf{X})\big] = R(f). \qquad \square$$

$\square$

Znaczenie minimalizacji punktowej

Zasada mówi, co estymować – średnią warunkową, medianę albo $\eta(\mathbf{x})$ – ale nie mówi, jak to zrobić. Wygląda na prostą, bo w każdym punkcie $\mathbf{x}$ wystarczy znać rozkład warunkowy $Y \mid \mathbf{X} = \mathbf{x}$ i nie trzeba patrzeć na inne punkty. Tego rozkładu jednak nie znamy, a przy cechach ciągłych $\mathbb{P}(\mathbf{X} = \mathbf{x}) = 0$, więc w próbie prawie na pewno nie ma ani jednej obserwacji o cechach dokładnie $\mathbf{x}$. Informację trzeba pożyczać z innych punktów: z otoczenia $\mathbf{x}$, jak w metodzie k najbliższych sąsiadów z rozdziału 3, albo z całej próby naraz, jak w modelu parametrycznym, którego wszystkie parametry wyznaczamy jednocześnie.

Pożyczanie sprzęga predykcje w różnych punktach i stąd biorą się kompromisy. Prosta dopasowana do zakrzywionej funkcji regresji, jak na rysunku 1.1, poprawia się w jednej części przestrzeni cech kosztem innej. Przy uśrednianiu lokalnym trzeba z kolei wybrać wielkość otoczenia: małe zawiera mało obserwacji, duże miesza punkty o różnych rozkładach warunkowych. Inaczej jest, gdy cechy przyjmują niewiele wartości i każdą z nich obserwujemy wiele razy – wtedy optymalną predykcję można szacować w każdym punkcie osobno, na przykład średnią wyników w tym punkcie.
Widać tu też rolę obu czynników rozkładu łącznego (1.1). Ryzyko warunkowe $r(a \mid \mathbf{x})$ zależy wyłącznie od rozkładu warunkowego $Y \mid \mathbf{X} = \mathbf{x}$, więc optymalna predykcja w punkcie $\mathbf{x}$ nie zależy od rozkładu brzegowego cech $p(\mathbf{x})$. Ten pojawia się dopiero w zewnętrznej wartości oczekiwanej we wzorze (2.2): waży punkty, decydując, ile wnosi do ryzyka błąd popełniony w danym obszarze przestrzeni cech – tak jak zapowiedzieliśmy w sekcji 1.5.

Od tej chwili wystarczy więc odpowiadać na pytanie: *dla danej straty L i danego rozkładu warunkowego $Y \mid \mathbf{X} = \mathbf{x}$, która wartość a minimalizuje (2.3)?* Strata wyznacza, jaką charakterystykę rozkładu warunkowego zwraca optymalny predyktor, na przykład średnią, medianę albo najbardziej prawdopodobną klasę. Wybór straty jest więc częścią modelowania.

2.3. Regresja: strata kwadratowa i strata absolutna

2.3.1. Funkcja regresji

Twierdzenie 2.2 (Optymalność funkcji regresji)**.** *Niech $\mathcal{Y} = \mathbb{R}$, $L(y, a) = (y - a)^2$ i niech $\mathbb{E}[Y^2] < \infty$. Wtedy ryzyko (2.1) jest minimalizowane przez* ***funkcję regresji***

$$f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]. \tag{2.4}$$

Dowód. Na mocy Twierdzenie 2.1 wystarczy dla ustalonego $\mathbf{x}$ zminimalizować $r(a \mid \mathbf{x}) = \mathbb{E}[(Y - a)^2 \mid \mathbf{X} = \mathbf{x}]$ względem $a \in \mathbb{R}$. Oznaczmy $m = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ i rozłóżmy różnicę $Y - a = (Y - m) + (m - a)$:

$$\mathbb{E}\big[(Y - a)^2 \mid \mathbf{X} = \mathbf{x}\big] = \mathbb{E}\big[(Y - m)^2 \mid \mathbf{X} = \mathbf{x}\big] + 2(m - a)\,\mathbb{E}\big[Y - m \mid \mathbf{X} = \mathbf{x}\big] + (m - a)^2.$$

Środkowy składnik znika, ponieważ $\mathbb{E}[Y - m \mid \mathbf{X} = \mathbf{x}] = m - m = 0$. Zostaje

$$r(a \mid \mathbf{x}) = \mathrm{Var}(Y \mid \mathbf{X} = \mathbf{x}) + (m - a)^2. \tag{2.5}$$

Pierwszy składnik nie zależy od a, drugi jest nieujemny i zeruje się dokładnie dla $a = m$. Zatem $f^*(\mathbf{x}) = m = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$. □ □

Z równania (2.5) dla $a = m$ wynika też, że ryzyko warunkowe optymalnego predyktora w punkcie $\mathbf{x}$ wynosi $\mathrm{Var}(Y \mid \mathbf{X} = \mathbf{x})$. **Optymalny predyktor ma więc dodatnie ryzyko**, o ile Y nie jest wyznaczone przez $\mathbf{X}$. Wrócimy do tego w sekcji 2.3.3.

2.3.2. Strata absolutna

Zmieńmy jedno założenie – stratę – i zobaczmy, jak zmienia się odpowiedź.

Twierdzenie 2.3 (Optymalność mediany warunkowej)**.** *Przy stracie $L(y, a) = |y - a|$ ryzyko (2.1) jest minimalizowane przez* ***medianę warunkową***

$$f^*(\mathbf{x}) = \mathrm{med}(Y \mid \mathbf{X} = \mathbf{x}). \tag{2.6}$$

Dowód (dla zainteresowanych)

Ustalmy $\mathbf{x}$ i oznaczmy przez F dystrybuantę rozkładu $Y \mid \mathbf{X} = \mathbf{x}$. Dla prostoty zakładamy, że F jest ciągła. Rozbijając wartość oczekiwaną według znaku $Y - a$, mamy

$$r(a \mid \mathbf{x}) = \int_{-\infty}^{a} (a - y)\, dF(y) + \int_{a}^{\infty} (y - a)\, dF(y).$$

Różniczkując po a (składniki brzegowe znoszą się, bo podcałkowa funkcja zeruje się w $y = a$):

$$\frac{\partial r}{\partial a}(a \mid \mathbf{x}) = F(a) - (1 - F(a)) = 2F(a) - 1.$$

Pochodna jest ujemna dla $F(a) < \frac{1}{2}$ i dodatnia dla $F(a) > \frac{1}{2}$, a funkcja $r(\cdot \mid \mathbf{x})$ jest wypukła jako suma funkcji wypukłych. Minimum przypada więc tam, gdzie $F(a) = \frac{1}{2}$, czyli w medianie rozkładu warunkowego. □

Bez założenia ciągłości rozumowanie przenosi się na pochodne jednostronne: minimum osiąga każda mediana, czyli każde a spełniające $F(a^-) \le \frac{1}{2} \le F(a)$ – w ogólności nie jest ona jednoznaczna.

Symbol f^* oznacza więc predyktor optymalny **przy danej stracie** – zmiana straty zmienia to, co się pod nim kryje. Gdy strata nie jest wskazana, f^* oznacza, tak jak w sekcji 1.5, funkcję regresji.

Wybór straty jest wyborem merytorycznym

Twierdzenia Twierdzenie 2.2 i Twierdzenie 2.3 dają **różne** odpowiedzi na to samo pytanie o ten sam rozkład. Gdy rozkład warunkowy jest skośny, średnia i mediana potrafią leżeć daleko od siebie – i wtedy pytanie „jaka jest najlepsza predykcja?" nie ma sensu, dopóki nie powiemy, co uznajemy za stratę.

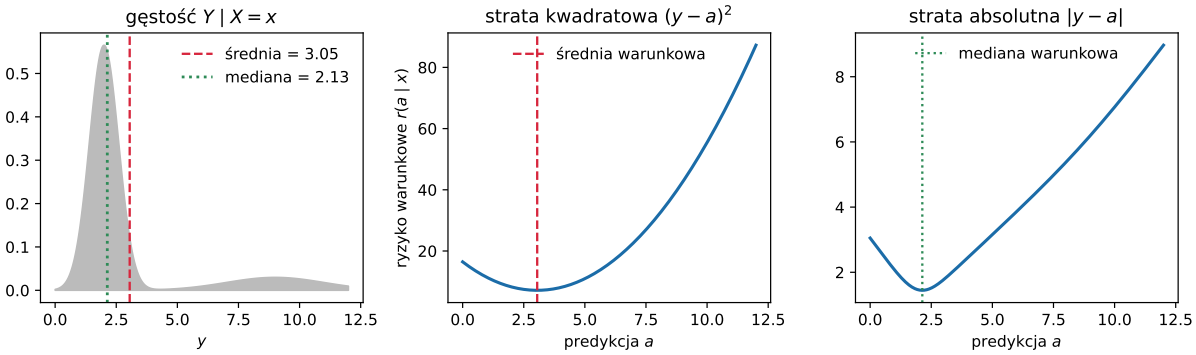
Strata kwadratowa karze duże błędy proporcjonalnie do kwadratu, więc jeden gruby błąd waży tyle co wiele drobnych: predyktor jest przyciągany w stronę ogona rozkładu. Strata absolutna waży wszystkie błędy liniowo i dlatego prowadzi do estymatora odpornego na obserwacje odstające.

To nie jest wybór między „dokładniejszym" a „mniej dokładnym" narzędziem. Przy stracie kwadratowej jeden błąd o wartości 10 kosztuje tyle, co sto błędów o wartości 1 (por. Sekcja 1.6), przy absolutnej – tyle, co dziesięć. Wybór straty to rozstrzygnięcie, która z tych wycen lepiej oddaje koszty w Twoim zastosowaniu.

Zilustrujmy to na konkretnym rozkładzie. Ustalmy punkt $\mathbf{x}$ i przyjmijmy, że rozkład warunkowy $Y \mid \mathbf{X} = \mathbf{x}$ jest mieszaniną dwóch rozkładów normalnych: z prawdopodobieństwem 0,85 wynik pochodzi z rozkładu $\mathcal{N}(2,\, 0{,}6^2)$, a z prawdopodobieństwem 0,15 – z rozkładu $\mathcal{N}(9,\, 2^2)$. Większość masy skupia się więc wokół 2, a niewielka jej część tworzy długi prawy ogon.

Średnia mieszaniny jest średnią średnich składników ważoną ich prawdopodobieństwami: $0{,}85 \cdot 2 + 0{,}15 \cdot 9 = 3{,}05$. Mediana nie ma prostego wzoru – wyznacza się ją numerycznie, rozwiązując równanie $F(a) = \frac{1}{2}$, gdzie F jest dystrybuantą mieszaniny (w kodzie poniżej robi to funkcja `brentq`). Wychodzi około 2,13, blisko środka składnika głównego, który ma 85% masy. Oba ryzyka warunkowe da się dla mieszaniny rozkładów normalnych policzyć dokładnie, bez symulacji.

Minima obu krzywych leżą w innych miejscach, choć rozkład warunkowy jest ten sam. Przy stracie kwadratowej długi prawy ogon przeciąga optymalną predykcję w prawo; przy stracie



Rysunek 2.1.: Rozkład warunkowy $Y \mid \mathbf{X} = \mathbf{x}$ i ryzyko warunkowe $r(a \mid \mathbf{x})$ jako funkcja predykcji a. Po lewej: gęstość mieszaniny $0{,}85\,\mathcal{N}(2,\, 0{,}6^2) + 0{,}15\,\mathcal{N}(9,\, 2^2)$ z zaznaczoną średnią i medianą. W środku: ryzyko przy stracie kwadratowej, minimalizowane przez średnią warunkową. Po prawej: ryzyko przy stracie absolutnej, minimalizowane przez medianę warunkową. Oba ryzyka policzono dokładnie ze wzorów dla rozkładu normalnego.

absolutnej ogon jest bez znaczenia, bo liczy się tylko to, po której stronie predykcji leży masa prawdopodobieństwa.

2.3.3. Rozkład ryzyka przy stracie kwadratowej

W sekcji 1.6 rozdzieliliśmy ryzyko na błąd redukowalny i nieredukowalny, nie podając ich postaci. Wróćmy do straty kwadratowej: dla niej możemy je teraz wyznaczyć. Zapytajmy, ile traci predyktor f, który nie jest optymalny. Uśredniając (2.5) po rozkładzie $\mathbf{X}$, dostajemy

$$\underbrace{\mathbb{E}\big[(Y - f(\mathbf{X}))^2\big]}_{\text{ryzyko } f} = \underbrace{\mathbb{E}\Big[\big(f^*(\mathbf{X}) - f(\mathbf{X})\big)^2\Big]}_{\text{błąd redukowalny}} + \underbrace{\mathbb{E}\big[\operatorname{Var}(Y \mid \mathbf{X})\big]}_{\text{błąd nieredukowalny}}. \tag{2.7}$$

Średnie po obu stronach liczymy po różnych rozkładach. Po lewej stronie występują $\mathbf{X}$ i Y, więc uśredniamy po parze $(\mathbf{X}, Y)$. Po prawej stronie Y już nie ma: zniknęło przy uśrednianiu przy ustalonym $\mathbf{X}$ w (2.5). Oba składniki są funkcjami samego $\mathbf{X}$ i uśredniamy je po rozkładzie cech.

Błąd redukowalny okazuje się średnim kwadratem odległości predyktora od funkcji regresji, a nieredukowalny – średnią wariancją warunkową wyniku, czyli średnią wariancją szumu ε z (1.4). Ten drugi zależy od rozkładu warunkowego $Y \mid \mathbf{X}$, a więc – jak zauważyliśmy w sekcji 1.6 – od zestawu cech, a nie od modelu.

Rozkład (2.7) jest zalążkiem kompromisu obciążenie–wariancja. W rozdziale 4 rozbijemy człon redukowalny dalej – na część wynikającą ze zbyt ubogiej klasy modeli i część wynikającą ze skończoności próby.

2.4. Klasyfikacja: strata 0–1 i klasyfikator bayesowski

Przejdźmy do $\mathcal{Y} = \{1, \ldots, K\}$ i straty 0–1 (1.7), która karze każdą pomyłkę tak samo. Jak zauważyliśmy w sekcji 1.6, ryzyko jest przy niej prawdopodobieństwem błędnej klasyfikacji. Klasyfikatory, czyli predyktory o wartościach w zbiorze klas, oznaczamy literą g. Prawdopodobieństwa klas zapisujemy, jak w sekcji 1.5, jako $\eta_k(\mathbf{x}) = \mathbb{P}(Y = k \mid \mathbf{X} = \mathbf{x})$.

Twierdzenie 2.4 (Optymalność reguły Bayesa)**.** *Spośród wszystkich klasyfikatorów* $g : \mathcal{X} \to \{1, \dots, K\}$ *prawdopodobieństwo błędu* $\mathbb{P}(g(\mathbf{X}) \neq Y)$ *minimalizuje* ***klasyfikator bayesowski***

$$g^*(\mathbf{x}) = \arg\max_k \ \eta_k(\mathbf{x}). \tag{2.8}$$

Dowód. Zastosujmy Twierdzenie 2.1. Ryzyko warunkowe wskazania klasy a w punkcie $\mathbf{x}$ wynosi

$$r(a \mid \mathbf{x}) = \mathbb{E}\big[\mathbb{1}(Y \neq a) \mid \mathbf{X} = \mathbf{x}\big] = \mathbb{P}(Y \neq a \mid \mathbf{X} = \mathbf{x}) = 1 - \eta_a(\mathbf{x}).$$

Minimalizacja $r(\cdot \mid \mathbf{x})$ jest więc równoważna maksymalizacji $\eta_a(\mathbf{x})$ po a, co daje dokładnie (2.8). Ponieważ zachodzi to punktowo dla każdego $\mathbf{x}$, minimalizowane jest również ryzyko uśrednione po rozkładzie $\mathbf{X}$. □ □

Ryzyko klasyfikatora bayesowskiego nazywamy **błędem bayesowskim**:

$$R^* = \mathbb{P}(g^*(\mathbf{X}) \neq Y) = \mathbb{E}\Big[1 - \max_k \eta_k(\mathbf{X})\Big]. \tag{2.9}$$

Ostatnie wyrażenie zależy już tylko od $\mathbf{X}$, więc średnią liczymy po rozkładzie cech: w każdym punkcie $\mathbf{x}$ pomyłka zdarza się z prawdopodobieństwem $1 - \max_k \eta_k(\mathbf{x})$, a $\mathbb{E}$ uśrednia te prawdopodobieństwa po $\mathbf{x}$.

Błąd bayesowski jest więc błędem nieredukowalnym z sekcji 1.6, wyznaczonym dla straty 0–1. Tak jak dla straty kwadratowej, możemy wyznaczyć również część redukowalną. Ryzyko warunkowe wskazania klasy a rozkłada się na

$$r(a \mid \mathbf{x}) = 1 - \eta_a(\mathbf{x}) = (1 - \max_k \eta_k(\mathbf{x})) + (\max_k \eta_k(\mathbf{x}) - \eta_a(\mathbf{x})).$$

Pierwszy składnik to ryzyko warunkowe klasyfikatora bayesowskiego. Drugi jest nieujemny i zeruje się dokładnie wtedy, gdy a jest klasą o największym prawdopodobieństwie. Uśredniając po rozkładzie $\mathbf{X}$, dostajemy odpowiednik (2.7):

$$\underbrace{\mathbb{P}(g(\mathbf{X}) \neq Y)}_{\text{ryzyko } g} = \underbrace{\mathbb{E}\Big[\max_k \eta_k(\mathbf{X}) - \eta_{g(\mathbf{X})}(\mathbf{X})\Big]}_{\text{błąd redukowalny}} + \underbrace{R^*}_{\text{błąd nieredukowalny}}. \tag{2.10}$$

Dla dwóch klas różnica $\max_k \eta_k(\mathbf{x}) - \eta_{g(\mathbf{x})}(\mathbf{x})$ wynosi 0, gdy $g(\mathbf{x}) = g^*(\mathbf{x})$, a w przeciwnym razie $|\eta_1(\mathbf{x}) - \eta_2(\mathbf{x})| = |2\eta_1(\mathbf{x}) - 1|$. Błąd redukowalny jest więc równy

$$\mathbb{E}\Big[\,|2\eta_1(\mathbf{X}) - 1| \cdot \mathbb{1}(g(\mathbf{X}) \neq g^*(\mathbf{X}))\Big].$$

Nie liczy on po prostu, jak często g nie zgadza się z regułą Bayesa, lecz waży każdą niezgodność tym, jak wyraźnie jedna klasa przeważa w danym punkcie. Niezgodność blisko granicy decyzyjnej, gdzie $\eta_1(\mathbf{x}) \approx \frac{1}{2}$, prawie nic nie kosztuje. W obszarze, gdzie $\eta_1(\mathbf{x})$ jest bliskie 0 lub 1, kosztuje niemal całą pomyłkę. Ten wzór na nadwyżkę ryzyka nad błędem bayesowskim jest punktem wyjścia teorii klasyfikacji w monografii Devroye i in. (1996, rozdz. 2).

Oba rozkłady, (2.7) i (2.10), mają tę samą budowę: ryzyko dowolnego predyktora to ryzyko predyktora optymalnego plus nieujemna nadwyżka, mierząca odległość od optimum. Przy stracie kwadratowej jest nią średni kwadrat odległości od funkcji regresji, przy stracie 0–1 – średnie prawdopodobieństwo trafienia utracone przez wybór gorszej klasy.

i Błąd bayesowski to nie jest wada modelu

R^* jest zwykle dodatni i przy ustalonych cechach nie da się go zmniejszyć **żadnym** modelem, żadną ilością danych ani żadną mocą obliczeniową. Jest dodatni zawsze, gdy istnieje obszar przestrzeni cech o dodatnim prawdopodobieństwie, w którym $\eta_k(\mathbf{x})$ nie koncentruje się na jednej klasie – czyli gdy te same cechy występują u obiektów o różnych etykietach. Praktyczna konsekwencja: gdyby błąd bayesowski problemu wynosił 7%, to klasyfikator z błędem 7,2% mógłby zyskać na dalszym strojeniu co najwyżej 0,2 punktu procentowego. Większej poprawy trzeba by szukać nie w modelu, lecz w cechach – w informacji, której obecne cechy nie zawierają. Wartości R^* zwykle nie znamy, ale już sama świadomość, że taki próg istnieje, chroni przed oczekiwaniem, że dość dobry model osiągnie błąd bliski zera.

2.5. Od prawdopodobieństw do decyzji

W sekcji 1.4 rozdzieliliśmy w klasyfikacji dwa etapy: oszacowanie prawdopodobieństw klas $\eta_k(\mathbf{x})$ i wybór klasy za pomocą reguły decyzyjnej. Klasyfikator bayesowski jest jedną z takich reguł – optymalną przy stracie 0–1. Ta sekcja odpowiada na dwa pytania: dlaczego model powinien zwracać właśnie $\eta_k(\mathbf{x})$ i jak wybrać regułę decyzyjną, gdy strata 0–1 nie opisuje dobrze kosztów zastosowania. Oba pytania rozstrzyga ta sama zasada minimalizacji punktowej.

2.5.1. Predykcja probabilistyczna

Niech $\mathcal{Y} = \{0, 1\}$ i $\eta(\mathbf{x}) = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$. Model zamiast etykiety zwraca liczbę $p \in [0, 1]$, która ma być prawdopodobieństwem klasy 1. Taka predykcja ma inną postać niż y i nie da się jej „trafić”: Y przyjmuje tylko wartości 0 i 1, więc strata $L(y, p)$ musi nagradzać coś innego niż zgodność p z y.

Pierwszy pomysł to traktować p jak zwykłą predykcję liczbową i karać kwadrat odchylenia od zaobserwowanej wartości. Tak powstaje **strata Briera** (Brier 1950)

$$L_{\mathrm{B}}(y, p) = (y - p)^2.$$

Drugi pomysł to patrzeć, jakie prawdopodobieństwo model przypisał temu, co faktycznie zaszło. Gdy $y = 1$, model przypisał mu p, gdy $y = 0$ – prawdopodobieństwo $1 - p$. Im mniejsze to prawdopodobieństwo, tym model bardziej się pomylił, więc za stratę bierzemy jego ujemny logarytm. Tak powstaje **strata logarytmiczna**

$$L_{\log}(y, p) = \begin{cases} -\ln p, & y = 1, \\ -\ln(1 - p), & y = 0, \end{cases} \qquad \text{czyli} \qquad L_{\log}(y, p) = -y \ln p - (1 - y) \ln(1 - p),$$

bo dla $y \in \{0, 1\}$ jeden z dwóch składników zawsze się zeruje. Strata ta wynosi 0, gdy model przypisał zaobserwowanej klasie prawdopodobieństwo 1, i rośnie do nieskończoności, gdy przypisał jej prawdopodobieństwo bliskie 0. Strata Briera nie przekracza natomiast 1, więc pewne siebie pomyłki karze znacznie łagodniej. Stratę logarytmiczną minimalizowaliśmy w sekcji 1.8, dopasowując model prawdopodobieństw klas.

Ta minimalizacja ma interpretację probabilistyczną. Model zwracający $p(\mathbf{x})$ zakłada, że $Y \mid \mathbf{X} = \mathbf{x}$ ma rozkład Bernoulliego z parametrem $p(\mathbf{x})$, a prawdopodobieństwo, jakie przypisuje

obserwacji y, to $p(\mathbf{x})^y(1-p(\mathbf{x}))^{1-y}$. Dla niezależnych obserwacji $(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)$ prawdopodobieństwo całej próby jest iloczynem takich czynników – jest to **funkcja wiarygodności** modelu. Jej ujemny logarytm to suma strat logarytmicznych,

$$-\ln\left(\prod_{i=1}^{n} p(\mathbf{x}_i)^{y_i}(1-p(\mathbf{x}_i))^{1-y_i}\right) = \sum_{i=1}^{n} L_{\log}(y_i, p(\mathbf{x}_i)),$$

więc minimalizacja średniej straty logarytmicznej na próbie to to samo co **metoda największej wiarygodności**.

Dla straty Briera nie trzeba nic liczyć. Y jest zmienną liczbową o wartościach 0 i 1, więc $\mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}] = \eta(\mathbf{x})$ i Twierdzenie 2.2 daje od razu $f^*(\mathbf{x}) = \eta(\mathbf{x})$. Dla straty logarytmicznej ryzyko warunkowe wynosi

$$r(p \mid \mathbf{x}) = -\eta(\mathbf{x}) \ln p - (1-\eta(\mathbf{x})) \ln(1-p).$$

Jest to funkcja wypukła zmiennej p, a jej pochodna $-\eta(\mathbf{x})/p + (1-\eta(\mathbf{x}))/(1-p)$ zeruje się dokładnie dla $p = \eta(\mathbf{x})$. Obie straty prowadzą więc do tego samego optimum: **najlepiej jest podać prawdziwe prawdopodobieństwo warunkowe**. Straty o tej własności nazywamy **właściwymi** (ang. *proper scoring rules*) (Gneiting i Raftery 2007).

Nie każda strata ją ma. Dla straty absolutnej $|y-p|$ ryzyko warunkowe

$$r(p \mid \mathbf{x}) = \eta(\mathbf{x})\,(1-p) + (1-\eta(\mathbf{x}))\,p$$

jest liniowe w p, więc minimum leży na końcu przedziału: $p = 1$, gdy $\eta(\mathbf{x}) > \frac{1}{2}$, i $p = 0$ w przeciwnym razie. Model oceniany tą stratą zwraca zatem etykietę klasyfikatora bayesowskiego zamiast prawdopodobieństwa i traci informację o tym, jak pewna jest ta etykieta. Tymczasem właśnie tej informacji potrzebują obie reguły decyzyjne omówione poniżej.

2.5.2. Straty niesymetryczne i próg decyzyjny

Strata 0–1 zakłada, że wszystkie pomyłki kosztują tyle samo. W diagnostyce medycznej, wykrywaniu oszustw czy filtrowaniu spamu założenie to jest fałszywe i zwykle kosztowne. Ogólniej, dla macierzy kosztów $L(y,a) = c_{ya}$ ryzyko warunkowe wynosi

$$r(a \mid \mathbf{x}) = \sum_{k=1}^{K} c_{ka}\,\eta_k(\mathbf{x}),$$

a Twierdzenie 2.1 daje regułę optymalną

$$f^*(\mathbf{x}) = \arg\min_a \sum_{k=1}^{K} c_{ka}\,\eta_k(\mathbf{x}). \tag{2.11}$$

W przypadku dwuklasowym z kosztami c_{10} (fałszywie ujemny) i c_{01} (fałszywie dodatni), przy zerowym koszcie trafnych decyzji ($c_{00} = c_{11} = 0$), reguła (2.11) redukuje się do progowania prawdopodobieństwa warunkowego na poziomie $c_{01}/(c_{01}+c_{10})$ zamiast na $\frac{1}{2}$ (Elkan 2001).

> **Dobry model, zły próg**
>
> W regule (2.11) spotykają się dwa niezależne składniki: prawdopodobieństwa $\eta_k(\mathbf{x})$ zależą wyłącznie od zjawiska, koszty c_{ya} – wyłącznie od zastosowania. Dlatego model powinien estymować prawdopodobieństwa, a próg decyzyjny dobiera się osobno, na etapie wdrożenia. Model zwracający twardą etykietę zamiast prawdopodobieństwa zamyka tę drogę: przy

zmianie kosztów trzeba go uczyć od nowa.

Predykcja probabilistyczna i reguła kosztowa składają się na dwa etapy z sekcji 1.4. Pierwszy etap oceniamy stratą właściwą, a jego optimum $\eta(\mathbf{x})$ nie zależy od kosztów zastosowania. W drugim podstawiamy to oszacowanie do reguły (2.11).

2.5.3. Opcja odmowy

Wróćmy do K klas i dopuśćmy dodatkową decyzję: model może odmówić odpowiedzi i przekazać przypadek człowiekowi. Decyzji jest wtedy więcej niż etykiet: do klas $1, \dots, K$ dochodzi odmowa. Stratę rozszerzamy na nową decyzję tak, że wskazanie klasy oceniamy jak w stracie 0–1, a odmowa kosztuje stałą kwotę $d \in (0, 1)$, niezależnie od prawdziwej klasy:

$$L(y, k) = \mathbb{1}(y \neq k), \qquad L(y, \text{odmowa}) = d.$$

Ryzyko warunkowe wskazania klasy k znamy z dowodu Twierdzenie 2.4: $r(k \mid \mathbf{x}) = 1 - \eta_k(\mathbf{x})$. Ryzyko warunkowe odmowy wynosi po prostu d. Najlepszą klasą jest $g^*(\mathbf{x})$, a jej ryzyko warunkowe to $1 - \max_k \eta_k(\mathbf{x})$. Reguła optymalna ma więc postać

$$f^*(\mathbf{x}) = \begin{cases} g^*(\mathbf{x}), & \text{gdy } 1 - \max_k \eta_k(\mathbf{x}) \leq d, \\ \text{odmowa}, & \text{w przeciwnym razie.} \end{cases} \tag{2.12}$$

Jest to **reguła Chowa** (Chow 1970): odmawiamy, gdy nawet najbardziej prawdopodobna klasa daje szansę pomyłki większą niż koszt odmowy. Przypadki skrajne potwierdzają intuicję. Ponieważ $\max_k \eta_k(\mathbf{x}) \geq 1/K$, przy $d \geq (K-1)/K$ odmowa nigdy się nie opłaca i wracamy do klasyfikatora bayesowskiego. Przy d bliskim zeru model odpowiada tylko tam, gdzie jest niemal pewny.

Minimalne ryzyko wynosi teraz $\mathbb{E}\big[\min\big(1 - \max_k \eta_k(\mathbf{X}),\, d\big)\big]$, ze średnią po rozkładzie cech, i nie przekracza błędu bayesowskiego (2.9). Opcja odmowy nie usuwa niepewności. Pozwala jedynie wymienić pomyłki w najtrudniejszych obszarach przestrzeni cech na stały, znany z góry koszt. Podobnie jak reguła kosztowa, reguła Chowa wymaga prawdopodobieństw $\eta_k(\mathbf{x})$, a nie samej etykiety.

2.6. Nieosiągalność optimum

Wszystkie twierdzenia tego rozdziału mają tę samą wadę: ich teza odwołuje się do rozkładu P, którego nie znamy. $\mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ i $\eta_k(\mathbf{x})$ to wielkości teoretyczne. Reguła bayesowska nie jest algorytmem, który można uruchomić – jest **wzorcem, do którego algorytmy się zbliżają**.

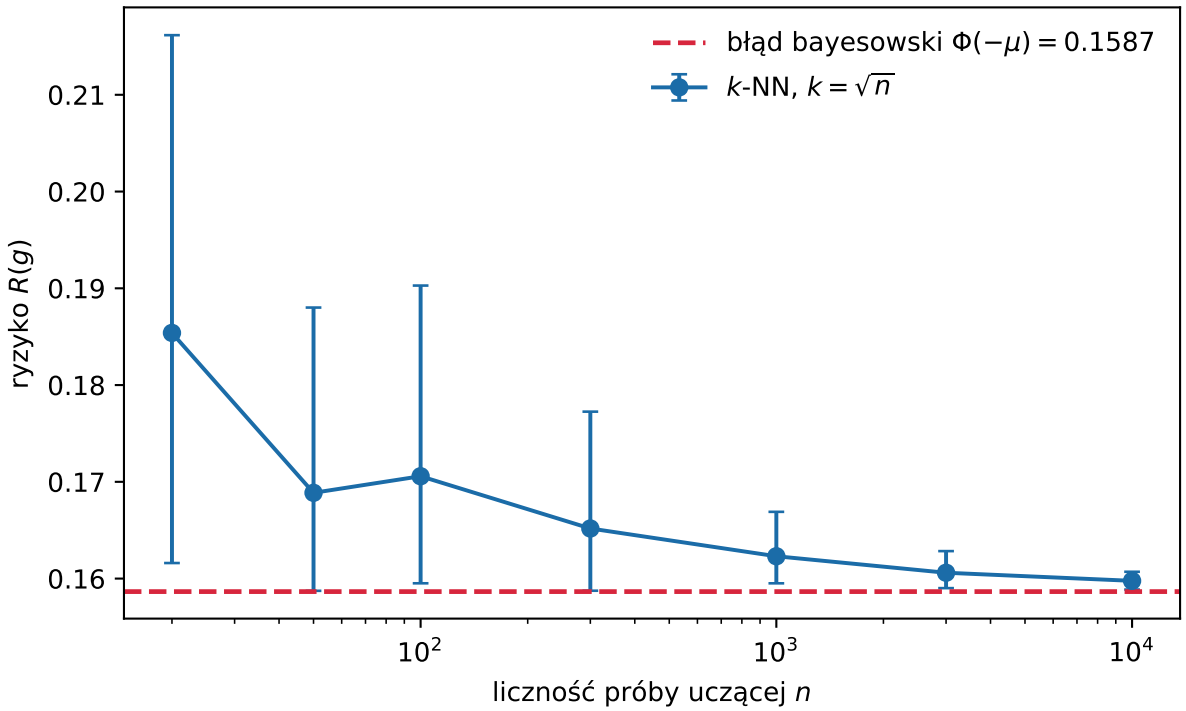
Wartość tego wzorca jest jednak praktyczna: pozwala oceniać algorytmy przez pytanie, jak dobrze estymują $\eta_k(\mathbf{x})$, i pozwala wiedzieć, kiedy przestać. Poniższy eksperyment pokazuje jedno i drugie na przykładzie, w którym błąd bayesowski znamy dokładnie.

Rozważmy dwie równoliczne klasy, $\pi_0 = \pi_1 = \frac{1}{2}$, i jedną cechę X, która w klasie 0 ma rozkład $\mathcal{N}(-\mu, 1)$, a w klasie 1 rozkład $\mathcal{N}(\mu, 1)$, $\mu > 0$. Oznaczając przez φ gęstość, a przez Φ dystrybuantę rozkładu normalnego standardowego, mamy $p(x \mid Y = 0) = \varphi(x + \mu)$ i $p(x \mid Y = 1) = \varphi(x - \mu)$. Cecha jest ciągła, a klasa dyskretna, więc $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$ wyznaczamy ze wzoru Bayesa (1.2):

$$\eta(x) = \frac{\varphi(x - \mu)}{\varphi(x - \mu) + \varphi(x + \mu)} = \frac{1}{1 + e^{-2\mu x}}.$$

Zatem $\eta(x) > \frac{1}{2}$ dokładnie dla $x > 0$, reguła bayesowska to $g^*(x) = \mathbb{1}(x > 0)$, a błąd bayesowski wynosi

$$R^* = \mathbb{P}(\mathcal{N}(\mu, 1) < 0) = \Phi(-\mu).$$



Rysunek 2.2.: Ryzyko klasyfikatora k-NN w zależności od liczności próby uczącej; cecha ma w klasach rozkłady $\mathcal{N}(-1, 1)$ i $\mathcal{N}(1, 1)$. Punkty to średnie z 25 niezależnych prób uczących, wąsy – kwantyle rzędu 0,1 i 0,9. Błąd bayesowski $\Phi(-1) \approx 0{,}1587$ wyznacza poziom, poniżej którego nie schodzi żaden klasyfikator, niezależnie od liczby obserwacji.

Krzywa opada i wypłaszcza się tuż nad czerwoną linią, nigdy jej nie przecinając – nie może, bo Twierdzenie 2.4 tego zabrania, a ryzyko policzyliśmy dokładnie, bez szumu losowania. Zachowanie jest typowe: zwiększanie próby przybliża nas do optimum coraz wolniej, a ostatnie punkty procentowe błędu są po prostu niedostępne.

i Dlaczego całkujemy zamiast losować zbiór testowy

Gdybyśmy oszacowali ryzyko na losowym zbiorze testowym, oszacowanie miałoby własny błąd standardowy. Gdybyśmy użyli np. 20 tys. obserwacji testowych, wynosiłby on około 0,0026 – czyli **więcej niż cała różnica**, którą chcemy pokazać w prawej części wykresu. Krzywa co jakiś czas schodziłaby przypadkiem pod czerwoną linię, sugerując coś, co jest niemożliwe.
Ponieważ w tym sztucznym przykładzie rozkład P znamy, ryzyko liczymy wprost z definicji (2.1) – całkując. W realnym problemie tej możliwości nie ma i pozostaje zbiór testowy wraz z jego niepewnością; jak sobie z nią radzić, mówi Rozdział 5.

Jak czytać taki wykres w praktyce

W realnym problemie czerwonej linii nie znamy – i to jest główna trudność diagnostyczna w uczeniu maszynowym. Widzimy tylko krzywą niebieską i musimy zgadnąć, czy jej wypłaszczenie oznacza „dotarliśmy do granicy zjawiska", czy „model jest za słaby".
Rozróżnienie tych dwóch sytuacji wymaga narzędzi z rozdziałów 4 i 5. Sygnał ostrzegawczy jest jednak prosty: jeśli podwojenie liczby danych nie poprawia wyniku, problemem prawie na pewno nie jest liczba danych. Może to oznaczać, że ryzyko jest już bliskie błędowi nieredukowalnemu, ale równie dobrze – że ogranicza nas wybrana metoda lub sposób jej dopasowania. Rozstrzygnięcie wymaga porównania różnych modeli.

Uwagi bibliograficzne

Statystyczną teorię decyzji w ujęciu bliskim temu rozdziałowi przedstawiają Hastie i in. (2009, rozdz. 2.4), a łagodniej, z przykładami, James i in. (2023, rozdz. 2). Bishop (2006, rozdz. 1.5) omawia te same zagadnienia od strony probabilistycznej: minimalizację oczekiwanej straty, opcję odmowy i rozdzielenie wnioskowania od decyzji. Rozważa tam też stratę $|y - a|^q$, która dla $q = 1$ prowadzi do mediany warunkowej. Nowsze ujęcie, obejmujące również straty dla predykcji probabilistycznej, zawiera Murphy (2022, rozdz. 5).

Ścisłą teorię klasyfikacji, zbudowaną wokół błędu bayesowskiego i nadwyżki ryzyka nad nim, wykładają Devroye i in. (1996), a analogiczną teorię regresji, z funkcją regresji jako optimum przy stracie kwadratowej, Györfi i in. (2002, rozdz. 1).

Straty właściwe i ich związek z estymacją prawdopodobieństw omawiają w pracy przeglądowej Gneiting i Raftery (2007). Elkan (2001) wyprowadza próg dla niesymetrycznych kosztów i pokazuje, że zamiast przesuwać próg, można zmienić proporcje klas w zbiorze uczącym. Chow (1970) bada, jak przy zmianie kosztu odmowy d zmieniają się jednocześnie częstość błędów i częstość odmów.

Zadania

Zadanie 2.1. Rozważ ryzyko ważone $\mathbb{E}[w(\mathbf{X})\,(Y - f(\mathbf{X}))^2]$ dla pewnej wagi $w(\mathbf{x}) > 0$ zależnej od punktu. Wykaż, że optymalny predyktor nadal jest równy $\mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$. Wyjaśnij, dlaczego ważenie nie zmienia rozwiązania, choć zmienia wartość ryzyka. Porównaj tę sytuację ze zmianą rozkładu brzegowego cech $p(\mathbf{x})$ przy niezmienionym rozkładzie warunkowym (Sekcja 1.5).

Zadanie 2.2. Rozważ **stratę pinball** (kwantylową) o parametrze $\tau \in (0, 1)$:

$$L_\tau(y, a) = \begin{cases} \tau(y - a), & y \geq a, \\ (1 - \tau)(a - y), & y < a. \end{cases}$$

Powtarzając rozumowanie z dowodu Twierdzenie 2.3 wykaż, że optymalny predyktor to kwantyl rzędu τ rozkładu warunkowego. Sprawdź, że dla $\tau = \frac{1}{2}$ odzyskujesz Twierdzenie 2.3.

Zadanie 2.3. Dla dwóch klas o rozkładach $\mathcal{N}(-\mu, \sigma^2)$ i $\mathcal{N}(\mu, \sigma^2)$ z równymi prawdopodobieństwami a priori wyprowadź wzór na błąd bayesowski w zależności od μ i σ. Dla jakiej wartości μ/σ błąd bayesowski spada poniżej 1%?

Zadanie 2.4. Zmodyfikuj eksperyment z Rysunek 2.2 tak, aby klasy miały prawdopodobieństwa a priori $\pi_0 = 0{,}9$ i $\pi_1 = 0{,}1$ (klasa 0 to ta, w której $X \sim \mathcal{N}(-\mu, 1)$). Wyznacz nowy błąd bayesowski i porównaj go z błędem klasyfikatora trywialnego, który zawsze wskazuje klasę częstszą. Kiedy k-NN zaczyna być od niego lepszy?

Zadanie 2.5. Wykorzystując (2.11) wyznacz próg decyzyjny dla problemu dwuklasowego, w którym pominięcie przypadku pozytywnego kosztuje dziesięciokrotnie więcej niż fałszywy alarm. Zilustruj numerycznie, jak przesunięcie progu zmienia liczbę błędów obu typów.

Zadanie 2.6. Korekta prawdopodobieństw a priori. Model klasyfikacyjny uczono na próbie, w której klasy występowały z częstościami π'_k, na przykład na próbie zbalansowanej. Model zwraca więc oszacowania $\eta'_k(\mathbf{x}) = \mathbb{P}'(Y = k \mid \mathbf{X} = \mathbf{x})$. W populacji, w której model będzie stosowany, klasy występują z częstościami π_k, a rozkłady cech w obrębie klas $p(\mathbf{x} \mid Y = k)$ są takie same jak w próbie. Korzystając ze wzoru Bayesa, wykaż, że

$$\eta_k(\mathbf{x}) = \frac{\eta'_k(\mathbf{x})\,\pi_k/\pi'_k}{\sum_{j=1}^{K} \eta'_j(\mathbf{x})\,\pi_j/\pi'_j}.$$

Pokaż, że w przypadku dwuklasowym korekta sprowadza się do pomnożenia szans $\eta(\mathbf{x})/(1-\eta(\mathbf{x}))$ przez stałą, i wyznacz tę stałą. Model wykrywania oszustw uczono na próbie zbalansowanej, a w populacji oszustwa stanowią 1% transakcji. Dla pewnej transakcji model zwrócił 0,8. Jakie jest prawdopodobieństwo oszustwa po korekcie? Wyjaśnij, dlaczego tej korekty nie da się przeprowadzić dla modelu zwracającego wyłącznie etykiety (por. ramka „Dobry model, zły próg").

Zadanie 2.7. Wykaż, że dla dowolnego rozkładu o skończonej wariancji średnia μ i mediana m spełniają $|\mu - m| \le \sigma$. (Wskazówka: skorzystaj z Twierdzenie 2.3 i nierówności Jensena.) Podaj rozkład, dla którego ta różnica jest bliska σ. Następnie pokaż, że przy ustalonym rozstępie międzykwartylowym różnica $|\mu - m|$ może być dowolnie duża. Co to mówi o odporności obu predyktorów?

Zadanie 2.8. Oto klasyczny problem taksówek Kahnemana i Tversky'ego (Kahneman 2011, rozdz. 16). W mieście jeżdżą taksówki dwóch przedsiębiorstw: 85% z nich należy do spółki Zielony, 15% do spółki Niebieski. Jedna z taksówek spowodowała wypadek i odjechała. Świadek zeznaje, że była niebieska. Test wiarygodności wykazał, że w warunkach takich jak w chwili wypadku świadek myli kolor w 20% przypadków, niezależnie od tego, jaki kolor widzi. Potraktujmy zeznanie świadka jako cechę X, a przedsiębiorstwo – jako klasę Y, z klasą pozytywną Niebieski.

a) Wyznacz $\eta(x) = \mathbb{P}(Y = \text{Niebieski} \mid X = x)$ dla obu możliwych zeznań i porównaj obie wartości z prawdopodobieństwem a priori $\mathbb{P}(Y = \text{Niebieski}) = 0{,}15$. W którą stronę i jak mocno każde z zeznań przesuwa ocenę, że wypadek spowodowała taksówka niebieska?
b) Wyznacz klasyfikator bayesowski przy stracie 0–1 i jego błąd. Porównaj go z błędem reguły „wierz świadkowi" oraz klasyfikatora stałego. Jak pogodzić wynik z odpowiedzią z punktu a)?
c) Przy jakim prawdopodobieństwie pomyłki świadka jego zeznanie zaczyna zmieniać decyzję klasyfikatora bayesowskiego przy stracie 0–1?
d) Załóżmy, że niesłuszne oczyszczenie spółki Niebieski kosztuje c razy więcej niż niesłuszne obwinienie. Korzystając z (2.11), wyznacz najmniejsze c, przy którym zeznanie „niebieska" prowadzi do decyzji Niebieski. Odnieś wynik do ramki „Dobry model, zły próg".

3. Metoda k najbliższych sąsiadów

W rozdziale 2 ustaliliśmy, czego szukamy. Przy stracie kwadratowej optymalnym predyktorem jest funkcja regresji $f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$, a przy stracie 0–1 – klasyfikator bayesowski, który wskazuje klasę o największym prawdopodobieństwie warunkowym $\eta_k(\mathbf{x})$. Obie wielkości odwołują się jednak do nieznanego rozkładu P. Ten rozdział przedstawia, jak oszacować je z danych niemal wprost z definicji.

Gdyby w próbie było wiele obserwacji o cechach dokładnie równych $\mathbf{x}$, moglibyśmy uśrednić ich wyniki i otrzymać próbkowy odpowiednik średniej warunkowej. Przy cechach ciągłych taka sytuacja praktycznie nie występuje: w zbiorze uczącym zwykle nie ma ani jednej obserwacji z $\mathbf{X} = \mathbf{x}$. Metoda k najbliższych sąsiadów (k-NN, ang. *k nearest neighbors*) zastępuje więc warunek „$\mathbf{X} = \mathbf{x}$” słabszym warunkiem „$\mathbf{X}$ blisko $\mathbf{x}$” i uśrednia wyniki obserwacji leżących najbliżej. Ta jedna idea daje zarówno metodę regresji, jak i klasyfikacji.

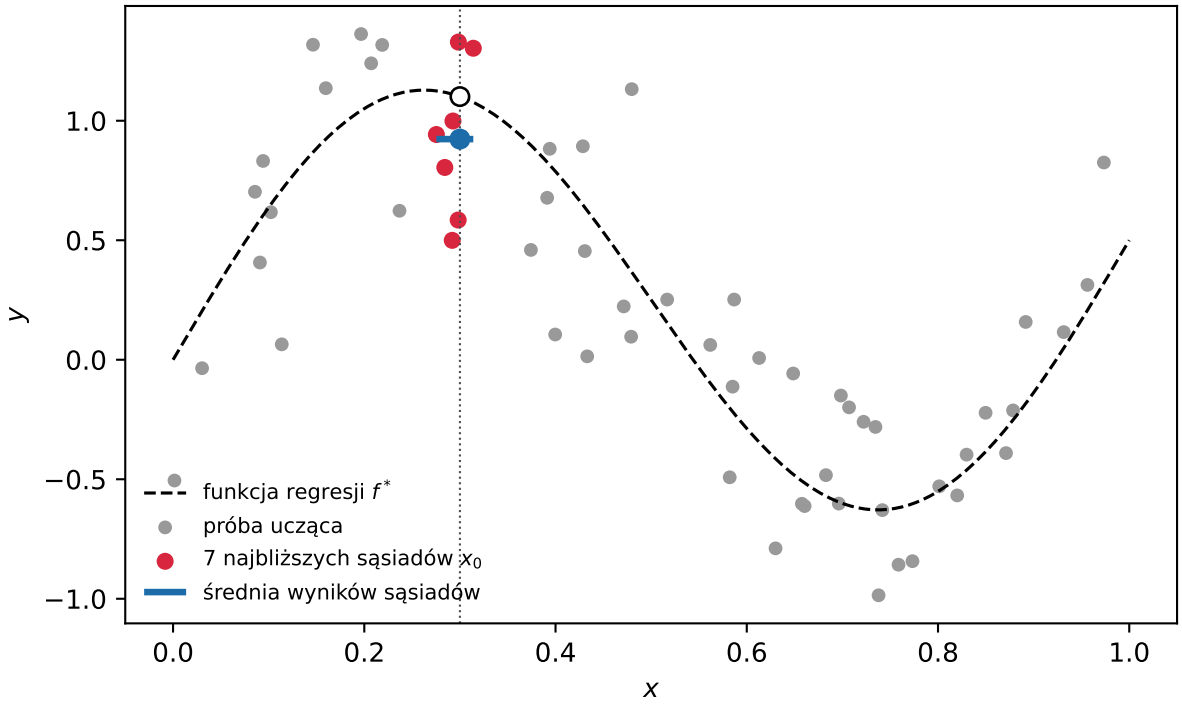
Metoda nie zakłada niczego o postaci f^* ani η_k, a mimo to przy rosnącej liczbie danych zbliża się do optimum z poprzedniego rozdziału. Zobaczymy jednak również, gdzie leży jej granica: w wielu wymiarach „blisko” przestaje znaczyć to, co podpowiada intuicja. Przy okazji k-NN poznamy też pojęcia, które wrócą przy każdej kolejnej metodzie: dobór stopnia wygładzenia, rolę skali cech i przekleństwo wymiarowości.

3.1. Uśrednianie lokalne

Zacznijmy od regresji z jedną cechą. W sekcji 1.9 przewidywaliśmy cenę mieszkania o metrażu x jako średnią cen k mieszkań o najbliższym metrażu. Rysunek 3.1 pokazuje ten sam zabieg na danych symulowanych, dla których funkcję regresji znamy.

Średnia wyników sąsiadów (niebieski punkt) jest bliska prawdziwej wartości $f^*(x_0)$ (pusty punkt), choć nie jest jej równa. Rozbieżność ma dwie przyczyny. Pierwsza to szum: siedem obserwacji to mało, by uśrednić losowe odchylenia wyników. Druga to szerokość otoczenia: sąsiedzi leżą w pewnym przedziale wokół x_0, a funkcja regresji nie jest na nim stała, więc uśredniamy wartości z jej okolicy, a nie z samego punktu x_0. Zwiększenie k osłabia pierwszy efekt i wzmacnia drugi. Do tego problemu wrócimy w sekcji 3.4.

Otoczenie punktu x_0 można wyznaczyć na dwa sposoby. Możemy ustalić promień h i uśredniać wszystkie obserwacje odległe od x_0 o mniej niż h. Możemy też ustalić liczbę obserwacji k i pozwolić, by promień wynikał z danych. Metoda k-NN wybiera drugą możliwość. Tam, gdzie danych jest dużo, otoczenie jest wąskie, a tam, gdzie mało – szerokie, ale nigdy puste. Przy ustalonym promieniu w obszarach o małej gęstości predykcja mogłaby opierać się na jednej obserwacji albo nie dać się wyznaczyć wcale.



Rysunek 3.1.: Uśrednianie lokalne. Szare punkty to próba ucząca, przerywana krzywa – prawdziwa funkcja regresji f^*. Aby przewidzieć wynik w punkcie x_0, wybieramy $k = 7$ obserwacji o cechach najbliższych x_0 (zaznaczone na czerwono) i uśredniamy ich wyniki. Pozioma kreska pokazuje tę średnią na przedziale zajmowanym przez sąsiadów.

3.2. Reguła k najbliższych sąsiadów

Niech $\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_n, y_n)\}$ będzie zbiorem uczącym, w którym każda obserwacja jest opisana p cechami liczbowymi, $\mathbf{x}_i \in \mathbb{R}^p$, a d – odległością w $\mathbb{R}^p$. Dla punktu $\mathbf{x}$ porządkujemy obserwacje uczące według odległości $d(\mathbf{x}_i, \mathbf{x})$ i przez $N_k(\mathbf{x})$ oznaczamy zbiór indeksów k obserwacji leżących najbliżej.

W regresji predykcją jest średnia wyników sąsiadów:

$$\hat{f}(\mathbf{x}) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x})} y_i. \tag{3.1}$$

Jest to próbkowy odpowiednik średniej warunkowej: średnią po rozkładzie $Y \mid \mathbf{X} = \mathbf{x}$ zastąpiliśmy średnią z próby po obserwacjach o cechach bliskich $\mathbf{x}$. Ta sama zamiana działa dla innych strat. Przy stracie absolutnej optimum jest mediana warunkowa (Twierdzenie 2.3), więc jej lokalnym oszacowaniem jest mediana wyników sąsiadów (Zadanie 3.4).

W klasyfikacji szacujemy prawdopodobieństwa klas. Za $\eta_c(\mathbf{x}) = \mathbb{P}(Y = c \mid \mathbf{X} = \mathbf{x})$ podstawiamy częstość klasy c wśród sąsiadów:

$$\hat{\eta}_c(\mathbf{x}) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x})} \mathbb{1}(y_i = c). \tag{3.2}$$

Jest to szczególny przypadek (3.1): częstość klasy to średnia zmiennej wskaźnikowej $\mathbb{1}(Y = c)$, a jej wartość oczekiwana warunkowa to właśnie $\eta_c(\mathbf{x})$. Klasyfikator k-NN wskazuje klasę najczęstszą wśród sąsiadów:

$$\hat{g}(\mathbf{x}) = \arg\max_c \ \hat{\eta}_c(\mathbf{x}). \tag{3.3}$$

Porównanie (3.3) z regułą bayesowską (2.8) pokazuje, że k-NN ma tę samą postać, tylko z nieznanym prawdopodobieństwem warunkowym zastąpionym jego oszacowaniem. Taką konstrukcję nazywamy **regułą podstawienia** (ang. *plug-in rule*). Pierwsze takie reguły nieparametryczne, w tym regułę najbliższego sąsiada, zaproponowali i zbadali Fix i Hodges (1951).

Warto zauważyć, czego k-NN **nie** robi. W sekcji 1.8 opisaliśmy trening jako minimalizację ryzyka empirycznego w klasie modeli $\mathcal{F}$. Metoda k-NN nie wybiera żadnej funkcji z ustalonej klasy i niczego nie minimalizuje. Naśladuje bezpośrednio postać optymalnego predyktora, wstawiając w miejsce średnich teoretycznych średnie lokalne. Ryzyko empiryczne pojawi się dopiero przy wyborze k.

Ponieważ (3.2) daje prawdopodobieństwa, a nie tylko etykiety, można je podstawić do dowolnej reguły decyzyjnej z sekcji 2.5: do progu kosztowego (2.11) albo do reguły Chowa z opcją odmowy. Oszacowanie jest jednak grube. Przyjmuje tylko $k + 1$ wartości $0, 1/k, \ldots, 1$, więc progi leżące między dwiema kolejnymi wielokrotnościami $1/k$ dają te same decyzje (Zadanie 3.5). Przy $k = 5$ progi 0,65 i 0,75 prowadzą do tej samej reguły, bo między nimi nie leży żadna wielokrotność $1/5$.

> **i** Remisy
>
> Reguła (3.3) nie zawsze wskazuje jedną klasę. Dla dwóch klas remis w głosowaniu jest możliwy tylko przy parzystym k, dlatego często wybiera się k nieparzyste. Przy większej liczbie klas remisu w ten sposób się nie uniknie. Druga możliwość to remis w odległościach: k-ty i $(k+1)$-szy sąsiad leżą w tej samej odległości od $\mathbf{x}$ i zbiór $N_k(\mathbf{x})$ nie jest wyznaczony jednoznacznie. Przy cechach ciągłych zdarza się to z prawdopodobieństwem zero, ale przy cechach dyskretnych bywa częste.

Implementacje rozstrzygają remisy umownie. W bibliotece scikit-learn przy remisie w głosowaniu wygrywa klasa występująca wcześniej w uporządkowanej liście klas, a przy remisie w odległościach wynik zależy od kolejności obserwacji w zbiorze uczącym. Dla teorii z sekcji 3.5 sposób rozstrzygania remisów nie ma znaczenia, dopóki nie faworyzuje systematycznie żadnej klasy.

3.3. Co znaczy „blisko”

Reguła k-NN wymaga odległości d, a jej wybór należy do modelu tak samo jak wybór k. Najczęściej używa się odległości euklidesowej

$$d(\mathbf{x}, \mathbf{x}') = \Big(\sum_{j=1}^{p} (x_j - x'_j)^2 \Big)^{1/2},$$

rzadziej odległości miejskiej (Manhattan) $\sum_j |x_j - x'_j|$. Obie są szczególnymi przypadkami odległości Minkowskiego $\big(\sum_j |x_j - x'_j|^q \big)^{1/q}$, dla $q = 2$ i $q = 1$.

Każda z tych odległości sumuje różnice w poszczególnych cechach i dlatego zależy od jednostek, w których cechy wyrażono. Rozważmy mieszkania opisane metrażem w m² i liczbą pokoi. Mieszkania o metrażach 50 i 52 m² mające 2 i 4 pokoje dzieli odległość euklidesowa $\sqrt{2^2 + 2^2} \approx 2{,}8$. Mieszkania o metrażach 50 i 56 m² z tą samą liczbą pokoi dzieli odległość 6. Pierwsza para jest więc „bliższa”, choć różni się układem mieszkania. Jeśli metraż zapiszemy w cm², różnica dwóch metrów kwadratowych urośnie do 20 000 i liczba pokoi przestanie mieć jakikolwiek wpływ na wybór sąsiadów. Zmiana jednostek, która nie zmienia żadnej informacji w danych, zmienia predykcje k-NN.

Skali cech nie da się więc pozostawić przypadkowi. Najprostszym rozwiązaniem jest **standaryzacja**: od każdej cechy odejmujemy jej średnią i dzielimy przez odchylenie standardowe, tak by wszystkie cechy miały porównywalny rozrzut. Jeśli x_{ij} oznacza wartość j-tej cechy i-tej obserwacji uczącej, to dla każdej cechy $j = 1, \ldots, p$ wyznaczamy

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^{n} x_{ij}, \qquad s_j = \Big(\frac{1}{n} \sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2 \Big)^{1/2}$$

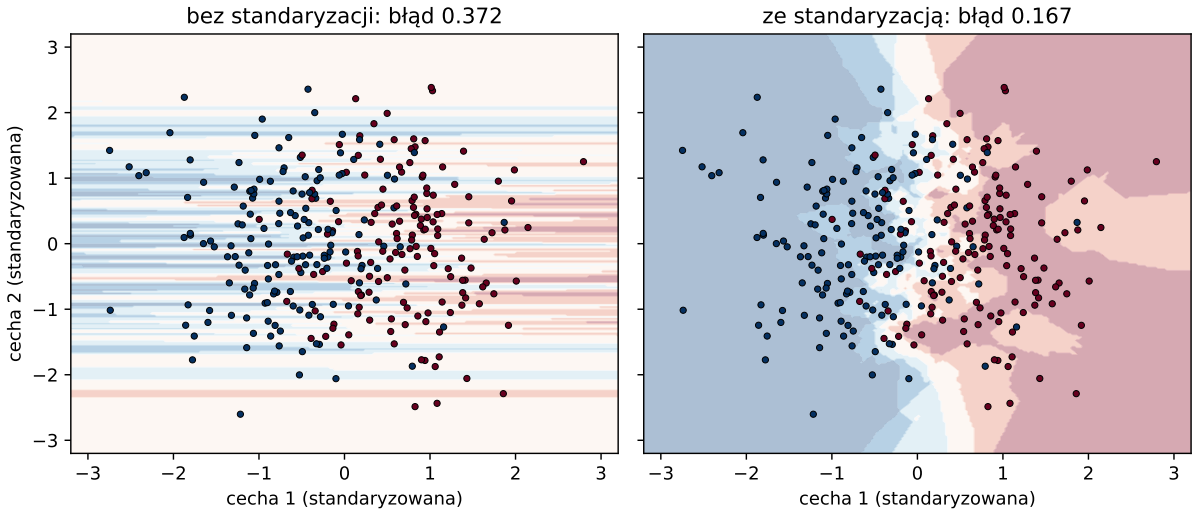
i zastępujemy cechę x_j dowolnego punktu $\mathbf{x}$ wartością

$$\tilde{x}_j = \frac{x_j - \bar{x}_j}{s_j}. \tag{3.4}$$

Po tym przekształceniu każda cecha ma w zbiorze uczącym średnią 0 i odchylenie standardowe 1, a odległości liczymy między punktami $\tilde{\mathbf{x}}$. Wielkości $\bar{x}_j$ i s_j wyznaczamy tylko na zbiorze uczącym i tymi samymi wartościami przekształcamy nowe obserwacje. Wyznaczenie ich na danych, na których oceniamy model, byłoby subtelną formą podglądania danych testowych. Wrócimy do tego w rozdziale 5.

Rysunek 3.2 pokazuje skutek pominięcia standaryzacji. Klasę wyznacza tylko pierwsza cecha, o odchyleniu standardowym rzędu 1. Druga cecha nie niesie informacji o klasie, ale jej odchylenie standardowe wynosi 100.

Bez standaryzacji o wyborze sąsiadów decyduje niemal wyłącznie cecha 2, która nie niesie informacji o klasie. Sąsiedzi są więc dobierani tak, jakby klasy nie było. Tło lewego panelu układa się w poziome pasy: oszacowanie $\hat{\eta}$ zmienia się wraz z cechą nieistotną, a prawie nie zmienia wraz



Rysunek 3.2.: Klasyfikator 5-NN bez standaryzacji (po lewej) i ze standaryzacją (po prawej), $n = 300$. Klasę wyznacza tylko cecha 1. Cecha 2 jest szumem o odchyleniu standardowym 100, więc bez standaryzacji to ona decyduje o tym, kto jest czyim sąsiadem. Oba panele narysowano w zmiennych standaryzowanych; tło pokazuje oszacowanie $\hat{\eta}(\mathbf{x})$, a w tytule podano błąd na dużym zbiorze testowym.

z istotną. Po standaryzacji obie cechy ważą tyle samo i granica decyzyjna wyraźnie zależy od cechy 1.

Prawy panel pokazuje jednak także drugi problem. Cecha 2 nadal jest szumem i nadal wpływa na odległości, choć już nie dominuje: granica nie jest pionowa, lecz poszarpana. Przy jednej takiej cesze strata jest niewielka, a błąd jest bliski błędowi bayesowskiemu $\Phi(-1) \approx 0{,}159$. Standaryzacja wyrównuje jednak tylko skale. Nie potrafi odróżnić cech istotnych od nieistotnych: z punktu widzenia odległości każda cecha jest równie ważna. Z każdą kolejną cechą nieistotną problem się nasila, co omówimy w sekcji 3.6.

Cechy jakościowe wymagają osobnej decyzji. Typowym rozwiązaniem jest zakodowanie każdej kategorii osobną zmienną zero-jedynkową. Odległość między dwiema obserwacjami zależy wtedy od liczby cech, w których się różnią (dla cech wyłącznie jakościowych jest to tzw. odległość Hamminga), a względną wagę cech jakościowych i ilościowych trzeba ustalić świadomie.

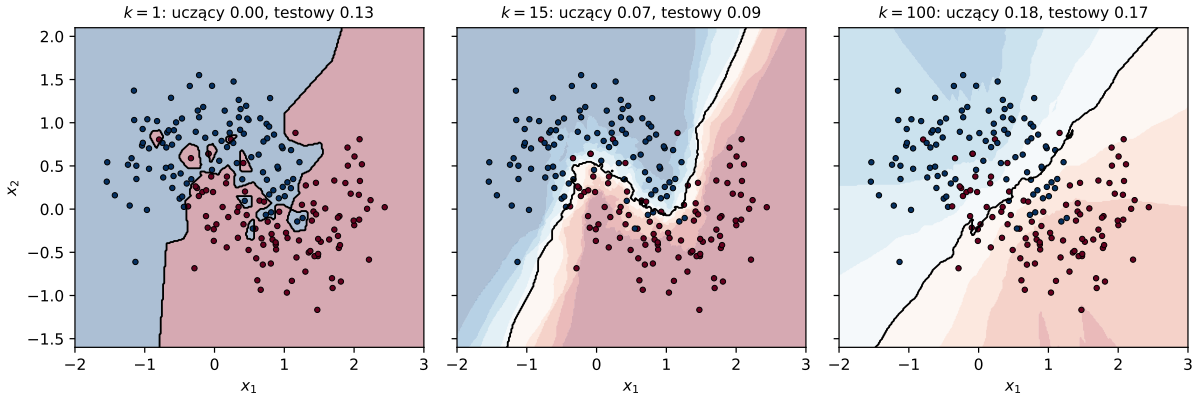
3.4. Rola liczby sąsiadów

Parametr k jest **hiperparametrem**: nie jest wyznaczany z danych w trakcie uczenia, tylko ustalany przed nim (por. Zadanie 1.5). Jego wpływ najłatwiej zrozumieć na przypadkach skrajnych.

Dla $k = 1$ predykcją jest wynik jednej, najbliższej obserwacji. Dla punktów ze zbioru uczącego najbliższym sąsiadem jest sam punkt, więc błąd na zbiorze uczącym wynosi zero (Zadanie 1.6). Nie wynika z tego nic dobrego o ryzyku. Predykcja w nowym punkcie przejmuje cały szum jednej obserwacji, a granica decyzyjna otacza każdy punkt uczący, także taki, którego klasa jest w swoim otoczeniu nietypowa.

Dla $k = n$ sąsiadami każdego punktu jest cały zbiór uczący. Predykcja nie zależy wtedy od $\mathbf{x}$: w regresji jest średnią wszystkich wyników, w klasyfikacji – klasą najczęstszą w próbie (Zadanie 3.3). Taki predyktor jest bardzo stabilny, ale ignoruje cechy.

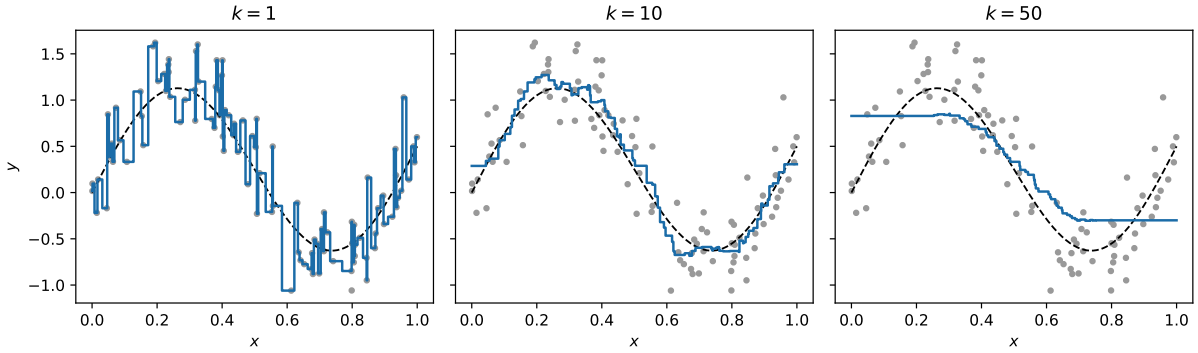
Między tymi skrajnościami k reguluje stopień **wygładzenia**. Rysunek 3.3 pokazuje to na klasycznym zbiorze dwóch półksiężyców.



Rysunek 3.3.: Klasyfikator k-NN dla $k = 1, 15, 100$ na zbiorze dwóch półksiężyców ($n = 200$, szum 0,30). Tło pokazuje oszacowanie $\hat{\eta}(\mathbf{x})$, czarna linia – granicę decyzyjną $\hat{\eta}(\mathbf{x}) = 1/2$. W tytułach podano błąd na zbiorze uczącym i na dużym zbiorze testowym z tego samego rozkładu.

Dla $k = 1$ granica jest poszarpana i tworzy wysepki wokół pojedynczych punktów. Błąd uczący wynosi zero, ale błąd testowy jest wyraźnie większy niż dla $k = 15$. Granica dla $k = 15$ oddaje kształt półksiężyców i nie reaguje na pojedyncze obserwacje. Dla $k = 100$, czyli połowy próby, otoczenia są tak szerokie, że sięgają do drugiego półksiężyca, granica się wypłaszcza, a błąd znów rośnie – tym razem zarówno testowy, jak i uczący.

To samo widać w regresji (Rysunek 3.4). Wykres predyktora (3.1) jest funkcją schodkową: zmienia wartość tylko wtedy, gdy zmienia się zbiór sąsiadów. Przy małym k schodki są gęste i podążają za szumem, przy dużym – predyktor spłaszcza funkcję regresji, najmocniej przy krańcach przedziału, gdzie sąsiedzi leżą tylko po jednej stronie punktu.



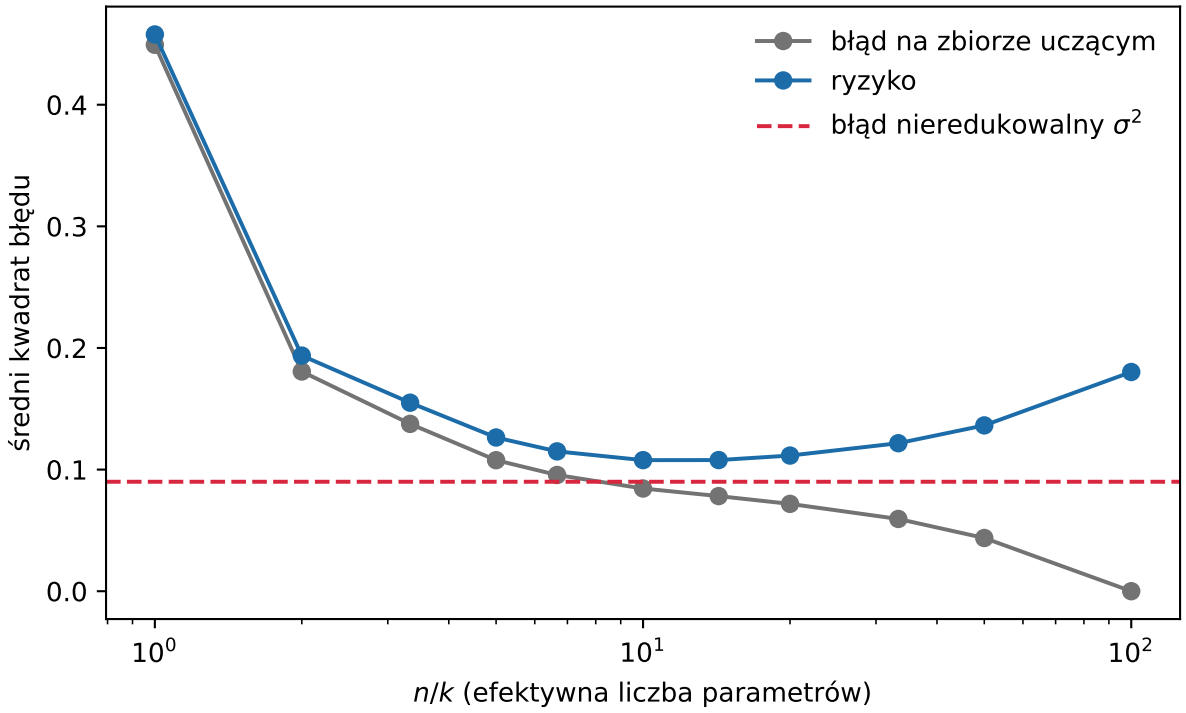
Rysunek 3.4.: Regresja k-NN dla $k = 1, 10, 50$ na tej samej próbie ($n = 100$). Przerywana krzywa to funkcja regresji f^*, niebieska – predyktor $\hat{f}$.

Zależność ryzyka od k można w tym przykładzie policzyć dokładnie, bo rozkład znamy. Cecha ma rozkład jednostajny na $[0, 1]$, więc rozkład ryzyka (2.7) przyjmuje postać

$$R(\hat{f}) = \int_0^1 \left(f^*(x) - \hat{f}(x)\right)^2 dx + \sigma^2,$$

a całkę liczymy numerycznie. Rysunek 3.5 zestawia tak policzone ryzyko z błędem na zbiorze uczącym. Oś poziomą opisaliśmy wielkością n/k. Przybliża ona liczbę grup obserwacji, w obrębie

których predyktor uśrednia, i bywa nazywana **efektywną liczbą parametrów** metody (Hastie i in. 2009, rozdz. 2.3). Na prawo od osi rośnie więc elastyczność modelu.



Rysunek 3.5.: Błąd na zbiorze uczącym i ryzyko regresji k-NN w zależności od n/k ($n = 100$). Ryzyko policzono dokładnie, całkując po znanym rozkładzie. Punkty to średnie z 50 niezależnych prób uczących. Przerywana linia to błąd nieredukowalny σ^2.

Błąd uczący maleje monotonicznie wraz ze wzrostem elastyczności i dla $k = 1$ spada do zera. Ryzyko zachowuje się inaczej: najpierw maleje, potem rośnie, a najmniejsze jest przy pośredniej wartości k. Na lewym krańcu wykresu predyktor jest zbyt sztywny, by odtworzyć kształt f^*, na prawym – odtwarza głównie szum. Krzywa w kształcie litery U to obraz kompromisu, który w rozdziale 4 rozłożymy na dwa składniki: obciążenie i wariancję.

Wykres prowadzi też do problemu praktycznego. Najlepsze k widzimy tylko dlatego, że znamy rozkład. W zastosowaniach mamy jedynie błąd uczący, który wskazuje zawsze $k = 1$, a więc wybór najgorszy z możliwych. Jak wybrać k, mając tylko dane, omówimy w rozdziale 5.

3.5. Zbieżność do optimum

W Rysunek 2.2 ryzyko klasyfikatora k-NN z $k = \sqrt{n}$ zbliżało się do błędu bayesowskiego wraz ze wzrostem próby. Nie był to przypadek wybranego rozkładu. Dla obu zadań, regresji i klasyfikacji, zachodzi następujący wynik (C. J. Stone 1977).

Twierdzenie 3.1 (Zgodność uniwersalna k-NN)**.** *Niech liczba sąsiadów $k = k_n$ zależy od liczności próby n tak, że*

$$k_n \to \infty \qquad \text{oraz} \qquad \frac{k_n}{n} \to 0 \qquad \text{przy } n \to \infty.$$

Wtedy dla ***każdego*** *rozkładu $(\mathbf{X}, Y)$:*

a) w klasyfikacji ryzyko klasyfikatora (3.3) dąży do błędu bayesowskiego, $\mathbb{E}[R(\hat{g}_n)] \to R(g^*)$;
b) w regresji, jeśli $\mathbb{E}[Y^2] < \infty$, ryzyko predyktora (3.1) przy stracie kwadratowej dąży do ryzyka funkcji regresji, $\mathbb{E}[R(\widehat{f}_n)] \to R(f^*)$.

Wartość oczekiwana $\mathbb{E}$ dotyczy tu losowości zbioru uczącego.

Dowód wymaga sporo techniki i go pomijamy; pełne ujęcie podają Devroye i in. (1996) dla klasyfikacji i Györfi i in. (2002) dla regresji. Rolę obu warunków łatwo jednak zrozumieć, wracając do dwóch źródeł błędu z Rysunek 3.1. Warunek $k_n \to \infty$ sprawia, że uśredniamy coraz więcej obserwacji, więc szum wyników przestaje mieć znaczenie. Warunek $k_n/n \to 0$ sprawia, że sąsiedzi stanowią coraz mniejszy ułamek próby, więc ich otoczenie kurczy się do punktu $\mathbf{x}$ i różnice między $f^*(\mathbf{x}_i)$ a $f^*(\mathbf{x})$ znikają. Wybór $k = \sqrt{n}$ spełnia oba warunki.

Siła twierdzenia leży w słowie „każdego". Nie zakładamy ciągłości funkcji regresji, postaci rozkładów klas ani istnienia gęstości. Metodę o tej własności nazywamy **uniwersalnie zgodną**. Jest to zarazem odpowiedź na wątpliwość z rozdziału 2: optimum, którego nie można wyznaczyć bez znajomości rozkładu, można osiągnąć w granicy, mając tylko dane.

Co się dzieje, gdy k nie rośnie? Dla reguły jednego najbliższego sąsiada odpowiedź podali Cover i Hart (1967).

Twierdzenie 3.2 (Twierdzenie Covera–Harta)**.** *Rozważmy dwie klasy i niech R^* oznacza błąd bayesowski. Przy łagodnych założeniach o regularności rozkładu ryzyko reguły jednego najbliższego sąsiada dąży przy $n \to \infty$ do granicy*

$$R_{1NN} = \mathbb{E}\big[\,2\,\eta(\mathbf{X})(1-\eta(\mathbf{X}))\big], \tag{3.5}$$

która spełnia

$$R^* \;\le\; R_{1NN} \;\le\; 2R^*(1-R^*) \;\le\; 2R^*. \tag{3.6}$$

Dowód. Podajemy szkic, pomijając część techniczną. Przy rosnącym n najbliższy sąsiad punktu $\mathbf{x}$ leży coraz bliżej $\mathbf{x}$, więc jego prawdopodobieństwo klasy zbliża się do $\eta(\mathbf{x})$. Etykieta sąsiada i nieznana etykieta punktu $\mathbf{x}$ są niezależnymi losowaniami z tego samego rozkładu dwupunktowego. Różnią się z prawdopodobieństwem

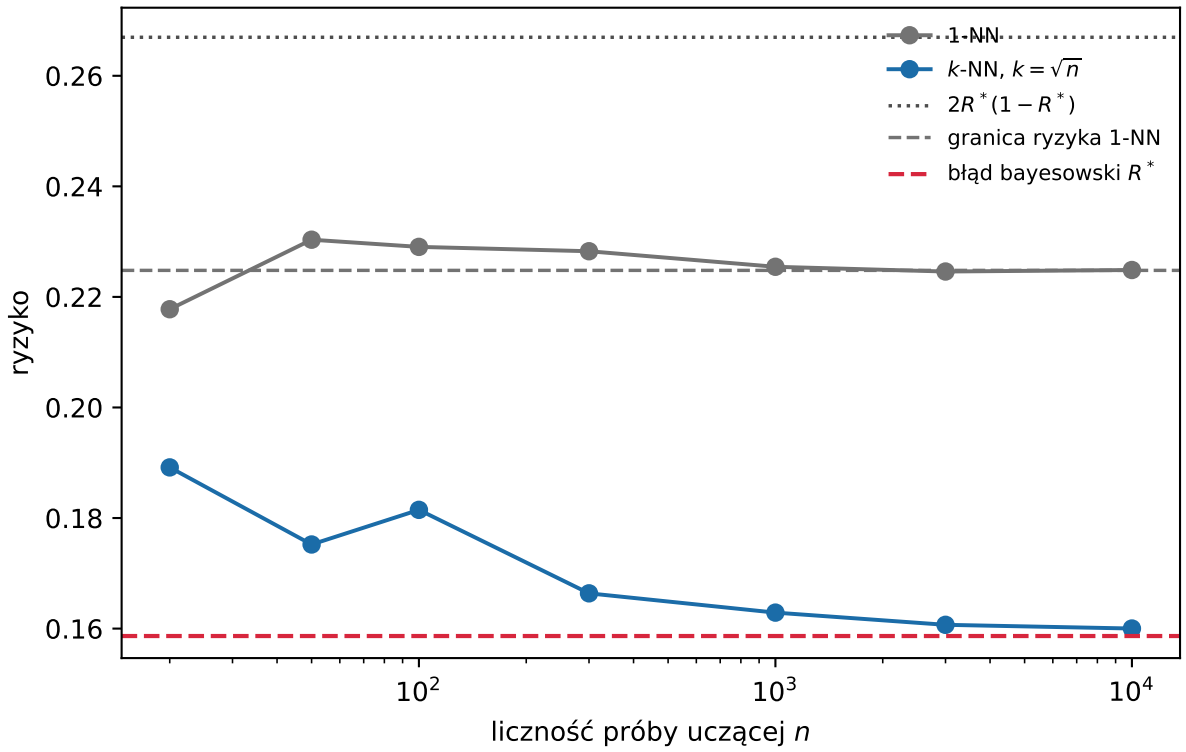
$$\eta(\mathbf{x})(1-\eta(\mathbf{x})) + (1-\eta(\mathbf{x}))\eta(\mathbf{x}) = 2\,\eta(\mathbf{x})(1-\eta(\mathbf{x})).$$

Uśrednienie po rozkładzie $\mathbf{X}$ daje (3.5).

Do nierówności oznaczmy $r(\mathbf{x}) = \min\big(\eta(\mathbf{x}), 1-\eta(\mathbf{x})\big)$; z (2.9) $R^* = \mathbb{E}[r(\mathbf{X})]$. Ponieważ $2\eta(1-\eta) = 2r(1-r)$, mamy $R_{1\mathrm{NN}} = \mathbb{E}[2r(\mathbf{X})(1-r(\mathbf{X}))]$. Lewa nierówność wynika z $r \le \frac{1}{2}$, czyli $2(1-r) \ge 1$. Dla prawej zauważmy, że $\mathbb{E}[2r(1-r)] = 2\mathbb{E}[r] - 2\mathbb{E}[r^2]$, a z nierówności Jensena $\mathbb{E}[r^2] \ge (\mathbb{E}[r])^2$, więc $R_{1\mathrm{NN}} \le 2R^* - 2(R^*)^2$. □ □

Wynik ma prostą interpretację. Reguła, która nie uśrednia niczego, myli się asymptotycznie co najwyżej dwa razy częściej niż reguła optymalna. Mówi się czasem, że połowa informacji potrzebnej do klasyfikacji zawarta jest w etykiecie najbliższego sąsiada. Zarazem 1-NN **nie jest** zgodna: jeśli $R^* > 0$, jej ryzyko nie spada do R^* nawet przy nieskończonej próbie, bo etykieta jednego sąsiada pozostaje losowa. Dopiero uśrednianie rosnącej liczby sąsiadów usuwa tę losowość.

Rysunek 3.6 sprawdza oba twierdzenia na rozkładzie z Rysunek 2.2: dwie równoliczne klasy $\mathcal{N}(\pm 1, 1)$, dla których $R^* = \Phi(-1) \approx 0{,}159$. Granicę (3.5) można tu policzyć numerycznie: wynosi około 0,225, a ograniczenie górne (3.6) – około 0,267.



Rysunek 3.6.: Ryzyko reguły 1-NN i reguły k-NN z $k=\sqrt{n}$ w zależności od liczności próby, dla dwóch klas $\mathcal{N}(\pm 1, 1)$. Ryzyko policzono dokładnie, całkując po znanym rozkładzie; punkty to średnie z 25 prób uczących. Linie poziome: błąd bayesowski R^*, granica ryzyka 1-NN z twierdzenia Covera–Harta i jej ograniczenie górne $2R^*(1-R^*)$.

Ryzyko 1-NN szybko stabilizuje się na poziomie granicy (3.5) i dalsze dane już go nie zmniejszają. Ryzyko reguły z $k = \sqrt{n}$ schodzi poniżej tej granicy i powoli zbliża się do R^*, zgodnie z Twierdzenie 3.1.

> ⚠ Zbieżność nie znaczy „szybko”
>
> Twierdzenie 3.1 mówi, dokąd zmierza ryzyko, ale nie mówi, jak szybko. Bez założeń o rozkładzie żadnej gwarancji tempa być nie może: dla dowolnej reguły klasyfikacji i dowolnie wolno malejącego ciągu istnieją rozkłady, dla których ryzyko zbliża się do R^* jeszcze wolniej (Devroye i in. 1996, rozdz. 7). Uniwersalność ma swoją cenę.
> Gdy funkcja regresji jest gładka, tempo da się oszacować, ale zależy ono od liczby cech p i maleje wraz z nią. W jednym wymiarze, jak na powyższym rysunku, kilkaset obserwacji wystarcza. W wielu wymiarach potrzebna liczba obserwacji rośnie tak szybko, że gwarancja asymptotyczna traci praktyczne znaczenie. Wyjaśnia to następna sekcja.

3.6. Przekleństwo wymiarowości

Metoda k-NN opiera się na założeniu, że w zbiorze uczącym są obserwacje **bliskie** punktowi $\mathbf{x}$, a więc takie, dla których f^* lub η mają podobne wartości. W jednym czy dwóch wymiarach to założenie jest łatwe do spełnienia. Wraz z liczbą cech p przestaje być spełnione, nawet przy bardzo dużych próbach. Zjawisko to nazywamy **przekleństwem wymiarowości** (ang. *curse of dimensionality*). Pokażemy trzy jego przejawy.

3.6.1. Otoczenie przestaje być lokalne

Niech cechy mają rozkład jednostajny w kostce $[0,1]^p$. Chcemy, aby otoczenie punktu obejmowało ułamek r wszystkich obserwacji, na przykład $r = 0{,}01$ przy $k = 10$ i $n = 1000$. Jeśli otoczenie jest mniejszą kostką o boku b, to obejmuje ułamek objętości b^p, więc

$$b = r^{1/p}. \tag{3.7}$$

W jednym wymiarze bok wynosi 0,01, czyli otoczenie jest naprawdę lokalne. W dwóch – 0,1. W dziesięciu wymiarach bok wynosi już $0{,}01^{1/10} \approx 0{,}63$: aby zebrać 1% danych, musimy objąć 63% zakresu **każdej** cechy. W stu wymiarach bok wynosi 0,955. „Otoczenie” obejmuje wtedy prawie cały zakres każdej zmiennej, a uśrednianie po nim przestaje być lokalne (Hastie i in. 2009, rozdz. 2.5).

Odwracając rachunek: aby otoczenie miało bok $b = 0{,}1$ i zawierało średnio 10 obserwacji, potrzebujemy $n = 10 \cdot 10^p$ obserwacji. Dla $p = 2$ to tysiąc, dla $p = 10$ – sto miliardów (Zadanie 3.7). Liczba potrzebnych obserwacji rośnie wykładniczo z wymiarem.

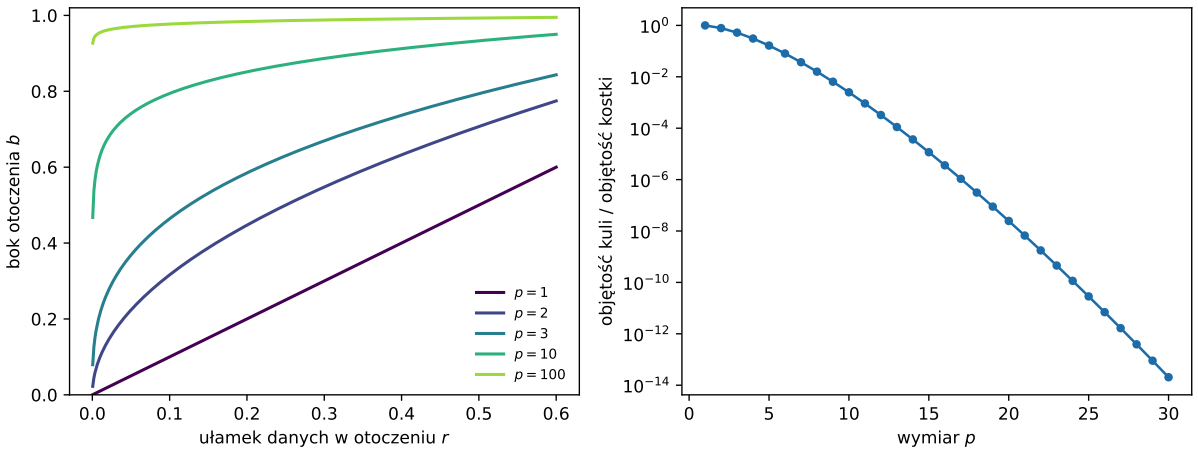
3.6.2. Objętość ucieka do narożników i brzegów

W jednym wymiarze odcinek $[-\frac{1}{2}, \frac{1}{2}]$ i „kula” o promieniu $\frac{1}{2}$ to ten sam zbiór. W dwóch wymiarach koło wpisane w kwadrat zajmuje $\pi/4 \approx 79\%$ jego pola, w trzech kula wpisana w sześcian – 52% objętości. W dziesięciu wymiarach ten udział spada do 0,25%, a w dwudziestu do około $2{,}5 \cdot 10^{-8}$ (Zadanie 3.6). Niemal cała objętość kostki leży w jej narożnikach, daleko od środka.

Podobnie jest z brzegami. W kuli o promieniu 1 warstwa przy powierzchni o grubości ε zajmuje ułamek $1 - (1-\varepsilon)^p$ objętości. Dla $\varepsilon = 0{,}05$ jest to 5% w jednym wymiarze, 40% w dziesięciu

i ponad 99% w stu. Punkty losowane jednostajnie leżą więc prawie wszystkie blisko brzegu, a predykcja w punkcie przy brzegu opiera się na sąsiadach leżących tylko po jednej jego stronie – jak na krańcach przedziału w Rysunek 3.4.

Rysunek 3.7 zestawia oba zjawiska.



Rysunek 3.7.: Geometria wysokich wymiarów. Po lewej: bok kostki-otoczenia, które obejmuje ułamek r danych jednostajnych w $[0,1]^p$, według wzoru $b = r^{1/p}$. Po prawej: ułamek objętości kostki zajmowany przez kulę wpisaną (oś pionowa w skali logarytmicznej).

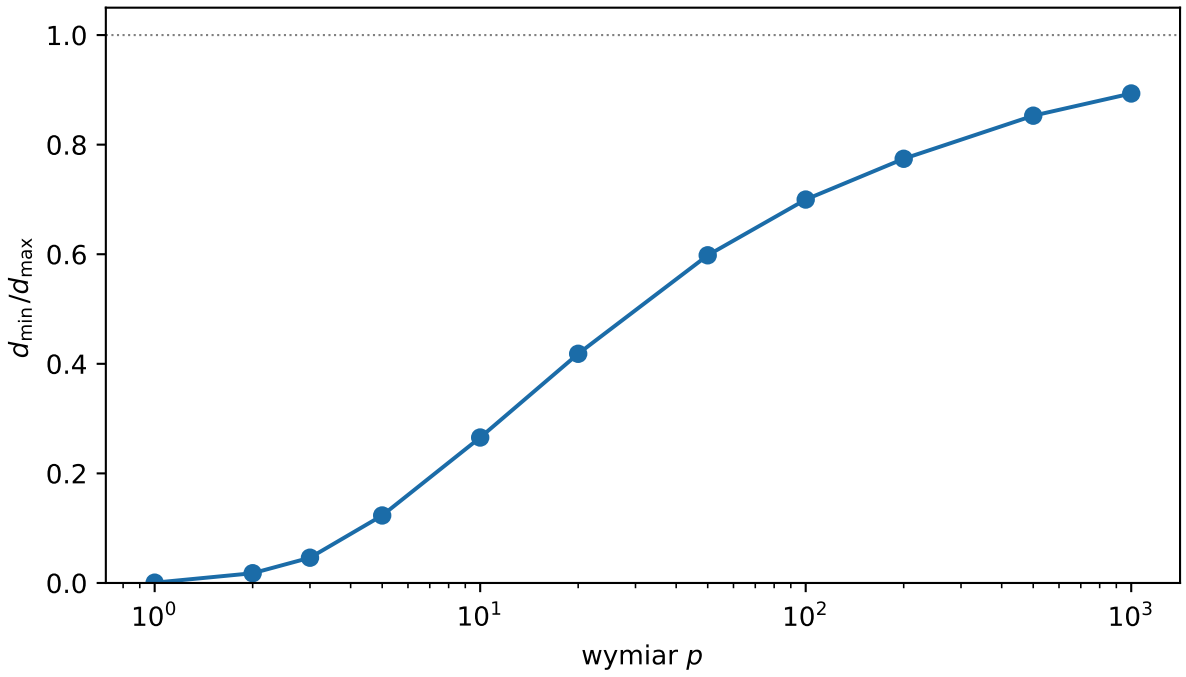
3.6.3. Odległości przestają się różnić

Trzeci przejaw jest dla k-NN najgroźniejszy. Wylosujmy n punktów jednostajnie z kostki $[0,1]^p$ i dla nowego punktu porównajmy odległość do najbliższego i najdalszego z nich. W jednym wymiarze najbliższy punkt jest setki razy bliżej niż najdalszy. Wraz ze wzrostem p iloraz tych odległości zbliża się do jedności (Rysunek 3.8): wszystkie punkty są od nowego punktu mniej więcej tak samo daleko. Zjawisko to, nazywane **koncentracją odległości**, zachodzi dla szerokiej klasy rozkładów, w których cechy nie są silnie zależne (Beyer i in. 1999). Gdy wszyscy są niemal równo odlegli, „najbliższy sąsiad" jest wyznaczony przez drobne, przypadkowe różnice i przestaje nieść informację o $\mathbf{x}$.

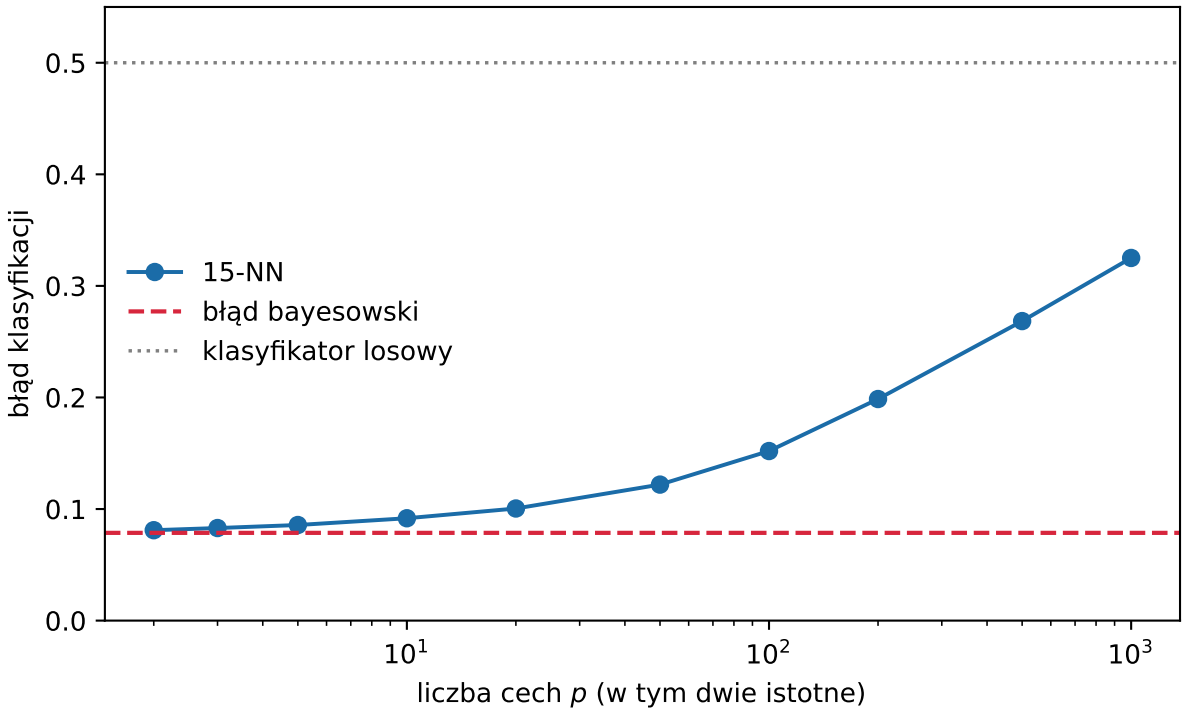
3.6.4. Skutek dla klasyfikacji

Połączmy te obserwacje z problemem z Rysunek 3.2. Weźmy dwie cechy istotne, w których klasy są dobrze rozdzielone, i dołączajmy do nich kolejne cechy będące czystym szumem, o tej samej skali. Klasyfikator bayesowski ignoruje szum, więc błąd bayesowski się nie zmienia. Metoda k-NN szumu zignorować nie potrafi, bo każda cecha wnosi swój wkład do odległości. Rysunek 3.9 pokazuje wynik.

Kilka cech szumowych prawie nie szkodzi. Przy stu cechach błąd jest już około dwukrotnie większy od bayesowskiego, a przy tysiącu pokonał ponad połowę drogi od błędu bayesowskiego do zgadywania. Tymczasem informacja potrzebna do dobrej klasyfikacji jest w danych cały czas obecna i zawsze w tych samych dwóch kolumnach. Metoda po prostu nie ma sposobu, by się o tym dowiedzieć.



Rysunek 3.8.: Koncentracja odległości. Dla $n = 1000$ punktów jednostajnych w $[0, 1]^p$ i losowego punktu zapytania pokazano iloraz odległości do najbliższego i najdalszego punktu (średnia z 50 punktów zapytania). Gdy iloraz zbliża się do 1, najbliższy i najdalszy sąsiad są od punktu niemal tak samo odlegli.



Rysunek 3.9.: Błąd klasyfikatora 15-NN w zależności od łącznej liczby cech p ($n = 500$, średnia z 5 prób uczących, błąd na zbiorze testowym liczności 10 000). Klasy różnią się tylko w dwóch pierwszych cechach, pozostałe $p - 2$ cech to szum. Linie poziome: błąd bayesowski, który nie zależy od cech nieistotnych, oraz błąd klasyfikatora losowego.

3.6.5. Co z tego wynika

Przekleństwo wymiarowości nie przeczy Twierdzenie 3.1. Twierdzenie nadal obowiązuje, ale liczba obserwacji, przy której jego teza staje się odczuwalna, rośnie z wymiarem tak szybko, że w praktyce jest nieosiągalna. Metoda, która nie zakłada nic o postaci zależności, musi każdą jej cechę „odkryć" w danych, a w wielu wymiarach na to brakuje danych.

Wyjściem są **założenia strukturalne**. Model liniowy zakłada, że wpływ każdej cechy jest stały i addytywny. Dzięki temu szacuje $p + 1$ współczynników zamiast wypełniać obserwacjami całą przestrzeń cech. Jeśli założenie jest w przybliżeniu prawdziwe, model liniowy wygrywa z k-NN już przy umiarkowanym p (James i in. 2023, rozdz. 3.5). Od tego zaczyna się część II książki (Rozdział 6).

Dlaczego k-NN mimo to bywa skuteczny

Rachunki tej sekcji dotyczą danych rozłożonych jednostajnie we wszystkich wymiarach. Dane rzeczywiste rzadko tak wyglądają. Cechy są zwykle silnie skorelowane, a obserwacje skupiają się w pobliżu struktur o znacznie mniejszym wymiarze niż p: zdjęcia twarzy zajmują znikomą część przestrzeni wszystkich obrazów o danej liczbie pikseli. O trudności zadania decyduje wtedy ten **wymiar wewnętrzny**, a nie liczba kolumn. Do wyznaczania takich struktur służą metody z części V (Rozdział 14).

3.7. Metoda k-NN w praktyce

Koszt obliczeniowy. Uczenie k-NN polega na zapamiętaniu zbioru uczącego i nic nie kosztuje. Koszt przenosi się na predykcję: naiwne wyszukanie sąsiadów jednego punktu wymaga obliczenia n odległości w p wymiarach, czyli czasu rzędu np. Przy dużych zbiorach stosuje się struktury danych przyspieszające wyszukiwanie, takie jak drzewa k-d i drzewa kul (w scikit-learn parametr `algorithm`). W małej liczbie wymiarów działają one znacznie szybciej niż przegląd wszystkich punktów, w dużej – z powodów opisanych w sekcji 3.6 – tracą przewagę. W bardzo dużych zbiorach używa się wyszukiwania przybliżonego, które zwraca punkty bliskie, choć niekoniecznie najbliższe.

Model to dane. W sekcji 1.9 zauważyliśmy, że opis dopasowanego modelu k-NN obejmuje cały zbiór uczący. Ma to konsekwencje praktyczne: model zajmuje tyle pamięci co dane, a jego udostępnienie oznacza udostępnienie danych, co bywa wykluczone, gdy dotyczą one osób.

Ważenie sąsiadów. We wzorze (3.1) wszyscy sąsiedzi ważą tyle samo, także ten, który ledwo zmieścił się w otoczeniu. Często stosowanym wariantem jest ważenie wyników odwrotnością odległości (w scikit-learn `weights="distance"`). Przy takim ważeniu punkt uczący pokrywający się z $\mathbf{x}$ przejmuje całą wagę, więc błąd na zbiorze uczącym znów wynosi zero niezależnie od k.

Typowe użycie. Standaryzację i klasyfikator łączymy w potok (`Pipeline`). Potok gwarantuje, że parametry standaryzacji wyznaczane są wyłącznie na danych przekazanych do `fit`, a przy predykcji stosowane bez zmian. Poniższy przykład porównuje oba warianty na zbiorze danych o nowotworach piersi dołączonym do scikit-learn: 569 obserwacji i 30 cech mierzonych w bardzo różnych skalach.

```
rozrzut cech (odchylenia standardowe): od 0.00231 do 577
bez standaryzacji: błąd na zbiorze testowym 0.076
ze standaryzacją : błąd na zbiorze testowym 0.064
```

```
[[1.  0. ]
 [0.1 0.9]
 [1.  0. ]]
```

Metoda `predict_proba` zwraca oszacowania (3.2), które można podstawić do reguły kosztowej zamiast używać domyślnego progu 1/2. Wartość $k = 10$ przyjęliśmy tu arbitralnie. Jak ją wybrać na podstawie danych i jak rzetelnie ocenić błąd tak wybranego modelu, omówimy w rozdziale 5.

Uwagi bibliograficzne

Metodę k najbliższych sąsiadów w ujęciu bliskim temu rozdziałowi przedstawiają James i in. (2023, rozdz. 2.2) oraz Hastie i in. (2009, rozdz. 2.3). W drugiej z tych książek można też znaleźć analizę przekleństwa wymiarowości dla metod lokalnych (Hastie i in. 2009, rozdz. 2.5) i omówienie klasyfikatorów k-NN w zastosowaniach (Hastie i in. 2009, rozdz. 13.3). Porównanie regresji k-NN z regresją liniową w zależności od liczby cech zawiera James i in. (2023, rozdz. 3.5).

Ścisłą teorię reguł najbliższych sąsiadów w klasyfikacji, z dowodami twierdzenia Stone'a i twierdzenia Covera–Harta oraz wynikami o braku uniwersalnego tempa zbieżności, wykładają Devroye i in. (1996). Analogiczną teorię dla regresji, łącznie z tempem zbieżności dla funkcji gładkich i jego zależnością od wymiaru, podają Györfi i in. (2002).

Regułę najbliższego sąsiada wprowadzili w raporcie z 1951 roku Fix i Hodges (1951), którzy wykazali też jej zgodność przy rosnącym k. Raport przedrukowano w 1989 roku w *International Statistical Review*. Cover i Hart (1967) udowodnili ograniczenie przez podwojony błąd bayesowski, a C. J. Stone (1977) – zgodność uniwersalną szerokiej klasy reguł uśredniania lokalnego, obejmującej k-NN. Zjawisko koncentracji odległości i jego skutki dla wyszukiwania najbliższych sąsiadów badają Beyer i in. (1999).

Zadania

Zadanie 3.1. Zbiór uczący składa się z sześciu obserwacji o dwóch cechach:

i	x_1	x_2	klasa	y
1	1	1	A	2,0
2	2	1	A	2,5
3	4	3	B	5,0
4	5	4	B	6,5
5	2	3	B	4,0
6	3	2	A	3,5

a) Dla punktu $\mathbf{x} = (1, 3)$ wyznacz odległości euklidesowe do wszystkich obserwacji i zbiory $N_1(\mathbf{x})$, $N_3(\mathbf{x})$.
b) Podaj predykcję klasy dla $k = 1$ i $k = 3$ oraz oszacowanie $\hat{\eta}_{\mathrm{B}}(\mathbf{x})$ dla $k = 3$.
c) Traktując y jako zmienną wynikową, podaj predykcję regresji k-NN dla $k = 1$ i $k = 3$.
d) Powtórz punkt a) dla odległości miejskiej. Czy zbiory sąsiadów się zmieniają? Jak rozstrzygnąć ewentualny remis?

Zadanie 3.2. W zbiorze z Zadanie 3.1 cecha x_2 jest mierzona w metrach. Przelicz ją na centymetry i powtórz punkt b) tego zadania. Następnie standaryzuj obie cechy (średnie i odchylenia wyznacz na zbiorze uczącym) i powtórz obliczenia raz jeszcze. Która z trzech wersji daje „właściwych" sąsiadów? Podaj przykład sytuacji, w której standaryzacja pogarsza wynik k-NN. (Wskazówka: Rysunek 3.2.)

Zadanie 3.3. Wykaż, że dla $k = n$ regresja k-NN przewiduje w każdym punkcie średnią $\bar{y}$, a klasyfikacja – klasę najczęstszą w próbie. Dla dwóch klas z $\pi = \mathbb{P}(Y = 1) > \frac{1}{2}$ wyznacz granicę ryzyka tego klasyfikatora przy $n \to \infty$ i porównaj ją z błędem bayesowskim, zapisanym przez η. Kiedy oba błędy są równe? Odnieś wynik do Zadanie 2.4.

Zadanie 3.4. Zmodyfikuj przykład z Rysunek 3.4 tak, aby 10% wyników zastąpić wartościami odstającymi, na przykład $y_i + 5$. Zaimplementuj regresję k-NN, która zamiast średniej zwraca medianę wyników sąsiadów, i porównaj ją z (3.1) dla $k = 15$: na wykresie oraz pod względem ryzyka przy stracie kwadratowej i absolutnej, liczonego względem rozkładu bez obserwacji odstających. Wyjaśnij wynik, odwołując się do Twierdzenie 2.3.

Zadanie 3.5. Klasyfikator k-NN z $k = 5$ zwraca oszacowania $\hat{\eta}(\mathbf{x}) \in \{0, \frac{1}{5}, \dots, 1\}$.

a) Pominięcie przypadku pozytywnego kosztuje dziesięć razy więcej niż fałszywy alarm. Korzystając z (2.11), wyznacz próg i zapisz otrzymaną regułę w postaci „klasa 1, jeśli wśród pięciu sąsiadów jest co najmniej j przypadków pozytywnych".
b) Ile różnych reguł decyzyjnych można otrzymać, zmieniając próg w przedziale $(0, 1)$? Wskaż przedziały progów dających tę samą regułę.
c) Jak zmienia się odpowiedź dla $k = 50$? Jaki wniosek płynie stąd dla doboru k, gdy oszacowania $\hat{\eta}$ mają służyć regule kosztowej lub regule Chowa?

Zadanie 3.6. Objętość kuli o promieniu ρ w $\mathbb{R}^p$ wynosi $V_p(\rho) = \dfrac{\pi^{p/2}}{\Gamma(p/2+1)}\,\rho^p$.

a) Wyznacz ułamek objętości kostki $[-\frac{1}{2}, \frac{1}{2}]^p$ zajmowany przez kulę wpisaną i sprawdź wartości podane w sekcji 3.6 dla $p = 2, 3, 10$.
b) Korzystając ze wzoru Stirlinga, wykaż, że ten ułamek dąży do zera przy $p \to \infty$, i to szybciej niż dowolny ciąg geometryczny.
c) Wyznacz odległość od środka kostki do jej wierzchołka. Jak zmienia się ona z p w porównaniu z promieniem kuli wpisanej?

Zadanie 3.7. Dane mają rozkład jednostajny w $[0, 1]^p$.

a) Ilu obserwacji potrzeba, aby kostka o boku 0,1 wokół punktu zawierała średnio 10 obserwacji? Podaj wynik dla $p = 1, 2, 5, 10$.
b) Przy $n = 10^6$ i $k = 10$ wyznacz bok otoczenia (3.7) dla $p = 2, 10, 50$.
c) Zakładając, że funkcja regresji spełnia $|f^*(\mathbf{x}) - f^*(\mathbf{x}')| \le L \max_j |x_j - x'_j|$, oszacuj z góry błąd, jaki wnosi do predykcji samo uśrednianie po otoczeniu o boku b. Co ten rachunek mówi o k-NN dla $p = 50$?

Zadanie 3.8. Rozważ dwie równoliczne klasy $\mathcal{N}(-\mu, 1)$ i $\mathcal{N}(\mu, 1)$ na prostej.

a) Wyznacz $\eta(x)$ i wykaż, że $2\eta(x)(1 - \eta(x)) = \dfrac{1}{2\cosh^2(\mu x)}$. (Wskazówka: zapisz η przez funkcję logistyczną.)

b) Policz numerycznie granicę (3.5) oraz ograniczenie $2R^*(1-R^*)$ dla $\mu \in \{0{,}25;\ 0{,}5;\ 1;\ 2;\ 3\}$. Dla jakich μ ograniczenie jest bliskie granicy, a dla jakich luźne?
c) Sprawdź wynik symulacyjnie, modyfikując kod Rysunek 3.6.
d) Podaj rozkład, dla którego w (3.6) zachodzi równość $R_{1\mathrm{NN}} = 2R^*(1 - R^*)$. (Wskazówka: kiedy nierówność Jensena jest równością?)

4. Kompromis obciążenie–wariancja

W rozdziale 3 zobaczyliśmy krzywą w kształcie litery U (Rysunek 3.5). Gdy zmniejszaliśmy liczbę sąsiadów k, błąd na zbiorze uczącym malał aż do zera, a ryzyko najpierw malało, potem rosło. Wyjaśniliśmy to wtedy słownie: przy dużym k predyktor jest zbyt sztywny, by odtworzyć kształt funkcji regresji, a przy małym odtwarza głównie szum. Ten rozdział nadaje temu wyjaśnieniu postać wzoru.

Punktem wyjścia jest rozkład ryzyka (2.7) z rozdziału 2. Przy stracie kwadratowej ryzyko predyktora f jest sumą błędu redukowalnego, czyli średniego kwadratu odległości f od funkcji regresji f^*, i błędu nieredukowalnego. Tamten rozkład dotyczył jednak ustalonej funkcji f. Predyktor, którego używamy w praktyce, ustalony nie jest: wyznaczamy go ze zbioru uczącego, a ten jest losowy. Inny zbiór uczący dałby inny predyktor. Uwzględnienie tej losowości rozbija błąd redukowalny na dwie części. **Obciążenie** mówi, jak daleko od f^* leży predyktor przeciętny, uśredniony po możliwych zbiorach uczących. **Wariancja** mówi, jak bardzo predyktor zmienia się od jednego zbioru uczącego do drugiego. Są to dwa źródła błędu, które opisaliśmy przy rysunku 3.1: szerokość otoczenia i szum w wynikach sąsiadów.

Pokażemy, że kompromis między tymi składnikami nie jest własnością metody k-NN. Tak samo zachowuje się regresja wielomianowa, w której elastyczność reguluje stopień wielomianu. Rozkład wyjaśnia też, dlaczego najlepsza elastyczność zależy od liczności próby i dlaczego w wielu wymiarach tak trudno opanować obciążenie, nie płacąc wariancją. Wypełnimy przy tym zapowiedź z rozdziału 2: rozłożymy błąd redukowalny na część wynikającą ze zbyt ubogiej klasy modeli i część wynikającą ze skończoności próby, a potem porównamy ten rozkład z rozkładem na obciążenie i wariancję.

Prawie cały rozdział dotyczy regresji ze stratą kwadratową. Tylko dla niej rozkład na obciążenie i wariancję ma prostą postać sumy. Co zostaje z niego w klasyfikacji, omówimy w sekcji 4.9.

4.1. Błąd uczący a ryzyko

W sekcji 1.8 zauważyliśmy, że dostatecznie bogata klasa modeli pozwala niemal zapamiętać zbiór uczący, łącznie z przypadkowymi odchyleniami wyników. Aby zbadać to zjawisko, potrzebujemy metod, których elastyczność można płynnie regulować. Jedną już znamy: w metodzie k-NN elastyczność rośnie, gdy k maleje, a miarą tej elastyczności jest efektywna liczba parametrów n/k.

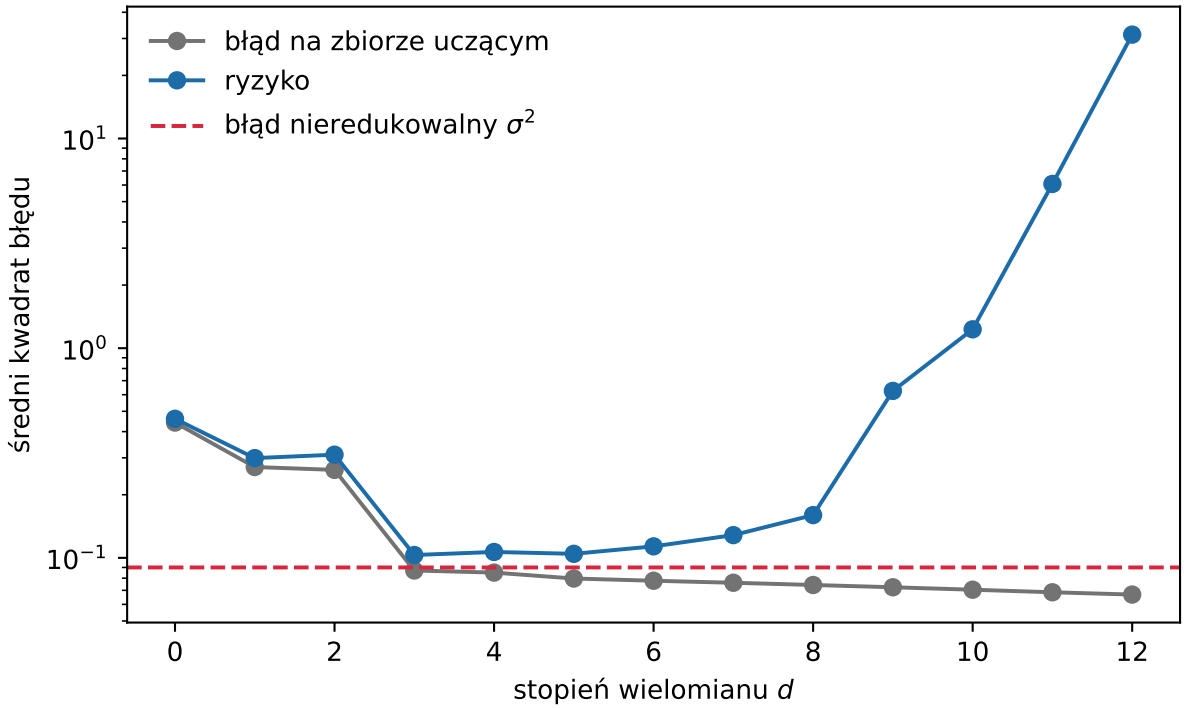
Drugą jest **regresja wielomianowa**. Dla cechy $x \in \mathbb{R}$ i ustalonego stopnia d rozważamy klasę wielomianów

$$\mathcal{F}_d = \{\, f(x) = \beta_0 + \beta_1 x + \cdots + \beta_d x^d : \beta_0, \ldots, \beta_d \in \mathbb{R} \,\}$$

i wybieramy z niej predyktor metodą najmniejszych kwadratów, czyli minimalizujemy ryzyko empiryczne przy stracie kwadratowej (1.10). Jak to zrobić rachunkowo, omawia sekcja 6.2; tu korzystamy z gotowej funkcji biblioteki NumPy. Przy ustalonym d jest to metoda parametryczna z $d + 1$ współczynnikami, a stopień d pełni rolę hiperparametru, podobnie jak k w metodzie k-NN.

Klasy wielomianów są zagnieżdżone: $\mathcal{F}_0 \subset \mathcal{F}_1 \subset \mathcal{F}_2 \subset \cdots$, bo wielomian stopnia d jest też wielomianem stopnia $d+1$ ze współczynnikiem $\beta_{d+1} = 0$. Minimum ryzyka empirycznego po większym zbiorze nie może być większe niż po mniejszym, więc **błąd na zbiorze uczącym nie rośnie wraz z** d – dla każdej próby, a nie tylko przeciętnie. Gdy $d+1$ osiąga liczbę różnych wartości x_i w próbie, istnieje wielomian przechodzący przez wszystkie punkty i błąd uczący spada do zera.

Rysunek 4.1 pokazuje błąd uczący i ryzyko dla wielomianów stopni od 0 do 12, dopasowanych do $n = 50$ obserwacji. Dane pochodzą z tego samego rozkładu co w rozdziale 3: X ma rozkład jednostajny na $[0, 1]$, $Y = f^*(X) + \varepsilon$, gdzie $f^*(x) = \sin(2\pi x) + x/2$, a szum ma odchylenie standardowe $\sigma = 0{,}3$. Ryzyko liczymy dokładnie, całkując po znanym rozkładzie, tak jak na rysunku 3.5.



Rysunek 4.1.: Błąd na zbiorze uczącym i ryzyko regresji wielomianowej w zależności od stopnia wielomianu d ($n = 50$). Ryzyko policzono dokładnie, całkując po znanym rozkładzie; punkty to średnie z 1000 niezależnych prób uczących. Oś pionowa w skali logarytmicznej. Przerywana linia to błąd nieredukowalny σ^2.

Obraz jest taki sam jak na rysunku 3.5, choć metoda jest zupełnie inna. Czytelnik, który rozwiązał zadanie 1.14, widział go już na własnej symulacji. Błąd uczący maleje monotonicznie i schodzi poniżej błędu nieredukowalnego, czego ryzyko nie może zrobić nigdy. Ryzyko najpierw spada, osiąga minimum przy stopniu 3–5, a potem rośnie, i to gwałtownie: przy $d = 12$ jest o rzędy wielkości większe niż w minimum.

Dwa krańce wykresu mają swoje nazwy. Model zbyt sztywny, jak prosta ($d = 1$), ma duży błąd uczący i duże ryzyko, przy czym obie wielkości są sobie bliskie. Mówimy wtedy o **niedopasowaniu** (ang. *underfitting*): model nie jest w stanie odtworzyć zależności nawet na danych, które widział. Model zbyt elastyczny ma mały błąd uczący i duże ryzyko. To **nadmierne dopasowanie** (ang. *overfitting*), o którym mówiliśmy w sekcji 1.8: model dopasował się do przypadkowych odchyleń w próbie, których nie da się przewidzieć dla nowych obiektów.

Różnicę między ryzykiem a błędem uczącym nazywa się czasem **optymizmem** błędu uczącego

(Hastie i in. 2009, rozdz. 7.4). Bierze się ona stąd, że predykcja $\hat{f}(x_i)$ zależy od wyniku y_i, z którym ją porównujemy: model był dobierany tak, by wypadać dobrze właśnie na tych obserwacjach. Dla metody k-NN optymizm da się policzyć dokładnie (Zadanie 4.4). Błąd uczący nie mówi więc, dlaczego ryzyko po prawej stronie wykresu rośnie. Aby to zrozumieć, musimy zobaczyć, jak dopasowany predyktor zależy od zbioru uczącego.

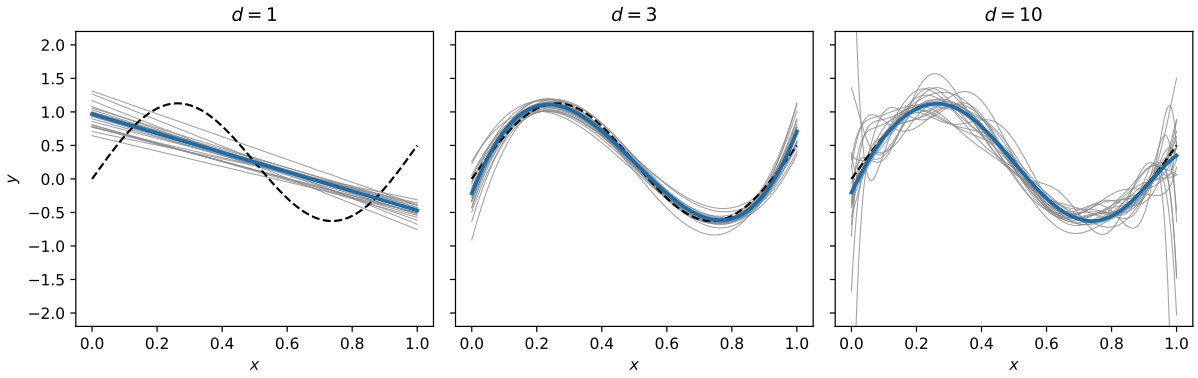
4.2. Zbiór uczący jest losowy

W sekcji 1.5 przyjęliśmy, że obserwacje $(\mathbf{X}_1, Y_1), \ldots, (\mathbf{X}_n, Y_n)$ są niezależnymi losowaniami z rozkładu P. Zbiór uczący $\mathcal{D}$ jest więc losowy, a wraz z nim losowy jest wyznaczony z niego predyktor. Będziemy go oznaczać $\hat{f}_{\mathcal{D}}$, gdy zechcemy tę zależność podkreślić. W każdym ustalonym punkcie $\mathbf{x}$ wartość $\hat{f}_{\mathcal{D}}(\mathbf{x})$ jest zmienną losową: jej losowość pochodzi wyłącznie z losowania zbioru uczącego.

Średnią i wariancję względem tego losowania oznaczamy $\mathbb{E}_{\mathcal{D}}$ i $\mathrm{Var}_{\mathcal{D}}$. Szczególną rolę odgrywa **predyktor przeciętny**

$$\bar{f}(\mathbf{x}) = \mathbb{E}_{\mathcal{D}}[\hat{f}_{\mathcal{D}}(\mathbf{x})], \tag{4.1}$$

czyli średnia predykcji w punkcie $\mathbf{x}$ po wszystkich zbiorach uczących liczności n, jakie mogliśmy wylosować. Jest to konstrukcja myślowa: w praktyce mamy jeden zbiór uczący i jeden predyktor. W symulacji, gdzie rozkład P znamy, możemy jednak wylosować wiele zbiorów uczących i zobaczyć, jak bardzo różnią się dopasowane do nich predyktory. Robi to Rysunek 4.2.



Rysunek 4.2.: Wielomiany stopni $d = 1, 3, 10$ dopasowane do 20 niezależnych prób uczących liczności $n = 50$ (cienkie linie). Gruba niebieska linia to predyktor przeciętny $\bar{f}$, oszacowany z 1000 prób, przerywana – funkcja regresji f^*.

Trzy panele pokazują trzy różne sytuacje. Proste ($d = 1$) dopasowane do różnych prób są do siebie podobne, ale wszystkie mijają się z funkcją regresji w ten sam sposób. Ich średnia również jest prostą i również nie oddaje kształtu f^*. Błąd jest **systematyczny**: nie zniknąłby, nawet gdybyśmy uśrednili nieskończenie wiele dopasowań. Wielomiany stopnia 10 zachowują się odwrotnie. Ich średnia niemal pokrywa się z f^*, ale pojedyncze dopasowania rozchodzą się w różne strony, najmocniej przy krańcach przedziału, gdzie danych jest mało, a wielomian wysokiego stopnia łatwo „ucieka”. Błąd jest **losowy**: zależy od tego, jaki zbiór uczący akurat wylosowaliśmy. Wielomiany stopnia 3 leżą pośrodku: ich średnia jest bliska f^*, a rozrzut niewielki.

Ryzyko na rysunku 4.1 łączy oba rodzaje błędu. Aby je rozdzielić, potrzebujemy dwóch pojęć z teorii estymacji.

4.3. Obciążenie i wariancja estymatora

Zacznijmy od sytuacji prostszej niż predykcja: od szacowania jednej liczby.

Definicja 4.1 (Obciążenie i błąd średniokwadratowy)**.** Niech $\hat{\theta}$ będzie estymatorem nieznanej liczby θ, czyli zmienną losową obliczaną z próby. Jego **obciążeniem** (ang. *bias*) nazywamy różnicę

$$\mathrm{b}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta,$$

a jego **błędem średniokwadratowym** (ang. *mean squared error*) – wielkość $\mathrm{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2]$. Estymator o zerowym obciążeniu nazywamy **nieobciążonym**.

Obciążenie mówi, gdzie estymator trafia przeciętnie, wariancja $\operatorname{Var}\hat{\theta}$ – jak bardzo jego wartości rozrzucone są wokół tej przeciętnej. Błąd średniokwadratowy łączy oba składniki:

$$\mathrm{MSE}(\hat{\theta}) = \mathrm{b}(\hat{\theta})^2 + \operatorname{Var}\hat{\theta}. \tag{4.2}$$

Jest to ta sama tożsamość, którą wyprowadziliśmy w dowodzie twierdzenia 2.2 jako (2.5): średni kwadrat odległości zmiennej losowej od stałej to jej wariancja plus kwadrat odległości jej średniej od tej stałej. Wystarczy zapisać $\hat{\theta} - \theta = (\hat{\theta} - \mathbb{E}[\hat{\theta}]) + (\mathbb{E}[\hat{\theta}] - \theta)$ i zauważyć, że iloczyn mieszany ma średnią zero.

Wzór (4.2) ma konsekwencję, która w pierwszej chwili zaskakuje: **estymator obciążony może być lepszy od nieobciążonego**, jeśli niewielkie obciążenie kupuje dużą redukcję wariancji. Rozważmy próbę $Y_1, \ldots, Y_n$ z rozkładu o średniej μ i wariancji σ^2. Średnia z próby $\bar{Y}$ jest nieobciążonym estymatorem μ o wariancji σ^2/n. Porównajmy ją z rodziną estymatorów **ściągających** $\hat{\mu}_c = c\bar{Y}$, gdzie $c \in [0,1]$. Ściąganie do zera wprowadza obciążenie $(c-1)\mu$ i zmniejsza wariancję do $c^2\sigma^2/n$, więc

$$\mathrm{MSE}(c\bar{Y}) = (1-c)^2\mu^2 + c^2\,\frac{\sigma^2}{n}.$$

Minimum tej funkcji kwadratowej leży w punkcie $c^* = \mu^2/(\mu^2 + \sigma^2/n)$, który jest zawsze mniejszy od 1 (Zadanie 4.1). Dla $\mu = 1$, $\sigma = 3$ i $n = 10$ mamy $c^* \approx 0{,}53$, a błąd średniokwadratowy spada z 0,9 dla $\bar{Y}$ do około 0,47. Obciążony estymator jest prawie dwa razy dokładniejszy.

Przykład ma oczywistą słabość: c^* zależy od nieznanego μ. Pokazuje jednak zasadę, która wróci wielokrotnie. Regresja grzbietowa w rozdziale 7 ściąga współczynniki modelu liniowego do zera właśnie po to, by zmniejszyć wariancję kosztem obciążenia, a w rozdziale 10 zobaczymy, że takie ściąganie wynika naturalnie z rozkładu a priori. Ile ściągać, trzeba wtedy ustalić na podstawie danych, czym zajmuje się rozdział 5.

Wróćmy do predykcji. Ustalmy punkt $\mathbf{x}_0$ i potraktujmy predykcję $\hat{f}_{\mathcal{D}}(\mathbf{x}_0)$ jako estymator liczby $\theta = f^*(\mathbf{x}_0)$. Jego obciążenie i wariancja to

$$b(\mathbf{x}_0) = \bar{f}(\mathbf{x}_0) - f^*(\mathbf{x}_0), \qquad v(\mathbf{x}_0) = \operatorname{Var}_{\mathcal{D}}\,\hat{f}_{\mathcal{D}}(\mathbf{x}_0). \tag{4.3}$$

W rysunku 4.2 obciążenie to pionowa odległość grubej niebieskiej linii od przerywanej, a wariancja opisuje rozrzut cienkich linii wokół niebieskiej. Obie wielkości są funkcjami punktu $\mathbf{x}_0$: wielomian stopnia 10 ma dużą wariancję przy krańcach przedziału i znacznie mniejszą w środku.

4.4. Rozkład oczekiwanego błędu predykcji

Możemy teraz połączyć obie warstwy losowości: losowość nowej obserwacji, którą przewidujemy, i losowość zbioru uczącego, z którego wyznaczyliśmy predyktor.

Twierdzenie 4.1 (Rozkład na obciążenie i wariancję)**.** *Niech $\hat{f}_{\mathcal{D}}$ będzie predyktorem wyznaczonym z losowego zbioru uczącego $\mathcal{D}$, a $\mathbf{x}_0$ – ustalonym punktem. Niech Y_0 ma rozkład warunkowy $Y \mid \mathbf{X} = \mathbf{x}_0$, będzie niezależne od $\mathcal{D}$ i niech $\mathbb{E}[Y_0^2] < \infty$ oraz $\mathbb{E}_{\mathcal{D}}[\hat{f}_{\mathcal{D}}(\mathbf{x}_0)^2] < \infty$. Wtedy*

$$\mathbb{E}[(Y_0 - \hat{f}_{\mathcal{D}}(\mathbf{x}_0))^2] = \underbrace{\operatorname{Var}(Y \mid \mathbf{X} = \mathbf{x}_0)}_{\text{błąd nieredukowalny}} + \underbrace{b(\mathbf{x}_0)^2}_{\text{obciążenie}^2} + \underbrace{v(\mathbf{x}_0)}_{\text{wariancja}}, \tag{4.4}$$

gdzie wartość oczekiwana po lewej stronie dotyczy łącznie Y_0 i $\mathcal{D}$, a b i v są określone wzorem (4.3).

Dowód. Rozłóżmy błąd predykcji na trzy różnice:

$$Y_0 - \hat{f}_{\mathcal{D}}(\mathbf{x}_0) = \underbrace{(Y_0 - f^*(\mathbf{x}_0))}_{A} + \underbrace{(f^*(\mathbf{x}_0) - \bar{f}(\mathbf{x}_0))}_{B} + \underbrace{(\bar{f}(\mathbf{x}_0) - \hat{f}_{\mathcal{D}}(\mathbf{x}_0))}_{C}.$$

Składnik A zależy tylko od Y_0 i ma średnią zero, bo $f^*(\mathbf{x}_0) = \mathbb{E}[Y_0]$. Składnik B jest stałą równą $-b(\mathbf{x}_0)$. Składnik C zależy tylko od $\mathcal{D}$ i również ma średnią zero, z definicji $\bar{f}$. Po podniesieniu sumy do kwadratu i uśrednieniu iloczyny mieszane znikają: $\mathbb{E}[AB] = B\,\mathbb{E}[A] = 0$, $\mathbb{E}[BC] = B\,\mathbb{E}[C] = 0$, a $\mathbb{E}[AC] = \mathbb{E}[A] \cdot \mathbb{E}[C] = 0$ dzięki niezależności Y_0 i $\mathcal{D}$. Zostają $\mathbb{E}[A^2] = \operatorname{Var}(Y \mid \mathbf{X} = \mathbf{x}_0)$, $B^2 = b(\mathbf{x}_0)^2$ i $\mathbb{E}[C^2] = v(\mathbf{x}_0)$. □ □

Pierwszy składnik zależy tylko od rozkładu $Y \mid \mathbf{X} = \mathbf{x}_0$ i żaden predyktor go nie zmniejszy. Dwa pozostałe to rozbity na części błąd redukowalny w punkcie $\mathbf{x}_0$, uśredniony po zbiorach uczących. Obciążenie jest błędem systematycznym, wariancja – losowym, w znaczeniu z rysunku 4.2.

Rozkład w jednym punkcie łatwo przenieść na całe ryzyko. Niech nowa obserwacja $(\mathbf{X}_0, Y_0)$ ma rozkład P i będzie niezależna od $\mathcal{D}$. Uśredniając (4.4) po rozkładzie $\mathbf{X}_0$ i pomijając po uśrednieniu indeks 0, otrzymujemy

$$\mathbb{E}_{\mathcal{D}}[R(\hat{f}_{\mathcal{D}})] = \mathbb{E}[\operatorname{Var}(Y \mid \mathbf{X})] + \mathbb{E}[b(\mathbf{X})^2] + \mathbb{E}[v(\mathbf{X})]. \tag{4.5}$$

Jest to rozkład (2.7) z rozdziału 2, uśredniony po zbiorach uczących, w którym błąd redukowalny rozpadł się na całkowite obciążenie do kwadratu i całkowitą wariancję.

i Trzy uśrednienia

We wzorze (4.5) występują trzy źródła losowości i łatwo je pomylić:

- **wynik Y przy ustalonych cechach** – jego zmienność to błąd nieredukowalny $\operatorname{Var}(Y \mid \mathbf{X})$, cecha zjawiska i zestawu cech;
- **zbiór uczący $\mathcal{D}$** – jego zmienność odpowiada za wariancję $v(\mathbf{x})$ i wyznacza predyktor przeciętny $\bar{f}$, cecha metody i liczności próby;
- **punkt X, w którym przewidujemy** – po nim uśredniamy na końcu, ważąc punkty rozkładem cech.

W szczególności „wariancja” w nazwie kompromisu to wariancja **predyktora** po zbiorach uczących, a nie wariancja szumu $\operatorname{Var}(Y \mid \mathbf{X})$. Model może mieć bardzo małą wariancję przy bardzo zaszumionych danych: predyktor stały $\hat{f} = 0$ ma wariancję zero niezależnie od szumu.

> **Ryzyko modelu a ryzyko metody**
>
> Ryzyko $R(\hat{f}_{\mathcal{D}})$ dopasowanego modelu jest liczbą zależną od tego, jaki zbiór uczący wylosowaliśmy – inną dla każdego zbioru. Wielkość $\mathbb{E}_{\mathcal{D}}[R(\hat{f}_{\mathcal{D}})]$ po lewej stronie (4.5) jest już własnością **metody uczenia** zastosowanej do prób liczności n, a nie konkretnego modelu. Rozkład na obciążenie i wariancję mówi więc, jak dobra jest procedura, a nie jak dobry jest model, który właśnie dopasowaliśmy. Rozróżnienie to wróci w rozdziale 5: walidacja krzyżowa szacuje raczej drugą z tych wielkości niż pierwszą (Hastie i in. 2009, rozdz. 7.12).

Twierdzenie 4.1 jest tożsamością: zachodzi dla każdej metody uczenia, każdego rozkładu i każdej liczności próby. Sam w sobie nie mówi nic o kompromisie. Kompromis to obserwacja dotycząca tego, jak oba składniki zależą od elastyczności metody: zwiększając elastyczność, zwykle zmniejszamy obciążenie i zwiększamy wariancję. Sprawdźmy to na obu naszych metodach.

4.5. Ilustracja: k-NN i regresja wielomianowa

Dla metody k-NN oba składniki można wypisać jawnie, jeśli przyjmiemy uproszczenie: punkty $\mathbf{x}_1, \dots, \mathbf{x}_n$ są ustalone, a losowe są tylko wyniki $Y_i = f^*(\mathbf{x}_i) + \varepsilon_i$, z niezależnymi szumami o wariancji σ^2. Taki **ustalony układ** (ang. *fixed design*) upraszcza rachunki, bo zbiór sąsiadów $N_k(\mathbf{x}_0)$ zależy tylko od położenia punktów, a nie od wyników. Predykcja (3.1) jest wtedy średnią k niezależnych zmiennych losowych o wartościach oczekiwanych $f^*(\mathbf{x}_i)$ i wariancjach σ^2, więc

$$b(\mathbf{x}_0) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x}_0)} f^*(\mathbf{x}_i) - f^*(\mathbf{x}_0), \qquad v(\mathbf{x}_0) = \frac{\sigma^2}{k}. \tag{4.6}$$

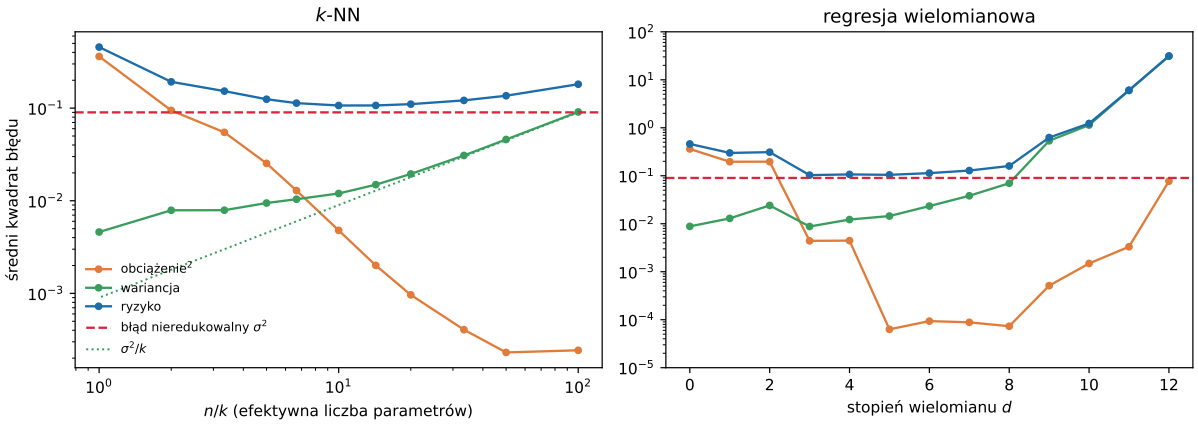
Oba wzory odpowiadają dwóm źródłom błędu z rysunku 3.1. Wariancja maleje jak $1/k$: im więcej wyników uśredniamy, tym mniej znaczy szum każdego z nich. Obciążenie to różnica między średnią wartości f^* w otoczeniu a wartością w samym punkcie. Rośnie wraz z k, bo otoczenie się poszerza, i jest tym większe, im bardziej f^* zmienia się w otoczeniu. Dla $k = 1$ obciążenie jest małe, a wariancja równa σ^2, więc oczekiwany błąd predykcji wynosi w przybliżeniu $2\sigma^2$ – znów pojawia się podwojenie, jak w twierdzeniu Covera–Harta (Twierdzenie 3.2). Dla $k = n$ wariancja jest najmniejsza, σ^2/n, ale obciążenie równa się odległości $f^*(\mathbf{x}_0)$ od średniej wszystkich wartości $f^*(\mathbf{x}_i)$.

Dla regresji wielomianowej takich prostych wzorów nie ma, ale oba składniki można oszacować symulacyjnie: wylosować wiele zbiorów uczących, w każdym punkcie siatki policzyć średnią i wariancję predykcji, a potem scałkować po rozkładzie X. Rysunek 4.3 pokazuje wynik dla obu metod. Przy k-NN cechy są losowe, jak na rysunku 3.5, a nie ustalone.

W obu panelach widać ten sam mechanizm. Obciążenie maleje, a wariancja rośnie wraz z elastycznością. Ryzyko, ich suma powiększona o σ^2, ma minimum tam, gdzie dalszy spadek obciążenia przestaje równoważyć wzrost wariancji. Kształt litery U z rysunków 3.5 i 4.1 jest więc sumą dwóch monotonicznych krzywych biegnących w przeciwne strony.

Przy k-NN wariancja jest bliska σ^2/k dla małych k, ale przy dużych k jest od niej wyraźnie większa: przy losowych cechach zmienia się od próby do próby także zbiór sąsiadów, a z nim średnia wartości f^* w otoczeniu, i ten składnik nie maleje jak $1/k$. Najmniejsze ryzyko przypada na k rzędu 7–10, gdzie obciążenie i wariancja są porównywalne.

Przy wielomianach obciążenie spada schodkami: stopnie parzyste prawie nic nie dodają do poprzedniego nieparzystego. Powodem jest symetria naszej funkcji regresji – po odjęciu stałej $1/4$ jest ona nieparzysta względem punktu $x = 1/2$, więc człony parzyste w rozwinięciu wokół tego



Rysunek 4.3.: Rozkład ryzyka na obciążenie do kwadratu, wariancję i błąd nieredukowalny. Po lewej: regresja k-NN w zależności od n/k ($n = 100$, 500 prób uczących); kropkowana linia to wariancja σ^2/k z ustalonego układu (4.6). Po prawej: regresja wielomianowa w zależności od stopnia d ($n = 50$, 1000 prób uczących, te same co na rysunku 4.1). Ryzyko jest sumą trzech składników. Wzrost obciążenia powyżej $d = 8$ to błąd losowy oszacowania $\bar{f}$ z 1000 prób, a nie własność metody. Oś pionowa w skali logarytmicznej.

punktu nic nie wnoszą. Każdy taki współczynnik zwiększa jednak wariancję i nie zmniejsza obciążenia. To czysty koszt, który dobrze widać w ryzyku: stopień 4 jest gorszy od stopnia 3, a stopień 6 od stopnia 5. Od stopnia 5 obciążenie jest praktycznie zerowe – wielomian tego stopnia przybliża f^* na $[0, 1]$ niemal dokładnie – a każdy kolejny stopień dokłada już tylko wariancji. Powyżej stopnia 8 wariancja rośnie gwałtownie, bo dopasowania przy krańcach przedziału, widoczne w rysunku 4.2, coraz częściej „uciekają".

Wzrost krzywej obciążenia powyżej stopnia 8 jest artefaktem symulacji, a nie własnością metody. Predyktor przeciętny $\bar{f}$ szacujemy średnią z tysiąca dopasowań, a średnia zmiennej o ogromnej wariancji sama jest niedokładna. Jej błąd losowy zawyża oszacowanie obciążenia do kwadratu średnio o wariancję podzieloną przez liczbę prób. Przy stopniu 12 to około 31/1000, czyli tyle, ile widać na wykresie. Prawdziwe obciążenie pozostaje bliskie zera.

Kompromis obciążenie–wariancja nie jest więc własnością konkretnego algorytmu. Metoda k-NN i regresja wielomianowa nie mają ze sobą nic wspólnego poza tym, że obie mają pokrętło elastyczności i uczą się ze skończonej próby.

4.6. Błąd aproksymacji i błąd estymacji

W rozdziale 2 zapowiedzieliśmy rozbicie błędu redukowalnego na część wynikającą ze zbyt ubogiej klasy modeli i część wynikającą ze skończoności próby. Rozkład na obciążenie i wariancję jest do tego bliski, ale nie identyczny. Obciążenie mierzymy względem predyktora przeciętnego $\bar{f}$, który zależy od liczności próby i od metody, a nie tylko od klasy. Zapowiedziany rozkład wygląda inaczej.

Niech metoda wybiera predyktor z ustalonej klasy $\mathcal{F}$ i niech

$$f_{\mathcal{F}} \in \arg\min_{f \in \mathcal{F}} R(f)$$

będzie najlepszym predyktorem w tej klasie, czyli tym, który wybralibyśmy, znając rozkład P. Dla dowolnego $\hat{f} \in \mathcal{F}$ zachodzi

$$R(\hat{f}) = \underbrace{R(f^*)}_{\text{błąd nieredukowalny}} + \underbrace{R(f_\mathcal{F}) - R(f^*)}_{\text{błąd aproksymacji}} + \underbrace{R(\hat{f}) - R(f_\mathcal{F})}_{\text{błąd estymacji}}. \tag{4.7}$$

Tożsamość jest trywialna, ale jej składniki mają wyraźny sens. **Błąd aproksymacji** mówi, ile tracimy, ograniczając się do klasy $\mathcal{F}$. Nie zależy od danych ani od n, tylko od klasy i od rozkładu. **Błąd estymacji** mówi, ile tracimy dlatego, że zamiast najlepszego elementu klasy wybraliśmy na podstawie skończonej próby inny. Jest losowy, bo zależy od $\mathcal{D}$, i z definicji $f_\mathcal{F}$ nieujemny. Poszerzenie klasy nie zwiększa błędu aproksymacji – minimum po większym zbiorze nie jest większe – ale zwykle zwiększa błąd estymacji, bo przy tej samej liczbie danych trudniej trafić w najlepszy element bogatszej klasy. Jest to ten sam kompromis w innym języku; bywa nazywany kompromisem aproksymacja–estymacja (Shalev-Shwartz i Ben-David 2014, rozdz. 5).

Rozkład (4.7) ma dwie zalety. Działa dla każdej straty, także dla straty 0–1, i nie wymaga uśredniania po zbiorach uczących. Ma też ograniczenie: wymaga ustalonej klasy $\mathcal{F}$. Metoda k-NN, jak zauważyliśmy w sekcji 3.2, niczego z ustalonej klasy nie wybiera, więc dla niej naturalny jest rozkład na obciążenie i wariancję.

Gdy oba rozkłady mają sens, są ze sobą ściśle związane. Oznaczmy $\|g\|^2 = \mathbb{E}[g(\mathbf{X})^2]$, gdzie średnią liczymy po rozkładzie cech. Z (2.7) przy stracie kwadratowej $R(f) - R(f^*) = \|f - f^*\|^2$, więc $f_\mathcal{F}$ jest elementem $\mathcal{F}$ najbliższym f^* w tej normie.

Twierdzenie 4.2 (Obciążenie a błąd aproksymacji)**.** *Niech strata będzie kwadratowa, a $\mathcal{F}$ – skończenie wymiarową przestrzenią liniową funkcji, taką jak $\mathcal{F}_d$. Niech $\hat{f}_\mathcal{D} \in \mathcal{F}$ dla każdego zbioru uczącego, a wszystkie występujące niżej średnie niech będą skończone. Wtedy*

$$\underbrace{\mathbb{E}[b(\mathbf{X})^2]}_{\textit{obciążenie}^2} = \underbrace{\|f_\mathcal{F} - f^*\|^2}_{\textit{błąd aproksymacji}} + \|\bar{f} - f_\mathcal{F}\|^2, \tag{4.8}$$

$$\underbrace{\mathbb{E}_\mathcal{D}[R(\hat{f}_\mathcal{D}) - R(f_\mathcal{F})]}_{\textit{oczekiwany błąd estymacji}} = \|\bar{f} - f_\mathcal{F}\|^2 + \underbrace{\mathbb{E}[v(\mathbf{X})]}_{\textit{wariancja}}. \tag{4.9}$$

Dowód. Norma $\|\cdot\|$ pochodzi od iloczynu skalarnego $\langle g, h\rangle = \mathbb{E}[g(\mathbf{X})h(\mathbf{X})]$, a $f_\mathcal{F}$ jest rzutem ortogonalnym f^* na podprzestrzeń $\mathcal{F}$. Różnica $f^* - f_\mathcal{F}$ jest więc ortogonalna do każdego elementu $\mathcal{F}$: gdyby $\langle f^* - f_\mathcal{F}, g\rangle \neq 0$ dla pewnego $g \in \mathcal{F}$, przesunięcie $f_\mathcal{F}$ o mały krok w kierunku g zmniejszyłoby odległość od f^*.

Predyktor przeciętny należy do $\mathcal{F}$: jeśli $\hat{f}_\mathcal{D} = \sum_j \hat{\beta}_j \varphi_j$ w pewnej bazie $\varphi_1, \ldots, \varphi_m$ przestrzeni $\mathcal{F}$, to $\bar{f} = \sum_j \mathbb{E}_\mathcal{D}[\hat{\beta}_j]\, \varphi_j$. Zatem $\bar{f} - f_\mathcal{F} \in \mathcal{F}$ jest ortogonalne do $f_\mathcal{F} - f^*$ i z twierdzenia Pitagorasa

$$\mathbb{E}[b(\mathbf{X})^2] = \|\bar{f} - f^*\|^2 = \|f_\mathcal{F} - f^*\|^2 + \|\bar{f} - f_\mathcal{F}\|^2.$$

Tak samo $\hat{f}_\mathcal{D} - f_\mathcal{F} \in \mathcal{F}$, więc $R(\hat{f}_\mathcal{D}) - R(f_\mathcal{F}) = \|\hat{f}_\mathcal{D} - f^*\|^2 - \|f_\mathcal{F} - f^*\|^2 = \|\hat{f}_\mathcal{D} - f_\mathcal{F}\|^2$. Uśredniając po $\mathcal{D}$ i rozkładając $\hat{f}_\mathcal{D} - f_\mathcal{F} = (\hat{f}_\mathcal{D} - \bar{f}) + (\bar{f} - f_\mathcal{F})$ tak jak w (4.2), dostajemy (4.9), bo $\mathbb{E}_\mathcal{D}[\|\hat{f}_\mathcal{D} - \bar{f}\|^2] = \mathbb{E}[v(\mathbf{X})]$. □ □

Oba rozkłady różnią się więc tylko tym, gdzie zaliczają składnik $\|\bar{f} - f_\mathcal{F}\|^2$, czyli odległość predyktora przeciętnego od najlepszego elementu klasy. Rozkład na obciążenie i wariancję traktuje go jako część obciążenia, rozkład na aproksymację i estymację – jako część błędu estymacji. Dla metody najmniejszych kwadratów ten składnik jest zwykle bardzo mały i znika, gdy n rośnie.

Wtedy obciążenie do kwadratu jest w praktyce równe błędowi aproksymacji, a wariancja – błędowi estymacji. Sprawdza to poniższe zestawienie dla wielomianów z rysunku 4.3. Najlepszy wielomian $f_{\mathcal{F}_d}$ wyznaczyliśmy, dopasowując wielomian metodą najmniejszych kwadratów do samej funkcji f^* na gęstej siatce.

d	aproksymacja	obciążenie^2	||f_bar - f_F||^2	wariancja
0	0.36168	0.36168	0.00000	0.00882
1	0.19604	0.19610	0.00006	0.01293
2	0.19604	0.19641	0.00038	0.02410
3	0.00439	0.00440	0.00001	0.00876
4	0.00439	0.00445	0.00006	0.01223
5	0.00002	0.00006	0.00004	0.01447
6	0.00002	0.00009	0.00008	0.02336
7	0.00000	0.00009	0.00009	0.03827
8	0.00000	0.00007	0.00007	0.06986

Kolumny „aproksymacja” i „obciążenie^2” zgadzają się do trzeciego miejsca po przecinku, a składnik $\|\bar{f} - f_{\mathcal{F}}\|^2$ jest kilkadziesiąt do kilkuset razy mniejszy od wariancji. Część tej różnicy to zresztą błąd symulacji, bo $\bar{f}$ szacujemy z tysiąca prób.

4.7. Krzywe uczenia

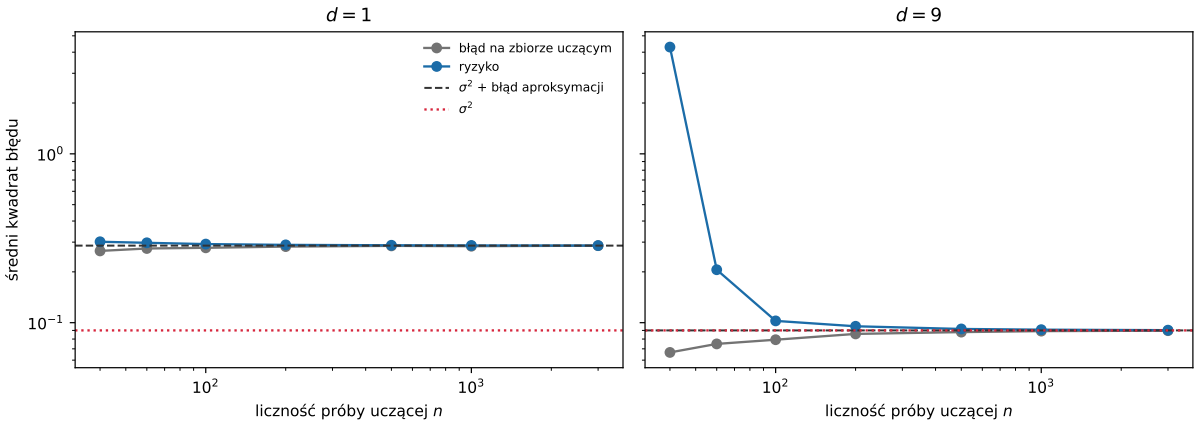
Dotąd zmienialiśmy elastyczność przy ustalonej liczności próby. Zmieńmy teraz liczność próby przy ustalonej metodzie. Wykres ryzyka i błędu uczącego w zależności od n nazywamy **krzywą uczenia** (ang. *learning curve*).

Rozkład (4.7) mówi, czego się spodziewać. Błąd aproksymacji nie zależy od n. Błąd estymacji maleje, gdy danych przybywa, bo dopasowany predyktor zbliża się do $f_{\mathcal{F}}$. Ryzyko dąży więc do poziomu $R(f^*)+[R(f_{\mathcal{F}})-R(f^*)]$, czyli sumy błędu nieredukowalnego i błędu aproksymacji. Błąd uczący zachowuje się odwrotnie: rośnie z n, bo coraz trudniej dopasować się do coraz większej liczby punktów, i dąży do tego samego poziomu od dołu. Rysunek 4.4 pokazuje to dla dwóch wielomianów: sztywnego ($d = 1$) i elastycznego ($d = 9$).

Dwa panele pokazują dwa typowe obrazy. Prosta szybko osiąga swoją granicę $\sigma^2 + 0{,}196 \approx 0{,}286$, gdzie 0,196 to błąd aproksymacji, i dalsze dane już nic nie dają. Krzywe błędu uczącego i ryzyka są blisko siebie, a obie leżą wysoko nad σ^2. Tak wygląda model, którego ryzyko zdominowało obciążenie. Wielomian stopnia 9 przy małym n ma ogromne ryzyko i wielką szczelinę między ryzykiem a błędem uczącym. Tak wygląda model, którego ryzyko zdominowała wariancja. Z rosnącym n szczelina się zamyka, a obie krzywe zbiegają do granicy praktycznie równej σ^2, bo błąd aproksymacji wielomianu stopnia 9 jest znikomy.

Z porównania paneli wynika rzecz ważna dla praktyki: **najlepsza elastyczność zależy od liczności próby**. Przy $n = 40$ prosta ma ryzyko ponad dziesięć razy mniejsze niż wielomian stopnia 9, a już przy $n = 100$ – mniej więcej trzy razy większe. Nie ma modelu „właściwie złożonego” w oderwaniu od ilości danych.

Krzywe uczenia odpowiadają też na pytanie diagnostyczne z rozdziału 2: czy wypłaszczenie ryzyka oznacza, że dotarliśmy do granicy zjawiska, czy że model jest za słaby? Rozstrzyga przebieg obu krzywych w funkcji n, a nie ich wygląd przy jednej liczności. Jeśli ryzyko wciąż spada, a szczelina między nim a błędem uczącym się zamyka, dominuje wariancja: pomoże więcej danych albo prostszy model. Jeśli obie krzywe są już płaskie i zbieżne, dominuje obciążenie i więcej



Rysunek 4.4.: Krzywe uczenia regresji wielomianowej stopnia $d = 1$ (po lewej) i $d = 9$ (po prawej): błąd na zbiorze uczącym i ryzyko w zależności od liczności próby n. Punkty to średnie z 300 prób uczących. Linia przerywana: granica ryzyka przy $n \to \infty$, równa sumie błędu nieredukowalnego i błędu aproksymacji. Linia kropkowana: błąd nieredukowalny σ^2. Obie osie w skali logarytmicznej.

danych nie pomoże. Samą szerokość szczeliny, czyli optymizm, trzeba czytać jako liczbę w jednostkach straty, bo jej wrażenie na rysunku zależy od skali osi: na rysunku 4.4 oś pionowa jest logarytmiczna, więc widać iloraz obu błędów, nie ich różnicę. Płaskie i zbieżne krzywe nie rozstrzygają jednak, czy ich granica to sam błąd nieredukowalny, czy błąd nieredukowalny powiększony o błąd aproksymacji; „wysoki poziom" wymaga punktu odniesienia. W lewym panelu wiemy, że to drugie, bo znamy σ^2. W praktyce punktem odniesienia jest porównanie różnych klas modeli: jeśli bogatsza klasa przy dużym n schodzi niżej, ograniczała nas klasa. Jeśli żadna nie schodzi niżej, ograniczają nas zapewne cechy, a poprawę może dać tylko ich zmiana. W realnym problemie ryzyka nie znamy i krzywą uczenia trzeba szacować, czym zajmuje się rozdział 5.

4.8. Dlaczego kompromis jest nieusuwalny

W rozdziale 2 zauważyliśmy, że gdybyśmy znali P i mogli wybrać dowolną funkcję, żaden kompromis by nie istniał. Każdy kompromis bierze się z ograniczeń klasy modeli lub ze skończoności próby. Kompromis obciążenie–wariancja łączy oba te ograniczenia. Przy ustalonym n obciążenie zmniejszamy, poszerzając klasę lub zawężając otoczenie, a każdy taki krok sprawia, że predyktor mocniej zależy od przypadkowych cech próby. Pokrętło elastyczności przesuwa błąd z jednego składnika do drugiego, ale nie usuwa go.

Są dwa sposoby, by zmniejszyć oba składniki naraz. Pierwszy to więcej danych: przy większym n ta sama elastyczność kosztuje mniej wariancji, więc optimum przesuwa się w stronę modeli bogatszych, jak w rysunku 4.4. Drugi to **trafne założenie strukturalne**. Jeśli f^* należy do małej klasy $\mathcal{F}$, to metoda wybierająca z tej klasy ma zerowy błąd aproksymacji i małą wariancję. Gdyby f^* była liniowa, regresja liniowa z p cechami miałaby zerowe obciążenie i wariancję rzędu $\sigma^2(p+1)/n$ (6.11). Trafne założenie zastępuje dane. Nietrafne wprowadza obciążenie, którego żadna ilość danych nie usunie.

4.8.1. Ile kosztuje elastyczność w wielu wymiarach

Jak drogie bywa nieprzyjmowanie żadnych założeń, pokazuje prosty rachunek dla metody k-NN. Niech cechy mają rozkład jednostajny w kostce $[0,1]^p$, szum ma wariancję σ^2, a funkcja regresji spełnia warunek Lipschitza $|f^*(\mathbf{x}) - f^*(\mathbf{x}')| \le L \max_j |x_j - x'_j|$, czyli nie zmienia się zbyt szybko. Rachunek jest przybliżony, ale jego wynik daje się uściślić (Györfi i in. 2002).

Z (3.7) otoczenie zawierające k z n punktów jest kostką o boku około $(k/n)^{1/p}$. Sąsiedzi leżą więc od $\mathbf{x}$ w odległości co najwyżej około połowy tego boku, a wartości f^* różnią się od $f^*(\mathbf{x})$ najwyżej o L razy tyle. Z (4.6)

$$b(\mathbf{x})^2 + v(\mathbf{x}) \;\lesssim\; \frac{L^2}{4}\Big(\frac{k}{n}\Big)^{2/p} + \frac{\sigma^2}{k}. \tag{4.10}$$

Pierwszy składnik rośnie z k, drugi maleje. Minimalizując prawą stronę względem k, otrzymujemy optymalną liczbę sąsiadów rzędu $k^* \sim n^{2/(p+2)}$ i nadwyżkę ryzyka nad σ^2 rzędu

$$n^{-2/(p+2)}$$

(Zadanie 4.9). Optymalne k^* rośnie z n, ale wolniej niż n, dokładnie tak, jak wymagają założenia twierdzenia 3.1.

Wykładnik $2/(p+2)$ maleje z wymiarem. Dla $p = 1$ nadwyżka ryzyka maleje jak $n^{-2/3}$, dla $p = 10$ – jak $n^{-1/6}$. Aby zmniejszyć ją o połowę, trzeba pomnożyć liczbę obserwacji przez $2^{(p+2)/2}$: niecałe trzy razy dla $p = 1$, cztery razy dla $p = 2$, 64 razy dla $p = 10$, ponad 2000 razy dla $p = 20$. Jest to przekleństwo wymiarowości z sekcji 3.6 w języku tego rozdziału: w wielu wymiarach otoczenia muszą być szerokie, żeby zawierały dość punktów, a szerokie otoczenia oznaczają duże obciążenie. Tego tempa nie poprawi przy tym żadna inna metoda. C. J. Stone (1982) wykazał, że przy samym założeniu Lipschitza $n^{-2/(p+2)}$ jest najlepszym tempem, jakie może zagwarantować jakikolwiek estymator. Ceną jest brak założeń, a nie słabość metody k-NN. Model liniowy, jeśli jest trafny, osiąga tempo $1/n$ niezależnie od p, ze stałą proporcjonalną do $p+1$ – stąd przewaga, o której pisaliśmy pod koniec sekcji 3.6.

> **i** Podwójne zejście
>
> Obraz z rysunku 4.3, w którym wariancja rośnie nieograniczenie wraz z liczbą parametrów, nie jest prawem natury. Belkin i in. (2019) opisali zjawisko **podwójnego zejścia** (ang. *double descent*). Gdy liczba parametrów przekracza liczbę obserwacji, model może dopasować dane dokładnie na nieskończenie wiele sposobów. Jeśli algorytm wybiera spośród nich rozwiązanie w pewnym sensie najprostsze, na przykład o najmniejszej normie współczynników, ryzyko po przejściu przez maksimum w progu interpolacji może znów maleć. Rozkład z twierdzenia 4.1 nadal obowiązuje, bo jest tożsamością. Zmienia się tylko to, jak wariancja zależy od liczby parametrów. Do tego zjawiska wrócimy przy sieciach neuronowych (rozdział 12).

4.9. Obciążenie i wariancja w klasyfikacji

Przy stracie 0–1 rozkład tak prosty jak (4.4) nie istnieje. Zobaczmy dlaczego. Ograniczmy się do dwóch klas i reguły podstawienia $\hat{g}_{\mathcal{D}}(\mathbf{x}) = \mathbb{1}(\hat{\eta}_{\mathcal{D}}(\mathbf{x}) > \frac{1}{2})$, takiej jak klasyfikator k-NN.

Ustalmy punkt $\mathbf{x}$. Klasyfikator wskazujący w nim klasę 1 myli się z prawdopodobieństwem $1 - \eta(\mathbf{x})$, wskazujący klasę 0 – z prawdopodobieństwem $\eta(\mathbf{x})$. Klasyfikator bayesowski wybiera

mniejszą z tych liczb. Jeśli $\hat{g}$ wskazuje w punkcie $\mathbf{x}$ inną klasę niż g^*, płaci więc nadwyżkę równą różnicy obu liczb, $|2\eta(\mathbf{x}) - 1|$. Uśredniając po $\mathbf{X}$, dostajemy

$$R(\hat{g}) - R(g^*) = \mathbb{E}\Big[\, |2\eta(\mathbf{X}) - 1| \; \mathbb{1}(\hat{g}(\mathbf{X}) \neq g^*(\mathbf{X}))\Big], \tag{4.11}$$

a po uśrednieniu po zbiorach uczących

$$\mathbb{E}_{\mathcal{D}}[R(\hat{g}_{\mathcal{D}})] - R(g^*) = \mathbb{E}\Big[\, |2\eta(\mathbf{X}) - 1| \; \mathbb{P}_{\mathcal{D}}(\hat{g}_{\mathcal{D}}(\mathbf{X}) \neq g^*(\mathbf{X}))\Big].$$

Liczy się więc tylko prawdopodobieństwo, że oszacowanie $\hat{\eta}_{\mathcal{D}}(\mathbf{x})$ znajdzie się po złej stronie progu $\frac{1}{2}$. Niech na przykład $\eta(\mathbf{x}) > \frac{1}{2}$ i niech $\hat{\eta}_{\mathcal{D}}(\mathbf{x})$ ma w przybliżeniu rozkład normalny o średniej $\bar{\eta}(\mathbf{x})$ i odchyleniu standardowym $s(\mathbf{x})$. Wtedy

$$\mathbb{P}_{\mathcal{D}}(\hat{g}_{\mathcal{D}}(\mathbf{x}) \neq g^*(\mathbf{x})) \approx \Phi\Big(\frac{\frac{1}{2} - \bar{\eta}(\mathbf{x})}{s(\mathbf{x})}\Big). \tag{4.12}$$

Obciążenie i wariancja nie dodają się tu, tylko oddziałują (Friedman 1997). Jeśli przeciętne oszacowanie leży po właściwej stronie progu ($\bar{\eta}(\mathbf{x}) > \frac{1}{2}$), licznik jest ujemny i wzrost wariancji zwiększa prawdopodobieństwo błędu. Obciążenie może być wtedy duże i nic nie kosztować, dopóki nie przeprowadzi $\bar{\eta}$ przez próg. Jeśli przeciętne oszacowanie leży po złej stronie, licznik jest dodatni i wzrost wariancji prawdopodobieństwo błędu **zmniejsza**, bo częściej wyrzuca $\hat{\eta}$ na właściwą stronę (Zadanie 4.10).

Z tej obserwacji wynikają dwa praktyczne wnioski. Po pierwsze, w klasyfikacji liczy się przede wszystkim mała wariancja. Klasyfikator może opierać się na mocno obciążonych oszacowaniach prawdopodobieństw i mimo to klasyfikować dobrze. Friedman (1997) tłumaczy w ten sposób skuteczność prostych metod, takich jak naiwny klasyfikator Bayesa z rozdziału 11. Po drugie, ta tolerancja dotyczy wyłącznie decyzji podejmowanej progiem $\frac{1}{2}$. Gdy oszacowanie $\hat{\eta}$ ma służyć regule kosztowej albo regule z opcją odmowy z sekcji 2.5, liczy się jego wartość, a nie tylko strona progu, i obciążenie znów kosztuje.

Uwagi bibliograficzne

Kompromis obciążenie–wariancja w ujęciu bliskim temu rozdziałowi przedstawiają James i in. (2023, rozdz. 2.2) oraz Hastie i in. (2009, rozdz. 2.9 i 7.3). Druga z tych książek omawia też optymizm błędu uczącego (Hastie i in. 2009, rozdz. 7.4), różnicę między ryzykiem dopasowanego modelu a ryzykiem oczekiwanym metody (Hastie i in. 2009, rozdz. 7.2) oraz przykład, w którym przy stracie 0–1 składniki nie sumują się (Hastie i in. 2009, rozdz. 7.3). Bishop (2006, rozdz. 3.2) wyprowadza rozkład dla regresji z funkcjami bazowymi i podkreśla jego ograniczoną wartość praktyczną: wymaga uśredniania po wielu zbiorach uczących, podczas gdy w praktyce mamy jeden.

Nazwę „dylemat obciążenie–wariancja" rozpowszechnili Geman i in. (1992), którzy pokazali, że ten sam kompromis rządzi estymatorami jądrowymi, metodą najbliższych sąsiadów i sieciami neuronowymi. Rozkład na błąd aproksymacji i błąd estymacji, centralny w teorii uczenia, wykładają Shalev-Shwartz i Ben-David (2014, rozdz. 5). Ścisłą analizę tempa zbieżności nieparametrycznych estymatorów regresji, w tym metody k-NN, zawiera Györfi i in. (2002). Optymalność tempa $n^{-2/(p+2)}$ dla funkcji Lipschitza, w ogólniejszej postaci dla klas funkcji gładkich, udowodnił C. J. Stone (1982).

Oddziaływanie obciążenia i wariancji przy stracie 0–1 i jego związek z przekleństwem wymiarowości analizuje Friedman (1997). Zjawisko podwójnego zejścia i jego miejsce względem klasycznego kompromisu opisują Belkin i in. (2019).

Zadania

Zadanie 4.1. Niech $Y_1, \dots, Y_n$ będzie próbą z rozkładu o średniej $\mu \neq 0$ i wariancji σ^2, a $\hat{\mu}_c = c\bar{Y}$ dla $c \in \mathbb{R}$.

a) Wyznacz obciążenie, wariancję i błąd średniokwadratowy $\hat{\mu}_c$.
b) Wykaż, że błąd średniokwadratowy jest najmniejszy dla $c^* = \mu^2/(\mu^2 + \sigma^2/n)$, i wyznacz jego wartość w minimum. Sprawdź liczby podane w sekcji 4.3.
c) Wyraź c^* przez stosunek sygnału do szumu $\mu^2/(\sigma^2/n)$. Kiedy ściąganie daje duży zysk, a kiedy prawie żaden?
d) Dlaczego $\hat{\mu}_{c^*}$ nie jest estymatorem, którego można użyć w praktyce? Co by się stało, gdyby w miejsce μ podstawić $\bar{Y}$?

Zadanie 4.2.

a) Wskaż miejsce w dowodzie twierdzenia 4.1, w którym korzystamy z niezależności Y_0 od zbioru uczącego. Rozważ regułę jednego najbliższego sąsiada i „nową" obserwację, która jest w istocie jedną z obserwacji uczących: $\mathbf{x}_0 = \mathbf{x}_i$, $Y_0 = y_i$. Ile wynosi wtedy lewa strona (4.4), a ile prawa? Skąd bierze się różnica?
b) Wyprowadź (4.5) z (4.4). Jakiego założenia o $\mathbf{X}_0$ potrzebujesz?
c) Szumy mają stałą wariancję σ^2, a punkty uczące są ustalone i parami różne. Wyznacz obciążenie, wariancję i oczekiwany błąd predykcji w punkcie $\mathbf{x}_0$ pokrywającym się z jednym z punktów uczących dla dwóch skrajnych predyktorów: stałego $\hat{f} \equiv 0$ oraz reguły jednego najbliższego sąsiada. Kiedy predyktor stały jest lepszy?

Zadanie 4.3. Punkty uczące leżą na siatce $x_i = i/n$, $i = 1, \dots, n$, a $Y_i = f^*(x_i) + \varepsilon_i$ z niezależnymi szumami o wariancji σ^2. Rozważ regresję k-NN z $k = 2m + 1$ w punkcie $x_0 = x_j$ leżącym na tyle daleko od krańców, by sąsiedzi leżeli symetrycznie.

a) Wykaż, że dla $f^*(x) = ax + c$ obciążenie w x_0 jest zerowe. Co się zmienia, gdy $x_0 = x_1$ leży na krańcu przedziału?
b) Wykaż, że dla $f^*(x) = x^2$ obciążenie wynosi $m(m+1)/(3n^2)$. (Wskazówka: $\sum_{j=-m}^{m} j^2 = m(m+1)(2m+1)/3$.)
c) Dla $n = 100$ i $\sigma = 0{,}1$ wyznacz numerycznie m minimalizujące oczekiwany błąd predykcji w x_0 dla $f^*(x) = x^2$. Jak zmienia się wynik, gdy $f^*(x) = 10x^2$? Wyjaśnij kierunek zmiany.

Zadanie 4.4. W sytuacji z zadania 4.3 (ustalone, parami różne punkty x_i) niech Y_i' będzie nową, niezależną obserwacją wyniku w punkcie x_i, o tym samym rozkładzie co Y_i. Wykaż, że dla regresji k-NN

$$\mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^{n}(Y_i' - \hat{f}(x_i))^2\Big] - \mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^{n}(Y_i - \hat{f}(x_i))^2\Big] = \frac{2\sigma^2}{k}.$$

(Wskazówka: każdy punkt x_i należy do swojego własnego otoczenia; rozpisz $\operatorname{Cov}(Y_i, \hat{f}(x_i))$.) Sprawdź wynik dla $k = 1$ (por. Zadanie 1.6). Co ten wzór mówi o błędzie uczącym jako ocenie ryzyka przy małym k?

Zadanie 4.5. Rozważ klasę funkcji stałych $\mathcal{F}_0$ i rozkład z tego rozdziału: X jednostajny na $[0,1]$, $f^*(x) = \sin(2\pi x) + x/2$, szum o wariancji σ^2. Predyktorem jest średnia $\bar{Y}$ z próby.

a) Wyznacz $f_{\mathcal{F}_0}$ i błąd aproksymacji. Wykaż, że ten drugi jest równy $\operatorname{Var} f^*(X) = \frac{1}{2} + \frac{1}{48} - \frac{1}{2\pi} \approx 0{,}362$.

b) Wyznacz $\bar{f}$ i oczekiwany błąd estymacji. Wykaż, że składnik $\|\bar{f} - f_{\mathcal{F}_0}\|^2$ z twierdzenia 4.2 jest tu równy zeru.
c) Wyznacz obciążenie $b(x)$ w punkcie. Jest ono duże w niektórych punktach, choć $\bar{f} = f_{\mathcal{F}_0}$. Jak to pogodzić z twierdzeniem 4.2?
d) Porównaj wyniki z pierwszymi wierszami zestawienia w sekcji 4.6 dla $n = 50$ i $\sigma = 0{,}3$.

Zadanie 4.6. Rozwiń symulację z zadania 1.14. Dla $n = 30$ i stopni $d = 1, \ldots, 10$:

a) wylosuj 500 zbiorów uczących i w punktach $x_0 = 0{,}5$ oraz $x_0 = 0{,}95$ oszacuj obciążenie, wariancję i oczekiwany błąd predykcji $\mathbb{E}[(Y_0 - \hat{f}(x_0))^2]$, losując Y_0 niezależnie;
b) sprawdź, że suma obciążenia do kwadratu, wariancji i σ^2 zgadza się z oczekiwanym błędem predykcji z dokładnością do błędu symulacji;
c) porównaj optymalne stopnie w obu punktach i wyjaśnij różnicę, odwołując się do rysunku 4.2.

Zadanie 4.7. Narysuj krzywe uczenia regresji k-NN dla rozkładu z tego rozdziału, dla n od 20 do 5000, w dwóch wariantach: ze stałym $k = 5$ i z $k = \lceil \sqrt{n} \rceil$.

a) Do jakiej granicy dąży ryzyko w każdym wariancie? (Wskazówka: dla stałego k obciążenie znika przy $n \to \infty$, a wariancja nie.)
b) Porównaj wynik wariantu ze stałym k z twierdzeniem Covera–Harta (Twierdzenie 3.2). Który składnik ryzyka odpowiada za to, że reguła ze stałym k nie jest zgodna?
c) Jak zachowuje się szczelina między ryzykiem a błędem uczącym w obu wariantach?

Zadanie 4.8. Mamy B predyktorów $\hat{f}_1, \ldots, \hat{f}_B$ o tym samym rozkładzie, z których każdy w punkcie $\mathbf{x}_0$ ma obciążenie b i wariancję v. Rozważ ich średnią $\hat{f}_{\text{sr}} = \frac{1}{B}\sum_{j=1}^{B} \hat{f}_j$.

a) Wyznacz obciążenie i wariancję $\hat{f}_{\text{sr}}(\mathbf{x}_0)$, gdy predyktory wyznaczono z niezależnych zbiorów uczących.
b) Powtórz rachunek przy założeniu, że każde dwa predyktory mają w punkcie $\mathbf{x}_0$ współczynnik korelacji $\rho > 0$. Wykaż, że wariancja średniej wynosi $\rho v + (1-\rho)v/B$ i nie spada poniżej ρv niezależnie od B.
c) W praktyce mamy jeden zbiór uczący. Predyktory można wyznaczyć z próbek losowanych z niego ze zwracaniem (metoda bootstrap, rozdział 5). Dlaczego będą one skorelowane? Dla której z metod tego rozdziału, wielomianów niskiego czy wysokiego stopnia, spodziewasz się większego zysku z uśredniania?

Zadanie 4.9.

a) Wyznacz k minimalizujące prawą stronę (4.10), traktując k jako zmienną ciągłą. Wykaż, że k^* jest rzędu $n^{2/(p+2)}$, a oba składniki w optimum – rzędu $n^{-2/(p+2)}$.
b) Wykaż, że $k^* \to \infty$ i $k^*/n \to 0$ przy $n \to \infty$. Porównaj z założeniami twierdzenia 3.1.
c) O ile trzeba zwiększyć n, aby nadwyżka ryzyka spadła o połowę? Podaj wynik dla $p = 1, 2, 5, 10, 20$.
d) Zastąp warunek Lipschitza warunkiem $|f^*(\mathbf{x}) - f^*(\mathbf{x}')| \le L$ dla wszystkich $\mathbf{x}, \mathbf{x}'$ (funkcja ograniczona, ale dowolnie nieregularna). Co rachunek mówi wtedy o tempie? Odnieś wynik do uwagi „Zbieżność nie znaczy »szybko«" z rozdziału 3.

Zadanie 4.10. W punkcie $\mathbf{x}$ prawdziwe prawdopodobieństwo klasy 1 wynosi $\eta(\mathbf{x}) = 0{,}7$, a oszacowanie $\hat{\eta}_{\mathcal{D}}(\mathbf{x})$ ma rozkład normalny o średniej $\bar{\eta}$ i odchyleniu standardowym s.

a) Dla $\bar{\eta} \in \{0{,}65;\ 0{,}55;\ 0{,}45\}$ i $s \in \{0{,}05;\ 0{,}1;\ 0{,}2\}$ oblicz prawdopodobieństwo, że klasyfikator $\mathbb{1}(\widehat{\eta} > \frac{1}{2})$ wskaże w $\mathbf{x}$ inną klasę niż klasyfikator bayesowski, oraz błąd średniokwadratowy $\mathbb{E}[(\widehat{\eta} - \eta)^2]$.

b) Wskaż pary oszacowań, w których mniejszy błąd średniokwadratowy idzie w parze z większym prawdopodobieństwem złej klasyfikacji.

c) Dla $\bar{\eta} = 0{,}45$ wyznacz granicę prawdopodobieństwa błędnej decyzji przy $s \to \infty$ i przy $s \to 0$. Zinterpretuj wynik.

d) Sprawdź symulacyjnie, że opisane zjawisko występuje dla klasyfikatora k-NN, wybierając punkt, w którym przy dużym k oszacowanie $\bar{\eta}$ przechodzi na złą stronę progu.

5. Ocena modeli w praktyce

Ryzyko $R(f) = \mathbb{E}\big[L(Y, f(\mathbf{X}))\big]$ jest średnią po rozkładzie P, którego nie znamy. W rozdziałach 2–4 mogliśmy je liczyć dokładnie, bo dane były sztuczne, a rozkład – zadany przez nas. W realnym problemie mamy tylko próbę. Jedyną wielkością, jaką można policzyć od razu, jest błąd na zbiorze uczącym, a ten, jak pokazała sekcja 4.1, jest optymistyczny i to tym bardziej, im elastyczniejsza metoda. Wskazuje zawsze model najbardziej elastyczny, a więc często najgorszy.

Ten rozdział omawia, jak szacować ryzyko z danych. Wszystkie metody opierają się na jednej zasadzie, którą sformułowaliśmy już w rozdziale 1: model trzeba oceniać na obserwacjach, których nie widział podczas dopasowania. Różnią się tym, jak takie obserwacje uzyskać, gdy próba jest jedna, i jaką cenę za to płacimy. Przykłady liczymy dalej na danych sztucznych z rozdziału 4, bo tylko tam możemy porównać oszacowanie z prawdziwym ryzykiem i sprawdzić, jak dobre jest.

5.1. Trzy pytania

Pytanie „jak dobry jest model?" kryje w sobie trzy różne pytania, na które odpowiada się różnymi narzędziami.

Selekcja modelu. Mamy kilku kandydatów: różne wartości k w metodzie k-NN, różne stopnie wielomianu, różne metody. Chcemy wybrać tego, którego ryzyko jest najmniejsze. Do tego wystarczy **uporządkować** kandydatów według ryzyka. Oszacowanie może systematycznie zawyżać ryzyko, na przykład dlatego, że modele uczymy na części danych, byle o podobną wielkość dla wszystkich kandydatów: wspólne przesunięcie nie zmienia kolejności. Liczy się dokładność, z jaką szacujemy **różnice** ryzyk.

Ocena modelu. Wybraliśmy model i chcemy wiedzieć, ile wynosi jego ryzyko: jaki odsetek pomyłek popełni na nowych pacjentach, o ile przeciętnie pomyli się w prognozie. Tu potrzebna jest **wartość** ryzyka, a obciążenie oszacowania jest błędem.

Ryzyko modelu czy ryzyko metody. W ramce „Ryzyko modelu a ryzyko metody" z rozdziału 4 rozróżniliśmy dwie wielkości. Pierwsza to ryzyko $R(\hat{f}_{\mathcal{D}})$ predyktora dopasowanego do zbioru uczącego $\mathcal{D}$, który faktycznie mamy. Druga to ryzyko oczekiwane metody uczenia, uśrednione po zbiorach uczących liczności n:

$$\overline{R}_n = \mathbb{E}_{\mathcal{D}}[R(\hat{f}_{\mathcal{D}})]. \tag{5.1}$$

Przy ocenie gotowego modelu, który trafi do użytku, interesuje nas pierwsza. Przy porównaniu metod, na przykład w pracy badawczej, częściej druga. Część narzędzi szacuje pierwszą z nich, część – drugą, choć zwykle przedstawia się je wszystkie jako oszacowania „błędu modelu".

Pytania i narzędzia

Pytanie	Narzędzie	Sekcja
ryzyko dopasowanego predyktora, gdy nic już nie wybieramy	zbiór testowy	5.2
wybór spośród kandydatów	zbiór walidacyjny, walidacja krzyżowa	5.3, 5.4
ryzyko predyktora wybranego spośród kandydatów na tych samych danych	nietknięty zbiór testowy (ryzyko wybranego modelu) albo zagnieżdżona walidacja krzyżowa (ryzyko oczekiwane procedury wyboru)	5.6
niepewność dowolnej wielkości obliczonej z próby	bootstrap	5.8

5.2. Zbiór testowy

Najprostsza sytuacja wygląda tak. Predyktor $\hat{f}$ jest już ustalony: dopasowaliśmy go do zbioru uczącego $\mathcal{D}$ i więcej go nie zmieniamy. Mamy też **zbiór testowy** – m nowych obserwacji $(\mathbf{X}'_1, Y'_1), \ldots, (\mathbf{X}'_m, Y'_m)$, niezależnych od siebie i od $\mathcal{D}$, z tego samego rozkładu P. Ryzyko szacujemy średnią stratą na zbiorze testowym:

$$\widehat{R}_{\text{test}} = \frac{1}{m} \sum_{j=1}^{m} L(Y'_j, \hat{f}(\mathbf{X}'_j)). \tag{5.2}$$

Jest to ryzyko empiryczne (1.9), tyle że liczone na danych, których predyktor nie widział. W rozdziale 1 zauważyliśmy, że dla predyktora ustalonego niezależnie od danych taka średnia jest nieobciążonym oszacowaniem ryzyka. Teraz możemy to powiedzieć dokładniej.

Twierdzenie 5.1 (Własności oszacowania testowego)**.** *Niech zbiór testowy będzie niezależny od $\mathcal{D}$, a jego obserwacje niezależne i o rozkładzie P. Oznaczmy $\tau^2 = \operatorname{Var}\left(L(Y, \hat{f}(\mathbf{X})) \,\middle|\, \mathcal{D}\right)$ wariancję straty na nowej obserwacji przy ustalonym predyktorze. Wtedy*

$$\mathbb{E}\left[\widehat{R}_{\text{test}} \,\middle|\, \mathcal{D}\right] = R(\hat{f}), \qquad \operatorname{Var}\left(\widehat{R}_{\text{test}} \,\middle|\, \mathcal{D}\right) = \frac{\tau^2}{m}.$$

Przy stracie 0–1 liczba błędów $m\widehat{R}_{\text{test}}$ ma, przy ustalonym $\mathcal{D}$, rozkład dwumianowy z parametrami m i $R(\hat{f})$, a $\tau^2 = R(\hat{f})(1 - R(\hat{f}))$.

Dowód. Przy ustalonym $\mathcal{D}$ predyktor $\hat{f}$ jest ustaloną funkcją, a straty $L_j = L(Y'_j, \hat{f}(\mathbf{X}'_j))$ są niezależnymi zmiennymi losowymi o tym samym rozkładzie, ze średnią $R(\hat{f})$ i wariancją τ^2. Średnia m takich zmiennych ma tę samą wartość oczekiwaną i wariancję τ^2/m. Przy stracie 0–1 każda strata L_j jest zmienną zero-jedynkową z prawdopodobieństwem sukcesu $R(\hat{f})$, więc ich suma ma rozkład dwumianowy. □ □

Założenie niezależności od $\mathcal{D}$ jest tu wszystkim. Gdyby obserwacje testowe trafiły choć częściowo do zbioru uczącego, straty L_j nie miałyby średniej $R(\hat{f})$ – mielibyśmy z powrotem optymizm błędu uczącego. Zwróćmy też uwagę, co twierdzenie szacuje: ryzyko **tego** predyktora, $R(\hat{f}_{\mathcal{D}})$, a nie ryzyko metody (5.1).

5.2.1. Niepewność oszacowania

Pierwiastek z wariancji, $\tau/\sqrt{m}$, to **błąd standardowy** oszacowania testowego. W klasyfikacji szacujemy go, podstawiając oszacowanie w miejsce ryzyka:

$$\widehat{\mathrm{se}} = \sqrt{\frac{\widehat{R}_{\mathrm{test}}\,(1-\widehat{R}_{\mathrm{test}})}{m}}. \tag{5.3}$$

Przy dużym m rozkład dwumianowy jest bliski normalnemu, więc przedział $\widehat{R}_{\mathrm{test}} \pm 1{,}96\,\widehat{\mathrm{se}}$ pokrywa ryzyko z prawdopodobieństwem około 95%. W regresji nie ma takiego wzoru i wariancję τ^2 szacujemy wariancją z próby strat testowych $L_j = L(Y'_j, \hat{f}(\mathbf{X}'_j))$, $j = 1, \ldots, m$. Kwadraty błędów mają jednak zwykle rozkład silnie skośny, więc przybliżenie normalne wymaga tu większego m niż w klasyfikacji.

Wzór (5.3) szybko studzi zaufanie do małych zbiorów testowych. Przy błędzie rzędu 10% i $m = 100$ błąd standardowy wynosi 0,03, więc przedział ufności rozciąga się od około 4% do 16%. Aby połowa szerokości przedziału wynosiła h, potrzeba

$$m \approx \frac{1{,}96^2\, R(1-R)}{h^2}$$

obserwacji. Dla $R = 0{,}1$ i $h = 0{,}01$ to około 3500 obserwacji, dla $h = 0{,}005$ – około 14 000. Dokładność rośnie jak $\sqrt{m}$: dwukrotne zawężenie przedziału kosztuje czterokrotnie więcej danych. Ten sam rachunek stał za ramką „Dlaczego całkujemy zamiast losować zbiór testowy" w rozdziale 2: przy błędzie około 0,16 i 20 000 obserwacjach testowych błąd standardowy wynosi $\sqrt{0{,}16 \cdot 0{,}84/20\,000} \approx 0{,}0026$.

5.2.2. Porównanie dwóch modeli

Częściej niż wartość ryzyka interesuje nas, który z dwóch modeli, A czy B, jest lepszy. Naturalnym oszacowaniem różnicy ryzyk jest różnica oszacowań testowych. Jeśli oba modele oceniamy na **tym samym** zbiorze testowym, różnica ta jest średnią różnic strat $D_j = L_j^A - L_j^B$ na poszczególnych obserwacjach, a jej wariancja wynosi

$$\frac{\mathrm{Var}(L^A - L^B)}{m} = \frac{\tau_A^2 + \tau_B^2 - 2\,\mathrm{Cov}(L^A, L^B)}{m}.$$

Straty dwóch rozsądnych modeli są silnie dodatnio skorelowane: oba mylą się na trudnych przypadkach i oba trafiają na łatwych. Kowariancja odejmuje się więc od sumy wariancji, a różnica jest szacowana znacznie dokładniej niż każde z ryzyk z osobna. Porównując modele, należy zatem korzystać z par strat na tych samych obserwacjach, a nie z dwóch oddzielnych przedziałów ufności.

Przy stracie 0–1 rachunek ma prostą postać. Obserwacje, na których oba modele się mylą albo oba trafiają, nic nie mówią o różnicy. Liczą się tylko obserwacje sporne: n_{AB} takich, na których myli się tylko A, i n_{BA} takich, na których myli się tylko B. Jeśli oba modele mają to samo ryzyko, to każda obserwacja sporna jest z równym prawdopodobieństwem jednego lub drugiego rodzaju, czyli n_{AB} ma rozkład dwumianowy z parametrami $n_{AB} + n_{BA}$ i 1/2. Na tym opiera się **test**

McNemara, polecany do porównywania dwóch klasyfikatorów na jednym zbiorze testowym (Dietterich 1998). Przykład: na $m = 1000$ obserwacjach model A myli się 100 razy, a model B – 120 razy. Dwa oddzielne przedziały ufności wyraźnie na siebie nachodzą: różnica 0,02 to tylko około 1,4 błędu standardowego różnicy dwóch niezależnych oszacowań. Jeśli jednak modele różnią się na 40 obserwacjach, z których na 30 myli się tylko B, a na 10 tylko A, to przy równości ryzyk wynik tak skrajny jak 10 do 30 ma prawdopodobieństwo około 0,002. Przewaga modelu A jest dobrze udokumentowana (Zadanie 5.3).

5.2.3. Cena odłożenia danych

Zbiór testowy nie jest za darmo. Obserwacje odłożone do oceny nie biorą udziału w uczeniu, więc oceniamy model uczony na $n-m$ zamiast n obserwacjach. Krzywe uczenia z sekcji 4.7 mówią, ile to kosztuje. Jeśli krzywa jest przy $n-m$ już płaska, niewiele. Jeśli stromo opada, model uczony na wszystkich danych byłby wyraźnie lepszy niż ten, który oceniliśmy. Mamy więc konflikt: duże m daje dokładną ocenę słabszego modelu, małe m – niedokładną ocenę lepszego.

Druga cena jest mniej oczywista. Zbiór testowy zachowuje swoje własności tylko wtedy, gdy wynik na nim nie wpływa na model. Jeśli po obejrzeniu błędu testowego zmienimy cechy, hiperparametry czy metodę, a potem ocenimy nowy model na tym samym zbiorze, zbiór testowy stał się częścią procedury uczenia. Każde takie spojrzenie zużywa go po trochu (sekcja 5.6).

5.3. Zbiór walidacyjny

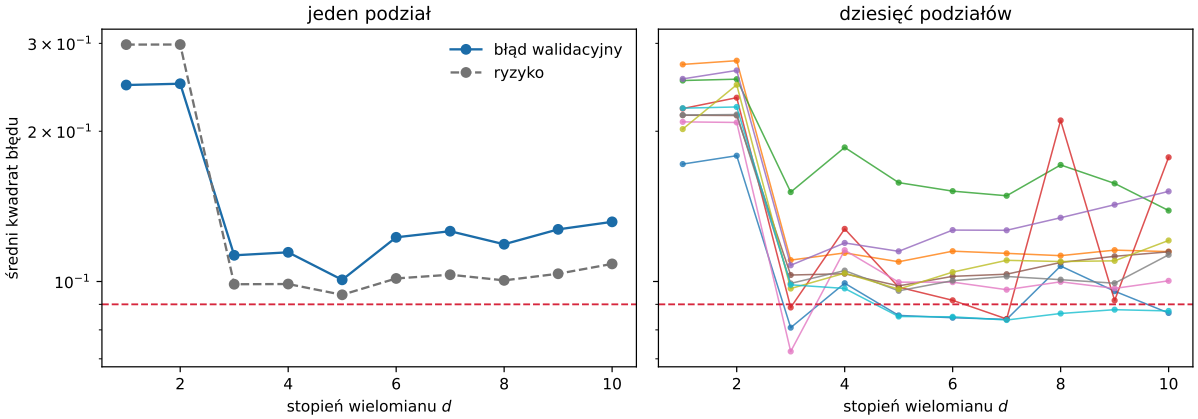
Gdy oprócz oceny trzeba dokonać wyboru – ustalić k, stopień wielomianu albo metodę – dane dzieli się na trzy części. Na **zbiorze uczącym** dopasowujemy kandydatów. Na **zbiorze walidacyjnym** szacujemy ich ryzyka i wybieramy najlepszego. Na **zbiorze testowym**, którego dotąd nie dotykaliśmy, oceniamy model wybrany. Zbiór walidacyjny odpowiada na pytanie o selekcję, zbiór testowy – na pytanie o ocenę.

Podział na zbiór uczący i walidacyjny ma dwie wady. Obie widać na rysunku 5.1. Wzięliśmy próbę $n = 100$ obserwacji z rozkładu z rozdziału 4: X jednostajne na $[0, 1]$, $f^*(x) = \sin(2\pi x)+x/2$, szum o odchyleniu standardowym $\sigma = 0{,}3$. Połowę obserwacji przeznaczyliśmy do uczenia wielomianów stopni 1–10, połowę – do walidacji.

Lewy panel pokazuje, że błąd walidacyjny dobrze oddaje kształt krzywej ryzyka: obie gwałtownie spadają między stopniem 2 a 3, mają minimum w okolicy stopnia 5 i dalej powoli rosną. Do selekcji to wystarcza. Prawy panel pokazuje pierwszą wadę: wynik zależy od tego, które obserwacje trafiły do której części. Różne podziały tej samej próby dają krzywe przesunięte względem siebie i wskazują różne stopnie jako najlepsze. Zbiór walidacyjny liczy 50 obserwacji, a jak widzieliśmy w sekcji 5.2, przy takiej liczności oszacowanie ma duży błąd standardowy. Druga wada to marnotrawstwo: wielomiany uczymy na połowie danych, więc oceniamy modele gorsze niż te, które moglibyśmy dopasować do całej próby. Przy stromej krzywej uczenia błąd walidacyjny przeszacowuje wtedy ryzyko, a przy stopniach wysokich, których wariancja najsilniej zależy od n, przeszacowuje je najbardziej. Wybieramy przez to model zwykle prostszy niż ten, który byłby najlepszy po dopasowaniu do całej próby.

5.4. Walidacja krzyżowa

Obie wady łagodzi prosty pomysł: zamiast jednego podziału zrobić kilka i tak je dobrać, by każda obserwacja trafiła do części oceniającej dokładnie raz.



Rysunek 5.1.: Błąd na zbiorze walidacyjnym regresji wielomianowej w zależności od stopnia d. Próba liczności $n = 100$ podzielona losowo na połowę uczącą i połowę walidacyjną. Po lewej: jeden podział; szara linia to ryzyko tych samych wielomianów, policzone całkowaniem po znanym rozkładzie. Po prawej: dziesięć różnych podziałów tej samej próby. Oś pionowa w skali logarytmicznej.

Definicja 5.1 (Walidacja krzyżowa)**.** Podzielmy indeksy $\{1, \dots, n\}$ losowo na K rozłącznych części $F_1, \dots, F_K$ możliwie równej liczności. Niech $\hat{f}^{(-k)}$ oznacza predyktor dopasowany do wszystkich obserwacji poza częścią F_k. **K-krotną walidacją krzyżową** (ang. *K-fold cross-validation*) nazywamy oszacowanie ryzyka

$$\mathrm{CV}_K = \frac{1}{n} \sum_{k=1}^{K} \sum_{i \in F_k} L(y_i, \hat{f}^{(-k)}(\mathbf{x}_i)). \tag{5.4}$$

Przypadek $K = n$, w którym każda część zawiera jedną obserwację, nazywamy **walidacją typu „pozostaw jeden”** (ang. *leave-one-out cross-validation*, LOOCV).

Każda obserwacja jest oceniana dokładnie raz, przez predyktor, który jej nie widział, i bierze udział w uczeniu $K-1$ razy. Wszystkie dane służą więc zarówno do uczenia, jak i do oceny, choć nigdy jednocześnie. Kosztem jest K dopasowań zamiast jednego. Pomysł ma długą historię; jego ujęcie jako ogólnej metody wyboru i oceny predyktorów zawdzięczamy M. Stone (1974).

Przy wyborze spośród kandydatów każdy z nich oceniamy na tym samym podziale na części, a wybieramy tego o najmniejszym CV_K. Dzięki temu porównanie jest sparowane w sensie sekcji 5.2: losowość podziału wpływa podobnie na wszystkich kandydatów.

5.4.1. Błąd uczący a LOOCV

Błąd uczący zaniża ryzyko, bo każdy punkt uczący wpływa na własną predykcję. W regresji k-NN (3.1) ten wpływ ma prostą postać: wynik y_i wchodzi do predykcji w $\mathbf{x}_i$ z wagą $1/k$. Pozwala to wyrazić resztę „pozostaw jeden” przez resztę na zbiorze uczącym. Niech wszystkie odległości między punktami będą różne, aby nie było remisów. Każdy punkt uczący $\mathbf{x}_i$ należy do swojego otoczenia $N_k(\mathbf{x}_i)$, bo sam od siebie ma odległość zero. Predykcja w punkcie uczącym to więc

$$\hat{f}(\mathbf{x}_i) = \frac{1}{k}\Big(y_i + \sum_{j \in N_k(\mathbf{x}_i),\, j \neq i} y_j\Big) = \frac{1}{k}\, y_i + \frac{k-1}{k}\, \hat{f}^{(-i)}(\mathbf{x}_i),$$

gdzie $\widehat{f}^{(-i)}(\mathbf{x}_i)$ jest średnią wyników $k-1$ pozostałych sąsiadów. Te $k-1$ punktów to dokładnie najbliżsi sąsiedzi $\mathbf{x}_i$ po usunięciu obserwacji i ze zbioru uczącego, więc $\widehat{f}^{(-i)}$ jest predyktorem $(k-1)$-NN dopasowanym bez obserwacji i. Odejmując obie strony od y_i, dostajemy

$$y_i - \hat{f}(\mathbf{x}_i) = \frac{k-1}{k}\,(y_i - \widehat{f}^{(-i)}(\mathbf{x}_i)). \tag{5.5}$$

Reszta na zbiorze uczącym jest więc resztą „pozostaw jeden" pomniejszoną o czynnik $(k-1)/k$. Stąd błąd LOOCV reguły $(k-1)$-NN jest równy błędowi uczącemu reguły k-NN pomnożonemu przez $\left(k/(k-1)\right)^2$ (Zadanie 5.5). Dla dużego k ten czynnik wynosi w przybliżeniu $1+2/k$, co zgadza się z wynikiem zadania 4.4: optymizm błędu uczącego reguły k-NN jest rzędu $2\sigma^2/k$.

Podobną postać mają wszystkie metody, w których wektor predykcji na zbiorze uczącym jest liniową funkcją wektora wyników, $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$, a usunięcie obserwacji nie zmienia sposobu ważenia pozostałych. Reszta „pozostaw jeden" wynosi wtedy $(y_i - \widehat{f}(\mathbf{x}_i))/(1-S_{ii})$, gdzie S_{ii} to waga, jaką predykcja w $\mathbf{x}_i$ przypisuje własnemu wynikowi (Hastie i in. 2009, rozdz. 7.10). Dla k-NN $S_{ii} = 1/k$. Do tej klasy należy też metoda najmniejszych kwadratów, w tym regresja wielomianowa z rozdziału 4. Im większa waga S_{ii}, tym mniejsza jest reszta na zbiorze uczącym w porównaniu z resztą „pozostaw jeden". Ubocznym skutkiem jest oszczędność obliczeń: walidacja „pozostaw jeden" wymaga wtedy jednego dopasowania zamiast n.

5.4.2. Ile części

Wybór K to znów kompromis między obciążeniem a wariancją, tym razem nie predyktora, tylko oszacowania ryzyka.

Najpierw obciążenie. Każdy z predyktorów $\widehat{f}^{(-k)}$ uczy się na $n(K-1)/K$ obserwacjach i jest oceniany na obserwacjach, których nie widział. Jeśli części mają równe liczności, każdy składnik sumy (5.4) ma więc wartość oczekiwaną równą ryzyku oczekiwanemu metody uczonej na próbie mniejszej niż n:

$$\mathbb{E}[\mathrm{CV}_K] = \overline{R}_{n(K-1)/K}. \tag{5.6}$$

Walidacja krzyżowa jest zatem **pesymistyczna**: szacuje ryzyko metody uczonej na mniejszej próbie, niż ta, której użyjemy. Wielkość pesymizmu zależy od nachylenia krzywej uczenia w okolicy n. Przy $K=2$ uczymy na połowie danych i pesymizm bywa znaczny, przy $K=n$ jest praktycznie zerowy.

Z wariancją sprawa jest mniej oczywista. Przy dużym K zbiory uczące różnych części pokrywają się prawie całkowicie, więc predyktory $\widehat{f}^{(-k)}$ są do siebie bardzo podobne, a ich błędy – silnie skorelowane. Średnia skorelowanych wielkości ma większą wariancję niż średnia niezależnych (Zadanie 4.8). Z tego powodu często mówi się, że LOOCV ma dużą wariancję. Z drugiej strony przy dużym K każdy predyktor jest lepszy, a podziałów nie trzeba losować. Który efekt przeważa, zależy od metody. Sprawdźmy to na naszym przykładzie: dla wielomianu stopnia 3 i $n=50$ wylosowaliśmy 500 prób i w każdej policzyliśmy CV_K dla $K = 2, 5, 10, 50$ oraz, całkowaniem, prawdziwe ryzyko dopasowanego modelu.

```
ryzyko oczekiwane przy n = 50: 0.1028
 K   uczących   E[R] przy n(K-1)/K   średnia CV   odch. std. CV
 2         25               0.1176       0.1143          0.0349
 5         40               0.1057       0.1041          0.0233
10         45               0.1043       0.1029          0.0221
50         49               0.1034       0.1020          0.0215
```

Średnie oszacowań układają się zgodnie z (5.6). Dla $K = 2$ średnia jest bliska ryzyku metody uczonej na 25 obserwacjach i wyraźnie wyższa niż ryzyko przy $n = 50$. Dla $K \geq 5$ pesymizm jest już mały w porównaniu z rozrzutem oszacowania. Odchylenie standardowe maleje z K, ale dla $K = 5, 10, 50$ jest prawie takie samo. W tym przykładzie LOOCV nie ma więc większej wariancji niż walidacja dziesięciokrotna. Wariancja LOOCV bywa duża przy metodach niestabilnych, których dopasowanie zmienia się skokowo przy niewielkiej zmianie danych (Arlot i Celisse 2010). Przy małym K niestabilność dotyka też walidacji krzyżowej: wielomian wysokiego stopnia uczony na połowie próby czasem „ucieka" przy krańcach przedziału, jak na rysunku 4.2, i pojedyncza część daje wtedy ogromny błąd.

W praktyce standardem jest $K = 5$ lub $K = 10$ (James i in. 2023, rozdz. 5.1). Pesymizm jest wtedy zwykle niewielki, koszt – pięć lub dziesięć dopasowań, a wynik nie zależy od szczególnych własności metody.

5.4.3. Co szacuje walidacja krzyżowa

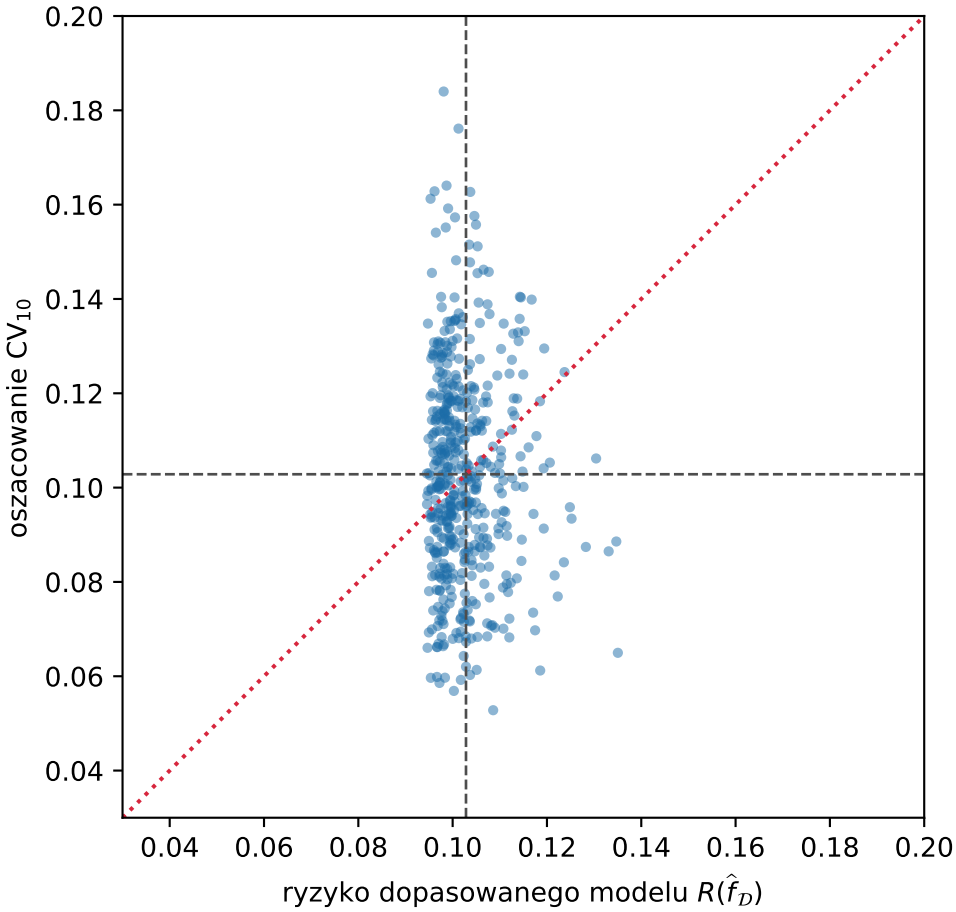
Z (5.6) wynika, że walidacja krzyżowa jest oszacowaniem ryzyka oczekiwanego metody, a nie ryzyka modelu dopasowanego do naszej próby. Można by jednak sądzić, że skoro oszacowanie liczymy z naszej próby, to przynajmniej podąża za ryzykiem naszego modelu: w próbach, z których wyszedł model gorszy niż przeciętny, powinno być wyższe. Rysunek 5.2 pokazuje, że tak nie jest.

```
odch. std. ryzyka modelu:  0.0090
odch. std. CV_10:          0.0221
korelacja:                 -0.022
```

Chmura punktów jest wydłużona w pionie i nie układa się wzdłuż przekątnej. Ryzyko dopasowanego modelu zmienia się od próby do próby niewiele, a oszacowanie walidacją krzyżową – ponad dwa razy bardziej, i obie wielkości są praktycznie nieskorelowane. Większość rozrzutu oszacowania pochodzi z szumu w n obserwacjach, na których je liczymy, a nie z różnic między dopasowanymi modelami. Oszacowanie trafia przeciętnie w $\overline{R}_n$ – środek chmury leży na przecięciu linii przerywanych – ale nie mówi, czy nasz model jest lepszy, czy gorszy od przeciętnego. Podobny obraz w przykładzie klasyfikacyjnym przedstawiają Hastie i in. (2009, rozdz. 7.12). Bates i in. (2024) wykazali, że dla modelu liniowego dopasowanego metodą najmniejszych kwadratów wielkością szacowaną przez walidację krzyżową nie jest ryzyko modelu dopasowanego do posiadanych danych, lecz ryzyko uśrednione po wielu hipotetycznych próbach, czyli $\overline{R}_n$. Ramka „Ryzyko modelu a ryzyko metody" z rozdziału 4 dostaje w ten sposób konkretną treść: walidacja krzyżowa ocenia procedurę uczenia zastosowaną do prób liczności n, a nie konkretny dopasowany model. Ocenę konkretnego modelu daje tylko niezależny zbiór testowy.

5.4.4. Błąd standardowy walidacji krzyżowej

Wynik walidacji krzyżowej podaje się zwykle z błędem standardowym. Najprostszy przepis traktuje n strat z (5.4) jak straty na zbiorze testowym i dzieli ich odchylenie standardowe przez $\sqrt{n}$. Te straty nie są jednak niezależne: każda para obserwacji z różnych części ma wspólną większość zbioru uczącego. Bengio i Grandvalet (2004) wykazali, że nieobciążony estymator wariancji CV_K nie istnieje dla żadnego K. Naiwny błąd standardowy jest zwykle zaniżony. W symulacji z rysunku 5.2 wygląda to tak:



Rysunek 5.2.: Oszacowanie dziesięciokrotną walidacją krzyżową a ryzyko dopasowanego modelu $R(\hat{f}_{\mathcal{D}})$ dla 500 prób liczności $n = 50$ (wielomian stopnia 3). Linie przerywane: ryzyko oczekiwane metody $\overline{R}_n$. Linia kropkowana: prosta $y = x$.

```
rzeczywiste odch. std. CV_10:      0.0221
średni naiwny błąd standardowy:    0.0202
pokrycie przedziału +- 1,96 se:    0.890
```

Naiwny błąd standardowy jest tu zaniżony o około 10%, a przedział, który nominalnie ma pokrywać ryzyko oczekiwane w 95% prób, pokrywa je w 89%. Przy metodach mniej stabilnych różnica bywa większa. Poprawne przedziały ufności dla walidacji krzyżowej wymagają dodatkowej pracy obliczeniowej (Bates i in. 2024). Do porównań i do wyboru modelu naiwny błąd standardowy wystarcza jednak jako miara skali niepewności.

Tak używa go **reguła jednego błędu standardowego** (Hastie i in. 2009, rozdz. 7.10). Niech j^* będzie kandydatem o najmniejszym oszacowaniu CV_K, a se_{j^*} jego błędem standardowym. Spośród kandydatów, dla których $\mathrm{CV}_K(j) \leq \mathrm{CV}_K(j^*) + \mathrm{se}_{j^*}$, wybieramy najprostszego, czyli najmniej elastycznego. Uzasadnienie jest heurystyczne: różnice mniejsze niż błąd standardowy mogą być przypadkowe, a w razie wątpliwości model prostszy ma mniejszą wariancję i łatwiej go interpretować.

5.4.5. Walidacja krzyżowa w klasyfikacji

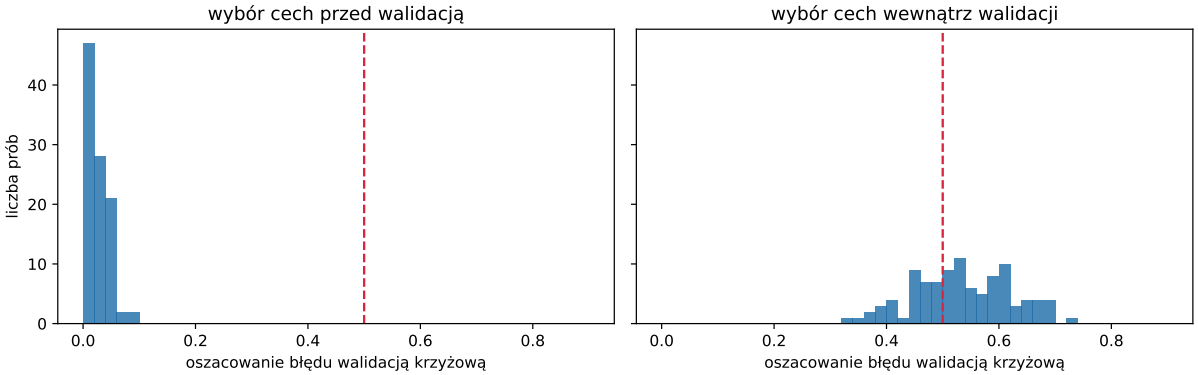
W klasyfikacji podział na części losuje się zwykle **warstwowo** (ang. *stratified*): tak, by proporcje klas w każdej części były takie jak w całej próbie. Przy rzadkiej klasie podział niewarstwowy może dać część bez żadnej obserwacji z tej klasy i błąd tej części nic o niej nie powie.

Druga decyzja dotyczy straty, którą oceniamy. Strata 0–1 odpowiada pytaniu o odsetek pomyłek, ale jest bardzo zgrubna: oszacowanie zmienia się skokami $1/n$ i nie odróżnia modelu, który pomylił się, podając $\hat{\eta} = 0{,}51$, od modelu, który podał 0,99. Jeśli model ma zwracać prawdopodobieństwa, na przykład dla reguły kosztowej z sekcji 2.5, należy go oceniać stratą właściwą: Briera albo logarytmiczną. Oszacowanie jest wtedy mniej zmienne, bo każda obserwacja wnosi informację ciągłą, a nie tylko „trafił–nie trafił". Strata logarytmiczna ma przy tym pułapkę: model k-NN zwraca $\hat{\eta} = 0$ albo 1, gdy wszyscy sąsiedzi są z jednej klasy. Jedna taka pomyłka daje stratę nieskończoną.

5.5. Wyciek informacji

Twierdzenie 5.1 i równość (5.6) mają wspólne założenie: obserwacje, na których oceniamy, nie mają żadnego wpływu na predyktor. W walidacji krzyżowej dotyczy to **całej procedury**, która z danych tworzy predyktor, a nie tylko ostatniego kroku, czyli dopasowania modelu. Każdy krok, w którym coś wyznaczamy z danych – parametry standaryzacji (3.4), uzupełnianie braków średnimi, wybór cech – trzeba powtarzać wewnątrz każdej części, korzystając wyłącznie z jej danych uczących. Złamanie tej zasady nazywa się **wyciekiem informacji** (ang. *data leakage*): informacja o obserwacjach oceniających przecieka do predyktora.

Przy standaryzacji wyciek jest zwykle niewielki. Średnia i odchylenie standardowe liczone z n zamiast z $n(K-1)/K$ obserwacji różnią się niewiele i prawie nic nie mówią o wynikach. Przy wyborze cech może być ogromny. Rozważmy przykład z Hastie i in. (2009, rozdz. 7.10.2). Mamy $n = 50$ obserwacji z dwóch równolicznych klas i $p = 5000$ cech, które są czystym szumem: nie zależą od klasy. Każdy klasyfikator ma tu ryzyko 1/2. Procedura jest następująca: wybieramy 100 cech najsilniej skorelowanych z klasą, a na nich budujemy klasyfikator jednego najbliższego sąsiada. Procedurę oceniamy pięciokrotną walidacją krzyżową na dwa sposoby. W **złym** wybór cech robimy raz, na całej próbie, a walidacji poddajemy tylko klasyfikator. W **dobrym** wybór cech powtarzamy w każdej części, na jej danych uczących.



Rysunek 5.3.: Oszacowania błędu procedury „wybór 100 cech najsilniej skorelowanych z klasą + klasyfikator 1-NN" pięciokrotną walidacją krzyżową, dla 100 prób ($n = 50$, $p = 5000$ cech niezależnych od klasy). Po lewej: wybór cech na całej próbie, przed walidacją. Po prawej: wybór cech wewnątrz każdej części. Czerwona linia: prawdziwe ryzyko 1/2.

```
średnie oszacowanie: zły sposób 0.017, dobry sposób 0.525
```

Zły sposób przekonuje, że klasyfikator niemal się nie myli, choć w danych nie ma żadnej informacji o klasie. Mechanizm jest prosty. Wśród 5000 cech szumu przy 50 obserwacjach zawsze znajdą się takie, które przypadkiem silnie korelują z klasą. Wybierając je na całej próbie, wybieramy cechy dopasowane także do klas obserwacji, które później posłużą do oceny. Klasyfikator „wie" o nich coś, czego w nowych danych nie będzie. Dobry sposób daje oszacowania rozrzucone wokół 1/2, jak być powinno. Ten błąd metodologiczny nie jest wymyślony: Ambroise i McLachlan (2002) pokazali, że w opublikowanych analizach danych z mikromacierzy, gdzie cech są tysiące, a obserwacji kilkadziesiąt, prowadził on do raportowania błędów bliskich zera dla klasyfikatorów bez wartości predykcyjnej.

W bibliotece scikit-learn przed tym błędem chroni potok (`Pipeline`), o którym mówiliśmy w sekcji 3.7. Funkcje walidacji krzyżowej wywołują `fit` całego potoku osobno w każdej części, więc standaryzacja, wybór cech i model widzą tylko jej dane uczące.

Wyciek ma też źródła, przed którymi potok nie chroni, bo dotyczą samego podziału na części. Walidacja krzyżowa zakłada, że obserwacje są niezależne, a nowe dane pochodzą z tego samego rozkładu. Gdy to założenie zawodzi, losowy podział daje ocenę zbyt optymistyczną:

- **Obserwacje zgrupowane.** Jeśli mamy po kilka pomiarów każdego pacjenta, a model ma działać dla nowych pacjentów, to losowy podział pomiarów pozwala ocenić model na pacjencie, którego inne pomiary widział. Dzielić trzeba całe grupy (w scikit-learn `GroupKFold`).
- **Dane uporządkowane w czasie.** Jeśli model ma przewidywać przyszłość, ocenia się go tylko na obserwacjach późniejszych niż te, na których się uczył (`TimeSeriesSplit`). Losowy podział pozwala „przewidywać" przeszłość na podstawie przyszłości.
- **Duplikaty.** Te same lub prawie te same obserwacje w części uczącej i oceniającej działają jak obserwacje testowe w zbiorze uczącym. Do tej kategorii należy też powielanie obserwacji rzadkiej klasy przeprowadzone przed podziałem.
- **Cechy z przyszłości.** Cecha zarejestrowana po zdarzeniu, które przewidujemy – na przykład kod zabiegu wykonywanego tylko u chorych – daje świetne wyniki w walidacji i jest niedostępna w momencie, gdy predykcja jest potrzebna.

Ogólna zasada jest taka: podział na część uczącą i oceniającą ma naśladować sytuację, w której model będzie używany. Jeśli przyszłe dane będą pochodzić z innego szpitala, innego roku albo innej populacji niż próba, żaden podział próby tego nie odtworzy. Walidacja krzyżowa szacuje ryzyko w populacji, z której pochodzi próba, a wiarygodność tej oceny, jak zauważyliśmy w rozdziale 1, zależy od sposobu zebrania danych.

5.6. Selekcja modelu a ocena modelu

Wróćmy do trzech pytań z początku rozdziału. Walidacja krzyżowa służy do wyboru spośród kandydatów. Po wyborze kusi, by jako ocenę wybranego modelu podać jego wynik walidacji krzyżowej, najmniejszy wśród kandydatów. To błąd, i to systematyczny.

Twierdzenie 5.2 (Optymizm wyboru)**.** *Niech $\widehat{R}_1, \dots, \widehat{R}_M$ będą oszacowaniami ryzyk $R_1, \dots, R_M$ kandydatów, nieobciążonymi: $\mathbb{E}[\widehat{R}_j] = R_j$. Niech $\hat{\jmath}$ będzie indeksem najmniejszego oszacowania. Ryzyka R_j są tu liczbami, a losowe są oszacowania i wraz z nimi indeks $\hat{\jmath}$, więc także $R_{\hat{\jmath}}$. Wtedy*

$$\mathbb{E}[\widehat{R}_{\hat{\jmath}}] = \mathbb{E}\Big[\min_j \widehat{R}_j\Big] \le \min_j R_j \le \mathbb{E}[R_{\hat{\jmath}}].$$

Gdy kandydaci są dopasowani do zbioru uczącego $\mathcal{D}$, a oceniani na niezależnym zbiorze walidacyjnym, twierdzenie stosujemy przy ustalonym $\mathcal{D}$, z wartościami oczekiwanymi warunkowymi względem $\mathcal{D}$.

Dowód. Dla każdego l zachodzi $\min_j \widehat{R}_j \le \widehat{R}_l$. Biorąc wartość oczekiwaną, dostajemy $\mathbb{E}[\min_j \widehat{R}_j] \le R_l$ dla każdego l, a więc także dla tego, przy którym R_l jest najmniejsze. Zmienna $R_{\hat{\jmath}}$ zależy od danych tylko przez indeks $\hat{\jmath}$, więc

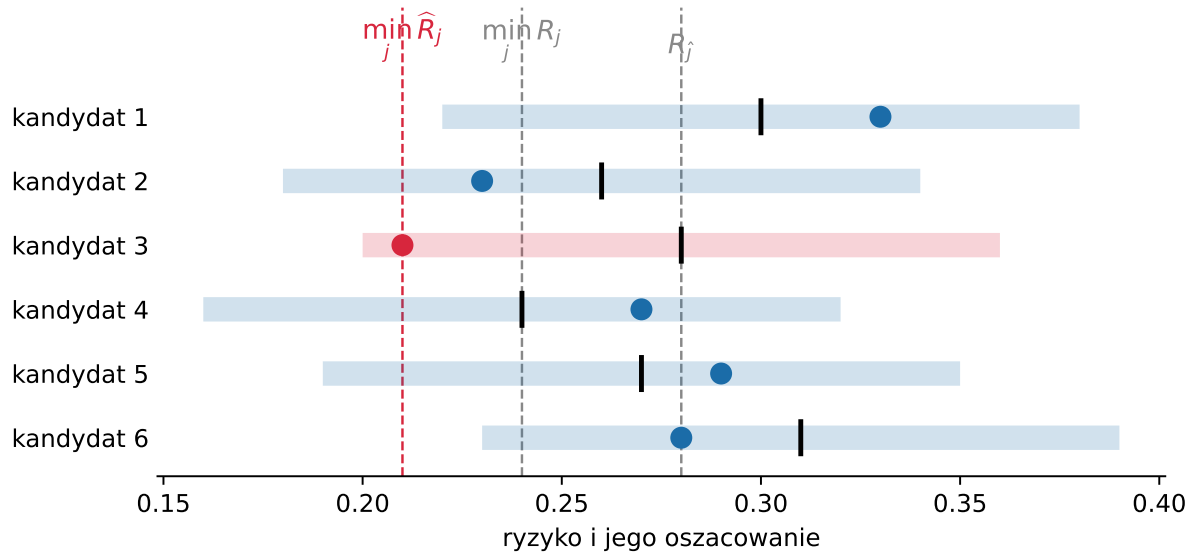
$$\mathbb{E}[R_{\hat{\jmath}}] = \sum_{j=1}^{M} R_j \, P(\hat{\jmath} = j).$$

Jest to średnia ważona ryzyk $R_1, \dots, R_M$, a średnia ważona nie jest mniejsza od najmniejszego ze składników. Stąd druga nierówność. □ □

Trzydziestu uczniów pisze test z dwudziestu pytań. Wszyscy umieją tyle samo: każdy myli się w każdym pytaniu z prawdopodobieństwem 0,3, więc przeciętnie popełnia 6 błędów. Liczba błędów każdego ucznia z osobna jest uczciwym oszacowaniem jego umiejętności. Wyniki rozrzucą się jednak wokół 6 z odchyleniem standardowym około 2, a najlepszy z trzydziestu popełni zwykle dwa albo trzy błędy. Nauczyciel, który uzna na tej podstawie, że zwycięzca myli się w co dziesiątym pytaniu, będzie w błędzie: zwycięzca umie tyle samo co reszta. Wygrał, bo los sprzyjał mu najbardziej, a jego wynik zawiera całe to szczęście. W następnym teście popełni przeciętnie 6 błędów.

Uczniowie to kandydaci, pytania – obserwacje walidacyjne, a odsetek błędnych odpowiedzi – oszacowanie $\widehat{R}_j$. Wybierając najmniejsze oszacowanie, wybieramy zarazem najkorzystniejszy szum, stąd pierwsza nierówność. Gdy umiejętności się różnią, szczęście może wynieść na pierwsze miejsce kogoś słabszego od najlepszego, stąd druga. Obie sytuacje pokazuje rysunek 5.4.

Wynik wybranego kandydata zaniża więc ryzyko nawet najlepszego z kandydatów, a ryzyko faktycznie wybranego modelu jest jeszcze większe. Zjawisko to bywa nazywane **klątwą zwycięzcy**. Rośnie z liczbą kandydatów i z wariancją oszacowań, a maleje, gdy jeden kandydat jest wyraźnie lepszy od pozostałych.



Rysunek 5.4.: Jedna realizacja oszacowań dla sześciu kandydatów. Pasek: typowy rozrzut oszacowania $\widehat{R}_j$ (dwa błędy standardowe w każdą stronę), kreska: ryzyko R_j, kropka: wylosowane oszacowanie. Najmniejsze oszacowanie (czerwone) wypadło na lewym krańcu rozrzutu kandydata 3 i leży na lewo od wszystkich ryzyk, także od najmniejszego, które ma kandydat 4. Wybrany kandydat nie jest najlepszy, więc jego ryzyko $R_{\hat{j}}$ przekracza $\min_j R_j$.

Jak zmierzyć ryzyko modelu, który wybieramy? Trzeba ocenić całą procedurę – „wybierz kandydata walidacją krzyżową i dopasuj go do danych" – tak samo, jak oceniamy każdą inną metodę uczenia: na danych, których ta procedura nie widziała. Prowadzi to do **zagnieżdżonej walidacji krzyżowej** (Varma i Simon 2006).

Zagnieżdżona walidacja krzyżowa

Niech $\mathcal{W}$ oznacza procedurę wyboru: dla zbioru uczącego $\mathcal{D}'$

1. dzieli $\mathcal{D}'$ na L części wewnętrznych i dla każdego kandydata j oblicza na $\mathcal{D}'$ oszacowanie $\mathrm{CV}_L^{(j)}$ według (5.4);
2. wybiera kandydata $\hat{j}$ o najmniejszym $\mathrm{CV}_L^{(j)}$;
3. dopasowuje go do całego $\mathcal{D}'$ i zwraca otrzymany predyktor $\mathcal{W}(\mathcal{D}')$.

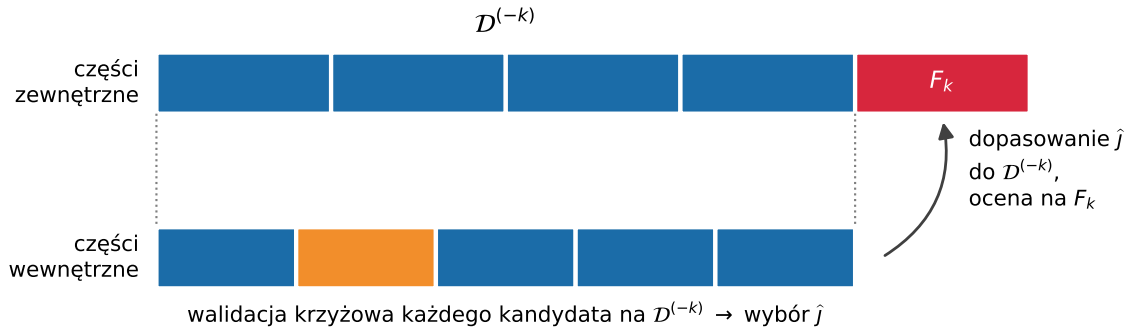
Zagnieżdżona walidacja krzyżowa to walidacja krzyżowa (5.4) procedury $\mathcal{W}$. Dzielimy dane na K części zewnętrznych $F_1, \ldots, F_K$; niech $\mathcal{D}^{(-k)}$ oznacza dane poza F_k. Oszacowaniem ryzyka całej procedury, łącznie z wyborem, jest

$$\mathrm{CV}_K^{\mathrm{zagn}} = \frac{1}{n} \sum_{k=1}^{K} \sum_{i \in F_k} L(y_i, \mathcal{W}(\mathcal{D}^{(-k)})(\mathbf{x}_i)).$$

Część F_k nie bierze udziału ani w wyborze, ani w dopasowaniu. W różnych częściach zewnętrznych wybrany może zostać inny kandydat – to normalne, bo oceniamy procedurę wyboru, a nie jednego kandydata.

Jeden krok zewnętrzny przedstawia rysunek 5.5.

Rysunek 5.6 pokazuje skalę zjawiska na danych bez żadnej informacji. Mamy $n = 100$ obser-



Rysunek 5.5.: Jeden krok zagnieżdżonej walidacji krzyżowej ($K = L = 5$). Górny pasek: części zewnętrzne; część F_k (czerwona) jest odłożona do oceny. Dolny pasek: pozostałe dane $\mathcal{D}^{(-k)}$ podzielone na części wewnętrzne; każda z nich kolejno (pomarańczowa) służy do walidacji kandydatów uczonych na pozostałych. Wybrany kandydat $\hat{j}$ jest dopasowywany do całego $\mathcal{D}^{(-k)}$ i oceniany na F_k. Krok powtarzamy dla $k = 1, \ldots, K$.

wacji z $p = 10$ cechami i klasą wylosowaną niezależnie od cech, więc każdy klasyfikator ma ryzyko 1/2. Kandydatami są klasyfikatory k-NN o dziesięciu różnych wartościach k, uczone na dziesięciu różnych losowych trójkach cech – razem 100 kandydatów. Porównujemy dwie liczby: najmniejszy wynik pięciokrotnej walidacji krzyżowej spośród pierwszych M kandydatów i wynik zagnieżdżonej walidacji krzyżowej procedury wybierającej spośród nich.

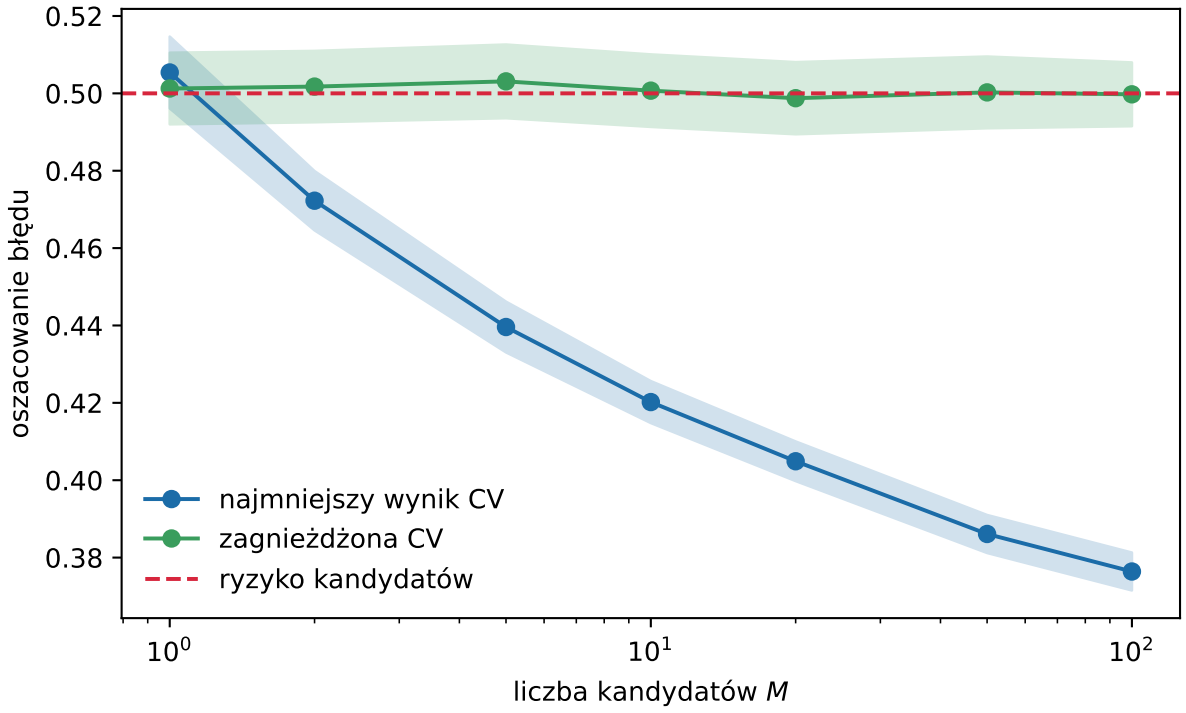
Przy jednym kandydacie nie ma wyboru, obie metody są zwykłą walidacją krzyżową i trafiają w 1/2. Z każdym kolejnym kandydatem minimum wyników walidacji krzyżowej spada, a przy stu kandydatach procedura bez żadnej wartości predykcyjnej „osiąga" błąd poniżej 40%. Zagnieżdżona walidacja krzyżowa pozostaje przy 1/2 niezależnie od M. Spadek minimum jest przy tym wolniejszy, niż byłby dla niezależnych oszacowań (Zadanie 5.6), bo kandydaci o podobnych k albo wspólnych cechach mają silnie skorelowane wyniki.

W tym przykładzie wybór jest bezwartościowy, bo kandydaci są równi. Gdy jeden z nich jest wyraźnie lepszy, optymizm wyboru jest mniejszy, ale zawsze ma ten sam kierunek. Cawley i Talbot (2010) pokazali, że przy wielu hiperparametrach i małych próbach przekracza on różnice między porównywanymi metodami, więc porównanie metod na podstawie najmniejszych wyników walidacji krzyżowej może wskazać złego zwycięzcę.

Zostaje pytanie, który model ostatecznie oddajemy do użytku. Zagnieżdżona walidacja krzyżowa ocenia procedurę, a nie jeden model, więc po jej zakończeniu procedurę wyboru przeprowadza się jeszcze raz, na wszystkich danych, i wybranego kandydata dopasowuje do całej próby. Ocena z zagnieżdżonej walidacji odnosi się do tego modelu w takim sensie, w jakim walidacja krzyżowa odnosi się do każdego modelu: jest oszacowaniem ryzyka oczekiwanego procedury, nieco pesymistycznym, bo liczonym dla mniejszych prób. Alternatywą, prostszą i często lepszą, gdy danych jest dużo, jest odłożenie na samym początku zbioru testowego, na który nie patrzy się aż do końca. Ten zbiór ocenia wtedy konkretny, ostatecznie wybrany model.

5.7. Strojenie hiperparametrów

Wybór hiperparametrów na podstawie walidacji krzyżowej to **strojenie** (ang. *hyperparameter tuning*). Gdy hiperparametr jest jeden, jak k w metodzie k-NN, wystarczy policzyć wynik dla



Rysunek 5.6.: Optymizm wyboru. Dane bez informacji o klasie ($n = 100$, $p = 10$), kandydaci to klasyfikatory k-NN na losowych trójkach cech. Niebieska linia: najmniejsze oszacowanie pięciokrotną walidacją krzyżową wśród M kandydatów. Zielona linia: zagnieżdżona walidacja krzyżowa procedury wyboru (5 części zewnętrznych, 5 wewnętrznych). Średnie z 200 prób; pas to ± 2 błędy standardowe średniej. Czerwona linia: ryzyko każdego kandydata.

każdej rozsądnej wartości. Gdy jest ich kilka, liczba kombinacji rośnie wykładniczo i trzeba wybrać, które sprawdzić.

Przeszukiwanie siatki (ang. *grid search*) sprawdza wszystkie kombinacje z ustalonych list wartości. Jest proste i łatwe do zrównoleglenia, ale marnotrawne, gdy hiperparametry są nierówno ważne. Bergstra i Bengio (2012) zwrócili uwagę, że tak bywa zwykle: ryzyko zależy silnie od jednego lub dwóch hiperparametrów, a od reszty słabo. Siatka 3×3 w dwóch wymiarach sprawdza dziewięć kombinacji, ale tylko trzy różne wartości każdego hiperparametru z osobna. Jeśli ważny jest tylko jeden, osiem z dziewięciu dopasowań niewiele wnosi. **Przeszukiwanie losowe** (ang. *random search*) losuje dziewięć punktów z tego samego obszaru, więc sprawdza dziewięć różnych wartości ważnego hiperparametru. Przy tej samej liczbie dopasowań przeszukiwanie losowe znajduje zwykle konfiguracje nie gorsze niż siatka, a w wielu wymiarach – wyraźnie lepsze.

Obie metody nie korzystają z wyników dotychczasowych prób. Metody **sekwencyjne** budują przybliżony model zależności wyniku walidacji od hiperparametrów i kolejne punkty wybierają tam, gdzie ten model przewiduje dobry wynik albo jest najbardziej niepewny. Należą do nich optymalizacja bayesowska i metoda TPE (ang. *tree-structured Parzen estimator*), stosowana domyślnie w bibliotece Optuna. Przy kosztownych modelach pozwalają one dodatkowo przerywać w trakcie uczenia próby, które od początku wypadają słabo.

Każda z tych metod jest procedurą wyboru spośród kandydatów, więc podlega twierdzeniu 5.2. Im więcej konfiguracji sprawdzimy i im skuteczniej szukamy minimum, tym bardziej najlepszy znaleziony wynik walidacji krzyżowej jest optymistyczny. Można dopasować się do szumu w walidacji tak samo, jak model dopasowuje się do szumu w danych uczących. Wynik strojenia nie jest więc oceną modelu. Ocenę daje zagnieżdżona walidacja krzyżowa albo zbiór testowy, który w strojeniu nie uczestniczył.

5.8. Bootstrap

Dotąd szacowaliśmy ryzyko. Równie często potrzebujemy niepewności innej wielkości obliczonej z próby: współczynnika modelu, predykcji w danym punkcie, pola pod krzywą, a nawet samego oszacowania ryzyka. Gdybyśmy znali rozkład P, sprawa byłaby prosta. Wylosowalibyśmy z niego wiele prób, w każdej policzyli interesującą nas wielkość i zobaczyli jej rozrzut – tak jak w rozdziale 4 oglądaliśmy rozrzut dopasowanych wielomianów na rysunku 4.2. Rozkładu P nie znamy, mamy tylko próbę.

Bootstrap (Efron 1979) zastępuje nieznany rozkład P jego najlepszym przybliżeniem, jakim dysponujemy: **rozkładem empirycznym** $\widehat{P}_n$, który każdej z n obserwacji próby przypisuje prawdopodobieństwo $1/n$. Losowanie n obserwacji z $\widehat{P}_n$ to losowanie n obserwacji z próby **ze zwracaniem**. Taką **próbę bootstrapową** $\mathcal{D}^*$ traktujemy jak nową próbę z populacji.

i Błąd standardowy metodą bootstrap

Niech $\hat{\theta} = s(\mathcal{D})$ będzie wielkością obliczoną z próby.

1. Dla $b = 1, \ldots, B$ wylosuj z próby ze zwracaniem n obserwacji, tworząc próbę $\mathcal{D}^*_b$, i oblicz $\hat{\theta}^*_b = s(\mathcal{D}^*_b)$.
2. Oszacowaniem błędu standardowego $\hat{\theta}$ jest odchylenie standardowe liczb $\hat{\theta}^*_1, \ldots, \hat{\theta}^*_B$.
3. Przedziałem ufności na poziomie 95% jest przedział między kwantylami rzędu 0,025 i 0,975 tych liczb (**przedział percentylowy**).

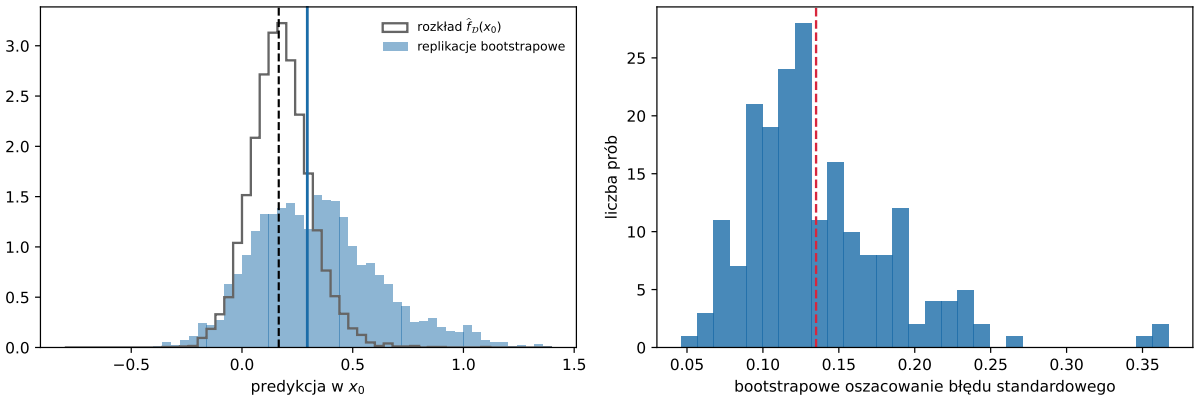
Metoda zawiera dwa przybliżenia. Pierwsze, statystyczne, to zastąpienie P przez $\widehat{P}_n$; jego jakość zależy od n i od tego, jak gładko $\hat{\theta}$ zależy od danych. Drugie, numeryczne, to skończone B; to przybliżenie poprawiamy po prostu, zwiększając B. Do błędu standardowego wystarcza zwykle B rzędu kilkuset, do kwantyli w przedziale – kilku tysięcy.

Próba bootstrapowa zawiera niektóre obserwacje wielokrotnie, a innych wcale. Prawdopodobieństwo, że ustalona obserwacja nie zostanie wylosowana w żadnym z n losowań, wynosi

$$\left(1 - \frac{1}{n}\right)^n \xrightarrow[n\to\infty]{} e^{-1} \approx 0{,}368. \tag{5.7}$$

Próba bootstrapowa zawiera więc przeciętnie około 63,2% różnych obserwacji z próby, a pozostałe 36,8% w niej nie występują (Zadanie 5.4).

Rysunek 5.7 pokazuje działanie metody na przykładzie, w którym znamy prawdziwy rozkład. Szacujemy błąd standardowy predykcji wielomianu stopnia 3 w punkcie $x_0 = 0{,}95$, blisko krańca przedziału, gdzie dopasowania są najmniej stabilne.



Rysunek 5.7.: Bootstrap dla predykcji $\hat{f}(x_0)$ wielomianu stopnia 3 w punkcie $x_0 = 0{,}95$ ($n = 50$). Po lewej: dla jednej próby rozkład 2000 replikacji bootstrapowych (niebieski) na tle prawdziwego rozkładu $\hat{f}_{\mathcal{D}}(x_0)$ po 5000 próbach z populacji (szary kontur); pionowe linie: $\hat{f}(x_0)$ z tej próby (niebieska) i $f^*(x_0)$ (przerywana). Po prawej: bootstrapowe oszacowania błędu standardowego ($B = 200$) dla 200 różnych prób; czerwona linia to prawdziwy błąd standardowy.

```
prawdziwy błąd standardowy:          0.135
bootstrap w jednej próbie:           0.293
przedział percentylowy:              [-0.14   1.016]
mediana oszacowań w 200 próbach:     0.125
kwantyle 10% i 90% oszacowań:        [0.087 0.198]
```

Lewy panel pokazuje najważniejszą własność bootstrapu. Replikacje rozkładają się wokół predykcji $\hat{f}(x_0)$ z naszej próby, a nie wokół prawdziwej wartości $f^*(x_0)$: próba bootstrapowa „nie wie" więcej o populacji niż próba, z której ją wylosowano. Bootstrap odtwarza więc co najwyżej **rozrzut** estymatora, a nie jego położenie. W tej akurat próbie odtwarza go źle: replikacje są ponad dwa razy szersze niż prawdziwy rozkład. Prawy panel pokazuje, że to próba nietypowa. Oszacowania błędu standardowego skupiają się w pobliżu prawdziwej wartości, z medianą nieco poniżej niej, a w osiemdziesięciu procentach prób różnią się od niej o mniej niż połowę. Rozkład oszacowań jest jednak prawostronnie skośny, a próba z lewego panelu leży w jego dalekim ogonie. W takich próbach przy krańcu przedziału jest mało punktów i wielomiany dopasowane do prób bootstrapowych mocno się tam rozchodzą. Bootstrap jest zawodny dokładnie tam, gdzie estymator jest niestabilny.

5.8.1. Bootstrap a ocena ryzyka

Bootstrap można też wykorzystać do szacowania ryzyka. Pierwszy pomysł – uczyć predyktor na próbie bootstrapowej i oceniać go na całej próbie – jest optymistyczny, bo około 63% obserwacji oceniających było w zbiorze uczącym. Poprawka nasuwa się sama: każdą obserwację i oceniać tylko predyktorami z tych prób bootstrapowych, które jej nie zawierają. Średnia takich strat po wszystkich obserwacjach to **bootstrap „pozostaw jeden”**, oznaczany $\widehat{R}^{(1)}$. Każda obserwacja jest tu oceniana przez predyktor, który jej nie widział, więc optymizmu nie ma. Jest za to pesymizm podobny do walidacji krzyżowej: próba bootstrapowa zawiera tylko około $0{,}632n$ różnych obserwacji i predyktor zachowuje się mniej więcej tak, jakby uczył się na tej liczbie danych.

Efron (1983) zaproponował, by oba błędy zrównoważyć, łącząc pesymistyczne $\widehat{R}^{(1)}$ z optymistycznym błędem uczącym $\overline{\mathrm{err}}$:

$$\widehat{R}^{(.632)} = 0{,}368\,\overline{\mathrm{err}} + 0{,}632\,\widehat{R}^{(1)}.$$

Waga 0,632 to przeciętny odsetek obserwacji wylosowanych do próby bootstrapowej (5.7); jej uzasadnienie jest przybliżone (Hastie i in. 2009, rozdz. 7.11). Estymator ten zawodzi przy metodach, które silnie dopasowują się do próby. Dla reguły jednego najbliższego sąsiada $\overline{\mathrm{err}} = 0$, więc nawet przy danych bez żadnej informacji, gdy ryzyko wynosi 1/2, dostajemy około $0{,}632 \cdot 0{,}5 \approx 0{,}32$. Wersja **.632+** (Efron i Tibshirani 1997) przesuwa wagę w stronę $\widehat{R}^{(1)}$, gdy różnica między $\widehat{R}^{(1)}$ a $\overline{\mathrm{err}}$ jest duża w porównaniu z błędem klasyfikatora bezwartościowego. Dla dwóch klas błędem tym jest $\hat{\gamma} = \hat{p}_1(1-\hat{q}_1) + (1-\hat{p}_1)\hat{q}_1$, gdzie $\hat{p}_1$ to odsetek klasy 1 w próbie, a $\hat{q}_1$ – odsetek obserwacji, którym predyktor przypisuje klasę 1. Względny stopień nadmiernego dopasowania $\widehat{R} = (\widehat{R}^{(1)} - \overline{\mathrm{err}})/(\hat{\gamma} - \overline{\mathrm{err}})$, obcięty do przedziału $[0,1]$, wyznacza wagę

$$\widehat{w} = \frac{0{,}632}{1 - 0{,}368\,\widehat{R}}, \qquad \widehat{R}^{(.632+)} = (1-\widehat{w})\,\overline{\mathrm{err}} + \widehat{w}\,\widehat{R}^{(1)}.$$

Bez nadmiernego dopasowania ($\widehat{R} = 0$) jest to estymator .632, przy skrajnym ($\widehat{R} = 1$) – sam $\widehat{R}^{(1)}$.

Porównajmy te estymatory z dziesięciokrotną walidacją krzyżową na zbiorze dwóch półksiężyców z rozdziału 3, dla klasyfikatorów 1-NN i 15-NN uczonych na $n = 100$ obserwacjach. Prawdziwe ryzyko dopasowanego modelu szacujemy na 20 000 obserwacjach testowych; jego błąd standardowy jest rzędu 0,002.

1-NN	średnia	odch. std.	pierwiastek ze śr. kw. błędu
prawdziwe ryzyko	0.132	0.015	0.000
błąd uczący	0.000	0.000	0.133
bootstrap (1)	0.144	0.035	0.032
.632	0.091	0.022	0.045
.632+	0.103	0.028	0.038
CV, K = 10	0.140	0.039	0.036

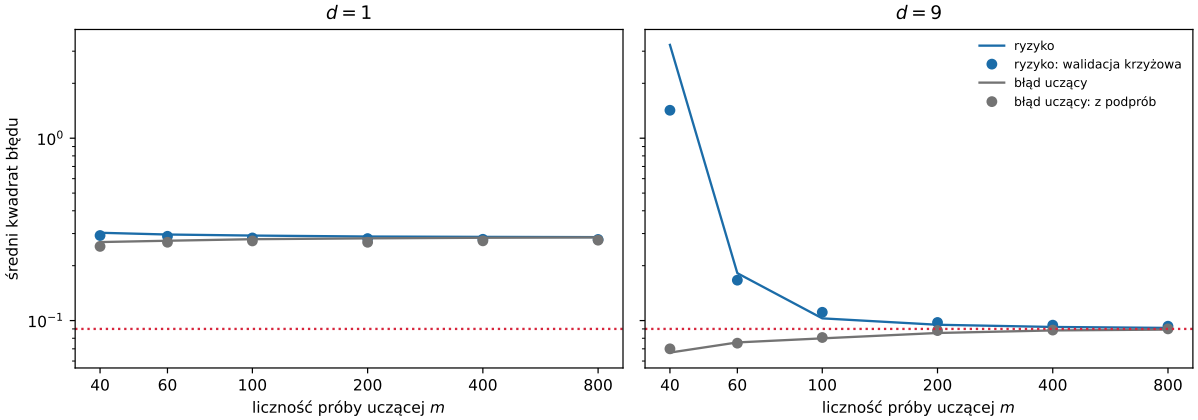
15-NN	średnia	odch. std.	pierwiastek ze śr. kw. błędu
prawdziwe ryzyko	0.097	0.006	0.000
błąd uczący	0.094	0.026	0.025
bootstrap (1)	0.122	0.026	0.036
.632	0.112	0.025	0.028
.632+	0.112	0.025	0.029
CV, K = 10	0.111	0.030	0.033

Wyniki potwierdzają, że żaden estymator nie wygrywa zawsze. Dla 1-NN błąd uczący jest zerowy, a .632 wyraźnie zaniża ryzyko. Wersja .632+ poprawia go, ale nie do końca, a $\widehat{R}^{(1)}$ i walidacja krzyżowa są lekko pesymistyczne. Dla 15-NN, który dopasowuje się do próby słabo, sam błąd uczący jest bliski ryzyku, a pozostałe estymatory nieco je zawyżają. W obu przypadkach odchylenia standardowe oszacowań są wyraźnie większe niż odchylenie standardowe samego ryzyka, a dla 15-NN – kilkakrotnie. Każdy estymator trafia przeciętnie mniej więcej we właściwe miejsce, ale pojedyncze oszacowanie z próby liczności 100 jest niepewne – to ten sam wniosek, który dał rysunek 5.2. W praktyce dominuje walidacja krzyżowa, bo jest prostsza, nie wymaga poprawek zależnych od metody i nie zakłada nic o stracie; estymatory bootstrapowe bywają przydatne przy bardzo małych próbach.

5.9. Krzywe uczenia z danych

W sekcji 4.7 krzywe uczenia rysowaliśmy, znając ryzyko. Z danych szacuje się je tak samo jak każde ryzyko: walidacją krzyżową. Dla każdej części F_k i każdej liczności m mniejszej niż liczność zbioru uczącego losujemy z danych spoza F_k podpróbę liczności m, dopasowujemy do niej model i liczymy jego błąd na F_k oraz na samej podpróbie. Losowanie podpróby powtarzamy kilkakrotnie i uśredniamy. W bibliotece scikit-learn robi to funkcja `learning_curve`. Rysunek 5.8 porównuje tak oszacowane krzywe z prawdziwymi dla wielomianów stopnia 1 i 9 z rysunku 4.4, przy jednej próbie liczności $N = 1000$.

```
d = 1: walidacja krzyżowa [0.293 0.29  0.284 0.282 0.279 0.278]
       prawdziwe ryzyko    [0.303 0.296 0.293 0.289 0.288 0.287]
d = 9: walidacja krzyżowa [1.423 0.167 0.111 0.098 0.094 0.093]
       prawdziwe ryzyko    [3.249 0.182 0.103 0.095 0.092 0.091]
```



Rysunek 5.8.: Krzywe uczenia regresji wielomianowej stopnia $d = 1$ (po lewej) i $d = 9$ (po prawej) oszacowane z jednej próby liczności $N = 1000$ pięciokrotną walidacją krzyżową, z 20 podpróbami dla każdej części i liczności (punkty), na tle prawdziwych krzywych z 300 prób z populacji (linie). Linia kropkowana: błąd nieredukowalny σ^2. Obie osie w skali logarytmicznej.

Oszacowane krzywe odtwarzają obraz z sekcji 4.7: dla prostej szczelina między krzywymi jest wąska, a obie leżą wysoko nad σ^2; dla wielomianu stopnia 9 szczelina jest szeroka przy małych licznościach i zamyka się, gdy danych przybywa. Diagnostyka z tamtej sekcji – ryzyko spada z n i szczelina się zamyka, więc dominuje wariancja; obie krzywe płaskie i zbieżne, więc dominuje obciążenie – działa więc także bez znajomości ryzyka. Największa rozbieżność występuje dla

$d = 9$ przy najmniejszej liczności. Ryzyko oczekiwane jest tam średnią zdominowaną przez nieliczne próby, w których wielomian wysokiego stopnia „ucieka" przy krańcu przedziału. Sto dopasowań z podprób jednej próby takie rzadkie zdarzenia łapie nieregularnie, więc w tym punkcie oszacowanie jest niedokładne.

Krzywa uczenia oszacowana z danych kończy się na liczności zbioru uczącego w walidacji krzyżowej, czyli $N(K-1)/K$. Czy dodanie danych pomoże, ocenia się więc, ekstrapolując jej przebieg poza zakres obserwacji. Jeśli krzywa ryzyka przy największych licznościach jest już płaska, więcej danych tej samej natury niewiele da.

5.10. Ocena modeli w praktyce

Wróćmy do przykładu z sekcji 3.7: klasyfikatora k-NN dla danych o nowotworach piersi, w którym $k = 10$ przyjęliśmy arbitralnie. Teraz wybierzemy k walidacją krzyżową i ocenimy procedurę wyboru zagnieżdżoną walidacją krzyżową. Standaryzacja jest częścią potoku, więc w każdej części jej parametry są wyznaczane tylko z danych uczących.

```
  k   błąd CV   błąd std.
  1    0.0422      0.0063
  3    0.0351      0.0070
  5    0.0351      0.0096
  7    0.0351      0.0086
  9    0.0351      0.0096
 11    0.0334      0.0058
 15    0.0387      0.0047
 21    0.0422      0.0063
 31    0.0457      0.0057
 51    0.0527      0.0074

najmniejszy błąd CV: k = 11, błąd 0.0334
reguła jednego błędu standardowego: k = 15

zagnieżdżona walidacja krzyżowa: błąd 0.0334
k wybrane w częściach zewnętrznych: [5, 5, 11, 3, 3]
```

Krzywa błędu walidacji krzyżowej jest w szerokim zakresie k płaska: między $k = 3$ a $k = 15$ wyniki różnią się mniej więcej o jeden błąd standardowy. Najmniejszy wynik osiąga jedna z wartości z tego zakresu, ale reguła jednego błędu standardowego wskazuje większe k, czyli model gładszy, statystycznie nieodróżnialny od najlepszego. Zagnieżdżona walidacja krzyżowa daje tu, przy innym podziale na części, przypadkiem dokładnie ten sam błąd co najmniejszy wynik walidacji. Przy dziesięciu kandydatach i dość stabilnej metodzie optymizm wyboru okazał się więc mały w porównaniu z niepewnością oszacowania. Nie mogliśmy tego jednak wiedzieć bez zagnieżdżonej walidacji. Wartości k wybrane w częściach zewnętrznych różnią się między sobą. Wybór konkretnego k jest niestabilny, bo kilka wartości jest prawie równie dobrych, a zagnieżdżona walidacja ocenia procedurę, która tę niestabilność obejmuje. Model do użytku otrzymujemy, dopasowując `strojenie` do wszystkich danych, co zrobiliśmy w pierwszym kroku.

Uwagi bibliograficzne

Zbiór walidacyjny, walidację krzyżową i bootstrap na poziomie tego rozdziału przedstawiają James i in. (2023, rozdz. 5). Pełniejsze omówienie, z analizą optymizmu błędu uczącego, walidacji krzyżowej, estymatorów bootstrapowych .632 i .632+ oraz różnicy między ryzykiem modelu a ryzykiem metody, zawiera Hastie i in. (2009, rozdz. 7); przykład z wyborem cech przed walidacją pochodzi z Hastie i in. (2009, rozdz. 7.10.2). Przegląd wariantów walidacji krzyżowej i ich własności teoretycznych, z zaleceniami co do wyboru K, dają Arlot i Celisse (2010).

Walidację krzyżową jako ogólną metodę wyboru i oceny predyktorów sformułował M. Stone (1974). Pytanie, co właściwie szacuje, i jak budować dla niej poprawne przedziały ufności, analizują Bates i in. (2024). Brak nieobciążonego estymatora wariancji wykazali Bengio i Grandvalet (2004), a testy statystyczne do porównywania klasyfikatorów, w tym test McNemara, omawia Dietterich (1998).

Optymizm wyniku walidacji krzyżowej po wyborze modelu i zagnieżdżoną walidację krzyżową opisali Varma i Simon (2006), a skalę tego zjawiska przy porównywaniu metod – Cawley i Talbot (2010). Klasycznym przykładem wycieku przez wybór cech jest praca Ambroise i McLachlan (2002). Przewagę przeszukiwania losowego nad siatką uzasadnili Bergstra i Bengio (2012).

Bootstrap wprowadził Efron (1979). Estymator .632 zaproponował Efron (1983) w pracy o szacowaniu błędu reguł predykcyjnych, a wersję .632+ podali Efron i Tibshirani (1997). Systematyczny wykład metody, z przedziałami ufności i wieloma przykładami, zawiera podręcznik Efron i Tibshirani (1993).

Zadania

Zadanie 5.1. Klasyfikator ma ryzyko około 8%.

a) Ile obserwacji testowych potrzeba, aby połowa szerokości przedziału ufności na poziomie 95% wynosiła 0,01? A 0,002?
b) Wykaż, że $R(1-R) \leq 1/4$, i podaj liczność zbioru testowego wystarczającą dla zadanej szerokości przedziału niezależnie od ryzyka. Ile razy jest ona większa od wyniku z punktu a)?
c) Klasa 1 stanowi 1% populacji, a interesuje nas czułość, czyli odsetek obserwacji klasy 1 rozpoznanych poprawnie. Ile obserwacji testowych trzeba, aby oszacować czułość rzędu 0,9 z dokładnością $\pm 0{,}02$?

Zadanie 5.2. Każda z opisanych procedur zawiera błąd metodologiczny. Wskaż go, określ kierunek, w którym zniekształca on ocenę, i zaproponuj poprawkę.

a) Wszystkie cechy standaryzujemy na całej próbie, a następnie przeprowadzamy dziesięciokrotną walidację krzyżową klasyfikatora k-NN.
b) Dzielimy dane na zbiór uczący i testowy. Dla $k = 1, \ldots, 50$ uczymy klasyfikator k-NN na zbiorze uczącym, wybieramy k o najmniejszym błędzie testowym i ten błąd podajemy jako ocenę modelu.
c) Dane zawierają po kilka wizyt każdego pacjenta; obserwacją jest wizyta, czyli wyniki badań i postawiona diagnoza. Model ma diagnozować pacjentów, których dotąd nie badaliśmy. Jego błąd dla takich pacjentów szacujemy pięciokrotną walidacją krzyżową, dzieląc wizyty losowo na pięć części.

d) Model prognozuje dzienną sprzedaż na podstawie sprzedaży z poprzednich dni. Obserwacją jest dzień t: cechami są wartości sprzedaży z dni $t-1, \ldots, t-7$, odpowiedzią sprzedaż w dniu t. Tak zbudowane obserwacje dzielimy losowo na dziesięć części i oceniamy model dziesięciokrotną walidacją krzyżową.
e) Klasa 1 jest rzadka, więc przed walidacją krzyżową powielamy jej obserwacje, aż klasy staną się równoliczne.

Zadanie 5.3. Dwa klasyfikatory oceniono na tym samym zbiorze testowym liczności $m = 1000$. Model A pomylił się 100 razy, model B – 120 razy. Na 70 obserwacjach pomyliły się oba.

a) Wyznacz liczby n_{AB} i n_{BA} obserwacji, na których myli się tylko jeden z modeli.
b) Oblicz błąd standardowy różnicy oszacowań ryzyka, traktując je jak niezależne. Czy różnica jest wyraźna?
c) Przy założeniu, że oba modele mają to samo ryzyko, wyznacz dokładnie prawdopodobieństwo wyniku co najmniej tak skrajnego jak zaobserwowany podział obserwacji spornych (w dowolną stronę). Porównaj z wynikiem punktu b) i wyjaśnij różnicę, odwołując się do kowariancji strat.
d) W przykładzie z sekcji 5.2 liczby błędów były te same, ale oba modele pomyliły się na 90 obserwacjach. Dlaczego przewaga modelu A była tam lepiej udokumentowana?
e) Wykaż, że dla straty 0–1 estymator wariancji różnicy strat $\widehat{\mathrm{Var}}(L^A - L^B)$ zależy tylko od n_{AB}, n_{BA} i m.

Zadanie 5.4. Próbę bootstrapową tworzymy, losując n razy ze zwracaniem z próby liczności n.

a) Wykaż, że prawdopodobieństwo, że ustalona obserwacja nie znajdzie się w próbie bootstrapowej, wynosi $(1 - 1/n)^n$, i że dąży ono do e^{-1}. Oblicz je dla $n = 10, 50, 1000$.
b) Wyznacz oczekiwaną liczbę różnych obserwacji w próbie bootstrapowej.
c) Wyznacz prawdopodobieństwo, że ustalona obserwacja znajdzie się w obu z dwóch niezależnie wylosowanych prób bootstrapowych. Odnieś wynik do pytania c) zadania 4.8.
d) Sprawdź wyniki a) i b) symulacją.

Zadanie 5.5.

a) Wyprowadź (5.5) i wywnioskuj z niego, że błąd LOOCV reguły $(k-1)$-NN jest równy błędowi uczącemu reguły k-NN pomnożonemu przez $\big(k/(k-1)\big)^2$. Gdzie korzystasz z założenia, że odległości są różne?
b) Sprawdź tę równość numerycznie: dla danych z rozdziału 4 ($n = 100$) i $k = 2, 5, 20$ porównaj wynik `cross_val_score` z `LeaveOneOut()` dla `KNeighborsRegressor(n_neighbors=k-1)` z przeskalowanym błędem uczącym `KNeighborsRegressor(n_neighbors=k)`.
c) Dlaczego ta sztuczka nie daje LOOCV reguły k-NN, lecz $(k-1)$-NN? Co z niej wynika dla $k = 1$?
d) W ustalonym układzie z zadania 4.3, przy zerowym obciążeniu, oblicz wartość oczekiwaną błędu uczącego reguły k-NN i przeskaluj ją jak w punkcie a). Porównaj wynik z oczekiwanym błędem predykcji reguły $(k-1)$-NN w punktach uczących, wyznaczonym z (4.6).

Zadanie 5.6. Mamy M kandydatów o tym samym ryzyku R, a ich oszacowania $\widehat{R}_1, \ldots, \widehat{R}_M$ są niezależne i mają rozkład normalny $\mathcal{N}(R, s^2)$.

a) Wykaż, że $\mathbb{E}[\min_j \widehat{R}_j] = R - s\, c_M$, gdzie c_M to wartość oczekiwana maksimum M niezależnych zmiennych o rozkładzie $\mathcal{N}(0,1)$.
b) Wyznacz c_2 analitycznie. (Wskazówka: $\max(Z_1, Z_2) = \frac{1}{2}(Z_1 + Z_2) + \frac{1}{2}|Z_1 - Z_2|$.)

c) Oszacuj symulacyjnie c_M dla $M = 5, 10, 100$. Przyjmując $s = 0{,}05$, porównaj otrzymany optymizm z rysunkiem 5.6.
d) Powtórz symulację dla oszacowań skorelowanych: każde dwa mają współczynnik korelacji ρ. (Wskazówka: $\widehat{R}_j = R + s(\sqrt{\rho}\, Z_0 + \sqrt{1-\rho}\, Z_j)$.) Jak optymizm zależy od ρ? Wyjaśnij, dlaczego krzywa na rysunku 5.6 opada wolniej niż w punkcie c).

Zadanie 5.7. Rozwiń symulację z rysunku 5.3.

a) Zbadaj, jak średnie oszacowanie przy złym sposobie zależy od liczby wybieranych cech $q \in \{1, 10, 100, 1000\}$ i od liczby cech $p \in \{100, 1000, 5000\}$. Wyjaśnij obserwowane zależności.
b) Zbuduj poprawną procedurę w scikit-learn jako potok `make_pipeline(SelectKBest(f_classif, k=100), KNeighborsClassifier(n_neighbors=1))` i oceń ją funkcją `cross_val_score`. Sprawdź, że wynik zgadza się z dobrym sposobem.
c) Zastąp wybór cech standaryzacją wyznaczaną na całej próbie i sprawdź, czy ten wyciek ma mierzalny wpływ na oszacowanie.

Zadanie 5.8. Dane pochodzą z rozkładu dwóch półksiężyców z szumem 0,30 (`make_moons`), $n = 200$. Prawdziwe ryzyko szacuj na zbiorze testowym liczności 20 000.

a) Dla jednej próby narysuj na jednym wykresie wynik dziesięciokrotnej walidacji krzyżowej i ryzyko klasyfikatora k-NN dla $k = 1, 3, \ldots, 99$. Zaznacz k wybrane walidacją krzyżową, regułą jednego błędu standardowego i k o najmniejszym ryzyku.
b) Powtórz punkt a) dla 100 prób. Narysuj histogram wybranych k. Oblicz średnią stratę wynikającą z wyboru, czyli różnicę między ryzykiem wybranego modelu a najmniejszym ryzykiem wśród kandydatów, dla obu reguł wyboru.
c) Oblicz średnią różnicę między najmniejszym wynikiem walidacji krzyżowej a ryzykiem wybranego modelu. Odnieś wynik do twierdzenia 5.2.

Część II.

Modele liniowe

6. Regresja liniowa

Regresja liniowa pojawiała się w tej książce kilka razy, zawsze jako punkt odniesienia. W sekcji 1.9 była przykładem metody parametrycznej: niezależnie od liczby obserwacji szacujemy w niej tyle samo współczynników. W rozdziale 4 dopasowywaliśmy wielomiany gotową funkcją biblioteki NumPy, a w sekcji 4.8 stwierdziliśmy, że trafne założenie liniowości daje predyktor nieobciążony o wariancji rzędu $\sigma^2(p+1)/n$, bez względu na to, jak trudna byłaby ta sama zależność dla metody k-NN. W tym rozdziale wyprowadzamy te fakty.

Model liniowy służy jednak nie tylko predykcji. Jego współczynniki mają prostą interpretację, a przy dodatkowych założeniach umiemy policzyć, jak bardzo zmieniłyby się, gdybyśmy wylosowali inną próbę. Daje to narzędzia wnioskowania w sensie sekcji 1.7: przedziały ufności i testy hipotez. Będziemy je rozwijać na przykładzie danych *Advertising* (James i in. 2023, rozdz. 2.1). Dla 200 rynków zbiór podaje budżety reklamy produktu w telewizji (`TV`), radiu (`radio`) i prasie (`newspaper`), w tysiącach dolarów, oraz sprzedaż produktu (`sales`) w tysiącach sztuk. Interesują nas trzy pytania: czy wydatki na reklamę w ogóle wiążą się ze sprzedażą, które media się do tego przyczyniają i jak dokładnie możemy przewidzieć sprzedaż przy zadanym budżecie. Odpowiedź na każde z nich wymaga nie tylko dopasowania modelu, ale też oceny, ile w dopasowaniu jest przypadku.

6.1. Model liniowy

Niech $\mathbf{X} = (X_1, \dots, X_p)$ będzie wektorem cech, a Y wynikiem. **Model regresji liniowej** zakłada, że

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon, \qquad \mathbb{E}[\varepsilon \mid \mathbf{X}] = 0, \tag{6.1}$$

czyli że funkcja regresji $f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ jest funkcją liniową (ściślej: afiniczną) cech. Liczby $\beta_0, \dots, \beta_p$ są nieznanymi parametrami. Współczynnik β_0 nazywamy **wyrazem wolnym** (ang. *intercept*), a β_j dla $j \geq 1$ – **współczynnikiem regresji** przy cesze X_j.

Założenie (6.1) można czytać na dwa sposoby. Pierwszy to twierdzenie o świecie: funkcja regresji naprawdę należy do klasy

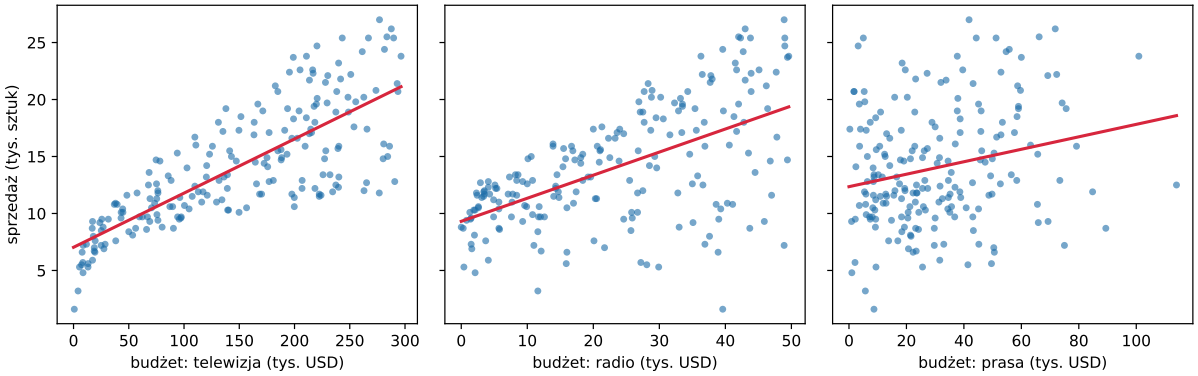
$$\mathcal{F}_{\text{lin}} = \{\, f(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p : \beta_0, \dots, \beta_p \in \mathbb{R} \,\}.$$

Wtedy błąd aproksymacji z sekcji 4.6 jest zerowy, a cały błąd redukowalny pochodzi ze skończoności próby. Drugi sposób nie wymaga tej wiary. Niezależnie od tego, czym jest f^*, w klasie $\mathcal{F}_{\text{lin}}$ istnieje element $f_{\mathcal{F}}$ najbliższy f^* w sensie średniego kwadratu, i to on jest celem estymacji. Dla jednej cechy jego współczynnik kierunkowy wynosi $\operatorname{Cov}(X,Y)/\operatorname{Var} X$ (Zadanie 6.1). Rachunki z sekcji 6.2 mają sens przy obu odczytaniach. Wyniki z sekcji 6.3 i 6.4 opierają się na pierwszym.

Liniowość dotyczy parametrów, a nie cech. Regresja wielomianowa z rozdziału 4 jest modelem liniowym z cechami $x, x^2, \dots, x^d$: predykcja jest kombinacją liniową współczynników, choć jest nieliniową funkcją x. Wszystko, co wyprowadzimy dla modelu (6.1), stosuje się więc do niej bez zmian.

Współczynnik β_j mówi, o ile zmienia się średni wynik, gdy cecha X_j rośnie o jednostkę, **a pozostałe cechy się nie zmieniają**. Porównujemy więc dwie grupy obiektów, które różnią

się tylko wartością X_j. Ta interpretacja opisuje zależność w populacji, a nie skutek interwencji. Rynki, na których budżet telewizyjny jest wyższy o tysiąc dolarów przy tych samych budżetach radiowym i prasowym, sprzedają przeciętnie o $1000\,\beta_1$ sztuk więcej. Czy podniesienie budżetu na danym rynku spowodowałoby taki wzrost, zależy od tego, co jeszcze różni te rynki, a tego model nie widzi.



Rysunek 6.1.: Dane *Advertising*: sprzedaż w zależności od budżetu reklamy w telewizji, radiu i prasie dla 200 rynków. Linie to proste regresji sprzedaży względem każdego medium osobno.

Na rysunku 6.1 sprzedaż wyraźnie rośnie z budżetem telewizyjnym, słabiej z radiowym, a z prasowym ledwie. Rozrzut wokół prostej dla telewizji rośnie przy tym z budżetem. Każdy z tych wykresów pokazuje jednak tylko jedną cechę naraz. Pytanie, co wnosi prasa, gdy znamy już budżety telewizyjny i radiowy, wymaga modelu z trzema cechami jednocześnie.

6.2. Metoda najmniejszych kwadratów

Mamy zbiór uczący $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$, gdzie $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})$. Wygodnie jest zapisać go macierzowo. **Macierz projektowa $\mathbf{X}$** ma wymiary $n \times (p+1)$: jej i-ty wiersz to $(1, x_{i1}, \dots, x_{ip})$, a pierwsza kolumna złożona z jedynek odpowiada wyrazowi wolnemu. Wyniki tworzą wektor $\mathbf{y} = (y_1, \dots, y_n)^\top$, a współczynniki – wektor $\beta = (\beta_0, \dots, \beta_p)^\top$. Predykcje modelu w punktach uczących to wtedy $\mathbf{X}\beta$, a suma kwadratów reszt wynosi

$$\mathrm{RSS}(\beta) = \sum_{i=1}^{n} \left(y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_p x_{ip}\right)^2 = \|\mathbf{y} - \mathbf{X}\beta\|^2. \tag{6.2}$$

Metoda najmniejszych kwadratów (MNK) wybiera β minimalizujące RSS. Jest to minimalizacja ryzyka empirycznego (1.10) przy stracie kwadratowej w klasie $\mathcal{F}_{\text{lin}}$, bo RSS/n jest błędem na zbiorze uczącym.

Rozpisując kwadrat normy,

$$\mathrm{RSS}(\beta) = \mathbf{y}^\top\mathbf{y} - 2\beta^\top\mathbf{X}^\top\mathbf{y} + \beta^\top\mathbf{X}^\top\mathbf{X}\beta.$$

Jest to funkcja kwadratowa β, a jej gradient wynosi $-2\mathbf{X}^\top\mathbf{y} + 2\mathbf{X}^\top\mathbf{X}\beta$. Przyrównując go do zera, otrzymujemy **równania normalne**

$$\mathbf{X}^\top\mathbf{X}\,\beta = \mathbf{X}^\top\mathbf{y}. \tag{6.3}$$

Twierdzenie 6.1 (Estymator najmniejszych kwadratów)**.** *Jeśli kolumny macierzy $\mathbf{X}$ są liniowo niezależne, to macierz $\mathbf{X}^\top\mathbf{X}$ jest odwracalna, a* RSS *ma dokładnie jedno minimum w punkcie*

$$\hat{\beta} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}. \tag{6.4}$$

Dowód. Dla dowolnego wektora $\mathbf{v}$ mamy $\mathbf{v}^\top\mathbf{X}^\top\mathbf{X}\mathbf{v} = \|\mathbf{X}\mathbf{v}\|^2$. Jeśli $\mathbf{X}^\top\mathbf{X}\mathbf{v} = \mathbf{0}$, to $\|\mathbf{X}\mathbf{v}\|^2 = 0$, czyli $\mathbf{X}\mathbf{v} = \mathbf{0}$, a z liniowej niezależności kolumn $\mathbf{v} = \mathbf{0}$. Macierz $\mathbf{X}^\top\mathbf{X}$ jest więc odwracalna, a $\hat{\beta}$ z (6.4) spełnia równania normalne.

Dla dowolnego β zapiszmy $\mathbf{y}-\mathbf{X}\beta = (\mathbf{y}-\mathbf{X}\hat{\beta})+\mathbf{X}(\hat{\beta}-\beta)$. Iloczyn mieszany $2(\hat{\beta}-\beta)^\top\mathbf{X}^\top(\mathbf{y}-\mathbf{X}\hat{\beta})$ znika na mocy równań normalnych, więc

$$\mathrm{RSS}(\beta) = \mathrm{RSS}(\hat{\beta}) + \|\mathbf{X}(\hat{\beta}-\beta)\|^2.$$

Drugi składnik jest dodatni dla $\beta \neq \hat{\beta}$, bo kolumny $\mathbf{X}$ są liniowo niezależne. □

Liniowa niezależność kolumn wymaga w szczególności, by $n \geq p+1$. Gdy cech jest więcej niż obserwacji, równania normalne mają nieskończenie wiele rozwiązań i wiele z nich daje $\mathrm{RSS} = 0$. Tak było z wielomianami w sekcji 4.1: gdy $d+1$ osiągało liczbę różnych wartości x_i, wielomian przechodził przez wszystkie punkty.

Dla jednej cechy ($p = 1$) równania normalne mają postać $\sum_i (y_i - \beta_0 - \beta_1 x_i) = 0$ i $\sum_i x_i(y_i - \beta_0 - \beta_1 x_i) = 0$, skąd

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \tag{6.5}$$

(Zadanie 6.1). Współczynnik kierunkowy to iloraz kowariancji z próby przez wariancję z próby, czyli próbkowy odpowiednik $\mathrm{Cov}(X,Y)/\operatorname{Var} X$. Druga równość mówi, że prosta regresji przechodzi przez punkt $(\bar{x}, \bar{y})$.

6.2.1. Geometria najmniejszych kwadratów

Wektor predykcji $\mathbf{X}\beta$ jest kombinacją liniową kolumn $\mathbf{X}$. Gdy β przebiega $\mathbb{R}^{p+1}$, wektor ten przebiega przestrzeń kolumn $\mathcal{C}(\mathbf{X})$ – podprzestrzeń $\mathbb{R}^n$ wymiaru $p+1$. Minimalizacja $\|\mathbf{y} - \mathbf{X}\beta\|$ to więc szukanie punktu tej podprzestrzeni najbliższego $\mathbf{y}$, czyli **rzutu ortogonalnego** $\mathbf{y}$ na $\mathcal{C}(\mathbf{X})$. Równania normalne zapisane jako

$$\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\hat{\beta}) = \mathbf{0}$$

mówią to samo: wektor reszt $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$, gdzie $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$, jest prostopadły do każdej kolumny $\mathbf{X}$. Z prostopadłości do kolumny jedynek wynika, że reszty sumują się do zera, a z prostopadłości do pozostałych kolumn – że w próbie są nieskorelowane z każdą cechą. Dopasowanie wyczerpało liniową informację o $\mathbf{y}$, jaką niosą cechy.

Wektor predykcji jest liniową funkcją wyników:

$$\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}, \qquad \mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top. \tag{6.6}$$

Macierz $\mathbf{H}$ nazywa się **macierzą daszkową** (ang. *hat matrix*), bo „nakłada daszek" na $\mathbf{y}$. Jest macierzą rzutu ortogonalnego: symetryczną ($\mathbf{H}^\top = \mathbf{H}$) i idempotentną ($\mathbf{H}^2 = \mathbf{H}$), bo rzut wektora, który już leży w podprzestrzeni, nic nie zmienia. Macierz $\mathbf{I}-\mathbf{H}$ rzutuje na dopełnienie ortogonalne $\mathcal{C}(\mathbf{X})$ i daje reszty, $\mathbf{e} = (\mathbf{I}-\mathbf{H})\mathbf{y}$. Ślad $\mathbf{H}$ jest równy wymiarowi podprzestrzeni, na którą rzutuje:

$$\operatorname{tr}\mathbf{H} = \operatorname{tr}\left((\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\right) = \operatorname{tr}\mathbf{I}_{p+1} = p+1, \tag{6.7}$$

gdzie skorzystaliśmy z równości $\operatorname{tr}(\mathbf{AB}) = \operatorname{tr}(\mathbf{BA})$. Ponieważ $\hat{\mathbf{y}}$ i $\mathbf{e}$ są prostopadłe, zachodzi twierdzenie Pitagorasa: $\|\mathbf{y}\|^2 = \|\hat{\mathbf{y}}\|^2 + \|\mathbf{e}\|^2$.

Ślad jako liczba parametrów

W sekcji 5.4 opisaliśmy metody, dla których $\hat{\mathbf{y}} = \mathbf{S}\mathbf{y}$. Metoda najmniejszych kwadratów do nich należy, z $\mathbf{S} = \mathbf{H}$. Dla regresji k-NN na przekątnej $\mathbf{S}$ stoi $1/k$, więc $\operatorname{tr}\mathbf{S} = n/k$ – to dokładnie efektywna liczba parametrów, którą w rozdziale 4 mierzyliśmy elastyczność tej metody. Dla MNK ślad $\mathbf{H}$ to $p+1$, czyli liczba współczynników. Ślad macierzy $\mathbf{S}$ jest więc wspólną miarą elastyczności metod liniowych względem $\mathbf{y}$ (Hastie i in. 2009, rozdz. 7.6). Element przekątny h_{ii} mówi, jaką wagę predykcja w punkcie $\mathbf{x}_i$ przypisuje własnemu wynikowi y_i; nazywa się go **dźwignią** obserwacji i (Zadanie 6.2).

Wzór to nie algorytm

Wzór (6.4) opisuje rozwiązanie, ale nie jest dobrym sposobem jego obliczania. Utworzenie $\mathbf{X}^\top\mathbf{X}$ podnosi do kwadratu wskaźnik uwarunkowania macierzy, czyli czynnik, o jaki błędy zaokrągleń mogą się wzmocnić przy rozwiązywaniu układu. Biblioteki rozkładają więc $\mathbf{X}$, a nie $\mathbf{X}^\top\mathbf{X}$. W rozkładzie QR, $\mathbf{X} = \mathbf{Q}\mathbf{R}$ z ortonormalnymi kolumnami $\mathbf{Q}$ i trójkątną $\mathbf{R}$, równania normalne sprowadzają się do układu trójkątnego $\mathbf{R}\beta = \mathbf{Q}^\top\mathbf{y}$. Funkcja `np.linalg.lstsq` korzysta z rozkładu według wartości osobliwych.

Dla wielomianu stopnia 10 na 50 punktach z przedziału $[0, 1]$ różnica jest dramatyczna:

```
uwarunkowanie X:     2.0e+07
uwarunkowanie X^T X: 4.1e+14
```

Przy podwójnej precyzji, czyli około 16 cyfrach znaczących, wskaźnik rzędu 10^{14} zostawia w rozwiązaniu najwyżej dwie wiarygodne cyfry. Dlatego w rozdziale 4 używaliśmy funkcji `Polynomial.fit`, która przed dopasowaniem przeskalowuje x do przedziału $[-1, 1]$.

6.2.2. Dopasowanie do danych *Advertising*

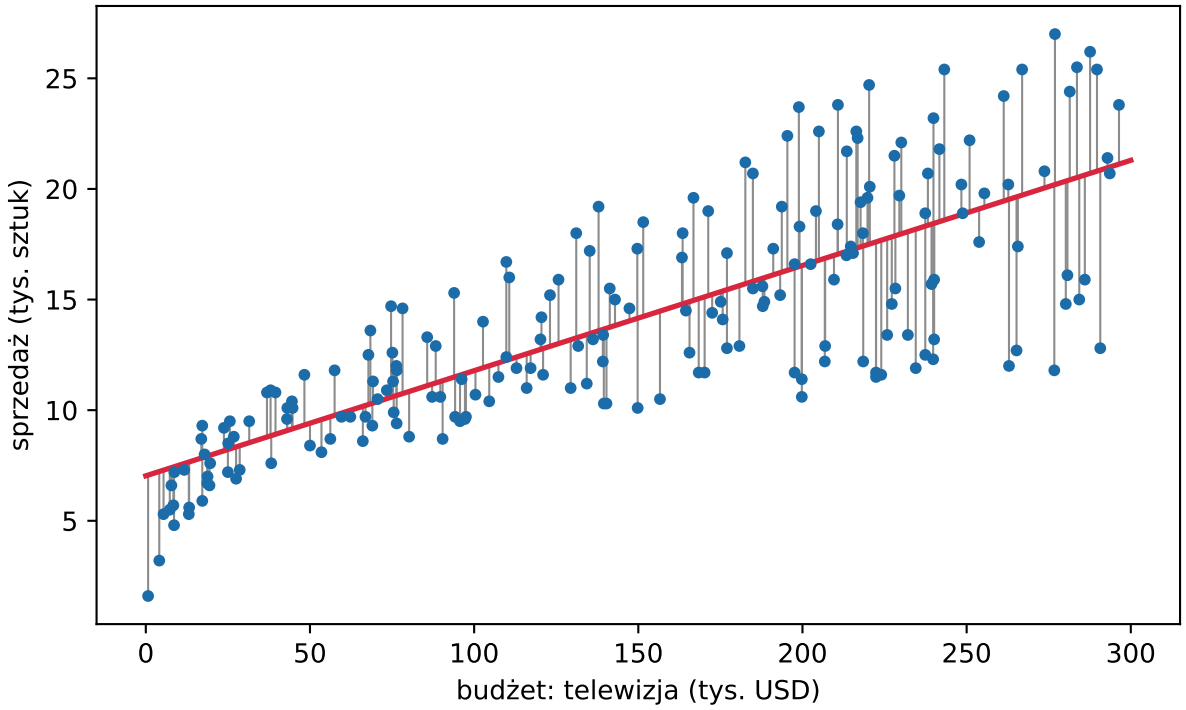
Zacznijmy od regresji sprzedaży względem budżetu telewizyjnego. Rysunek 6.2 pokazuje prostą najmniejszych kwadratów i reszty, czyli pionowe odcinki, których kwadraty minimalizujemy.

Otrzymujemy $\hat{\beta}_0 \approx 7{,}03$ i $\hat{\beta}_1 \approx 0{,}0475$. Każdy dodatkowy tysiąc dolarów budżetu telewizyjnego wiąże się przeciętnie z 47,5 sztukami sprzedanego produktu więcej. Wyraz wolny to przewidywana sprzedaż przy zerowym budżecie telewizyjnym. Tutaj ma on sens, bo w danych są rynki z budżetem bliskim zera.

Teraz dopasujmy model ze wszystkimi trzema mediami i porównajmy jego współczynniki ze współczynnikami trzech regresji z jedną cechą.

	regresja z jedną cechą	regresja z trzema cechami
TV	0.0475	0.0458
radio	0.2025	0.1885
newspaper	0.0547	-0.0010

Współczynniki przy telewizji i radiu prawie się nie zmieniają. Przy prasie zmienia się wszystko: w regresji z jedną cechą tysiąc dolarów wiąże się z 55 sztukami więcej, w regresji z trzema cechami – z praktycznie zerową zmianą, a nawet z lekkim spadkiem. Obie liczby są poprawne,



Rysunek 6.2.: Regresja sprzedaży względem budżetu telewizyjnego metodą najmniejszych kwadratów. Pionowe odcinki to reszty $e_i = y_i - \hat{y}_i$; prosta minimalizuje sumę ich kwadratów.

ale odpowiadają na różne pytania. Pierwsza porównuje rynki o różnym budżecie prasowym bez względu na pozostałe budżety. Druga porównuje rynki o różnym budżecie prasowym i **tych samych** budżetach telewizyjnym i radiowym. Korelacja budżetów prasowego i radiowego w próbie wynosi 0,35: tam, gdzie dużo wydaje się na radio, wydaje się też więcej na prasę. W regresji z jedną cechą prasa przejmuje więc część zasługi radia. Współczynnik w regresji wielokrotnej jest równy współczynnikowi regresji $\mathbf{y}$ względem tej części cechy, której nie da się liniowo przewidzieć z pozostałych cech (Zadanie 6.8).

6.3. Własności estymatora MNK

Dopasowanie metodą najmniejszych kwadratów to rachunek na danych. Aby powiedzieć, jak daleko $\hat{\beta}$ może leżeć od β, potrzebujemy modelu losowości. Tak jak w sekcji 4.4 przy metodzie k-NN, przyjmujemy **ustalony układ**: punkty $\mathbf{x}_1, \ldots, \mathbf{x}_n$ traktujemy jako ustalone, a losowe są tylko wyniki. Formalnie oznacza to warunkowanie względem cech; wszystkie wartości oczekiwane w tej sekcji liczymy przy danym $\mathbf{X}$.

Definicja 6.1 (Założenia modelu liniowego)**.** Wektor wyników ma postać $\mathbf{y} = \mathbf{X}\beta + \varepsilon$, gdzie macierz $\mathbf{X}$ jest ustalona, ma liniowo niezależne kolumny, oraz

- (Z1) $\mathbb{E}\varepsilon = \mathbf{0}$,
- (Z2) $\operatorname{Cov}\varepsilon = \sigma^2\mathbf{I}$, czyli błędy są nieskorelowane i mają jednakową wariancję σ^2.

Założenie (Z1) to pierwsze odczytanie modelu z sekcji 6.1: funkcja regresji jest liniowa. Założenie (Z2) wyklucza między innymi sytuację z rysunku 6.1, w której rozrzut wokół prostej rośnie z budżetem.

Twierdzenie 6.2 (Średnia i macierz kowariancji estymatora MNK)**.** *Przy założeniach (Z1)–(Z2)*

$$\mathbb{E}\hat{\beta} = \beta, \qquad \operatorname{Cov}\hat{\beta} = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}. \tag{6.8}$$

Dowód. Z (6.4),

$$\hat{\beta} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top(\mathbf{X}\beta + \varepsilon) = \beta + \mathbf{A}\varepsilon, \qquad \mathbf{A} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top.$$

Macierz $\mathbf{A}$ jest ustalona, więc $\mathbb{E}\hat{\beta} = \beta + \mathbf{A}\,\mathbb{E}\varepsilon = \beta$. Dla wektora losowego $\mathbf{A}\varepsilon$ zachodzi $\operatorname{Cov}(\mathbf{A}\varepsilon) = \mathbf{A}\operatorname{Cov}(\varepsilon)\mathbf{A}^\top$, więc

$$\operatorname{Cov}\hat{\beta} = \sigma^2\mathbf{A}\mathbf{A}^\top = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1} = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}.$$

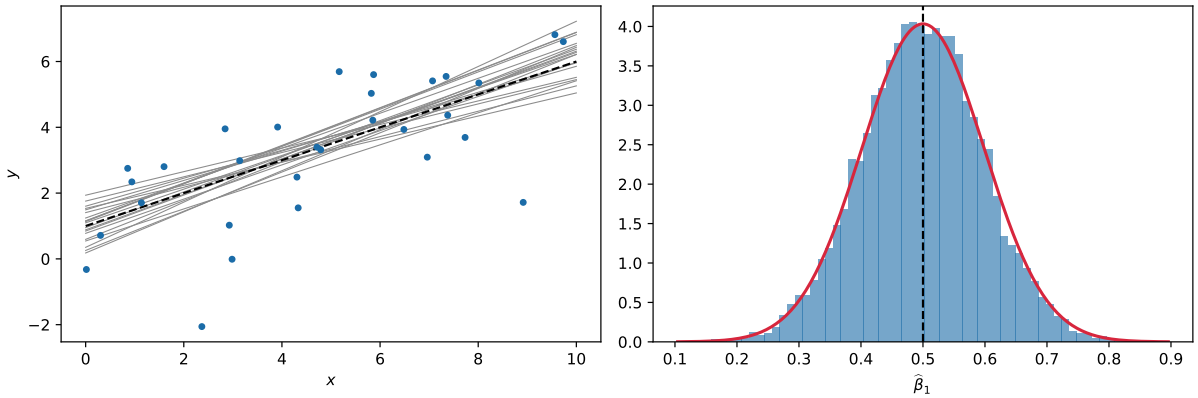
□

Estymator MNK jest więc nieobciążony, a jego rozrzut zależy od dwóch rzeczy: od poziomu szumu σ^2 i od układu punktów, zapisanego w $\mathbf{X}^\top\mathbf{X}$. Dla jednej cechy, odwracając macierz 2×2, otrzymujemy

$$\operatorname{Var}\hat{\beta}_1 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \qquad \operatorname{Var}\hat{\beta}_0 = \sigma^2\Big(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\Big) \tag{6.9}$$

(Zadanie 6.1). Nachylenie jest wyznaczone tym dokładniej, im szerzej rozrzucone są punkty x_i. Gdy wszystkie leżą blisko siebie, niewielki szum w wynikach wystarcza, by mocno przechylić prostą. Ponieważ $\sum_i (x_i - \bar{x})^2 = n s_x^2$, gdzie s_x^2 jest wariancją z próby, odchylenie standardowe $\hat{\beta}_1$ maleje jak $\sigma/(s_x\sqrt{n})$.

Rysunek 6.3 pokazuje to na symulacji. Punkty x_i, $n = 30$, wylosowaliśmy raz z rozkładu jednostajnego na $[0, 10]$ i trzymamy je ustalone. W każdej z 10 000 prób losujemy nowe wyniki $y_i = 1 + 0{,}5\,x_i + \varepsilon_i$, z $\varepsilon_i \sim \mathcal{N}(0, 1{,}5^2)$, i dopasowujemy prostą.



Rysunek 6.3.: Estymator MNK w 10 000 próbach z modelu $y_i = 1 + 0{,}5\,x_i + \varepsilon_i$ przy ustalonych punktach x_i ($n = 30$, $\sigma = 1{,}5$). Po lewej: proste dopasowane do 20 prób (cienkie linie) i prawdziwa prosta (przerywana). Po prawej: histogram $\hat{\beta}_1$ na tle gęstości rozkładu normalnego o średniej β_1 i wariancji z (6.9).

Średnia $\hat{\beta}_1$ po próbach jest równa $\beta_1 = 0{,}5$ z dokładnością do szumu symulacji, a histogram pokrywa się z gęstością o wariancji (6.9). Kształt tej gęstości jest normalny, bo błędy w symulacji są normalne; twierdzenie 6.2 mówi tylko o średniej i wariancji.

6.3.1. Wariancja predykcji

Predykcja w punkcie $\mathbf{x}_0$ to $\hat{f}(\mathbf{x}_0) = \tilde{\mathbf{x}}_0^\top \hat{\beta}$, gdzie $\tilde{\mathbf{x}}_0 = (1, \mathbf{x}_0)$ jest wektorem cech uzupełnionym o jedynkę. Z twierdzenia 6.2 jest ona nieobciążonym estymatorem $f^*(\mathbf{x}_0) = \tilde{\mathbf{x}}_0^\top \beta$ o wariancji

$$\operatorname{Var} \hat{f}(\mathbf{x}_0) = \sigma^2 \, \tilde{\mathbf{x}}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \tilde{\mathbf{x}}_0. \tag{6.10}$$

W punktach uczących macierz kowariancji wektora predykcji to $\operatorname{Cov}(\mathbf{H}\mathbf{y}) = \sigma^2 \mathbf{H}\mathbf{H}^\top = \sigma^2 \mathbf{H}$, więc wariancja predykcji w $\mathbf{x}_i$ wynosi $\sigma^2 h_{ii}$. Średnio po punktach uczących, z (6.7),

$$\frac{1}{n} \sum_{i=1}^{n} \operatorname{Var} \hat{f}(\mathbf{x}_i) = \frac{\sigma^2}{n} \operatorname{tr} \mathbf{H} = \sigma^2 \, \frac{p+1}{n}. \tag{6.11}$$

To jest fakt, na który powoływaliśmy się w sekcji 4.8. Jeśli model liniowy jest trafny, predyktor MNK nie ma obciążenia, a jego wariancja maleje jak $1/n$ ze stałą proporcjonalną do liczby współczynników, bez względu na wymiar cech. Porównajmy to z wariancją σ^2/k regresji k-NN w ustalonym układzie (4.6). Można ją zapisać jako $\sigma^2(n/k)/n$: obie metody płacą wariancją σ^2 razy efektywna liczba parametrów podzielona przez n. Różnica leży w obciążeniu. Metoda k-NN, żeby mieć małe obciążenie, potrzebuje małych otoczeń, czyli wielu efektywnych parametrów. Model liniowy, jeśli jest trafny, ma zerowe obciążenie przy $p+1$ parametrach.

Wzór (6.11) dotyczy punktów uczących. Dla nowego punktu $\mathbf{X}_0$ z tego samego rozkładu co cechy uczące wariancja jest nieco większa, ale przy dużym n również bliska $\sigma^2(p+1)/n$. Wtedy bowiem $\mathbf{X}^\top \mathbf{X} \approx n \, \mathbb{E}[\tilde{\mathbf{X}}_0 \tilde{\mathbf{X}}_0^\top]$, więc średnia wartość $\tilde{\mathbf{X}}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \tilde{\mathbf{X}}_0$ jest bliska $\operatorname{tr} \mathbf{I}_{p+1}/n$.

6.3.2. Estymacja wariancji błędu

Wzory (6.8) i (6.10) zawierają nieznane σ^2. Naturalnym kandydatem na jego estymator są reszty, ale są one systematycznie mniejsze od błędów: dopasowanie dostosowało się do tych samych danych.

Twierdzenie 6.3 (Wartość oczekiwana sumy kwadratów reszt)**.** *Przy założeniach (Z1)–(Z2)*

$$\mathbb{E} \operatorname{RSS}(\hat{\beta}) = \sigma^2 (n - p - 1),$$

więc

$$\hat{\sigma}^2 = \frac{\operatorname{RSS}(\hat{\beta})}{n - p - 1} \tag{6.12}$$

jest nieobciążonym estymatorem σ^2.

Dowód. Ponieważ $(\mathbf{I} - \mathbf{H})\mathbf{X} = \mathbf{0}$, wektor reszt to $\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{y} = (\mathbf{I} - \mathbf{H})\varepsilon$. Macierz $\mathbf{I} - \mathbf{H}$ jest symetryczna i idempotentna, więc $\operatorname{RSS} = \mathbf{e}^\top \mathbf{e} = \varepsilon^\top (\mathbf{I} - \mathbf{H})\varepsilon$. Dla ustalonej macierzy $\mathbf{M}$ mamy $\mathbb{E}[\varepsilon^\top \mathbf{M} \varepsilon] = \sum_{i,j} M_{ij} \mathbb{E}[\varepsilon_i \varepsilon_j] = \sigma^2 \operatorname{tr} \mathbf{M}$, a $\operatorname{tr}(\mathbf{I} - \mathbf{H}) = n - (p+1)$ z (6.7). □

Dowód pokazuje, skąd bierze się mianownik $n - p - 1$. Wektor błędów ma n współrzędnych, ale rzut na $\mathcal{C}(\mathbf{X})$ „pochłania" jego składową w $p+1$ kierunkach i przenosi ją do predykcji. W resztach zostaje składowa w pozostałych $n - p - 1$ kierunkach, które nazywa się **resztowymi stopniami swobody**. Wariancja z próby z mianownikiem $n - 1$ jest szczególnym przypadkiem $p = 0$ (Zadanie 6.5). Błąd na zbiorze uczącym, RSS/n, ma wartość oczekiwaną $\sigma^2(1 - (p+1)/n)$, czyli zaniża nawet błąd nieredukowalny. To jest optymizm błędu uczącego z sekcji 4.1, który dla MNK można policzyć dokładnie (Zadanie 6.4).

6.3.3. Twierdzenie Gaussa–Markowa

Estymator MNK jest nieobciążony, ale czy jest najlepszy? Odpowiedź zależy od tego, z czym go porównujemy. Estymator $\tilde{\beta}$ nazywamy **liniowym**, jeśli $\tilde{\beta} = \mathbf{C}\mathbf{y}$ dla macierzy $\mathbf{C}$ zależnej tylko od $\mathbf{X}$. Estymator MNK jest liniowy, z $\mathbf{C} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$.

Twierdzenie 6.4 (Gaussa–Markowa)**.** *Przy założeniach (Z1)–(Z2) niech $\tilde{\beta} = \mathbf{C}\mathbf{y}$ będzie dowolnym liniowym estymatorem β nieobciążonym dla każdej wartości β. Wtedy macierz* $\operatorname{Cov}\tilde{\beta} - \operatorname{Cov}\hat{\beta}$ *jest dodatnio półokreślona. W szczególności dla każdego wektora* $\mathbf{c}$

$$\operatorname{Var}(\mathbf{c}^\top\tilde{\beta}) \geq \operatorname{Var}(\mathbf{c}^\top\hat{\beta}).$$

Dowód. Niech $\mathbf{A} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$ i $\mathbf{D} = \mathbf{C} - \mathbf{A}$. Nieobciążoność oznacza $\mathbb{E}\tilde{\beta} = \mathbf{C}\mathbf{X}\beta = \beta$ dla każdego β, czyli $\mathbf{C}\mathbf{X} = \mathbf{I}$. Ponieważ $\mathbf{A}\mathbf{X} = \mathbf{I}$, mamy $\mathbf{D}\mathbf{X} = \mathbf{0}$. Stąd $\mathbf{A}\mathbf{D}^\top = (\mathbf{X}^\top\mathbf{X})^{-1}(\mathbf{D}\mathbf{X})^\top = \mathbf{0}$ i

$$\operatorname{Cov}\tilde{\beta} = \sigma^2\mathbf{C}\mathbf{C}^\top = \sigma^2(\mathbf{A}+\mathbf{D})(\mathbf{A}+\mathbf{D})^\top = \sigma^2\mathbf{A}\mathbf{A}^\top + \sigma^2\mathbf{D}\mathbf{D}^\top = \operatorname{Cov}\hat{\beta} + \sigma^2\mathbf{D}\mathbf{D}^\top.$$

Macierz $\mathbf{D}\mathbf{D}^\top$ jest dodatnio półokreślona, bo $\mathbf{c}^\top\mathbf{D}\mathbf{D}^\top\mathbf{c} = \|\mathbf{D}^\top\mathbf{c}\|^2 \geq 0$. □

Estymator MNK jest więc najlepszym liniowym estymatorem nieobciążonym (ang. *best linear unbiased estimator*, BLUE) (Hastie i in. 2009, rozdz. 3.2.2). Dotyczy to też każdej kombinacji liniowej współczynników, w tym predykcji $\tilde{\mathbf{x}}_0^\top\hat{\beta}$ w dowolnym punkcie. Dla modelu z samym wyrazem wolnym twierdzenie mówi, że średnia z próby jest najlepszą nieobciążoną średnią ważoną obserwacji (Zadanie 6.6).

> **i** Czego twierdzenie nie mówi
>
> Twierdzenie porównuje MNK tylko z estymatorami liniowymi i nieobciążonymi. W sekcji 4.3 widzieliśmy, że estymator ściągający $c\bar{Y}$, obciążony, może mieć wyraźnie mniejszy błąd średniokwadratowy niż nieobciążona średnia $\bar{Y}$. Ten sam mechanizm działa dla współczynników regresji. Założenie (Z2) też jest istotne: gdy błędy mają różne wariancje, lepiej ważyć obserwacje odwrotnościami tych wariancji, a MNK traktuje wszystkie jednakowo.

6.4. Wnioskowanie o parametrach

Twierdzenie 6.2 podaje średnią i wariancję $\hat{\beta}$. Żeby z jednej próby zbudować przedział ufności albo policzyć p-wartość, potrzebujemy całego rozkładu. Dokładamy więc trzecie założenie:

- (Z3) $\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I})$, czyli błędy są niezależne i mają rozkład normalny.

Twierdzenie 6.5 (Rozkłady w modelu liniowym z normalnymi błędami)**.** *Przy założeniach (Z1)–(Z3):*

a) $\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1})$*;*
b) RSS/σ^2 *ma rozkład* χ^2 *z* $n-p-1$ *stopniami swobody;*
c) $\hat{\beta}$ *i* RSS *są niezależne.*

szkic. Część (a): $\hat{\beta} = \beta + \mathbf{A}\varepsilon$ jest przekształceniem liniowym wektora gaussowskiego, więc ma rozkład normalny, a jego parametry podaje twierdzenie 6.2.

Części (b) i (c) wynikają z geometrii. Wybierzmy bazę ortonormalną $\mathbb{R}^n$, w której pierwsze $p+1$ wektorów rozpina $\mathcal{C}(\mathbf{X})$, a pozostałe $n-p-1$ – jej dopełnienie ortogonalne. Niech $\mathbf{Q}$ będzie macierzą ortogonalną o tych wektorach w kolumnach, a $\mathbf{z} = \mathbf{Q}^\top\varepsilon$ wektorem współrzędnych błędów w nowej bazie. Rozkład $\mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I})$ jest sferycznie symetryczny, więc obrót go nie zmienia: $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I})$, czyli współrzędne $z_1, \ldots, z_n$ są niezależne. Składowa $\mathbf{H}\varepsilon$ zależy tylko od $z_1, \ldots, z_{p+1}$, a reszty $\mathbf{e} = (\mathbf{I} - \mathbf{H})\varepsilon$ – tylko od $z_{p+2}, \ldots, z_n$. Stąd $\mathrm{RSS} = \|\mathbf{e}\|^2 = z_{p+2}^2 + \cdots + z_n^2$ jest sumą kwadratów $n-p-1$ niezależnych zmiennych $\mathcal{N}(0, \sigma^2)$, co daje (b). Ponadto $\hat{\beta} - \beta = \mathbf{A}\varepsilon = \mathbf{A}\mathbf{H}\varepsilon$ (bo $\mathbf{X}^\top\mathbf{H} = \mathbf{X}^\top$) zależy tylko od $z_1, \ldots, z_{p+1}$, co daje (c). Szczegółowy wykład zawierają Seber i Lee (2003, rozdz. 2–3). □

6.4.1. Błędy standardowe i przedziały ufności

Z części (a) wariancja $\hat{\beta}_j$ to $\sigma^2 v_{jj}$, gdzie v_{jj} jest j-tym elementem przekątnej $(\mathbf{X}^\top\mathbf{X})^{-1}$ (numerując od zera). Zastępując σ przez $\hat{\sigma}$ z (6.12), otrzymujemy **błąd standardowy**

$$\mathrm{SE}(\hat{\beta}_j) = \hat{\sigma}\sqrt{v_{jj}}.$$

Statystyka

$$T_j = \frac{\hat{\beta}_j - \beta_j}{\mathrm{SE}(\hat{\beta}_j)} = \frac{(\hat{\beta}_j - \beta_j)/(\sigma\sqrt{v_{jj}})}{\sqrt{\mathrm{RSS}/(\sigma^2(n-p-1))}} \tag{6.13}$$

jest ilorazem zmiennej o rozkładzie $\mathcal{N}(0,1)$ przez pierwiastek z niezależnej od niej zmiennej χ^2_{n-p-1} podzielonej przez liczbę stopni swobody. Taki iloraz ma z definicji **rozkład t Studenta** z $n-p-1$ stopniami swobody. Nie zależy on od nieznanych β i σ, więc

$$\mathbb{P}(|T_j| \le t_{n-p-1}) = 1 - \alpha,$$

gdzie t_{n-p-1} oznacza kwantyl rzędu $1-\alpha/2$ tego rozkładu. Przekształcając nierówność, dostajemy **przedział ufności** dla β_j na poziomie $1-\alpha$:

$$\Big[\, \hat{\beta}_j - t_{n-p-1}\,\mathrm{SE}(\hat{\beta}_j),\ \hat{\beta}_j + t_{n-p-1}\,\mathrm{SE}(\hat{\beta}_j) \,\Big]. \tag{6.14}$$

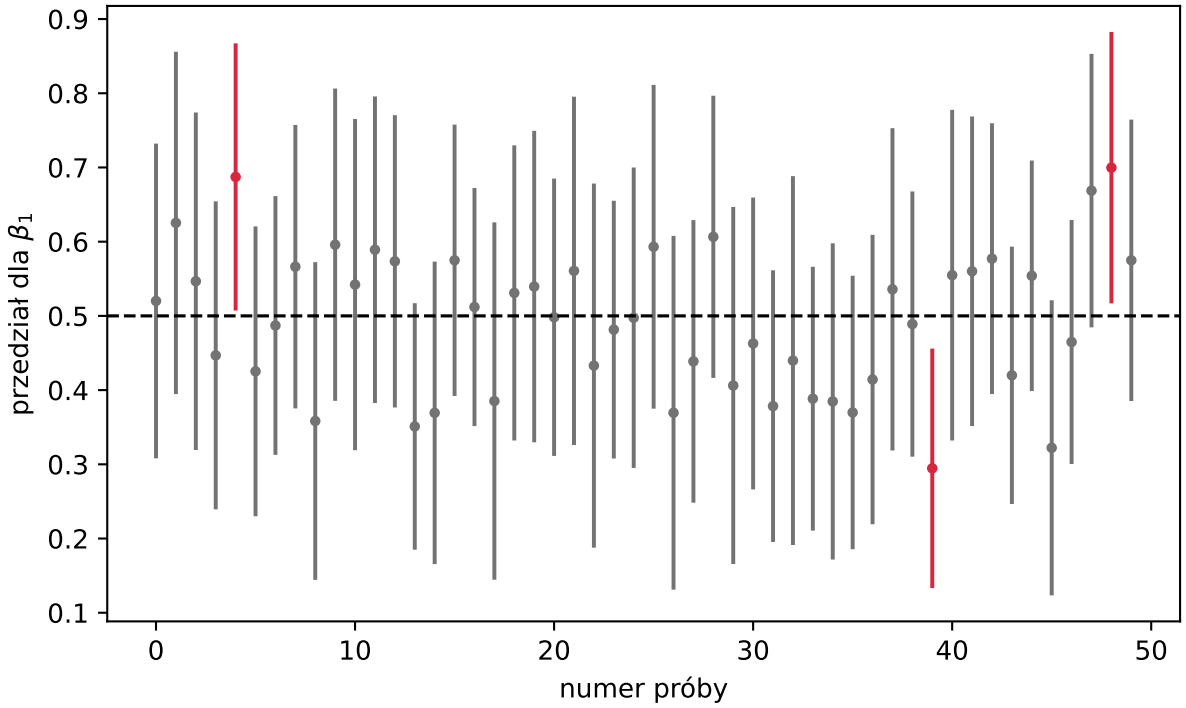
Zastąpienie σ oszacowaniem kosztuje: rozkład t ma grubsze ogony niż normalny, więc kwantyl jest większy od 1,96. Przy 28 stopniach swobody wynosi 2,05, przy dużej ich liczbie zbliża się do 1,96.

Losowy jest przedział, a nie β_j. Poziom ufności 95% oznacza, że w 95% prób procedura daje przedział zawierający β_j. O jednym obliczonym przedziale nie mówi nic więcej: β_j albo w nim leży, albo nie. Rysunek 6.4 pokazuje przedziały z 50 pierwszych prób symulacji z rysunku 6.3.

```
odsetek przedziałów pokrywających beta1 we wszystkich próbach: 0.953
```

We wszystkich 10 000 próbach przedział pokrył β_1 w około 95% przypadków. Tak musi być, gdy założenia (Z1)–(Z3) są spełnione. Co się dzieje, gdy nie są, sprawdza Zadanie 6.7.

Pakiet `statsmodels` liczy błędy standardowe, statystyki t i przedziały ufności za nas. Dla regresji sprzedaży względem budżetu telewizyjnego:



Rysunek 6.4.: Przedziały ufności 95% dla β_1 z 50 prób symulacji z rysunku 6.3. Czerwone przedziały nie zawierają prawdziwej wartości $\beta_1 = 0{,}5$ (linia przerywana).

	coef	**std err**	**t**	**P> |t|**	**[0.025**	**0.975]**
const	7.0326	0.458	15.360	0.000	6.130	7.935
TV	0.0475	0.003	17.668	0.000	0.042	0.053

Przedział ufności dla współczynnika przy telewizji to około [0,042; 0,053]. Tysiąc dolarów budżetu telewizyjnego wiąże się więc przeciętnie z 42 do 53 sztukami sprzedanego produktu więcej.

6.4.1.1. Przedział dla średniej i przedział predykcji

Pytanie „jaka jest przeciętna sprzedaż na rynkach o budżecie $\mathbf{x}_0$?" dotyczy liczby $f^*(\mathbf{x}_0) = \tilde{\mathbf{x}}_0^\top \beta$. Jej estymator $\tilde{\mathbf{x}}_0^\top \hat{\beta}$ ma wariancję (6.10), a przedział ufności buduje się tak samo jak (6.14), z $\mathrm{SE}^2 = \hat{\sigma}^2\, \tilde{\mathbf{x}}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \tilde{\mathbf{x}}_0$. Pytanie „ile sprzeda się na **jednym** nowym rynku o budżecie $\mathbf{x}_0$?" dotyczy zmiennej losowej $Y_0 = \tilde{\mathbf{x}}_0^\top \beta + \varepsilon_0$. Błąd ε_0 nowej obserwacji jest niezależny od próby, więc

$$\mathrm{Var}\,(Y_0 - \tilde{\mathbf{x}}_0^\top \hat{\beta}) = \sigma^2 + \sigma^2\, \tilde{\mathbf{x}}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \tilde{\mathbf{x}}_0.$$

Jest to rozkład z rozdziału 2 w małej skali: pierwszy składnik to błąd nieredukowalny, drugi – redukowalny, który dla nieobciążonego estymatora składa się z samej wariancji. **Przedział predykcji** ma w miejscu SE^2 sumę obu składników, z σ^2 zastąpionym przez $\hat{\sigma}^2$. Przy rosnącym n przedział ufności dla średniej kurczy się do punktu, a przedział predykcji nie zejdzie poniżej $\pm 1{,}96\,\sigma$.

	mean	mean_se	mean_ci_lower	mean_ci_upper	obs_ci_lower	obs_ci_upper
0	11.26	0.14	10.99	11.53	7.93	14.58

Dla rynku z budżetem telewizyjnym 100 i radiowym 20 tysięcy dolarów model z dwiema cechami przewiduje sprzedaż 11,26 tysiąca sztuk. Przeciętna sprzedaż na takich rynkach leży z ufnością 95% między 10,99 a 11,53 tysiąca (kolumny `mean_ci`), ale sprzedaż na konkretnym rynku – między 7,93 a 14,58 tysiąca (kolumny `obs_ci`).

6.4.2. Test istnienia relacji

Wróćmy do pierwszego pytania ze wstępu. Hipoteza $H_0 : \beta_j = 0$ mówi, że cecha X_j nie wiąże się ze średnim wynikiem, gdy pozostałe cechy są ustalone. Przy tej hipotezie statystyka $t = \hat{\beta}_j / \mathrm{SE}(\hat{\beta}_j)$ ma rozkład t z $n - p - 1$ stopniami swobody. Jej wartość mówi, o ile błędów standardowych oszacowanie odbiega od zera. **p-wartość**

$$p = \mathbb{P}_{H_0}(|T| \geq |t_{\mathrm{obs}}|)$$

to prawdopodobieństwo, że przy prawdziwej H_0 statystyka wypadłaby co najmniej tak daleko od zera jak w naszej próbie. Mała p-wartość oznacza, że dane byłyby przy H_0 zaskakujące, i jest podstawą do jej odrzucenia. Nie jest prawdopodobieństwem, że H_0 jest prawdziwa. Hipotezę odrzucamy na poziomie α wtedy i tylko wtedy, gdy przedział ufności (6.14) nie zawiera zera.

	coef	**std err**	**t**	**P> |t|**	**[0.025**	**0.975]**
const	2.9389	0.312	9.422	0.000	2.324	3.554
TV	0.0458	0.001	32.809	0.000	0.043	0.049
radio	0.1885	0.009	21.893	0.000	0.172	0.206
newspaper	-0.0010	0.006	-0.177	0.860	-0.013	0.011

W modelu z trzema mediami współczynniki przy telewizji i radiu mają statystyki t rzędu 30 i 20, a współczynnik przy prasie – $t \approx -0{,}18$ i $p \approx 0{,}86$. W regresji z samą prasą ten sam współczynnik ma $t \approx 3{,}3$ i $p \approx 0{,}001$. Nie ma tu sprzeczności, bo hipotezy są różne. Pierwsza mówi, że prasa nie wnosi nic, gdy znamy budżety telewizyjny i radiowy. Druga – że sprzedaż nie zależy od budżetu prasowego w ogóle.

6.4.2.1. Test F

Gdy cech jest wiele, chcemy zapytać, czy **którakolwiek** z nich wiąże się z wynikiem: $H_0 : \beta_1 = \cdots = \beta_p = 0$. Nie możemy odpowiedzieć na to pytanie, wykonując p testów t. Każdy z nich na poziomie 5% myli się przy prawdziwej H_0 z prawdopodobieństwem 0,05, więc przy 100 cechach niemal na pewno któryś odrzuci hipotezę. Symulacja ze 100 cechami niezależnymi od wyniku pokazuje to wprost:

```
średnia liczba istotnych testów t:      4.9 na 100
odsetek prób z co najmniej jednym:      0.968
odsetek prób, w których test F odrzuca: 0.054
```

Przeciętnie około pięć cech wychodzi „istotnych”, a prawie w każdej próbie co najmniej jedna. Test F, który zaraz wyprowadzimy, odrzuca prawdziwą hipotezę w około 5% prób, tak jak powinien.

Wyprowadzimy go od razu w ogólniejszej postaci. Niech model M_0 powstaje z modelu M przez usunięcie q cech, czyli przez hipotezę, że ich współczynniki są zerowe. Przestrzeń kolumn $\mathcal{C}(\mathbf{X}_0)$

modelu M_0 jest zawarta w $\mathcal{C}(\mathbf{X})$, więc $\mathrm{RSS}_0 \geq \mathrm{RSS}$. Pytamy, czy spadek $\mathrm{RSS}_0 - \mathrm{RSS}$ jest większy, niż dałby sam szum. Wektor $\mathbf{y} - \hat{\mathbf{y}}_0$ rozkłada się na $(\mathbf{y} - \hat{\mathbf{y}}) + (\hat{\mathbf{y}} - \hat{\mathbf{y}}_0)$, przy czym pierwszy składnik jest prostopadły do $\mathcal{C}(\mathbf{X})$, a drugi w niej leży. Z twierdzenia Pitagorasa

$$\mathrm{RSS}_0 = \mathrm{RSS} + \|\hat{\mathbf{y}} - \hat{\mathbf{y}}_0\|^2.$$

Jeśli H_0 jest prawdziwa, to $\mathbf{X}\beta \in \mathcal{C}(\mathbf{X}_0)$, więc $\hat{\mathbf{y}} - \hat{\mathbf{y}}_0$ jest rzutem samego szumu ε na q-wymiarową podprzestrzeń: część $\mathcal{C}(\mathbf{X})$ prostopadłą do $\mathcal{C}(\mathbf{X}_0)$. Rozumowanie ze szkicu dowodu twierdzenia 6.5, z bazą dopasowaną do trzech wzajemnie prostopadłych podprzestrzeni, daje $\|\hat{\mathbf{y}} - \hat{\mathbf{y}}_0\|^2/\sigma^2 \sim \chi^2_q$, niezależne od RSS. Statystyka

$$F = \frac{(\mathrm{RSS}_0 - \mathrm{RSS})/q}{\mathrm{RSS}/(n-p-1)} \tag{6.15}$$

jest więc przy H_0 ilorazem dwóch niezależnych zmiennych χ^2 podzielonych przez swoje stopnie swobody, czyli ma **rozkład** F z q i $n-p-1$ stopniami swobody (Seber i Lee 2003, rozdz. 4). Licznik i mianownik mają czytelny sens. Mianownik to $\hat{\sigma}^2$, nieobciążony estymator σ^2 niezależnie od H_0. Licznik przy H_0 również ma średnią σ^2, bo każdy z q kierunków wnosi przeciętnie σ^2. Gdy H_0 jest fałszywa, licznik zawiera też składową sygnału. Przy H_0 statystyka F oscyluje więc wokół 1, a duże wartości świadczą przeciw H_0.

Hipoteza, że wszystkie współczynniki poza wyrazem wolnym są zerowe, odpowiada modelowi M_0 z samym wyrazem wolnym. Dopasowaniem jest wtedy średnia $\bar{y}$, więc $\mathrm{RSS}_0 = \mathrm{TSS} = \sum_i (y_i - \bar{y})^2$, a $q = p$. Dla modelu z trzema mediami $F \approx 570$, a p-wartość jest rzędu 10^{-96}. Wydatki na reklamę wiążą się ze sprzedażą.

Dla $q = 1$ test F i test t sprawdzają tę samą hipotezę i są równoważne: $F = t^2$ (Zadanie 6.8). Sprawdźmy to dla prasy:

```
F = 0.0312,  t^2 = 0.0312,  p = 0.860
```

6.5. Jakość dopasowania

Test F mówi, czy cechy niosą jakąkolwiek informację o wyniku, ale nie mówi, ile jej niosą. Dwie miary opisują to bezpośrednio.

Pierwsza to $\hat{\sigma} = \sqrt{\mathrm{RSS}/(n-p-1)}$, nazywana w pakietach **resztowym błędem standardowym** (ang. *residual standard error*, RSE). Szacuje odchylenie standardowe błędu, czyli typową odległość wyniku od prostej regresji, w jednostkach Y. W regresji sprzedaży względem telewizji $\hat{\sigma} \approx 3{,}26$ tysiąca sztuk przy średniej sprzedaży 14,0 tysiąca, więc predykcja myli się typowo o mniej więcej jedną czwartą.

Druga miara jest bezwymiarowa. Model zawiera wyraz wolny, więc wektor $\bar{y}\,\mathbf{1}$ leży w $\mathcal{C}(\mathbf{X})$, a wraz z nim $\hat{\mathbf{y}} - \bar{y}\,\mathbf{1}$. Reszty są do $\mathcal{C}(\mathbf{X})$ prostopadłe, zatem z twierdzenia Pitagorasa

$$\underbrace{\sum_{i=1}^{n}(y_i - \bar{y})^2}_{\mathrm{TSS}} = \underbrace{\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2}_{\mathrm{ESS}} + \underbrace{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}_{\mathrm{RSS}}. \tag{6.16}$$

Całkowita zmienność wyniku rozkłada się na część odtworzoną przez model i część resztową. **Współczynnik determinacji**

$$R^2 = 1 - \frac{\mathrm{RSS}}{\mathrm{TSS}} = \frac{\mathrm{ESS}}{\mathrm{TSS}} \tag{6.17}$$

to odsetek zmienności y w próbie odtworzony przez model; leży w przedziale $[0, 1]$. Dla jednej cechy jest równy kwadratowi współczynnika korelacji z próby, $R^2 = r^2$ (Zadanie 6.1).

	RSS	R^2	skorygowany R^2	RSE
TV	2102.5306	0.6119	0.6099	3.2587
TV + radio	556.9140	0.8972	0.8962	1.6814
TV + radio + newspaper	556.8253	0.8972	0.8956	1.6855

Dodanie radia podnosi R^2 z 0,61 do 0,90 i zmniejsza $\hat{\sigma}$ o połowę. Dodanie prasy zmienia RSS dopiero na trzecim miejscu znaczącym, a $\hat{\sigma}$ nawet nieco rośnie, bo spadek licznika nie równoważy utraty stopnia swobody w mianowniku.

R^2 nigdy nie maleje po dodaniu cechy. Z tego samego powodu co błąd uczący w sekcji 4.1: klasy modeli są zagnieżdżone, a minimum po większej klasie nie jest większe. Nie jest to przypadek, bo $1 - R^2 = (\mathrm{RSS}/n)/(\mathrm{TSS}/n)$ jest po prostu błędem uczącym podzielonym przez wariancję y z próby. R^2 ma więc wszystkie wady błędu uczącego i nie nadaje się do wyboru modelu. **Skorygowany** R^2,

$$R^2_{\mathrm{adj}} = 1 - \frac{\mathrm{RSS}/(n-p-1)}{\mathrm{TSS}/(n-1)},$$

zastępuje oba ilorazy estymatorami nieobciążonymi i może zmaleć po dodaniu cechy, jak w ostatnim wierszu tabeli. Poprawka usuwa jednak tylko obciążenie $\hat{\sigma}^2$ dla jednego, z góry ustalonego modelu. Gdy porównujemy wiele modeli i wybieramy najlepszy, pojawia się optymizm wyboru z sekcji 5.6, którego żadna poprawka stopni swobody nie usuwa.

R^2 nie jest też własnością samej zależności. Dla jednej cechy $\mathbb{E}[\mathrm{ESS}]$ rośnie z rozrzutem x_i przy tym samym β_1 i tym samym σ (Zadanie 6.1). Ten sam model z tym samym szumem da więc wysokie R^2 na próbie o szerokim zakresie cechy i niskie na próbie o wąskim. Do porównań między próbami lepiej nadaje się $\hat{\sigma}$, wyrażone w jednostkach wyniku.

6.6. Cechy jakościowe

Dotąd wszystkie cechy były liczbami. Zbiór *Credit* (James i in. 2023, rozdz. 3.3.1) opisuje 400 klientów banku. Wynikiem jest średnie saldo zadłużenia na karcie kredytowej (`Balance`, w dolarach), a wśród cech są zarówno liczby – dochód (`Income`, w tysiącach dolarów), limit kredytowy (`Limit`), ocena kredytowa (`Rating`), wiek (`Age`) – jak i cechy jakościowe: czy klient ma dom (`Own`), czy jest studentem (`Student`) i z jakiego regionu pochodzi (`Region`: `East`, `South` albo `West`).

Cechę o dwóch wartościach zastępujemy **zmienną zero-jedynkową** $x_i = 1$, gdy i-ty klient ma dom, i $x_i = 0$ w przeciwnym razie. Model $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ mówi wtedy, że średnie saldo wynosi β_0 w grupie bez domu i $\beta_0 + \beta_1$ w grupie z domem. Współczynnik β_1 jest różnicą średnich obu grup, a jego estymatorem MNK – różnica średnich z próby (Zadanie 6.9).

	coef	**std err**	**t**	**P> |t|**	**[0.025**	**0.975]**
const	509.8031	33.128	15.389	0.000	444.675	574.931
Own_Yes	19.7331	46.051	0.429	0.669	-70.801	110.267

Klienci bez domu mają przeciętnie saldo 509,80 dolara, a klienci z domem o 19,73 dolara wyższe. Przy $p \approx 0{,}67$ dane nie świadczą jednak o żadnej różnicy.

Cecha o K wartościach wymaga $K-1$ zmiennych zero-jedynkowych. Jedną wartość wybieramy jako **poziom odniesienia**, a dla każdej z pozostałych tworzymy zmienną równą 1 na tym poziomie i 0 poza nim. Wyraz wolny jest wtedy średnią na poziomie odniesienia, a współczynnik przy zmiennej poziomu k – różnicą średnich poziomu k i poziomu odniesienia. Gdybyśmy dodali zmienne dla wszystkich K poziomów, ich suma byłaby równa kolumnie jedynek. Kolumny $\mathbf{X}$ byłyby liniowo zależne, a równania normalne miałyby nieskończenie wiele rozwiązań (twierdzenie 6.1): dowolną stałą można przenieść z wyrazu wolnego do wszystkich zmiennych zero-jedynkowych naraz.

Wybór poziomu odniesienia, a ogólniej sposób kodowania, zmienia współczynniki, ale nie zmienia dopasowania. Każde poprawne kodowanie daje kolumny, które razem z kolumną jedynek rozpinają tę samą przestrzeń: wektory stałe w obrębie grup. Ta sama przestrzeń $\mathcal{C}(\mathbf{X})$ oznacza tę samą macierz daszkową, te same predykcje, to samo RSS i to samo R^2. Zmieniają się tylko współrzędne $\hat{\mathbf{y}}$ w bazie kolumn, czyli współczynniki.

```
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const        531.0000     46.319     11.464      0.000     439.939     622.061
South        -12.5025     56.681     -0.221      0.826    -123.935      98.930
West         -18.6863     65.021     -0.287      0.774    -146.515     109.142
==============================================================================
F = 0.043,  p = 0.957
```

Średnie saldo na wschodzie wynosi 531 dolarów, na południu jest o 12,50, a na zachodzie o 18,69 dolara niższe. Testy t dla obu zmiennych zero-jedynkowych porównują te regiony ze wschodem, więc ich wyniki zależą od poziomu odniesienia. Gdyby nim był zachód, testowalibyśmy inne różnice i dostali inne p-wartości. Na pytanie, czy region w ogóle wiąże się z saldem, odpowiada test F hipotezy, że oba współczynniki są zerowe ($q = K - 1 = 2$). Jego wynik nie zależy od kodowania, bo zależy tylko od RSS i RSS_0. Tutaj $F \approx 0{,}04$ przy $p \approx 0{,}96$: region nie różnicuje sald.

6.7. Interakcje i nieliniowość

Model (6.1) jest **addytywny**: zmiana X_1 o jednostkę zmienia średni wynik o β_1 bez względu na wartości pozostałych cech. W danych *Advertising* to założenie jest wątpliwe. Reklama w telewizji i w radiu może się wzajemnie wzmacniać, tak że tysiąc dolarów wydany na telewizję daje więcej, gdy budżet radiowy jest duży. Prostym sposobem uwzględnienia takiego efektu jest **interakcja**, czyli dodanie iloczynu cech jako nowej cechy:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \varepsilon = \beta_0 + (\beta_1 + \beta_3 X_2)\, X_1 + \beta_2 X_2 + \varepsilon. \tag{6.18}$$

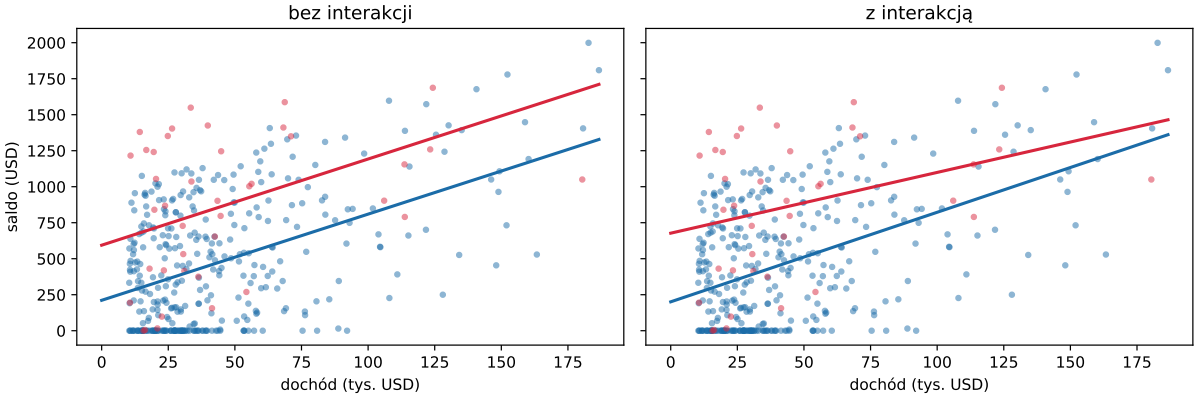
Nachylenie względem X_1 wynosi teraz $\beta_1 + \beta_3 X_2$ i zmienia się z X_2. Model pozostaje liniowy w parametrach, więc cała teoria z poprzednich sekcji stosuje się bez zmian; iloczyn $X_1 X_2$ jest po prostu jeszcze jedną kolumną $\mathbf{X}$.

```
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const          6.7502      0.248     27.233      0.000      6.261      7.239
TV             0.0191      0.002     12.699      0.000      0.016      0.022
radio          0.0289      0.009      3.241      0.001      0.011      0.046
TV_radio       0.0011   5.24e-05     20.727      0.000      0.001      0.001
==============================================================================
R^2 = 0.968,  RSE = 0.944
```

Statystyka t dla interakcji przekracza 20, a R^2 rośnie z 0,897 w modelu addytywnym do 0,968; $\hat{\sigma}$ spada z 1,68 do 0,94. Tysiąc dolarów budżetu telewizyjnego wiąże się teraz z $19{,}1 + 1{,}09 \cdot \texttt{radio}$ sztukami więcej: przy zerowym budżecie radiowym z 19 sztukami, przy budżecie radiowym 40 tysięcy dolarów – z 62.

Przy interakcji zostawiamy w modelu oba efekty główne, nawet gdy ich testy t nie są istotne. Bez $\beta_1 X_1$ model wymusza zerowe nachylenie względem X_1 w punkcie $X_2 = 0$, a położenie zera na skali X_2 bywa umowne. Z tego samego powodu β_1 w modelu (6.18) jest nachyleniem przy $X_2 = 0$, a nie przeciętnym nachyleniem. Wyśrodkowanie cech zmienia jego sens, ale nie zmienia dopasowania (Zadanie 6.10).

Interakcja cechy ilościowej z jakościową ma prosty obraz. W modelu salda względem dochodu i statusu studenta bez interakcji zmienna zero-jedynkowa przesuwa prostą w górę lub w dół: dostajemy dwie **równoległe** proste. Interakcja dochodu ze zmienną zero-jedynkową pozwala prostym mieć różne nachylenia. Taki model jest równoważny dopasowaniu dwóch osobnych prostych, po jednej w każdej grupie, z tą różnicą, że obie korzystają ze wspólnego oszacowania σ^2.

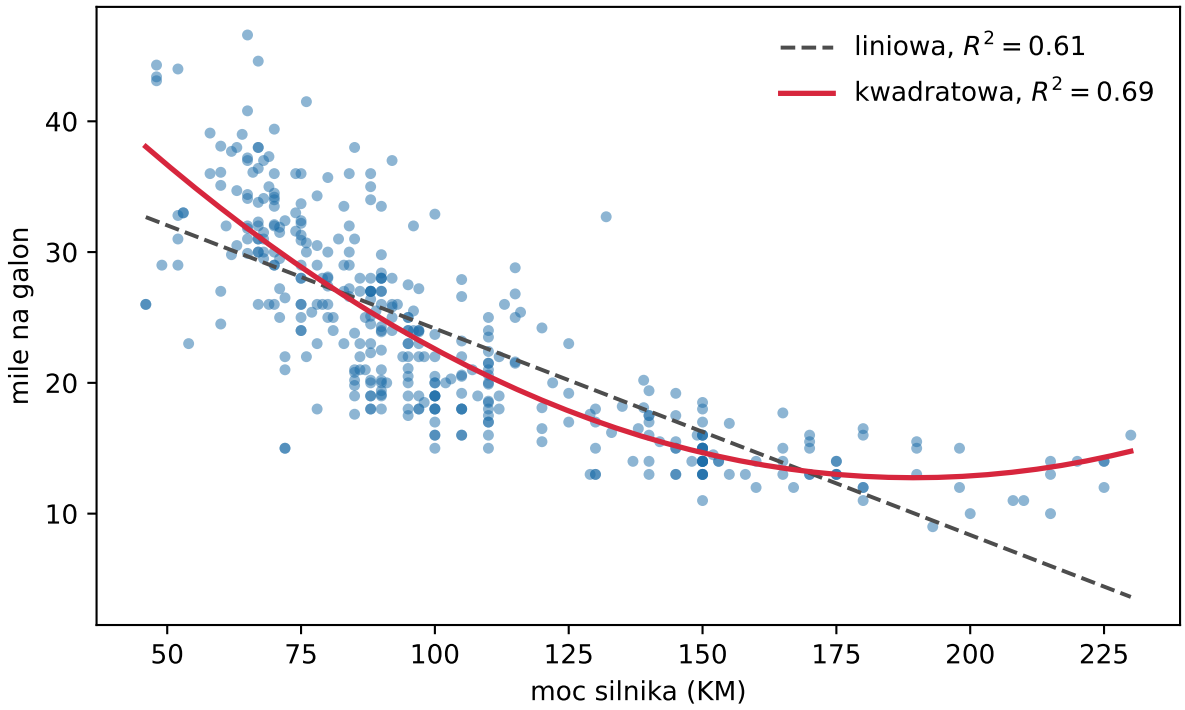


Rysunek 6.5.: Saldo karty kredytowej w zależności od dochodu dla studentów (czerwone) i pozostałych klientów (niebieskie). Po lewej: model bez interakcji, dwie równoległe proste. Po prawej: model z interakcją dochodu i statusu studenta, proste o różnych nachyleniach.

W modelu bez interakcji studenci mają przy tym samym dochodzie saldo wyższe o 383 dolary, a każdy tysiąc dolarów dochodu wiąże się z saldem wyższym o 5,98 dolara w obu grupach. Z interakcją nachylenie wynosi 6,22 dla pozostałych klientów i 4,22 dla studentów. Różnica nachyleń ma jednak $p \approx 0{,}25$, a studentów jest w próbie tylko 40: dane nie przeczą prostym równoległym.

Druga droga wyjścia poza model liniowy w cechach to ich przekształcenia. Zbiór *Auto* (James i in. 2023, rozdz. 3.3.2) opisuje 392 samochody (po usunięciu pięciu z brakującymi danymi). Zużycie paliwa, wyrażone w milach na galon (`mpg`), maleje z mocą silnika (`horsepower`) wyraźnie po

krzywej. Dodając kwadrat mocy jako cechę, dostajemy model $\texttt{mpg} = \beta_0 + \beta_1\,\texttt{hp} + \beta_2\,\texttt{hp}^2 + \varepsilon$ – regresję wielomianową z rozdziału 4, liniową w parametrach.



Rysunek 6.6.: Zasięg na galonie paliwa w zależności od mocy silnika dla 392 samochodów. Linia przerywana: regresja liniowa; linia ciągła: regresja z kwadratem mocy.

Składnik kwadratowy podnosi R^2 z 0,61 do 0,69, a jego statystyka t wynosi około 10. Wybór przekształceń – które potęgi, logarytmy, interakcje – jest jednak wyborem klasy modeli i podlega kompromisowi z rozdziału 4: każda dodana kolumna zmniejsza RSS na próbie i zwiększa wariancję. O tym, ile złożoności się opłaca, rozstrzyga walidacja z rozdziału 5, a nie R^2.

6.8. Diagnostyka modelu

Wnioskowanie z sekcji 6.4 opiera się na założeniach (Z1)–(Z3). Nie obserwujemy błędów ε_i, więc założenia sprawdzamy na resztach. Reszty nie są jednak kopiami błędów. Z dowodu twierdzenia 6.3 $\mathbf{e} = (\mathbf{I} - \mathbf{H})\varepsilon$, więc przy (Z1)–(Z2)

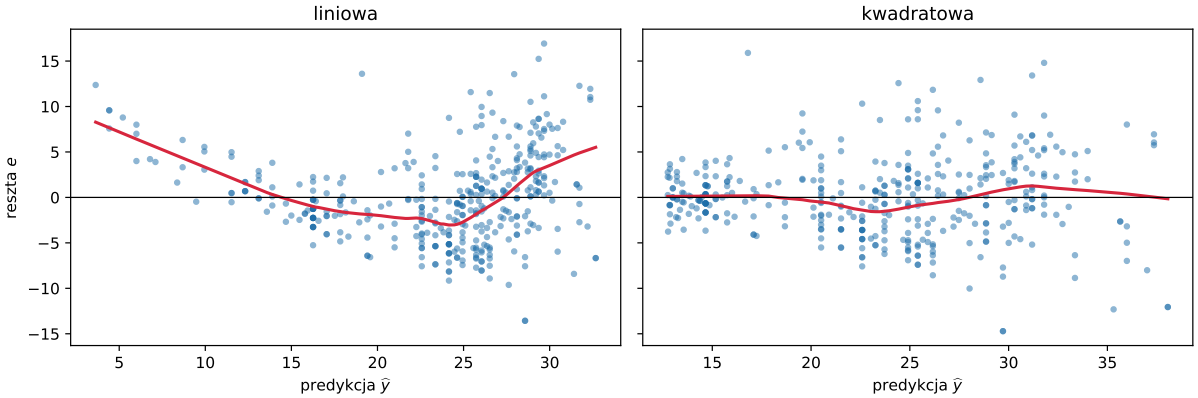
$$\operatorname{Cov} \mathbf{e} = \sigma^2(\mathbf{I} - \mathbf{H}), \qquad \operatorname{Var} e_i = \sigma^2(1 - h_{ii}). \tag{6.19}$$

Reszty są skorelowane i mają różne wariancje, nawet gdy błędy są niezależne i jednakowe. Najmniejsze są reszty obserwacji o dużej dźwigni h_{ii}, bo dopasowanie przyciąga się do nich najmocniej. **Reszta standaryzowana** $r_i = e_i/(\hat{\sigma}\sqrt{1 - h_{ii}})$ usuwa tę nierówność. Gdy n jest duże w porównaniu z p, dźwignie są małe, średnio $(p+1)/n$, i reszty zachowują się prawie jak błędy.

6.8.1. Brak liniowości

Reszty są w próbie prostopadłe do $\mathcal{C}(\mathbf{X})$, a więc nieskorelowane z predykcjami $\hat{y}_i$. Jeśli model jest trafny, wykres reszt względem predykcji powinien być bezkształtnym pasem wokół zera. Struktura – łuk, lejek – świadczy, że średnia reszt zależy od $\hat{y}$, czyli że $\mathbb{E}[\varepsilon \mid \mathbf{X}] \neq 0$ i założenie

(Z1) nie jest spełnione. Rysujemy reszty względem predykcji, a nie względem każdej cechy, bo działa to dla dowolnej liczby cech.



Rysunek 6.7.: Reszty w zależności od predykcji dla danych *Auto*. Po lewej: regresja liniowa względem mocy; po prawej: regresja z kwadratem mocy. Czerwona linia to wygładzenie lokalną regresją (LOWESS).

W modelu liniowym reszty układają się w wyraźny łuk: dla małych i dużych predykcji są przeważnie dodatnie, dla średnich – ujemne. Model systematycznie zawyża zasięg samochodów o średniej mocy i zaniża go na krańcach. Po dodaniu kwadratu mocy łuk prawie znika. Widać natomiast, że rozrzut reszt rośnie z predykcją, czym zajmiemy się przy heteroskedastyczności.

6.8.2. Skorelowane błędy

Założenie (Z2) wymaga, by błędy były nieskorelowane. Typowo nie są, gdy obserwacje są uporządkowane w czasie – błąd w jednym miesiącu jest podobny do błędu w poprzednim – albo zgrupowane, jak pomiary tego samego pacjenta czy uczniowie tej samej klasy. Dodatnio skorelowane obserwacje częściowo powtarzają tę samą informację, więc próba jest efektywnie mniejsza, niż wskazuje n.

Dowód nieobciążoności w twierdzeniu 6.2 korzystał tylko z (Z1), więc $\hat{\beta}$ pozostaje nieobciążony. Ten sam rachunek daje jednak w ogólności

$$\operatorname{Cov}\hat{\beta} = \mathbf{A}\Sigma\mathbf{A}^{\top} = (\mathbf{X}^{\top}\mathbf{X})^{-1}\mathbf{X}^{\top}\Sigma\mathbf{X}(\mathbf{X}^{\top}\mathbf{X})^{-1}, \qquad \Sigma = \operatorname{Cov}\varepsilon, \tag{6.20}$$

i tylko przy $\Sigma = \sigma^2\mathbf{I}$ upraszcza się do $\sigma^2(\mathbf{X}^{\top}\mathbf{X})^{-1}$. Klasyczne błędy standardowe szacują niewłaściwą wielkość. Sprawdźmy to na symulacji: $n = 100$ kolejnych pomiarów w czasie $t_i = i/n$, prosta $y_i = 1 + 2t_i + \varepsilon_i$ i błędy autoregresyjne $\varepsilon_i = 0{,}8\,\varepsilon_{i-1} + z_i$, gdzie z_i są niezależne i standardowe normalne.

```
średnia nachylenia:              2.032
odchylenie std. nachylenia:      1.626
średni klasyczny błąd std.:      0.529
pokrycie przedziału 95%:         0.475
```

Nachylenie jest szacowane bez obciążenia, ale jego rzeczywiste odchylenie standardowe jest około trzy razy większe od błędu standardowego podawanego przez klasyczny wzór, a przedział „95%” pokrywa prawdziwą wartość w mniej niż połowie prób. Rachunek dla średniej z próby (Zadanie 6.14) wyjaśnia ten czynnik: przy $\rho = 0{,}8$ sto obserwacji niesie tyle informacji co około jedenaście niezależnych. Skorelowanie widać na wykresie reszt w kolejności czasu, gdzie sąsiednie reszty

mają podobne wartości. Rozwiązaniem jest modelowanie zależności albo błędy standardowe szacowane ze wzoru (6.20) z estymatorem Σ dopuszczającym korelację sąsiednich obserwacji w czasie lub obserwacji w tej samej grupie.

6.8.3. Heteroskedastyczność

Założenie (Z2) wymaga też jednakowej wariancji błędów (**homoskedastyczności**). W danych *Advertising* wariancja rośnie z budżetem telewizyjnym (rysunek 6.2), a w danych *Auto* – z predykcją (rysunek 6.7). Taką sytuację nazywamy **heteroskedastycznością**. Skutki są te same co przy skorelowanych błędach: $\widehat{\beta}$ jest nieobciążony, ale klasyczne błędy standardowe są niepoprawne, a MNK przestaje być najlepszym liniowym estymatorem nieobciążonym.

Przy niezależnych błędach o wariancjach σ_i^2 macierz Σ jest diagonalna, a środek wzoru (6.20) ma postać $\sum_i \sigma_i^2\, \tilde{\mathbf{x}}_i \tilde{\mathbf{x}}_i^\top$. Nie znamy σ_i^2, ale nie musimy ich znać osobno. Środkowa macierz jest sumą n składników wymiaru $(p+1)\times(p+1)$, a sumy uśredniają. White (1980) pokazał, że zastąpienie σ_i^2 przez e_i^2 daje zgodny estymator $\operatorname{Cov}\widehat{\beta}$, choć każde e_i^2 osobno jest bardzo złym oszacowaniem σ_i^2. Tak powstają **odporne błędy standardowe** (ang. *heteroskedasticity-consistent*, HC), nazywane od kształtu wzoru (6.20) estymatorem kanapkowym. Reszty są systematycznie mniejsze od błędów, zwłaszcza przy dużej dźwigni (6.19), więc w małych próbach lepiej działa wariant HC3, w którym e_i^2 zastępuje się przez $e_i^2/(1-h_{ii})^2$, czyli kwadrat reszty „pozostaw jeden” z zadania 6.3 (MacKinnon i White 1985). W `statsmodels` wystarczy wywołać `fit(cov_type="HC3")`.

Symulacja pokazuje, kiedy różnica jest istotna. Niech cecha ma rozkład jednostajny na $[-5,5]$, $y_i = 1 + 0{,}5\,x_i + \varepsilon_i$, a odchylenie standardowe błędu wynosi $0{,}2\,x_i^2$, czyli rośnie ku krańcom przedziału.

```
n =   30:  pokrycie klasyczne 0.843,  HC3 0.940
n =  100:  pokrycie klasyczne 0.812,  HC3 0.941
n = 1000:  pokrycie klasyczne 0.807,  HC3 0.952
```

Klasyczny przedział pokrywa nachylenie w około 80% prób i nie poprawia się z rosnącym n, bo jego błąd nie jest losowy, lecz systematyczny. Przedział z błędem HC3 trzyma poziom bliski 95%. Klasyczny wzór zawodzi tu szczególnie, bo wariancja jest największa tam, gdzie dźwignia: nachylenie wyznaczają głównie punkty skrajne, a te są najbardziej zaszumione. Gdyby wariancja zmieniała się niezależnie od położenia punktów, klasyczne błędy standardowe byłyby prawie poprawne.

W danych *Advertising* odporne błędy standardowe nie zmieniają wniosków, ale zmieniają szerokość przedziałów. W modelu z telewizją i radiem błąd standardowy współczynnika przy telewizji rośnie z 0,00139 do 0,00195, a przy radiu z 0,0080 do 0,0102.

Gdy wariancje σ_i^2 są znane z dokładnością do stałej, można zrobić więcej: minimalizować ważoną sumę kwadratów $\sum_i (y_i - \tilde{\mathbf{x}}_i^\top \beta)^2/\sigma_i^2$. Jest to MNK dla danych podzielonych przez σ_i, które spełniają (Z2), więc z twierdzenia Gaussa–Markowa **ważona MNK** jest najlepszym liniowym estymatorem nieobciążonym. W praktyce wag zwykle nie znamy. Gdy rozrzut rośnie proporcjonalnie do poziomu wyniku, często pomaga modelowanie $\log Y$ zamiast Y (Zadanie 6.15).

6.8.4. Obserwacje odstające i wpływowe

Pojedyncza obserwacja może być nietypowa na dwa sposoby. **Obserwacja odstająca** ma nietypowy wynik: leży daleko od dopasowania, czyli ma dużą resztę. **Obserwacja o dużej dźwigni** ma nietypowe cechy: leży daleko od pozostałych w przestrzeni cech. Dźwignie sumują się do $p+1$, więc średnio wynoszą $(p+1)/n$. Dla jednej cechy $h_{ii} = 1/n + (x_i - \bar{x})^2 / \sum_k (x_k - \bar{x})^2$ (Zadanie 6.2) rośnie z odległością od średniej. Za dużą zwykle uznaje się dźwignię przekraczającą dwukrotność średniej (Belsley i in. 1980).

Do wykrywania obserwacji odstających reszta standaryzowana ma wadę: odstająca obserwacja zawyża $\hat{\sigma}$ i tym samym zaniża własną resztę standaryzowaną. **Reszta studentyzowana**

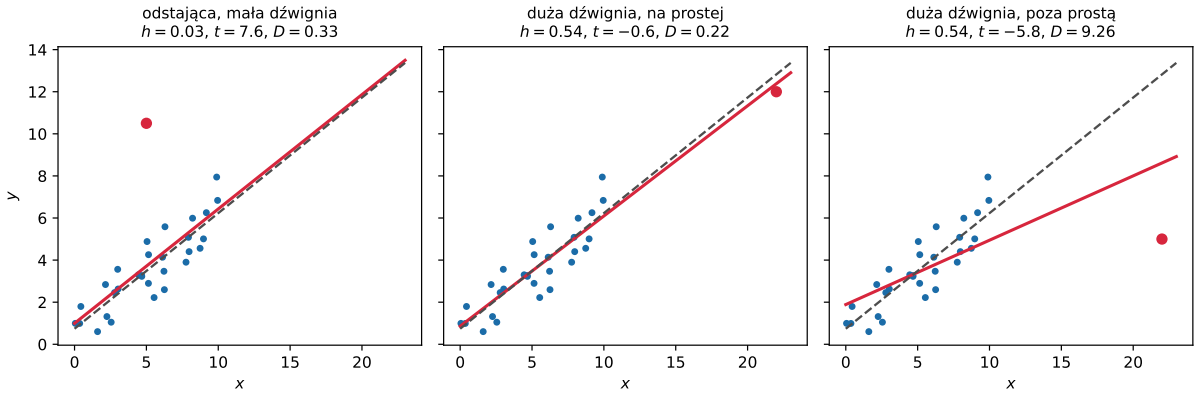
$$t_i = \frac{e_i}{\hat{\sigma}_{(-i)}\sqrt{1-h_{ii}}} \tag{6.21}$$

używa oszacowania $\hat{\sigma}_{(-i)}$ z dopasowania bez obserwacji i. Jest to reszta „pozostaw jeden" podzielona przez oszacowanie jej odchylenia standardowego (Zadanie 6.11), a przy (Z1)–(Z3) ma rozkład t z $n-p-2$ stopniami swobody. Wartości $|t_i| > 3$ są podejrzane. Przy wielu obserwacjach kilka wartości powyżej 2 jest jednak normalne, z tego samego powodu co kilka „istotnych" cech-szumów w sekcji 6.4.

Obserwacja jest **wpływowa**, jeśli jej usunięcie wyraźnie zmienia dopasowanie. Mierzy to **odległość Cooka** (Cook 1977)

$$D_i = \frac{\|\mathbf{X}(\hat{\beta} - \hat{\beta}^{(-i)})\|^2}{(p+1)\,\hat{\sigma}^2} = \frac{e_i^2}{(p+1)\,\hat{\sigma}^2} \cdot \frac{h_{ii}}{(1-h_{ii})^2}. \tag{6.22}$$

Licznik to zmiana wektora predykcji po usunięciu obserwacji i. Druga postać wynika ze wzoru na $\hat{\beta} - \hat{\beta}^{(-i)}$ z zadania 6.3, bo $\|\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\tilde{\mathbf{x}}_i\|^2 = \tilde{\mathbf{x}}_i^\top(\mathbf{X}^\top\mathbf{X})^{-1}\tilde{\mathbf{x}}_i = h_{ii}$ (Zadanie 6.12). Wpływ jest więc iloczynem dwóch czynników: wielkości reszty i dźwigni. Obserwacja odstająca o małej dźwigni przesuwa prostą niewiele. Obserwacja o dużej dźwigni leżąca na prostej też nie, a nawet zmniejsza błędy standardowe, bo poszerza zakres cechy. Groźna jest obserwacja, która ma dużą dźwignię i nie pasuje do pozostałych.



Rysunek 6.8.: Trzy rodzaje nietypowych obserwacji, dodanych (czerwony punkt) do 30 obserwacji z modelu $y = 1 + 0{,}5\,x + \varepsilon$. Linia ciągła: prosta MNK ze wszystkimi obserwacjami; przerywana: bez czerwonego punktu. W tytułach: dźwignia h, reszta studentyzowana t i odległość Cooka D dodanego punktu.

Rysunek 6.8 pokazuje trzy przypadki. W pierwszym punkt ma dużą resztę studentyzowaną, ale leży blisko średniej x, więc prosta przesuwa się tylko nieznacznie w górę. W drugim punkt ma

dużą dźwignię, ale zgadza się z resztą danych i prawie nic nie zmienia. W trzecim duża dźwignia i niedopasowanie razem przechylają prostą, a odległość Cooka jest wielokrotnie większa niż w dwóch pozostałych przypadkach.

Wykrytej obserwacji nie należy automatycznie usuwać. Najpierw trzeba ustalić, skąd się wzięła. Błąd zapisu poprawiamy lub usuwamy. Prawdziwa, ale nietypowa obserwacja może świadczyć, że model nie obowiązuje w całym zakresie cech, na przykład że zależność zakrzywia się na krańcach. Wtedy uczciwie jest pokazać wyniki z tą obserwacją i bez niej albo zawęzić zakres, dla którego formułujemy wnioski.

6.8.5. Współliniowość

W zadaniu 6.8 wyprowadzamy wzór $\operatorname{Var}\hat{\beta}_j = \sigma^2/\|\mathbf{r}_j\|^2$, gdzie $\mathbf{r}_j$ to reszty z regresji cechy j względem pozostałych cech. Jeśli R_j^2 oznacza współczynnik determinacji tej regresji, to z rozkładu (6.16) $\|\mathbf{r}_j\|^2 = (1-R_j^2)\sum_i (x_{ij}-\bar{x}_j)^2$, a więc

$$\operatorname{Var}\hat{\beta}_j = \frac{\sigma^2}{\sum_{i=1}^n (x_{ij}-\bar{x}_j)^2} \cdot \frac{1}{1-R_j^2}. \tag{6.23}$$

Pierwszy czynnik to wariancja, jaką $\hat{\beta}_j$ miałby w regresji prostej, czyli gdyby pozostałe cechy były nieskorelowane z cechą j. Drugi, $\mathrm{VIF}_j = 1/(1-R_j^2)$, nazywa się **czynnikiem inflacji wariancji** (ang. *variance inflation factor*). Mówi, ile razy wariancja rośnie dlatego, że cechę j da się przewidzieć z pozostałych. Do oszacowania β_j służy tylko ta część cechy, której pozostałe cechy nie wyjaśniają. Gdy R_j^2 zbliża się do 1, tej części prawie nie ma, a VIF_j rośnie nieograniczenie. Silną zależność liniową między cechami nazywamy **współliniowością**.

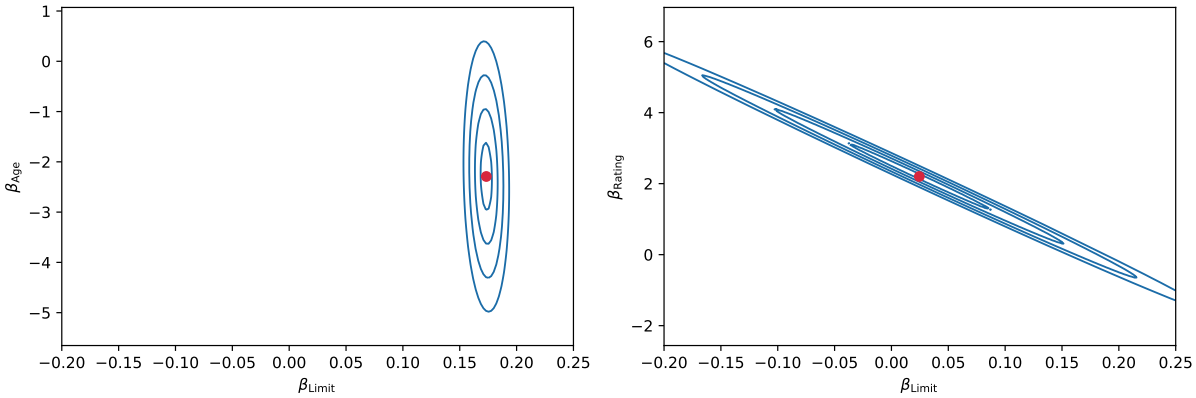
W danych *Credit* limit kredytowy i ocena kredytowa mają korelację 0,997: ocena jest w praktyce liniową funkcją limitu. Porównajmy dwa modele salda: z limitem i wiekiem oraz z limitem i oceną.

		wsp
Limit + Age	Limit	0.1
	Age	-2.2
Limit + Rating	Limit	0.0
	Rating	2.2

Oba modele dopasowują się tak samo dobrze ($R^2 \approx 0{,}75$). Błąd standardowy współczynnika przy limicie jest jednak w drugim modelu prawie trzynaście razy większy, a sam limit przestaje być istotny ($p \approx 0{,}70$), choć w pierwszym modelu ma statystykę t ponad 30. Rysunek 6.9 pokazuje przyczynę.

Przy limicie i wieku poziomice są małymi elipsami: każda zmiana któregokolwiek współczynnika szybko zwiększa RSS, więc oba są dobrze wyznaczone. Przy limicie i ocenie poziomice tworzą długą, wąską dolinę. Wzdłuż niej zwiększenie współczynnika przy limicie i odpowiednie zmniejszenie współczynnika przy ocenie prawie nie zmienia predykcji, bo obie cechy są niemal proporcjonalne. Dane wyznaczają dokładnie pewną kombinację obu współczynników, ale nie każdy z nich z osobna.

Współliniowość szkodzi więc interpretacji współczynników, a nie predykcji: w obu modelach predykcje dla klientów podobnych do tych z próby są prawie takie same. To sytuacja z sekcji 1.7, w której metraż i liczba pokoi pozwalają dobrze przewidywać cenę, ale nie pozwalają rozdzielić ich



Rysunek 6.9.: Poziomice RSS jako funkcji dwóch współczynników regresji salda dla danych *Credit* (wyraz wolny dobrany optymalnie dla każdej pary). Po lewej: limit i wiek; po prawej: limit i ocena kredytowa. Punkt: minimum RSS. Poziomice odpowiadają wzrostowi RSS o $1, 4, 9$ i 16 wartości $\hat{\sigma}^2$. Oś pozioma ma w obu panelach tę samą skalę.

wpływu. Współliniowość kilku cech nie musi przy tym być widoczna w korelacjach par (Zadanie 6.13). Czynnik VIF ją wykrywa, bo R_j^2 mierzy zależność cechy j od wszystkich pozostałych naraz.

```
Limit     160.59
Age         1.01
Rating    160.67
Name: VIF, dtype: float64
```

Wartości VIF rzędu 160 dla limitu i oceny oznaczają, że wariancje ich współczynników są około 160 razy większe niż przy cechach nieskorelowanych, a błędy standardowe – około 13 razy większe. Wiek, prawie niezależny od obu, ma VIF bliski 1. Typowe rozwiązania to usunięcie jednej z cech, zastąpienie ich wspólną cechą albo ściąganie współczynników, jak w przypadku estymatora $c\bar{Y}$ z sekcji 4.3.

Uwagi bibliograficzne

Regresję liniową w ujęciu bliskim temu rozdziałowi wykładają James i in. (2023, rozdz. 3.1–3.2), także na danych *Advertising*. Hastie i in. (2009, rozdz. 3.2) podają geometrię najmniejszych kwadratów, twierdzenie Gaussa–Markowa (Hastie i in. 2009, rozdz. 3.2.2) oraz interpretację współczynników regresji wielokrotnej przez kolejne regresje na resztach, wykorzystaną w zadaniu 6.8 (Hastie i in. 2009, rozdz. 3.2.3). Geometryczny obraz MNK jako rzutu ortogonalnego rysuje też Bishop (2006, rozdz. 3.1), który wyprowadza MNK jako metodę największej wiarygodności przy normalnych błędach. Ślad macierzy wygładzającej jako efektywną liczbę parametrów omawiają Hastie i in. (2009, rozdz. 7.6).

Pełne dowody faktów, które tu tylko naszkicowaliśmy – rozkładów $\widehat{\beta}$ i RSS, ich niezależności, testu F dla dowolnych hipotez liniowych – zawierają Seber i Lee (2003). Rozkład normalny wielowymiarowy i formy kwadratowe wykładają w rozdz. 2, estymację w rozdz. 3, a testowanie hipotez w rozdz. 4.

Cechy jakościowe, interakcje, przekształcenia cech i przegląd problemów modelu liniowego, od nieliniowości po współliniowość, omawiają James i in. (2023, rozdz. 3.3). Diagnostykę wpływu pojedynczych obserwacji i współliniowości systematycznie wykładają Belsley i in. (1980); odległość Cooka pochodzi od Cook (1977). Estymator kowariancji odporny na heteroskedastyczność wprowadził White (1980), a jego warianty o lepszych własnościach w małych próbach, w tym HC3, porównali MacKinnon i White (1985).

Zadania

Zadanie 6.1. Rozważ regresję z jedną cechą, $p = 1$.

a) Z równań normalnych wyprowadź wzory (6.5).
b) Niech r będzie współczynnikiem korelacji z próby, a s_x, s_y – odchyleniami standardowymi z próby. Wykaż, że $\hat{\beta}_1 = r\, s_y / s_x$. Wyraź prostą regresji w zmiennych standaryzowanych $(x-\bar{x})/s_x$ i $(y-\bar{y})/s_y$. Dlaczego przy $|r| < 1$ przewidywane odchylenie wyniku od średniej, mierzone w odchyleniach standardowych, jest zawsze mniejsze niż odchylenie cechy?
c) Wykaż, że $R^2 = r^2$.
d) Odwracając macierz $\mathbf{X}^\top\mathbf{X}$ wymiaru 2×2, wyprowadź (6.9).
e) Niech para (X, Y) ma skończone drugie momenty i $\operatorname{Var} X > 0$. Znajdź a, b minimalizujące $\mathbb{E}[(Y - a - bX)^2]$ i porównaj wynik z (6.5).
f) Przy założeniach (Z1)–(Z2) wykaż, że $\mathbb{E}[\mathrm{ESS}] = \beta_1^2 \sum_i (x_i - \bar{x})^2 + \sigma^2$. (Wskazówka: $\mathrm{ESS} = \hat{\beta}_1^2 \sum_i (x_i - \bar{x})^2$.) Jak zmienia się typowa wartość R^2, gdy rozrzut x_i rośnie, a β_1 i σ są ustalone?

Zadanie 6.2. Niech $\mathbf{H}$ będzie macierzą daszkową (6.6).

a) Wykaż, że $\mathbf{H}^\top = \mathbf{H}$, $\mathbf{H}^2 = \mathbf{H}$ i $\mathbf{HX} = \mathbf{X}$. Wywnioskuj, że $\mathbf{H1} = \mathbf{1}$, czyli że każda predykcja $\hat{y}_i$ jest kombinacją wyników $y_1, \ldots, y_n$ o wagach sumujących się do jedynki. Czy wagi te muszą być nieujemne?
b) Wykaż, że $0 \le h_{ii} \le 1$. (Wskazówka: z $\mathbf{H} = \mathbf{H}^2 = \mathbf{H}^\top\mathbf{H}$ wynika $h_{ii} = \sum_j h_{ij}^2$.)
c) Dla jednej cechy wykaż, że $h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_k (x_k - \bar{x})^2}$. Które obserwacje mają największy wpływ na własne dopasowanie?
d) Porównaj własności z punktów (a)–(b) z macierzą $\mathbf{S}$ regresji k-NN z sekcji 5.4. Czym różnią się wagi w obu metodach?

Zadanie 6.3. Niech $\hat{\beta}^{(-i)}$ będzie estymatorem MNK wyznaczonym bez obserwacji i, a $\tilde{\mathbf{x}}_i^\top$ – i-tym wierszem $\mathbf{X}$.

a) Korzystając ze wzoru Shermana–Morrisona $(\mathbf{M} - \mathbf{u}\mathbf{u}^\top)^{-1} = \mathbf{M}^{-1} + \frac{\mathbf{M}^{-1}\mathbf{u}\mathbf{u}^\top\mathbf{M}^{-1}}{1 - \mathbf{u}^\top\mathbf{M}^{-1}\mathbf{u}}$, wykaż, że

$$\hat{\beta} - \hat{\beta}^{(-i)} = \frac{(\mathbf{X}^\top\mathbf{X})^{-1}\tilde{\mathbf{x}}_i\, e_i}{1 - h_{ii}}.$$

b) Wywnioskuj, że reszta „pozostaw jeden” wynosi $y_i - \tilde{\mathbf{x}}_i^\top \hat{\beta}^{(-i)} = e_i/(1 - h_{ii})$, i zapisz błąd LOOCV metody najmniejszych kwadratów przez reszty i dźwignie jednego dopasowania. Jest to wzór, na który powołaliśmy się w sekcji 5.4.
c) Sprawdź wynik numerycznie dla regresji sprzedaży względem `TV` i `radio`, porównując go z n jawnymi dopasowaniami.
d) Które obserwacje mają resztę „pozostaw jeden” najbardziej różną od zwykłej reszty?

Zadanie 6.4. Przy założeniach (Z1)–(Z2) niech Y_i' będzie nową obserwacją wyniku w punkcie $\mathbf{x}_i$, niezależną od próby i o tym samym rozkładzie co Y_i.

a) Wykaż, że $\sum_{i=1}^n \operatorname{Cov}(Y_i, \hat{y}_i) = \sigma^2(p+1)$.
b) Wykaż, że

$$\mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^n (Y_i' - \hat{y}_i)^2\Big] = \sigma^2\Big(1 + \frac{p+1}{n}\Big), \qquad \mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^n (Y_i - \hat{y}_i)^2\Big] = \sigma^2\Big(1 - \frac{p+1}{n}\Big),$$

więc optymizm błędu uczącego wynosi $2\sigma^2(p+1)/n$.
c) Porównaj wynik z zadaniem 4.4, zapisując optymizm metody k-NN przez efektywną liczbę parametrów n/k.
d) Ile cech można dodać do modelu przy $n = 100$, żeby błąd uczący zaniżał błąd na nowych obserwacjach w tych samych punktach o nie więcej niż 10% wartości σ^2?

Zadanie 6.5.

a) Niech ε ma średnią $\mathbf{0}$ i macierz kowariancji $\sigma^2\mathbf{I}$, a $\mathbf{M}$ będzie ustaloną macierzą. Wykaż, że $\mathbb{E}[\varepsilon^\top \mathbf{M}\varepsilon] = \sigma^2 \operatorname{tr}\mathbf{M}$. Czy potrzebna jest normalność?
b) Wykaż, że dla modelu z samym wyrazem wolnym ($p = 0$) estymator (6.12) jest wariancją z próby z mianownikiem $n-1$.
c) Przeprowadź symulację z rysunku 6.3 dla modelu wielomianowego stopnia $d = 1, 5, 15$ przy $n = 30$, w którym prawdziwa funkcja regresji jest prostą. Porównaj średnie RSS/n i $\mathrm{RSS}/(n-d-1)$ po próbach z σ^2.

Zadanie 6.6. Niech $Y_i = \mu + \varepsilon_i$, $i = 1, \ldots, n$, z nieskorelowanymi błędami o średniej zero.

a) Wykaż, że estymatorem MNK parametru μ jest $\bar{Y}$.
b) Estymator liniowy $\sum_i c_i Y_i$ jest nieobciążony wtedy i tylko wtedy, gdy $\sum_i c_i = 1$. Przy $\operatorname{Var}\varepsilon_i = \sigma^2$ wykaż bezpośrednio, bez twierdzenia 6.4, że jego wariancja jest najmniejsza dla $c_i = 1/n$.
c) Estymator $c\bar{Y}$ z sekcji 4.3 może mieć mniejszy błąd średniokwadratowy niż $\bar{Y}$. Dlaczego nie przeczy to twierdzeniu Gaussa–Markowa?
d) Niech teraz $\operatorname{Var}\varepsilon_i = \sigma_i^2$ będą różne i znane. Znajdź najlepszy liniowy estymator nieobciążony μ. Ile razy mniejszą wariancję ma od $\bar{Y}$, gdy połowa obserwacji ma wariancję 1, a połowa 9?

Zadanie 6.7. Przyjmij układ z rysunku 6.3: ustalone x_i z rozkładu jednostajnego na $[0, 10]$, $y_i = 1 + 0{,}5\, x_i + \varepsilon_i$. Dla $n = 20$ i $n = 500$ oszacuj na 10 000 próbach, jak często przedział (6.14) na poziomie 95% zawiera β_1, gdy

a) $\varepsilon_i \sim \mathcal{N}(0, 1{,}5^2)$;
b) ε_i ma scentrowany rozkład wykładniczy o odchyleniu standardowym 1,5 (rozkład silnie skośny);
c) $\varepsilon_i \sim \mathcal{N}(0, (0{,}3\, x_i)^2)$, czyli wariancja błędu rośnie z x, jak w danych *Advertising*.

Które z założeń (Z1)–(Z3) jest naruszone w każdym przypadku? Dlaczego w przypadku (b) zwiększenie n pomaga, a w przypadku (c) nie? Porównaj w przypadku (c) odchylenie standardowe $\hat{\beta}_1$ z symulacji ze średnią $\mathrm{SE}(\hat{\beta}_1)$ podawaną przez wzór.

Zadanie 6.8. Niech $\mathbf{x}_j$ będzie kolumną j macierzy $\mathbf{X}$, $\mathbf{X}_{-j}$ – macierzą bez tej kolumny, a $\mathbf{r}_j$ – wektorem reszt z regresji $\mathbf{x}_j$ względem kolumn $\mathbf{X}_{-j}$.

a) Dla danych *Advertising* wyznacz reszty z regresji `newspaper` względem `TV` i `radio`, a potem współczynnik kierunkowy regresji `sales` względem tych reszt. Porównaj go ze współczynnikiem przy `newspaper` w modelu z trzema mediami.
b) Wykaż w ogólności, że $\hat{\beta}_j = \langle \mathbf{r}_j, \mathbf{y} \rangle / \|\mathbf{r}_j\|^2$. (Wskazówka: zapisz $\mathbf{y} = \mathbf{X}_{-j}\hat{\gamma} + \hat{\beta}_j \mathbf{x}_j + \mathbf{e}$ i pomnóż skalarnie przez $\mathbf{r}_j$. Wektor $\mathbf{r}_j$ jest prostopadły do kolumn $\mathbf{X}_{-j}$ i leży w $\mathcal{C}(\mathbf{X})$.)
c) Wywnioskuj, że $\operatorname{Var} \hat{\beta}_j = \sigma^2 / \|\mathbf{r}_j\|^2$. Co się dzieje z dokładnością oszacowania β_j, gdy cechę X_j da się dobrze przewidzieć z pozostałych cech? Odnieś to do przykładu z metrażem i liczbą pokoi z sekcji 1.7.
d) Wykaż, że $\mathrm{RSS}_0 - \mathrm{RSS} = \hat{\beta}_j^2 \|\mathbf{r}_j\|^2$, gdzie RSS_0 dotyczy modelu bez cechy j, i wywnioskuj, że statystyka (6.15) dla $q = 1$ jest kwadratem statystyki t.

Zadanie 6.9. Niech cecha binarna dzieli próbę na grupy 0 i 1 o licznościach n_0, n_1 i średnich wyników $\bar{y}_0$, $\bar{y}_1$.

a) Przy kodowaniu 0/1 wykaż, że $\hat{\beta}_0 = \bar{y}_0$ i $\hat{\beta}_1 = \bar{y}_1 - \bar{y}_0$.
b) Wyznacz współczynniki przy kodowaniu $-1/+1$ i wykaż, że predykcje są takie same. Sprawdź oba kodowania dla cechy `Own` w danych *Credit*.
c) Dla cechy o K poziomach wskaż niezerowy wektor $\mathbf{v}$, dla którego $\mathbf{X}\mathbf{v} = \mathbf{0}$, gdy w modelu jest wyraz wolny i K zmiennych zero-jedynkowych. Co oznaczają współczynniki modelu bez wyrazu wolnego, z K zmiennymi zero-jedynkowymi?
d) Wykaż, że statystyka t dla β_1 z punktu (a) jest statystyką testu t dla dwóch prób z łączną wariancją.

Zadanie 6.10. Rozważ model z interakcją (6.18) i podstaw $X_1 = \tilde{X}_1 + c_1$, $X_2 = \tilde{X}_2 + c_2$.

a) Wyraź współczynniki modelu w zmiennych $\tilde{X}_1$, $\tilde{X}_2$ przez $\beta_0, \ldots, \beta_3$. Wykaż, że współczynnik interakcji się nie zmienia, a przy $\tilde{X}_1$ stoi $\beta_1 + \beta_3 c_2$.
b) Jak interpretować współczynnik przy $\tilde{X}_1$, gdy c_2 jest średnią X_2 w próbie?
c) Dopasuj model z interakcją dla danych *Advertising* z wyśrodkowanymi budżetami. Porównaj współczynniki, błędy standardowe i predykcje z modelem bez wyśrodkowania. Które wielkości się zmieniły, a które nie?

Zadanie 6.11.

a) Wyprowadź (6.19). Dlaczego reszta obserwacji o dźwigni bliskiej 1 jest bliska zera bez względu na jej wynik?
b) Korzystając z zadania 6.3, wykaż, że wariancja reszty „pozostaw jeden” $y_i - \tilde{\mathbf{x}}_i^\top \hat{\beta}^{(-i)}$ wynosi $\sigma^2/(1-h_{ii})$. Wywnioskuj, że reszta „pozostaw jeden” podzielona przez swoje odchylenie standardowe to $e_i/(\sigma\sqrt{1-h_{ii}})$.
c) Dlaczego w (6.21) używamy $\hat{\sigma}_{(-i)}$, a nie $\hat{\sigma}$? Rozważ próbę z jedną bardzo odległą obserwacją odstającą.
d) Wylosuj $n = 50$ obserwacji z modelu spełniającego (Z1)–(Z3) i policz reszty studentyzowane. Ile z nich przekracza co do modułu 2, a ile powinno przekraczać przeciętnie?

Zadanie 6.12.

a) Wyprowadź drugą równość w (6.22) ze wzoru z zadania 6.3.
b) Wykaż, że $D_i = \frac{r_i^2}{p+1} \cdot \frac{h_{ii}}{1-h_{ii}}$, gdzie r_i jest resztą standaryzowaną.
c) Dla regresji salda względem dochodu, limitu i statusu studenta w danych *Credit* policz odległości Cooka ze wzoru i porównaj z `get_influence().cooks_distance` z pakietu `statsmodels`. Obejrzyj pięć najbardziej wpływowych obserwacji. Co je łączy?

Zadanie 6.13.

a) Wykaż, że $\|\mathbf{r}_j\|^2 = (1 - R_j^2) \sum_i (x_{ij} - \bar{x}_j)^2$, i wyprowadź (6.23) z zadania 6.8.
b) Wykaż, że dla dwóch cech VIF $= 1/(1 - r^2)$, gdzie r jest ich korelacją z próby. Przy jakiej korelacji VIF przekracza 10?
c) Policz VIF dla limitu, wieku i oceny w danych *Credit*, wyznaczając R_j^2 z trzech regresji pomocniczych, i porównaj z wynikiem funkcji `variance_inflation_factor`.
d) Niech X_1, X_2, X_3 będą niezależne o rozkładzie $\mathcal{N}(0, 1)$, a $X_4 = X_1 + X_2 + X_3 + 0{,}1\, Z$ z niezależnym $Z \sim \mathcal{N}(0, 1)$. Wyznacz korelacje par cech i VIF cechy X_4. Sprawdź wynik na symulacji.

Zadanie 6.14. Niech $Y_t = \mu + \varepsilon_t$, $t = 1, \ldots, n$, gdzie $\operatorname{Cov}(\varepsilon_s, \varepsilon_t) = \sigma^2 \rho^{|s-t|}$ dla $|\rho| < 1$.

a) Wykaż, że $\operatorname{Var} \bar{Y} = \frac{\sigma^2}{n}\left[1 + 2\sum_{k=1}^{n-1}\left(1 - \frac{k}{n}\right)\rho^k\right]$, i że dla dużego n jest to w przybliżeniu $\frac{\sigma^2}{n} \cdot \frac{1+\rho}{1-\rho}$.
b) **Efektywną licznością próby** nazwijmy liczbę niezależnych obserwacji, których średnia ma tę samą wariancję. Ile wynosi ona dla $n = 100$ i $\rho = 0{,}8$? A dla $\rho = -0{,}5$?
c) Przyjmij bez dowodu, że dla dużego n wariancja z próby s^2 jest bliska σ^2. Ile razy klasyczny błąd standardowy $s/\sqrt{n}$ zaniża odchylenie standardowe $\bar{Y}$ przy $\rho = 0{,}8$? Porównaj z symulacją z sekcji 6.8.

Zadanie 6.15. Niech $\log Y = \beta_0 + \beta_1 x + \varepsilon$, gdzie $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ jest niezależne od x.

a) Wykaż, że mediana Y przy danym x wynosi $e^{\beta_0 + \beta_1 x}$, a wzrost x o jednostkę mnoży ją przez e^{β_1}. Dlaczego dla małych β_1 można to czytać jako wzrost o $100\,\beta_1$ procent?
b) Wykaż, że $\mathbb{E}[Y \mid x] = e^{\beta_0 + \beta_1 x + \sigma^2/2}$. Co się dzieje, gdy prognozę $\mathbb{E}[Y \mid x]$ liczymy jako $e^{\widehat{\beta}_0 + \widehat{\beta}_1 x}$?
c) Wykaż, że w tym modelu odchylenie standardowe Y przy danym x jest proporcjonalne do $\mathbb{E}[Y \mid x]$. Jakiego wzoru reszt modelu dla Y (zamiast $\log Y$) należy się wtedy spodziewać?
d) Dopasuj regresję log(`mpg`) względem mocy dla danych *Auto* i narysuj reszty względem predykcji. Porównaj z rysunkiem 6.7.

7. Selekcja i regularyzacja

Rozdział w przygotowaniu.

8. Regresja logistyczna

Rozdział w przygotowaniu.

9. Uogólnione modele liniowe i regresja Poissona

Rozdział w przygotowaniu.

Część III.

Podejście probabilistyczne

10. Paradygmat bayesowski

Rozdział w przygotowaniu.

11. Modele generatywne: LDA, QDA i naiwny Bayes

Rozdział w przygotowaniu.

Część IV.

Poza liniowość

12. Perceptron wielowarstwowy i propagacja wsteczna

Rozdział w przygotowaniu.

13. Maszyny wektorów nośnych

Rozdział w przygotowaniu.

Część V.

Uczenie nienadzorowane

14. Analiza składowych głównych

Rozdział w przygotowaniu.

15. Grupowanie: k-średnich, GMM i algorytm EM

Rozdział w przygotowaniu.

Bibliografia

Ambroise, Christophe i Geoffrey J. McLachlan. 2002. „Selection Bias in Gene Extraction on the Basis of Microarray Gene-Expression Data". *Proceedings of the National Academy of Sciences* 99 (10): 6562–66. https://doi.org/10.1073/pnas.102102699.

Arlot, Sylvain i Alain Celisse. 2010. „A Survey of Cross-Validation Procedures for Model Selection". *Statistics Surveys* 4: 40–79. https://doi.org/10.1214/09-SS054.

Bates, Stephen, Trevor Hastie i Robert Tibshirani. 2024. „Cross-Validation: What Does It Estimate and How Well Does It Do It?" *Journal of the American Statistical Association* 119 (546): 1434–45. https://doi.org/10.1080/01621459.2023.2197686.

Belkin, Mikhail, Daniel Hsu, Siyuan Ma i Soumik Mandal. 2019. „Reconciling Modern Machine-Learning Practice and the Classical Bias–Variance Trade-Off". *Proceedings of the National Academy of Sciences* 116 (32): 15849–54. https://doi.org/10.1073/pnas.1903070116.

Belsley, David A., Edwin Kuh i Roy E. Welsch. 1980. *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. Wiley Series in Probability and Statistics. Wiley. https://doi.org/10.1002/0471725153.

Bengio, Yoshua i Yves Grandvalet. 2004. „No Unbiased Estimator of the Variance of K-Fold Cross-Validation". *Journal of Machine Learning Research* 5: 1089–105.

Bergstra, James i Yoshua Bengio. 2012. „Random Search for Hyper-Parameter Optimization". *Journal of Machine Learning Research* 13: 281–305.

Beyer, Kevin, Jonathan Goldstein, Raghu Ramakrishnan i Uri Shaft. 1999. „When Is »Nearest Neighbor« Meaningful?" *Database Theory – ICDT'99*, Lecture Notes in Computer Science, 217–35. https://doi.org/10.1007/3-540-49257-7_15.

Bishop, Christopher M. 2006. *Pattern Recognition and Machine Learning*. Information Science and Statistics. Springer.

Box, George E. P. 1976. „Science and Statistics". *Journal of the American Statistical Association* 71 (356): 791–99. https://doi.org/10.1080/01621459.1976.10480949.

Box, George E. P. i Norman R. Draper. 1987. *Empirical Model-Building and Response Surfaces*. Wiley Series in Probability and Mathematical Statistics. Wiley.

Brier, Glenn W. 1950. „Verification of Forecasts Expressed in Terms of Probability". *Monthly Weather Review* 78 (1): 1–3. https://doi.org/10.1175/1520-0493(1950)078%3C0001:VOFEIT%3E2.0.CO;2.

Caruana, Rich, Yin Lou, Johannes Gehrke, Paul Koch, Marc Sturm i Noémie Elhadad. 2015. „Intelligible Models for HealthCare: Predicting Pneumonia Risk and Hospital 30-day Read-

mission". *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1721–30. https://doi.org/10.1145/2783258.2788613.

Cawley, Gavin C. i Nicola L. C. Talbot. 2010. „On Over-Fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation". *Journal of Machine Learning Research* 11: 2079–107.

Chow, C. K. 1970. „On Optimum Recognition Error and Reject Tradeoff". *IEEE Transactions on Information Theory* 16 (1): 41–46. https://doi.org/10.1109/TIT.1970.1054406.

Cook, R. Dennis. 1977. „Detection of Influential Observation in Linear Regression". *Technometrics* 19 (1): 15–18. https://doi.org/10.1080/00401706.1977.10489493.

Cover, Thomas M. i Peter E. Hart. 1967. „Nearest Neighbor Pattern Classification". *IEEE Transactions on Information Theory* 13 (1): 21–27. https://doi.org/10.1109/TIT.1967.1053964.

Devroye, Luc, László Györfi i Gábor Lugosi. 1996. *A Probabilistic Theory of Pattern Recognition*. Stochastic Modelling and Applied Probability 31. Springer. https://doi.org/10.1007/978-1-4612-0711-5.

Dietterich, Thomas G. 1998. „Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms". *Neural Computation* 10 (7): 1895–923. https://doi.org/10.1162/089976698300017197.

Efron, Bradley. 1979. „Bootstrap Methods: Another Look at the Jackknife". *The Annals of Statistics* 7 (1): 1–26. https://doi.org/10.1214/aos/1176344552.

Efron, Bradley. 1983. „Estimating the Error Rate of a Prediction Rule: Improvement on Cross-Validation". *Journal of the American Statistical Association* 78 (382): 316–31. https://doi.org/10.1080/01621459.1983.10477973.

Efron, Bradley i Robert Tibshirani. 1993. *An Introduction to the Bootstrap*. Monographs on Statistics and Applied Probability 57. Chapman & Hall. https://doi.org/10.1201/9780429246593.

Efron, Bradley i Robert Tibshirani. 1997. „Improvements on Cross-Validation: The .632+ Bootstrap Method". *Journal of the American Statistical Association* 92 (438): 548–60. https://doi.org/10.1080/01621459.1997.10474007.

Elkan, Charles. 2001. „The Foundations of Cost-Sensitive Learning". *Proceedings of the Seventeenth International Joint Conference on Artificial Intelligence (IJCAI)*, 973–78.

Fix, Evelyn i J. L. Hodges Jr. 1951. *Discriminatory Analysis. Nonparametric Discrimination: Consistency Properties*. Report 4, Project 21-49-004. USAF School of Aviation Medicine.

Friedman, Jerome H. 1997. „On Bias, Variance, 0/1–Loss, and the Curse-of-Dimensionality". *Data Mining and Knowledge Discovery* 1 (1): 55–77. https://doi.org/10.1023/A:1009778005914.

Geman, Stuart, Elie Bienenstock i René Doursat. 1992. „Neural Networks and the Bias/Variance

Dilemma". *Neural Computation* 4 (1): 1–58. https://doi.org/10.1162/neco.1992.4.1.1.

Gneiting, Tilmann i Adrian E. Raftery. 2007. „Strictly Proper Scoring Rules, Prediction, and Estimation". *Journal of the American Statistical Association* 102 (477): 359–78. https://doi.org/10.1198/016214506000001437.

Györfi, László, Michael Kohler, Adam Krzyżak i Harro Walk. 2002. *A Distribution-Free Theory of Nonparametric Regression*. Springer Series in Statistics. Springer. https://doi.org/10.1007/b97848.

Hastie, Trevor, Robert Tibshirani i Jerome Friedman. 2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2. wyd. Springer.

James, Gareth, Daniela Witten, Trevor Hastie, Robert Tibshirani i Jonathan Taylor. 2023. *An Introduction to Statistical Learning with Applications in Python*. Springer Texts in Statistics. Springer.

Kahneman, Daniel. 2011. *Thinking, Fast and Slow*. Farrar, Straus and Giroux.

MacKinnon, James G. i Halbert White. 1985. „Some Heteroskedasticity-Consistent Covariance Matrix Estimators with Improved Finite Sample Properties". *Journal of Econometrics* 29 (3): 305–25. https://doi.org/10.1016/0304-4076(85)90158-7.

Murphy, Kevin P. 2022. *Probabilistic Machine Learning: An Introduction*. MIT Press.

Rudin, Cynthia. 2019. „Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead". *Nature Machine Intelligence* 1 (5): 206–15. https://doi.org/10.1038/s42256-019-0048-x.

Seber, George A. F. i Alan J. Lee. 2003. *Linear Regression Analysis*. 2. wyd. Wiley Series in Probability and Statistics. Wiley. https://doi.org/10.1002/9780471722199.

Shalev-Shwartz, Shai i Shai Ben-David. 2014. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press. https://doi.org/10.1017/CBO9781107298019.

Stone, Charles J. 1977. „Consistent Nonparametric Regression". *The Annals of Statistics* 5 (4): 595–620. https://doi.org/10.1214/aos/1176343886.

Stone, Charles J. 1982. „Optimal Global Rates of Convergence for Nonparametric Regression". *The Annals of Statistics* 10 (4): 1040–53. https://doi.org/10.1214/aos/1176345969.

Stone, M. 1974. „Cross-Validatory Choice and Assessment of Statistical Predictions". *Journal of the Royal Statistical Society: Series B (Methodological)* 36 (2): 111–33. https://doi.org/10.1111/j.2517-6161.1974.tb00994.x.

Varma, Sudhir i Richard Simon. 2006. „Bias in Error Estimation When Using Cross-Validation for Model Selection". *BMC Bioinformatics* 7: 91. https://doi.org/10.1186/1471-2105-7-91.

White, Halbert. 1980. „A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity". *Econometrica* 48 (4): 817–38. https://doi.org/10.2307/1912934.